思维链提示激发大语言模型的推理能力

Jason Wei **Xuezhi Wang** **Dale Schuurmans** **Maarten Bosma**

Brian Ichter **Fei Xia** **Ed H. Chi** **Quoc V. Le** **Denny Zhou**

Google Research，Brain 团队

{jasonwei,dennyzhou}@google.com

Chain-of-Thought Prompting Elicits Reasoning in Large Language Models

中文公开版 v1.1（含定点删节）· 底本 arXiv:2201.11903v6 · 2023 年 1 月 10 日

公开版说明。本译本由 dot 于 2026 年 11 月制作，为 AI 辅助非官方中文翻译，未经原作者审校、授权背书或认可。正文、方法、公式、统计结果及作者自有图表保留；对尚未核清再分发许可的第三方示例作定点删节，保留其编号与研究分析。中文重排、翻译、删节与许可补充均为改动；中文提示不等同于原实验英文提示。原文示例中的错误推理按研究记录保留。删节与第三方归属见文末“公开版许可与范围”。

来源与许可。原题及全体作者见上方。底本为 2023 年 1 月 10 日的 arXiv:2201.11903v6：https://arxiv.org/abs/2201.11903v6；原文由作者按 CC BY 4.0 提供。中文改编中可许可的新增表达亦按 CC BY 4.0 提供；第三方材料保留各自条件，GSM8K、SVAMP 的 MIT 与 BIG-bench 的 Apache 2.0 完整许可附于文末。本版不是毫无删节的全译，也不将第三方权利一概重新授予为 CC BY 4.0。

摘要

我们探究了生成*思维链*（即一系列中间推理步骤）如何显著提升大型语言模型执行复杂推理的能力。 具体而言，我们展示了一种称为*思维链提示*的简单方法：在提示中提供少量思维链演示作为示例，即可使此类推理能力在足够大的语言模型中自然涌现。

在三个大型语言模型上的实验表明，思维链提示能够提升模型在一系列算术推理、常识推理和符号推理任务上的表现。 其实际收益可能十分显著。 例如，仅使用八个思维链示例来提示 PaLM 540B，就能在数学应用题基准 GSM8K 上取得最先进的准确率，甚至超过经过微调并配有验证器的 GPT-3。

标准提示	思维链提示
模型输入	**模型输入**
问：Roger 有 5 个网球。他又买了 2 罐网球，每罐有 3 个。他现在有多少个网球?	问：Roger 有 5 个网球。他又买了 2 罐网球，每罐有 3 个。他现在有多少个网球?
答：答案是 11。	答：Roger 最初有 5 个球。2 罐网球，每罐 3 个，共有 6 个。5 + 6 = 11。答案是 11。
[MultiArith 第三方题目叙事删节；本位仅保留运算结构 $23-20+6$。]	[MultiArith 第三方题目叙事删节；本位仅保留运算结构 $23-20+6$。]
模型输出	**模型输出**
答：答案是 27。 ×	答：中间计算：23 - 20 = 3；3 + 6 = 9。答案是 9。 ✓

图 1: 思维链提示使大型语言模型能够处理复杂的算术推理、常识推理和符号推理任务。 思维链推理过程以高亮显示。

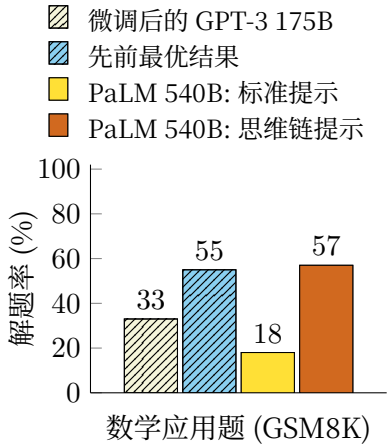


图 2: PaLM 540B 使用思维链提示，在数学应用题基准 GSM8K 上取得了新的最先进性能。 微调后的 GPT-3 和先前最优结果来自 Cobbe et al. (2021)。

1 引言

近年来，语言模型为自然语言处理领域带来了革命性变化(Peters et al., 2018; Devlin et al., 2019; Brown et al., 2020, 等)。 已有研究表明，扩大语言模型的规模能够带来一系列收益，例如提升性能和样本效率(Kaplan et al., 2020; Brown et al., 2020, 等)。 然而，仅仅扩大模型规模，尚不足以在算术推理、常识推理和符号推理等具有挑战性的任务上取得优异表现(Rae et al., 2021)。

本研究探讨如何通过一种由两个想法启发的简单方法，释放大型语言模型的推理能力。 第一，算术推理技术可以受益于生成导向最终答案的自然语言推理依据。 除了以形式语言代替自然语言的神经符号方法(Roy and Roth, 2015; Chiang and Chen, 2019; Amini et al., 2019; Chen et al., 2019)之外，先前研究还通过从头训练(Ling et al., 2017)或微调预训练模型(Cobbe et al., 2021)，使模型具备了生成自然语言中间步骤的能力。 第二，大型语言模型为通过*提示*开展上下文少样本学习提供了令人振奋的前景。 也就是说，无须为每项新任务分别微调一个语言模型检查点，只需用少量展示该任务的输入–输出示例来“提示”模型。 值得注意的是，这种做法已经在一系列简单的问答任务上取得成功(Brown et al., 2020)。

然而，上述两个想法都存在关键局限。对于以推理依据增强训练和微调的方法，构建大量高质量推理依据的成本很高，这比构建常规机器学习所使用的简单输入–输出对复杂得多。 对于Brown et al. (2020)所采用的传统少样本提示方法，它在需要推理能力的任务上表现不佳，而且通常不会随着语言模型规模的扩大而显著改善(Rae et al., 2021)。 本文以一种能够规避上述局限的方式，结合了这两个想法的优势。具体而言，我们提供由⟨输入、*思维链*、输出⟩三元组构成的提示，探索语言模型通过少样本提示完成推理任务的能力。 *思维链*是一系列导向最终输出的自然语言中间推理步骤，我们将这一方法称为*思维链提示*。图 1展示了一个提示示例。

我们在算术推理、常识推理和符号推理基准上进行了实证评估，结果表明思维链提示优于标准提示，有时优势十分显著。 图 2展示了其中一项结果：在数学应用题基准 GSM8K(Cobbe et al., 2021)上，对PaLM 540B 使用思维链提示，大幅优于标准提示，并取得了新的最先进性能。 仅依靠提示的方法具有重要意义，因为它不需要大型训练数据集，而且一个模型检查点就能在不损失通用性的情况下执行多种任务。 本研究强调，大型语言模型能够通过少量包含任务相关自然语言信息的示例进行学习（相较之下，另一种方式是通过大型训练数据集自动学习输入和输出背后的模式）。

2 思维链提示

请想一想自己在解决多步数学应用题等复杂推理任务时的思考过程。 通常，我们会将问题分解为若干中间步骤，逐一解决，再给出最终答案：*“Jane 给妈妈 2 朵花后，她还剩 10 朵...然后再给爸爸 3 朵，她就剩 7 朵...所以答案是 7。”* 本文的目标是赋予语言模型生成类似*思维链*的能力，也就是生成一系列连贯的中间推理步骤，最终得出问题的答案。 我们将表明，只要在少样本提示的示例中提供思维链推理的演示，足够大的语言模型就能生成思维链。

图 1展示了一个例子：模型通过生成思维链，解决了一道原本会答错的数学应用题。 这里的思维链类似于解题过程，也可以被理解为解题过程，但我们仍选择称其为思维链，以更好地表达这样一个想法：它模仿了逐步得出答案的思考过程（此外，解题过程或解释通常位于最终答案*之后*(Narang et al., 2020; Wiegreffe et al., 2022; Lampinen et al., 2022, 等)）。

作为促进语言模型推理的一种方法，思维链提示具有几个很有吸引力的特点。

1. 第一，思维链原则上允许模型将多步问题分解为中间步骤，这意味着可以为需要更多推理步骤的问题分配额外的计算量。
2. 第二，思维链为模型行为提供了一个可解释的观察窗口，表明模型可能是如何得出某个答案的，并让我们有机会调试推理路径中出错的环节（不过，完整刻画模型为支持某个答案而进行的计算，仍是一个开放问题）。
3. 第三，思维链推理可用于数学应用题、常识推理和符号操作等任务，并且至少在原则上，可能适用于人类能够通过语言解决的任何任务。
4. 最后，只需在少样本提示的示例中加入思维链序列示例，就能方便地在足够大的现成语言模型中激发思维链推理。

在实证实验中，我们将考察思维链提示在算术推理（节 3）、常识推理（节 4）和符号推理（节 5）中的作用。

3 算术推理

我们首先考察图 1所示形式的数学应用题，用以衡量语言模型的算术推理能力。 算术推理虽然对人类而言很简单，却是语言模型经常难以完成的任务(Hendrycks et al., 2021; Patel et al., 2021, 等)。值得注意的是，在拥有 540B 参数的语言模型上使用思维链提示，其在多项任务上的表现能够媲美针对任务专门微调的模型，甚至在具有挑战性的 GSM8K 基准上取得了新的最先进性能(Cobbe et al., 2021)。

3.1 实验设置

我们在多个基准上研究思维链提示对不同语言模型的作用。

基准。 我们考察以下五个数学应用题基准：**(1)** 数学应用题基准**GSM8K**(Cobbe et al., 2021)， **(2)** 包含不同结构数学应用题的**SVAMP**数据集(Patel et al., 2021)， **(3)** 包含多样化数学应用题的**ASDiv**数据集(Miao et al., 2020)， **(4)** 代数应用题数据集**AQuA**，以及 **(5)** **MAWPS**基准(Koncel-Kedziorski et al., 2016)。 题目示例见附录中的表 12。

标准提示。 作为基线，我们采用由Brown et al. (2020)推广的标准少样本提示方法：在语言模型对测试时的样例输出预测之前，在上下文中向其提供输入–输出对示例。 这些示例以问题和答案的形式呈现。 模型直接给出答案，如图 1左侧所示。

数学应用题（自由作答）	**数学应用题（多项选择）**	**CSQA（常识）**
问：Roger 有 5 个网球。他又买了 2 罐，每罐有 3 个。他现在有多少个网球? 答：Roger 最初有 5 个球。2 罐，每罐 3 个，共有 6 个。5 + 6 = 11。答案是 11。	问：输入从 1 到 500 的数字，需要敲击多少次按键? 选项：(a) 1156 (b) 1392 (c) 1480 (d) 1562 (e) 1788。 答：1 到 9 有 9 个一位数；10 到 99 有 90 个两位数；100 到 500 有 401 个三位数。9 + 90(2) + 401(3) = 1392。答案是 (b)。	[CSQA 第三方题目及对应输出删节：再分发与改编许可未核清。]
StrategyQA	**日期理解**	**体育理解**
问：是或否：梨会沉入水中吗? 答：梨的密度约为 0.6 g/cm^3，小于水的密度。因此梨会浮起来。所以答案是否。	问：音乐会原定于 06/01/1943 举行，但推迟了一天，改到今天。10 天前的日期是什么? 用 MM/DD/YYYY 格式作答。 答：06/01/1943 后一天是 06/02/1943，所以今天是 06/02/1943。今天的 10 天前是 05/23/1943。所以答案是 05/23/1943。	问：下面这句话是否合理? “Joao Moutinho 在 NFC 冠军赛中接到了掩护短传球。” 答：Joao Moutinho 是足球运动员。NFC 冠军赛属于美式橄榄球，而不是足球。所以答案是否。
SayCan（指挥机器人）	**末字母拼接**	**抛硬币（状态跟踪）**
[SayCan 示例内容暂略；官方 v0 标为 CC BY 4.0，但此处具体材料尚未完成逐项核验。]	问：取“Lady Gaga”中各个单词的最后一个字母，并将其拼接起来。 答：“Lady”的最后一个字母是“y”。“Gaga”的最后一个字母是“a”。将它们拼接起来得到“ya”。所以答案是 ya。	问：一枚硬币正面朝上。Maybelle 翻转了硬币。Shalonda 没有翻转。硬币是否仍然正面朝上? 答：Maybelle 翻转了硬币。因此硬币共被翻转 1 次，是奇数次。它最初正面朝上，奇数次翻转后会反面朝上。所以答案是否。

图 3: 算术推理、常识推理和符号推理基准中的⟨输入、思维链、输出⟩三元组示例。思维链以高亮显示。 完整提示见节 G。

思维链提示。 我们提出的方法是在少样本提示的每个示例中，为对应答案添加一条思维链，如图 1右侧所示。 由于大多数数据集只有评估划分，我们手工编写了一组包含思维链的八个少样本示例，用于提示。图 1右侧展示了其中一个思维链示例，完整示例集见附录中的表 20。 （这些具体示例没有经过提示工程；节 3.4和节 A.2研究了其稳健性。） 为了探究这种形式的思维链提示能否在各种数学应用题上成功激发有效推理，除 AQuA 以外，我们对所有基准都使用了同一组八个思维链示例；AQuA 是多项选择题，而不是自由作答题。 对于 AQuA，我们使用了训练集中的四个示例及其解答，见附录中的表 21。

语言模型。 我们评估了五个大型语言模型。 第一个是**GPT-3**(Brown et al., 2020)，我们使用 text-ada-001、text-babbage-001、text-curie-001 和 text-davinci-002，它们推测分别对应参数量为 350M、1.3B、6.7B 和 175B 的 InstructGPT 模型(Ouyang et al., 2022)。第二个是**LaMDA**(Thoppilan et al., 2022)，其模型参数量分别为 422M、2B、8B、68B 和 137B。 第三个是**PaLM**，其模型参数量分别为 8B、62B 和 540B。 第四个是**UL2 20B**(Tay et al., 2022)，第五个是**Codex**(Chen et al., 2021, OpenAI API 中的 code-davinci-002)。 我们使用贪心解码从模型中采样（不过，后续研究表明，对多次采样生成的最终答案进行多数投票，可以进一步改进思维链提示

(Wang et al., 2022a))。 对于LaMDA，我们报告五个随机种子的平均结果，每个种子对应一种随机打乱后的不同示例顺序。 由于LaMDA实验在不同种子之间没有表现出较大方差，为节省计算资源，其余所有模型均只报告一种示例顺序下的结果。

3.2 结果

图 4汇总了思维链提示最突出的结果，附录中的表 2列出了各个模型系列、模型规模和基准的全部实验结果。 有三个关键发现。 第一，图 4表明，思维链提示是一种随模型规模增长而涌现的能力(Wei et al., 2022b)。 也就是说，思维链提示对小模型的性能没有正面影响，只有用于参数量为~100B 的模型时才会带来性能提升。 我们通过定性观察发现，较小规模的模型会生成流畅但不合逻辑的思维链，导致其表现低于标准提示。

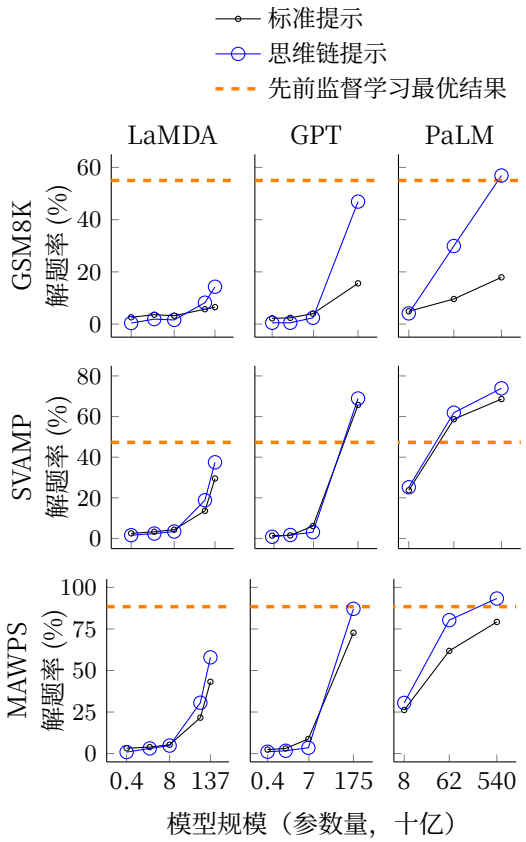


图 4: 思维链提示使大型语言模型能够解决具有挑战性的数学问题。尤其值得注意的是，思维链推理是随模型规模增大而涌现的能力。 GSM8K、SVAMP 和 MAWPS 的先前最优结果分别来自 Cobbe et al. (2021)、Jie et al. (2022) 和 Lan et al. (2021)。

第二，思维链提示对更复杂的问题带来的性能提升更大。 例如，在基线性能最低的数据集 GSM8K 上，最大的 GPT 和PaLM模型性能提升至原来的两倍以上。 另一方面，对于 MAWPS 中最简单、只需一步即可解决的子集 SingleOp，性能提升要么为负，要么非常小（见附录中的表 3）。

第三，在 GPT-3 175B 和PaLM 540B 上使用思维链提示，与此前最先进的方法相比表现出色；后者通常需要在带标签的训练数据集上微调针对特定任务的模型。 图 4显示，PaLM 540B 通过思维链提示，在 GSM8K、SVAMP 和 MAWPS 上取得了新的最先进性能（但请注意，在 SVAMP 上，标准提

示已经超过了此前最佳结果）。 在另外两个数据集 AQuA 和 ASDiv 上，采用思维链提示的PaLM与最先进性能的差距在 2% 以内（附录中的表 2）。

为更好地理解思维链提示为何有效， 我们人工检查了LaMDA 137B 在 GSM8K 上生成的思维链。 在随机抽取的 50 个模型给出了正确最终答案的样例中，除两例碰巧得出正确答案之外，其余生成的思维链在逻辑和数学上也都是正确的（见节 D.1；正确的模型生成思维链示例见表 8）。 我们还随机检查了 50 个模型给出错误答案的样例。 该分析的结果可以概括为：46% 的思维链除存在小错误（计算错误、符号映射错误或缺少一个推理步骤）外，基本正确；其余 54% 的思维链在语义理解或连贯性方面存在重大错误（见节 D.2）。 为初步了解扩大模型规模为何能提升思维链推理能力，我们对PaLM 62B 的错误进行了类似分析，并考察将其扩展为PaLM 540B 后这些错误是否得到纠正。 总体而言，将PaLM扩大到 540B，可以纠正 62B 模型中很大一部分缺少一步和语义理解错误（见节 A.1）。

3.3 消融研究

观察到思维链提示带来的收益后，一个自然的问题是：其他类型的提示能否带来相同的性能提升? 图 5展示了针对下述三种思维链变体的消融研究。

仅方程。思维链提示可能有用的一个原因，是它会生成待求解的数学方程，因此我们测试了一种变体：提示模型在给出答案之前，仅输出一个数学方程。 图 5表明，仅方程提示对 GSM8K 帮助不大，这意味着 GSM8K 中问题的语义过于复杂，在没有思维链中的自然语言推理步骤时，难以直接将其转化为方程。 不过，对于只需一步或两步的问题数据集，我们发现仅方程提示确实能够改善性能，因为可以很容易地从题目推导出方程（见附录中的表 6）。

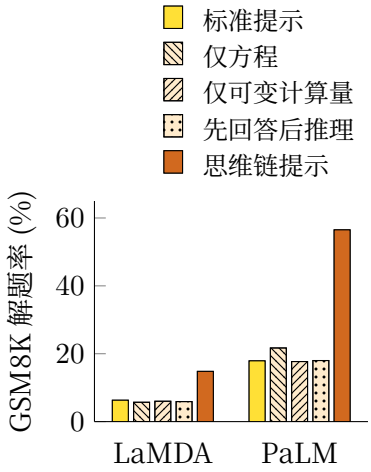


图 5: 使用 LaMDA 137B 和 PaLM 540B 对不同提示变体开展的消融研究。 其他数据集的结果见附录表 6和表 7。

仅可变计算量。 另一种直觉是，思维链让模型能够在较难的问题上投入更多计算量（即生成更多中间词元）。 为了将可变计算量的影响与思维链推理的影响分离，我们测试了一种设置：提示模型只输出一串点（. . .），点的数量等于解题所需方程的字符数。 这一变体的表现与基线大致相同，说明可变计算量本身并不是思维链提示成功的原因，而用自然语言表达中间步骤似乎确有作用。

答案之后的思维链。 思维链提示的另一项潜在益处可能只是：这类提示让模型能够更好地调用预训练期间获取的相关知识。 因此，我们测试了另一种设置，仅在答案之后给出思维链提示，以单独考察模

型是否确实依赖所生成的思维链来给出最终答案。 这一变体的表现与基线大致相同，说明思维链所体现的顺序推理具有超出单纯激活知识的作用。

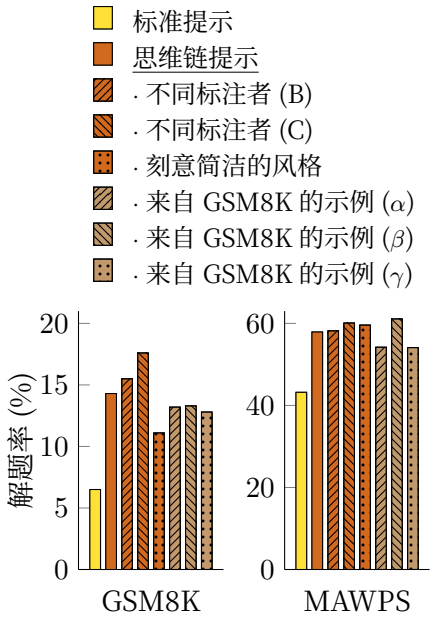


图 6: 思维链提示的结果会因提示示例不同而有所波动（符合预期），但在不同标注者及不同示例下均优于标准提示。

3.4 思维链的稳健性

对示例的敏感性是提示方法的一个重要考量因素。例如，改变少样本示例的排列顺序，就可能使 GPT-3 在 SST-2 上的准确率从接近随机水平（54.3%）变动到接近最先进水平（93.4%）(Zhao et al., 2021)。 在本节的最后一个小节中，我们评估对于不同标注者所写思维链的稳健性。 上述结果使用的是标注者 A 编写的思维链。除此之外，本文另外两位共同作者（标注者 B 和 C）还为同一组少样本示例独立编写了思维链（见节 H）。 标注者 A 还参照Cobbe et al. (2021)所给解答的风格，编写了另一版比原版更简洁的思维链。[1]

图 6展示了LaMDA 137B 在 GSM8K 和 MAWPS 上的这些结果（其他数据集的消融结果见附录中的表 6 / 表 7）。 虽然不同思维链标注之间存在差异，而这也是基于示例的提示方法所预期会出现的情况(Le Scao and Rush, 2021; Reynolds and McDonell, 2021; Zhao et al., 2021)，但所有思维链提示集都大幅优于标准基线。 这一结果表明，成功使用思维链并不依赖于某一种特定的语言风格。

为了确认思维链提示也能在其他示例集上奏效，我们还从 GSM8K 训练集这一独立来源中，随机抽取了三组示例，每组八个，并开展实验（该数据集中的样例本身就包含类似思维链的推理步骤）。[2] 图 6表明，这些提示的表现与我们手工编写的示例相当，同样显著优于标准提示。

[1]例如，原版思维链使用多个短句（*“最初有 9 台计算机。在 4 天中的每一天，都增加了 5 台计算机。因此增加了 5 * 4 = 20 台计算机。9 + 20 等于 29。”*），而简洁版思维链则为*“增加了 5 * 4 = 20 台新计算机。因此，服务器机房现在有 9 + 20 = 29 台新计算机。”*。

[2]为适应输入上下文窗口，我们抽取词元数≤ 60的样例；同时，为了与我们编写的八个示例公平比较，将样例限制为只需≤ 2步即可解决。

除了对标注者、独立编写的思维链、不同示例以及各种语言模型具有稳健性之外，我们还发现，算术推理中的思维链提示对不同示例顺序和不同示例数量也具有稳健性（见节 A.2）。

4 常识推理

虽然思维链尤其适合数学应用题，但其基于语言的特性实际上使它能够应用于广泛的常识推理问题。这些问题以一般背景知识为前提，涉及对物理交互和人际互动的推理。 常识推理是与世界交互的关键能力，而当前的自然语言理解系统仍然难以胜任(Talmor et al., 2021)。

基准。 我们考察了五个数据集，涵盖多种常识推理类型。 广泛使用的**CSQA**(Talmor et al., 2019)提出有关世界的常识问题，这些问题涉及复杂语义，往往需要先验知识。 **StrategyQA**(Geva et al., 2021)要求模型推导出多跳策略来回答问题。 我们从 BIG-bench 项目(BIG-bench collaboration, 2021)中选取了两个专门的评估集：**日期**理解，涉及根据给定上下文推断日期；以及**体育**理解，涉及判断与体育相关的句子是否合理。 最后，**SayCan**数据集(Ahn et al., 2022)涉及将自然语言指令映射为从一个离散动作集合中选取的机器人动作序列。 图 3展示了所有数据集附有思维链标注的示例。

提示。 我们沿用上一节的实验设置。 对于 CSQA 和 StrategyQA，我们从训练集中随机选择样例，并为其手工编写思维链，用作少样本示例。 这两个 BIG-bench 任务没有训练集，因此我们将评估集中的前十个样例选为少样本示例，并报告在评估集其余样例上的结果。 对于 SayCan，我们使用Ahn et al. (2022)所用训练集中的六个示例，并同样手工编写思维链。

结果。 图 7重点展示了PaLM的结果（LaMDA、GPT-3 以及不同模型规模的完整结果见表 4）。 在所有任务上，扩大模型规模都改善了标准提示的表现；思维链提示带来了进一步提升，其中PaLM 540B 的提升似乎最大。 采用思维链提示后，PaLM 540B 相对基线取得了优异表现，在 StrategyQA 上超过此前最先进的结果（75.6% 对 69.4%），并在体育理解上超过一位未借助外部帮助的体育爱好者（95.4% 对 84%）。 这些结果表明，思维链提示也能够改善需要多种常识推理能力的任务表现（不过请注意，在 CSQA 上的收益很小）。

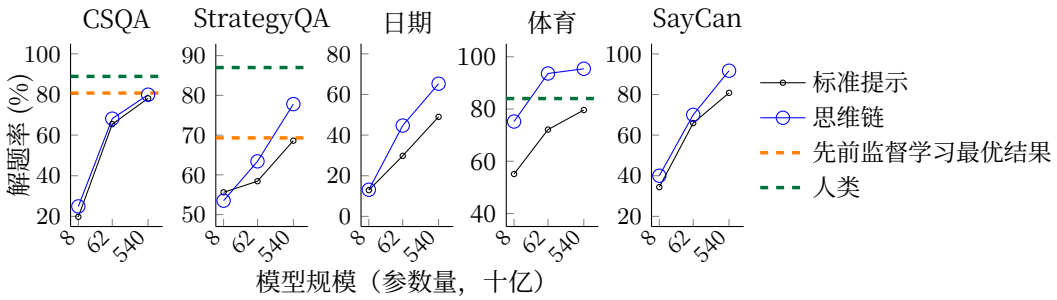


图 7: 思维链提示也提高了语言模型的常识推理能力。 此处展示的语言模型为 PaLM。 先前最优结果来自 CSQA (Talmor et al., 2019) 和 StrategyQA (Geva et al., 2021) 排行榜（仅限单模型，截至 2022 年 5 月 5 日）。 不同规模的 LaMDA、GPT-3 和 PaLM 的更多结果见表 4。

5 符号推理

最后一组实验评估考察符号推理。这类推理对人类很简单，但对语言模型可能具有挑战性。 我们表明，思维链提示不仅能使语言模型完成在标准提示设置下具有挑战性的符号推理任务，还能促进长度泛化，使模型处理推理时比少样本示例中所见输入更长的输入。

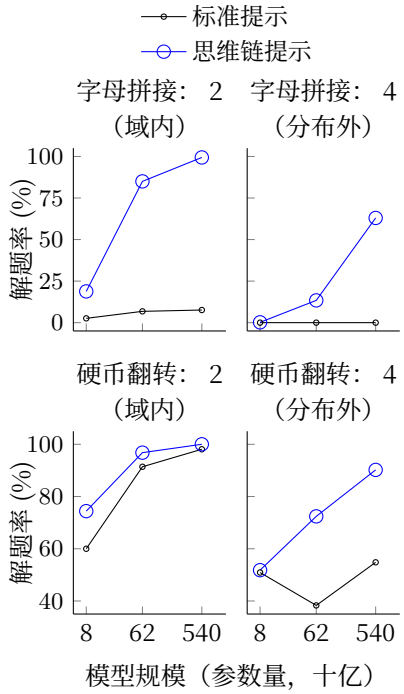


图 8：使用思维链提示能够促进两项符号推理任务向更长序列的泛化。

任务。 我们采用以下两个玩具任务。

- **末字母拼接**。 该任务要求模型将姓名中各个单词的最后一个字母拼接起来（例如，“*Amy Brown*” → “*yn*”）。 它是首字母拼接的更具挑战性的版本，而语言模型在不使用思维链的情况下就已经能够完成首字母拼接。[3] 我们从姓名统计数据（https://namecensus.com/）中分别最常见的一千个名字和姓氏中随机选取并拼接，生成完整姓名。
- **翻转硬币**。 该任务要求模型回答：在若干人翻转或不翻转硬币之后，硬币是否仍然正面朝上（例如，“*一枚硬币正面朝上。Phoebe 翻转了硬币。Osvaldo 没有翻转硬币。硬币仍然正面朝上吗？*” → “*否*”）。

由于这些符号推理任务的构造有明确定义，我们为每项任务同时考察一个*域内*测试集和一个*域外*（OOD）测试集：前者的样例步数与训练/少样本示例相同，后者的评估样例则比示例包含更多步骤。 对于末字母拼接，模型只会看到由两个单词组成的姓名示例，随后需要对由 3 个和 4 个单词组成的姓名进行末字母拼接。[4] 我们对翻转硬币任务中可能翻转的次数采用相同处理。 实验设置使用的方法和模型与前两节相同。 我们同样为每项任务的少样本示例手工编写了思维链，如图 3所示。

结果。 PaLM在这些域内和域外评估中的结果见图 8，LaMDA的结果见附录中的表 5。 对于PaLM 540B，思维链提示带来了接近 100% 的解题成功率（请注意，标准提示下的PaLM 540 已经能够解决翻转硬币任务，但LaMDA 137B 则不能）。 请注意，这些域内评估之所以属于“玩具任务”，是因为少样本示例中的思维链已经提供了完整的解题结构；模型只需将相同步骤应用于测试样例中的新符号即可。 然而，小模型仍然无法完成任务：对于这三项任务，对未见符号执行抽象操作的能力只有在模型参数规模达到 100B 时才会出现。

[3]我们使用 GPT-3 `davinci`测试了 10 个常见姓名，除一个外全部答对。
[4]对于长度超过 2 个单词的姓名，我们将多个名字和姓氏拼接在一起。

至于域外评估，标准提示在两个任务上均失败。 使用思维链提示后，语言模型的性能随规模扩大而上升（尽管表现低于域内设置）。 因此，对于足够大规模的语言模型，思维链提示能够促进长度泛化，使其超越已见思维链的长度。

6 讨论

我们探索了思维链提示这一简单机制，用以激发大型语言模型的多步推理行为。 首先，我们看到思维链提示能够大幅改善算术推理表现，其提升明显强于消融变体，并且对不同标注者、示例和语言模型具有稳健性（节 3）。 随后，常识推理实验凸显了思维链推理的语言特性如何使其具有广泛适用性（节 4）。 最后，我们表明，在符号推理中，思维链提示能够促进对更长序列的域外泛化（节 5）。在所有实验中，思维链推理都仅通过提示现成语言模型来激发。 在撰写本文的过程中，我们没有对任何语言模型进行微调。

思维链推理随着模型规模扩大而涌现，是贯穿本研究的一个主题(Wei et al., 2022b)。 在许多标准提示的规模增长曲线平坦的推理任务上，思维链提示产生了显著上升的规模增长曲线。 思维链提示似乎扩大了大型语言模型能够成功完成的任务集合。换言之，本研究强调，标准提示仅揭示了大型语言模型能力的下界。 这一观察或许提出了比其解答更多的问题。例如，随着模型规模进一步扩大，我们可以期待推理能力提升多少？ 还有哪些提示方法可能扩大语言模型能够解决的任务范围？

关于局限性，我们首先需要说明：虽然思维链模仿了人类推理者的思考过程，但这并不能回答神经网络是否真的在“推理”；我们将其留作一个开放问题。 第二，虽然在少样本设置下，手工为示例添加思维链的成本很低，但在微调时，这类标注成本可能高得难以承受（不过，合成数据生成或零样本泛化或许能够克服这一问题）。 第三，无法保证推理路径正确；这些路径可能导向正确答案，也可能导向错误答案。提高语言模型生成内容的事实准确性，是未来研究的一个开放方向(Rashkin et al., 2021; Ye and Durrett, 2022; Wiegreffe et al., 2022, 等)。 最后，思维链推理只有在模型规模较大时才会涌现，这使其在实际应用中的服务成本较高；未来研究可以探索如何在较小模型中诱导出推理能力。

7 相关工作

本研究受到多个研究领域的启发，我们在扩展的相关工作部分（节 C）中进行了详细介绍。这里介绍两个可能最相关的方向及其关联论文。

第一个相关方向是使用中间步骤解决推理问题。Ling et al. (2017)率先提出利用自然语言推理依据，通过一系列中间步骤解决数学应用题的思路。他们的工作与使用形式语言进行推理的研究形成了鲜明对比(Roy et al., 2015; Chiang and Chen, 2019; Amini et al., 2019; Chen et al., 2019)。Cobbe et al. (2021)扩展了Ling et al. (2017)的工作，构建了更大的数据集，并用其微调预训练语言模型，而非从头训练模型。在程序合成领域，Nye et al. (2021)利用语言模型，先逐行预测中间计算结果，再预测 Python 程序的最终输出，并表明这种逐步预测方法优于直接预测最终输出。

自然地，本文也与近期大量关于提示的研究密切相关。 自Brown et al. (2020)所述的少样本提示方法得到推广以来，多种通用方法改善了模型的提示能力，例如自动学习提示(Lester et al., 2021)，或向模型提供描述任务的指令(Wei et al., 2022a; Sanh et al., 2022; Ouyang et al., 2022)。 这些方法改进或增强的是提示的输入部分（例如，在输入之前添加指令），而我们的工作采取了一个互补的方向，即在语言模型的输出中添加思维链。

8 结论

我们探索了思维链提示，将其作为一种简单且广泛适用的方法，以增强语言模型的推理能力。 通过算术推理、符号推理和常识推理实验，我们发现，思维链推理是随模型规模增长而涌现的一种特性，它使足够大的语言模型能够完成原本具有平坦规模增长曲线的推理任务。 我们希望，拓宽语言模型能够完成的推理任务范围，将启发更多基于语言的推理方法研究。

致谢

我们感谢 Jacob Devlin、Claire Cui、Andrew Dai 和 Ellie Pavlick 对本文提出反馈意见。 我们感谢 Jacob Austin、Yuhuai Wu、Henryk Michalewski、Aitor Lewkowycz、Charles Sutton 和 Aakanksha Chowdhery 进行的有益讨论。 我们感谢 Sid Maxwell 告知我们原始稿件的人工错误分析中存在的一处错误。

参考文献

Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, et al. 2022. Do as I can, not as I say: Grounding language in robotic affordances. *arXiv preprint arXiv:2204.01691*.

Aida Amini, Saadia Gabriel, Shanchuan Lin, Rik Koncel-Kedziorski, Yejin Choi, and Hannaneh Hajishirzi. 2019. MathQA: Towards interpretable math word problem solving with operation-based formalisms. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, Minneapolis, Minnesota. Association for Computational Linguistics.

Daniel Andor, Luheng He, Kenton Lee, and Emily Pitler. 2019. Giving BERT a calculator: Finding operations and arguments with reading comprehension. *EMNLP*.

Jacob Andreas, Dan Klein, and Sergey Levine. 2018. Learning with latent language. *NAACL*.

Jacob Austin, Augustus Odena, Maxwell Nye, Maarten Bosma, Henryk Michalewski, David Dohan, Ellen Jiang, Carrie Cai, Michael Terry, Quoc Le, et al. 2021. Program synthesis with large language models. *arXiv preprint arXiv:2108.07732*.

BIG-bench collaboration. 2021. Beyond the imitation game: Measuring and extrapolating the capabilities of language models. *In preparation*.

Kaj Bostrom, Xinyu Zhao, Swarat Chaudhuri, and Greg Durrett. 2021. Flexible generation of natural language deductions. *EMNLP*.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. 2020. Language models are few-shot learners. *NeurIPS*.

Jonathon Cai, Richard Shin, and Dawn Song. 2017. Making neural programming architectures generalize via recursion. *ICLR*.

Oana-Maria Camburu, Tim Rocktäschel, Thomas Lukasiewicz, and Phil Blunsom. 2018. e-SNLI: Natural language inference with natural language explanations. *NeurIPS*.

Howard Chen, Jacqueline He, Karthik Narasimhan, and Danqi Chen. 2022. Can rationalization improve robustness? *NAACL*.

Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. 2021. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*.

Xinyun Chen, Chen Liang, Adams Wei Yu, Denny Zhou, Dawn Song, and Quoc V. Le. 2019. Neural symbolic reader: Scalable integration of distributed and symbolic representations for reading comprehension. *ICLR*.

Ting-Rui Chiang and Yun-Nung Chen. 2019. Semantically-aligned equation generation for solving and reasoning math word problems. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 2656--2668, Minneapolis, Minnesota. Association for Computational Linguistics.

Peter Clark, Oyvind Tafjord, and Kyle Richardson. 2020. Transformers as soft reasoners over language. *IJCAI*.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. 2021. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL*.

Honghua Dong, Jiayuan Mao, Tian Lin, Chong Wang, Lihong Li, and Denny Zhou. 2019. Neural logic machines. *ICLR*.

Dheeru Dua, Sameer Singh, and Matt Gardner. 2020. Benefits of intermediate annotations in reading comprehension. *ACL*.

Mor Geva, Daniel Khashabi, Elad Segal, Tushar Khot, Dan Roth, and Jonathan Berant. 2021. Did aristotle use a laptop? A question answering benchmark with implicit reasoning strategies. *TACL*.

Yuling Gu, Bhavana Dalvi Mishra, and Peter Clark. 2022. DREAM: Uncovering mental models behind language models. *NAACL*.

Braden Hancock, Paroma Varma, Stephanie Wang, Martin Bringmann, Percy Liang, and Christopher Ré. 2018. Training classifiers with natural language explanations. *ACL*.

Peter Hase and Mohit Bansal. 2022. When can models learn from explanations? a formal framework for understanding the roles of explanation data. *ACL*.

Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. 2021. Measuring mathematical problem solving with the math dataset. *arXiv preprint arXiv:2103.03874*.

Mohammad Javad Hosseini, Hannaneh Hajishirzi, Oren Etzioni, and Nate Kushman. 2014. Learning to solve arithmetic word problems with verb categorization. *EMNLP*.

Zhanming Jie, Jierui Li, and Wei Lu. 2022. Learning to reason deductively: Math word problem solving as complex relation extraction. *arXiv preprint arXiv:2203.10316*.

Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. 2020. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*.

Rik Koncel-Kedziorski, Subhro Roy, Aida Amini, Nate Kushman, and Hannaneh Hajishirzi. 2016. MAWPS: A math word problem repository. *NAACL*.

Andrew K. Lampinen, Ishita Dasgupta, Stephanie C.Y. Chan, Kory Matthewson, Michael Henry Tessler, Antonia Creswell, James L. McClelland, Jane X. Wang, and Felix Hill. 2022. Can language models learn from explanations in context? *arXiv preprint arXiv:2204.02329*.

Yihuai Lan, Lei Wang, Qiyuan Zhang, Yunshi Lan, Bing Tian Dai, Yan Wang, Dongxiang Zhang, and Ee-Peng Lim. 2021. MWPToolkit: An open-source framework for deep learning-based math word problem solvers. *arXiv preprint arXiv:2109.00799*.

Teven Le Scao and Alexander Rush. 2021. How many data points is a prompt worth? *NAACL*.

Brian Lester, Rami Al-Rfou, and Noah Constant. 2021. The power of scale for parameter-efficient prompt tuning. *EMNLP*.

Iddo Lev, Bill MacCartney, Christopher Manning, and Roger Levy. 2004. Solving logic puzzles: From robust processing to precise semantics. *Proceedings of the 2nd Workshop on Text Meaning and Interpretation*.

Xiang Lisa Li and Percy Liang. 2021. Prefix-tuning: Optimizing continuous prompts for generation. *ACL*.

Zhengzhong Liang, Steven Bethard, and Mihai Surdeanu. 2021. Explainable multi-hop verbal reasoning through internal monologue. *NAACL*.

Wang Ling, Dani Yogatama, Chris Dyer, and Phil Blunsom. 2017. Program induction by rationale generation: Learning to solve and explain algebraic word problems. *ACL*.

Pengfei Liu, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi, and Graham Neubig. 2021. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *arXiv preprint arXiv:2107.13586*.

Bodhisattwa Prasad Majumder, Oana-Maria Camburu, Thomas Lukasiewicz, and Julian McAuley. 2021. Rationale-inspired natural language explanations with commonsense. *arXiv preprint arXiv:2106.13876*.

Ana Marasović, Iz Beltagy, Doug Downey, and Matthew E Peters. 2022. Few-shot self-rationalization with natural language prompts. *NAACL Findings*.

Joshua Maynez, Shashi Narayan, Bernd Bohnet, and Ryan McDonald. 2020. On faithfulness and factuality in abstractive summarization. In *ACL*.

Shen Yun Miao, Chao Chun Liang, and Keh Yih Su. 2020. A diverse corpus for evaluating and developing English math word problem solvers. *ACL*.

Sewon Min, Xinxi Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi, and Luke Zettlemoyer. 2022. Rethinking the role of demonstrations: What makes in-context learning work? *arXiv preprint arXiv:2202.12837*.

Sharan Narang, Colin Raffel, Katherine Lee, Adam Roberts, Noah Fiedel, and Karishma Malkan. 2020. WT5?! Training text-to-text models to explain their predictions. *arXiv preprint arXiv:2004.14546*.

Maxwell Nye, Anders Johan Andreassen, Guy Gur-Ari, Henryk Michalewski, Jacob Austin, David Bieber, David Dohan, Aitor Lewkowycz, Maarten Bosma, David Luan, et al. 2021. Show your work: Scratchpads for intermediate computation with language models. *arXiv preprint arXiv:2112.00114*.

Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. 2022. Training language models to follow instructions with human feedback. *arXiv preprint arXiv:2203.02155*.

Arkil Patel, Satwik Bhattamishra, and Navin Goyal. 2021. Are NLP models really able to solve simple math word problems? *NAACL*.

Matthew E. Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, and Luke Zettlemoyer. 2018. Deep contextualized word representations. *NAACL*.

Xinyu Pi, Qian Liu, Bei Chen, Morteza Ziyadi, Zeqi Lin, Yan Gao, Qiang Fu, Jian-Guang Lou, and Weizhu Chen. 2022. Reasoning like program executors. *arXiv preprint arXiv:2201.11473*.

Piotr Piękos, Mateusz Malinowski, and Henryk Michalewski. 2021. Measuring and improving BERT's mathematical abilities by predicting the order of reasoning. *ACL*.

Jack W. Rae, Sebastian Borgeaud, Trevor Cai, Katie Millican, Jordan Hoffmann, Francis Song, John Aslanides, Sarah Henderson, Roman Ring, Susannah Young, et al. 2021. Scaling language models: Methods, analysis & insights from training Gopher. *arXiv preprint arXiv:2112.11446*.

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J Liu. 2020. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21:1--67.

Dheeraj Rajagopal, Vidhisha Balachandran, Eduard H. Hovy, and Yulia Tsvetkov. 2021. SelfExplain: A self-explaining architecture for neural text classifiers. *EMNLP*.

Nazneen Fatema Rajani, Bryan McCann, Caiming Xiong, and Richard Socher. 2019. Explain yourself! Leveraging language models for commonsense reasoning. *ACL*.

Qiu Ran, Yankai Lin, Peng Li, Jie Zhou, and Zhiyuan Liu. 2019. NumNet: Machine reading comprehension with numerical reasoning. *EMNLP*.

Hannah Rashkin, Vitaly Nikolaev, Matthew Lamm, Michael Collins, Dipanjan Das, Slav Petrov, Gaurav Singh Tomar, Iulia Turc, and David Reitter. 2021. Measuring attribution in natural language generation models. *arXiv preprint arXiv:2112.12870*.

Gabriel Recchia. 2021. Teaching autoregressive language models complex tasks by demonstration. *arXiv preprint arXiv:2109.02102*.

Emily Reif, Daphne Ippolito, Ann Yuan, Andy Coenen, Chris Callison-Burch, and Jason Wei. 2022. A recipe for arbitrary text style transfer with large language models. *ACL*.

Laria Reynolds and Kyle McDonell. 2021. Prompt programming for large language models: Beyond the few-shot paradigm. *Extended Abstracts of the 2021 CHI Conference on Human Factors in Computing Systems*.

Subhro Roy and Dan Roth. 2015. Solving general arithmetic word problems. *EMNLP*.

Subhro Roy, Tim Vieira, and Dan Roth. 2015. Reasoning about Quantities in Natural Language. *TACL*.

Mohammed Saeed, Naser Ahmadi, Preslav Nakov, and Paolo Papotti. 2021. RuleBERT: Teaching soft rules to pre-trained language models. *EMNLP*.

Victor Sanh, Albert Webson, Colin Raffel, Stephen H. Bach, Lintang Sutawika, Zaid Alyafeai, Antoine Chaffin, Arnaud Stiegler, Teven Le Scao, Arun Raja, et al. 2022. Multitask prompted training enables zero-shot task generalization. *ICLR*.

Jianhao Shen, Yichun Yin, Lin Li, Lifeng Shang, Xin Jiang, Ming Zhang, and Qun Liu. 2021. Generate & rank: A multi-task framework for math word problems. In *Findings of the Association for Computational Linguistics: EMNLP 2021*.

Alon Talmor, Jonathan Herzig, Nicholas Lourie, and Jonathan Berant. 2019. CommonsenseQA: A question answering challenge targeting commonsense knowledge. *NAACL*.

Alon Talmor, Oyvind Tafjord, Peter Clark, Yoav Goldberg, and Jonathan Berant. 2020. Leap-of-thought: Teaching pre-trained models to systematically reason over implicit knowledge. *NeurIPS*.

Alon Talmor, Ori Yoran, Ronan Le Bras, Chandra Bhagavatula, Yoav Goldberg, Yejin Choi, and Jonathan Berant. 2021. CommonsenseQA 2.0: Exposing the limits of ai through gamification. *NeurIPS Track on Datasets and Benchmarks*.

Yi Tay, Mostafa Dehghani, Vinh Q Tran, Xavier Garcia, Dara Bahri, Tal Schuster, Huaixiu Steven Zheng, Neil Houlsby, and Donald Metzler. 2022. Unifying language learning paradigms. *arXiv preprint arXiv:2205.05131*.

Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam Shazeer, Apoorv Kulshreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, et al. 2022. LaMDA: Language models for dialog applications. *arXiv preprint arXiv:2201.08239*.

Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, and Denny Zhou. 2022a. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*.

Yizhong Wang, Swaroop Mishra, Pegah Alipoormolabashi, Yeganeh Kordi, Amirreza Mirzaei, Anjana Arunkumar, Arjun Ashok, Arut Selvan Dhanasekaran, Atharva Naik, David Stap, et al. 2022b. Benchmarking generalization via in-context instructions on 1,600+ language tasks. *arXiv preprint arXiv:2204.07705*.

Jason Wei, Maarten Bosma, Vincent Y. Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M. Dai, and Quoc V. Le. 2022a. Finetuned language models are zero-shot learners. *ICLR*.

Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, et al. 2022b. Emergent abilities of large language models. *Transactions on Machine Learning Research*.

Sarah Wiegreffe, Jack Hessel, Swabha Swayamdipta, Mark Riedl, and Yejin Choi. 2022. Reframing human-AI collaboration for generating free-text explanations. *NAACL*.

Sarah Wiegreffe and Ana Marasović. 2021. Teach me to explain: A review of datasets for explainable NLP. *NeurIPS*.

Sarah Wiegreffe, Ana Marasović, and Noah A. Smith. 2021. Measuring association between labels and free-text rationales. *EMNLP*.

Tongshuang Wu, Ellen Jiang, Aaron Donsbach, Jeff Gray, Alejandra Molina, Michael Terry, and Carrie J Cai. 2022a. PromptChainer: Chaining large language model prompts through visual programming. *CHI Extended Abstracts*.

Tongshuang Wu, Michael Terry, and Carrie Jun Cai. 2022b. AI chains: Transparent and controllable human-AI interaction by chaining large language model prompts. *CHI*.

Yujun Yan, Kevin Swersky, Danai Koutra, Parthasarathy Ranganathan, and Milad Hashemi. 2020. Neural execution engines: Learning to execute subroutines. *NeurIPS*.

Huihan Yao, Ying Chen, Qinyuan Ye, Xisen Jin, and Xiang Ren. 2021. Refining language models with compositional explanations. *NeurIPS*.

Xi Ye and Greg Durrett. 2022. The unreliability of explanations in few-shot in-context learning. *arXiv preprint arXiv:2205.03401*.

Yordan Yordanov, Vid Kocijan, Thomas Lukasiewicz, and Oana-Maria Camburu. 2021. Few-shot out-of-domain transfer learning of natural language explanations. *arXiv preprint arXiv:2112.06204*.

Omar Zaidan, Jason Eisner, and Christine Piatko. 2007. Using ``annotator rationales" to improve machine learning for text categorization. *NAACL*.

Wojciech Zaremba and Ilya Sutskever. 2014. Learning to execute. *arXiv preprint arXiv:1410.4615*.

Eric Zelikman, Yuhuai Wu, and Noah D. Goodman. 2022. STaR: Bootstrapping reasoning with reasoning. *arXiv preprint arXiv:2203.14465*.

Tony Z. Zhao, Eric Wallace, Shi Feng, Dan Klein, and Sameer Singh. 2021. Calibrate before use: Improving few-shot performance of language models. *ICML*.

Wangchunshu Zhou, Jinyi Hu, Hanlin Zhang, Xiaodan Liang, Maosong Sun, Chenyan Xiong, and Jian Tang. 2020. Towards interpretable natural language understanding with explanations as latent variables. *NeurIPS*.

检查清单

1. 适用于所有作者……
   (a) 摘要和引言中的主要论点是否准确反映了论文的贡献和范围？ [是]
   (b) 是否描述了本研究的局限性？ [是] 见节 6和节 A.2。
   (c) 是否讨论了本研究可能产生的负面社会影响？ [是] 我们预计，本文贡献不会直接导致负面社会影响。不过，一个需要考虑的问题是，生成的思维链并不总是符合事实；节 D.1将此列为一项局限性（请注意，我们不建议将这类思维链当作事实使用，也不建议将其用于任何真实世界场景）。
   (d) 是否阅读了伦理审查指南，并确保论文符合这些指南？ [是]
2. 如果包含理论结果……
   (a) 是否陈述了所有理论结果的全部假设？ [不适用]
   (b) 是否包含了所有理论结果的完整证明？ [不适用]
3. 如果进行了实验……
   (a) 是否提供了复现主要实验结果所需的代码、数据和说明（通过补充材料或 URL 提供）？ [是] 我们在补充材料中包含了LaMDA和 GPT-3 的输入、输出及目标答案。虽然我们使用的是专有模型，但 GPT-3 的结果完全可复现。节 E.1进一步讨论了可复现性。
   (b) 是否明确给出了所有训练细节（例如数据划分、超参数及其选择方式）？ [是] 已明确说明数据划分；超参数不适用。
   (c) 是否报告了误差条（例如多次实验后针对随机种子的误差条）？ [是] 表 6和表 7给出了 LaMDA 137B 在多个随机种子下的标准差，每个种子对应一种不同的随机示例顺序。
   (d) 是否提供了总计算量和所用资源类型（例如 GPU 类型、内部集群或云服务提供商）？ [是] 节 E.2描述了资源类型，但我们没有估计总计算量。
4. 如果使用现有资源（例如代码、数据、模型），或整理/发布新资源……
   (a) 如果本研究使用了现有资源，是否引用了其创建者？ [是] 根据 NeurIPS 主席的建议，我们对使用的两个模型进行了匿名化处理。这些模型将在论文的正式定稿版中引用。
   (b) 是否说明了这些资源的许可证？ [是] 见节 E.3。
   (c) 是否通过补充材料或 URL 提供了任何新资源？ [是] 唯一的新资源是翻转硬币和末字母拼接数据集，它们已在补充材料中提供。
   (d) 是否讨论了是否以及如何取得所使用/整理数据涉及人员的同意？ [不适用] 未收集人类数据。
   (e) 是否讨论了所使用/整理的数据是否包含个人可识别信息或冒犯性内容？ [不适用] 未收集人类数据。
5. 如果使用了众包或开展了涉及人类受试者的研究……
   (a) 是否包含了提供给参与者的完整说明文本，以及适用情况下的截图？ [不适用]
   (b) 是否描述了参与者可能面临的风险，并在适用情况下提供了机构审查委员会（IRB）批准文件的链接？ [不适用]
   (c) 是否提供了支付给参与者的估计时薪以及参与者报酬总支出？ [不适用]

A 常见问题

A.1 为什么增大模型规模会改善思维链提示的效果?

有效的思维链推理仅在达到一定模型规模后才会以可预见的方式出现，这一发现令人感兴趣。 已有研究表明，扩大语言模型规模能够带来性能和样本效率的提升等益处 (Kaplan et al., 2020)；但思维链推理具有涌现性，因为仅凭小规模模型的性能进行外推，无法预测它何时能够成功：事实上，对于大多数参数量小于 10B 的模型，思维链反而会损害性能。

为什么模型规模会改善思维链提示的效果，这个问题显然涉及多个方面，我们尝试通过错误分析对其作出初步探究。 这项小规模分析包括人工阅读 PaLM 62B 所犯的 45 个错误，并将其分为语义理解错误（20 个）、遗漏一步错误（18 个）和其他错误（7 个）。 “其他”类别包括幻觉、重复输出和符号映射错误。 这一粗略分类借鉴了 节 D.2 中针对 LaMDA 所做的初步错误分析，其中的类别是根据需要作出哪些改进才能使思维链正确而设计的。

如 图 9 所示，将 PaLM 的规模扩大到 540B 参数，修正了这三类错误中相当大的一部分。 图 10 给出了通过将 PaLM 扩展至 540B 而修正的语义理解错误和遗漏一步错误的示例。 这一结果似乎与如下假设一致：随着模型规模增大，语言模型会获得一系列语义理解和逻辑推理技能（但请注意，模型规模往往与训练计算量等其他因素混杂在一起）。

62B 语言模型的错误类型	62B 错误数	扩展至 540B 后修正数
语义理解错误	20	6
遗漏一步	18	12
其他	7	4

图 9: 对 PaLM 62B 答错的 45 道题进行的错误分析。 这些错误被分为语义理解错误、遗漏一步错误和其他错误。其他错误类别包括幻觉、重复输出和符号映射错误。 将 PaLM 的规模扩大到 540B，修正了各类别中相当大的一部分错误。

关于小语言模型为何失败，还有三点值得注意。 第一点观察是，小语言模型即使在相对简单的符号映射任务上也会失败。 如 节 5 所示，即便符号推理任务仅要求模型利用少样本示例中给出的同一种思维链逻辑结构泛化到新例子，小语言模型仍然无法完成。 第二点观察是，小语言模型的算术能力似乎本来就较弱，正如 Brown et al. (2020) 所表明的那样，进行简单算术运算（不涉及语义理解）的能力也需要足够大的模型规模。 最后，我们通过定性观察发现，小语言模型经常无法生成可被解析的最终答案，原因要么是重复，要么是其逻辑始终无法得出最终答案。

总之，由模型规模增大带来的思维链推理成功是一种复杂现象，可能涉及多种涌现能力（语义理解、符号映射、保持主题、算术能力、忠实性等）。 未来的工作可以更全面地研究：预训练数据、模型架构和优化目标的哪些属性，在因果意义上使这类推理能力成为可能。

A.2 提示工程起什么作用?

使用提示时的一个关键考量，是模型对提示具体写法的敏感程度。 已有大量工作表明，提示会以出人意料的方式影响语言模型 (Min et al., 2022)。 我们编写思维链标注的一般方法，是从训练集中选取八个示例，并将通向最终答案的推理过程分解为多个步骤。 图 3 提供了思维链标注示例，完整提示见 节 G。 为分析思维链对提示工程的敏感程度，我们针对多种因素进行了稳健性实验。

问题	62B 模型输出	540B 模型输出
Tracy 用一段 4 英尺长的铁丝支撑花园里的番茄植株。她把铁丝剪成每段 6 英寸长。她得到了多少段?	她把铁丝剪成每段 6 英寸。这意味着她得到了 4 * 6 = 24 段。答案是 24。 （错误：语义理解错误）	铁丝长 4 英尺，即 4 * 12 = 48 英寸。每段长 6 英寸，所以得到了 48 / 6 = 8 段。答案是 8。 （正确）
Tom 的船可以每小时行驶 10 英里。他从下午 1 点航行到 4 点，然后以每小时 6 英里的速度返回。返回需要多长时间?	他从下午 1 点航行到 4 点，即航行了 3 小时。他以每小时 6 英里的速度返航。这意味着他航行了 3 * 6 = 18 英里。答案是 18。 （错误：语义理解错误）	他从下午 1 点到 4 点以每小时 10 英里的速度航行，共 3 小时。3 小时、每小时 10 英里，即 3 * 10 = 30 英里。然后他以每小时 6 英里返航。他要航行 30 英里，因此需要 30 / 6 = 5 小时。答案是 5。 （正确）
Stephen 在网上订购了食品杂货，账单为 40.00 美元。配送商在最终金额上加收 25% 的费用，另收 3.00 美元配送费。Stephen 还给了 4.00 美元小费。加上额外费用后，最终价格是多少?	Stephen 的食品杂货最终价格为 40.00 美元。配送商加收 25%，因此最终金额为 40.00 美元的 125%，即 125% * 40.00 = 50.00 美元。配送商另收 3.00 美元配送费，所以最终价格为 50.00 + 3.00 = 53.00 美元。答案是 53.00 美元。 （错误：遗漏一步）	Stephen 的账单为 40.00 美元。配送商加收 25%，即 40.00 美元的 25%，也就是 0.25 * 40.00 = 10.00 美元。配送费为 3.00 美元，小费为 4.00 美元。因此总账单为 40.00 + 10.00 + 3.00 + 540b model 4.00 = 57.00 美元。答案是 57。 （正确；原图中的“540b model”字样按原样保留）
四所学校参加篮球锦标赛。每校各派出一支女子篮球队和一支男子篮球队，每队 5 名队员，每队还各有一名教练。所有学校总共派出了多少人?	有 4 所学校。每校派出一支女队和一支男队，每队 5 人，所以有 4 * 2 * 5 = 40 名队员。每队有一名教练，所以有 40 + 4 = 44 名教练。答案是 44。 （错误：遗漏一步）	每校派出 2 支队伍，每队 5 人，即每校有 2 * 5 = 10 名队员。每校另派出 2 名教练，因此每校共 10 + 2 = 12 人。共有 4 所学校，所以总共派出 4 * 12 = 48 人。答案是 48。 （正确）

图 10：通过将 PaLM 从 62B 扩展到 540B 而修正的语义理解错误和遗漏一步错误的示例。

- **不同的标注者**。 我们首先分析了相对于三位不同标注者的稳健性（节 3.4 和 图 6）。尽管性能存在明显差异（我们将在后文讨论），但对于三位标注者中的每一位，在算术、常识和符号推理的八个数据集上，思维链的表现都大幅优于基线（表 6 和 表 7）。与 Cobbe et al. (2021) 中的标注过程类似，我们没有向标注者提供有关如何编写思维链标注的具体说明，只要求他们写出得出最终答案的逐步推理过程。因此，这些标注都是以各位标注者自己的语言表达方式和“思维链”写作风格完成的。
- **没有机器学习背景的标注者**。 GSM8K 数据集 (Cobbe et al., 2021) 恰好提供了一个带有众包工作者编写的推理链的训练集，使我们能够考察：采用来自没有机器学习背景的独立来源的推理链时，思维链是否仍然有效。因此，我们从 GSM8K 中随机抽取了三组带有思维链的示例，每组八个。在全部四个算术数据集上，这些思维链标注也都大幅优于基线（表 6），表明思维链并不依赖某一组特定的标注者。
- **不同的示例**。 上述采用不同 GSM8K 示例的实验（表 6）也表明，思维链提示对不同的示例组合均有效。值得注意的是，我们在全部四个算术数据集上测试了每组示例（而不是分别从各个数据集的训练集中选取示例），这说明示例不一定需要与测试样本来自同一数据集分布。

- **不同的示例顺序**。 先前的工作表明，在某些情况下（例如分类），连提示的顺序也很重要：改变少样本示例的排列顺序，可以使 GPT-3 在 SST-2 上的准确率从接近随机猜测水平（54.3%）变化到接近最先进水平（93.4%）(Zhao et al., 2021)。我们在 表 6 和 表 7 中展示了不同示例带来的性能标准差。在几乎所有情况下，由提示顺序引起的标准差都相对很小。唯一的例外是硬币翻转任务：不同示例顺序带来了较高的标准差，原因很可能如 Zhao et al. (2021) 所述，对于分类任务，连续出现许多同一类别的示例会使模型输出产生偏向。
- **不同的示例数量**。 我们还发现，在改变少样本示例数量时，思维链提示带来的收益通常仍然存在。图 11 展示了五个数据集上的这一结果（我们没有足够的计算资源在全部数据集上运行此实验）。我们还在初步实验中发现，进一步增加标准提示中的示例数量并未带来显著收益（例如，将示例从 8 个增加到 16 个，并不足以使标准提示的性能提升到赶上思维链提示的程度）。
- **不同的语言模型**。 另一个有趣的问题是，对某个模型效果更好的提示，是否也对其他大语言模型效果更好。我们发现，使用相同提示时，思维链提示在三种模型（LaMDA、GPT-3 和 PaLM）上的所有数据集上都提升了性能，GPT-3 上的 CSQA 和 StrategyQA 除外（表 1、表 4、表 5）。思维链带来的收益不能在模型之间完美迁移，这是一个局限；后续工作可以研究，不同的预训练数据集和模型架构为何以及如何影响思维链提示所带来的性能增益。

不过，提示工程仍然重要。 尽管算术推理的结果相对于提示具有较好的稳健性，我们仍想明确指出，提示工程确实很重要，而且在许多情况下能够显著提升性能。 虽然大多数思维链标注都优于标准提示，但在许多情况下仍存在较大差异。 例如，在硬币翻转任务中，性能从标注者 A 的 99.6% 到标注者 C 的 71.4% 不等，不过两者都高于标准提示的 50.0%（见 表 7）。 甚至存在一些任务，提示工程是获得良好性能的必要条件。 在初步实验中，我们尝试使用思维链让语言模型将含有 5 个项目的列表顺序反转。 两位合著者尽了最大努力，仍无法写出能够解决该任务的思维链提示，而第三位合著者却写出了能够完美解决该任务的思维链。

如何以稳健的方式生成思维链标注，可能是一个有趣的未来研究方向。 例如，一个想法是通过提示让大语言模型自动生成思维链（并且可能在验证集上对此进行优化）。

A.3 思维链提示会提高我所关心任务的性能吗?

虽然思维链提示原则上适用于任何文本到文本的任务，但它对某些任务的帮助比对其他任务更大。 根据本文的实验，我们的直觉是，当满足以下三个条件时，思维链的帮助最大：（1）任务具有挑战性且需要多步推理，（2）使用大语言模型，以及（3）规模扩展曲线相对平坦。 反之，当其中一个或多个条件不满足时，收益就较小。

算术推理的结果或许支持这些直觉。 思维链提示带来的性能增益在 PaLM 540B 的 GSM8K 结果上最大，该情形满足上述条件（具有挑战性的多步问题、平坦的规模扩展曲线）。 对于 MAWPS 中仅需一步或两步的子集（SingleOP、SingleEq 和 AddSub），性能增益较小，因为 PaLM 540B 在这些子集上已经达到 90% 或更高的性能（而且通常而言，性能已经较好时，可供改进的空间也会更小）。

尽管本文重点研究了多步推理任务（算术、常识和符号推理），但思维链提示有可能适用于人类使用“思维链”来解决的任何任务（至少原则上如此）。 我们将思维链提示在这些多样化任务（例如机器翻译等）上的实证评估留待未来工作。

A.4 为什么对于某些算术推理数据集，仅用方程进行提示还不够?

仅用方程作为中间步骤进行提示，确实对许多数据集有帮助，尤其是那些只需要少量推理步骤的数据集（SVAMP、ASDiv、MAWPS）。然而，对于 GSM8K，仅使用方程并未显著改善性能。根据定性

分析，我们认为这些问题在语义上太具挑战性，模型难以直接将其转换为数学方程。考虑下面这个来自 LaMDA 137B 的例子：

> **问题：** 迈克打了 40 分钟乒乓球。在前 20 分钟里，他得了 4 分。在后 20 分钟里，他多得了 25% 的分数。他总共得了多少分?
>
> **仅使用方程（错误答案）：** (4 + 20 * 0.25) = 6。答案是 6。
>
> **思维链（正确）：** 迈克打了 40 分钟乒乓球。在前 20 分钟里，他得了 4 分。在后 20 分钟里，他多得了 25% 的分数。所以他在后 20 分钟的得分多了 25%。4 x 1.25 = 5。所以他在后 20 分钟里得了 5 分。因此他总共得了 9 分。答案是 9。

模型很难直接将全部语义转换成一个方程，但思维链使它能够通过自然语言形式的中间步骤，更好地推理问题的各个部分。

B 全部实验结果

本节提供了不同模型及模型规模在所有基准上的实验结果表，比较标准提示与思维链提示。

对于算术推理基准，有些思维链（连同生成的方程）本身正确，只是模型在某个算术运算上出错。Cobbe et al. (2021) 也观察到了类似现象。 因此，我们可以进一步加入一个 Python 程序作为外部计算器（使用 Python 的 `eval` 函数），应用于所生成思维链中的所有方程。 当思维链中存在多个方程时，我们通过字符串匹配，将一个方程的外部计算器结果传递给后续方程。 如 表 1 所示，我们发现，加入计算器能够显著提高思维链提示在大多数任务上的性能。

表 1: 在五项算术推理基准上，对各种大型语言模型使用思维链提示均优于标准提示。 所有指标均为准确率（%）。 外部计算器：仅对算术运算进行事后外部计算。 先前最优结果的数据来源如下。 *a*: Cobbe et al. (2021). *b* & *e*: Pi et al. (2022), *c*: Lan et al. (2021), *d*: Piękos et al. (2021).

	提示方法	GSM8K	SVAMP	ASDiv	AQuA	MAWPS
先前最优结果	不适用（微调）	55[a]	57.4[b]	75.3[c]	37.9[d]	88.4[e]
UL2 20B	标准	4.1	10.1	16.0	20.5	16.6
	思维链	4.4 (+0.3)	12.5 (+2.4)	16.9 (+0.9)	23.6 (+3.1)	19.1 (+2.5)
	+ 外部计算器	6.9	28.3	34.3	23.6	42.7
LaMDA 137B	标准	6.5	29.5	40.1	25.5	43.2
	思维链	14.3 (+7.8)	37.5 (+8.0)	46.6 (+6.5)	20.6 (-4.9)	57.9 (+14.7)
	+ 外部计算器	17.8	42.1	53.4	20.6	69.3
GPT-3 175B	标准	15.6	65.7	70.3	24.8	72.7
(text-davinci-002)	思维链	46.9 (+31.3)	68.9 (+3.2)	71.3 (+1.0)	35.8 (+11.0)	87.1 (+14.4)
	+ 外部计算器	49.6	70.3	71.1	35.8	87.5
Codex	标准	19.7	69.9	74.0	29.5	78.7
(code-davinci-002)	思维链	63.1 (+43.4)	76.4 (+6.5)	80.4 (+6.4)	45.3 (+15.8)	92.6 (+13.9)
	+ 外部计算器	65.4	77.0	80.0	45.3	93.3
PaLM 540B	标准	17.9	69.4	72.1	25.2	79.2
	思维链	56.9 (+39.0)	79.0 (+9.6)	73.9 (+1.8)	35.8 (+10.6)	93.3 (+14.2)
	+ 外部计算器	58.6	79.8	72.6	35.8	93.5

表 2: 五项算术推理基准上的标准提示与思维链提示比较。注意，思维链提示的效果是随模型规模增大而涌现的能力：只有模型规模足够大时，它才会带来性能提升。

		GSM8K		SVAMP		ASDiv		AQuA		MAWPS	
模型		标准	思维链	标准	思维链	标准	思维链	标准	思维链	标准	思维链
UL2	20B	4.1	**4.4**	10.1	**12.5**	16.0	**16.9**	20.5	**23.6**	16.6	**19.1**
LaMDA	420M	2.6	0.4	2.5	1.6	3.2	0.8	23.5	8.3	3.2	0.9
	2B	3.6	1.9	3.3	2.4	4.1	3.8	22.9	17.7	3.9	3.1
	8B	3.2	1.6	4.3	3.4	5.9	5.0	22.8	18.6	5.3	4.8
	68B	5.7	**8.2**	13.6	**18.8**	21.8	**23.1**	22.3	20.2	21.6	**30.6**
	137B	6.5	**14.3**	29.5	**37.5**	40.1	**46.6**	25.5	20.6	43.2	**57.9**
GPT	350M	2.2	0.5	1.4	0.8	2.1	0.8	18.1	8.7	2.4	1.1
	1.3B	2.4	0.5	1.5	1.7	2.6	1.4	12.6	4.3	3.1	1.7
	6.7B	4.0	2.4	6.1	3.1	8.6	3.6	15.4	13.4	8.8	3.5
	175B	15.6	**46.9**	65.7	**68.9**	70.3	**71.3**	24.8	**35.8**	72.7	**87.1**
Codex	-	19.7	**63.1**	69.9	**76.4**	74.0	**80.4**	29.5	**45.3**	78.7	**92.6**
PaLM	8B	4.9	4.1	15.1	**16.8**	23.7	**25.2**	19.3	**21.7**	26.2	**30.5**
	62B	9.6	**29.9**	48.2	46.7	58.7	**61.9**	25.6	22.4	61.8	**80.3**
	540B	17.9	**56.9**	69.4	**79.0**	72.1	**73.9**	25.2	**35.8**	79.2	**93.3**

表 3: MAWPS 基准的四个子集上标准提示与思维链提示的比较。将 MAWPS 基准按子集分层，旨在说明：对于大型语言模型已经表现良好的简单一步或两步问题（例如 SingleOp、SingleEq 和 AddSub），性能提升很小。

		SingleOp		SingleEq		AddSub		MultiArith	
模型		标准	思维链	标准	思维链	标准	思维链	标准	思维链
UL2	20B	24.9	**27.2**	18.0	**20.2**	18.5	18.2	5.0	**10.7**
LaMDA	420M	2.8	1.0	2.4	0.4	1.9	0.7	5.8	1.5
	2B	4.6	4.1	2.4	3.3	2.7	3.2	5.8	1.8
	8B	8.0	7.0	4.5	4.4	3.4	5.2	5.2	2.4
	68B	36.5	**40.8**	23.9	**26.0**	17.3	**23.2**	8.7	**32.4**
	137B	73.2	**76.2**	48.8	**58.7**	43.0	**51.9**	7.6	**44.9**
GPT	350M	3.2	1.8	2.0	0.2	2.0	1.5	2.3	0.8
	1.3B	5.3	3.0	2.4	1.6	2.3	1.5	2.2	0.5
	6.7B	13.5	3.9	8.7	4.9	8.6	2.5	4.5	2.8
	175B	90.9	88.8	82.7	**86.6**	83.3	81.3	33.8	**91.7**
Codex	-	93.1	91.8	86.8	**93.1**	90.9	89.1	44.0	**96.2**
PaLM	8B	41.8	**46.6**	29.5	28.2	29.4	**31.4**	4.2	**15.8**
	62B	87.9	85.6	77.2	**83.5**	74.7	**78.2**	7.3	**73.7**
	540B	94.1	94.1	86.5	**92.3**	93.9	91.9	42.2	**94.7**

表 4: 五项常识推理基准上的标准提示与思维链提示比较。思维链提示的效果是随模型规模增大而涌现的能力：只有模型规模足够大时，它才会带来性能提升。

		CSQA		StrategyQA		日期		体育		SayCan	
模型		标准	思维链	标准	思维链	标准	思维链	标准	思维链	标准	思维链
UL2	20B	34.2	**51.4**	59.0	53.3	13.5	**14.0**	57.9	**65.3**	20.0	**41.7**
LaMDA	420M	20.1	19.2	46.4	24.9	1.9	1.6	50.0	49.7	7.5	7.5
	2B	20.2	19.6	52.6	45.2	8.0	6.8	49.3	57.5	8.3	8.3
	8B	19.0	20.3	54.1	46.8	9.5	5.4	50.0	52.1	28.3	33.3
	68B	37.0	**44.1**	59.6	**62.2**	15.5	**18.6**	55.2	**77.5**	35.0	**42.5**
	137B	53.6	**57.9**	62.4	**65.4**	21.5	**26.8**	59.5	**85.8**	43.3	**46.6**
GPT	350M	14.7	15.2	20.6	0.9	4.3	0.9	33.8	41.6	12.5	0.8
	1.3B	12.0	19.2	45.8	35.7	4.0	1.4	0.0	26.9	20.8	9.2
	6.7B	19.0	**24.0**	53.6	50.0	8.9	4.9	0.0	4.4	17.5	**35.0**
	175B	79.5	73.5	65.9	65.4	43.8	**52.1**	69.6	**82.4**	81.7	**87.5**
Codex	-	82.3	77.9	67.1	**73.2**	49.0	**64.8**	71.7	**98.5**	85.8	**88.3**
PaLM	8B	19.8	**24.9**	55.6	53.5	12.9	13.1	55.1	**75.2**	34.2	**40.0**
	62B	65.4	**68.1**	58.4	**63.4**	29.8	**44.7**	72.1	**93.6**	65.8	**70.0**
	540B	78.1	**79.9**	68.6	**77.8**	49.0	**65.3**	80.5	**95.4**	80.8	**91.7**

表 5: 标准提示与思维链提示的比较：思维链提示使两项符号操作任务能够泛化到推理时更长的样例。

		末字母拼接						硬币翻转（状态跟踪）					
		2		分布外：3		分布外：4		2		分布外：3		分布外：4	
模型		标准	思维链	标准	思维链	标准	思维链	标准	思维链	标准	思维链	标准	思维链
UL2	20B	0.6	**18.8**	0.0	0.2	0.0	0.0	70.4	67.1	51.6	52.2	48.7	50.4
LaMDA	420M	0.3	**1.6**	0.0	0.0	0.0	0.0	52.9	49.6	50.0	50.5	49.5	49.1
	2B	2.3	**6.0**	0.0	0.0	0.0	0.0	54.9	**55.3**	47.4	48.7	49.8	50.2
	8B	1.5	**11.5**	0.0	0.0	0.0	0.0	52.9	**55.5**	48.2	49.6	51.2	50.6
	68B	4.4	**52.0**	0.0	**0.8**	0.0	**2.5**	56.2	**83.2**	50.4	**69.1**	50.9	**59.6**
	137B	5.8	**77.5**	0.0	**34.4**	0.0	**13.5**	49.0	**99.6**	50.7	**91.0**	49.1	**74.5**
PaLM	8B	2.6	**18.8**	0.0	0.0	0.0	**0.2**	60.0	**74.4**	47.3	**57.1**	50.9	**51.8**
	62B	6.8	**85.0**	0.0	**59.6**	0.0	**13.4**	91.4	**96.8**	43.9	**91.0**	38.3	**72.4**
	540B	7.6	**99.4**	0.2	**94.8**	0.0	**63.0**	98.1	**100.0**	49.3	**98.6**	54.8	**90.2**

表 6：算术推理数据集的消融和稳健性结果。思维链通常显著优于各个消融变体。“仅方程”的表现介于标准提示和思维链提示之间，因为它允许通过方程进行中间推理，但不利用自然语言。使用不同标注者编写的提示或其他示例时，思维链提示会产生波动（符合预期），但仍大幅优于标准提示。所示标准差来自少样本提示示例的不同排列顺序，使用五个不同的随机种子。这里展示 LaMDA 137B 的结果，因为额外调用 GPT-3 和 PaLM 既受限又昂贵。

	GSM8K	SVAMP	ASDiv	MAWPS
标准提示	6.5 ±0.4	29.5 ±0.6	40.1 ±0.6	43.2 ±0.9
思维链提示	14.3 ±0.4	36.7 ±0.4	46.6 ±0.7	57.9 ±1.5
消融实验				
· 仅方程	5.4 ±0.2	35.1 ±0.4	45.9 ±0.6	50.1 ±1.0
· 仅可变计算量	6.4 ±0.3	28.0 ±0.6	39.4 ±0.4	41.3 ±1.1
· 先回答后推理	6.1 ±0.4	30.7 ±0.9	38.6 ±0.6	43.6 ±1.0
稳健性				
· 不同标注者 (B)	15.5 ±0.6	35.2 ±0.4	46.5 ±0.4	58.2 ±1.0
· 不同标注者 (C)	17.6 ±1.0	37.5 ±2.0	48.7 ±0.7	60.1 ±2.0
· 刻意简洁的风格	11.1 ±0.3	38.7 ±0.8	48.0 ±0.3	59.6 ±0.7
· 来自 GSM8K 的示例 (α)	12.6 ±0.6	32.8 ±1.1	44.1 ±0.9	53.9 ±1.1
· 来自 GSM8K 的示例 (β)	12.7 ±0.5	34.8 ±1.1	46.9 ±0.6	60.9 ±0.8
· 来自 GSM8K 的示例 (γ)	12.6 ±0.7	35.6 ±0.5	44.4 ±2.6	54.2 ±4.7

表 7: 四个常识和符号推理数据集的消融和稳健性结果。思维链通常显著优于各个消融变体。使用不同标注者编写的提示或其他示例时，思维链提示会产生波动（符合预期），但仍大幅优于标准提示。所示标准差来自少样本提示示例的不同排列顺序，使用五个不同的随机种子。这里展示 LaMDA 137B 的结果，因为额外调用 GPT-3 和 PaLM 既受限又昂贵。例外是这里使用 PaLM 运行 SayCan，因为 SayCan 评估集只有 120 个样例，多次运行的成本较低。

	常识			符号	
	日期	体育	SayCan	拼接	硬币
标准提示	21.5 ±0.6	59.5 ±3.0	80.8 ±1.8	5.8 ±0.6	49.0 ±2.1
思维链提示	26.8 ±2.1	85.8 ±1.8	91.7 ±1.4	77.5 ±3.8	99.6 ±0.3
消融实验					
· 仅可变计算量	21.3 ±0.7	61.6 ±2.2	74.2 ±2.3	7.2 ±1.6	50.7 ±0.7
· 先回答后推理	20.9 ±1.0	63.0 ±2.0	83.3 ±0.6	0.0 ±0.0	50.2 ±0.5
稳健性					
· 不同标注者 (B)	27.4 ±1.7	75.4 ±2.7	88.3 ±1.4	76.0 ±1.9	77.5 ±7.9
· 不同标注者 (C)	25.5 ±2.5	81.1 ±3.6	85.0 ±1.8	68.1 ±2.2	71.4 ±11.1

C 相关工作的扩展讨论

思维链提示是一种通用方法，其灵感来自此前的多个研究方向：提示、自然语言解释、程序合成与执行、数值与逻辑推理，以及中间语言步骤。

C.1 提示

大规模语言模型近期的成功，使人们越来越关注如何通过提示来提高其执行任务的能力（Brown et al. (2020)；综述见 Liu et al. (2021)）。 本文属于通用提示方法这一类别，即通过优化输入提示，使单个大语言模型能够更好地执行多种任务 (Li and Liang, 2021; Lester et al., 2021; Reif et al., 2022, 等)。

近期的一条研究路线旨在通过提供描述任务的指令，改善语言模型执行任务的能力 (Raffel et al., 2020; Wei et al., 2022a; Ouyang et al., 2022; Sanh et al., 2022; Wang et al., 2022b)。 这条研究路线与本文相关，因为它也用元数据来扩充输入–输出对。不过，指令扩充的是任务的输入（指令通常置于输入之前），而思维链提示扩充的是语言模型的输出。 另一个相关方向是按顺序组合语言模型的输出；人机交互（HCI）领域的研究 (Wu et al., 2022a,b) 通过一项涉及 20 人的用户研究表明，组合语言模型依次生成的内容能够改善任务结果。

C.2 自然语言解释

另一个密切相关的方向是使用自然语言解释（NLE），其目标通常是提高模型的可解释性 (Zhou et al., 2020; Wiegreffe and Marasovic´, 2021, 等)。 这类工作通常关注自然语言推断 (Camburu et al., 2018; Yordanov et al., 2021; Bostrom et al., 2021)，并在生成最终预测的同时或之后产生解释 (Narang et al., 2020; Majumder et al., 2021; Wiegreffe et al., 2021, 2022)。 相比之下，本文所研究的思维链处理发生在最终答案*之前*。 此外，NLE 的目的主要是提高神经网络的可解释性 (Rajagopal et al., 2021)，而思维链提示的目标是让模型将多跳推理任务分解为多个步骤，可解释性只是其附带效果。 Marasovic´et al. (2022) 表明，利用 NLE 进行基于提示的微调能够改善自然语言推断和分类性能，不过他们主要关注对解释合理性的评估。 相比之下，我们的工作关注一系列需要多跳推理的算术、常识和符号任务。

C.3 程序合成与执行

在程序合成与执行领域，使用中间推理步骤有着悠久历史 (Zaremba and Sutskever, 2014, 等)。 这一方向的近期工作包括多项架构创新 (Cai et al., 2017; Dong et al., 2019; Yan et al., 2020)，以及大语言模型的使用 (Chen et al., 2021; Austin et al., 2021)。 与我们最接近的程序执行工作可能是 Nye et al. (2021)，他们表明，大语言模型可以完成最多 10 位数的加法、计算多项式的值，以及执行 Python 程序。 生成程序再执行程序可以被视为一种推理，而我们的工作将这种领域特定的基本操作推广到自然语言；自然语言是开放域的，原则上与任何文本到文本的自然语言处理任务都相关。

C.4 数值与逻辑推理

数值与逻辑推理是机器学习和自然语言处理领域长期研究的任务 (Lev et al., 2004, 等)。 近期的工作也试图通过多种方式将数值推理能力注入语言模型，例如用一组预定义的可执行操作来增强 BERT (Andor et al., 2019)、加入图神经网络 (Ran et al., 2019)，以及使用专门的训练流程 (Piękos et al., 2021)。 另一条研究路线旨在使语言模型能够进行逻辑推理或形式推理，其做法通常是使用自然语言

来表述形式规则 (Clark et al., 2020; Saeed et al., 2021; Liang et al., 2021)。 这里最相关的工作可能是 Recchia (2021)，它表明，微调能够使模型进行长除法取余运算，而这此前对 Transformer 模型而言很困难。 这一方向的工作通常针对特定任务并使用微调，而我们表明，思维链提示无需任何微调就能适用于广泛的任务。

C.5 中间语言步骤

大量先前工作表明，通过训练或微调赋予神经网络生成中间步骤的能力，能够在多种情境下带来各种益处。 例如，已有研究表明，自然语言形式的中间步骤可以 提高性能 (Zaidan et al., 2007; Yao et al., 2021; Hase and Bansal, 2022; Gu et al., 2022)， 提高稳健性 (Chen et al., 2022)， 加快训练 (Hancock et al., 2018)， 减轻偏见 (Dua et al., 2020)， 甚至在图像和强化学习场景下也能提供帮助 (Andreas et al., 2018)。 为了赋予模型生成中间步骤的能力，先前工作通常使用人工标注的训练数据集进行微调 (Camburu et al., 2018; Rajani et al., 2019, 等)，或生成合成数据集 (Talmor et al., 2020; Zelikman et al., 2022)。 与这些训练或微调方法相比，我们的工作表明，只需通过提示，就能从足够大规模的现成语言模型中引出多种自然语言推理能力。 这种提示设置很重要，因为它无需大量带标签的标注就能实现中间步骤推理，而且单个模型无需任何梯度更新就能执行一系列推理任务。

D 附录：补充分析

D.1 正确思维链分析

如正文所述，我们分析了 LaMDA 137B 在 GSM8K 数据集上得到正确答案的 50 条思维链。 在这 50 条思维链中，只有一条是通过错误推理得出正确答案的（见 表 9：“偶然正确”）。 其余 49 条的逻辑和数学运算均正确，示例见 表 8。 其中五条存在轻微瑕疵，但仍保持了连贯且可理解的逻辑：

- 一条包含说明不够明确的陈述（见 表 9：“正确但陈述不够明确”）。
- 一条作出了无关但正确的陈述（见 表 9：“正确但陈述无关”）。
- 两条逻辑正确，但方程中省略了具体步骤，不过仍然可以理解（见 表 9：“正确但方程不完善”）。
- 一条数学运算正确，但语义颠倒（见 表 9：“正确但语义颠倒”）。

表 8：模型针对 GSM8K 数据集生成的正确思维链示例。

问题： James 决定每周进行 3 次短跑训练，每次跑 3 趟，每趟 60 米。他每周总共跑多少米? **模型回答 （正确）：** James 决定每周进行 3 次短跑训练，每次跑 3 趟。每趟跑 60 米。因此他每周跑 60 米 x 3 趟 x 3 次。也就是 60 米 x 9。 答案是 540. ✓
问题： Brandon 的 iPhone 使用年限是 Ben 的四倍。Ben 的 iPhone 使用年限是 Suzy 的两倍。如果 Suzy 的 iPhone 使用了 1 年，Brandon 的 iPhone 使用了多少年? **模型回答 （正确）：** Brandon 的 iPhone 使用年限是 Ben 的 4 倍。Ben 的 iPhone 使用年限是 Suzy 的 2 倍。因此 Brandon 的 iPhone 使用年限是 Suzy 的 4 x 2 = 8 倍。Suzy 的 iPhone 使用了 1 年。因此 Brandon 的 iPhone 使用了 8 x 1 = 8 年。 答案是 8. ✓
问题： Jean 有 30 根棒棒糖。Jean 吃掉 2 根。她想把剩下的棒棒糖每 2 根装进一个袋子。Jean 能装满多少个袋子? **模型回答 （正确）：** Jean 最初有 30 根棒棒糖。她吃了其中 2 根。因此还剩 28 根。她想每 2 根装一袋。因此可以装 28 / 2 = 14 袋。 答案是 14. ✓

虽然我们发现，对于最终答案正确的数学题，思维链推理大多也是正确的，但这很可能是因为对于开放作答题，偶然得到正确的最终答案较为困难。 对于选择题或二分类问题，模型更有可能通过错误的推理路径得出正确答案（例如我们评估的所有常识推理数据集）。 这是一个局限，未来的工作应分析这类思维链的事实正确性。

表 9: 在模型答对的 50 个样例中，有 7 个明显案例的生成思维链并不完善。我们发现，其余 43 个与人类可能写出的标准答案相当。

问题： 有 36 只企鹅在雪地里晒太阳。其中三分之一跳进海里游泳，另有三分之一进入洞穴吃晚餐。还剩多少只企鹅在晒太阳? **模型回答** **（碰巧正确）：**共有 36 只企鹅。其中三分之一跳进海里游泳。所以是 12 只企鹅。另有三分之一进入洞穴吃晚餐。所以是 12 只企鹅。 答案是 12.
问题： John 有 2 栋房屋，每栋有 3 间卧室。每间卧室有 2 扇窗户。此外，每栋房屋还有 4 扇不属于卧室的窗户。两栋房屋共有多少扇窗户? **模型回答** **（正确，但陈述不够明确）：**有 2 栋房屋，每栋有 3 间卧室。每间卧室有 2 扇窗户。因此每栋房屋有 2 x 3 = 6 扇窗户。此外，每栋房屋还有 4 扇不属于卧室的窗户。 因此每栋房屋有 4 + 4 = 8 扇窗户。因此每栋房屋有 6 x 2 = 12 扇窗户。 因此两栋房屋共有 12 + 8 = 20 扇窗户。 答案是 20.
问题： Ann 今年 9 岁，她哥哥的年龄是她的两倍。3 年后她哥哥几岁? **模型回答** **（正确，但含无关陈述）：**Ann 今年 9 岁。她哥哥的年龄是她的两倍。因此她哥哥今年 18 岁。3 年后， 她将是 12 岁。 因此她哥哥将是 18 + 3 = 21 岁。 答案是 21.
问题： 一家本地加油站以每加仑 $3.00 的价格销售汽油。某应用公司规定，在该站加油可获得每加仑 $.20 的返现。如果某人购买 10 加仑汽油，扣除返现奖励后，汽油实际花费是多少? **模型回答** **（正确，但算式不完善）：**汽油原价为每加仑 3 美元。如果买 10 加仑，就是 3 x 10 = 30 美元。 如果每加仑优惠 20 美分，就是 20 x 10 = 2 美元。 因此总价为 30 - 2 = 28 美元。 答案是 28 美元。
问题： Nissa 雇用 60 名季节工，在她的百货商店圣诞村里扮演精灵。三分之一的精灵因被孩子吐到身上而辞职，随后剩余精灵中又有 10 人因被孩子踢到小腿而辞职。还剩多少名精灵? **模型回答** **（正确，但算式不完善）：**Nissa 雇用 60 名季节工。其中三分之一辞职。 因此还剩 60 - 1/3 = 40 名精灵。 随后 10 名精灵辞职。因此还剩 40 - 10 = 30 名精灵。 答案是 30 名精灵。
问题： Jones 奶奶为消防员午宴烤了 5 个苹果派。她把每个派切成 8 块，将五个派摆在自助餐桌上供客人自取。傍晚结束时，客人取食后还剩 14 块派。客人拿走了多少块? **模型回答** **（正确，但语义颠倒）：**烤好了 5 个派，每个切成 8 块。然后把 5 个派提供给客人。8 x 5 = 40 块派。 客人吃了 14 块派。还剩 40 - 14 = 26 块派。 答案是 26. ✓

D.2 错误思维链分析

我们还人工分析了从 LaMDA 137B 在 GSM8K 上的错误输出中随机抽取的 50 个样本。 思维链可能以许多方式出错，这使得错误分类的设计并不简单。 我们决定根据需要作出哪些修改才能使思维链正确来对错误分类，目的是阐明未来可以如何改进模型。

我们发现，许多思维链可以通过以下三类修改中的某一类变得正确。

- **仅有计算错误**。 我们发现，8% 的思维链除了一个计算错误外完全正确，换言之，像 Cobbe et al. (2021) 那样将外部计算器应用于方程，就能使思维链正确。表 10 中的“仅有计算错误”展示了此类错误的一个例子。事实上，当我们加入一个 Python 程序作为外部计算器时，LaMDA 137B 使用思维链提示在 GSM8K 上的解题率从 14.3% 提高到了 17.3%，如 表 2 所示。 此外，还有 34% 的样本在包含其他类型错误的同时，也包含计算错误。不过，我们对其余错误进行分类时，不考虑计算错误。
- **符号映射错误**。 接下来我们发现，16% 的思维链除了我们所称的符号映射错误外均正确。我们将符号映射错误定义为：思维链除数字符号以外均正确，而且仅修改方程、不修改文字，就能使其完全正确。 有人可能会认为，只要将正确的最终方程放进任何思维链即可，因此我们将此类别限定为：修改后能够成为完全正确的推理过程，而不只是最终答案正确的思维链。表 10 中的“符号映射错误”展示了此类错误的一个例子。
- **遗漏一步错误**。 下一类错误是除了遗漏一个步骤之外均正确的思维链。换言之，这些思维链只需补上模型遗漏的一个推理步骤，就可以改写为正确的思维链。表 10 中的“遗漏一步错误”展示了此类错误的一个例子。我们发现，22% 的错误属于这一类别。

表 10：错误思维链示例，按节 D.2所述方式分类。

问题： Dan 种了 3 株玫瑰。每株有 25 朵玫瑰花。每朵花有 8 根刺。一共有多少根刺? **模型回答 （错误；仅计算错误）：** Dan 种了 3 株玫瑰。每株有 25 朵玫瑰花。每朵花有 8 根刺。因此 3 x 25 x 8 = 300. 答案是 300. × **错误类别说明：** 只需用外部计算器计算该算式，而不是要求模型计算，就能使生成的思维链正确。
问题： Jill 教课每小时收入 $20，担任啦啦队教练每小时收入 $30。如果她一年工作 50 周，每周教课 35 小时、担任教练 15 小时，她的年薪是多少? **模型回答 （错误；符号映射错误）：** Jill 教课每小时收入 20 美元，担任啦啦队教练每小时收入 30 美元。如果她一年工作 50 周，每周教课 35 小时、担任教练 15 小时，那么她教课的时间为 50 x 35 = 1750 小时，担任教练的时间为 15 x 30 = 450 小时。因此她工作 1750 + 450 = 2200 小时。其中 1750 小时每小时收入 20 美元，450 小时每小时收入 30 美元。因此年薪为 20 x 1750 + 30 x 450 = $36,500。 答案是 $36,500. × **错误类别说明：** 模型错误地映射为“15 x 30”，而不是“15 x 50”。只需修正这一处（并使用外部计算器），即可使思维链正确。
问题： Kelian 有两份食谱，一份包含 20 条说明，另一份的说明数量是第一份的两倍。准备这两道菜，Kelian 一共需要阅读多少条说明? **模型回答 （错误；缺失一个步骤）：** Kelian 有两份食谱。一份包含 20 条说明，另一份的说明数量是第一份的两倍。因此第二份有 40 条说明。所以准备两道菜，Kelian 需要阅读 40 条说明。 答案是 40. × **错误类别说明：** 只需增加一个步骤，就能使模型答案正确（在本例中，把 20 和 40 相加）。

我们发现，其余思维链（50 条中的 27 条；54%）需要大量修改，才能成为正确的思维链。 这里几乎所有样本都涉及某种语义理解错误（见 表 11：“语义理解错误”），这 27 条中还有 8 条的思维链不连贯，即所生成思维链中的某些陈述无法从先前陈述推出，或违背了基本的世界知识（见 表 11：“思维链不连贯错误”）。

表 11: 错误思维链示例，按节 D.2所述方式分类。 这些思维链包含多个错误，无法通过小幅修改修正。

问题： Gretchen 有 110 枚硬币。金币比银币多 30 枚。Gretchen 有多少枚金币? **模型回答 （错误；语义理解错误）：** Gretchen 有 110 枚硬币。金币比银币多 30 枚。因此有 110 - 30 = 80 枚银币。所以有 80 枚银币，以及 110 - 80 = 30 枚金币。 答案是 30. × **错误类别说明：** 模型没有理解 110 枚是硬币总数，也没有理解必须解方程才能得到金币和银币的数量。
问题： 一个舞蹈班有 20 名学生，20% 报了现代舞，剩下学生中的 25% 报了爵士舞，其余报了街舞。报街舞的学生占全部学生的百分之几? **模型回答 （错误；思维链不连贯）：** 20% 的学生报了现代舞。剩下学生中的 25% 报了爵士舞。其余报了街舞。因此 报街舞的学生占全部学生的比例等于报街舞的学生比例，减去 报现代舞的学生比例， 减去报爵士舞的学生比例。 因此报街舞的学生占全部学生的比例为 (25 + 20) - (25 + 20) = 100%。 答案是 100%. × **错误类别说明：** 这条思维链不连贯，因为报街舞的学生占全部学生的比例，不可能等于报街舞的学生比例再减去另一项。

总体而言，无法保证大语言模型生成的推理过程连贯或在事实上正确，近期对语言模型生成内容及解释的事实正确性进行评估的工作也强调了这一点 (Maynez et al., 2020; Rashkin et al., 2021; Ye and Durrett, 2022; Marasovic´et al., 2022; Wiegreffe et al., 2022)。错误的推理过程既可能导致错误的最终答案，也可能偶然得到正确的最终答案（与开放作答任务相比，在二分类等任务中更有可能偶然得到正确的最终答案）。提高语言模型生成内容相对于上下文和世界知识的事实正确性，是语言模型研究中一个重要且尚未解决的研究方向，也有望改善语言模型的多步推理能力。提高解码质量的一种潜在方法，是生成多条推理路径，再使用验证器对各条路径进行评分，不过这需要训练验证器 (Cobbe et al., 2021; Shen et al., 2021; Thoppilan et al., 2022)。

D.3 补充稳健性分析

由于正文中的实验使用了固定数量的少样本示例（8 个，受限于 1024 个词元的输入长度），我们验证了思维链提示在少样本示例数量变化时的稳健性。 我们使用 LaMDA 137B 进行实验，在标准提示的规模扩展曲线大体平坦（最大模型未能获得较高性能）的五个数据集上，比较思维链提示与标准提示。 如 图 11 所示，在改变提示中少样本示例的数量时，思维链提示相对于标准提示的提升仍然保持稳健。

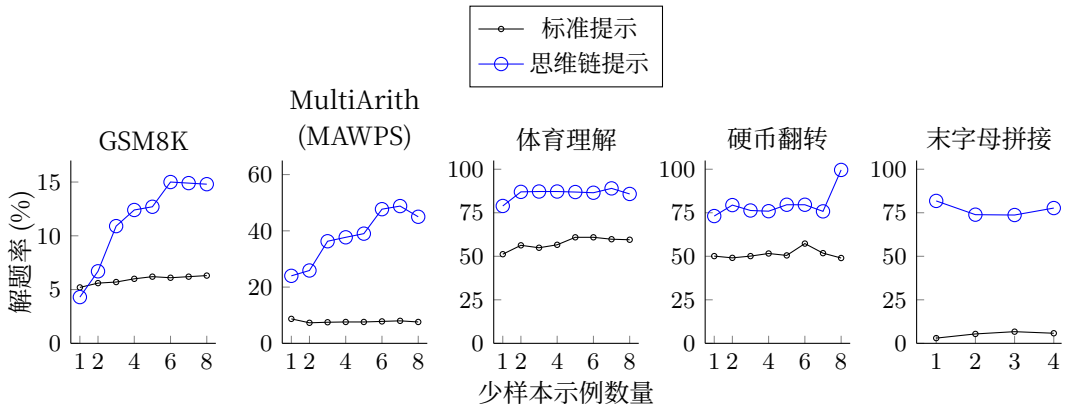


图 11: 改变提示中少样本示例的数量时，思维链提示相较标准提示的提升依然稳健。

表 12：本文使用的数学应用题基准及样例汇总。N：评估样例数。

数据集	N	示例问题
GSM8K	1,319	Josh 决定尝试翻修房屋后转售。他以 $80,000 购入一栋房屋，又投入 $50,000 进行修缮。这使房屋价值增加了 150%。他赚了多少利润?
SVAMP	1,000	每包 DVD 售价 76 美元。如果每包优惠 25 美元，买一包需要支付多少钱?
ASDiv	2,096	[示例题目删节：ASDiv 上游教学题目授权未核清。]
AQuA	254	一辆汽车以匀速沿直线驶向一座竖直塔的底部。从车内观察塔顶，仰角从 45° 变为 60° 经过了 10 分钟。还需要多久汽车才能到达塔底？ 选项： (a) $5\sqrt{3}$ + 1 (b) $6\sqrt{3}$ + $\sqrt{2}$ (c) $7\sqrt{3}$ - 1 (d) $8\sqrt{3}$ - 2 (e) 以上均不是
MAWPS: SingleOp	562	[示例题目删节：MAWPS 对应原始题目许可未核清。]
MAWPS: SingleEq	508	[示例题目删节：MAWPS 对应原始题目许可未核清。]
MAWPS: AddSub	395	[示例题目删节：MAWPS 对应原始题目许可未核清。]
MAWPS: MultiArith	600	[示例题目删节：MAWPS 对应原始题目许可未核清。]

E 补充细节

版本记录

V5 → V6。修正了图 3 中的一处小笔误。

V4 → V5。添加了 Codex 和 UL2 的结果。对论文的文字表述和风格作了少量调整。

V3 → V4。修正了图 3 中的笔误，并补充了几处引用。

V2 → V3。添加了 GPT-3 的结果。为数学任务添加了 SVAMP 和 AQuA 评估数据集。为常识任务添加了 SayCan 评估。添加了相关工作的扩展讨论一节（节 C）。添加了常识推理和符号推理的消融实验（表 7）。添加了常见问题一节（节 A）。在 节 B 中添加了原始结果。

V1 → V2。添加了 PaLM 的结果（V1 只有 LaMDA）。

E.1 可复现性声明

由于我们的结果使用了两组未公开提供的大语言模型，我们采取以下措施来促进可复现性。 首先，[公开版编者注：下述为原文的可复现性声明，公开版删节项目见文末。]我们在 节 G 的 表 20–表 27 中提供了所有任务的确切输入提示（并强调，我们没有进行任何微调，只对现成的语言模型应用提示）。 其次，我们使用公开可用的 GPT-3 API，在四种模型规模上进行实验：text-ada-001、text-babbage-001、text-curie-001、text-davinci-002。 最后，我们在补充材料中以 zip 文件的形式，提供了 LaMDA 137B 在每个任务上的确切输入、目标答案和预测结果。

E.2 计算资源

对于所评估的全部三种语言模型，我们仅进行了基于提示的推断。本文未进行任何微调。对于 LaMDA 137B 的推断，我们使用 TPU v3（8x8 配置，64 个芯片 / 128 个核心）；对于 PaLM 540B 的推断，我们使用 TPU v4（4x4x12 配置，192 个芯片 / 384 个核心）。GPT-3 实验通过公开 API 完成。[5]

E.3 数据集细节与许可证

[公开版编者注：本节保留原论文对许可证的历史陈述，不代表本次逐项核验结论。公开再分发所实际采用的许可、保留范围和删节以文末说明为准。]我们列出本文所用全部算术和常识数据集的细节与许可证。符号推理数据集通过合成方式创建，如 节 4 所述。

算术推理

- 数学应用题库（Math Word Problem Repository）(Koncel-Kedziorski et al., 2016)：AddSub (Hosseini et al., 2014)：https://www.cs.washington.edu/nlp/arithmetic； MultiArith (Roy and Roth, 2015)，许可证：CC BY 4.0。
- ASDiv (Miao et al., 2020)：https://github.com/chaochun/nlu-asdiv-dataset。
- AQuA (Ling et al., 2017)：https://github.com/deepmind/AQuA，许可证：https://github.com/deepmind/AQuA/blob/master/LICENSE。
- GSM8K (Cobbe et al., 2021)：https://github.com/openai/grade-school-math，MIT 许可证：https://github.com/openai/grade-school-math/blob/master/LICENSE。

[5] https://beta.openai.com/docs/api-reference/making-requests

- SVAMP (Patel et al., 2021)：https://github.com/arkilpatel/SVAMP，MIT 许可证：https://github.com/arkilpatel/SVAMP/blob/main/LICENSE。

常识推理

- CSQA (Talmor et al., 2019)：https://www.tau-nlp.org/commonsenseqa，https://github.com/jonathanherzig/commonsenseqa。
- StrategyQA (Geva et al., 2021)：我们使用 BIG-bench collaboration (2021) 中的开放域设置（仅含问题的集合）：https://github.com/google/BIG-bench/tree/main/bigbench/benchmark_tasks/strategyqa。原始数据集来自 https://github.com/eladsegal/strategyqa，MIT 许可证：https://github.com/eladsegal/strategyqa/blob/main/LICENSE。
- BIG-Bench (BIG-bench collaboration, 2021) 中的日期理解和体育理解：Apache 许可证 v.2：https://github.com/google/BIG-bench/blob/main/LICENSE。
- SayCan (Ahn et al., 2022)：SayCan 数据集可在 https://say-can.github.io/ 获取，采用 CC BY 4.0 许可证。

F 附录：输入/输出示例

表 13: 以下是 LaMDA 137B 在字母拼接任务上生成的正确与错误思维链示例。

问题： 取出 “Waldo Schmidt” 中各单词的最后一个字母，并将它们拼接起来。 **模型回答 （正确）：** “Waldo” 的最后一个字母是 “o”。 “Schmidt” 的最后一个字母是 “t”。 将它们拼接起来得到 “ot”. 因此答案是 ot. ✓
问题： 取出 “Daniel Friedman” 中各单词的最后一个字母，并将它们拼接起来。 **模型回答 （错误）：** “Daniel” 的最后一个字母是 “l”。 “Friedman” 的最后一个字母是 “m”。 将它们拼接起来得到 “lm”. 因此答案是 lm. ×

表 14: 以下是 LaMDA 137B 在硬币翻转任务上生成的正确与错误思维链示例。

问题： 一枚硬币正面朝上。 Andree 翻转了硬币。 Audrie 没有翻转硬币。 硬币是否仍然正面朝上? **模型回答 （正确）：** 硬币的翻转者是 Andree. 所以硬币被翻转了 1 次，这是奇数。 硬币起初正面朝上，因此翻转奇数次后会反面朝上。 因此答案是否。 ✓
问题： 一枚硬币正面朝上。 Kristian 没有翻转硬币。 Dallas 没有翻转硬币。 硬币是否仍然正面朝上? **模型回答 （错误）：** 硬币被 Kristian 翻转了。 所以硬币被翻转了 1 次，这是奇数。 硬币起初正面朝上，因此翻转奇数次后会反面朝上。 因此答案是否。 ×

表 15: 以下是 LaMDA 137B 在 CSQA 上生成的正确与错误思维链示例。

[公开版定点删节：尚未核得 CommonsenseQA 此处具体题目可公开再分发及改编的许可，省略题目、选项及对应输出。保留表号、标题与正文统计及研究分析。]

表 16: 以下是 LaMDA 137B 在 StrategyQA 上生成的正确与错误思维链示例。

问题： 《驱魔人》会刺激边缘系统吗? **模型回答 （正确）：** 《驱魔人》是一部恐怖电影。恐怖电影令人害怕。边缘系统参与恐惧反应。因此，《驱魔人》会刺激边缘系统。 因此答案是是。 ✓
问题： Jackson Pollock 是否接受过 Leonardo da Vinci 的训练? **模型回答 （正确）：** Leonardo da Vinci 生活在 15 世纪。Jackson Pollock 生活在 20 世纪。因此，Jackson Pollock 不可能接受过 Leonardo da Vinci 的训练。 因此答案是否。 ✓
问题： Harry Potter 能预订韩亚航空的航班吗? **模型回答 （错误）：** Harry Potter 是虚构人物。 因此，Harry Potter 可以做任何事情。 因此答案是是。 × (标准答案为 “否”.)
问题： 诡辩家会使用重剑吗? **模型回答 （错误）：** 诡辩家是擅长说服术的人。重剑是一种剑。 因此，诡辩家可以使用重剑。 因此答案是是。 × (标准答案为 “否”.)

表 17：以下是 LaMDA 137B 在日期理解任务上生成的正确与错误思维链示例。

问题： 对 Jane 来说，1992 年 5 月 6 日仿佛就在昨天，但实际上已是十年前。一个月前的日期是什么？请用 MM/DD/YYYY 格式回答。 **模型回答 （正确）：** 1992 年 5 月 6 日是十年前，因此今天是 2002 年 5 月 6 日。一个月前是 2002 年 4 月 6 日。因此答案是 04/06/2002。 ✓
问题： 今天是 1899 年的最后一天。24 小时后的日期是什么？请用 MM/DD/YYYY 格式回答。 **模型回答 （正确）：** 今天是 12/31/1899。24 小时后是 01/01/1900。 因此答案是 01/01/1900. ✓
问题： Jane 安排明天（周二，7/9/1972）与 5 个人进行 3 场会面。从今天算起一周前的日期是什么？请用 MM/DD/YYYY 格式回答。 **模型回答 （错误）：** 明天是 7/9/1972。 从今天算起一周前是 7/2/1972。 因此答案是 7/2/1972. × (标准答案为 07/01/1972.)
问题： 今天是 2020 年的回文日，因为日期的 MMDDYYYY 格式正读和倒读相同。明天的日期是什么？请用 MM/DD/YYYY 格式回答。 **模型回答 （错误）：** 今天是 02/29/2020。 明天是 03/01/2020。 因此答案是 03/01/2020. × (标准答案为“02/03/2020”.)

表 18：以下是 LaMDA 137B 在体育理解任务上生成的正确与错误思维链示例。

问题： 下列句子是否合理？ “Joao Moutinho 在三垒被判出局。” **模型回答 （正确）：** Joao Moutinho 是足球运动员。 三垒出局属于棒球，而不是足球。 因此答案是否。 ✓
问题： 下列句子是否合理？ “Malcolm Brogdon 在 NBA 总决赛中用欧洲步上篮。” **模型回答 （正确）：** Malcolm Brogdon 是篮球运动员。 欧洲步上篮属于篮球。 因此答案是是。 ✓
问题： 下列句子是否合理？ “Derrick White 反手射门。” **模型回答 （错误）：** Derrick White 是篮球运动员。 反手射门属于篮球。 因此答案是是。 × (标准答案为“否”, 反手射门属于冰球。)
问题： 下列句子是否合理？ “Nazem Kadri 在本垒被判出局。” **模型回答 （错误）：** Nazem Kadri 是冰球运动员。 本垒出局属于冰球。 因此答案是是。 × (标准答案为“否”, 本垒出局属于棒球。)

表 19：由 PaLM 540B 在 SayCan 机器人规划任务中生成的正确与错误思维链示例。

[公开版定点删节：此处 SayCan 题目、提示及对应输出未能完成与官方材料的逐项来源核验。保留原表编号、标题及正文研究结论；不表示其官方数据集无开放许可。]

G 附录：完整提示

表 20: 数学应用题完整思维链提示的少样本示例。除 AQuA 外，所有数学应用题数据集都使用这组示例。

提示：数学应用题

问： 小树林里有 15 棵树。工人今天将在这里植树。完工后，树林里将有 21 棵树。工人今天种了多少棵树?
答： 原来有 15 棵树。又种了一些之后共有 21 棵。因此一定种了 21 - 15 = 6。 答案是 6.

问： 停车场里有 3 辆车，又来了 2 辆，停车场里现在有多少辆车?
答： 原来有 3 辆车。又来了 2 辆。3 + 2 = 5。 答案是 5.

问： Leah 有 32 块巧克力，她的姐妹有 42 块。如果她们吃掉了 35 块，还总共剩下多少块?
答： 原来，Leah 有 32 块巧克力，她的姐妹有 42 块。因此一共有 32 + 42 = 74 块。吃掉 35 块后，剩下 74 - 35 = 39 块。 答案是 39.

问： Jason 有 20 根棒棒糖。他给了 Denny 一些。现在 Jason 有 12 根棒棒糖。他给了 Denny 多少根?
答： Jason 最初有 20 根棒棒糖。给了 Denny 一些之后还剩 12 根。因此他给了 Denny 20 - 12 = 8 根。 答案是 8.

问： Shawn 有五个玩具。圣诞节时，妈妈和爸爸各送了他两个玩具。他现在有多少个玩具?
答： Shawn 最初有 5 个玩具。如果妈妈和爸爸各送他 2 个，那么又多了 4 个。5 + 4 = 9。 答案是 9.

问： 服务器机房原来有九台计算机。从星期一到星期四，每天又安装五台。机房现在有多少台计算机?
答： 原来有 9 台计算机。在 4 天中的每一天，又增加了 5 台。因此共增加 5 * 4 = 20 台。9 + 20 等于 29。 答案是 29.

问： Michael 有 58 个高尔夫球。星期二，他丢了 23 个。星期三，他又丢了 2 个。到星期三结束时，他还剩多少个高尔夫球?
答： Michael 最初有 58 个高尔夫球。星期二丢了 23 个后，他有 58 - 23 = 35 个。再丢 2 个后，他有 35 - 2 = 33 个高尔夫球。 答案是 33.

问： Olivia 有 $23。她买了五个贝果，每个 $3。她还剩多少钱?
答： Olivia 原有 23 美元。5 个贝果每个 3 美元，一共是 5 x 3 = 15 美元。因此她还剩 23 - 15 美元。23 - 15 等于 8。 答案是 8.

表 21：AQuA 完整思维链提示的少样本示例。

提示：AQuA 代数应用题
问： John 发现 15 个数的平均数是 40。如果每个数都加上 10，那么这些数的平均数是多少?
选项：(a) 50 (b) 45 (c) 65 (d) 78 (e) 64
答： 如果每个数都加上 10，那么平均数也增加 10。因此新的平均数为 50。 答案是 (a).

问： 如果 a / b = 3/4 且 8a + 5b = 22，求 a 的值。
选项：(a) 1/2 (b) 3/2 (c) 5/2 (d) 4/2 (e) 7/2
答： 如果 a / b = 3/4，则 b = 4a / 3。因此 8a + 5(4a / 3) = 22。化简得 8a + 20a / 3 = 22，即 44a / 3 = 22。所以 a 等于 3/2。 答案是 (b).

问： 一个人以 20 km/hr 的速度行进，2.5 hr 后到达目的地。求行进距离?
选项：(a) 53 km (b) 55 km (c) 52 km (d) 60 km (e) 50 km
答： 这个人的行进距离为 20 km/hr * 2.5 hrs = 50 km。 答案是 (e).

问： 输入从 1 到 500 的所有数字需要敲击多少次按键?
选项：(a) 1156 (b) 1392 (c) 1480 (d) 1562 (e) 1788
答： 从 1 到 9 共有 9 个一位数。从 10 到 99 共有 90 个两位数。从 100 到 500 共有 401 个三位数。9 + 90(2) + 401(3) = 1392。 答案是 (b).

表 22：末字母拼接任务完整思维链提示的少样本示例。

提示：末字母拼接
问： 取出 ”Elon Musk” 中各单词的最后一个字母，并将它们拼接起来。
答： ”Elon” 的最后一个字母是 ”n”。 ”Musk” 的最后一个字母是 ”k”。 将它们拼接起来得到 ”nk”. 答案是 nk.

问： 取出 ”Larry Page” 中各单词的最后一个字母，并将它们拼接起来。
答： ”Larry” 的最后一个字母是 ”y”。 ”Page” 的最后一个字母是 ”e”。 将它们拼接起来得到 ”ye”. 答案是 ye.

问： 取出 ”Sergey Brin” 中各单词的最后一个字母，并将它们拼接起来。
答： ”Sergey” 的最后一个字母是 ”y”。 ”Brin” 的最后一个字母是 ”n”。 将它们拼接起来得到 ”yn”. 答案是 yn.

问： 取出 ”Bill Gates” 中各单词的最后一个字母，并将它们拼接起来。
答： ”Bill” 的最后一个字母是 ”l”。 ”Gates” 的最后一个字母是 ”s”。 将它们拼接起来得到 ”ls”. 答案是 ls.

表 23：硬币翻转任务完整思维链提示的少样本示例。

提示：硬币翻转

问： Q: 一枚硬币正面朝上。 Ka 翻转了硬币。 Sherrie 翻转了硬币。 硬币是否仍然正面朝上?
答： 硬币的翻转者是 Ka 和 Sherrie. 所以硬币被翻转了 2 次，这是偶数。 硬币起初正面朝上，因此翻转偶数次后仍会正面朝上。 因此答案是是。

问： 一枚硬币正面朝上。 Jamey 翻转了硬币。 Teressa 翻转了硬币。 硬币是否仍然正面朝上?
答： 硬币的翻转者是 Jamey 和 Teressa. 所以硬币被翻转了 2 次，这是偶数。 硬币起初正面朝上，因此翻转偶数次后仍会正面朝上。 因此答案是是。

问： 一枚硬币正面朝上。 Maybelle 翻转了硬币。 Shalonda 没有翻转硬币。 硬币是否仍然正面朝上?
答： 硬币的翻转者是 Maybelle. 所以硬币被翻转了 1 次，这是奇数。 硬币起初正面朝上，因此翻转奇数次后会反面朝上。 因此答案是否。

问： 一枚硬币正面朝上。 Millicent 没有翻转硬币。 Conception 翻转了硬币。 硬币是否仍然正面朝上?
答： 硬币的翻转者是 Conception. 所以硬币被翻转了 1 次，这是奇数。 硬币起初正面朝上，因此翻转奇数次后会反面朝上。 因此答案是否。

问： 一枚硬币正面朝上。 Sal 翻转了硬币。 Raymond 没有翻转硬币。 硬币是否仍然正面朝上?
答： 硬币的翻转者是 Sal. 所以硬币被翻转了 1 次，这是奇数。 硬币起初正面朝上，因此翻转奇数次后会反面朝上。 因此答案是否。

问： 一枚硬币正面朝上。 Conception 翻转了硬币。 Kristian 没有翻转硬币。 硬币是否仍然正面朝上?
答： 硬币的翻转者是 Conception. 所以硬币被翻转了 1 次，这是奇数。 硬币起初正面朝上，因此翻转奇数次后会反面朝上。 因此答案是否。

问： 一枚硬币正面朝上。 Inga 没有翻转硬币。 Elanor 没有翻转硬币。 硬币是否仍然正面朝上?
答： 没有人翻转硬币。 所以硬币被翻转了 0 次。 硬币起初正面朝上，且未被翻转，因此仍然正面朝上。 因此答案是是。

问： 一枚硬币正面朝上。 Ryan 翻转了硬币。 Shaunda 翻转了硬币。 硬币是否仍然正面朝上?
答： 硬币的翻转者是 Ryan 和 Shaunda. 所以硬币被翻转了 2 次，这是偶数。 硬币起初正面朝上，因此翻转偶数次后仍会正面朝上。 因此答案是是。

表 24：CSQA 完整思维链提示的少样本示例。各选项之间原有换行，表中为节省空间而省略。

[公开版定点删节：尚未核得 CommonsenseQA 此处具体题目可公开再分发及改编的许可，省略题目、选项及对应输出。保留表号、标题与正文统计及研究分析。]

表 25：StrategyQA 完整思维链提示的少样本示例。

提示：StrategyQA

问： 仓鼠会成为某些动物的食物吗?
答： 仓鼠属于被捕食的动物。猎物是捕食者的食物。因此，仓鼠会成为某些动物的食物。 因此答案是是。

问： Brooke Shields 能在宾夕法尼亚大学取得成功吗?
答： Brooke Shields 就读于普林斯顿大学。普林斯顿大学与宾夕法尼亚大学的学术要求大致同样严格。因此，Brooke Shields 也能在宾夕法尼亚大学取得成功。 因此答案是是。

问： 回答是或否：氢的原子序数的平方是否超过辣妹组合的成员数?
答： 氢的原子序数是 1。1 的平方是 1。辣妹组合有 5 名成员。因此，氢的原子序数的平方小于 5。 因此答案是否。

问： 回答是或否：在某些大学毕业典礼期间，看到霜是否常见?
答： 大学毕业典礼可以在 12 月、5 月和 6 月举行。12 月是冬季，因此可能出现霜。所以某些毕业典礼期间可能有霜。 因此答案是是。

问： 回答是或否：一只美洲驼能在越南战争（1945-46）期间产仔两次吗?
答： 越南战争持续了 6 个月。美洲驼的妊娠期为 11 个月，比 6 个月更长。因此，美洲驼不可能在越南战争期间产仔两次。 因此答案是否。

问： 回答是或否：梨会沉入水中吗?
答： 梨的密度约为 $0.6g/cm^3$，小于水的密度。密度小于水的物体会浮起来。因此，梨会浮起来。 因此答案是否。

表 26：日期理解任务完整思维链提示的少样本示例。

提示：日期理解

问： 再过 36 小时就是 2015 年。从今天算起一周后的日期是什么？请用 MM/DD/YYYY 格式回答。
答： 如果再过 36 小时就是 2015 年，那么再过 2 天就是 2015 年。01/01/2015 的 2 天前是 12/30/2014，因此今天是 12/30/2014。从今天算起一周后是 01/05/2015。 因此答案是 01/05/2015.

问： 2019 年的第一天是星期二，今天是 2019 年的第一个星期一。今天的日期是什么？请用 MM/DD/YYYY 格式回答。
答： 如果 2019 年的第一天是星期二，那么 01/01/2019 是星期二。今天是第一个星期一，也就是六天之后。因此今天是 01/07/2019。 因此答案是 01/07/2019.

问： 音乐会原定于 06/01/1943 举行，但推迟了一天到今天。10 天前的日期是什么？请用 MM/DD/YYYY 格式回答。
答： 06/01/1943 的后一天是 06/02/1943，因此今天是 06/02/1943。今天之前的 10 天是 05/23/1943。 因此答案是 05/23/1943.

问： 今天是 4/19/1969。24 小时后的日期是什么？请用 MM/DD/YYYY 格式回答。
答： 今天是 04/19/1969。24 小时后是今天的后一天，也就是 04/20/1969。 因此答案是 04/20/1969.

问： Jane 以为今天是 3/11/2002，但实际是晚了 1 天的 3 月 12 日。24 小时后的日期是什么？请用 MM/DD/YYYY 格式回答。
答： 今天是 03/12/2002。因此 24 小时后的日期是 03/13/2002。 因此答案是 03/13/2002.

问： Jane 出生于 2001 年 2 月的最后一天。今天是她的 16 岁生日。昨天的日期是什么？请用 MM/DD/YYYY 格式回答。
答： 2 月的最后一天是 28 日，因此 Jane 出生于 02/28/2001。今天是她的 16 岁生日，因此今天是 02/28/2017。那么昨天是 02/27/2017。 因此答案是 02/27/2017.

表 27：体育理解任务完整思维链提示的少样本示例。

提示：体育理解

问： 下列句子是否合理？“Kyle Palmieri 被判砍杆犯规。”
答： Kyle Palmieri 是冰球运动员。砍杆犯规属于冰球。因此答案是是。

问： 下列句子是否合理？“Joao Moutinho 在 NFC 冠军赛中接住了掩护短传。”
答： Joao Moutinho 是足球运动员。NFC 冠军赛属于美式橄榄球，而不是足球。因此答案是否。

问： 下列句子是否合理？“Carson Wentz 打了挡拆配合。”
答： Carson Wentz 是美式橄榄球运动员。挡拆属于篮球，而不是橄榄球。因此答案是否。

问： 下列句子是否合理？“Jonas Valanciunas 投中了压哨球。”
答： Jonas Valanciunas 是篮球运动员。压哨球属于篮球。因此答案是是。

问： 下列句子是否合理？“Jamel Murray 在罚球线上百发百中。”
答： Jamal Murray 是篮球运动员。罚球线上百发百中属于篮球。因此答案是是。

问： 下列句子是否合理？“Sam Darnold 传出了冰球。”
答： Sam Darnold 是美式橄榄球运动员。传冰球属于冰球，而不是美式橄榄球。因此答案是否。

问： 下列句子是否合理？“Draymond Green 传球达阵。”
答： Draymond Green 是篮球运动员。传球达阵属于橄榄球，而不是篮球。因此答案是否。

问： 下列句子是否合理？“Malcolm Brogdon 打板投篮命中。”
答： Malcolm Brogdon 是篮球运动员。打板投篮属于篮球。因此答案是是。

表 28：SayCan 机器人规划任务的完整思维链提示的少样本示例。

[公开版定点删节：此处 SayCan 题目、提示及对应输出未能完成与官方材料的逐项来源核验。保留原表编号、标题及正文研究结论；不表示其官方数据集无开放许可。]

H 附录：数学应用题的其他标注者

表 29: 数学应用题完整思维链提示的少样本示例。这些示例与表 20相同，只是思维链由另一位标注者编写（“标注者 B”而非“标注者 A”）。 标注者均为论文共同作者，并熟悉思维链提示的目标。

提示：数学应用题

问： 小树林里有 15 棵树。工人今天将在这里植树。完工后，树林里将有 21 棵树。工人今天种了多少棵树?
答： 现在有 21 棵树，最初有 15 棵，因此工人种了 21 - 15 = 6 棵树。 答案是 6.

问： 停车场里有 3 辆车，又来了 2 辆，停车场里现在有多少辆车?
答： 最初有 3 辆车，又来了 2 辆，因此现在应该有 3 + 2 = 5 辆车。 答案是 5.

问： Leah 有 32 块巧克力，她的姐妹有 42 块。如果她们吃掉了 35 块，还总共剩下多少块?
答： Leah 有 32 块巧克力，她的姐妹有 42 块，两人共有 32 + 42 = 74 块。吃掉 35 块后，现在有 74 - 35 = 39 块巧克力。 答案是 39.

问： Jason 有 20 根棒棒糖。他给了 Denny 一些。现在 Jason 有 12 根棒棒糖。他给了 Denny 多少根?
答： Jason 最初有 20 根棒棒糖，但现在只有 12 根，因此他给了 Denny 20 - 12 = 8 根棒棒糖。 答案是 8.

问： Shawn 有五个玩具。圣诞节时，妈妈和爸爸各送了他两个玩具。他现在有多少个玩具?
答： 妈妈和爸爸各送给 Shawn 2 个玩具，因此他又得到了 2 * 2 = 4 个，现在有 5 + 4 = 9 个玩具。 答案是 9.

问： 服务器机房原来有九台计算机。从星期一到星期四，每天又安装五台。机房现在有多少台计算机?
答： 从星期一到星期四每天安装 5 台计算机，因此共安装了 5 * 4 = 20 台。最初有 9 台，因此现在有 20 + 9 = 29 台计算机。 答案是 29.

问： Michael 有 58 个高尔夫球。星期二，他丢了 23 个。星期三，他又丢了 2 个。到星期三结束时，他还剩多少个高尔夫球?
答： Michael 最初有 58 个高尔夫球，丢了 23 个，所以还剩 58 - 23 = 35 个。又丢了 2 个后，他现在有 35 - 2 = 33 个球。 答案是 33.

问： Olivia 有 $23。她买了五个贝果，每个 $3。她还剩多少钱?
答： 5 个贝果每个 $3，应花费 5 * 3 = 15 美元。Olivia 最初有 $23，因此现在还剩 23 - 15 = 8 美元。 答案是 8.

表 30: 数学应用题完整思维链提示的少样本示例。这些示例与表 20相同，只是思维链由另一位标注者编写（“标注者 C”而非“标注者 A”）。

提示：数学应用题

问： 小树林里有 15 棵树。工人今天将在这里植树。完工后，树林里将有 21 棵树。工人今天种了多少棵树?
答： 最初有 15 棵树。后来有 21 棵。两者之差必定就是他们种的树的数量。因此，他们一定种了 21 - 15 = 6 棵树。 答案是 6.

问： 停车场里有 3 辆车，又来了 2 辆，停车场里现在有多少辆车?
答： 停车场里已有 3 辆车。又来了 2 辆。现在有 3 + 2 = 5 辆车。 答案是 5.

问： Leah 有 32 块巧克力，她的姐妹有 42 块。如果她们吃掉了 35 块，还总共剩下多少块?
答： Leah 有 32 块巧克力，她的姐妹有 42 块。这意味着最初有 32 + 42 = 74 块。已经吃掉 35 块。因此两人总共还剩 74 - 35 = 39 块巧克力。 答案是 39.

问： Jason 有 20 根棒棒糖。他给了 Denny 一些。现在 Jason 有 12 根棒棒糖。他给了 Denny 多少根?
答： Jason 原有 20 根棒棒糖。既然他现在只有 12 根，他一定把其余的给了 Denny。他给 Denny 的棒棒糖数量一定为 20 - 12 = 8 根。 答案是 8.

问： Shawn 有五个玩具。圣诞节时，妈妈和爸爸各送了他两个玩具。他现在有多少个玩具?
答： 他有 5 个玩具。他从妈妈那里得到了 2 个，之后就有 5 + 2 = 7 个玩具。然后爸爸又送了 2 个，因此他总共有 7 + 2 = 9 个玩具。 答案是 9.

问： 服务器机房原来有九台计算机。从星期一到星期四，每天又安装五台。机房现在有多少台计算机?
答： 从星期一到星期四共有 4 天。每天增加 5 台计算机。这意味着总共增加了 4 * 5 = 20 台。最初有 9 台，因此现在有 9 + 20 = 29 台计算机。 答案是 29.

问： Michael 有 58 个高尔夫球。星期二，他丢了 23 个。星期三，他又丢了 2 个。到星期三结束时，他还剩多少个高尔夫球?
答： Michael 最初有 58 个球。星期二他丢了 23 个，之后还剩 58 - 23 = 35 个球。星期三他又丢了 2 个，因此现在有 35 - 2 = 33 个球。 答案是 33.

问： Olivia 有 $23。她买了五个贝果，每个 $3。她还剩多少钱?
答： 她买了 5 个贝果，每个 $3。这意味着她买贝果花了 5 * $3 = $15。她最初有 $23，因此现在有 $23 - $15 = $8。 答案是 8.

公开版许可与范围（dot，2026 年 11 月 10 日）

底本及署名。Jason Wei、Xuezhi Wang、Dale Schuurmans、Maarten Bosma、Brian Ichter、Fei Xia、Ed H. Chi、Quoc V. Le、Denny Zhou，*Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*，arXiv:2201.11903v6，2023-01-10。原文及版本：https://arxiv.org/abs/2201.11903v6。原文许可：https://creativecommons.org/licenses/by/4.0/。

翻译和改动。dot 制作的 AI 辅助非官方中文译本，未经原作者审校或背书。相对原文进行了翻译、中文排版、图表文字重排、定点删节及本许可说明增补；不是官方译本，亦不保证无误。原文错误示例保留用于研究分析，不应作为事实结论。中文新增表达在可许可范围内按 CC BY 4.0 提供，原作者和第三方材料的既有权利及条件不变。

保留范围。保留摘要、正文、致谢、核对清单、参考文献、附录研究讨论、公式、统计数据、作者自有方法与统计图，以及作者手写算术提示和合成符号任务。未因数据集例题的独立权利而删除实验统计图。

定点删节清单

- 图 1：省略源于 MultiArith 的食堂题叙事及输出中复述该叙事的文字，仅保留原数值、运算结构、模型答案和提示对照。原始题目授权未完成核验；Roger 网球示例及方法结构保留。
- 图 3 的 CSQA、SayCan 两个示例单元格，以及表 15、24 的 CSQA 题目、选项、输出：CSQA 具体材料的可再分发及翻译许可未核清。SayCan 对应删节见下项。
- 表 19、28 及上述 SayCan 单元格：省略具体指令、提示与输出。官方网页将 SayCan v0 数据集标为 CC BY 4.0，但本次未完成这些具体材料的逐项来源核验，因此暂不随本版分发。此处不声称 SayCan 没有开放许可。研究统计、方法及正文讨论保留。
- 表 12：仅省略 ASDiv、MAWPS SingleOp、SingleEq、AddSub、MultiArith 五行的示例题目。数据集名称和评估样例数保留。ASDiv 仓库标为 CC BY-NC 4.0，但题目来自上游教学站点，具体题目再授权链未核清；MAWPS 四题未核得可适用的原始题目授权。GSM8K、SVAMP、AQuA 三行例题保留。

所有删节处均保留图表编号或位置提示；这里的“未核清”不是对作品有无著作权或一切使用是否合法的裁断。公开交付仅含本 PDF、README 及必要许可证通知，不包含原英文 PDF、未审源码、数据集副本或内嵌附件。

保留的第三方材料及来源

- **GSM8K**。OpenAI；Copyright (c) 2021 OpenAI。采用 MIT 许可，完整通知见后。已逐题匹配官方 test.jsonl 中的题目，包括正文 FAQ、错误分析图及附录题目。来源：https://github.com/openai/grade-school-math；许可：https://github.com/openai/grade-school-math/blob/master/LICENSE。修改：题目和答案译为中文、排版重组；模型生成输出按论文呈现。
- **SVAMP**。Arkil Patel；Copyright (c) 2021 Arkil Patel。采用 MIT 许可，完整通知见后。表 12 的 DVD 例题匹配官方 SVAMP.json 的 chal-1。来源：https://github.com/arkilpatel/SVAMP；许可：https://github.com/arkilpatel/SVAMP/blob/main/LICENSE。修改：中文翻译。

- **StrategyQA**。Elad Segal 及 StrategyQA 作者；Copyright (c) 2021 Elad Segal。原数据 MIT 许可，完整通知见后；本篇使用 BIG-bench 的问题集合，亦保留 Apache 2.0 条件。图中的梨题、附录六条提示及四条模型例题已匹配官方任务文件。来源：https://github.com/eladsegal/strategyqa；许可：https://github.com/eladsegal/strategyqa/blob/main/LICENSE；任务：https://github.com/google/BIG-bench/tree/main/bigbench/benchmark_tasks/strategyqa。修改：中文翻译及排版，推理链为论文作者添加。
- **BIG-bench 日期与体育理解**。日期任务作者 Xinyi Wu、Zijian Wang；体育任务作者 Ethan Kim；BIG-bench contributors。日期十条、体育十二条具体材料已逐项匹配官方 task.json（含重复出现于图中的示例）。采用仓库 Apache 2.0 许可，完整条文见后。来源：https://github.com/google/BIG-bench/tree/main/bigbench/benchmark_tasks/date_understanding 与 https://github.com/google/BIG-bench/tree/main/bigbench/benchmark_tasks/sports_understanding；许可：https://github.com/google/BIG-bench/blob/main/LICENSE。修改：中文翻译、图表重排，保留论文推理与错误示范；体育提示中的 Jamel/Jamal 拼写差异按底本保留。
- **AQuA**。Google DeepMind；Copyright 2017 Google Inc.。采用 Apache 2.0 许可，完整条文见后。四条提示匹配官方 train.json 第 18、15、19、55 项（从 0 开始），塔题匹配 test.json 第 0 项。来源：https://github.com/google-deepmind/AQuA；许可：https://github.com/google-deepmind/AQuA/blob/master/LICENSE。修改：中文翻译及排版。塔题选项按论文底本保留；底本与数据集原始选项的括号写法不同，不在本译本中静默修正。

许可边界。上述材料不是仅凭论文的 CC BY 4.0 标记而获得许可，而是另外核对其来源和许可。保留的第三方内容仍须遵守下列 MIT 与 Apache 2.0 条款。删节材料不得经原图、英文原文、源码或附件重新夹带发布。这里不提供法律意见。

GSM8K – Copyright (c) 2021 OpenAI

MIT License

Copyright (c) 2021 OpenAI

Permission is hereby granted, free of charge, to any person obtaining a copy
of this software and associated documentation files (the "Software"), to deal
in the Software without restriction, including without limitation the rights
to use, copy, modify, merge, publish, distribute, sublicense, and/or sell
copies of the Software, and to permit persons to whom the Software is
furnished to do so, subject to the following conditions:

The above copyright notice and this permission notice shall be included in all
copies or substantial portions of the Software.

THE SOFTWARE IS PROVIDED "AS IS", WITHOUT WARRANTY OF ANY KIND, EXPRESS OR
IMPLIED, INCLUDING BUT NOT LIMITED TO THE WARRANTIES OF MERCHANTABILITY,
FITNESS FOR A PARTICULAR PURPOSE AND NONINFRINGEMENT. IN NO EVENT SHALL THE
AUTHORS OR COPYRIGHT HOLDERS BE LIABLE FOR ANY CLAIM, DAMAGES OR OTHER
LIABILITY, WHETHER IN AN ACTION OF CONTRACT, TORT OR OTHERWISE, ARISING FROM,
OUT OF OR IN CONNECTION WITH THE SOFTWARE OR THE USE OR OTHER DEALINGS IN THE
SOFTWARE.

SVAMP – Copyright (c) 2021 Arkil Patel

MIT License

Copyright (c) 2021 Arkil Patel

Permission is hereby granted, free of charge, to any person obtaining a copy
of this software and associated documentation files (the "Software"), to deal
in the Software without restriction, including without limitation the rights
to use, copy, modify, merge, publish, distribute, sublicense, and/or sell
copies of the Software, and to permit persons to whom the Software is
furnished to do so, subject to the following conditions:

The above copyright notice and this permission notice shall be included in all
copies or substantial portions of the Software.

THE SOFTWARE IS PROVIDED "AS IS", WITHOUT WARRANTY OF ANY KIND, EXPRESS OR
IMPLIED, INCLUDING BUT NOT LIMITED TO THE WARRANTIES OF MERCHANTABILITY,
FITNESS FOR A PARTICULAR PURPOSE AND NONINFRINGEMENT. IN NO EVENT SHALL THE
AUTHORS OR COPYRIGHT HOLDERS BE LIABLE FOR ANY CLAIM, DAMAGES OR OTHER
LIABILITY, WHETHER IN AN ACTION OF CONTRACT, TORT OR OTHERWISE, ARISING FROM,
OUT OF OR IN CONNECTION WITH THE SOFTWARE OR THE USE OR OTHER DEALINGS IN THE
SOFTWARE.

StrategyQA – Copyright (c) 2021 Elad Segal

MIT License

Copyright (c) 2021 Elad Segal

Permission is hereby granted, free of charge, to any person obtaining a copy
of this software and associated documentation files (the "Software"), to deal
in the Software without restriction, including without limitation the rights
to use, copy, modify, merge, publish, distribute, sublicense, and/or sell
copies of the Software, and to permit persons to whom the Software is
furnished to do so, subject to the following conditions:

The above copyright notice and this permission notice shall be included in all
copies or substantial portions of the Software.

THE SOFTWARE IS PROVIDED "AS IS", WITHOUT WARRANTY OF ANY KIND, EXPRESS OR
IMPLIED, INCLUDING BUT NOT LIMITED TO THE WARRANTIES OF MERCHANTABILITY,
FITNESS FOR A PARTICULAR PURPOSE AND NONINFRINGEMENT. IN NO EVENT SHALL THE
AUTHORS OR COPYRIGHT HOLDERS BE LIABLE FOR ANY CLAIM, DAMAGES OR OTHER
LIABILITY, WHETHER IN AN ACTION OF CONTRACT, TORT OR OTHERWISE, ARISING FROM,
OUT OF OR IN CONNECTION WITH THE SOFTWARE OR THE USE OR OTHER DEALINGS IN THE
SOFTWARE.

BIG-bench contributors; date: Xinyi Wu, Zijian Wang; sports: Ethan Kim. AQuA: Copyright 2017 Google Inc.

Apache License
Version 2.0, January 2004
http://www.apache.org/licenses/

TERMS AND CONDITIONS FOR USE, REPRODUCTION, AND DISTRIBUTION

1. Definitions.

"License" shall mean the terms and conditions for use, reproduction,
and distribution as defined by Sections 1 through 9 of this document.

"Licensor" shall mean the copyright owner or entity authorized by
the copyright owner that is granting the License.

"Legal Entity" shall mean the union of the acting entity and all
other entities that control, are controlled by, or are under common
control with that entity. For the purposes of this definition,
"control" means (i) the power, direct or indirect, to cause the
direction or management of such entity, whether by contract or
otherwise, or (ii) ownership of fifty percent (50%) or more of the
outstanding shares, or (iii) beneficial ownership of such entity.

"You" (or "Your") shall mean an individual or Legal Entity
exercising permissions granted by this License.

"Source" form shall mean the preferred form for making modifications,
including but not limited to software source code, documentation
source, and configuration files.

"Object" form shall mean any form resulting from mechanical
transformation or translation of a Source form, including but
not limited to compiled object code, generated documentation,
and conversions to other media types.

"Work" shall mean the work of authorship, whether in Source or
Object form, made available under the License, as indicated by a
copyright notice that is included in or attached to the work
(an example is provided in the Appendix below).

"Derivative Works" shall mean any work, whether in Source or Object
form, that is based on (or derived from) the Work and for which the
editorial revisions, annotations, elaborations, or other modifications
represent, as a whole, an original work of authorship. For the purposes
of this License, Derivative Works shall not include works that remain
separable from, or merely link (or bind by name) to the interfaces of,
the Work and Derivative Works thereof.

"Contribution" shall mean any work of authorship, including
the original version of the Work and any modifications or additions
to that Work or Derivative Works thereof, that is intentionally
submitted to Licensor for inclusion in the Work by the copyright owner
or by an individual or Legal Entity authorized to submit on behalf of
the copyright owner. For the purposes of this definition, "submitted"
means any form of electronic, verbal, or written communication sent
to the Licensor or its representatives, including but not limited to
communication on electronic mailing lists, source code control systems,
and issue tracking systems that are managed by, or on behalf of, the
Licensor for the purpose of discussing and improving the Work, but
excluding communication that is conspicuously marked or otherwise
designated in writing by the copyright owner as "Not a Contribution."

"Contributor" shall mean Licensor and any individual or Legal Entity on behalf of whom a Contribution has been received by Licensor and subsequently incorporated within the Work.

2. Grant of Copyright License. Subject to the terms and conditions of this License, each Contributor hereby grants to You a perpetual, worldwide, non-exclusive, no-charge, royalty-free, irrevocable copyright license to reproduce, prepare Derivative Works of, publicly display, publicly perform, sublicense, and distribute the Work and such Derivative Works in Source or Object form.

3. Grant of Patent License. Subject to the terms and conditions of this License, each Contributor hereby grants to You a perpetual, worldwide, non-exclusive, no-charge, royalty-free, irrevocable (except as stated in this section) patent license to make, have made, use, offer to sell, sell, import, and otherwise transfer the Work, where such license applies only to those patent claims licensable by such Contributor that are necessarily infringed by their Contribution(s) alone or by combination of their Contribution(s) with the Work to which such Contribution(s) was submitted. If You institute patent litigation against any entity (including a cross-claim or counterclaim in a lawsuit) alleging that the Work or a Contribution incorporated within the Work constitutes direct or contributory patent infringement, then any patent licenses granted to You under this License for that Work shall terminate as of the date such litigation is filed.

4. Redistribution. You may reproduce and distribute copies of the Work or Derivative Works thereof in any medium, with or without modifications, and in Source or Object form, provided that You meet the following conditions:

   (a) You must give any other recipients of the Work or Derivative Works a copy of this License; and

   (b) You must cause any modified files to carry prominent notices stating that You changed the files; and

   (c) You must retain, in the Source form of any Derivative Works that You distribute, all copyright, patent, trademark, and attribution notices from the Source form of the Work, excluding those notices that do not pertain to any part of the Derivative Works; and

   (d) If the Work includes a "NOTICE" text file as part of its distribution, then any Derivative Works that You distribute must include a readable copy of the attribution notices contained within such NOTICE file, excluding those notices that do not pertain to any part of the Derivative Works, in at least one of the following places: within a NOTICE text file distributed as part of the Derivative Works; within the Source form or documentation, if provided along with the Derivative Works; or, within a display generated by the Derivative Works, if and wherever such third-party notices normally appear. The contents of the NOTICE file are for informational purposes only and do not modify the License. You may add Your own attribution notices within Derivative Works that You distribute, alongside or as an addendum to the NOTICE text from the Work, provided that such additional attribution notices cannot be construed as modifying the License.

   You may add Your own copyright statement to Your modifications and may provide additional or different license terms and conditions for use, reproduction, or distribution of Your modifications, or for any such Derivative Works as a whole, provided Your use,

reproduction, and distribution of the Work otherwise complies with
the conditions stated in this License.

5. Submission of Contributions. Unless You explicitly state otherwise,
   any Contribution intentionally submitted for inclusion in the Work
   by You to the Licensor shall be under the terms and conditions of
   this License, without any additional terms or conditions.
   Notwithstanding the above, nothing herein shall supersede or modify
   the terms of any separate license agreement you may have executed
   with Licensor regarding such Contributions.

6. Trademarks. This License does not grant permission to use the trade
   names, trademarks, service marks, or product names of the Licensor,
   except as required for reasonable and customary use in describing the
   origin of the Work and reproducing the content of the NOTICE file.

7. Disclaimer of Warranty. Unless required by applicable law or
   agreed to in writing, Licensor provides the Work (and each
   Contributor provides its Contributions) on an "AS IS" BASIS,
   WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or
   implied, including, without limitation, any warranties or conditions
   of TITLE, NON-INFRINGEMENT, MERCHANTABILITY, or FITNESS FOR A
   PARTICULAR PURPOSE. You are solely responsible for determining the
   appropriateness of using or redistributing the Work and assume any
   risks associated with Your exercise of permissions under this License.

8. Limitation of Liability. In no event and under no legal theory,
   whether in tort (including negligence), contract, or otherwise,
   unless required by applicable law (such as deliberate and grossly
   negligent acts) or agreed to in writing, shall any Contributor be
   liable to You for damages, including any direct, indirect, special,
   incidental, or consequential damages of any character arising as a
   result of this License or out of the use or inability to use the
   Work (including but not limited to damages for loss of goodwill,
   work stoppage, computer failure or malfunction, or any and all
   other commercial damages or losses), even if such Contributor
   has been advised of the possibility of such damages.

9. Accepting Warranty or Additional Liability. While redistributing
   the Work or Derivative Works thereof, You may choose to offer,
   and charge a fee for, acceptance of support, warranty, indemnity,
   or other liability obligations and/or rights consistent with this
   License. However, in accepting such obligations, You may act only
   on Your own behalf and on Your sole responsibility, not on behalf
   of any other Contributor, and only if You agree to indemnify,
   defend, and hold each Contributor harmless for any liability
   incurred by, or claims asserted against, such Contributor by reason
   of your accepting any such warranty or additional liability.

END OF TERMS AND CONDITIONS

APPENDIX: How to apply the Apache License to your work.

   To apply the Apache License to your work, attach the following
   boilerplate notice, with the fields enclosed by brackets "[]"
   replaced with your own identifying information. (Don't include
   the brackets!) The text should be enclosed in the appropriate
   comment syntax for the file format. We also recommend that a
   file or class name and description of purpose be included on the
   same "printed page" as the copyright notice for easier
   identification within third-party archives.

Copyright [yyyy] [name of copyright owner]

Licensed under the Apache License, Version 2.0 (the "License");

```
you may not use this file except in compliance with the License.
You may obtain a copy of the License at

    http://www.apache.org/licenses/LICENSE-2.0

Unless required by applicable law or agreed to in writing, software
distributed under the License is distributed on an "AS IS" BASIS,
WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
See the License for the specific language governing permissions and
limitations under the License.
```

AQuA 原始许可通知

```
Copyright 2017 Google Inc.

Licensed under the Apache License, Version 2.0 (the "License");
you may not use this file except in compliance with the License.
You may obtain a copy of the License at

    http://www.apache.org/licenses/LICENSE-2.0

Unless required by applicable law or agreed to in writing, software
distributed under the License is distributed on an "AS IS" BASIS,
WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
See the License for the specific language governing permissions and
limitations under the License.
```