共形思考：公开发布说明

Conformal Thinking: Risk Control for Reasoning on a Compute Budget

原作者：Xi Wang、Anushri Suresh、Alvin Zhang、Rishi More、William Jurayj、Mehrdad Farajtabar、Daniel Khashabi、Eric Nalisnick。

正式发表：Proceedings of the 43rd International Conference on Machine Learning (ICML 2026), Proceedings of Machine Learning Research, volume 306。

来源与许可

本译文依据 PMLR 正式发表的 15 页英文版本。
https://proceedings.mlr.press/v306/wang26hd.html

原文版权归原作者所有。PMLR 出版协议第 2 条规定以 Creative Commons Attribution 4.0 International（CC BY 4.0）公开发布，第 3 条要求引用原始发表信息并链接 PMLR。
https://proceedings.mlr.press/pmlr-license-agreement.html

原文及本译文的翻译、编排贡献按 CC BY 4.0 提供。
https://creativecommons.org/licenses/by/4.0/

版本与修改

dot 制作的 AI 辅助非官方中文译文。公开版 v1.1，2026-11-10。在原中文全译 v1.0 前增加本页，补齐译者、许可链接与修改声明。后续 22 页内容保持原样，没有删节。原译本保留正文、数学符号、公式编号、参考文献和作者统计图；重排为中文单栏，提供图注/图内文字说明，将疑似笔误明确标为译注。保留原译本页码。

原作者、ICML 和 PMLR 未审校或认可本译文。翻译可能有误，应以原文为准。许可不提供担保，也不自动覆盖第三方材料。此文件不包含原始英文 PDF、原始源包、软件包或第三方数据集原始样例。

共形思考：计算预算约束下的推理风险控制

Conformal Thinking: Risk Control for Reasoning on a Compute Budget

Xi Wang[*1]，Anushri Suresh[*1]，Alvin Zhang[*1]，Rishi More[*1]，
William Jurayj[1]，Mehrdad Farajtabar[2]，Daniel Khashabi[1]，Eric Nalisnick[1]

中文全译 v1.0 · 整理日期：2026年11月10日

[*]同等贡献。[1]约翰斯·霍普金斯大学，美国马里兰州巴尔的摩；[2]Apple，美国。通讯作者：Xi Wang（xwang457@jh.edu）、Eric Nalisnick（nalisnick@jhu.edu）。

译本说明：本文件为非官方中文译本，并非作者撰写或审定的中文原稿。译文以正式出版的15页英文PDF为准，保留原文的数学符号、公式编号、图表与参考文献信息；图内英文保留，中文图注提供说明。原文发表于第43届国际机器学习大会论文集（韩国首尔），Proceedings of Machine Learning Research，第306卷，2026年，版权归原作者所有。原文链接：https://proceedings.mlr.press/v306/wang26hd.html。原文采用Creative Commons Attribution 4.0（CC BY 4.0）许可；本译本系据原文制作的翻译改编，不代表原作者认可。原文中会影响理解的疑似笔误以“译注”明确标出，其余不擅自改动论证。

摘要

推理型大语言模型（LLM）支持测试时扩展：随着词元预算增加，数据集层面的准确率也会提升。这推动了自适应推理的发展，即在额外词元能够提升可靠性时投入词元，而在额外计算不太可能带来帮助时提前停止。然而，无论是设定词元预算，还是设定自适应推理的阈值，都是一个实际难题，其中涉及根本性的风险与准确率权衡。我们将预算设定问题重新表述为风险控制问题，在最小化计算量的同时限制错误率。我们的框架引入一个上阈值，在模型有信心时停止推理（存在输出错误答案的风险）；同时引入一种新颖的参数化下阈值，提前终止无法求解的样本（存在过早停止的风险）。给定目标风险和一个验证集，我们使用分布无关风险控制来优化设定这些停止机制。在多种推理任务和模型上的实验结果验证了该风险控制方法的有效性：下阈值和集成停止机制能够提高计算效率，同时遵守用户指定的风险目标。

1 引言

推理型大语言模型支持测试时扩展：投入更多推理词元通常能够获得更好的性能 (DeepSeek-AI et al., 2025; Snell et al., 2024)。然而，推理型大语言模型面临的一个实际挑战是，如何诱导出能够随样本难度调整的自适应推理行为，即判断继续思考何时仍然有用、何时只是在浪费计算。近期工作通过监测推理模型对答案的不确定性（例如测量置信度或熵），提出了自适应思考机制；当不确定性降至预先定义的阈值以下时，就停止推理 (Wang et al., 2025a; Yang et al., 2025; Fu et al., 2025)。自适应思考能够实现依赖样本的词元预算，因为达到置信阈值所需的推理投入因问题而异。然而，自适应思考并没有缓解设定推理预算这一实际挑战，而只是将词元预算设定问题转化为阈值设定问题。事实上，设定阈值可能比设定词元预算更加棘手，因为阈值通常难以解释，而且取决于不确定性指标，其取值范围可能十分任意（图1左）。

受提前退出架构中自适应计算的相关研究启发 (Schuster et al., 2022; Jazbec et al., 2024)，本文提出一个用于设定自适应推理停止规则的原则性框架。具体而言，我们利用了测试时扩展的一个关键含义：任何提前终止推理的行为都会引入出错风险。基于这一观察，我们将推理预算设定问题重新表述为选择可接受风险水平的问题。风险是一个可解释的量，能够直接对接下游决策。我们使用分布无关风险控制 (Bates et al., 2021; Angelopoulos et al., 2024, 2025)，将用户指定的风险自动映射为相应的推理链终止准则。

具体来说，我们区分了两类互补的风险及其对应控制机制（见图2）：一类是假阳性风险，即误以为模型已经得到了正确答案，由置信度上阈值控制；另一类是假阴性风险，即误以为当前及未来的答案都会错误。后一类风险由下阈值控制，这是一种迫使推理遵循进展计划的新机制。这两类风险和阈值对应不同的低效来源：上阈值减少模型事实上已经收敛之后浪费的词元（式(10)）；下阈值则避免在继续推理不太可能有帮助时仍然消耗词元（式(11)）。

本文的贡献包括：（i）提出一组损失函数，用于刻画推理型大语言模型因提前停止而产生的不同低效与错误来源（第4.2节）；（ii）提出一种新颖的参数化下阈值，在模型置信度以足够快的速度上升时终止推理（第4.3节）[1]；（iii）证明在相同目标风险水平下，不同方法的效率各异，而同时使用上、下阈值能够持续带来效率提升（第5.3节）。

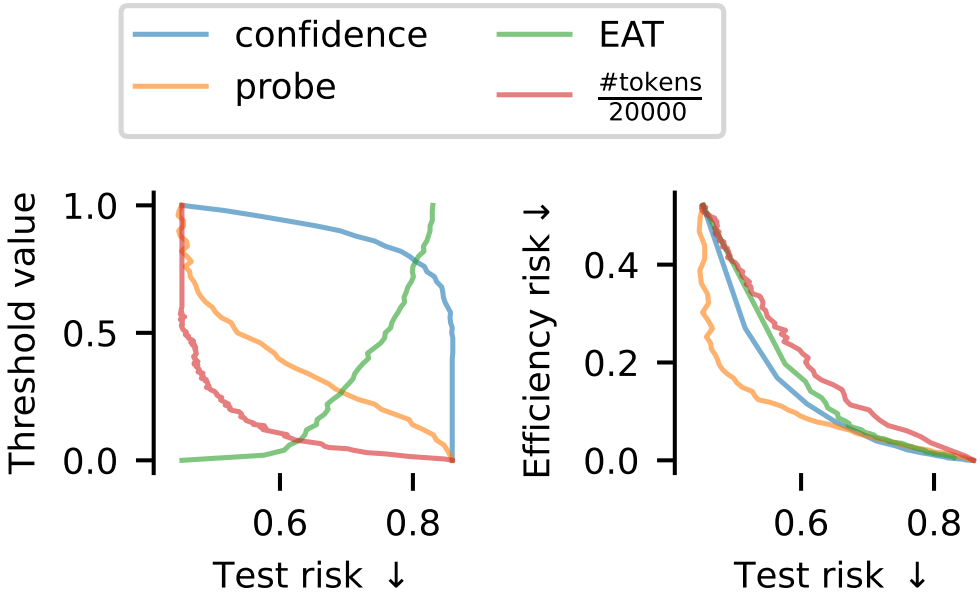


图 1: **不同目标测试风险下的提前停止行为。左：**为达到给定的目标测试风险，不同提前停止信号所需的阈值差异显著，表明阈值选择依赖于信号。**右：**不同提前停止方法的相对效率取决于目标测试风险，没有任何一种方法在所有风险水平下始终最有效率。这里展示的结果仅使用上阈值停止规则；若同时引入上、下阈值，风险与阈值之间的映射将更加复杂。译注（图内英文）：confidence为置信度，probe为探针，#tokens为词元数，Threshold value为阈值，Test risk为测试风险，Efficiency risk为效率风险。

2 背景：通过置信度（上）阈值实现自适应提前停止

推理模型会过度思考。 近期的推理型大语言模型通过后训练，以带有分隔符的格式输出显式推理轨迹，然后给出最终答案：

$$y = \langle \texttt{think} \rangle \, r_{1:T} \, \langle \texttt{/think} \rangle \, a, \tag{1}$$

其中，一次完整生成y由以下部分组成：长度为T（词元或步骤）的推理片段$r_{1:T}$、表示思考起止的特殊词元<think>和</think>，以及最终答案a。一个常见现象是，对许多样本而言，T可能远大于必要长度，即出现“过度思考”，从而引入不必要的推理成本。模型往往在已经可以提取出正确答案时仍继续推理 (Wang et al., 2025a; Yang et al., 2025)，这使T成为一个关键超参数。

用于自适应提前停止的不确定性监测。 给定输入x，用$r_{1:t}$表示截至第t步的部分推理轨迹。近期工作 (Wang et al., 2025a; Yang et al., 2025)提出，监测由部分轨迹计算得到的标量置信度或不确定性信号，从而自适应地提前停止推理：

$$s_t = u(x, r_{1:t}), \tag{2}$$

[1]译注：正式英文原文此处为“when the model’s confidence is increasing at a sufficient rate”，疑似漏写否定词；根据第4.3节，该机制实际是在置信度未能以要求的速度提升时终止推理。此处保留原句含义并提示这一不一致。

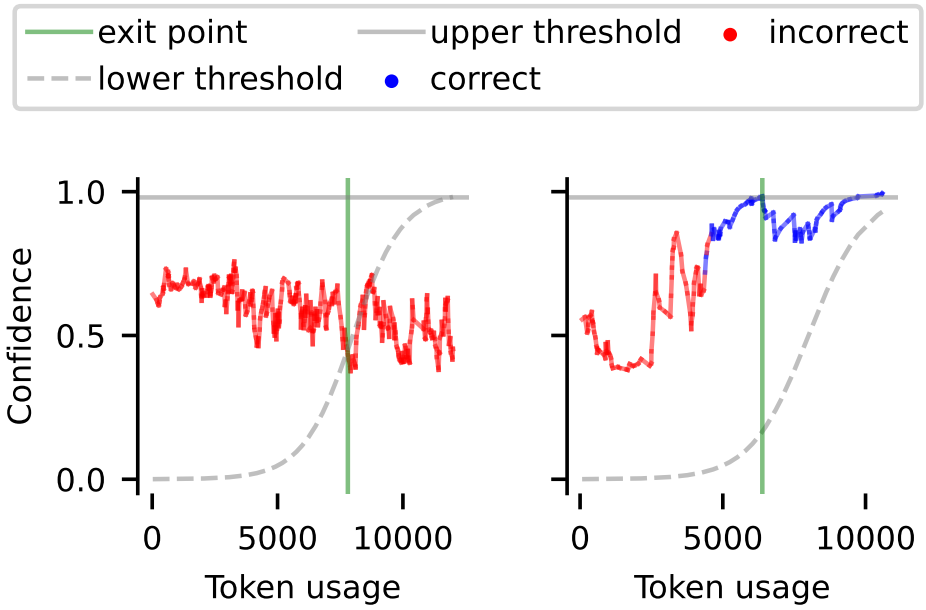


图 2: **通过受风险控制的置信度动态实现双阈值提前退出**。图中展示Qwen3-8B在AIME题目上的置信度随词元使用量变化的轨迹。**左：**一个无法求解的样本，模型置信度不断波动，未能达到上阈值；参数化下阈值使推理提前停止，防止不必要的词元消耗。**右：**一个可求解的样本，置信度稳步上升并越过上阈值，在达到足够置信度后触发终止。译注（图内英文）：exit point为退出点，upper/lower threshold为上/下阈值，correct/incorrect为正确/错误，Confidence为置信度，Token usage为词元使用量。

其中，较大的s_t通常表示较高置信度（或较低不确定性，取决于约定）。s_t的常见选择来自⟨/think⟩之后生成词元的统计性质，例如熵 (Wang et al., 2025a)或置信度 (Yang et al., 2025)。各个时点对s_t的评估可能带有噪声，或具有不便使用的取值范围，因此通常会使用平滑、取倒数或归一化等变换来降低方差：

$$\tilde{s}_t \;=\; g(s_{1:t})\,, \tag{3}$$

其中，g表示上述某种能够改善信号质量的变换，具体质量标准取决于应用。利用这一稳定化信号，典型的提前退出策略在变换后的分数首次超过阈值λ时停止推理：

$$\tau \;=\; \min\Big\{t \geq 1 \;:\; \tilde{s}_t \geq \lambda\Big\}. \tag{4}$$

我们将其称为上阈值退出机制。该策略随后输出答案a，并避免生成$r_{t>\text{exit}}$。这一表述统一了大量“有信心即停止”的方法 (Wang et al., 2025a; Yang et al., 2025)。需要注意，相关的“稳定即停止”方法 (Liu & Wang, 2025; Wu et al., 2025)会在答案跨推理步骤保持稳定时停止，但无法区分两种可以停止的情况：答案已经正确，还是问题难到没有希望解决。这正是本文的核心动机之一。

自适应思考的优势。 对于一个给定数据集，自适应推理会根据置信度达到目标阈值所需的时间，为每个问题分配不同数量的词元。与对所有问题都分配固定预算相比，这能够更合理地在样本之间分配预算。因此，自适应思考可以用更少的总词元达到相同的数据集层面准确率，也就是实现更高效的推理。

3 相关工作

推理过程中的提前退出。 大量工作致力于在额外推理不太可能有帮助时，提前退出思维链以降低推理成本。如第2节所述，多数现有方法实现的是上阈值规则：监测置信度或不确定性的代理指标（例如熵，或中间答案的稳定性），利用熵信号、试探答案的置信度，或答案一致性与收敛性的启发式规则，在模型看似足够确定或已经收敛时停止 (Wang et al., 2025a; Yang et al., 2025; Mao et al., 2025; Liu & Wang, 2025; Liao et al., 2025; Wei et al.; Fu et al., 2025; Jurayj et al., 2025)。**本文的不同之处：**我们的框架在两方面区别于既有研究。首先，我们形式化了一种低置信度停止准则，即“当推理未能变得（足够）更有信心时停止”。该下阈值既可独立使用，也可与上阈值结合成双阈值规则，在单条轨迹内同时识别有把握的成功和有把握的失败。事实上，Wang et al. (2025a)明确指出了一项局限：在具有挑战性的数据集上，大多数问题始终无法达到目标上阈值，导致大量词元浪费。其次，先前工作通常依赖手动调整的截断值、参数扫描或启发式准则。相比之下，我们使用分布无关风险控制 (Bates et al., 2021; Angelopoulos et al., 2024, 2025)来选择阈值，在控制目标指标的同时提供有限样本保证。

面向推理型大语言模型的风险控制。 当然，我们并不是唯一将风险控制与大语言模型推理相结合的工作。最接近的前期工作是Thought Calibration（思考校准） (Wu et al., 2025)。它也是一种“稳定即停止”方法，使用线性探针预测时刻t的答案是否与最终时刻T的答案相同。随后，作者使用“先学习、再检验”（learn-then-test） (Angelopoulos et al., 2025)来校准探针输出触发推理链提前终止的阈值。值得注意的是，Wu et al. (2025)也发现，其方法能够终止无法求解的样本，类似于我们的下阈值机制；但该能力基于其一致性探针信号，而我们的方法面向通用信号。PAC Reasoning (Zeng et al., 2026)使用风险控制来决定，是采用推理链的输出，还是完全放弃推理。**本文的不同之处：**Thought Calibration没有显式考虑因问题过难而停止的情况，只考虑中间解正确或稳定的情况，即采用单一阈值。PAC Reasoning不控制推理链本身的长度，而只控制是否进行推理的决策。

推理中的过度思考。 我们的动机与近期关于更长推理并非总有益的证据相似。这些研究表明，无论通过多样本选择 (Hassid et al., 2026)、结构化解码或搜索 (Xu et al., 2026)，还是通过更广泛的推理系统流程 (Moshkov et al., 2025)，较短的完整推理链有时会更准确或更高效。我们将这些发现视为支持自适应停止的补充动机。不同于这些方法，我们的方法既不在已经完成的轨迹之间进行选择，也不重新设计解码；相反，它为正在进行的推理轨迹提供样本级停止规则，并通过校准阈值，在计算预算约束下满足明确的风险目标。

面向提前退出神经网络的风险控制。 决定何时停止一条推理链，在概念上与一个更早的问题相同：决定在提前退出神经网络（EENN）的哪个出口停止 (Huang et al., 2018)。风险控制已应用于语言建模 (Schuster et al., 2022)、时间序列分类 (Ringel et al., 2024)，以及图像生成、语义分割和推测解码 (Jazbec et al., 2024)中的EENN。我们的工作主要受到Jazbec et al. (2024)形式化框架的启发，旨在将其用于大语言模型推理。

4 方法：共形思考

记号。 用y^*表示真实答案，$f_t(x)$表示模型针对问题x在第t步给出的预测，T表示总推理步数。在每一步t，模型还会输出一个辅助标量信号$s_t \in \mathbb{R}$（例如置信度），该信号是提前停止策略的主要输入。

动机与目标。 本研究有两个主要目标：（i）开发一种面向大语言模型推理的自适应提前停止机制，使用户能够指定对错误率的控制要求；（ii）扩展现有仅使用上阈值的方法 Jazbec et al. (2024)，使其也能在某个样本很可能无法于T步推理（即最大预算）内求解时停止。对于目标

（i），给定一个用于衡量中间解$f_t(x)$质量的损失函数$\ell(y^*, f_t(x))$，理想情况下，我们希望控制期望损失，即真实风险（而非经验风险），并将其视为退出超参数λ的函数：

$$\mathcal{R}(\lambda) \triangleq \mathbb{E}_{x,y^*}\left[\ell\left(y^*, f_t(x); \lambda\right)\right] \leq \epsilon,$$

其中$\epsilon \in (0,1)$，$\lambda \in (0,1)$。参数ϵ即风险容忍度，由用户指定；例如，下文将考虑提前终止所得解错误的比例，即假阳性。由于λ将从有限校准集中选出，对真实风险的控制只能以概率形式实现，详见第4.4节。如第2节所述，可以通过置信度阈值来指定λ。这又引出了目标（ii）：上阈值方法旨在推理链得到正确解时停止。考虑到大语言模型所应用的任务十分具有挑战性，例如Humanity's Last Exam（人类最后的考试）(Center for AI Safety et al., 2026)和前沿数学问题，我们也希望在任务过难时终止推理，即模型不太可能在T步推理内得到正确答案时停止。

4.1 带风险控制的双阈值提前退出

根据上述目标，我们将式(4)中的单阈值策略改为双阈值策略。令$\lambda_+ \in (0,1)$表示上阈值，与先前工作一样，用于识别模型何时足够确信自己已经得到正确答案。令$\lambda_- \in (0,1)$表示下阈值，编码继续推理所需的最低置信水平。我们的提前退出策略可写为：

$$\tau = \min\left\{t \geq 1 : \tilde{s}_t \geq \lambda_+ \vee \tilde{s}_t \leq \lambda_-\right\} \tag{5}$$

其中始终保持$\lambda_+ > \lambda_-$。这一顺序意味着“或”条件是互斥的：模型只能经由其中一个阈值退出。

接下来，我们希望设定λ_+和λ_-，使风险

$$\begin{aligned}&\mathcal{R}(\lambda_+, \lambda_-) \triangleq \\ &\quad \mathbb{E}_{x,y^*}\left[\ell^+\left(y^*, f_t(x); \lambda_+\right) + \ell^-\left(y^*, f_t(x); \lambda_-\right)\right]\end{aligned} \tag{6}$$

同样被用户指定的容忍度所界定，即$\mathcal{R}(\lambda_+, \lambda_-) \leq \epsilon$，其中仍有$\epsilon \in (0,1)$。或者，如果用户对两种退出方式（下阈值与上阈值）分别有风险目标，也可以单独加以控制：

$$\begin{aligned}\mathcal{R}^+(\lambda_+, \lambda_-) &\triangleq \mathbb{E}_{x,y^*}\left[\ell^+\left(y^*, f_t(x); \lambda_+\right) \mid \lambda_-\right] \leq \epsilon^+, \\ \mathcal{R}^-(\lambda_+, \lambda_-) &\triangleq \mathbb{E}_{x,y^*}\left[\ell^-\left(y^*, f_t(x); \lambda_-\right) \mid \lambda_+\right] \leq \epsilon^-.\end{aligned} \tag{7}$$

需要注意，上、下阈值的控制问题并不独立，因为经由一个阈值退出的样本会影响可能经由另一阈值退出的样本分布。下面介绍方法细节。我们将该方法称为Conformal Thinking（共形思考），因为它使用共形风险控制算法 (Bates et al., 2021; Angelopoulos et al., 2024, 2025)来设定λ_+和λ_-，从而实现高效的大语言模型“思考”，即推理。

4.2 提前退出推理的损失函数

下面定义四个损失函数，用于刻画提前退出所带来的正确性与效率权衡。由于我们只考虑有监督分类任务，所有损失的取值范围都是$[0,1]$。

预测性能损失。 首先量化过早停止所导致的分类错误。先考虑上阈值情形，产生**假阳性**的风险可以由以下损失刻画：

$$\begin{aligned}&\ell^+(y^*, f_t(x), \tilde{s}_t(x); \lambda_+) = \\ &\qquad \mathbb{I}\left[\tilde{s}_t(x) \geq \lambda_+\right] \cdot \mathbb{I}\left[f_t(x) \neq y^*\right],\end{aligned} \tag{8}$$

其中$\mathbb{I}[\cdot]$为指示函数。$\mathbb{I}[\tilde{s}_t(x) \geq \lambda_+]$检验置信度度量是否已经超过上阈值，$\mathbb{I}[f_t(x) \neq y^*]$则检验当前答案是否错误。

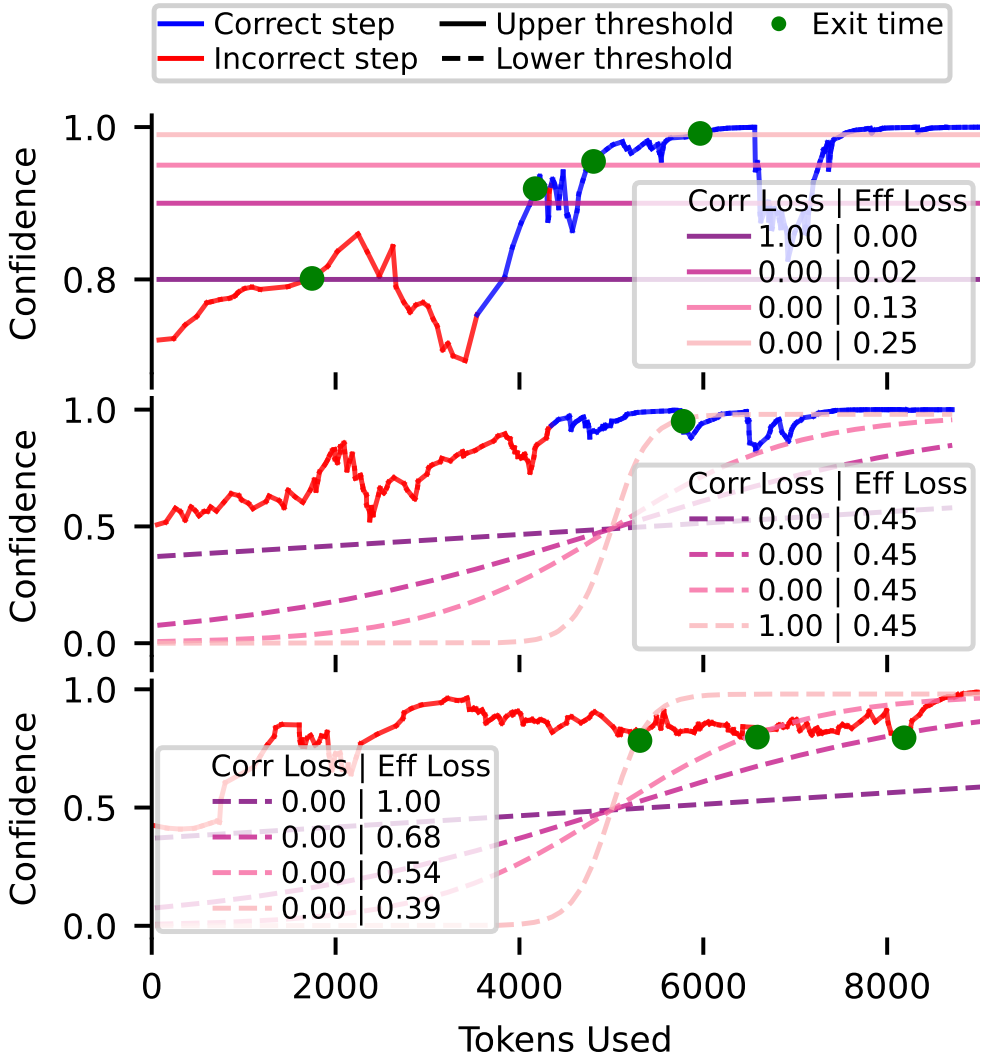


图 3: **不同阈值下所提出的正确性损失与效率损失的可视化**。不同颜色的线（从紫色到粉色）表示不同阈值曲线，框中的数字表示各阈值对应的正确性损失和效率损失。上排展示上阈值的正确性损失与效率损失（式(8)和(10)）。下方两图展示下阈值的sigmoid曲线（式(12)）及其相应的下阈值正确性损失与效率损失（式(9)和(11)）。对于某个给定样本，当多个阈值具有相同正确性损失时（例如上排最上面的3条线，以及下排所有线），应优先选择效率损失最小的阈值，以在保持用户指定风险容忍度的同时最大化效率。译注（图内英文）：confidence为置信度，token usage为词元使用量，correctness/efficiency loss分别为正确性/效率损失。

下阈值的损失应刻画**假阴性**：$\tilde{s}_t(x)$表明推理在T步内将始终无法得到正确回答，但实际上，继续推理会在某一步$k \in (t, T]$得到正确答案。

$$\ell^-(y^*, f_{t:T}(x), \tilde{s}_t(x); \lambda_-) = \frac{\mathbb{I}[\tilde{s}_t(x) \le \lambda_-]}{T - t + 1} \cdot \sum_{t \le k \le T} \mathbb{I}\left[f_k(x) = y^*\right]. \quad (9)$$

注意，与上述假阳性损失不同，这一损失具有前瞻性：它不仅需要检查当前解$f_t(x)$是否正确，还需要检查所有未来的解（$f_k(x),\ t \le k \le T$）。该损失返回在当前及未来解上计算的准确率。因此，如果只有一个未来时点的$f_k(x)$正确，其损失将低于多个未来答案都正确的情况。

效率损失。 现在定义用于衡量在第t步提前停止效率的损失。这些损失不依赖阈值参数λ，而是在多个λ都满足风险容忍度时，用于选择其中一个值。重要的是，这些损失相对于总推理预算T进行归一化，因为我们希望量化T中有多大比例属于“浪费”的推理步骤。

仍先从上阈值开始，我们希望量化当前停止时刻与理想停止时刻之间的差距；后者即答案首次正确时的推理步骤索引：

$$\mathcal{J}^+(t) = \frac{1}{T}\max(0, t - t'), \quad (10)$$

其中$t' = \min\{t \le T : f_t(x) = y^*\}$。当模型在第$t'$步获得正确答案时，此后的任何推理都是浪费的计算。因此，该损失衡量的是归一化遗憾：答案已经正确之后继续思考的步数，占总步数的比例。它与式(8)的损失互为补充，因为后者只考虑当前出口处的答案是否正确，不考虑如果更早退出会产生什么反事实结果。图3上排展示了若干退出位置与上阈值设定组合的预测损失及效率损失。

再看下阈值，其损失衡量的是：此前各出口中，答案错误的部分占多大比例？该损失通过考虑过去的出口，对式(9)中的预测损失形成补充：

$$\mathcal{J}^-(t) = \frac{1}{T}\sum_{k \le t} \mathbb{I}[y^* \ne f_k(x)]. \quad (11)$$

较小的值意味着我们要么很早就停止了，要么模型已经解决了问题。较大的值（极端情况下为1）则意味着消耗了很大比例的预算，却没有取得多少进展。

4.3 动态下阈值

到目前为止，我们将下阈值与上阈值一样描述为一个静态量。但请注意，静态下阈值只能在推理降低模型置信度时触发退出。我们实际希望迫使模型“按计划”提升置信度。如果推理未能以特定速度改善$\tilde{s}_t(x)$，就将其视为一个信号：模型很可能无法得到正确答案，应当退出以节约词元。换言之，模型必须展现出有规律的置信度增长，才被允许继续推理。

我们将下阈值设为推理步数的参数化函数，以落实这一置信度进展计划。这意味着下阈值是动态而非静态的。虽然存在多种参数化方式，并且其选择可能取决于任务，但我们发现下面的形式在总体上有效。给定总推理预算B个词元，令ω_t为截至第t步推理生成的词元总数。

$$\lambda_-(t; c, s, l, u) = \sigma(c\,(\omega_t - sB)\,, l, u)\,, \quad (12)$$

$$\sigma(z, l, u) = \frac{u - l}{1 + e^{-z}} + l \quad (13)$$

其中$c \in \mathbb{R}^+$表示斜率，$\sigma(z, l, u)$为压缩到(l, u)范围内的逻辑斯蒂（sigmoid）函数，$l < u < 1$（u通常可选为λ_+），$s \in \mathbb{R}$则相对于最大词元预算水平平移sigmoid。较大的c意味着继续推理需要置信度更快提升；结合不同的s值，式(13)可以得到多种形状，例如线性（$s = 0.5, cB \ll 1$）、指数（$s > 1$）、对数（$s < 0$）或常数（$c \to 0$）。

此时，真正需要设定的参数是$\{c, s, l\}$，因此式(6)中的双阈值风险更适合写成$\mathcal{R}(\lambda_+, \{c, s, l\})$。图3下方两排展示了在$s = 0.5$、$l = 0$及不同$c$值下，各种退出位置和动态阈值设定组合及其对应损失。最后，为简化记号，本文余下部分会略微滥用记号，仅用一个符号c表示参数集合$\{c, s, l\}$。

算法 1 计算超参数

输入： 验证集$\mathcal{V} = \{(x_n, y_n)\}_{n=1}^{N}$
输入： 风险预算$\epsilon \in (0,1)$
输入： 候选不确定性信号集合$\mathcal{S}$
输入： 阈值网格$\{\Lambda_s\}_{s\in\mathcal{S}}$
输入： 对每个x_n产生模型输出$\hat{y}_n$的预测过程
输入： 风险估计量$\widetilde{\mathrm{Risk}}(\lambda;\mathcal{V})$
输入： 效率损失估计量$\widehat{\mathcal{J}}(s,\lambda;\mathcal{V})$
输出： 选定的信号与阈值对$(s^\star, \lambda^\star)$

初始化可行集合： $\mathfrak{C} \leftarrow \emptyset$
for 每个信号$s \in \mathcal{S}$ **do** ▷ 对信号进行网格搜索
  for 每个阈值$\lambda \in \Lambda_s$ **do** ▷ 以及对阈值进行网格搜索
    计算校正后的估计风险：$r \leftarrow \widetilde{\mathrm{Risk}}(\lambda;\mathcal{V})$
    if $r \le \epsilon$ **then**
      计算效率损失：$e \leftarrow \widehat{\mathcal{J}}(s,\lambda;\mathcal{V})$
      将(s,λ,e)加入$\mathfrak{C}$
if $\mathfrak{C} = \emptyset$ **then** ▷ 不存在可行配对
  返回(None, None)
else
  $(s^\star,\lambda^\star) \leftarrow \arg\min_{(s,\lambda,e)\in\mathfrak{C}} e$ ▷ 选择最优配对
  返回$(s^\star,\lambda^\star)$

4.4 控制风险的超参数选择

在定义了必要构件（双阈值退出策略、损失函数和动态下阈值）之后，现在介绍如何选择c和λ_+，使风险被控制在ϵ水平。我们利用现有的分布无关风险控制算法 (Bates et al., 2021; Angelopoulos et al., 2024, 2025)。具体而言，我们采用Bates et al. (2021)的上置信界（upper confidence bound，UCB）方法，它已被证明对风险受控的EENN有效 (Jazbec et al., 2024)。

以高概率实现控制。 给定一个留出数据集$\mathcal{V} = \{(x_i, y_i^*)\}_{n=1}^{N}$，UCB算法可以返回一组超参数设定，使（真实）风险以高概率受到控制：

$$\mathbb{P}_{\mathcal{V}}\left(\mathcal{R}\left(\hat{\lambda}_+, \hat{c}\right) \le \epsilon\right) \;\ge\; 1-\delta \tag{14}$$

其中$\delta \in [0,1]$。$\mathbb{P}_{\mathcal{V}}$中的随机性受校准集$\mathcal{V}$规模的影响，因为我们需要用它选择$\hat{\lambda}_+$和$\hat{c}$。校准集越大，经验风险对真实风险的近似就越好，超参数选择也就越稳健。应用UCB算法的一个技术条件是，损失函数 (Bates et al., 2021)或风险 (Jazbec et al., 2024)必须是超参数的单调函数。我们假设本文的风险关于c和λ_+单调。

两步超参数选择。 为了联合使用下阈值和上阈值，原则上可以对所有可能的c与λ_+组合运行风险控制，例如使用“先学习、再检验” (Angelopoulos et al., 2025)。不过，我们发现下面这种两步解耦程序在实践中同样有效，尽管它在理论严谨性上有所损失。首先，使用UCB在目标风险ϵ^+下选择λ_+；然后固定上阈值，通过控制风险$\mathbb{E}[\ell^- \mid \hat{\lambda}_+] \le \epsilon^-$来选择$c$。

由于c是在$\hat{\lambda}_+$已经选定后才选择的，对c的选择仍有风险控制保证。如附录C所推导，当下阈值提前退出的可解样本比例超过不可解样本比例时，即下阈值机制完全失效时，上阈值的风险界可能被违反。虽然这种情况在理论上可能发生，但我们认为，实践中只有非常极端的分布偏移，才会使验证集上找到的c在测试环境中彻底失效，从而出现这一现象。

选择算法的高层概述。 UCB算法的完整细节可参见Bates et al. (2021)及附录B。这里简要介绍其思路。我们从直觉层面说明，因为大多数风险控制算法都具有下面的一般形式，而用户也可

能希望用其他算法替换UCB。对于每个置信度信号$s \in \mathcal{S}$和每个阈值$\lambda \in \Lambda_s$（或$c \in \mathcal{C}$的值），计算给定损失函数下的经验风险：

$$\widehat{\mathrm{Risk}}(\lambda; \mathcal{V}) = \frac{1}{N} \sum_{n=1}^{N} \ell\left(y_n^*, f_\tau(x_n), s_\tau(x_n); \lambda\right), \tag{15}$$

其中τ表示信号s在超参数λ下诱导出的退出位置。一种朴素实现，本质上就是标准交叉验证，会选择所有满足$\widehat{\mathrm{Risk}}(\lambda; \mathcal{V}) \le \epsilon$的$\lambda$值。

然而，$\mathcal{V}$是有限的，而且往往很小，因此经验风险可能是对真实风险的乐观估计。结果是，朴素交叉验证选择的阈值可能对验证集过拟合，使真实风险未能受到控制。图4第一列展示了这一现象：朴素校准频繁导致实际测试风险超过目标线$y = x$。UCB以及其他风险控制算法用一个校正后的风险替换经验风险：

$$\widetilde{\mathrm{Risk}}(\lambda; \mathcal{V}) = \widehat{\mathrm{Risk}}(\lambda; \mathcal{V}) + \text{（有限样本校正项）},$$

其中有限样本校正项是验证集规模的函数。随后通过寻找使校正风险满足约束的取值来进行超参数选择，即$\widetilde{\mathrm{Risk}}(\mathcal{V}, s, \lambda) \le \epsilon$。图4第二列展示了加入有限样本校正的效果：在对$\mathcal{V}$进行不同重采样时，测试风险始终保持在用户指定的风险容忍度以下。

如果存在多组可行的(s, λ)，例如不同类型的不确定性信号及阈值，我们就选择使前述某个效率损失最小的组合：

$$\widehat{\mathcal{J}}(s, \lambda; \mathcal{V}) = \frac{1}{N} \sum_{n=1}^{N} \mathcal{J}\left(\tau_n(s, \lambda)\right), \tag{16}$$

其中$\tau_n(s, \lambda)$表示第n个验证样本在信号s和阈值参数λ下的退出位置。该程序会选出不超过目标风险且效率最高的超参数配置。

完整流程。 算法1总结了完整实现。最终的选择规则是：（i）在$\mathcal{V}$上枚举信号与阈值的候选组合；（ii）使用风险控制落实风险预算，同时计入有限样本误差；（iii）在所有可行候选中选择效率损失估计最小者。由此得到一个适用于任意信号、简单且即插即用的校准接口，并且相比朴素阈值调优，更能防范验证集过拟合。

4.5 风险控制视角的优势

需要注意，在以下两种情形中，严格来说并不需要风险控制。

- **纯粹的比较性评估。**如果目的仅在于说明某种提前停止信号在准确率与计算量的权衡上优于另一种，那么扫描阈值就已足够：可以在带标签的基准数据集上枚举阈值，并报告得到的帕累托前沿或曲线下面积，而无需承诺采用某个具体运行点。
- **完全可解释的信号。**如果停止信号已直接针对正确性进行校准，例如置信度值p确实意味着$\Pr(\text{正确}) = p$，那么选择阈值就等价于选择错误率，临时设定阈值带来的问题也会较小。

为何这些条件在实践中并不典型。 第一种情形在两个方面偏离实际部署环境。首先，真实系统通常需要一个具体配置，或少量具体配置，来满足用户或应用指定的错误容忍度，而不是事后报告整条参数扫描曲线。[2]

第二个条件对于现有提前停止信号也很少成立：原始阈值与实际达到的错误水平之间的映射，高度依赖于信号、模型和任务（图1左）。此外，下阈值常被实现为时间或词元数的参数化函数，含有更多超参数，这些参数更难解释，也更难跨任务迁移。因此，手动调参并不可靠，也更加需要能够考虑有限样本影响的原则性选择方法。

[2]译注：原文称“在两个方面”，但此处仅列出“首先”这一项，随后转而讨论第二种条件；译文按正式原文保留。

风险控制带来的收益。 因此，我们的框架要求用户指定风险容忍度ϵ，这是一个具有下游含义的运行量；再利用留出验证集和有限样本校正，自动选择阈值，必要时还会在多种停止准则之间进行选择，使实际测试风险以高概率遵守用户指定的容忍度。这将用户的负担从调整不透明的阈值，转变为选择可解释的错误容忍度。

5 实证验证

本节首先通过实验验证风险控制的有效性，然后展示风险控制框架通过信号集成以及上、下阈值联合所带来的效率提升。

5.1 实验设置

模型与数据集。 我们在Qwen3-8B、Qwen3-30B-A3B、DeepSeek-R1-Distill-Qwen-32B以及Qwen3-VL-8B上评估方法。数据集包括AIME（1983–2025年，1011个样本）、去除AIME后的DeepScaleR子集（1189个样本）(Luo et al., 2025)、GPQA-Diamond（198个样本）(Rein et al., 2024)，以及视觉语言推理数据集MathVision（304个样本）(Wang et al., 2024)。

推理生成。 我们使用的系统提示为“Please reason step by step, and put your final answer within \boxed{}.”，即“请逐步推理，并将最终答案放在\boxed{}内”。所有模型均采用其模型卡推荐的解码配置，所有实验均使用vLLM进行生成。

答案与不确定性信号的提取。 在推理生成过程中，我们将两个相邻`\n\n`分隔符之间的文本视为一个块；所有不确定性信号都在每次增长的文本块结束时计算。如果决定在某一块处提前停止，则附加强制字符串`"\n **Final Answer**\n \boxed{"`，以提取规范的方框答案。我们考虑两种基于不确定性的信号：置信度 (Yang et al., 2025)和EAT (Wang et al., 2025a)；对于Qwen3-8B，还在AIME上训练了一个探针模型 (Zhang et al., 2025)。此外，我们也将词元数用作停止准则。附录A.1介绍这些信号。

5.2 风险控制框架能够控制风险

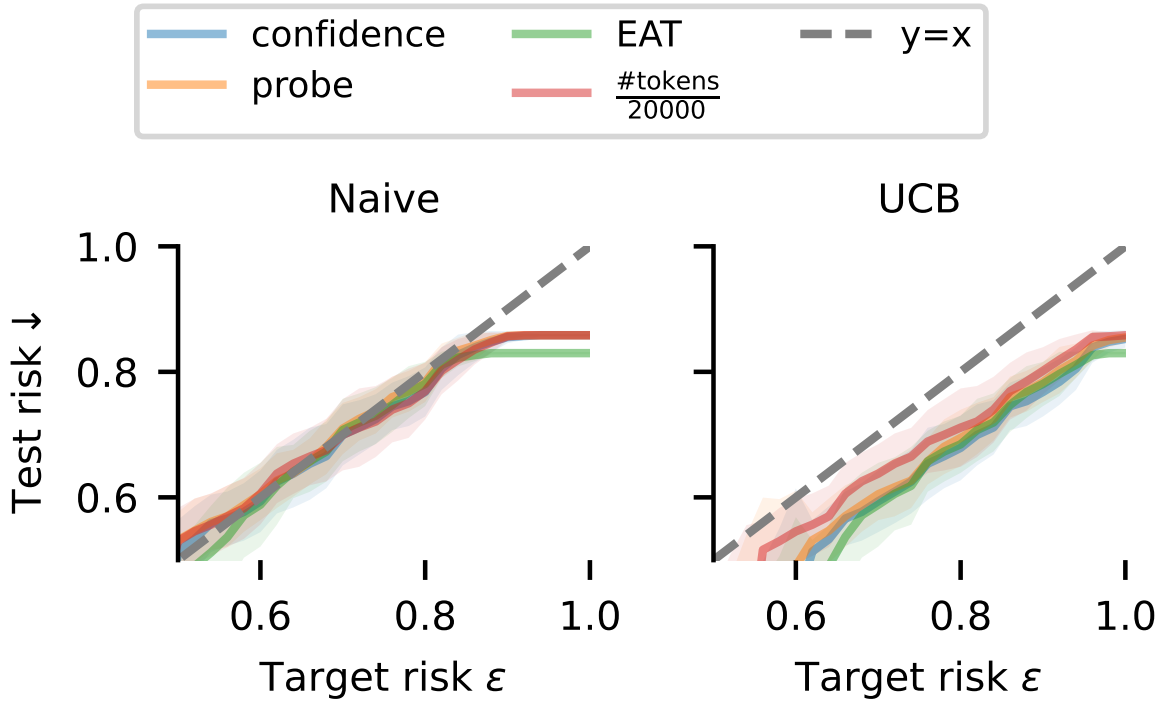
首先，对算法1的有效性进行合理性检验。具体而言，我们希望验证：给定风险容忍度ϵ，在验证集上选出的阈值是否能使测试风险小于ϵ。

我们在AIME上考察Qwen3-8B模型，并采用多种提前停止信号，包括基于不确定性的信号、基于探针的信号，以及仅使用词元数的信号。我们随机生成40组验证集与测试集划分，验证集大小为50个样本（约5%），并同时研究假阳性损失（式(8)）与假阴性损失（式(9)）。我们以0.01为步长枚举$[0, 1]$中的ϵ值，使用算法1找到阈值，再将测试集上实际达到的风险与ϵ进行比较。

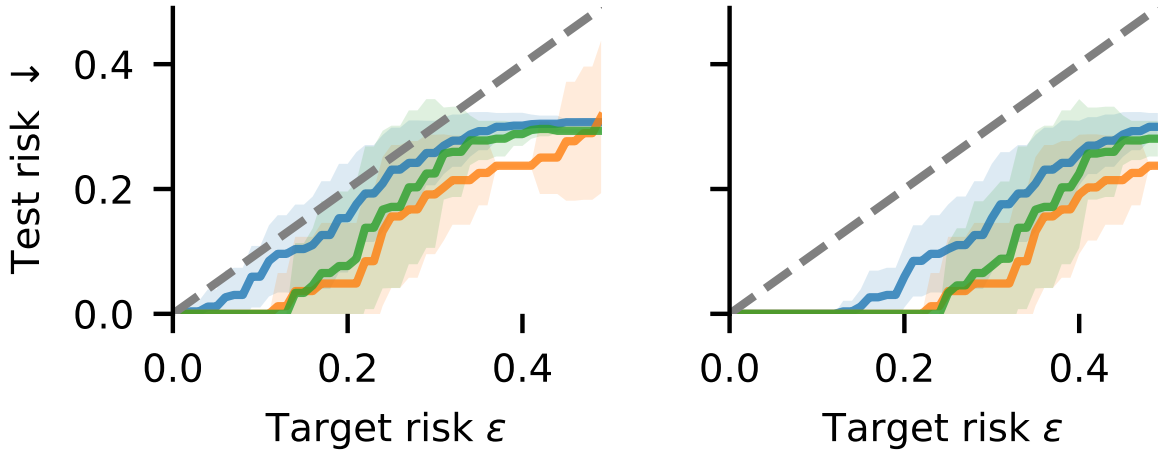
结果见图4。使用有限样本校正（UCB）能够使未见测试集上的风险低于用户指定的阈值。朴素交叉验证虽然能够控制均值，但其标准差带经常跨越$y = x$直线，即许多单次运行超过了目标风险。

5.3 风险控制框架能够提高效率

下面展示风险控制框架如何支持更高效的推理。实验枚举不同ϵ值，并对每个ϵ，考察模型正确回答的问题总数与消耗的词元总数之间的关系。



(a) 假阳性风险



(b) 假阴性风险

图 4: **风险控制的实证验证**。横轴为用户指定的目标风险ϵ，纵轴为经验测试风险。实线和阴影区域分别表示40次随机测试集与验证集划分所得结果的均值和标准差，不同颜色表示不同提前停止信号。左侧面板（Naive）在验证集上选择阈值时不进行有限样本校正，导致实际测试风险频繁超过ϵ；对由下阈值（式(12)）控制的假阴性风险（式(9)）尤其如此，因为下阈值更加灵活，也更容易受到噪声影响。右侧面板（UCB）采用考虑验证不确定性的概率风险控制程序，保证在所选阈值下，测试风险以高概率不超过ε。译注（图内英文）：Naive为朴素方法，UCB为上置信界方法，Target risk为目标风险，Test risk为测试风险，confidence为置信度，probe为探针，#tokens为词元数。

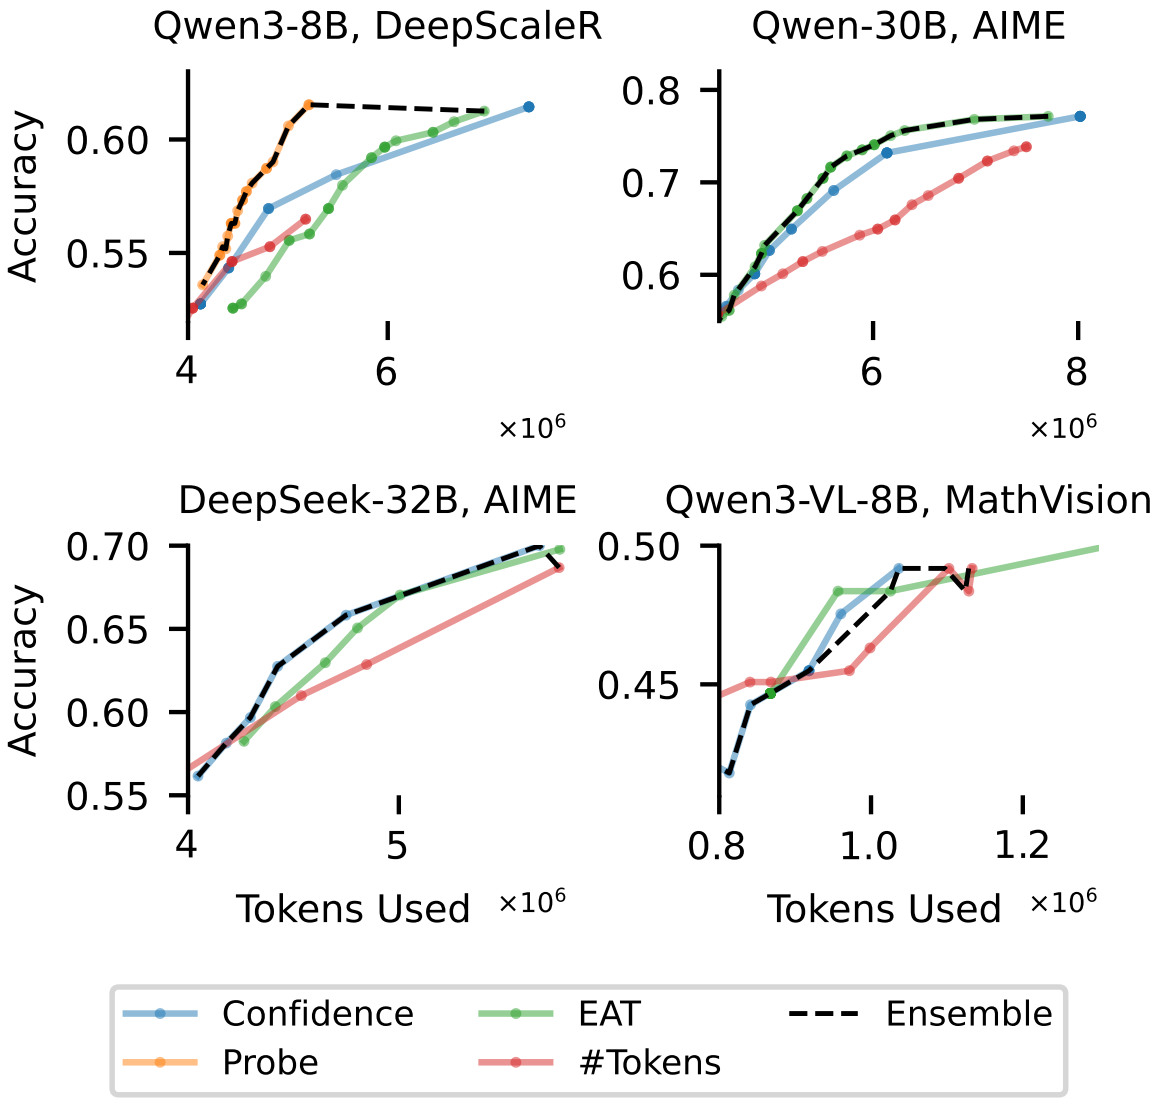


图 5: **信号集成提高效率**。在四个模型上，我们考虑仅使用上阈值的提前停止。给定目标容忍度ϵ，风险控制框架选择使效率损失（式(10)）最小的信号，形成信号的集成，进而在测试集上实现更高效率，即更好的准确率与词元量权衡。译注（图内英文）：ensemble为集成，accuracy为准确率，token usage或tokens为词元使用量，confidence为置信度，probe为探针；模型名称及EAT缩写保留原文。

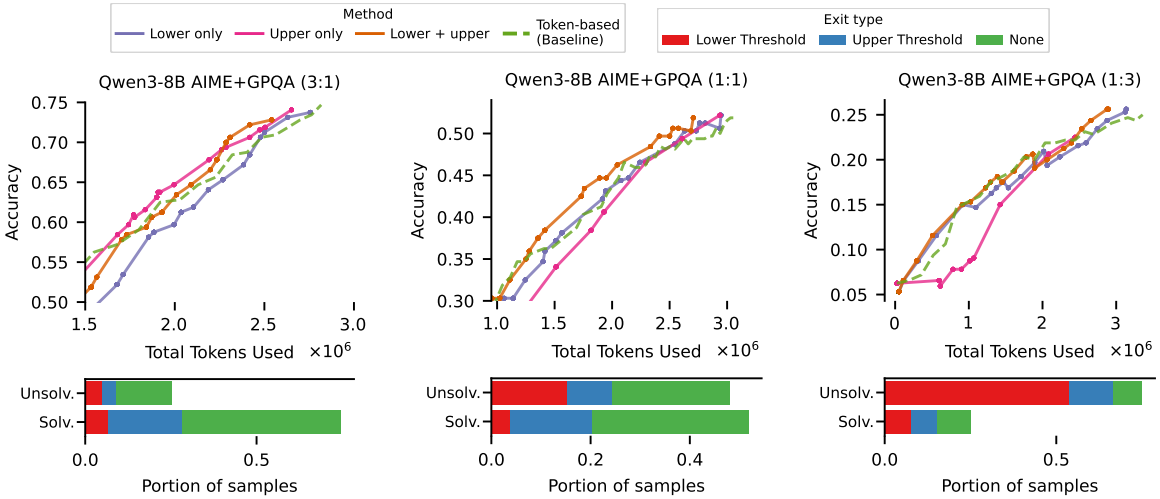


图 6: **无法求解的样本越普遍，下阈值的收益越大**。我们使用置信度作为不确定性信号，在可解:不可解比例分别为3:1、1:1和1:3的数据集上评估Qwen3-8B。这些数据集通过合并AIME与GPQA、按完整词元预算下的可解性标注样本，再进行子采样以匹配各个比例而构建。**上排：**Lower-only（仅下阈值）、Upper-only（仅上阈值）和Lower+Upper（上下阈值联合）方法的测试准确率与总词元数关系；被下阈值弃答的样本视为错误。每个点对应一个在验证集上校准的风险容忍度ϵ，同时给出统一词元预算基线。当不可解样本较常见时（1:1和1:3），Upper-only聚集在高词元用量区域，因为许多运行始终达不到置信度截断值，只能一直运行到预算耗尽；加入下阈值后，曲线向左移动，即用更少的词元达到相近准确率。**下排：**在Lower+Upper的一个代表性运行点（准确率第二高）上，报告可解和不可解样本所占比例及触发终止的条件。结果显示，可解样本通常经由上阈值退出，不可解样本通常经由下阈值退出。译注（图内英文）：solvable/unsolvable为可解/不可解，upper/lower threshold为上/下阈值，uniform token budget为统一词元预算。

信号集成提高效率。 给定ϵ，算法1的关键步骤之一是选择使效率损失最小的信号与阈值对（第6行和第11行）[3]。由此可以构造不确定性信号集成：对于每个ϵ和数据集，选择效率最高的信号与阈值。结果证实，验证集上效率最高的配置可以转化为测试集上的效率收益，见图5。总体而言，集成能够在全部候选中选出最有效率的信号。例如，在Qwen3-8B上，我们有一个在AIME上训练的强大探针模型，因此集成在不同ϵ下始终选择探针。

下阈值提高效率。 接下来考察上阈值和下阈值如何通过互补来提升效率。上阈值主要在可解样本上节约词元，在模型获得信心后停止；下阈值则主要在不可解样本上节约词元，终止那些不确定性没有改善、否则会消耗全部预算的运行。因此，下阈值的价值取决于测试集中可解:不可解样本的构成。为研究这一依赖关系，我们构建了**可解:不可解比例**分别为3:1、1:1和1:3的受控评估集。具体做法是合并AIME与GPQA，根据模型在完整词元预算下能否得到正确最终答案来标注每个样本，然后进行子采样以匹配目标比例。

使用置信度作为不确定性信号，我们比较Upper-only、Lower-only和Lower+Upper。对于Upper-only和Lower-only，曲线上的每个点对应一个在验证划分上校准的风险容忍度ϵ。对于Lower+Upper，我们将上阈值固定为达到最小验证风险的值，再扫描下阈值。

如图6所示，当可解样本占主导时（3:1），Upper-only已获得大多数计算节省，Lower-only增加的收益很少。当不可解样本较常见时（1:1和1:3），Upper-only变得低效：许多运行始终不满足置信度截断条件，只能运行到最大预算，因而其曲线停留在高词元用量区域（图6上排）。加入下阈值能够缓解这一失效模式，并使曲线在准确率相近时明显左移。图6下排进一步证实了这种分工：在一个代表性运行点上（Lower+Upper准确率第二高的点），可解样本多数经由上阈值退出，而不可解样本多数经由下阈值退出。

5.4 消融研究

最后，我们研究风险控制在验证集规模变化以及分布偏移下的稳健性。该研究聚焦于在DeepScaleR上评估的Qwen3-8B。

验证集规模。 固定测试集为800个样本，将验证集大小设为$\{8, 16, 40\}$。总体而言，验证集越小，UCB相比朴素方法的优势越明显（图7）。

分布偏移。 我们研究验证集与测试集之间的两类分布偏移：

- **长度偏移：** 验证集的总体长度与测试集不同。结果见图8：从短（验证）到长（测试）的迁移带来了挑战，尤其是对下阈值风险而言，因为下阈值形状高度依赖推理长度。由上阈值控制的假阳性风险则没有明显退化。
- **数据集偏移：** 验证集与测试集来自不同数据集。我们考察AIME与GPQA-Diamond，即数学题与科学题之间的迁移。需要注意，这也包含难度偏移，因为GPQA的解出率远低于AIME。结果见图9。同样，不进行有限样本校正的朴素方法出现严重的风险超标，而UCB仍能将测试风险限制在目标风险ϵ以下。

6 结论、局限性与未来工作

结论。 我们提出了Conformal Thinking（共形思考），一种用于提升大语言模型推理效率的方法。我们不只是等到推理链达到高置信度或稳定状态才停止，而是增加第二个阈值，用它表示模型为了继续推理而必须遵守的置信度提升“计划”。这样，无论模型处于高置信度状态，还是看起来已没有希望得到正确答案，推理链都可以终止。

[3]译注：这里保留正式原文对算法行号的引用；按算法实际排印，最优可行组合的选择位于后面的arg min步骤。

局限性。 本方法的主要局限在于，我们假设风险函数关于超参数单调，并假设引入下阈值不会影响上阈值损失所产生的风险。由于这两个假设均涉及真实风险，只有在大样本情形下才能严格验证，而此时有限样本校正的重要性又相对较低。此外，我们目前的评估仅限于科学与数学推理任务，主要原因是现有不确定性信号还无法对那些推理过程和输出结构较弱的任务进行有效的提前停止。

未来工作。 未来可以考虑利用测试时学习，为不同样本分别设定参数或阈值 (Zhou et al., 2026)；将风险控制框架应用于智能体框架，例如 Sadhuka et al. (2025)，以识别智能体即将失败的情况；将框架扩展到其他测试时扩展形式，例如并行推理链；最后，还可以改善不确定性信号本身的校准程度和可解释性，例如在后训练期间增加辅助目标 (Wang et al., 2026)，从而降低对事后校准的依赖。

影响声明

本文工作的目标是推动机器学习领域的发展。本研究可能产生多种社会影响，但我们认为其中没有需要在此特别强调的方面。

致谢

感谢Metod Jazbec和Alexander Timans提供有益反馈。本研究部分获得Apple、美国国防高级研究计划局（DARPA，合同编号HR001125C0304）以及美国海军研究办公室（ONR，项目编号N0001424-1-2089）的支持。本文表达的观点、发现、结论或建议均为作者个人意见，并不一定反映DARPA的立场。我们感谢约翰斯·霍普金斯大学DSAI集群提供的计算资源。

参考文献

Angelopoulos, A. N., Bates, S., Fisch, A., Lei, L., and Schuster, T. Conformal risk control. The Twelfth International Conference on Learning Representations, 2024.

Angelopoulos, A. N., Bates, S., Candès, E. J., Jordan, M. I., and Lei, L. Learn then test: Calibrating predictive algorithms to achieve risk control. The Annals of Applied Statistics, 19(2):1641–1662, 2025.

Bates, S., Angelopoulos, A., Lei, L., Malik, J., and Jordan, M. Distribution-free, risk-controlling prediction sets. Journal of the ACM (JACM), 2021.

Center for AI Safety, Scale AI, and HLE Contributors Consortium. A benchmark of expert-level academic questions to assess AI capabilities. Nature, 649:1139–1146, 2026. doi: 10.1038/s41586-025-09962-4. URL https://arxiv.org/abs/2501.14249.

DeepSeek-AI, Guo, D., Yang, D., Zhang, H., Song, J., Zhang, R., Xu, R., Zhu, Q., Ma, S., Wang, P., Bi, X., Zhang, X., Yu, X., Wu, Y., Wu, Z. F., Gou, Z., Shao, Z., Li, Z., Gao, Z., Liu, A., Xue, B., Wang, B., Wu, B., Feng, B., Lu, C., Zhao, C., Deng, C., Zhang, C., Ruan, C., Dai, D., Chen, D., Ji, D., Li, E., Lin, F., Dai, F., Luo, F., Hao, G., Chen, G., Li, G., Zhang, H., Bao, H., Xu, H., Wang, H., Ding, H., Xin, H., Gao, H., Qu, H., Li, H., Guo, J., Li, J., Wang, J., Chen, J., Yuan, J., Qiu, J., Li, J., Cai, J. L., Ni, J., Liang, J., Chen, J., Dong, K., Hu, K., Gao, K., Guan, K., Huang, K., Yu, K., Wang, L., Zhang, L., Zhao, L., Wang, L., Zhang, L., Xu, L., Xia, L., Zhang, M., Zhang, M., Tang, M., Li, M., Wang, M., Li, M., Tian, N., Huang, P., Zhang, P., Wang, Q., Chen, Q., Du, Q., Ge, R., Zhang, R., Pan, R., Wang, R., Chen, R. J., Jin, R. L., Chen, R., Lu, S., Zhou, S., Chen, S., Ye, S., Wang, S., Yu, S., Zhou, S., Pan, S., Li, S. S., Zhou, S., Wu, S., Ye, S., Yun, T., Pei, T., Sun,

T., Wang, T., Zeng, W., Zhao, W., Liu, W., Liang, W., Gao, W., Yu, W., Zhang, W., Xiao, W. L., An, W., Liu, X., Wang, X., Chen, X., Nie, X., Cheng, X., Liu, X., Xie, X., Liu, X., Yang, X., Li, X., Su, X., Lin, X., Li, X. Q., Jin, X., Shen, X., Chen, X., Sun, X., Wang, X., Song, X., Zhou, X., Wang, X., Shan, X., Li, Y. K., Wang, Y. Q., Wei, Y. X., Zhang, Y., Xu, Y., Li, Y., Zhao, Y., Sun, Y., Wang, Y., Yu, Y., Zhang, Y., Shi, Y., Xiong, Y., He, Y., Piao, Y., Wang, Y., Tan, Y., Ma, Y., Liu, Y., Guo, Y., Ou, Y., Wang, Y., Gong, Y., Zou, Y., He, Y., Xiong, Y., Luo, Y., You, Y., Liu, Y., Zhou, Y., Zhu, Y. X., Xu, Y., Huang, Y., Li, Y., Zheng, Y., Zhu, Y., Ma, Y., Tang, Y., Zha, Y., Yan, Y., Ren, Z. Z., Ren, Z., Sha, Z., Fu, Z., Xu, Z., Xie, Z., Zhang, Z., Hao, Z., Ma, Z., Yan, Z., Wu, Z., Gu, Z., Zhu, Z., Liu, Z., Li, Z., Xie, Z., Song, Z., Pan, Z., Huang, Z., Xu, Z., Zhang, Z., and Zhang, Z. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning, 2025. URL https://arxiv.org/abs/2501.12948.

Fu, Y., Chen, J., Zhu, S., Fu, Z., Dai, Z., Zhuang, Y., Ma, Y., Qiao, A., Rosing, T., Stoica, I., and Zhang, H. Efficiently scaling llm reasoning with certaindex, 2025. URL https://arxiv.org/abs/2412.20993.

Hassid, M., Synnaeve, G., Adi, Y., and Schwartz, R. Don' t overthink it. preferring shorter thinking chains for improved llm reasoning, 2026. URL https://arxiv.org/abs/2505.17813.

Huang, G., Chen, D., Li, T., Wu, F., van der Maaten, L., and Weinberger, K. Multi-scale dense networks for resource efficient image classification. International Conference on Learning Representations, 2018.

Jazbec, M., Timans, A., HadziˇVeljkovic,́ T., Sakmann, K., Zhang, D., Andersson Naesseth, C., and Nalisnick, E. Fast yet safe: Early-exiting with risk control. Advances in Neural Information Processing Systems, 37:129825–129854, 2024.

Jurayj, W., Cheng, J., and Durme, B. V. Is that your final answer? test-time scaling improves selective question answering. In Annual Meeting of the Association for Computational Linguistics, 2025. URL https://aclanthology.org/2025.acl-short.50/.

Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), Proceedings of the 17th International Conference on Machine Learning (ICML 2000), pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.

Liao, B., Dong, H., Xu, Y., Sahoo, D., Monz, C., Li, J., and Xiong, C. Fractured chain-of-thought reasoning, 2025. URL https://arxiv.org/abs/2505.12992.

Liu, X. and Wang, L. Answer convergence as a signal for early stopping in reasoning. In Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, pp. 17907–17918, 2025.

Luo, M., Tan, S., Wong, J., Shi, X., Tang, W. Y., Roongta, M., Cai, C., Luo, J., Li, L. E., Popa, R. A., and Stoica, I. Deepscaler: Surpassing o1-preview with a 1.5b model by scaling rl, 2025. Notion Blog.

Mao, M., Yin, B., Zhu, Y., and Fang, X. Early stopping chain-of-thoughts in large language models, 2025. URL https://arxiv.org/abs/2509.14004.

Moshkov, I., Hanley, D., Sorokin, I., Toshniwal, S., Henkel, C., Schifferer, B., Du, W., and Gitman, I. Aimo-2 winning solution: Building state-of-the-art mathematical reasoning models with openmathreasoning dataset, 2025. URL https://arxiv.org/abs/2504.16891.

Rein, D., Hou, B. L., Stickland, A. C., Petty, J., Pang, R. Y., Dirani, J., Michael, J., and Bowman, S. R. GPQA: A graduate-level google-proof q&a benchmark. In First Conference on Language Modeling, 2024. URL https://openreview.net/forum?id=Ti67584b98.

Ringel, L., Cohen, R., Freedman, D., Elad, M., and Romano, Y. Early time classification with accumulated accuracy gap control. In Proceedings of the 41st International Conference on Machine Learning, pp. 42584–42600, 2024.

Sadhuka, S., Prinster, D., Fannjiang, C., Scalia, G., Regev, A., and Wang, H. E-valuator: Reliable agent verifiers with sequential hypothesis testing. arXiv preprint arXiv:2512.03109, 2025.

Schuster, T., Fisch, A., Gupta, J., Dehghani, M., Bahri, D., Tran, V., Tay, Y., and Metzler, D. Confident adaptive language modeling. Advances in Neural Information Processing Systems, 2022.

Snell, C., Lee, J., Xu, K., and Kumar, A. Scaling llm test-time compute optimally can be more effective than scaling model parameters. arXiv preprint arXiv:2408.03314, 2024.

Wang, K., Pan, J., Shi, W., Lu, Z., Ren, H., Zhou, A., Zhan, M., and Li, H. Measuring multimodal mathematical reasoning with math-vision dataset. In The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track, 2024. URL https://openreview.net/forum?id=QWTCcxMpPA.

Wang, L., Zuo, C., Jurayj, W., Van Durme, B., and Liu, A. Process supervision of confidence margin for calibrated llm reasoning. arXiv preprint arXiv:2604.23333, 2026.

Wang, X., McInerney, J., Wang, L., and Kallus, N. Entropy after ⟨/Think⟩ for reasoning model early exiting, 2025a. URL https://arxiv.org/abs/2509.26522.

Wang, Y., Zhang, Y., Yu, T., Xu, C., Zhang, F., and Lian, F. Adaptive deep reasoning: Triggering deep thinking when needed, 2025b. URL https://arxiv.org/abs/2505.20101.

Wei, Z., Pang, L., Liu, J., Shi, W., Deng, J., Xu, S., Duan, Z., Sun, F., Shen, H., and Cheng, X. The evolution of thought: Tracking llm overthinking via reasoning dynamics analysis, 2026. URL https://arxiv. org/abs/2508.17627.

Wu, M., Zhou, C., Bates, S., and Jaakkola, T. Thought calibration: Efficient and confident test-time scaling. ArXiv, abs/2505.18404, 2025. URL https://api.semanticscholar.org/CorpusID:278905640.

Xu, Z., Lou, X., Wang, G., Chuang, Y.-N., Luo, F., Zheng, G., Szalay, A. S., Liu, Z., and Braverman, V. Dts: Enhancing large reasoning models via decoding tree sketching, 2026. URL https://arxiv.org/abs/2511.00640.

Yang, C., Si, Q., Duan, Y., Zhu, Z., Zhu, C., Li, Q., Lin, Z., Cao, L., and Wang, W. Dynamic early exit in reasoning models, 2025. URL https://arxiv.org/abs/2504.15895.

Zeng, H., Huang, J., Jing, B., Wei, H., and An, B. On the provable performance guarantee of efficient reasoning models, 2026. URL https://arxiv.org/abs/2510.09133.

Zhang, A., Chen, Y., Pan, J., Zhao, C., Panda, A., Li, J., and He, H. Reasoning models know when they' re right: Probing hidden states for self-verification, 2025. URL https://arxiv.org/abs/2504.05419.

Zhou, C., Wang, Z., Wu, M., Zhu, Q. J., Shi, F. C., Wang, C., Wilson, A., Jaakkola, T., and Bates, S. Online reasoning calibration: Test-time training enables generalizable conformal llm reasoning. arXiv preprint arXiv:2604.01170, 2026.

A 补充实验说明

A.1 信号提取

我们评估在每个思维片段处度量不确定性或置信度的信号。具体而言，我们重点考察两项主要指标：</think> 之后的熵（Entropy After </think>，EAT）(Wang et al., 2025b)，以及置信度（Confidence）(Yang et al., 2025)。

令 $p_\theta(\cdot \mid x)$ 表示给定前缀 x 时的下一词元 分布。我们通过同时追加思维终止标签和强制生成字符串，定义变换后的前缀 x_{forced}：

$$x_{\text{forced}} = x \oplus \texttt{</think>} \oplus \texttt{forcing_string}. \tag{17}$$

其中，如正文所述，forcing_string 为 "\n **Final Answer**\n \boxed{"。

对于 EAT，我们还会在应用强制生成字符串之前追加思维终止标签 </think>。

置信度（Confidence） 在 x_{forced} 之后以贪心方式生成一个答案，记作 $\mathbf{a} = (a_1, \ldots, a_L)$。随后，使用 $\mathbf{a}$ 上经过长度归一化的对数似然作为置信度得分：

$$C_{\text{seq}}(x, \mathbf{a}) = \frac{1}{L} \sum_{i=1}^{L} \log p_\theta(a_i \mid x, a_{<i}). \tag{18}$$

EAT 不生成完整答案，而是直接考察 x_{forced} 之后下一词元 预测分布的熵：

$$\mathbb{H}(p_\theta(\cdot \mid x_{\text{forced}})). \tag{19}$$

其中，如正文所述，forcing_string 定义为 "\n **Final Answer**\n \boxed{"。

置信度（Confidence） 在 x_{forced} 之后以贪心方式生成一个答案，记作 $\mathbf{a} = (a_1, \ldots, a_L)$。随后，使用 $\mathbf{a}$ 上经过长度归一化的对数似然作为置信度得分：

$$C_{\text{seq}}(x, \mathbf{a}) = \frac{1}{L} \sum_{i=1}^{L} \log p_\theta(a_i \mid x, a_{<i}). \tag{20}$$

EAT 不生成完整答案，而是直接考察 x_{forced} 之后下一词元 预测分布的熵：

$$\mathbb{H}(p_\theta(\cdot \mid x_{\text{forced}})). \tag{21}$$

译注：正式原文在此重复给出了置信度和 EAT 的定义及相应公式，译文予以保留，以保持内容和公式编号一致。

探针信号。 我们还计算基于探针的信号；这些探针在 AIME 推理轨迹上训练。

表征提取与标注：令 P 表示原始问题提示，$x_{1:T}$ 表示推理轨迹。假设模型在词元索引 $1 \le t_1 < \cdots < t_K \le t_T$ 处输出 K 个候选最终答案，第 s 个候选答案记为 $\hat{a}_s$。对于每一步 s，我们重建解码上下文

$$C_s = [P;\, x_{1:t_s}],$$

并提取最后一个隐藏层中最后一个词元 的隐藏表征：

$$h_s \in \mathbb{R}^d.$$

根据其相对于标准答案 $a^\star$ 的正确性，对每一步进行标注：

$$y_s = I[\hat{a}_s = a^\star] \in \{0, 1\}.$$

由此得到数据集

$$\mathcal{D} = \{(h_s, y_s)\}_{s=1}^{K}.$$

探针模型与训练：我们训练一个两层多层感知机（MLP）探针(Zhang et al., 2025)，由表征 h_s 预测逐步正确性 y_s。该探针在 1983–2024 年的 AIME 数据上训练。

B 风险控制与有限样本校正

本节详细介绍如何使用分布无关风险控制校准阈值参数。目标是选择一个信号–阈值对（或参数），使其（i）满足用户指定的风险预算 ϵ；且（ii）在所有可行候选中，使对应的效率损失最小。

B.1 问题设定

令 $\mathcal{V} = \{(x_i, y_i^*)\}_{i=1}^n$ 为带标签的验证集。对于给定的不确定性信号 $s \in \mathcal{S}$ 和阈值参数 $\lambda \in \Lambda_s$（例如，上阈值对应 $\lambda = \lambda_+$，参数化下阈值对应 $\lambda = c$），令 $\tau_i(s, \lambda)$ 表示由此确定的实例 i 的退出时刻。给定逐实例损失 $\ell(\cdot; \lambda) \in [0, 1]$（例如式 (8) 或式 (9)），总体风险为

$$\mathrm{Risk}(s, \lambda) \;=\; \mathbb{E}\big[\ell\big(y^*, f_{\tau(s,\lambda)}(x), \tilde{s}_{\tau(s,\lambda)}(x); \lambda\big)\big]\,,$$

而其在 $\mathcal{V}$ 上的经验估计为

$$\widehat{\mathrm{Risk}}(\mathcal{V}, s, \lambda) \;=\; \frac{1}{n}\sum_{i=1}^{n} \ell\big(y_i^*, f_{\tau_i(s,\lambda)}(x_i), \tilde{s}_{\tau_i(s,\lambda)}(x_i); \lambda\big)\,. \tag{22}$$

B.2 为何需要有限样本校正

由于抽样噪声，直接使用 $\widehat{\mathrm{Risk}}(\mathcal{V}, s, \lambda)$ 可能过于乐观：在 $\mathcal{V}$ 上看似可行的候选 (s, λ)，在部署后可能违反目标风险约束。当遍历大型网格 $\bigcup_{s\in\mathcal{S}} \Lambda_s$ 并选择最高效的可行配置时，这一问题会被放大，因为选择过程可能利用经验风险的随机向下波动。

为缓解这一问题，我们用保守的、经过有限样本调整的量 $\widetilde{\mathrm{Risk}}(\mathcal{V}, s, \lambda)$ 替代原始经验估计，并以 $\widetilde{\mathrm{Risk}}(\mathcal{V}, s, \lambda) \le \epsilon$ 作为可行性条件。

B.3 校准方法

我们考察两种变体，它们仅在如何施加风险约束方面有所不同。

朴素方法（Naive，不做有限样本校正）。

$$\widetilde{\mathrm{Risk}}_{\mathrm{naive}}(\mathcal{V}, s, \lambda) \;=\; \widehat{\mathrm{Risk}}(\mathcal{V}, s, \lambda). \tag{23}$$

当 n 较大时，这一基线通常有效，但不能防止对验证集的过拟合。

UCB：基于集中不等式的上置信界。 对于取值有界于 $[0, 1]$ 的损失，Hoeffding 不等式表明：对于固定的 (s, λ)，以至少 $1 - \delta$ 的概率，有

$$\mathrm{Risk}(s, \lambda) \;\le\; \widehat{\mathrm{Risk}}(\mathcal{V}, s, \lambda) \;+\; \sqrt{\frac{\log(1/\delta)}{2n}}.$$

因此，我们定义

$$\widetilde{\mathrm{Risk}}_{\mathrm{UCB}}(\mathcal{V}, s, \lambda) \;=\; \widehat{\mathrm{Risk}}(\mathcal{V}, s, \lambda) \;+\; \sqrt{\frac{\log(1/\delta)}{2n}}, \tag{24}$$

并且仅在 $\widetilde{\mathrm{Risk}}_{\mathrm{UCB}}(\mathcal{V}, s, \lambda) \le \epsilon$ 时，判定 (s, λ) 可行。在实际操作中，n 较小时校正项更大，而随着 n 增长，校正项趋于零，因此具有自适应的保守性。

实践说明（多重比较）。 式 (24) 为固定候选提供高概率界。在遍历有限网格 $\mathcal{G} = \{(s, \lambda) : s \in \mathcal{S}, \lambda \in \Lambda_s\}$ 时，可以将 δ 替换为 $\delta/|\mathcal{G}|$，通过联合界加强该界。在实验中，我们采用上述简单校正，并报告在留出的测试集上实际得到的风险。

C 假阳性保证的失效

假阳性率定义为

$$\mathrm{FPR} = \frac{I}{I + C}, \tag{25}$$

其中，I 和 C 分别表示回答错误和回答正确的问题数。

如果下阈值使我们分别对比例为 p_i 的错误样本和比例为 p_c 的正确样本弃答，那么新的假阳性率变为

$$\mathrm{FPR}_{\mathrm{new}} = \frac{(1 - p_i)I}{(1 - p_i)I + (1 - p_c)C}. \tag{26}$$

由此可知，当 $p_i < p_c$，即下阈值过滤掉的正确样本占其总量的比例高于错误样本的相应比例时，有

$$\mathrm{FPR}_{\mathrm{new}} > \mathrm{FPR}, \tag{27}$$

这意味着保证失效。反之，当 $p_i \geq p_c$ 时，保证仍然有效。

这种失效模式发生在下阈值机制本身失效时，例如校准集与测试集之间存在显著分布偏移的情况。此时，下阈值虽然可能在校准集上得到了良好校准，但在测试集上的泛化较差，导致其对正确样本的弃答比例过高。不过，值得注意的是，分布偏移往往会破坏所有保证，而不仅仅是这一项保证。我们已经加入专门的局限性章节来讨论此问题；另请参阅我们对审稿人 RnRS 的回复。（译注：关于审稿回复的这句话亦见于正式原文，现予以保留。）

在实践中，只要下阈值按预期发挥作用，即过滤掉的错误样本比例高于正确样本比例，也就是

$$p_i \geq p_c, \tag{28}$$

上阈值的保证就保持有效。

D 消融研究结果

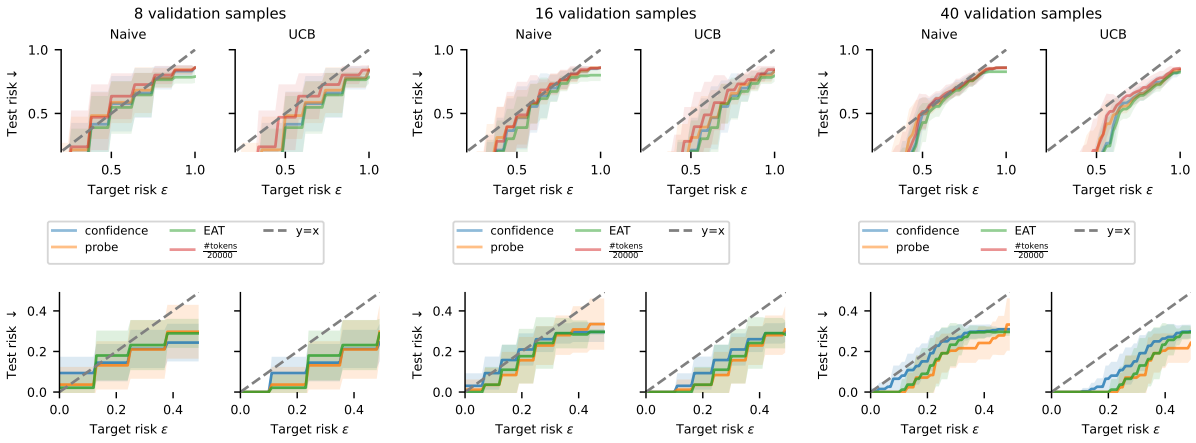


图 7: 验证集规模的消融实验。**上排：**假阳性风险；**下排：**假阴性风险。在验证集规模较小时，有理论依据的风险控制方法（UCB）比朴素交叉验证（Naive）表现出更好的风险控制能力，此外对于……（译注：原文图注在 “as well as for” 处中断，未给出后文。） 译注（图内英文）：validation samples 为验证样本，Test risk 为测试风险，Target risk 为目标风险，confidence 为置信度，probe 为探针，#tokens 为词元数。

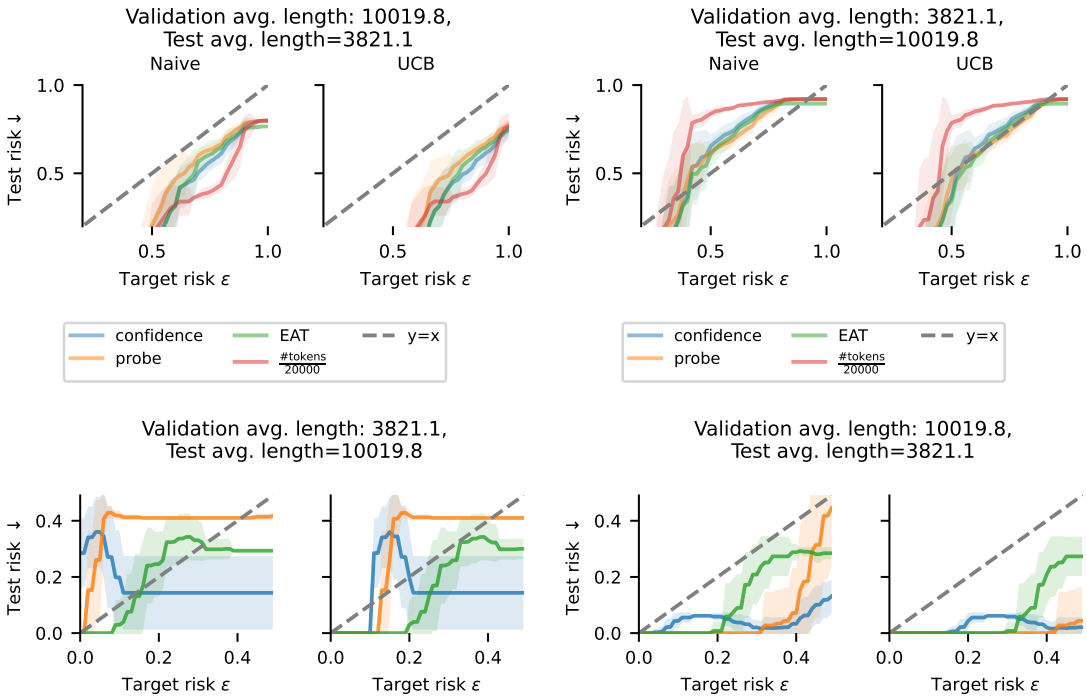


图 8: 验证集与测试集之间长度偏移的消融实验。**上排：**假阳性风险；**下排：**假阴性风险。从短到长的偏移（第一列）给风险控制带来更多挑战。对于上阈值（上排），有理论依据的风险控制缓解了除基于词元数的信号外所有信号的风险超标问题。由下阈值控制的假阴性风险对长度偏移缺乏稳健性，因为下阈值的形状依赖于推理时域。译注（图内英文）：Validation avg. length 和 Test avg. length 分别为验证集和测试集的平均长度；其余标注同图 7。

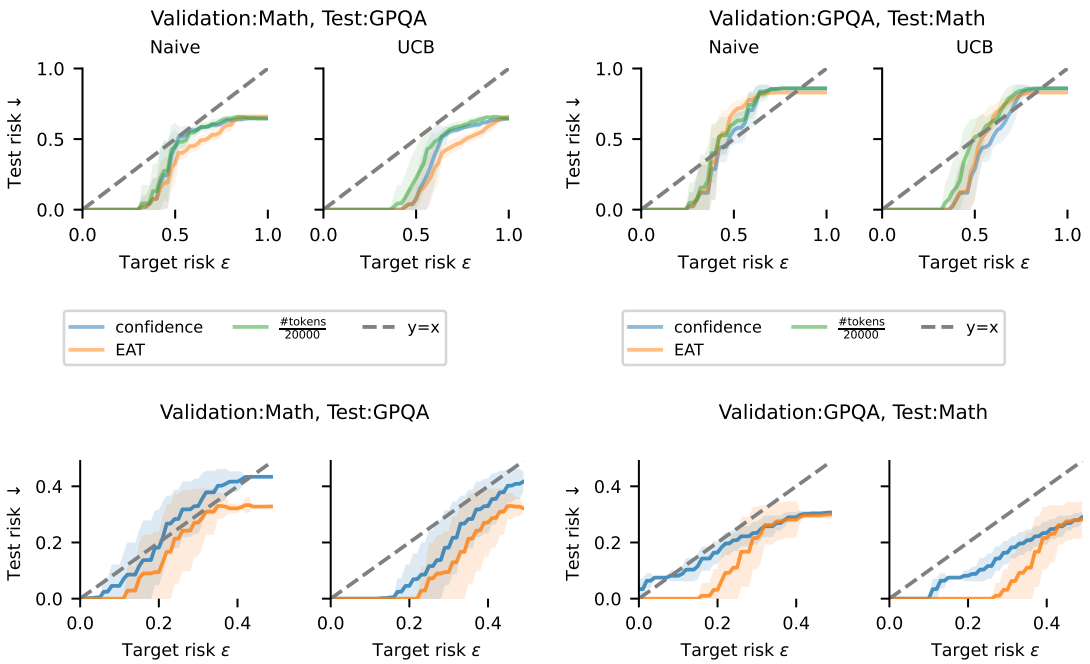


图 9: 验证集与测试集之间数据集偏移的消融实验。**上排：**假阳性风险；**下排：**假阴性风险。与此前的观察一致，采用有理论依据的风险控制，在分布偏移下仍然能够获得控制得更好的风险。译注（图内英文）：Validation 为验证集，Test 为测试集，Math 和 GPQA 为数据集名称；其余标注同图 7。