你的模型已经想得够多了

训练大型推理模型停止过度思考

Your Models Have Thought Enough:
Training Large Reasoning Models to Stop Overthinking

JET · 中文公开删节版

Jinyi Han，Ying Huang，Ying Liao，Zishang Jiang，Xikun Lu，Haiquan Zhao，Xinyi Wang，Guanghao Zhou，Sihang Jiang，Jiaqing Liang，Weikang Zhou，Zeye Sun，Fei Yu，Yanghua Xiao

华东师范大学上海智能教育研究院；复旦大学数据科学学院；复旦大学计算机科学技术学院与人工智能学院；蚂蚁集团。通讯作者：Yanghua Xiao。

版本：中文公开删节版 v1.1，2026年11月10日（北京时间）。依据arXiv:2509.23392v3，2026年3月30日，原 PDF 共 25 页。本公开版更正旧译稿封面误写的“11页”，并非原文逐页对应排版。

范围：保留摘要、方法论述、实验分析、推导、算法、数值表格及参考文献。暂不收录含逐字数据集实例的原图 2，以及末尾三个完整案例的题目和模型逐字输出。图表编号保留占位。此公开版不是全文译本。

来源：https://arxiv.org/abs/2509.23392v3
原文 PDF：https://arxiv.org/pdf/2509.23392v3
代码：https://github.com/JinyiHan99/Just-Enough-Think

许可：原论文为CC BY 4.0，https://creativecommons.org/licenses/by/4.0/。本稿为 dot 制作的非官方 AI 辅助中文翻译与排版改编，非作者审定译本；原作者、图表和研究成果归原权利人。译者说明单独标出，不冒充论文结论。翻译与排版贡献同以 CC BY 4.0 提供；改动包括翻译、重新排版、译注、上述删节及封面页数更正。

公开版范围说明

本公开版基于 arXiv:2509.23392v3 的 25 页原文，以及已有中文译稿制作。研究正文、公式推导、实验表格、统计图和作者对案例的分析保留。原图 2 与末尾三个完整案例的逐字问题、模型推理和回答暂不收录，因为这些数据集材料的独立再传播授权尚未逐项核实。未收录不表示认定原论文引用侵权。

原作者、所属机构和会议未审校或认可本译文。再次传播时须保留原作者、题名、来源及许可链接，并说明翻译与删节等改动。独立代码、模型、数据集与第三方图文仍适用各自权利。此发布包不附原文或源码。本说明不是法律意见或无侵权保证。

目录

公开版范围说明 1

阅读说明 3

摘要 3

1 引言 3

2 预备实验 4
2.1 任务定义 . . . 4
2.2 预备实验与分析 . . . 5

3 方法 5
3.1 两阶段rollout构建 . . . 5
3.2 奖励与目标设计 . . . 6
3.3 JET截断rollout的梯度分析 . . . 7

4 实验 8
4.1 实验设置 . . . 8
4.2 主要结果 . . . 10
4.3 JET的泛化分析 . . . 10
4.4 PES产生的答案多样性对训练的影响 . . . 10
4.5 JET训练中的分布一致性 . . . 10
4.6 PES的效率分析 . . . 11
4.7 长度奖励设计分析 . . . 12

5 相关工作 12

6 结论 12

A 实验细节 17

B 算法 19

C 进一步分析 19
C.1 RL训练过程中的性能演变 . . . 19
C.2 其他模型上的进一步分析 . . . 21
C.3 JET主动停止思考的分析 . . . 22
C.4 准确性与长度奖励系数的影响 . . . 22
C.5 仅奖励正确答案长度的影响 . . . 23
C.6 三种奖励策略的细节 . . . 23
C.7 课程学习对JET训练的影响 . . . 23
C.8 PES的进一步分析 . . . 23
C.9 案例研究 . . . 24

D 华为昇腾NPU平台验证 24

E LLM使用说明 25

F 完整案例文本的公开版说明 26

阅读说明

rollout译作轨迹采样／生成；token保留英文，指模型处理的词元；backbone为骨干模型；on-policy为同策略。图表中保留的短标签：ACC为准确率，Length为输出长度或该行长度变化，AVG为平均，Base为基础模型，Methods为方法，Step为训练步，Time为时间，w/o为不使用，w/为使用，Linear为线性奖励，Exp为指数衰减奖励。图表数值、模型标识及数学公式按原文保留；全图中文说明见图注。比较表Base行通常给绝对平均长度，其他行给相对变化，请结合正负号及表注阅读。

本文是研究论文的翻译，不是对所有推理主张的背书。特别是分布一致性证明、部分图引用、个别超参数与数字表述存在原文内部不一致，已在相应位置用译注说明。正负百分比和百分点不能混为一谈。

摘要

大型推理模型（LRM）在困难任务中表现突出，但深度推理通常带来大量计算成本。为实现高效推理，现有RL方法仍难在rollout阶段构造短路径，限制有效学习。受证据累积模型启发，我们发现LRM在推理早期就已积累充分信息，后续步骤可能冗余。基于这一认识，提出JET，训练模型主动停止不必要推理。JET在rollout阶段截断轨迹，使模型接触短且分布一致的路径；同时使用质量受控的长度奖励，鼓励简洁并保持正确性。大量实验表明，JET在不牺牲准确性的前提下显著提高效率。特别是在Olympiad基准上，DeepSeek-Distill-Qwen-1.5B准确率提高4.6%，输出长度减少46.3%。代码已公开。

1 引言

大型推理模型（LRM）在数学解题(Shao et al., 2024)、竞赛编程(Jiang et al., 2024)等高度结构化且复杂的推理任务上取得了显著进展。其推理过程包含细致的中间步骤、反思性的自我验证，以及对替代求解策略的探索(Min et al., 2024)。这些发展通常被视为对人类“系统2”认知过程的近似(Qu et al., 2025a; Li et al., 2025)。OpenAI o1(OpenAI, 2025)和DeepSeek-R1(Guo et al., 2025)等模型在实践中展示了这种能力。

然而，LRM的系统2式推理需要付出大量计算成本。模型经常执行超出必要数量的推理步骤，为获得正确答案消耗过多计算资源，我们将这一现象称为“过度思考”(Chen et al., 2024; Luo et al., 2025b)。这与人类认知的高效性和适应性形成鲜明对比。因此，如何维持高准确率并提高计算效率，已成为LRM的核心挑战。

为解决推理效率问题，强化学习（RL）成为一个有前景的范式(Hu et al., 2025b; Liu et al., 2025)。其核心思想是：利用额外奖励信号，引导模型生成既正确又简洁的答案。现有方法主要分为两类：（i）自适应思考模式选择，通过监督微调（SFT）使模型具备思考／不思考等多种模式，再结合思考奖励进行RL，为每道题选择合适模式(Zhang et al., 2025; Wu et al., 2025a; Huang et al., 2025a)；（ii）基于长度的优化，引入显式长度奖励，鼓励简洁推理(Team et al., 2025; Gao et al., 2025)。

有效的奖励方法依赖于让模型接触多样样本，但LRM天然偏好冗长输出，很少生成短推理轨迹。这种固有冗长性使训练数据产生偏差（图1a），导致奖励信号无法有效鼓励简洁推理(Wu et al., 2025b)。直接压缩长答案或提供外部短答案似乎是一种简单解决办法，但这会在模型自然生成分布与人工缩短样本之间引入**显著分布不匹配**，使梯度更新不稳定，并妨碍模型在自身生成过程中的学习(Huang et al., 2025b)。

要克服这些限制，需要从模型自身的长推理链中识别**短且分布一致**的推理轨迹。认知科学中的证据累积模型(Lee and Cummins, 2004)认为，人类决策是不断整合信息直至达到阈值的动态过程，阈值之后的证据主要用于支持已经作出的决策。受此启发，我们假设LRM的推理也遵循类似机制：轨迹较早部分已经包含足以确定最终答案的信息，继续生成会产生冗余推理。预备实验也支

持这一假设。

基于这一认识，我们提出“恰到好处的思考”（Just-Enough Thinking，JET），训练模型主动终止不必要的思考。JET包含两个核心部分：第一，在RL轨迹采样（rollout）阶段额外执行轨迹截断，使模型接触不同长度的推理路径，同时保持与模型自然生成过程一致；第二，引入质量受控的长度奖励，更好地引导模型提高效率。对于每个推理组，若多条轨迹得出正确答案，则以最短正确轨迹为参照，为所有正确轨迹分配长度奖励，奖励随轨迹长度增加而逐渐下降。

主要贡献如下：

- 受证据累积模型启发，我们提出JET：在rollout阶段利用轨迹截断使模型接触不同长度的推理路径，并以长度感知奖励引导高效推理。
- 实验证明，LRM在推理早期就积累了大部分必要信息。截断rollout可构建与模型自然生成分布一致的短路径，为JET训练提供依据。
- 我们提供理论分析，说明两阶段截断策略可保留有效学习信号，使策略模型能够可靠地从缩短后的轨迹中学习。
- 大量实验显示，JET显著提升复杂任务中的推理效率。例如，在Olympiad上，DeepSeek-Distill-Qwen-1.5B准确率提高4.6%，输出长度减少46.3%。模型主动停止思考的行为也能泛化到其他推理基准。

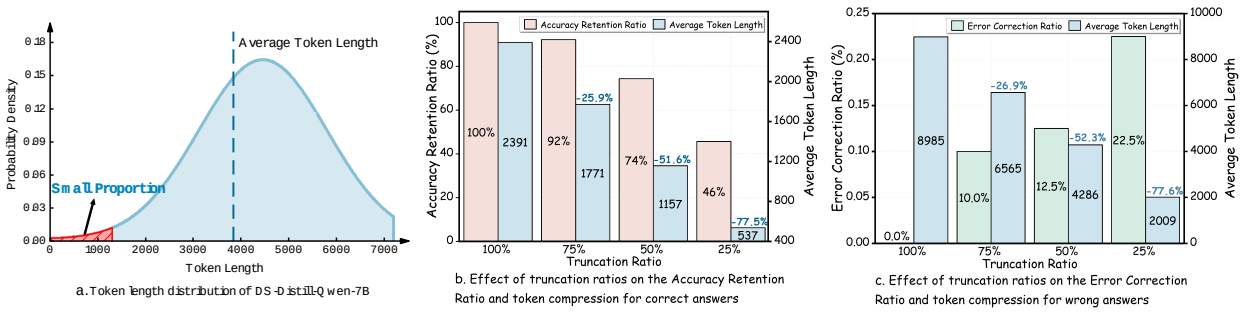


图 1: a：DeepSeek-R1-Distill-Qwen-7B对同一道数学题生成500个答案的token分布，少于1000个token的答案极少；b：在MATH500上，截断比例与准确率保持比例、token压缩比例的关系；c：对错误答案，截断比例与错误纠正率、token压缩比例的关系。

2 预备实验

LRM常生成很长的多步推理序列，但完整序列是否为得出正确答案所必需，尚不清楚。本节研究：**模型是否在初始推理步骤中就积累了足以产生正确答案的信息**。为此，我们使用DeepSeek-Distill-Qwen-7B在MATH500上进行预备实验，主要评估仅保留推理序列早期部分对答案正确性的影响。

2.1 任务定义

设M为大型推理模型。给定问题$q \in \mathcal{Q}$，模型生成中间推理状态序列$S = [s_1, s_2, \ldots, s_L]$，并给出最终答案$o_q$，其中$L$是推理步骤总长度。按照标准自回归生成范式：

$$P(S_q, o_q \mid q) = \prod_{i=1}^{L} P(s_i \mid q, s_{<i}) \cdot P(o_q \mid q, S_q). \tag{1}$$

将完整序列的前$\lfloor TL \rfloor$个中间推理步骤定义为**截断推理序列**$S_q^{(T)} = [s_1, \ldots, s_{\lfloor TL \rfloor}]$，其中$T \in [0, 1)$。在截断点插入强制**停止思考信号**$z_{\text{stop}}$，要求模型停止思考，并根据已有中间步骤产生最终答案$\hat{A}^{(T)}$:

$$\hat{o}_q^{(T)} \sim P(o_q \mid q, S_q^{(T)}, z_{\text{stop}}). \tag{2}$$

我们使用三个互补指标量化截断后的正确性与效率。

准确率保持比例（ARR）：原先回答正确的问题中，截断后仍正确的比例。令$\mathcal{Q}_{\text{correct}} = \{q \in \mathcal{Q} \mid o_q = o_q^*\}$表示完整推理下答对的问题集，$o_q^*$为标准答案，则

$$\text{ARR}(T) = \frac{1}{|\mathcal{Q}_{\text{correct}}|} \sum_{q \in \mathcal{Q}_{\text{correct}}} \mathbb{I}(\hat{o}_q^{(T)} = o_q^*). \tag{3}$$

错误纠正率（ECR）：最初回答错误的问题中，截断后变为正确的比例。令$\mathcal{Q}_{\text{incorrect}} = \{q \in \mathcal{Q} \mid o_q \neq o_q^*\}$为完整推理下答错的问题集，则

$$\text{ECR}(T) = \frac{1}{|\mathcal{Q}_{\text{incorrect}}|} \sum_{\bar{q} \in \mathcal{Q}_{\text{incorrect}}} \mathbb{I}(\hat{o}_{\bar{q}}^{(T)} = o_q^*), \tag{4}$$

其中$\hat{o}_{\bar{q}}^{(T)}$是截断推理后的答案。[1]

长度压缩比例（LCR）：只依靠截断前缀生成最终答案时，推理token数量的减少比例:

$$\text{LCR}(T) = 1 - \frac{|S_q^{(T)}|}{|S_q|}. \tag{5}$$

2.2 预备实验与分析

首先让模型生成完整推理轨迹和最终答案，建立基线；随后只保留原链的前75%、50%或25%，并插入停止思考提示，例如“等等，我已经有足够信息得到最终答案。因此，最终答案是……”（见图2左侧），引导模型根据部分推理给出最终答案，并评估其表现。

即使移除推理链的大部分内容，LRM仍能保持大部分准确性。图1b显示，保留前75%推理时，原先正确答案中超过90%仍正确；只使用前一半时，约四分之三仍正确；即使仅使用四分之一，也保留了近一半的原先正确解。这说明关键解题信息在早期积累，后续步骤对正确性的贡献较小。

此外，截断可将一些原先错误的答案变为正确答案，从而缓解“过度思考”。图1c显示，随着推理链逐步缩短，原先错误答案中被纠正的比例提高。冗余或过量推理有时会误导LRM，适当限制推理过程可提高整体答案准确率。

截断还显著减少token消耗。完整推理平均每题约2391个token。只保留前三分之四，token消耗约减少25%，准确率几乎没有损失。即使仅使用推理链的前25%，token使用量也降至原先的约75%。虽然此时准确率下降，但模型仍能以显著更低的计算成本获得合理表现。[2]

要点

LRM在推理早期积累了大部分关键解题信息，因此可以在显著减少推理token的同时保持较高准确性。

3 方法

基于LRM在推理早期积累大部分解题信息的观察，我们提出基于DAPO(Yu et al., 2025)的强化学习方法JET。它训练模型在获得充分信息后停止推理，使答案准确、推理简洁。

[1]译注：此式保留原文记号，求和变量为$\bar{q}$，标准答案下标应相应理解为$\bar{q}$；ARR原式多余的右括号已作纯排版修正。

[2]译注：原文确实写为“降至原先约75%”，而非“减少约75%”；与截断比例之间存在表述疑点，此处忠实保留，读者应结合原图核对，不能将两种说法混用。

3.1 两阶段rollout构建

为使模型接触多样推理行为并促进高效策略学习，我们提出图2所示的两阶段rollout策略，同时生成完整与截断推理轨迹，在RL中平衡正确性与简洁性。

阶段1：完整推理 模型通过标准自回归过程生成完整推理轨迹。它们包含所有中间步骤及最终答案，为自然推理行为提供完整参照，既是下一阶段构造截断轨迹的基础，也为RL rollout提供多样推理路径。

阶段2：轨迹截断 在阶段1的完整轨迹上，于不同中间步骤截断，构造较短路径。每个截断点都插入显式停止思考提示，要求模型立即给出结论，而不继续推理。这样在引入多样提前停止路径的同时，保持截断轨迹与模型生成分布一致。

确定截断位置。最优截断点不易确定：过早截断可能答错，过晚则保留冗余步骤；穷举搜索成本高，会降低RL效率。因此，我们提出渐进式提前停止（Progressive Early-Stopping, PES），沿每条完整轨迹构造一系列截断变体：

$$t_k = t_0 + k\Delta t, \qquad k = 0, 1, \ldots, K. \tag{6}$$

其中t_0为初始截断位置，Δt是预设步长或分位数间隔，K控制截断次数。在每个t_k处，显式停止思考提示要求模型立即输出最终答案。

该渐进策略：（i）保持与模型自身生成分布一致；（ii）提高捕捉最优或近最优截断点t^*的可能性；（iii）提供多样的提前停止轨迹，引导模型学会何时有效终止推理。 两阶段共同生成多样

原图含逐字数据集实例，公开版暂不收录。

图 2: 原图 2 的公开版占位。原图展示截断实例与两阶段轨迹采样流程；逐字实例及原图暂不收录。

轨迹，引导策略在不牺牲准确性的前提下高效推理。完整轨迹提供全面覆盖，截断轨迹鼓励简洁推理，从而平衡正确性与简洁性。

3.2 奖励与目标设计

奖励系统是RL训练的另一个关键组成，用于引导期望行为。我们使用两类奖励：鼓励正确且格式规范答案的基础奖励，以及鼓励简洁推理的长度奖励。

基础奖励。遵循标准RL实践，基础奖励结合格式奖励r_f与正确性奖励r_{acc}。$r_f \in \{0, 1\}$要求最终答案置于`\boxed{}`中；$r_{acc} \in \{0, 1\}$通过与标准答案进行精确字符串匹配来评价正确性。

长度奖励。为鼓励简洁且正确的推理，我们设计以正确性为条件的长度奖励，遵循以下原则：

- **正确性优先：**只有正确回答有资格获得长度奖励，使准确性保持为首要目标。
- **偏好简洁：**正确回答中，较短路径获得更高奖励。
- **逐题归一化：**根据同一道题最短与最长正确答案计算相对奖励，避免不同题目长度分布造成偏差。

形式化地，令$\mathcal{C} = \{i \mid r_{acc}(i) = 1\}$为某题正确回答的索引集，$\ell_{\min} = \min_{j\in\mathcal{C}} \ell_j$与$\ell_{\max} = \max_{j\in\mathcal{C}} \ell_j$分别为最短和最长正确答案长度。回答$i$的长度奖励为

$$r_\ell(i) = \begin{cases} \dfrac{\ell_{\max} - \ell_i}{\ell_{\max} - \ell_{\min} + \varepsilon}\, \alpha(1-\delta) + \delta, & i \in \mathcal{C}, \\ 0, & i \notin \mathcal{C}. \end{cases} \tag{7}$$

α控制奖励随长度衰减的速率，$\delta \in (0,1)$设置正确答案的最低奖励，$\varepsilon > 0$防止所有正确回答等长时除零。

总奖励。将正确性、格式与简洁性相结合，引导准确、规范且简洁的推理：

$$R(i) = w_f r_f(i) + w_{acc} r_{acc}(i) + w_\ell r_\ell(i). \tag{8}$$

三项分别为格式、正确性和长度奖励，权重w_f, w_{acc}, w_ℓ均非负，用于平衡各项贡献。组合后，模型不仅产生正确答案，也保持适当格式并偏好简洁路径。

训练目标。原始DAPO针对每个输入q及其答案A采样G个输出$\{o_i\}_{i=1}^{G}$，优化目标为

$$\begin{aligned}\mathcal{J}_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a)\sim\mathcal{D},\{o_i\}\sim\pi_{\theta_{old}}}\Bigg[\frac{1}{\sum_{i=1}^{G}|o_i|}\sum_{i=1}^{G}\sum_{t=1}^{|o_i|}\min\Big(r_{i,t}(\theta)\hat{A}_{i,t},\\ \text{clip}(r_{i,t}(\theta), 1-\varepsilon_{low}, 1+\varepsilon_{high})\hat{A}_{i,t}\Big)\Bigg].\end{aligned} \tag{9}$$

其中重要性采样比为

$$r_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t} \mid q, o_{i,<t})}, \qquad \hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^{G})}{\text{std}(\{R_i\}_{i=1}^{G})}.$$

标准DAPO只在完整推理轨迹上计算损失，JET则同时纳入完整轨迹与“截断后补全”的轨迹。把后者加入目标，可让策略学会在信息充分时停止推理，输出正确且简洁的答案。完整算法见算法1。

3.3 JET截断rollout的梯度分析

JET在截断处追加短停止思考句及最终答案。原文认为，该操作不会造成显著的序列概率分布不连续，因而保持RL更新稳定。下面在DAPO目标（式9）下分析其影响。

考虑轨迹$\hat{o}_i^{(\mathcal{T})} = \{o_{i,1}, \ldots, o_{i,\mathcal{T}+m}\}$，前$\mathcal{T}$个token来自旧策略$\pi_{\theta_{old}}$，后$m$个token为

$$\{\varphi_{\mathcal{T}+1}, \ldots, \varphi_{\mathcal{T}+m}\},$$

组成强制后缀，且$m \ll \mathcal{T}$。当前策略下的完整轨迹对数概率可自回归分解为

$$\log \pi_\theta(\hat{o}_i) = \sum_{t=1}^{\mathcal{T}} \log \pi_\theta(o_{i,t} \mid o_{i,1:t-1}) + \sum_{t=\mathcal{T}+1}^{\mathcal{T}+m} \log \pi_\theta(\varphi_t \mid o_{i,1:t-1}). \tag{10}$$

等价地，

$$\pi_\theta(\hat{o}_i) = \pi_\theta(o_{i,1:\mathcal{T}})C, \qquad C = \prod_{t=\mathcal{T}+1}^{\mathcal{T}+m} \pi_\theta(\varphi_t \mid o_{i,1:t-1}). \tag{11}$$

由于$m \ll \mathcal{T}$，原文认为后缀因子C对整体轨迹概率的贡献可忽略。

RL更新稳定性依赖token级重要性比$r_{i,t}(\theta)$。对于从旧策略采样的前缀token（$t \le \mathcal{T}$），信赖域约束保证$\pi_\theta \approx \pi_{\theta_{old}}$，因此$r_{i,t}(\theta) \approx 1$，并处于裁剪边界内。对于强制后缀token（$t > \mathcal{T}$），虽然策略可能赋予不同概率，但影响受到限制，因为：（i）重要性比被裁剪，防止极端更新；（ii）其总数m较小。

因此，假设强制后缀在旧策略下的概率不可忽略，则序列级重要性比满足

$$\frac{\pi_\theta(\hat{o}_i)}{\pi_{\theta_{old}}(\hat{o}_i)} = \prod_{t=1}^{\mathcal{T}} r_{i,t}(\theta) \prod_{t=\mathcal{T}+1}^{\mathcal{T}+m} r_{i,t}(\theta) \approx 1. \tag{12}$$

原文由此认为，追加短强制后缀可保持序列级分布，并保证信赖域内策略更新稳定。

译者说明：理论论证的适用边界

以上为作者论证，而非无条件保证。仅由$m \ll T$不能推出概率乘积C的影响可忽略；多个接近1的token比相乘也未必接近1。PPO／DAPO目标裁剪不等于对每个token概率比施加硬性信赖域约束。这里的结论需要额外假设，应与实验观察分开理解。

4 实验

4.1 实验设置

模型。选用具有代表性且广泛使用的DeepSeek-R1-Distill-Qwen-7B和1.5B(DeepSeek-AI et al., 2025)作为骨干模型。

数据集。（i）训练数据：合并MATH与DAPO-MATH[3]构建难度混合数据集，删除所有中文题后得到14564个样本。（ii）测试数据：使用多样基准评估域内及域外表现。域内数学推理采用不同难度的AIME2024[4]、MATH500(Lightman et al., 2023)、GSM8K(Cobbe et al., 2021)、AMC[5]和Olympiad(He et al., 2024)。域外泛化采用GPQA-Diamond、CommonsenseQA，以及通过每个科目采样2000道题构建的MMLU子集。为保证统计稳健性，AIME2024与AMC上的全部实验各独立重复10次。[6]

指标。使用四个指标：准确率（Acc）衡量正确性，输出长度（Length）衡量简洁性，准确率变化Δacc跟踪性能变化，token压缩比例（式5）衡量效率。 **基线**。除骨干模型外，还比较：

表 1: 不同方法在其他推理任务上的泛化能力。ACC括号内为相对Base的准确率变化；Length为相对Base的token压缩比例（百分比）。

	Methods	CSQA		GPQA-Diamond		MMLU		AVG	
		ACC	Length	ACC	Length	ACC	Length	ACC	Length
DS-Qwen-1.5B	Base	44.2	787	32.3	5619	43.8	1306	40.1	1370
	SFT	47.0 (+2.8)	740 (-6.0)	34.9 (+2.6)	5288 (-5.9)	44.7 (+0.1)	1122 (-14.1)	42.2 (+2.1)	1227 (-8.7)
	DPO	44.6 (+0.4)	690 (-12.3)	30.3 (-2.0)	5283 (-6.0)	44.5 (+0.7)	1143 (-12.5)	39.8 (-0.3)	1221 (-10.3)
	DAPO	45.6 (+1.4)	479 (-39.1)	37.9 (+5.6)	4591 (-18.3)	46.5 (+1.8)	856 (-34.4)	43.3 (+3.2)	938 (-30.6)
	AdaptThink	48.0 (+3.8)	887 (+12.7)	32.3 (+0.0)	4601 (-18.1)	44.5 (-2.0)	1224 (-6.3)	41.6 (+1.5)	1299 (-3.9)
	Laser-D	47.1 (+2.9)	685 (-13.0)	34.3 (+2.0)	5352 (-4.8)	47.2 (+3.4)	1143 (-12.5)	42.9 (+2.8)	1223 (-10.1)
	Laser-DE	47.8 (+3.6)	685 (-13.0)	33.8 (+1.5)	5575 (-0.8)	46.2 (+2.4)	1217 (-6.8)	42.6 (+2.5)	1279 (-6.9)
	LCR1	44.3 (+0.1)	431 (-45.2)	33.8 (+1.5)	3678 (-34.5)	42.7 (-1.1)	744 (-43.0)	40.3 (+0.2)	**802** (-40.9)
	JET	45.6 (+1.4)	407 (-48.3)	43.4 (+11.1)	4182 (-25.6)	44.6 (+0.8)	715 (-45.3)	**44.5** (+4.4)	806 (-39.7)
DS-Qwen-7B	Base	63.7	631	47.5	6359	60.1	1022	57.1	1191
	SFT	65.4 (+1.7)	593 (-6.0)	45.5 (-2.1)	5418 (-14.8)	60.2 (+0.1)	1044 (+2.2)	57.0 (-0.1)	1136 (-6.2)
	DPO	65.9 (+2.2)	586 (-7.1)	49.0 (+1.5)	5519 (-13.2)	60.1 (+0.0)	947 (-7.3)	58.3 (+1.2)	1083 (-9.2)
	DAPO	65.7 (+2.0)	519 (-17.7)	51.0 (+3.5)	5485 (-13.7)	58.9 (-1.3)	907 (-11.3)	58.5 (+1.4)	1034 (-14.3)
	AdaptThink	65.9 (+2.2)	536 (-15.1)	44.4 (-3.1)	4820 (-24.2)	57.3 (-2.8)	840 (-17.8)	55.9 (-2.6)	962 (-19.0)
	Laser-D	65.8 (+2.1)	600 (-4.9)	51.0 (+3.5)	4417 (-30.5)	62.3 (+2.2)	1059 (+3.6)	59.7(+2.6)	1090 (-10.6)
	Laser-DE	64.8 (+1.1)	553 (-12.4)	46.5 (-1.0)	3884 (-38.9)	63.4 (+3.3)	1027 (+0.5)	58.2 (+1.1)	1023 (-16.9)
	LCR1	65.0 (+1.3)	404 (-36.0)	50.0 (+2.5)	3429 (-46.1)	56.5 (-3.6)	611 (-40.2)	57.2 (+0.1)	**700** (-40.8)
	JET	66.4 (+2.7)	531 (-15.8)	52.5 (+5.0)	5530 (-13.0)	63.9 (+3.8)	860 (-15.9)	**60.9** (+3.8)	1013 (-14.9)

（1）**SFT**：遵循OVERTHINK(Chen et al., 2024)，以本方法rollout阶段生成的最短正确答案构建训练集并微调；（2）**DPO**：将最短正确答案标为偏好回答、最长答案标为拒绝回答，构建偏

[3] https://huggingface.co/datasets/BytedTsinghua-SIA/DAPO-Math-17k
[4] https://huggingface.co/datasets/math-ai/aime24
[5] https://huggingface.co/datasets/AI-MO/aimo-validation-amc
[6] 译注：“MMLU每个科目2000题”为原文说法；原文未进一步解释抽样口径，此处不替作者修正。

好数据集；（3）**DAPO**：类似R1，用于增强推理能力的常用RL算法；（4）**AdaptThink（AdaThink）**(Zhang et al., 2025)：教会模型何时思考或不思考来回答查询；（5）**IC-R1**（原文引文缺失）：基于GRPO，剪除无效步骤以提高效率；（6）**Laser**（原文引文缺失）：基于RL，以目标序列长度的阶跃函数奖励促进效率。详细设置与超参数见附录A。[7]

[7]译注：原文不同位置出现IC-R1、LCR1等拼写，保留各处标注，勿据此推断为不同方法。

表 2: 各方法在不同数学任务上的表现。ACC括号内为相对Base的准确率变化；Length为相对Base的token压缩比例（百分比）。

Methods	GSM8K		MATH500		AIME24		AMC		Olympiad		AVG	
	ACC	Length	ACC	Length	ACC	Length	ACC	Length	ACC	Length	ACC	Length
DeepSeek-Distill-Qwen-1.5B												
Base	76.0	468	79.6	3617	28.7	11046	63.3	7644	47.0	7679	58.9	4765
SFT	81.4 (+5.4)	559 (+19.4)	78.8 (-0.8)	2591 (-28.4)	27.7 (-1.0)	9139 (-17.3)	57.2 (-6.1)	5394 (-29.4)	42.5 (-4.5)	5532 (-28.0)	57.5 (-1.4)	3583 (-16.7)
DPO	80.2 (+4.2)	530 (+13.2)	78.6 (-1.0)	2652 (-26.7)	24.0 (-4.7)	9966 (-9.8)	59.0 (-4.3)	5482 (-28.3)	44.0 (-3.0)	5929 (-22.8)	57.2 (-1.7)	3744 (-14.9)
DAPO	80.0 (+4.0)	826 (+76.5)	85.8 (+6.2)	3106 (-14.1)	26.7 (-2.0)	8583 (-22.3)	66.3 (+3.0)	5666 (-25.9)	46.6 (-0.4)	5822 (-24.2)	61.1 (+2.1)	3822 (-2.0)
AdaThink	82.0 (+6.0)	772 (+65.0)	79.6 (+0.0)	1905 (-47.3)	23.7 (-5.0)	7434 (-32.7)	58.7 (-4.6)	3983 (-47.9)	49.8 (+2.8)	4706 (-38.7)	58.8 (-0.2)	2948 (-20.3)
Laser-D	84.9 (+8.9)	1073 (+129.3)	85.2 (+5.6)	2424 (-33.0)	30.0 (+1.3)	7271 (-34.2)	65.8 (+2.5)	4355 (-43.0)	53.2 (+6.2)	4813 (-37.3)	**63.8**(+4.9)	3221 (-3.6)
Laser-DE	84.1 (+8.1)	1179 (+151.9)	84.2 (+4.6)	2798 (-22.6)	29.7 (+1.0)	7960 (-27.9)	65.2 (+1.9)	5018 (-34.4)	50.5 (+3.5)	5265 (-31.4)	62.7 (+3.8)	3604 (+7.1)
LCR1	75.0 (-1.0)	443 (-5.3)	77.6 (-2.0)	1851 (-48.8)	19.0 (-9.7)	7155 (-35.2)	56.4 (-6.9)	3897 (-49.0)	44.0 (-3.0)	4193 (-45.4)	54.4 (-4.5)	**2682**(-36.8)
JET	83.8 (+7.8)	605 (+29.3)	83.0 (+3.4)	2072 (-42.7)	32.0 (+3.3)	6641 (-39.9)	66.1 (+2.8)	3872 (-49.3)	51.6 (+4.6)	4121 (-46.3)	63.3 (+4.4)	2710 (-29.8)
DeepSeek-Distill-Qwen-7B												
Base	87.0	469	92.0	2918	51.3	9812	78.9	6013	63.1	6782	74.5	4026
SFT	87.3 (+0.3)	438 (-6.6)	91.4 (-0.6)	2568 (-12.0)	48.7 (-2.6)	9814 (+0.0)	78.6 (-0.3)	5836 (-2.9)	62.7 (-0.4)	6441 (-5.0)	73.7 (-0.7)	3862 (-5.3)
DPO	86.1 (-0.9)	438 (-6.6)	90.0 (-2.0)	2590 (-11.2)	53.0 (+1.7)	9552 (-2.6)	77.2 (-1.7)	5797 (-3.6)	60.4 (-2.7)	6465 (-4.7)	73.4 (-1.1)	3839 (-5.8)
DAPO	90.1 (+3.1)	583 (+24.3)	91.6 (-0.4)	2720 (-6.8)	53.3 (+2.0)	8414 (-14.2)	81.7 (+2.8)	4903 (-18.5)	63.4 (+0.3)	5361 (-21.0)	76.0 (+1.5)	3405 (-7.2)
AdaThink	88.9 (+1.9)	304 (-35.2)	87.8 (-4.2)	1325 (-54.6)	50.7 (-0.6)	8131 (-17.1)	77.2 (-1.7)	3871 (-35.6)	61.3 (-1.8)	4656 (-31.3)	73.2 (-1.3)	2720 (-34.8)
Laser-D	91.6 (+4.6)	965 (+105.8)	92.0 (+0.0)	1950 (-33.2)	52.7 (+1.4)	6361 (-35.2)	82.8 (+3.9)	3505 (-41.7)	64.7 (+1.6)	3755 (-44.6)	76.8 (+2.3)	2649 (-9.8)
Laser-DE	91.5 (+4.5)	948 (+102.1)	92.4 (+0.4)	1942 (-33.4)	53.0 (+1.7)	5809 (-40.8)	82.9 (+4.0)	3357 (-44.2)	64.6 (+1.5)	3713 (-45.3)	**76.9** (+2.4)	2554 (-12.3)
LCR1	86.0 (-1.0)	386 (-17.7)	87.6 (-4.4)	1313 (-55.0)	50.0 (-1.3)	6329 (-35.5)	76.5 (-2.4)	3173 (-47.2)	59.1 (-4.0)	3575 (-47.3)	71.8 (-2.6)	**2238** (-40.5)
JET	86.1 (-0.9)	324 (-30.9)	91.2 (-0.8)	2091 (-28.3)	54.0 (+2.7)	7981 (-18.7)	81.0 (+2.1)	4301 (-28.5)	63.9 (+0.8)	5083 (-25.1)	75.2 (+0.8)	2999 (-26.3)

arXiv 2509.23392v3

4.2 主要结果

JET显著缩短输出，同时不牺牲准确性，显示出较高效率。LCR1等方法压缩幅度更大，但损害准确率。例如7B模型在MATH500上的长度减少超过50%，准确率却下降4.4个百分点，偏离高效推理目标。JET则持续大幅缩短输出，1.5B模型平均减少39.7%，同时在各任务保持甚至提高准确率，取得更有利的效率与准确性权衡。

JET在高难数学推理上表现突出。在AIME24和AMC等竞赛基准上，7B模型准确率分别达到54.0（较Base增加2.7）和81.0（增加2.1）。这表明JET能够捕捉关键推理步骤、减少冗余计算并提高解答质量，输出也比其他方法更短。

JET在简单任务上也有明显优势。Laser在部分任务上表现相近，但面对简单问题仍可能生成不必要的长推理。例如GSM8K的token使用量增加105.8%，说明其动态难度感知机制未能有效适应任务难度。相比之下，JET在不同难度下保持准确性与输出长度的平衡。

JET在不同规模和模型家族中保持稳定表现。以DeepSeek-R1-Distill-Llama-8B进一步测试（表3），域内准确率提高2个百分点，token使用减少31%，说明策略稳健且能泛化到不同规模模型。

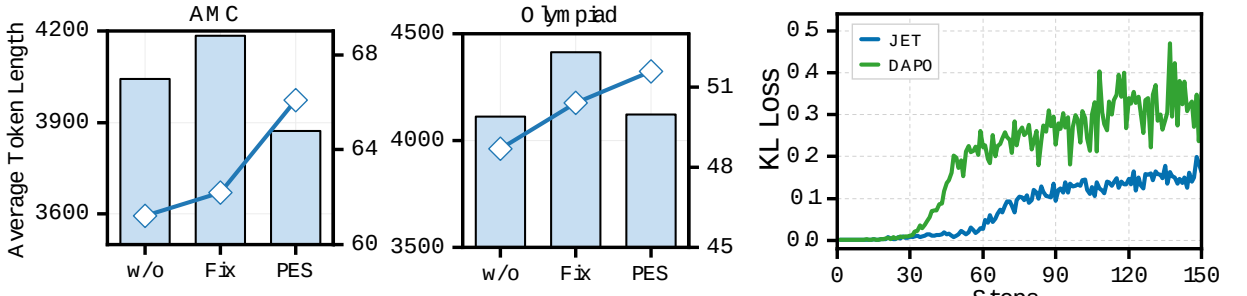
4.3 JET的泛化分析

JET在不同领域、不同难度的常识推理任务中展现稳健泛化，说明有效性源于优化了与领域无关的推理框架，而非偶然因素。虽然最初面向数学，JET在CSQA（常识判断）、GPQA（专业推理）及MMLU（多学科评估）上均有较强表现。

最大提升来自高难GPQA-Diamond，凸显**处理复杂语义结构的能力**。7B模型提升5.0，明显优于其他方法；1.5B模型提升更达11.1。作者认为，这说明JET增强了深层推理结构建模，而非依靠表面模式匹配，并能在陌生领域保持较高表现。

4.4 PES产生的答案多样性对训练的影响

比较PES、固定位置截断（Fix）和不提前停止的完整推理（w/o PES），结果见图3，补充分析见附录C.8。PES通过生成不同长度的路径，让模型接触不同策略并学会何时提前停止有益，从而提高准确性和效率。相反，w/o PES容易在长序列中积累错误，Fix无法适应问题复杂度。



a. Performance of different rollout strategies during RL training on AMC and Olympiad

b. Evolution of KL loss throughout RL training

图 3: a：RL训练中不同rollout策略的表现。b：使用DS-Distill-Qwen-1.5B时，训练过程中的KL损失变化。

4.5 JET训练中的分布一致性

以DS-Qwen-1.5B为骨干，与DAPO比较训练中的KL散度动态，研究JET是否保留模型原生概率分布。原文引用图5，称JET在整个训练中维持较低KL，表明截断策略未引入分布扭曲；即使推理被

截断，仍保持序列级概率结构，不偏离原始输出分布，使RL稳定。[8]

4.6 PES的效率分析

PES取得显著计算效率提升。它不搜索最优截断点，而以简单有效的渐进策略近似最优推理长度。截断完整轨迹降低rollout开销；较短轨迹需要更少前向传播，并加快梯度计算，从而加速RL。图4显示，相比生成完整推理链的基线，rollout生成与策略优化最高可加速5倍。

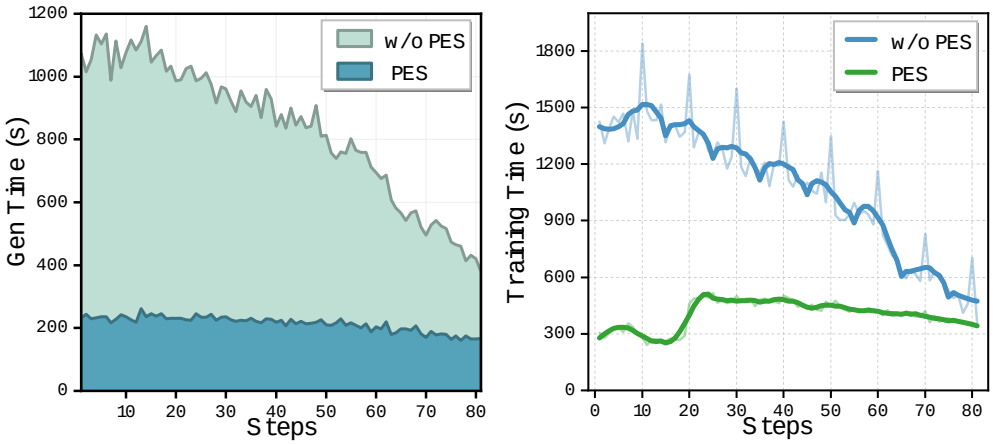


图 4: 有无PES时的rollout生成时间与RL训练时间对比。PES通过较短轨迹加速RL训练。

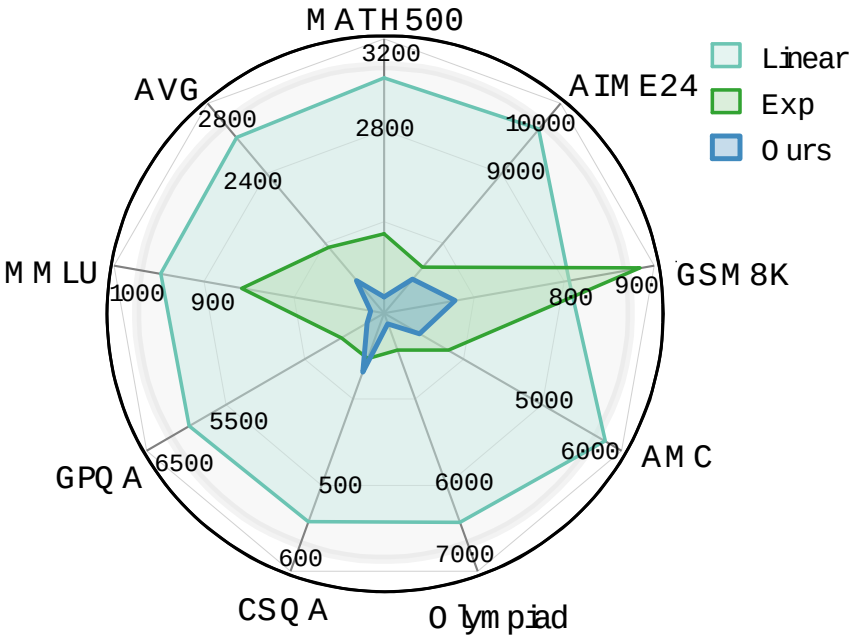


图 5: JET采用不同长度奖励策略时，在九个基准上的平均输出token长度（原图题写“三种”，正文还列有Sigmoid；保留原图）。

[8]译注：此处原文图引用疑有误，KL曲线实际位于图3。更低的KL仅是相对比较证据，并不能单独证明“无分布扭曲”。

4.7 长度奖励设计分析

将本方法的长度奖励与线性（Linear）、指数衰减（Exp）及Sigmoid(Arora and Zanette, 2025)三种替代方式比较。线性奖励按推理长度成比例赋分；指数衰减更强烈惩罚长输出；Sigmoid提供平滑过渡，适度惩罚中等长度并强烈抑制很长推理。公式及补充分析见附录C.6，结果见图5。在八个数据集上，加权线性奖励有效缩短推理；它在鼓励更短输出的同时保证最低奖励，从而保留必要步骤并移除冗余，在准确性和效率之间取得较好平衡（表4）。

5 相关工作

增强LLM深度思考能力。与LLM快速、启发式驱动的行为不同，慢思考推理系统通过审慎、分析性的推理增强能力(Snell et al., 2024)。这些方法使用测试时扩展，使模型在回答困难问题前投入更多计算和时间(Muennighoff et al., 2025b)。强化学习已成为后训练阶段建立强推理能力的主要技术。OpenAI o1(Jaech et al., 2024)是首次大规模将RL用于深度推理的模型，在复杂任务上表现出色。随后，DeepSeek-R1(DeepSeek-AI et al., 2025)成为首个达到o1表现的开源模型，使更多研究者能够使用相关技术。这推动了Gemini2.5(Comanici et al., 2025)、QwQ(Team, 2025)和Phi-4(Abdin et al., 2024)等长推理模型的发展。近期工作显示，采用可验证奖励的RL（RLVR）(Chu et al., 2025; Betley et al., 2025)可显著提升高难推理任务表现，尤其是数学和编程(Shao et al., 2024; Hu et al., 2025a)。

高效推理。详细推理常带来更多正确答案，但LRM冗余思考显著增加推理时间和计算成本，即“过度思考”(Sui et al., 2025; Feng et al., 2025)。现有工作从不同角度提升效率。一类设置固定token预算，通过显式token限制控制推理长度(Muennighoff et al., 2025a; Sun et al., 2025; Aggarwal and Welleck, 2025; Anthropic, 2025)，例如CoT-Valve(Ma et al., 2025)与L1(Aggarwal and Welleck, 2025)；但不同难度问题的合适预算不易选择。另一类教会模型按题目难度调整长度，如Adar1(Luo et al., 2025a)和DAST(Shen et al., 2025)构建偏好数据集，让模型自行决定每个查询采用“思考”还是“不思考”模式(Lou et al., 2025; Zhang et al., 2025; Bai et al., 2023)。还有越来越多工作探索RL高效推理：O1-Pruner(Luo et al., 2025b; Qu et al., 2025b; Dai et al., 2025)、ThinkPrune(Hou et al., 2025)和Kimi(Team et al., 2025)在奖励函数中加入长度惩罚，鼓励简洁且准确的推理。

6 结论

本文提出JET，训练LRM主动终止不必要推理，实现高效推理。JET针对RL中很少出现短推理路径而导致样本偏差的问题。人工构造的短答案常偏离自然概率分布，妨碍有效学习。受证据累积模型启发，我们设计两阶段rollout，其中通过轨迹截断构造与自然分布一致的短路径，使模型针对同题观察长度和正确性不同的多条路径。再引入质量受控的长度奖励，引导更高效的推理。两个代表性LRM上的实验表明，JET能在不牺牲准确性的前提下显著缩短输出，且效率优势有效泛化到其他推理任务。

参考文献（保留原文书目信息）

Marah Abdin, Jyoti Aneja, Harkirat Behl, Sébastien Bubeck, Ronen Eldan, and 1 others. 2024. Phi-4 technical report. Preprint, arXiv:2412.08905.

Pranjal Aggarwal and Sean Welleck. 2025. L1: Controlling how long a reasoning model thinks with reinforcement learning. arXiv preprint arXiv:2503.04697.

Anthropic. 2025. Building with extended thinking.

Daman Arora and Andrea Zanette. 2025. Training language models to reason efficiently. Preprint, arXiv:2502.04463.

Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, and 1 others. 2023. Qwen technical report. arXiv preprint arXiv:2309.16609.

Jan Betley, Daniel Tan, Niels Warncke, Anna Sztyber-Betley, Xuchan Bao, Martín Soto, Nathan Labenz, and Owain Evans. 2025. Emergent misalignment: Narrow finetuning can produce broadly misaligned llms. arXiv preprint arXiv:2502.17424.

Hanting Chen, Yasheng Wang, Kai Han, Dong Li, Lin Li, Zhenni Bi, Jinpeng Li, Haoyu Wang, Fei Mi, Mingjian Zhu, and 1 others. 2025. Pangu embedded: An efficient dual-system llm reasoner with metacognition. arXiv preprint arXiv:2505.22375.

Xingyu Chen, Jiahao Xu, Tian Liang, Zhiwei He, Jianhui Pang, Dian Yu, Linfeng Song, Qiuzhi Liu, Mengfei Zhou, Zhuosheng Zhang, and 1 others. 2024. Do not think that much for 2+ 3=? on the overthinking of o1-like llms. arXiv preprint arXiv:2412.21187.

Tianzhe Chu, Yuexiang Zhai, Jihan Yang, Shengbang Tong, Saining Xie, Dale Schuurmans, and 1 others. 2025. Sft memorizes, rl generalizes: A comparative study of foundation model post-training. Preprint, arXiv:2501.17161.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, and 1 others. 2021. Training verifiers to solve math word problems. arXiv preprint arXiv:2110.14168.

Gheorghe Comanici, Eric Bieber, Mike Schaekermann, Ice Pasupat, Noveen Sachdeva, Inderjit Dhillon, Marcel Blistein, Ori Ram, Dan Zhang, Evan Rosen, and 1 others. 2025. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. arXiv preprint arXiv:2507.06261.

Muzhi Dai, Chenxu Yang, and Qingyi Si. 2025. S-grpo: Early exit via reinforcement learning in reasoning models. arXiv preprint arXiv:2505.07686.

DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, and 1 others. 2025. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. Preprint, arXiv:2501.12948.

Sicheng Feng, Gongfan Fang, Xinyin Ma, and Xinchao Wang. 2025. Efficient reasoning models: A survey. arXiv preprint arXiv:2504.10903.

Jiaxuan Gao, Shu Yan, Qixin Tan, Lu Yang, Shusheng Xu, Wei Fu, Zhiyu Mei, Kaifeng Lyu, and Yi Wu. 2025. How far are we from optimal reasoning efficiency? arXiv preprint arXiv:2506.07104.

Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, and 1 others. 2025. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948.

Chaoqun He, Renjie Luo, Yuzhuo Bai, Shengding Hu, Zhen Leng Thai, Junhao Shen, Jinyi Hu, Xu Han, Yujie Huang, Yuxiang Zhang, and 1 others. 2024. Olympiadbench: A challenging benchmark for promoting agi with olympiad-level bilingual multimodal scientific problems. arXiv preprint arXiv:2402.14008.

Bairu Hou, Yang Zhang, Jiabao Ji, Yujian Liu, Kaizhi Qian, Jacob Andreas, and Shiyu Chang. 2025. Thinkprune: Pruning long chain-of-thought of llms via reinforcement learning. Preprint, arXiv:2504.01296.

Jian Hu, Jason Klein Liu, Haotian Xu, and Wei Shen. 2025a. Reinforce++: An efficient rlhf algorithm with robustness to both prompt and reward models. Preprint, arXiv:2501.03262.

Jingcheng Hu, Yinmin Zhang, Qi Han, Daxin Jiang, Xiangyu Zhang, and Heung-Yeung Shum. 2025b. Open-reasoner-zero: An open source approach to scaling up reinforcement learning on the base model. arXiv preprint arXiv:2503.24290.

Shijue Huang, Hongru Wang, Wanjun Zhong, Zhaochen Su, Jiazhan Feng, Bowen Cao, and Yi R Fung. 2025a. Adactrl: Towards adaptive and controllable reasoning via difficulty-aware budgeting. arXiv preprint arXiv:2505.18822.

Zeyu Huang, Tianhao Cheng, Zihan Qiu, Zili Wang, Yinghui Xu, Edoardo M Ponti, and Ivan Titov. 2025b. Blending supervised and reinforcement fine-tuning with prefix sampling. arXiv preprint arXiv:2507.01679.

Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helyar, Aleksander Madry, Alex Beutel, Alex Carney, and 1 others. 2024. Openai o1 system card. arXiv preprint arXiv:2412.16720.

Juyong Jiang, Fan Wang, Jiasi Shen, Sungju Kim, and Sunghun Kim. 2024. A survey on large language models for code generation. arXiv preprint arXiv:2406.00515.

Michael D Lee and Tarrant DR Cummins. 2004. Evidence accumulation in decision making: Unifying the "take the best" and the "rational" models. Psychonomic bulletin & review, 11(2):343–352.

Zhong-Zhi Li, Duzhen Zhang, Ming-Liang Zhang, Jiaxin Zhang, Zengyan Liu, Yuxuan Yao, Haotian Xu, Junhao Zheng, Pei-Jie Wang, Xiuyi Chen, and 1 others. 2025. From system 1 to system 2: A survey of reasoning large language models. arXiv preprint arXiv:2502.17419.

Hunter Lightman, Vineet Kosaraju, Yuri Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. 2023. Let's verify step by step. In The Twelfth International Conference on Learning Representations.

Zichen Liu, Changyu Chen, Wenjun Li, Penghui Qi, Tianyu Pang, Chao Du, Wee Sun Lee, and Min Lin. 2025. Understanding r1-zero-like training: A critical perspective. arXiv preprint arXiv:2503.20783.

Chenwei Lou, Zewei Sun, Xinnian Liang, Meng Qu, Wei Shen, Wenqi Wang, Yuntao Li, Qingping Yang, and Shuangzhi Wu. 2025. Adacot: Pareto-optimal adaptive chain-of-thought triggering via reinforcement learning. arXiv preprint arXiv:2505.11896.

Haotian Luo, Haiying He, Yibo Wang, Jinluan Yang, Rui Liu, Naiqiang Tan, Xiaochun Cao, Dacheng Tao, and Li Shen. 2025a. Ada-r1: Hybrid-cot via bi-level adaptive reasoning optimization. Preprint, arXiv:2504.21659.

Haotian Luo, Li Shen, Haiying He, Yibo Wang, Shiwei Liu, Wei Li, Naiqiang Tan, Xiaochun Cao, and Dacheng Tao. 2025b. O1-pruner: Length-harmonizing fine-tuning for o1-like reasoning pruning. arXiv preprint arXiv:2501.12570.

Xinyin Ma, Guangnian Wan, Runpeng Yu, Gongfan Fang, and Xinchao Wang. 2025. Cot-valve: Length-compressible chain-of-thought tuning. Preprint, arXiv:2502.09601.

Yingqian Min, Zhipeng Chen, Jinhao Jiang, Jie Chen, Jia Deng, Yiwen Hu, Yiru Tang, Jiapeng Wang, Xiaoxue Cheng, Huatong Song, and 1 others. 2024. Imitate, explore, and self-improve: A reproduction report on slow-thinking reasoning systems. arXiv preprint arXiv:2412.09413.

Niklas Muennighoff, Zitong Yang, Weijia Shi, Xiang Lisa Li, Li Fei-Fei, Hannaneh Hajishirzi, Luke Zettlemoyer, Percy Liang, Emmanuel Candès, and Tatsunori Hashimoto. 2025a. s1: Simple test-time scaling. arXiv preprint arXiv:2501.19393.

Niklas Muennighoff, Zitong Yang, Weijia Shi, Xiang Lisa Li, Li Fei-Fei, Hannaneh Hajishirzi, Luke Zettlemoyer, Percy Liang, Emmanuel Candès, and Tatsunori Hashimoto. 2025b. s1: Simple test-time scaling. Preprint, arXiv:2501.19393.

OpenAI. 2025. Learning to reason with llms.

Xiaoye Qu, Yafu Li, Zhaochen Su, Weigao Sun, Jianhao Yan, Dongrui Liu, Ganqu Cui, Daizong Liu, Shuxian Liang, Junxian He, and 1 others. 2025a. A survey of efficient reasoning for large reasoning models: Language, multimodality, and beyond. arXiv preprint arXiv:2503.21614.

Yuxiao Qu, Matthew YR Yang, Amrith Setlur, Lewis Tunstall, Edward Emanuel Beeching, Ruslan Salakhutdinov, and Aviral Kumar. 2025b. Optimizing test-time compute via meta reinforcement fine-tuning. arXiv preprint arXiv:2503.07572.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y. K. Li, Y. Wu, and Daya Guo. 2024. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. Preprint, arXiv:2402.03300.

Yi Shen, Jian Zhang, Jieyun Huang, Shuming Shi, Wenjing Zhang, Jiangze Yan, Ning Wang, Kai Wang, Zhaoxiang Liu, and Shiguo Lian. 2025. Dast: Difficulty-adaptive slow-thinking for large reasoning models. Preprint, arXiv:2503.04472.

Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. 2025. Hybridflow: A flexible and efficient rlhf framework. In Proceedings of the Twentieth European Conference on Computer Systems, pages 1279–1297.

Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. 2024. Scaling llm test-time compute optimally can be more effective than scaling model parameters. Preprint, arXiv:2408.03314.

Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen Zhong, Hanjie Chen, and 1 others. 2025. Stop overthinking: A survey on efficient reasoning for large language models. arXiv preprint arXiv:2503.16419.

Yi Sun, Han Wang, Jiaqiang Li, Jiacheng Liu, Xiangyu Li, Hao Wen, Yizhen Yuan, Huiwen Zheng, Yan Liang, Yuanchun Li, and 1 others. 2025. An empirical study of llm reasoning ability under strict output length constraint. arXiv preprint arXiv:2504.14350.

Kimi Team, Angang Du, Bohong Yin, Bowei Xing, Bowen Qu, Bowen Wang, Cheng Chen, Chenlin Zhang, and 1 others. 2025. Kimi-vl technical report. Preprint, arXiv:2504.07491.

Qwen Team. 2025. Qwq-32b: Embracing the power of reinforcement learning.

Siye Wu, Jian Xie, Yikai Zhang, Aili Chen, Kai Zhang, Yu Su, and Yanghua Xiao. 2025a. Arm: Adaptive reasoning model. arXiv preprint arXiv:2505.20258.

Zongqian Wu, Baoduo Xu, Tianyu Li, Zhu Sun, Xiaofeng Zhu, and Lei Feng. 2025b. Mitigating strategy-selection bias in reasoning for more effective test-time scaling. arXiv preprint arXiv:2509.17905.

Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, and 1 others. 2025. Dapo: An open-source llm reinforcement learning system at scale. arXiv preprint arXiv:2503.14476.

Jiajie Zhang, Nianyi Lin, Lei Hou, Ling Feng, and Juanzi Li. 2025. Adaptthink: Reasoning models can learn when to think. arXiv preprint arXiv:2505.13417.

A 实验细节

硬件与软件平台 所有实验在配备4张NVIDIA A800 PCIe GPU（每张80GB显存）的工作站上进行，系统为Ubuntu20.04.6 LTS，实现基于Verl(Sheng et al., 2025)框架。

训练配置 使用温度采样（$\tau = 1.0$）生成rollout，并强制序列结束token；采用vLLM高效批量解码，配置128个rollout槽位和分页注意力。RL最大提示长度2048个token，最大回答长度10000个token；训练100步，batch size为64，Actor使用Adam，学习率10^{-6}。

rollout采用分组采样，每题$G = 12$。首先生成3个完整答案；初始截断点t_0为原长度25%，增量$\Delta t = 25\%$，进行$k = 3$次截断，每个截断点要求输出最终预测。于是每题得到9个短答案和3个完整答案，共12个回答。

RL裁剪参数下界为0.2，上界为0.28；奖励权重为$w_{acc} = 0.9, w_f = 0.1, w_\ell = 1$，平衡准确性、格式与长度。

推理配置 温度0.6，最大模型长度30000个token，最大生成token数16000，top-p为0.95。

长度奖励设计 第4.7节还介绍了线性奖励和指数衰减奖励。线性奖励定义为

$$r_\ell(i) = \begin{cases} \dfrac{\ell_{\max} - \ell_i}{\ell_{\max} - \ell_{\min} + \varepsilon}, & i \in \mathcal{C}, \\ 0, & \text{其他情况。} \end{cases} \tag{13}$$

Sigmoid长度奖励对推理长度提供平滑惩罚(Arora and Zanette, 2025)：

$$r_\ell(i) = \begin{cases} 1 - \alpha\, \sigma\left(\dfrac{\ell_i - \mu_x}{\sigma_x + \varepsilon} \right), & i \in \mathcal{C}, \\ 0, & \text{其他情况。} \end{cases} \tag{14}$$

ℓ_i是第i个回答的token长度，$\mu_x = \mathbb{E}_{j \in \mathcal{C}}[\ell_j]$与$\sigma_x = \sqrt{\mathrm{Var}_{j \in \mathcal{C}}(\ell_j)}$是问题$x$的全部正确rollout的长度均值和标准差；$\sigma(z) = 1/(1 + e^{-z})$为Sigmoid函数；$\alpha \in [0, 1]$为超参数，$\varepsilon > 0$用于数值稳定。

指数衰减奖励将线性项替换为指数函数：

$$r_\ell(i) = \begin{cases} \left(\dfrac{\ell_{\max} - \ell_i}{\ell_{\max} - \ell_{\min} + \varepsilon} \right)^{\alpha} (1 - \delta) + \delta, & i \in \mathcal{C}, \\ 0, & \text{其他情况。} \end{cases} \tag{15}$$

原文称全部实验固定$\alpha = 1.2, \delta = 0.05, \varepsilon = 10^{-8}$。[9]

基线实现

- 对AdaptThink、LCR1和Laser，最初尝试用论文官方GitHub仓库复现，但结果未完全匹配所报告性能。为公平且不削弱原结果，直接下载Hugging Face已训练模型，采用论文指定提示配置，并使用附录A的推理参数评估。
- SFT与DPO均在JET两阶段rollout下，每题采样12个答案。最短正确答案为SFT训练目标和DPO偏好回答，最长答案为DPO拒绝回答。7B训练集为5.8K样本，1.5B为5.6K；两者使用LoRA微调1个epoch，截断长度4096，学习率10^{-5}，最大训练样本数100000。
- DAPO与JET采用相同数据及参数，只改变rollout和奖励配置，去掉长度奖励，仅保留准确性与格式奖励。

[9]译注：上文Sigmoid段规定$\alpha \in [0, 1]$，这里却统一写1.2；原文未解释两者差异，本译稿保留而不擅自改动。

表 3: DS-Distill-Llama-8B在各数学任务上的表现。ACC括号内为相对Base的准确率变化；Length为该基准所有样本的平均token压缩比例；AVG进一步平均各基准压缩比例。

Methods	GSM8K		MATH500		AIME24		AMC		Olympiad		AVG	
	ACC	Length	ACC	Length	ACC	Length	ACC	Length	ACC	Length	ACC	Length
DeepSeek-Distill-Llama-8B												
Base	88.6	1756	88.0	4299	41.0	12223	76.9	7521	52.4	8193	69.4	5493
SFT	69.5 (-19.0)	410 (-76.7)	77.6 (-10.4)	2833 (-34.1)	34.7 (-6.3)	9683 (-20.8)	72.8 (-4.1)	6392 (-15.0)	47.3 (-5.2)	6249 (-23.7)	60.4 (-9.0)	3970 (-27.7)
DPO	71.0 (-17.5)	415 (-76.4)	78.6 (-9.4)	3215 (-25.2)	36.3 (-4.7)	11314 (-7.4)	76.4 (-0.5)	6450 (-14.2)	49.5 (-3.0)	6868 (-16.2)	62.4 (-7.0)	4288 (-21.9)
DAPO	81.7 (-6.8)	1027 (-41.5)	86.6 (-1.4)	3258 (-24.2)	40.8 (-0.2)	9701 (-20.6)	77.4 (+0.5)	5463 (-27.4)	52.4 (0.0)	6463 (-21.1)	67.8 (-1.6)	4081 (-25.7)
JET	91.1 (+2.6)	1002 (-42.9)	89.0 (+1.0)	2922 (-32.0)	41.0 (0.0)	9231 (-24.5)	76.8 (-0.1)	5261 (-30.1)	59.1 (+6.7)	5822 (-28.9)	71.4 (+2.0)	3821 (-30.4)

arXiv 2509.23392v3

表 4: 三种奖励策略在八个基准数据集上的准确率比较。

Strategy	GSM8K	MATH500	AIME24	AMC	Olympiad	CSQA	GPQA	MMLU	AVG
Ours	83.8	83.2	32	66.1	51.6	45.6	43.4	44.6	56.3
Linear	82.6	82.6	31.7	64.2	50.2	45.6	38.9	45.2	55.1
Exp	85.3	84.6	33	63.6	52.3	46.0	43.4	45.9	56.8

表 5: 准确性奖励系数w_{acc}和长度奖励系数w_ℓ对模型表现的影响。

Methods	**GSM8K**		**MATH500**		**AIME24**		**AMC**		**Olympiad**		**AVG**	
	ACC	Length	ACC	Length	ACC	Length	ACC	Length	ACC	Length	ACC	Length
Base	76.0	468	79.6	3617	28.7	11046	63.3	7644	47.0	7679	58.9	4765
$w_\ell = 1.0, w_{acc} = 0.9$	83.8	605	83.2	2072	32.0	6641	66.1	3872	51.6	4121	**63.3**	**2710**
$w_\ell = 0.9, w_{acc} = 1.0$	82.6	726	82.2	2459	28.7	7731	66.0	4783	49.3	4852	61.8	3243
$w_\ell = 0.0, w_{acc} = 0.9$	84.2	886	84.0	2997	29.3	9822	65.9	5671	48.7	6044	62.4	3974
$w_\ell = 1.0, w_{acc} = 1.5$	81.4	985	85.4	3591	30.7	10332	66.8	6727	47.7	6963	62.4	4547
$w_\ell = 1.5, w_{acc} = 1.0$	79.8	981	83.4	3553	25.7	10532	64.1	6406	48.6	6959	60.3	4482
$w/incorrect$	78.0	871	82.4	3823	29.7	9711	64.2	7452	46.7	6997	60.2	4658

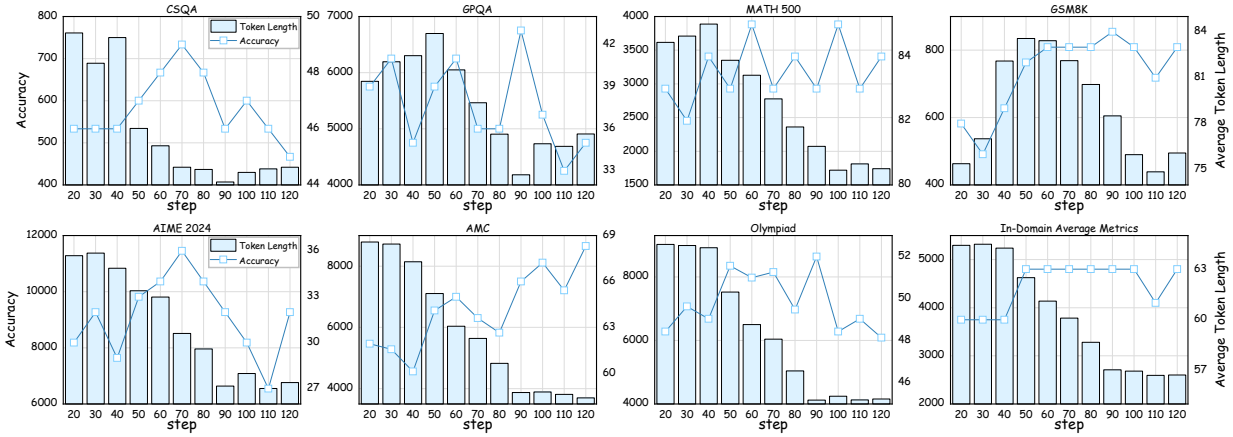


图 6: JET训练过程中，DeepSeek-Distill-Qwen-1.5B在各基准的准确率与输出长度变化。

B 算法

根据第3.1节，算法1给出JET伪代码，列出关键步骤以便复现。

C 进一步分析

C.1 RL训练过程中的性能演变

我们跟踪DeepSeek-Distill-Qwen-1.5B和7B在JET训练中多个下游任务上的表现，主要趋势见图6与7。

平均token长度随训练显著下降，而准确率保持稳定或提高，说明方法成功鼓励简洁且准确的回答。早期两模型输出较长、准确率中等，反映策略仍在探索如何平衡质量和简洁性。随着训练推进，输出长度急剧下降，尤其在MATH500、GSM8K和AMC等结构化推理任务中，平均token数减少超过50%。关键是压缩同时维持或改善准确率，说明短输出在语义上有意义，而非仅仅截断。

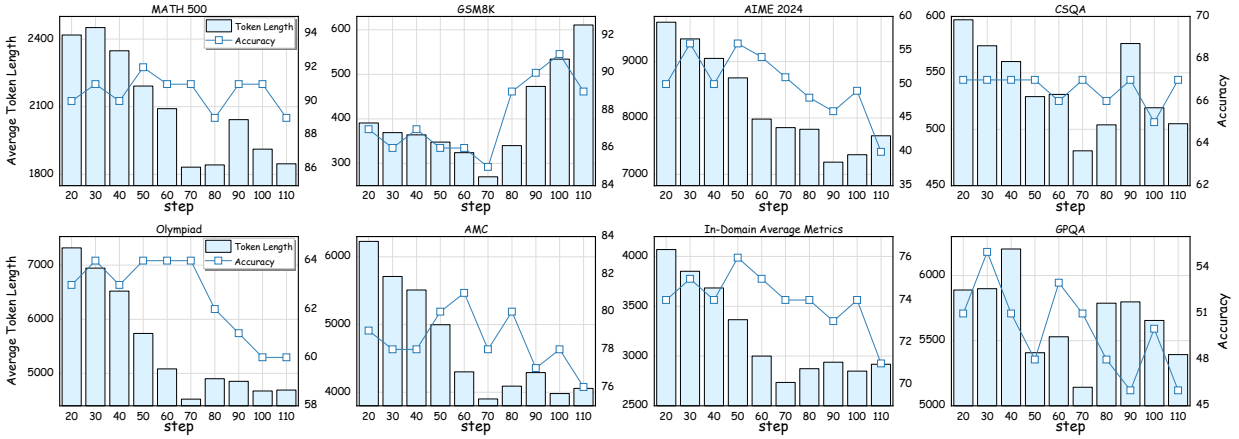


图 7: JET训练过程中，DeepSeek-Distill-Qwen-7B在各基准的准确率与输出长度变化。

算法 1 恰到好处的思考（JET）算法

输入： 初始策略π_θ，训练集$\mathcal{Q}$，rollout规模G，策略更新次数μ
输出： 训练后策略π_θ

for step $= 1, \ldots, M$ **do**
  采样小批量$\mathcal{Q}_b \subset \mathcal{Q}$
  保存当前策略：$\pi_{\theta_{old}} \leftarrow \pi_\theta$
  for 每个$q \in \mathcal{Q}_b$ **do**
    阶段1：完整轨迹rollout
    生成G_{full}条完整轨迹：$\{o_i^{full}\}_{i=1}^{G_{full}} \sim \pi_{\theta_{old}}(\cdot \mid q)$
    阶段2：截断轨迹rollout
    for 每个o_i^{full}及截断比例$T \in \mathcal{T}$ **do**
      在T处截断，追加停止思考提示并补全：
      $\hat{o}_{i,T} \sim \pi_{\theta_{old}}(\cdot \mid q, o_i^{(T)}, z_{stop})$
    end for
    汇集全部轨迹$\mathcal{O}_q$，计算r_{acc}, r_f, r_ℓ（式7）
    为所有轨迹计算token级优势$\hat{A}_{i,t}$
  end for
  for iteration $= 1, \ldots, \mu$ **do**
    最大化$\mathcal{J}_{DAPO}$更新策略（式9）
  end for
end for
return π_θ

7B模型收敛比1.5B更快，趋势更平滑，最终准确率更高、长度缩减更一致，可能源于更强泛化能力和更丰富表征。小模型也显著改善，说明方法能有效适应不同规模。

总体而言，域内指标显示从长且低效的输出向短且更精确、性能稳定的回答演进，体现RL设计成功使模型行为同时对齐正确性和简洁性。

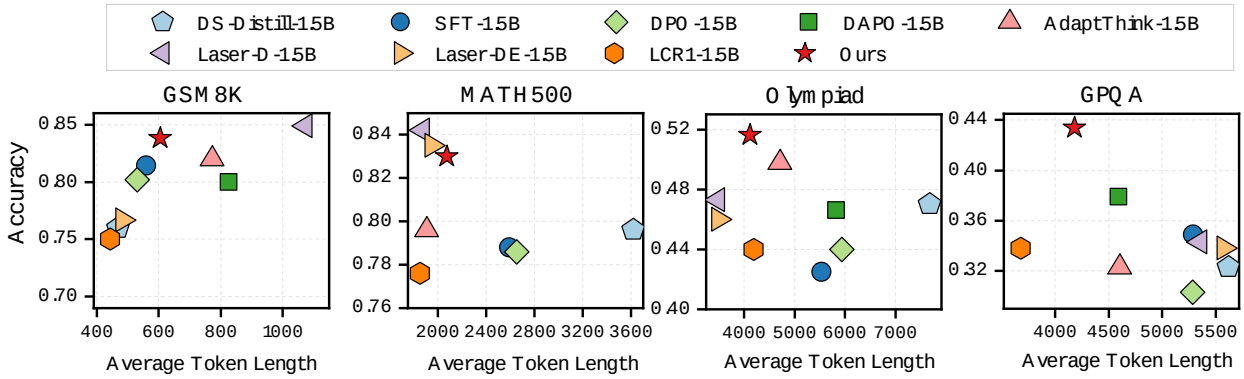


图 8: JET在多数任务中展现较强表现。帕累托式图中，越靠左上意味着输出更短、准确率更高。

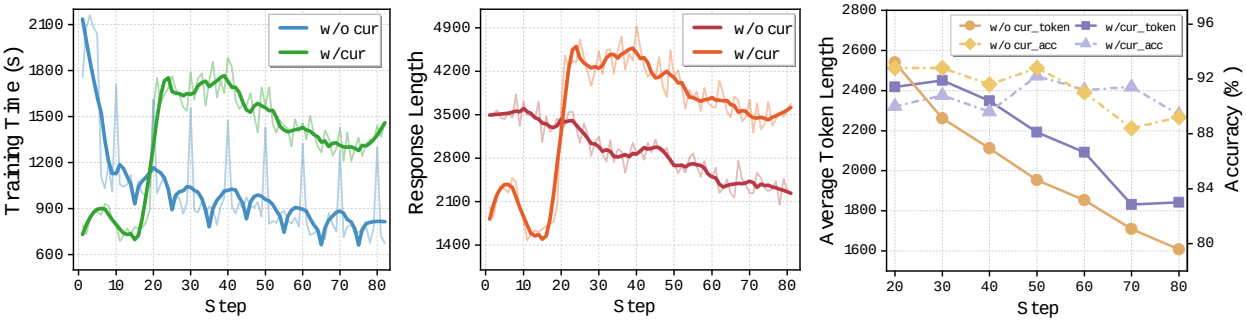


图 9: 课程学习对JET训练的影响。从左至右：每步RL训练时间、rollout生成时间、输出token长度、MATH500准确率；均使用DeepSeek-Distill-Qwen-7B。

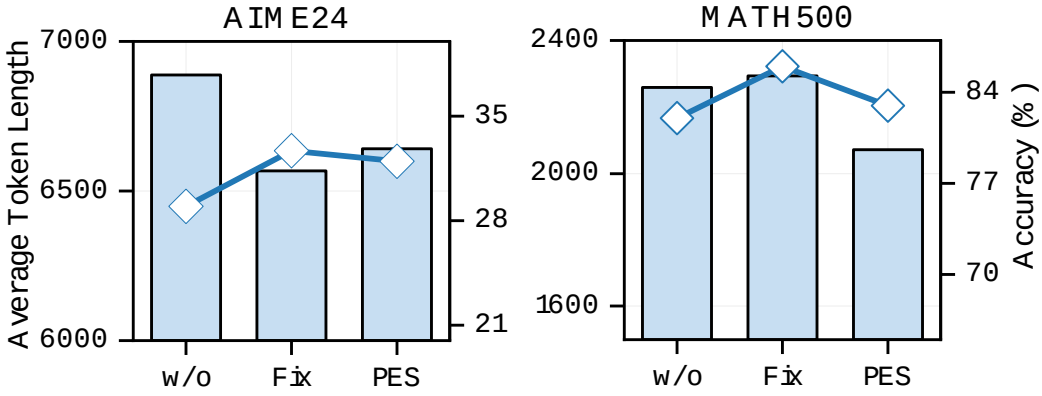


图 10: PES对AIME24与MATH500的影响。

C.2 其他模型上的进一步分析

为检验有效性，进一步采用DeepSeek-R1-Distill-Llama-8B骨干。由于其他基线并未在该模型上评估，因此只报告其中一部分，结果见表3。

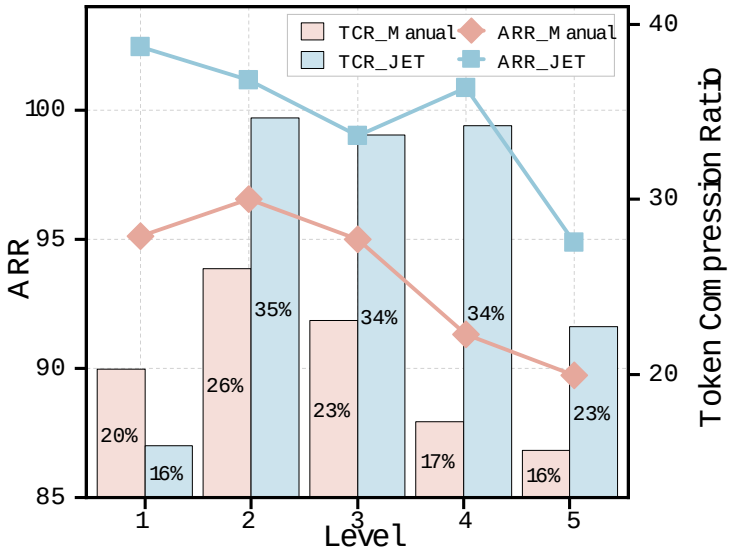


图 11: JET在不同难度级别上的表现。

JET跨骨干保持准确率与长度的稳定平衡。相对基础模型，准确率提高2个百分点，平均token使用减少31%；域外任务中token减少29%，准确率提高0.8个百分点，说明效率与性能优势可扩展到更大规模模型。

还针对1.5B模型绘制准确率与平均输出长度的帕累托式图（图8）。左上方意味着正确性与效率权衡更好。多数任务中JET均位于这一有利区域，说明相对其他方法，高效推理显著改善。

C.3 JET主动停止思考的分析

为验证自适应推理，在MATH500不同难度数学题上评估JET，并与手动截断（保留75%）比较，见图11。

JET可依据任务难度主动停止推理，显著节省token并保持高准确性。优势源于RL训练中接触不同推理长度，学会为不同任务选择最优深度。相反，固定75%截断可能导致简单任务推理不足、复杂任务推理过浅。JET动态调整深度，避免过度和无效推理，可按复杂度自适应。[10]

C.4 准确性与长度奖励系数的影响

JET训练使用三种数据格式。由于模板仅要求最终答案放入\boxed{}，骨干模型格式遵循能力已较强，因此本节不研究格式影响，而聚焦准确性与长度奖励如何塑造行为。使用DS-Distill-Qwen-1.5B，固定其他RL设置，只改变两个系数，结果见表5。

长度奖励对维持简洁推理至关重要。虽然PES产生短rollout，但不会改变模型的固有偏好；没有长度奖励，模型会迅速转向更长回答。

当长度奖励权重低于或高于准确性奖励权重时，输出都会过长。尽管最终轨迹长度相近，原因不同，均反映奖励投机：

- 长度权重较低时，模型主要利用准确性奖励。长推理提高获得高准确性评分的可能性，延长输出成为可靠策略，是准确性驱动的奖励投机。
- 长度权重较高时，作者认为由于尺度不匹配，准确性仍主导优化。其取值为0或1，产生较大且稳定的梯度信号；长度奖励连续、范围相对较小。因此即使显式权重较小，准确性所诱发梯度仍更强。为避免准确性奖励为0，模型偏好长输出，仍属对准确性项的奖励投机。

[10]译注：“简单任务推理不足”亦为原文原意，虽与通常对固定预算的直觉不完全一致，未改写为作者未说的结论。

这些观察表明，准确性与长度奖励的适当平衡对稳定训练及防止两类奖励投机至关重要。[11]

C.5 仅奖励正确答案长度的影响

研究只对每组正确答案施加长度奖励，是否更能缩短回答、提升整体表现。使用DS-Distill-Qwen-1.5B，训练设置与主实验相同，比较仅正确答案获得长度奖励（本方法）与所有答案包括错误答案都获得奖励（w/incorrect），结果见表5。

仅奖励正确答案可同时提高准确率和降低输出长度。相对基础模型，其平均准确率更高、回答明显更短，并持续优于奖励所有答案的方案。

原因在于奖励错误答案会引入**冲突学习信号**：即使正确性奖励为0，错误答案仍得到长度奖励，短错误回答与长正确回答因而被视为奖励相近。这削弱缩短正确回答的压力，并鼓励更长输出，形成奖励投机。只奖励正确答案消除干扰、聚焦梯度，明确鼓励缩短正确回答，从而学习更稳定、压缩更有效、准确率更高。结果显示该限制对实现期望行为至关重要。

C.6 三种奖励策略的细节

正文关注三种长度奖励对输出长度的影响，这里进一步评估准确性，结果见表4。

指数加权奖励平均准确率最高，尤其在困难数学任务上。本方法的加权线性奖励在这些任务略低，但在GPQA、MMLU等知识基准仍有竞争力，显示稳定性与泛化。标准线性奖励多数任务最差，说明对复杂问题激励不足。

长度控制方面，线性奖励较弱，模型容易受到冗长推理噪声影响。指数衰减惩罚更强，但可能过早截断，导致难题推理不完整、准确率不稳定。

C.7 课程学习对JET训练的影响

使用DeepSeek-Distill-Qwen-7B评估课程学习，结果见图9。

不使用课程学习的训练效率显著更高。每步约600–800秒，而课程学习约1400秒，计算开销减少接近50%。

非课程策略输出更简洁且不损害正确性。两者在MATH500准确率相近，课程学习则倾向较长回答。

解释如下：课程学习逐步让模型接触更难样本，可帮助样本难度差异大或易陷局部最优的情况；但JET的训练数据与rollout策略已在不同难度上提供多样、信息丰富的样本。因此，不采用课程学习的随机采样已能充分暴露必要信号，以较低成本取得相近或更佳表现。直接接触多样样本也有助于学习简洁而正确的输出。

C.8 PES的进一步分析

第4.4节分析训练中多样路径的影响，此处增加AIME24与MATH500结果（图10）。**更长推理并不总带来更好表现，可能引入错误传播与噪声，降低最终准确率**。与无PES基线比较得到一个反直觉发现：完整推理链看似有利，实际不如PES。在不同难度数据集上，PES持续超过全部基线策略。

[11]译注：关于梯度强弱的说明为作者解释；奖励是离散还是连续，本身不足以决定策略梯度大小，还依赖奖励尺度、方差、优势归一化及采样分布。

C.9 案例研究

展示两类案例：（i）JET与Base、AdaptThink回答对比（案例1）；（ii）JET训练后信息充分时主动终止思考（案例2、3）。

案例1：与Base和AdaptThink比较。Base7B回答正确，但过长，消耗4087个token；AdaptThink仅636个token，却回答错误；JET仅1537个token，简洁且正确。这说明JET有效平衡准确性与简洁性。

案例2：基于置信度的主动提前停止。JET在推理中察觉信息已充分、答案很可能正确，提前终止并输出答案，体现自适应停止能力，在保持正确性时减少不必要计算。

案例3：获得正确答案后终止。JET在推理中识别已经获得正确解，立即结束并输出，说明能判断进一步推理不再必要，减少冗余计算并保证正确性。

总体上，案例说明JET可兼顾简洁、正确与规范格式；自适应策略让模型在获得足够信息后停止推理，相对基线改善效率、输出质量及对任务要求的对齐。

D 华为昇腾NPU平台验证

为验证JET不限于NVIDIA GPU，使用非DeepSeek架构在华为昇腾平台补充实验。具体在Ascend910B NPU部署JET，训练华为盘古系列70亿参数模型Pangu-Embedded-7B(Chen et al., 2025)。

硬件与软件配置 配置见表6。全部训练与评估在单节点8张Ascend910B（每张64GB HBM）上进行。软件包含带torch-npu的PyTorch2.5.1、vLLM0.7.4与vllm-ascend插件，以及CANN8.1.RC1。关键适配包括禁用NPU不支持的`torch.compile`，张量并行设为1，并修改模型`forward`签名，以在NPU后端启用vLLM分页KV缓存。

表 6: 昇腾NPU实验的硬件和软件配置。

组件	规格
加速器	Ascend910B NPU
单设备内存	64GB HBM
CANN版本	8.1.RC1
PyTorch／torch-npu	2.5.1
vLLM	0.7.4
vllm-ascend	0.7.3.post1

结果 在完整GSM8K测试集（1319题）用贪心解码评估基础模型与JET，最大生成长度8000个token，结果见表7。 JET与基础模型准确率相近（94.69%对94.77%），平均输出长度降低

表 7: Ascend910B上Pangu-Embedded-7B的GSM8K结果。

模型	准确率	平均长度
Base	94.77%	1662
JET	94.69%（−0.08）	1462（−12.0%）

12.0%（1662至1462个token）。结果表明，它能有效泛化到不同硬件（昇腾NPU）、不同架构（Pangu-Embedded）及非DeepSeek模型家族，持续降低推理长度而不牺牲准确性。[12]

[12]译注：“不牺牲准确性”为作者定性描述；表中确有0.08个百分点下降，且未报告该差异的显著性检验。

E LLM使用说明

作者使用大型语言模型辅助稿件写作和润色，具体包括改善措辞、可读性与表达清晰度，以及句子改写、语法检查和行文连贯性。

LLM未参与构思、研究方法或实验设计。全部研究概念、想法与分析均由作者提出并实施。LLM贡献仅限提升语言质量，不涉及科学内容或数据分析。

作者对稿件全部内容负责，包括LLM生成或润色的文本，并确认相关文本遵守伦理准则，不涉及剽窃或科研不端。

F 完整案例文本的公开版说明

原文末尾案例 1（JET 与 Base、AdaptThink 比较）、案例 2 和案例 3（主动停止思考）的完整题目与逐字模型输出，均暂不收录。作者对其结果和行为的分析见前文“案例研究”。