机器学习论文 · 校准与不确定性

现代神经网络的校准问题

On Calibration of Modern Neural Networks

Chuan Guo* · Geoff Pleiss* · Yu Sun*
Kilian Q. Weinberger

康奈尔大学

*同等贡献，按字母顺序排列。

中文完整译文

正文、参考文献、补充材料 · LaTeX 重排版

第34届国际机器学习大会（ICML 2017），澳大利亚悉尼
Proceedings of Machine Learning Research 70:1321–1330

译文版本 1.0 · 2026年11月10日
中文翻译与编排：dot · 非官方译文

版本、范围与版权说明

本译文以 PMLR 正式发表版本为底本，完整覆盖原文 PDF 的10页（含参考文献）以及独立补充材料 PDF 的4页。正文的摘要、第1–6节、致谢、全部47条参考文献，以及补充材料第S1–S4节、8幅图和4张表均纳入。公式和数据保留原文含义与编号，图表标题和正文完整翻译；原图中的英文坐标、图例和模型缩写保留，并在本页提供中文对照。参考文献保留英文著录，同时附中文题名。

本版为中文单栏重新排版，页码不与英文原文一一对应。图中的曲线、直方图和数值保留原始矢量内容，未重新估计或生成实验数据。原文补充材料证明中的疑似排印错误、正文中可疑的样本数量等均以明确标注的译注处理，不将修正混入原作者论述。

原文与引用： Chuan Guo, Geoff Pleiss, Yu Sun, Kilian Q. Weinberger. On Calibration of Modern Neural Networks. Proceedings of the 34th International Conference on Machine Learning, PMLR 70:1321–1330, 2017.

https://proceedings.mlr.press/v70/guo17a.html

正文 PDF：

https://proceedings.mlr.press/v70/guo17a/guo17a.pdf

补充材料 PDF：

https://proceedings.mlr.press/v70/guo17a/guo17a-supp.pdf

版权与许可： 原文版权归原作者所有（2017）。ICML 2017 的 PMLR 出版协议采用 Creative Commons Attribution 4.0 International（CC BY 4.0）。本中文翻译和重新排版属于对原文的改编，署名与来源如上；本译文同以 CC BY 4.0 提供。原作者、ICML 或 PMLR 未参与或认可本译文。许可不提供任何担保。

许可：https://creativecommons.org/licenses/by/4.0/

当届出版协议：https://media.nips.cc/Conferences/ICML2017/permission_to_publish_icml2017.pdf

通信作者： Chuan Guo（cg563@cornell.edu），Geoff Pleiss（geoff@cs.cornell.edu），Yu Sun（ys646@cornell.edu）。

原图英文标识对照

Confidence / Avg. confidence 置信度／平均置信度。

Accuracy / Error / Test error 准确率／错误率／测试错误率。

Outputs / Gap / % of Samples 输出（各箱准确率）／校准差距／样本占比。

Depth / Filters per layer / Weight decay 深度／每层滤波器数／权重衰减。

Batch Normalization / Without / With 批量归一化／不使用／使用。

Epoch / NLL / Entropy 训练轮次／负对数似然／熵。

Uncal. / Temp. Scale. / Hist. Bin. / Iso. Reg. 未校准／温度缩放／直方图分箱／保序回归。

SD / FG / BIN 随机深度／细粒度／二分类。

目录

版本、范围与版权说明 **1**

摘要 **3**

1 引言 **3**

2 定义 **5**

3 观察校准不良现象 **6**

4 校准方法 **8**

4.1 二分类模型的校准 8

4.2 向多分类模型扩展 9

4.3 其他相关工作 10

5 结果 **10**

6 结论 **14**

致谢 **14**

参考文献 **15**

补充材料 **20**

S1. 校准指标的进一步说明 20

S2. 温度缩放的进一步说明 20

S3. 补充表格 22

S4. 更多可靠性图 25

译者校注（非原文） 26

摘要

置信度校准，即预测能够反映真实正确概率的概率估计值，对于许多应用中的分类模型都很重要。我们发现，与十年前的神经网络不同，现代神经网络的校准表现很差。通过大量实验，我们观察到，深度、宽度、权重衰减和批量归一化是影响校准的重要因素。我们在图像和文档分类数据集上，评估了各种后处理校准方法在最先进架构上的表现。我们的分析和实验不仅为理解神经网络学习提供了见解，还为实际应用给出了一种简单直接的方法：在大多数数据集上，温度缩放，即 Platt 缩放的一种单参数变体，在校准预测方面出人意料地有效。

1 引言

深度学习的近期进展大幅提高了神经网络的准确率（Simonyan & Zisserman, 2015；Srivastava et al., 2015；He et al., 2016；Huang et al., 2016；2017）。因此，在目标检测（Girshick, 2015）、语音识别（Hannun et al., 2014）和医疗诊断（Caruana et al., 2015）等应用中，人们如今已将复杂的决策任务交由神经网络完成。在这些场景中，神经网络是更大规模决策流程中的重要组成部分。

在现实世界的决策系统中，分类网络不仅必须准确，还应当指出自己何时可能出错。例如，考虑一辆使用神经网络检测行人和其他障碍物的自动驾驶汽车（Bojarski et al., 2016）。如果检测网络无法有把握地判断眼前是否存在障碍物，那么汽车在制动时就应更多地依赖其他传感器的输出。另一个例子是自动化医疗：当疾病诊断网络的置信度较低时，就应将控制权交给人类医生（Jiang et al., 2012）。具体而言，网络除了给出预测，还应提供经过校准的置信度度量。换言之，与预测类别标签关联的概率应当反映该预测实际上正确的概率。

经过校准的置信度估计对于模型的可解释性也很重要。人类对概率有一种天然的认知直觉（Cosmides & Tooby, 1996）。良好的置信度估计能够提供有价值的额外信息，从而使用户信任模型；对于分类决策往往难以解释的神经网络而言，这一点尤其重要。此外，良好的概率估计还可用于将神经网络纳入其他概率模型。例如，在语音识别中将网络输出与语言模型结合（Hannun et al., 2014；Xiong et al., 2016），或在目标检测中将网络输出与摄像机信息结合（Kendall & Cipolla, 2016），都可以提高性能。

2005 年，Niculescu-Mizil & Caruana（2005）表明，神经网络通常能够在二分类任务中产生校准良好的概率。如今的神经网络无疑比十年前更准确，但我们却十分惊讶地发现，现代神经网络已不再具有良好的校准表现。图 1 直观展示了这一现象，它比较了一个 5 层 LeNet（左；LeCun et al., 1998）和一个 110 层 ResNet（右；He et al., 2016）在 CIFAR-100 数据集上的表现。上排以直方图展示了预测置信度（即与预测标签关联的概率）的分布。LeNet 的平均置信度与其准确率十分接近，而 ResNet 的平均置信度则显著高于其准确率。下排的可靠性图（DeGroot & Fienberg, 1983；Niculescu-Mizil & Caruana, 2005）进一步说明了这一点：这些图展示了准确率随置信度的变化。我们可以看到，LeNet 的校准表现良好，因为置信度很好地近似了期望准确率（即各柱条大致沿对角线排列）。相比之下，ResNet 的准确率更高，却与其置信度不匹配。

我们的目标不仅是理解神经网络为何变得校准不良，还要找出哪些方法能够缓解这一问题。在本文中，我们在若干计算机视觉和自然语言处理任务上表明，神经网络产生的置信度无法代表真实概率。此外，我们还对可能导致校准不良的网络训练与架构发展趋势给出见解和直观解释。最后，我们在最先进的神经网络上比较了各种后处理校准方法，并提出了我们自己的若干扩展方法。令人惊讶的是，我们发现，Platt 缩放（Platt et al., 1999）的一种单参数变体往往是获得校准概率最有效的方法，我们将其称为温度缩放。由于这种方法可以直接使用现有深度学习框架实现，因此很容易在实际应用中采用。

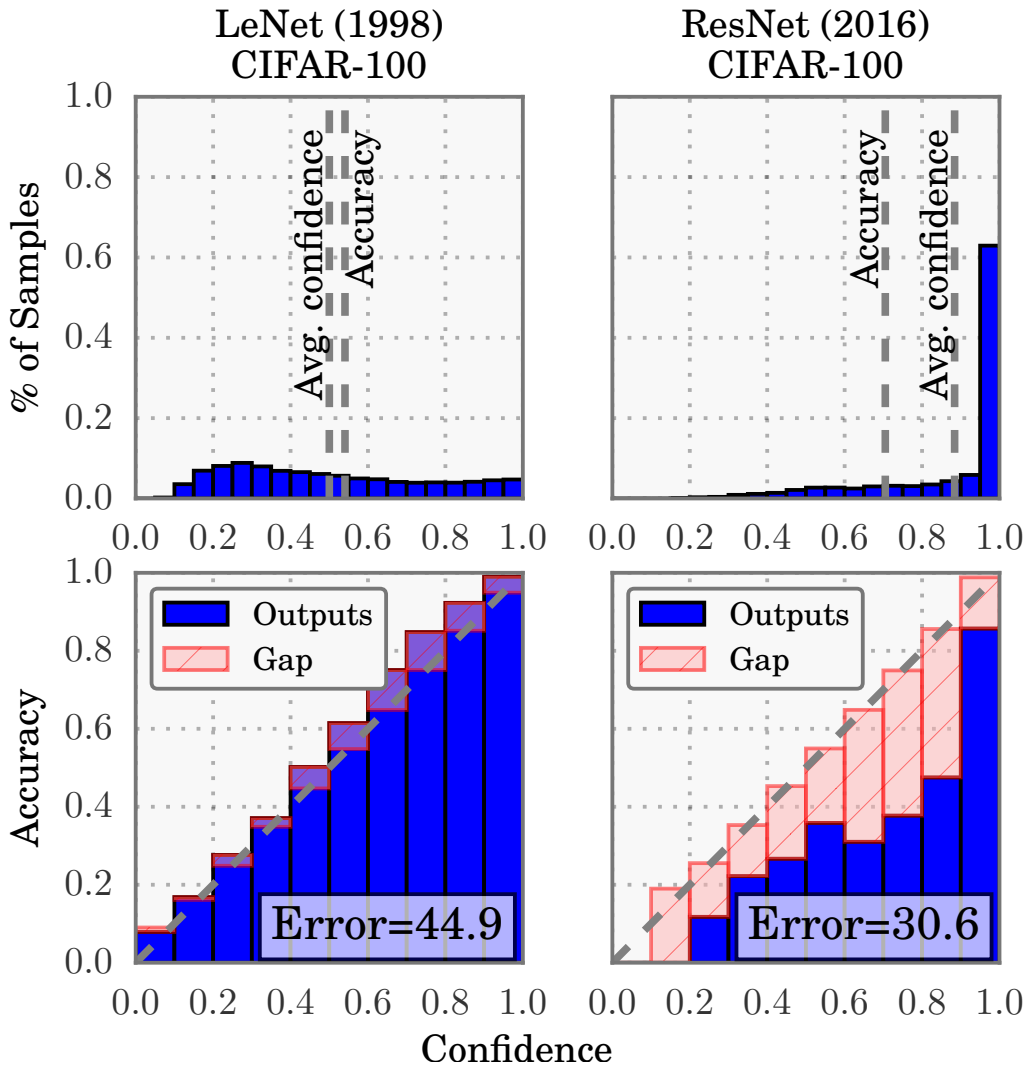


图 1: 5 层 LeNet（左）和 110 层 ResNet（右）在 CIFAR-100 上的置信度直方图（上）和可靠性图（下）。详细说明见下文。

2 定义

本文研究的问题是使用神经网络进行有监督多分类。输入 $X \in \mathcal{X}$ 和标签 $Y \in \mathcal{Y} = \{1, \dots, K\}$ 是服从真实联合分布 $\pi(X, Y) = \pi(Y \mid X)\pi(X)$ 的随机变量。设 h 为一个神经网络，且 $h(X) = (\hat{Y}, \hat{P})$，其中 $\hat{Y}$ 是类别预测，$\hat{P}$ 是与之关联的置信度，即预测正确的概率。我们希望置信度估计 $\hat{P}$ 是经过校准的，直观而言，这意味着 $\hat{P}$ 代表真实概率。例如，给定 100 个置信度均为 0.8 的预测，我们期望其中有 80 个分类正确。更形式化地，我们将完美校准定义为

$$\mathbb{P}\big(\hat{Y} = Y \mid \hat{P} = p\big) = p, \qquad \forall p \in [0, 1]. \tag{1}$$

其中，概率是相对于该联合分布而言的。在所有实际场景中，都不可能实现完美校准。此外，由于 $\hat{P}$ 是一个连续随机变量，无法使用有限个样本计算式 (1) 中的概率。这促使我们寻求能够把握式 (1) 本质的经验近似。

可靠性图。 可靠性图（例如图 1 下排）是模型校准情况的可视化表示（DeGroot & Fienberg, 1983；Niculescu-Mizil & Caruana, 2005）。它们将样本的期望准确率绘制为置信度的函数。如果模型完美校准，即式 (1) 成立，那么图中应当呈现恒等函数。任何对这条理想对角线的偏离都表示校准不良。

为了利用有限样本估计期望准确率，我们将预测划分到 M 个区间分箱中（每个区间的宽度为 $1/M$），并计算每个分箱的准确率。令 B_m 表示预测置信度落在区间 $I_m = (\frac{m-1}{M}, \frac{m}{M}]$ 内的样本索引集合。B_m 的准确率为

$$\mathrm{acc}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \mathbf{1}(\hat{y}_i = y_i),$$

其中，$\hat{y}_i$ 和 y_i 分别是样本 i 的预测类别标签和真实类别标签。基本概率论告诉我们，$\mathrm{acc}(B_m)$ 是 $\mathbb{P}(\hat{Y} = Y \mid \hat{P} \in I_m)$ 的无偏且一致的估计量。我们将分箱 B_m 内的平均置信度定义为

$$\mathrm{conf}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \hat{p}_i,$$

其中，$\hat{p}_i$ 是样本 i 的置信度。对于分箱 B_m，$\mathrm{acc}(B_m)$ 和 $\mathrm{conf}(B_m)$ 分别近似式 (1) 的左侧和右侧。因此，对于一个完美校准的模型，所有 $m \in \{1, \dots, M\}$ 都有 $\mathrm{acc}(B_m) = \mathrm{conf}(B_m)$。注意，可靠性图并不展示某个分箱中样本所占的比例，因此不能用它来估计有多少样本得到了校准。

期望校准误差（ECE）。 尽管可靠性图是有用的可视化工具，但用一个标量汇总统计量来描述校准情况更为方便。由于比较两个分布的统计量无法做到面面俱到，已有研究提出了各有侧重的不同变体。衡量校准不良的一种方式，是置信度与准确率之差的绝对值的期望，即

$$\mathbb{E}_{\hat{P}}\Big[\Big|\mathbb{P}\big(\hat{Y} = Y \mid \hat{P} = p\big) - p\Big|\Big]. \tag{2}$$

期望校准误差（Expected Calibration Error，Naeini et al., 2015），简称 ECE，通过将预测划分到 M 个等宽分箱中（与可靠性图相似），然后对各分箱的准确率与置信度之差求加权平均，来近似式 (2)。更准确地说，

$$\mathrm{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{n} \big|\mathrm{acc}(B_m) - \mathrm{conf}(B_m)\big|, \tag{3}$$

其中，n 为样本数。对于给定分箱，acc 和 conf 之间的差表示校准差距（可靠性图中的红色柱条，例如图 1）。我们将 ECE 作为衡量校准的主要经验指标。关于该指标的更多分析，见第 S1 节。

最大校准误差（MCE）。 在必须具有可靠置信度度量的高风险应用中，我们可能希望最小化置信度与准确率在最坏情况下的偏差：

$$\max_{p\in[0,1]} \left|\mathbb{P}\big(\hat{Y} = Y \mid \hat{P} = p\big) - p\right|. \tag{4}$$

最大校准误差（Maximum Calibration Error，Naeini et al., 2015），简称 MCE，用于估计这一偏差的上界。与 ECE 类似，这一近似也涉及分箱：

$$\text{MCE} = \max_{m\in\{1,\dots,M\}} \left|\text{acc}(B_m) - \text{conf}(B_m)\right|. \tag{5}$$

在可靠性图中，MCE 衡量所有分箱中最大的校准差距（红色柱条），而 ECE 衡量所有差距的加权平均。对于完美校准的分类器，MCE 和 ECE 均为 0。

负对数似然。 负对数似然是衡量概率模型质量的标准指标（Friedman et al., 2001）。在深度学习中，它也被称为交叉熵损失（Bengio et al., 2015）。给定概率模型 $\hat{\pi}(Y \mid X)$ 和 n 个样本，负对数似然（NLL）定义为：

$$\mathcal{L} = -\sum_{i=1}^{n} \log\big(\hat{\pi}(y_i \mid x_i)\big). \tag{6}$$

一个标准结论是（Friedman et al., 2001），在期望意义下，当且仅当 $\hat{\pi}(Y \mid X)$ 恢复了真实条件分布 $\pi(Y \mid X)$ 时，NLL 达到最小值。

3 观察校准不良现象

近年来，神经网络的架构和训练过程发展迅速。在本节中，我们找出了一些近期变化，它们与图 1 中观察到的校准不良现象有关。虽然我们不能断言其中存在因果关系，但我们发现，模型容量以及正则化的缺乏，与模型的校准情况密切相关。

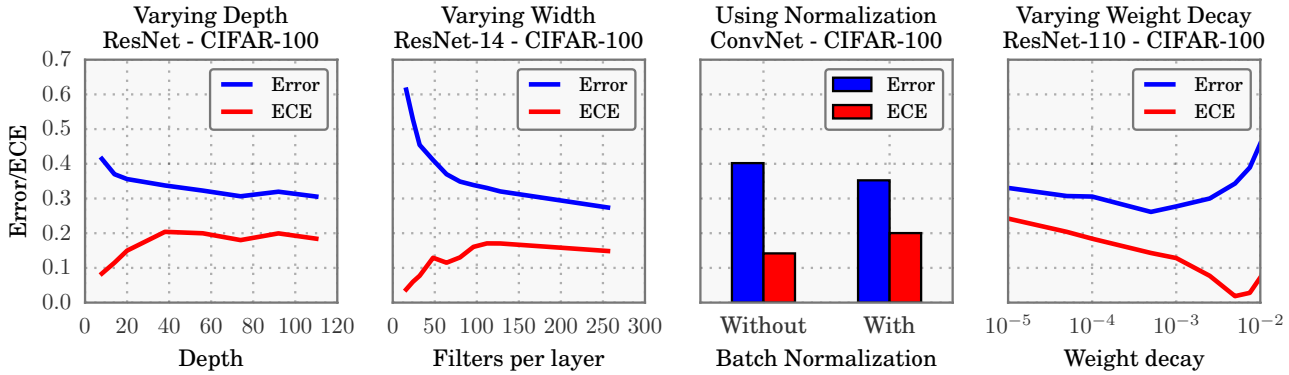


图 2: 网络深度（最左）、宽度（中左）、批量归一化（中右）以及权重衰减（最右）对校准不良程度的影响，以 ECE 衡量（越低越好）。

模型容量。 过去几年中，神经网络的模型容量以惊人的速度增长。如今，包含数百层甚至数千层的网络（He et al., 2016；Huang et al., 2016），以及每层包含数百个卷积滤波器的网络（Zagoruyko & Komodakis, 2016），都已很常见。近期研究表明，非常深或非常宽的模型比更小的模型具有更好的泛化能力，同时又具有轻松拟合训练集的能力（Zhang et al., 2017）。

尽管增加深度和宽度可能降低分类错误率，但我们观察到，这些增加会对模型校准产生负面影响。图 2 展示了在 CIFAR-100 上训练的 ResNet 的错误率和 ECE 随深度和宽度的变化。最左侧的图改变一个每层包含 64 个卷积滤波器的网络的深度；中间偏左的图则将深度固定为 14 层，并改变每层

的卷积滤波器数量。尽管图中即使最小的模型也存在一定程度的校准不良，但 ECE 指标会随模型容量增大而显著上升。在训练过程中，一旦模型能够正确分类（几乎）所有训练样本，就可以通过提高预测的置信度进一步最小化 NLL。增大模型容量将降低训练 NLL，从而使模型在平均意义上更加自信，乃至过度自信。

批量归一化。 批量归一化（Batch Normalization；Ioffe & Szegedy, 2015）通过尽量减小神经网络隐藏层内部激活值的分布偏移，改善神经网络的优化。近期研究表明，这些归一化技术促成了非常深的架构的发展，例如 ResNet（He et al., 2016）和 DenseNet（Huang et al., 2017）。已有研究表明，批量归一化可以缩短训练时间，减少对额外正则化的需求，并在某些情况下提高网络的准确率。

虽然很难确切指出批量归一化如何影响模型的最终预测，但我们的确观察到，使用批量归一化训练的模型往往具有更严重的校准不良。在图 2 中间偏右的图中，我们可以看到，使用批量归一化后，一个 6 层卷积网络的校准表现变得更差，尽管分类准确率略有提高。我们发现，无论批量归一化模型使用何种超参数（例如较低或较高的学习率等），这一结果都成立。

权重衰减。 权重衰减曾是神经网络最主要的正则化机制，但在现代神经网络的训练中，其使用正在减少。学习理论指出，正则化是防止过拟合的必要手段，尤其是在模型容量增加时（Vapnik, 1998）。然而，由于批量归一化具有明显的正则化效果，近期研究似乎表明，使用较少 L_2 正则化的模型往往泛化得更好（Ioffe & Szegedy, 2015）。因此，如今使用很小的权重衰减，甚至完全不使用权重衰减来训练模型，已十分常见。2015 年表现最好的 ImageNet 模型所使用的权重衰减，都比前些年的模型小一个数量级（He et al., 2016；Simonyan & Zisserman, 2015）。

我们发现，使用较少的权重衰减进行训练会对校准产生负面影响。图 2 最右侧的图展示了一个 110 层 ResNet 在不同权重衰减强度下的训练错误率和 ECE。其使用的其他正则化形式只有数据增强和批量归一化。我们观察到，使校准最优的参数设置与使准确率最优的参数设置并不相同。虽然就分类错误率而言，模型同时表现出正则化过强和正则化不足的情况，但过强的权重衰减似乎并不会对校准产生负面影响。即使早已超过达到最优准确率的点，继续增加正则化仍会改善模型校准。曲线末端的轻微上升，可能是使用了妨碍优化的权重衰减系数所造成的。

NLL。 NLL 可以用来间接衡量模型校准。在实践中，我们观察到 NLL 与准确率之间出现了脱节，这可能解释了图 2 中的校准不良。这种脱节之所以发生，是因为神经网络可能在 NLL 上过拟合，却不在 0/1 损失上过拟合。我们在一些校准不良模型的训练曲线中观察到了这一趋势。图 3 展示了在 CIFAR-100 上，测试错误率和 NLL（经过重新缩放以匹配错误率）随训练过程的变化。在第 250 个训练轮次降低学习率时，错误率和 NLL 都立即下降；然而，在余下的训练过程中，NLL 出现了过拟合。令人惊讶的是，NLL 上的过拟合有利于分类准确率。在 CIFAR-100 上，在 NLL 过拟合的区间内，测试错误率从 29% 降至 27%。这一现象为校准不良提供了具体解释：网络以牺牲概率建模的质量为代价，学得了更高的分类准确率。

我们可以将这一发现与近期研究大型神经网络泛化能力的工作联系起来。Zhang et al.（2017）观察到，深度神经网络似乎违反了学习理论中的通常认识，即正则化较少的大型模型无法很好地泛化。观察到的 NLL 与 0/1 损失之间的脱节表明，这些高容量模型并不一定不会过拟合；相反，过拟合体现在概率误差上，而不是分类错误率上。

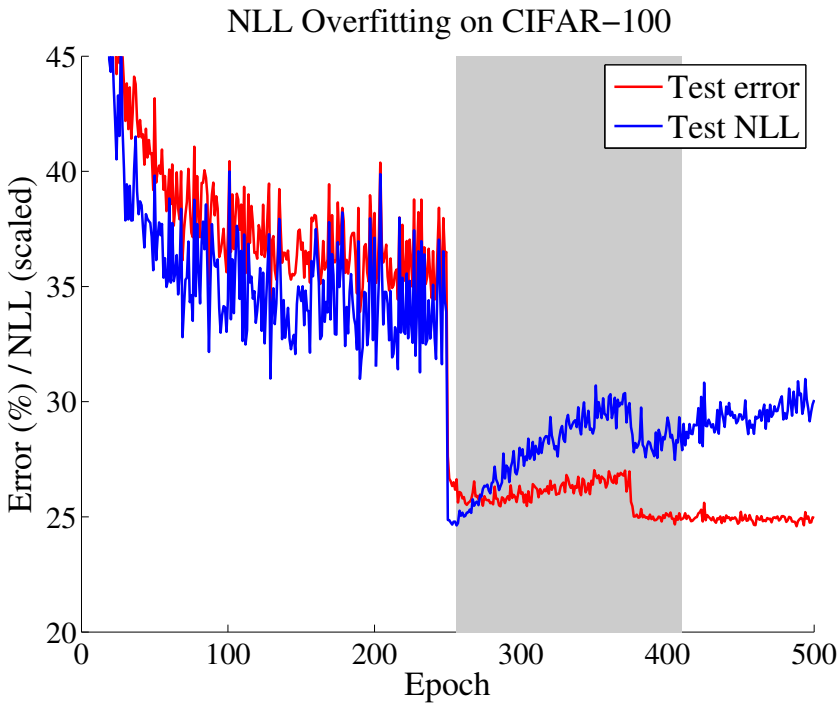


图 3: 采用随机深度的 110 层 ResNet 在 CIFAR-100 上训练期间的测试错误率与 NLL。为了适配图中的尺度，NLL 乘以了一个常数。在第 250 和第 375 个训练轮次，学习率均降低为原来的十分之一。阴影区域标示了获得最佳验证损失与最佳验证错误率的两个训练轮次之间的区间。

4 校准方法

本节首先回顾已有的校准方法，并介绍我们提出的新变体。所有方法都是后处理步骤，用来产生经过校准的概率。每种方法都需要一个留出的验证集；在实践中，可以直接使用调节超参数时所用的同一个验证集。我们假设训练集、验证集和测试集来自同一分布。

4.1 二分类模型的校准

我们首先介绍二分类情形下的校准，即 $\mathcal{Y} = \{0, 1\}$。为简便起见，本小节始终假设模型只输出正类的置信度。[1]给定样本 x_i，我们可以得到 $\hat{p}_i$，即网络预测的 $y_i = 1$ 的概率，以及 $z_i \in \mathbb{R}$，即网络的非概率输出，也称为 logit。预测概率 $\hat{p}_i$ 由 z_i 经过 sigmoid 函数 σ 得到，即 $\hat{p}_i = \sigma(z_i)$。我们的目标是根据 y_i、$\hat{p}_i$ 和 z_i 产生校准后的概率 $\hat{q}_i$。

直方图分箱（Histogram binning） (Zadrozny & Elkan, 2001) 是一种简单的非参数校准方法。简而言之，所有未经校准的预测 $\hat{p}_i$ 被划分到互斥的箱 $B_1, \ldots, B_M$ 中。每个箱被赋予一个校准后的分数 θ_m；也就是说，若 $\hat{p}_i$ 被分配到箱 B_m，则 $\hat{q}_i = \theta_m$。在测试时，若预测 $\hat{p}_{\text{te}}$ 落入箱 B_m，则校准后的预测 $\hat{q}_{\text{te}}$ 就是 θ_m。更确切地说，对于适当选定的 M（通常较小），我们首先定义箱的边界 $0 = a_1 \leq a_2 \leq \cdots \leq a_{M+1} = 1$，其中箱 B_m 由区间 $(a_m, a_{m+1}]$ 定义。通常，选取箱边界时，要么使各区间等长，要么使每个箱中的样本数量相等。选择预测值 θ_i，使逐箱的平方损失最小：

$$\min_{\theta_1,\ldots,\theta_M} \sum_{m=1}^{M} \sum_{i=1}^{n} \mathbf{1}(a_m \leq \hat{p}_i < a_{m+1})(\theta_m - y_i)^2. \tag{7}$$

其中 $\mathbf{1}$ 是示性函数。给定固定的箱边界，式 (7) 的解所得到的 θ_m，对应于箱 B_m 内正类样本指示值的平均值。

[1]这与第 2 节中的设定不同；在那里，模型同时产生类别预测和置信度。

保序回归（Isotonic regression） (Zadrozny & Elkan, 2002) 可以说是最常见的非参数校准方法，它学习一个分段常数函数 f 来变换未经校准的输出，即 $\hat{q}_i = f(\hat{p}_i)$。具体而言，保序回归求出使平方损失 $\sum_{i=1}^{n}(f(\hat{p}_i) - y_i)^2$ 最小的 f。由于 f 被约束为分段常数函数，我们可以将优化问题写成：

$$\min_{\substack{M \\ \theta_1,\ldots,\theta_M \\ a_1,\ldots,a_{M+1}}} \sum_{m=1}^{M}\sum_{i=1}^{n} \mathbf{1}(a_m \le \hat{p}_i < a_{m+1})(\theta_m - y_i)^2$$

$$\text{满足} \quad 0 = a_1 \le a_2 \le \cdots \le a_{M+1} = 1,$$
$$\theta_1 \le \theta_2 \le \cdots \le \theta_M.$$

其中 M 是区间数量，$a_1, \ldots, a_{M+1}$ 是区间边界，而 $\theta_1, \ldots, \theta_M$ 是函数值。在这种参数化下，保序回归是直方图分箱的严格推广，它联合优化箱边界和各箱的预测值。

贝叶斯分位数分箱（Bayesian Binning into Quantiles，BBQ） (Naeini et al., 2015) 是利用贝叶斯模型平均对直方图分箱进行的扩展。实质上，BBQ 将所有可能的分箱方案边缘化，以产生 $\hat{q}_i$。更形式化地说，分箱方案 s 是一个二元组 $(M, \mathcal{I})$，其中 M 是箱的数量，$\mathcal{I}$ 是相应地将 $[0,1]$ 划分为互不相交区间的划分方式（$0 = a_1 \le a_2 \le \cdots \le a_{M+1} = 1$）。一个分箱方案的参数是 $\theta_1, \ldots, \theta_M$。在这个框架下，直方图分箱和保序回归都只产生一个分箱方案，而 BBQ 考虑验证数据集 D 的所有可能分箱方案组成的空间 $\mathcal{S}$。BBQ 对各个方案产生的概率进行贝叶斯平均：[2]

$$\begin{aligned}\mathbb{P}(\hat{q}_{\text{te}} \mid \hat{p}_{\text{te}}, D) &= \sum_{s \in \mathcal{S}} \mathbb{P}(\hat{q}_{\text{te}}, S = s \mid \hat{p}_{\text{te}}, D) \\ &= \sum_{s \in \mathcal{S}} \mathbb{P}(\hat{q}_{\text{te}} \mid \hat{p}_{\text{te}}, S = s, D)\, \mathbb{P}(S = s \mid D).\end{aligned}$$

其中 $\mathbb{P}(\hat{q}_{\text{te}} \mid \hat{p}_{\text{te}}, S = s, D)$ 是采用分箱方案 s 得到的校准概率。使用均匀先验时，权重 $\mathbb{P}(S = s \mid D)$ 可由贝叶斯法则推导得到：

$$\mathbb{P}(S = s \mid D) = \frac{\mathbb{P}(D \mid S = s)}{\sum_{s' \in \mathcal{S}} \mathbb{P}(D \mid S = s')}.$$

参数 $\theta_1, \ldots, \theta_M$ 可以视为 M 个相互独立的二项分布的参数。因此，对 $\theta_1, \ldots, \theta_M$ 设定 Beta 先验后，就可以得到边缘似然 $\mathbb{P}(D \mid S = s)$ 的闭式表达式。这样，我们就能对任意测试输入计算 $\mathbb{P}(\hat{q}_{\text{te}} \mid \hat{p}_{\text{te}}, D)$。

Platt 缩放（Platt scaling） (Platt et al., 1999) 与其他方法不同，是一种参数化校准方法。它将分类器的非概率预测用作逻辑回归模型的特征，并在验证集上训练该模型，使其返回概率。具体而言，在神经网络的情境下 (Niculescu-Mizil & Caruana, 2005)，Platt 缩放学习标量参数 $a, b \in \mathbb{R}$，并输出 $\hat{q}_i = \sigma(a z_i + b)$ 作为校准后的概率。参数 a 和 b 可以通过验证集上的 NLL 损失进行优化。需要注意，在这一阶段，神经网络的参数保持固定。

4.2 向多分类模型扩展

对于涉及 $K > 2$ 个类别的分类问题，我们回到最初的问题表述。对于每个输入 x_i，网络输出类别预测 $\hat{y}_i$ 和置信度分数 $\hat{p}_i$。在这种情况下，网络的 logits $\mathbf{z}_i$ 是向量，其中 $\hat{y}_i = \text{argmax}_k\, z_i^{(k)}$，而 $\hat{p}_i$ 通常由 softmax 函数 σ_{SM} 得到：

$$\sigma_{\text{SM}}(\mathbf{z}_i)^{(k)} = \frac{\exp(z_i^{(k)})}{\sum_{j=1}^{K} \exp(z_i^{(j)})}, \qquad \hat{p}_i = \max_k \sigma_{\text{SM}}(\mathbf{z}_i)^{(k)}.$$

目标是根据 y_i、$\hat{y}_i$、$\hat{p}_i$ 和 $\mathbf{z}_i$，产生校准后的置信度 $\hat{q}_i$ 以及一个（可能是新的）类别预测 $\hat{y}_i'$。

[2] 由于验证数据集是有限的，$\mathcal{S}$ 也是有限的。

分箱方法的扩展。 将二分类校准方法扩展到多分类情形的一种常见方式，是将问题视为 K 个一对其余的分类问题 (Zadrozny & Elkan, 2002)。对于 $k = 1, \ldots, K$，我们构造一个二分类校准问题，其标签为 $\mathbf{1}(y_i = k)$，预测概率为 $\sigma_{\text{SM}}(\mathbf{z}_i)^{(k)}$。这样就得到 K 个校准模型，每个模型对应一个特定类别。测试时，我们得到未经归一化的概率向量 $[\hat{q}_i^{(1)}, \ldots, \hat{q}_i^{(K)}]$，其中 $\hat{q}_i^{(k)}$ 是类别 k 的校准后概率。新的类别预测 $\hat{y}_i'$ 是该向量的 argmax，而新的置信度 $\hat{q}_i'$ 则是用 $\sum_{k=1}^{K} \hat{q}_i^{(k)}$ 归一化后的向量最大值。这种扩展可以应用于直方图分箱、保序回归和 BBQ。

矩阵缩放和向量缩放 是 Platt 缩放的两种多分类扩展。设 $\mathbf{z}_i$ 是输入 x_i 在 softmax 层之前产生的 logits 向量。矩阵缩放对 logits 施加线性变换 $\mathbf{W}\mathbf{z}_i + \mathbf{b}$：

$$\begin{aligned} \hat{q}_i &= \max_k \sigma_{\text{SM}}(\mathbf{W}\mathbf{z}_i + \mathbf{b})^{(k)}, \\ \hat{y}_i' &= \operatorname*{argmax}_k (\mathbf{W}\mathbf{z}_i + \mathbf{b})^{(k)}. \end{aligned} \tag{8}$$

参数 $\mathbf{W}$ 和 $\mathbf{b}$ 通过验证集上的 NLL 进行优化。由于矩阵缩放的参数数量随类别数 K 呈二次增长，我们将向量缩放定义为一种变体，其中 $\mathbf{W}$ 被限制为对角矩阵。

温度缩放（Temperature scaling） 是 Platt 缩放最简单的扩展，对所有类别只使用一个标量参数 $T > 0$。给定 logits 向量 $\mathbf{z}_i$，新的置信度预测为

$$\hat{q}_i = \max_k \sigma_{\text{SM}}(\mathbf{z}_i / T)^{(k)}. \tag{9}$$

T 称为温度；当 $T > 1$ 时，它会使 softmax “软化”（即提高输出熵）。当 $T \to \infty$ 时，概率 $\hat{q}_i$ 趋近于 $1/K$，表示最大的不确定性。当 $T = 1$ 时，就恢复原始概率 $\hat{p}_i$。当 $T \to 0$ 时，概率收缩为点质量（即 $\hat{q}_i = 1$）。T 通过验证集上的 NLL 进行优化。由于参数 T 不改变 softmax 函数最大值所在的位置，类别预测 $\hat{y}_i'$ 保持不变。换句话说，温度缩放不影响模型的准确率。

温度缩放常用于知识蒸馏 (Hinton et al., 2015) 和统计力学 (Jaynes, 1957) 等情境。据我们所知，此前尚无将其用于概率模型校准的工作。[3]该模型等价于在 logits 满足某些约束的条件下，最大化输出概率分布的熵（见第 S2 节）。

4.3 其他相关工作

近年来，校准和置信度分数已经在各种情境中得到研究。Kuleshov & Ermon (2016) 研究了在线情形中的校准问题，其中输入可能来自具有对抗性的来源。Kuleshov & Liang (2015) 探讨了当输出空间是结构化对象时，如何产生校准的概率。Lakshminarayanan et al. (2016) 使用网络集成来获得不确定性估计。Pereyra et al. (2017) 将惩罚过度自信的预测作为一种正则化方式。Hendrycks & Gimpel (2017) 使用置信度分数来判断样本是否来自分布之外。

贝叶斯神经网络 (Denker & Lecun, 1990; MacKay, 1992) 返回输出的概率分布，以此作为表示模型不确定性的另一种方式。Gal & Ghahramani (2016) 建立了 Dropout (Srivastava et al., 2014) 与模型不确定性之间的联系，认为对丢弃部分节点后的模型进行采样，是针对给定样本估计所有可能模型的概率分布的一种方式。Kendall & Gal (2017) 将这种方法与一个为每个数据点输出预测均值和方差的模型相结合。这种不确定性概念并不局限于分类问题。相比之下，我们的框架不需要对模型进行采样；它返回的是给定输出的置信度，而不是可能输出的分布。

5 结果

我们将第 4 节中的校准方法应用于图像分类和文档分类神经网络。对于图像分类，我们使用以下 6 个数据集：

[3]为了突出与已有工作的联系，我们用 $1/T$ 来定义温度缩放，而不是使用一个相乘的标量。

1. **Caltech-UCSD Birds** (Welinder et al., 2010)：200 种鸟类。训练集、验证集和测试集分别包含 5994、2897 和 2897 张图像。

2. **Stanford Cars** (Krause et al., 2013)：按品牌、型号和年份划分的 196 类汽车。训练集、验证集和测试集分别包含 8041、4020 和 4020 张图像。

3. **ImageNet 2012** (Deng et al., 2009)：来自 1000 个类别的自然场景图像。训练集、验证集和测试集分别包含 130 万、25,000 和 25,000 张图像。

4. **CIFAR-10/CIFAR-100** (Krizhevsky & Hinton, 2009)：来自 10/100 个类别的彩色图像（32×32）。训练集、验证集和测试集分别包含 45,000、5,000 和 10,000 张图像。

5. **Street View House Numbers（SVHN）** (Netzer et al., 2011)：从 Google 街景中裁剪出的门牌号码的 32×32 彩色图像。训练集、验证集和测试集分别包含 604,388、6,000 和 26,032 张图像。

我们训练了最先进的卷积网络：ResNets (He et al., 2016)、带随机深度（SD）的 ResNets (Huang et al., 2016)、Wide ResNets (Zagoruyko & Komodakis, 2016) 和 DenseNets (Huang et al., 2017)。我们采用各篇论文所述的数据预处理、训练流程和超参数。对于 Birds 和 Cars，我们对在 ImageNet 上预训练的网络进行微调。

对于文档分类，我们在以下 4 个数据集上进行实验：

1. **20 News**：按内容划分为 20 个类别的新闻文章。训练集、验证集和测试集分别包含 9034、2259 和 7528 篇文档。

2. **Reuters**：按主题划分为 8 个类别的新闻文章。训练集、验证集和测试集分别包含 4388、1097 和 2189 篇文档。

3. **Stanford Sentiment Treebank（SST）** (Socher et al., 2013)：以带有情感标注的句法分析树表示的电影评论。每个样本都包含一个粗粒度的二分类标签和一个细粒度的 5 分类标签。按照 (Tai et al., 2015) 中的描述，二分类任务的训练集、验证集和测试集分别包含 6920、872 和 1821 篇文档，细粒度任务则分别包含 544、1101 和 2210 篇文档。[4]

对于 20 News 和 Reuters，我们训练深度平均网络（Deep Averaging Networks，DANs）(Iyyer et al., 2015)，网络具有 3 个前馈层，并使用批量归一化。这些网络采用原论文建议的优化超参数，取得了有竞争力的准确率。对于 SST，我们使用作者代码中的默认设置来训练 TreeLSTMs（长短期记忆网络）(Tai et al., 2015)。

校准结果。 表 1 展示了应用各种方法之前和之后，以 ECE（$M = 15$ 个箱）衡量的模型校准情况（MCE、NLL 和错误率表格见第 S3 节）。值得注意的是，大多数数据集和模型都存在一定程度的校准不良，ECE 通常在 4% 至 10% 之间。这并非特定架构才有的问题：我们在卷积网络（有或没有跳跃连接）、循环网络以及深度平均网络中都观察到了校准不良。两个值得注意的例外是 SVHN 和 Reuters，其 ECE 均低于 1%。这两个数据集的错误率都很低（分别为 1.98% 和 2.97%），因此其 ECE 与错误率之比与其他数据集相当。

[4]译注：原文在此将细粒度任务的训练集规模写作 544，疑有漏字。本译文照录该数字，不将推测的修正混入原作者论述。

表 1: 在标准视觉和自然语言处理数据集上，校准之前以及采用各种校准方法之后的 ECE（%，使用 $M = 15$ 个箱）。模型名称后面的数字表示网络深度。

数据集	模型	未校准	直方图分箱	保序回归	BBQ	温度缩放	向量缩放	矩阵缩放
Birds	ResNet 50	9.19%	4.34%	5.22%	4.12%	**1.85%**	3.0%	21.13%
Cars	ResNet 50	4.3%	**1.74%**	4.29%	1.84%	2.35%	2.37%	10.5%
CIFAR-10	ResNet 110	4.6%	0.58%	0.81%	**0.54%**	0.83%	0.88%	1.0%
CIFAR-10	ResNet 110 (SD)	4.12%	0.67%	1.11%	0.9%	**0.6%**	0.64%	0.72%
CIFAR-10	Wide ResNet 32	4.52%	0.72%	1.08%	0.74%	**0.54%**	0.6%	0.72%
CIFAR-10	DenseNet 40	3.28%	0.44%	0.61%	0.81%	**0.33%**	0.41%	0.41%
CIFAR-10	LeNet 5	3.02%	1.56%	1.85%	1.59%	**0.93%**	1.15%	1.16%
CIFAR-100	ResNet 110	16.53%	2.66%	4.99%	5.46%	**1.26%**	1.32%	25.49%
CIFAR-100	ResNet 110 (SD)	12.67%	2.46%	4.16%	3.58%	0.96%	**0.9%**	20.09%
CIFAR-100	Wide ResNet 32	15.0%	3.01%	5.85%	5.77%	**2.32%**	2.57%	24.44%
CIFAR-100	DenseNet 40	10.37%	2.68%	4.51%	3.59%	1.18%	**1.09%**	21.87%
CIFAR-100	LeNet 5	4.85%	6.48%	2.35%	3.77%	**2.02%**	2.09%	13.24%
ImageNet	DenseNet 161	6.28%	4.52%	5.18%	3.51%	**1.99%**	2.24%	-
ImageNet	ResNet 152	5.48%	4.36%	4.77%	3.56%	**1.86%**	2.23%	-
SVHN	ResNet 152 (SD)	0.44%	**0.14%**	0.28%	0.22%	0.17%	0.27%	0.17%
20 News	DAN 3	8.02%	**3.6%**	5.52%	4.98%	4.11%	4.61%	9.1%
Reuters	DAN 3	0.85%	1.75%	1.15%	0.97%	0.91%	**0.66%**	1.58%
SST 二分类	TreeLSTM	6.63%	1.93%	**1.65%**	2.27%	1.84%	1.84%	1.84%
SST 细粒度	TreeLSTM	6.71%	2.09%	**1.65%**	2.61%	2.56%	2.98%	2.39%

我们最重要的发现是，温度缩放尽管极为简单，却有着出人意料的效果。在视觉任务上，温度缩放优于所有其他方法，在 NLP 数据集上，其表现也与其他方法相当。也许更令人惊讶的是，温度缩放优于 Platt 缩放的向量和矩阵变体，而后两者严格来说是更一般的方法。事实上，向量缩放本质上得到了与温度缩放相同的解：学到的向量各分量几乎为常数，因此与标量变换没有区别。换句话说，网络校准不良本质上是低维的。

温度缩放唯一未能实现校准的数据集是 Reuters。在这一情形中，上述方法中只有一种能够改善校准。由于该数据集原本就已经校准良好（ECE $\leq 1\%$），任何方法都没有太大的改进空间，甚至一开始就可能没有必要进行后处理。我们的测量也可能受到数据集划分方式或特定分箱方案的影响。

矩阵缩放在具有数百个类别的数据集（即 Birds、Cars 和 CIFAR-100）上表现不佳，并且在有 1000 个类别的 ImageNet 数据集上无法收敛。这是意料之中的，因为其参数数量随类别数量呈二次增长。任何拥有数万个（或更多）参数的校准模型，即使采用正则化，也会对小规模验证集产生过拟合。

分箱方法能够改善大多数数据集上的校准，但并不优于温度缩放。此外，分箱方法往往会改变类别预测，从而损害准确率（见第 S3 节）。直方图分箱是最简单的分箱方法，通常优于保序回归和 BBQ，尽管后两种方法严格来说都更一般。这进一步支持了我们的发现：简单模型最适合用来纠正校准。

可靠性图。 图 4 展示了 CIFAR-100 上 110 层 ResNet 在校准之前和之后的可靠性图。从最左侧的图中可以看出，未经校准的 ResNet 的预测往往过于自信。随后，我们可以观察到温度缩放（中左）、直方图分箱（中右）和保序回归（最右）对校准的影响。图中展示的三种方法都产生了好得多的置信度估计。在这三种方法中，温度缩放最接近恢复出我们期望的对角线函数。每个箱都得到了良好校准；考虑到所有概率仅由一个参数加以修改，这一结果十分显著。其他数据集的可靠性图见第 S4 节。

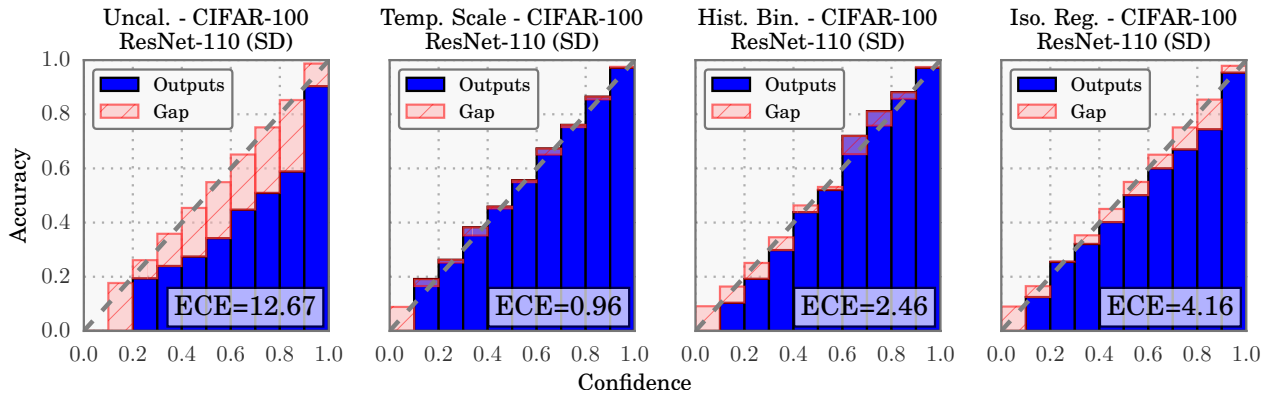


图 4: CIFAR-100 在校准之前（最左）和校准之后（中左、中右、最右）的可靠性图。

计算时间。 所有方法的计算量均随验证集样本数量线性增长。温度缩放是迄今为止最快的方法，因为它归结为一个一维凸优化问题。使用共轭梯度求解器，只需 10 次迭代就能找到最优温度，在大多数现代硬件上耗时不到一秒。事实上，即使采用朴素的线搜索来寻找最优温度，也比其他任何方法都快。向量缩放和矩阵缩放的计算复杂度分别随类别数量线性增长和二次增长，这反映了各方法的参数数量。对于 CIFAR-100（$K = 100$），使用共轭梯度下降寻找向量缩放的近似最优解，耗时至少多两个数量级。直方图分箱和保序回归的耗时比温度缩放多一个数量级，而 BBQ 的耗时则大约多三个数量级。

译注： 本段所称的一维凸优化，严格说是针对逆温度 $\beta = 1/T$ 而言：NLL 关于 β 为凸函数，并不意味着它关于 T 本身也必然为凸函数。

实现的简便性。 BBQ 可以说是最难实现的方法，因为它需要实现一个模型平均方案。其他所有方法都相对容易实现，而温度缩放可以说是最容易纳入神经网络流程的方法。例如，在 Torch7 (Collobert et al., 2011) 中，我们通过在 logits 与 softmax 之间插入一个参数为 $1/T$ 的 `nn.MulConstant` 来实现温度缩放。训练时我们设定 $T = 1$，随后在验证集上寻找其最优值。

6 结论

现代神经网络呈现出一种奇特的现象：即便分类错误率在降低，概率误差和校准不良程度却在加剧。我们已经表明，神经网络架构和训练方面近年来的进展，包括模型容量、归一化和正则化，都会对网络校准产生显著影响。为什么这些趋势在提高准确率的同时会影响校准，仍有待未来的研究来理解。尽管如此，简单的技术就能有效补救神经网络中的校准不良现象。在这些方法中，温度缩放最简单、最快，也最直接，而且令人惊讶的是，它通常也是最有效的。

致谢

作者的研究部分得到美国国家科学基金会 III-1618134、III-1526012 和 IIS-1149882 项目的资助，以及比尔及梅琳达·盖茨基金会和美国海军研究办公室的支持。

参考文献

文献的作者、原题名、发表信息与年份按原文保留；方括号内为题名中译，便于检索和对照。原文自身的著录信息未作推测性补全。

1. Bengio, Yoshua, Goodfellow, Ian J, and Courville, Aaron. Deep learning. Nature, 521:436–444, 2015.

   ［深度学习］

2. Bojarski, Mariusz, Del Testa, Davide, Dworakowski, Daniel, Firner, Bernhard, Flepp, Beat, Goyal, Prasoon, Jackel, Lawrence D, Monfort, Mathew, Muller, Urs, Zhang, Jiakai, et al. End to end learning for self-driving cars. arXiv preprint arXiv:1604.07316, 2016.

   ［用于自动驾驶汽车的端到端学习］

3. Caruana, Rich, Lou, Yin, Gehrke, Johannes, Koch, Paul, Sturm, Marc, and Elhadad, Noemie. Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission. In KDD, 2015.

   ［可理解的医疗模型：预测肺炎风险和30天内再次住院］

4. Collobert, Ronan, Kavukcuoglu, Koray, and Farabet, Clément. Torch7: A matlab-like environment for machine learning. In BigLearn Workshop, NIPS, 2011.

   ［Torch7：面向机器学习的类 MATLAB 环境］

5. Cosmides, Leda and Tooby, John. Are humans good intuitive statisticians after all? rethinking some conclusions from the literature on judgment under uncertainty. cognition, 58(1):1–73, 1996.

   ［人类究竟是否善于直觉统计？重新审视不确定性判断文献中的一些结论］

6. DeGroot, Morris H and Fienberg, Stephen E. The comparison and evaluation of forecasters. The statistician, pp. 12–22, 1983.

   ［预测者的比较与评估］

7. Deng, Jia, Dong, Wei, Socher, Richard, Li, Li-Jia, Li, Kai, and Fei-Fei, Li. Imagenet: A large-scale hierarchical image database. In CVPR, pp. 248–255, 2009.

   ［ImageNet：大规模层次化图像数据库］

8. Denker, John S and Lecun, Yann. Transforming neural-net output levels to probability distributions. In NIPS, pp. 853–859, 1990.

   ［将神经网络输出值转换为概率分布］

9. Friedman, Jerome, Hastie, Trevor, and Tibshirani, Robert. The elements of statistical learning, volume 1. Springer series in statistics Springer, Berlin, 2001.

   ［统计学习要素］

10. Gal, Yarin and Ghahramani, Zoubin. Dropout as a bayesian approximation: Representing model uncertainty in deep learning. In ICML, 2016.

［将 Dropout 视为贝叶斯近似：表示深度学习中的模型不确定性］

11. Girshick, Ross. Fast r-cnn. In ICCV, pp. 1440–1448, 2015.

［Fast R-CNN］

12. Hannun, Awni, Case, Carl, Casper, Jared, Catanzaro, Bryan, Diamos, Greg, Elsen, Erich, Prenger, Ryan, Satheesh, Sanjeev, Sengupta, Shubho, Coates, Adam, et al. Deep speech: Scaling up end-to-end speech recognition. arXiv preprint arXiv:1412.5567, 2014.

［Deep Speech：扩展端到端语音识别］

13. He, Kaiming, Zhang, Xiangyu, Ren, Shaoqing, and Sun, Jian. Deep residual learning for image recognition. In CVPR, pp. 770–778, 2016.

［用于图像识别的深度残差学习］

14. Hendrycks, Dan and Gimpel, Kevin. A baseline for detecting misclassified and out-of-distribution examples in neural networks. In ICLR, 2017.

［检测神经网络误分类样本和分布外样本的基线方法］

15. Hinton, Geoffrey, Vinyals, Oriol, and Dean, Jeff. Distilling the knowledge in a neural network. 2015.

［蒸馏神经网络中的知识］

16. Huang, Gao, Sun, Yu, Liu, Zhuang, Sedra, Daniel, and Weinberger, Kilian. Deep networks with stochastic depth. In ECCV, 2016.

［具有随机深度的深度网络］

17. Huang, Gao, Liu, Zhuang, Weinberger, Kilian Q, and van der Maaten, Laurens. Densely connected convolutional networks. In CVPR, 2017.

［密集连接的卷积网络］

18. Ioffe, Sergey and Szegedy, Christian. Batch normalization: Accelerating deep network training by reducing internal covariate shift. 2015.

［批归一化：通过减少内部协变量偏移加速深度网络训练］

19. Iyyer, Mohit, Manjunatha, Varun, Boyd-Graber, Jordan, and Daumé III, Hal. Deep unordered composition rivals syntactic methods for text classification. In ACL, 2015.

［深度无序组合在文本分类上可媲美句法方法］

20. Jaynes, Edwin T. Information theory and statistical mechanics. Physical review, 106(4):620, 1957.

［信息论与统计力学］

21. Jiang, Xiaoqian, Osl, Melanie, Kim, Jihoon, and Ohno-Machado, Lucila. Calibrating predictive model estimates to support personalized medicine. Journal of the American Medical Informatics Association, 19(2):263–274, 2012.

［校准预测模型的估计以支持个性化医疗］

22. Kendall, Alex and Cipolla, Roberto. Modelling uncertainty in deep learning for camera relocalization. 2016.

［用于相机重定位的深度学习不确定性建模］

23. Kendall, Alex and Gal, Yarin. What uncertainties do we need in bayesian deep learning for computer vision? arXiv preprint arXiv:1703.04977, 2017.

［计算机视觉中的贝叶斯深度学习需要哪些不确定性？］

24. Krause, Jonathan, Stark, Michael, Deng, Jia, and Fei-Fei, Li. 3d object representations for fine-grained categorization. In IEEE Workshop on 3D Representation and Recognition (3dRR), Sydney, Australia, 2013.

［用于细粒度分类的三维物体表示］

25. Krizhevsky, Alex and Hinton, Geoffrey. Learning multiple layers of features from tiny images, 2009.

［从微小图像学习多层特征］

26. Kuleshov, Volodymyr and Ermon, Stefano. Reliable confidence estimation via online learning. arXiv preprint arXiv:1607.03594, 2016.

［通过在线学习进行可靠的置信度估计］

27. Kuleshov, Volodymyr and Liang, Percy. Calibrated structured prediction. In NIPS, pp. 3474–3482, 2015.

［经过校准的结构化预测］

28. Lakshminarayanan, Balaji, Pritzel, Alexander, and Blundell, Charles. Simple and scalable predictive uncertainty estimation using deep ensembles. arXiv preprint arXiv:1612.01474, 2016.

［利用深度集成进行简单且可扩展的预测不确定性估计］

29. LeCun, Yann, Bottou, Léon, Bengio, Yoshua, and Haffner, Patrick. Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11):2278– 2324, 1998.

［基于梯度的学习在文档识别中的应用］

30. MacKay, David JC. A practical bayesian framework for backpropagation networks. Neural computation, 4(3): 448–472, 1992.

［反向传播网络的实用贝叶斯框架］

31. Naeini, Mahdi Pakdaman, Cooper, Gregory F, and Hauskrecht, Milos. Obtaining well calibrated probabilities using bayesian binning. In AAAI, pp. 2901, 2015.

［利用贝叶斯分箱获得良好校准的概率］

32. Netzer, Yuval, Wang, Tao, Coates, Adam, Bissacco, Alessandro, Wu, Bo, and Ng, Andrew Y. Reading digits in natural images with unsupervised feature learning. In Deep Learning and Unsupervised Feature Learning Workshop, NIPS, 2011.

［利用无监督特征学习读取自然图像中的数字］

33. Niculescu-Mizil, Alexandru and Caruana, Rich. Predicting good probabilities with supervised learning. In ICML, pp. 625–632, 2005.

［利用监督学习预测良好的概率］

34. Pereyra, Gabriel, Tucker, George, Chorowski, Jan, Kaiser, Łukasz, and Hinton, Geoffrey. Regularizing neural networks by penalizing confident output distributions. arXiv preprint arXiv:1701.06548, 2017.

［通过惩罚高置信度输出分布对神经网络进行正则化］

35. Platt, John et al. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. Advances in large margin classifiers, 10(3): 61–74, 1999.

［支持向量机的概率输出及其与正则化似然方法的比较］

36. Simonyan, Karen and Zisserman, Andrew. Very deep convolutional networks for large-scale image recognition. In ICLR, 2015.

［用于大规模图像识别的超深卷积网络］

37. Socher, Richard, Perelygin, Alex, Wu, Jean, Chuang, Jason, Manning, Christopher D., Ng, Andrew, and Potts, Christopher. Recursive deep models for semantic compositionality over a sentiment treebank. In EMNLP, pp. 1631–1642, 2013.

［面向情感树库中语义组合性的递归深度模型］

38. Srivastava, Nitish, Hinton, Geoffrey, Krizhevsky, Alex, Sutskever, Ilya, and Salakhutdinov, Ruslan. Dropout: A simple way to prevent neural networks from overfitting. Journal of Machine Learning Research, 15:1929–1958, 2014.

［Dropout：防止神经网络过拟合的简单方法］

39. Srivastava, Rupesh Kumar, Greff, Klaus, and Schmidhuber, Jürgen. Highway networks. arXiv preprint arXiv:1505.00387, 2015.

［高速公路网络］

40. Tai, Kai Sheng, Socher, Richard, and Manning, Christopher D. Improved semantic representations from tree-structured long short-term memory networks. 2015.

［利用树结构长短期记忆网络改进语义表示］

41. Vapnik, Vladimir N. Statistical Learning Theory. Wiley-Interscience, 1998.

［统计学习理论］

42. Welinder, P., Branson, S., Mita, T., Wah, C., Schroff, F., Belongie, S., and Perona, P. Caltech-UCSD Birds 200. Technical Report CNS-TR-2010-001, California Institute of Technology, 2010.

［Caltech-UCSD Birds 200］

43. Xiong, Wayne, Droppo, Jasha, Huang, Xuedong, Seide, Frank, Seltzer, Mike, Stolcke, Andreas, Yu, Dong, and Zweig, Geoffrey. Achieving human parity in conversational speech recognition. arXiv preprint arXiv:1610.05256, 2016.

［在对话式语音识别中达到人类水平］

44. Zadrozny, Bianca and Elkan, Charles. Obtaining calibrated probability estimates from decision trees and naive bayesian classifiers. In ICML, pp. 609–616, 2001.

［从决策树和朴素贝叶斯分类器获得校准的概率估计］

45. Zadrozny, Bianca and Elkan, Charles. Transforming classifier scores into accurate multiclass probability estimates. In KDD, pp. 694–699, 2002.

［将分类器分数转换为准确的多类概率估计］

46. Zagoruyko, Sergey and Komodakis, Nikos. Wide residual networks. In BMVC, 2016.

［宽残差网络］

47. Zhang, Chiyuan, Bengio, Samy, Hardt, Moritz, Recht, Benjamin, and Vinyals, Oriol. Understanding deep learning requires rethinking generalization. In ICLR, 2017.

［理解深度学习需要重新思考泛化］

补充材料：《现代神经网络的校准问题》

S1. 校准指标的进一步说明

我们可以将 ECE 指标与精确的校准不良定义联系起来。这里重述该定义：

$$\mathbb{E}_{\widehat{P}}\Big[\Big|\mathbb{P}\Big(\widehat{Y}=Y \mid \widehat{P}=p\Big)-p\Big|\Big].$$

令 $F_{\widehat{P}}(p)$ 为 $\widehat{P}$ 的累积分布函数，使得 $F_{\widehat{P}}(b)-F_{\widehat{P}}(a)=\mathbb{P}(\widehat{P}\in[a,b])$。 利用黎曼–斯蒂尔切斯积分，有

$$\begin{aligned}
&\mathbb{E}_{\widehat{P}}\Big[\Big|\mathbb{P}\Big(\widehat{Y}=Y \mid \widehat{P}=p\Big)-p\Big|\Big] \\
&\quad=\int_0^1\Big|\mathbb{P}\Big(\widehat{Y}=Y \mid \widehat{P}=p\Big)-p\Big|\,\mathrm{d}F_{\widehat{P}}(p) \\
&\quad\approx\sum_{m=1}^{M}\Big|\mathbb{P}\Big(\widehat{Y}=Y \mid \widehat{P}=p_m\Big)-p_m\Big|\,\mathbb{P}(\widehat{P}\in I_m).
\end{aligned}$$

其中 I_m 表示分箱 B_m 对应的区间。当 n 足够大时，$|\operatorname{acc}(B_m)-\widehat{p}(B_m)|$ 能够很好地近似 $|\mathbb{P}(\widehat{Y}=Y \mid \widehat{P}=p_m)-p_m|$。 因此，采用 M 个分箱的 ECE 收敛于

$$\mathbb{E}_{\widehat{P}}\Big[\Big|\mathbb{P}\Big(\widehat{Y}=Y \mid \widehat{P}=p\Big)-p\Big|\Big]$$

的含 M 项的黎曼–斯蒂尔切斯和。

S2. 温度缩放的进一步说明

这里，我们利用熵最大化原理，并结合一个适当的平衡方程，推导温度缩放模型。

命题 1. 给定 n 个样本的 logit 向量 $\mathbf{z}_1,\dots,\mathbf{z}_n$ 及其类别标签 $y_1,\dots,y_n$，温度缩放是下述熵最大化问题的唯一解 q：

$$\begin{aligned}
\max_{q}\quad & -\sum_{i=1}^{n}\sum_{k=1}^{K} q(\mathbf{z}_i)^{(k)}\log q(\mathbf{z}_i)^{(k)} \\
\text{满足}\quad & q(\mathbf{z}_i)^{(k)}\geq 0 \qquad \forall i,k, \\
& \sum_{k=1}^{K} q(\mathbf{z}_i)^{(k)}=1 \qquad \forall i, \\
& \sum_{i=1}^{n} z_i^{(y_i)}=\sum_{i=1}^{n}\sum_{k=1}^{K} z_i^{(k)} q(\mathbf{z}_i)^{(k)}.
\end{aligned}$$

前两个约束保证 q 是概率分布，最后一个约束则限制了分布的范围。 直观地说，该约束规定：真实类别 logit 的平均值等于加权 logit 的平均值。

证明. 我们利用拉格朗日函数求解这一约束优化问题。首先忽略非负性约束 $q(\mathbf{z}_i)^{(k)}\geq 0$，稍后再说明解满足这一条件。 令 $\lambda,\beta_1,\dots,\beta_n\in\mathbb{R}$ 为拉格朗日乘子，定义

$$\begin{aligned}
L=\ & -\sum_{i=1}^{n}\sum_{k=1}^{K} q(\mathbf{z}_i)^{(k)}\log q(\mathbf{z}_i)^{(k)} \\
& +\lambda\sum_{i=1}^{n}\left[\sum_{k=1}^{K} z_i^{(k)} q(\mathbf{z}_i)^{(k)}-z_i^{(y_i)}\right] \\
& +\sum_{i=1}^{n}\beta_i\sum_{k=1}^{K}\Big(q(\mathbf{z}_i)^{(k)}-1\Big).
\end{aligned}$$

对 $q(\mathbf{z}_i)^{(k)}$ 求导得

$$\frac{\partial L}{\partial q(\mathbf{z}_i)^{(k)}} = -nK - \log q(\mathbf{z}_i)^{(k)} + \lambda z_i^{(k)} + \beta_i.$$

令拉格朗日函数 L 的梯度为 0，整理得到

$$q(\mathbf{z}_i)^{(k)} = e^{\lambda z_i^{(k)} + \beta_i - nK}.$$

由于对所有 i 都有 $\sum_{k=1}^{K} q(\mathbf{z}_i)^{(k)} = 1$，因此必有

$$q(\mathbf{z}_i)^{(k)} = \frac{e^{\lambda z_i^{(k)}}}{\sum_{j=1}^{K} e^{\lambda z_i^{(j)}}}.$$

令 $T = \frac{1}{\lambda}$，便得到温度缩放模型。 □

译者提示：以上拉格朗日函数、导数及指数式保留原文写法；其中的排印问题及 T 的取值限制见本补充材料末尾的译者校注。

图 S1 对命题 1 作了可视化展示。我们看到，随着训练继续，模型开始在 NLL 上过拟合（红线）。这会产生一个低熵的类别 softmax 分布（蓝线），从而解释了模型的过度自信。温度缩放不仅降低了 NLL，也提高了分布的熵（绿线）。

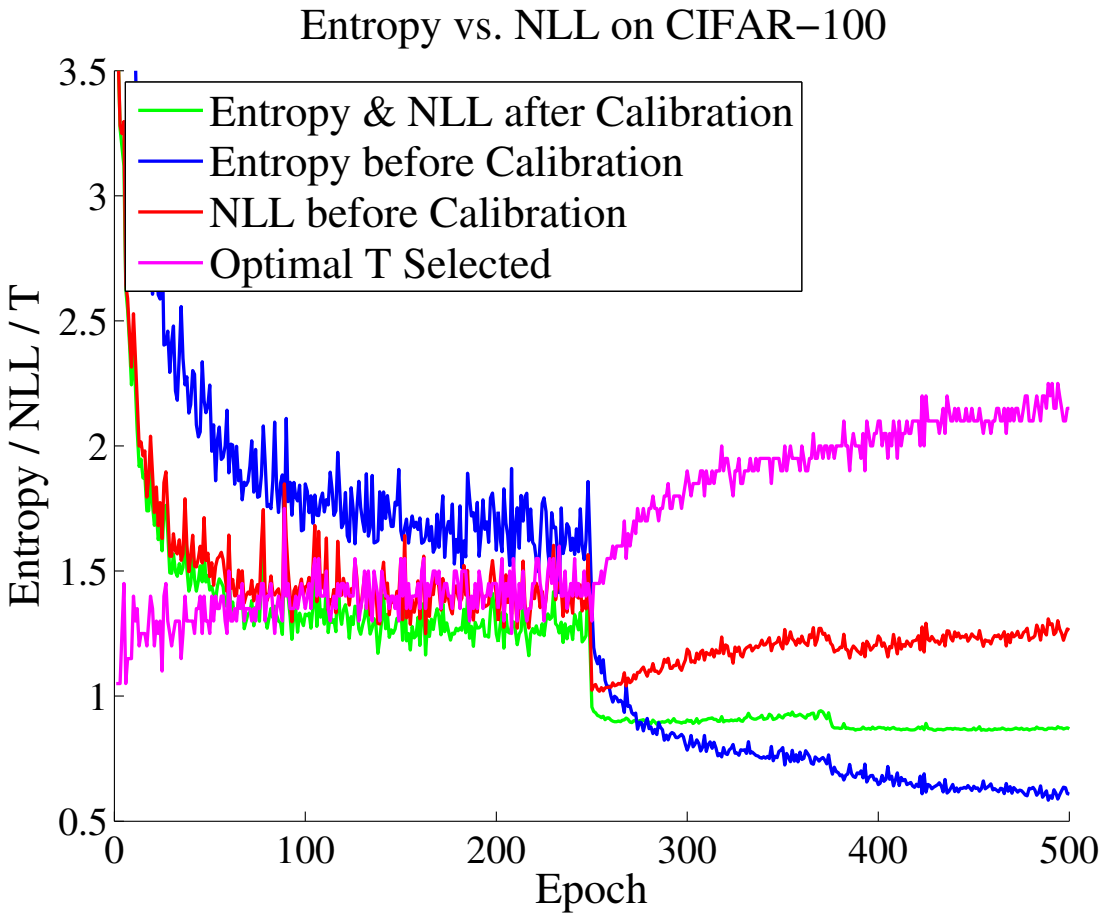


图 S1: CIFAR-100 上校准前后的熵与 NLL。随着校准前的熵持续降低，温度缩放选择的最优 T 在整个优化过程中不断增大。校准后的熵与 NLL 在验证集上重合（这可以由 T 的一阶最优性条件推导得到）。

图中文字对照： Entropy vs. NLL on CIFAR-100：CIFAR-100 上的熵与 NLL； Entropy / NLL / T：熵 / 负对数似然 / 温度；Epoch：训练轮次； Entropy & NLL after Calibration：校准后的熵与 NLL；Entropy before Calibration：校准前的熵；NLL before Calibration：校准前的 NLL； Optimal T Selected：所选择的最优 T。

S3. 补充表格

表 S1、S2 和 S3 展示了正文第 5 节所述全部实验设置下的 MCE、测试错误率和 NLL。

表中名称说明： Birds：鸟类数据集；Cars：汽车数据集； 20 News：20 类新闻组数据集；SST 二分类对应 SST Binary，SST 细粒度对应 SST Fine Grained； SD 表示随机深度（stochastic depth）； BBQ 表示贝叶斯分位数分箱（Bayesian Binning into Quantiles）。 模型名称及其深度保留原文标识。粗体为各行最小值；短横线保留原文的未报告项。

数据集	模型	未校准	直方图分箱	保序回归	BBQ	温度缩放	向量缩放	矩阵缩放
Birds	ResNet 50	30.06%	25.35%	16.59%	11.72%	**9.08%**	9.81%	38.67%
Cars	ResNet 50	41.55%	**5.16%**	15.23%	9.31%	20.23%	8.59%	29.65%
CIFAR-10	ResNet 110	33.78%	26.87%	**7.8%**	72.64%	8.56%	27.39%	22.89%
CIFAR-10	ResNet 110 (SD)	34.52%	17.0%	16.45%	19.26%	15.45%	15.55%	**10.74%**
CIFAR-10	Wide ResNet 32	27.97%	12.19%	6.19%	9.22%	9.11%	**4.43%**	9.65%
CIFAR-10	DenseNet 40	22.44%	7.77%	19.54%	14.57%	4.58%	**3.17%**	4.36%
CIFAR-10	LeNet 5	8.02%	16.49%	18.34%	82.35%	**5.14%**	19.39%	16.89%
CIFAR-100	ResNet 110	35.5%	7.03%	10.36%	10.9%	4.74%	**2.5%**	45.62%
CIFAR-100	ResNet 110 (SD)	26.42%	9.12%	10.95%	9.12%	**8.85%**	**8.85%**	35.6%
CIFAR-100	Wide ResNet 32	33.11%	6.22%	14.87%	11.88%	**5.33%**	6.31%	44.73%
CIFAR-100	DenseNet 40	21.52%	9.36%	10.59%	**8.67%**	19.4%	8.82%	38.64%
CIFAR-100	LeNet 5	10.25%	18.61%	**3.64%**	9.96%	5.22%	8.65%	18.77%
ImageNet	DenseNet 161	14.07%	13.14%	11.57%	10.96%	12.29%	**9.61%**	-
ImageNet	ResNet 152	12.2%	14.57%	**8.74%**	8.85%	12.29%	9.61%	-
SVHN	ResNet 152 (SD)	19.36%	11.16%	18.67%	**9.09%**	18.05%	30.78%	18.76%
20 News	DAN 3	17.03%	10.47%	9.13%	**6.28%**	8.21%	8.24%	17.43%
Reuters	DAN 3	**14.01%**	16.78%	44.95%	36.18%	25.46%	18.88%	19.39%
SST 二分类	TreeLSTM	21.66%	**3.22%**	13.91%	36.43%	6.03%	6.03%	6.03%
SST 细粒度	TreeLSTM	27.85%	28.35%	19.0%	**8.67%**	44.75%	11.47%	11.78%

表 S1: 标准视觉与自然语言处理数据集上，校准前及使用不同校准方法后的 MCE（%，采用 $M = 15$ 个分箱）。模型名称后的数字表示网络深度。MCE 似乎对分箱方式非常敏感，不太适用于较小的测试集。

数据集	模型	未校准	直方图分箱	保序回归	BBQ	温度缩放	向量缩放	矩阵缩放
Birds	ResNet 50	**22.54%**	55.02%	23.37%	37.76%	**22.54%**	22.99%	29.51%
Cars	ResNet 50	14.28%	16.24%	14.9%	19.25%	14.28%	**14.15%**	17.98%
CIFAR-10	ResNet 110	**6.21%**	6.45%	6.36%	6.25%	**6.21%**	6.37%	6.42%
CIFAR-10	ResNet 110 (SD)	5.64%	5.59%	5.62%	**5.55%**	5.64%	5.62%	5.69%
CIFAR-10	Wide ResNet 32	**6.96%**	7.3%	7.01%	7.35%	**6.96%**	7.1%	7.27%
CIFAR-10	DenseNet 40	**5.91%**	6.12%	5.96%	6.0%	**5.91%**	5.96%	6.0%
CIFAR-10	LeNet 5	15.57%	15.63%	15.69%	15.64%	15.57%	**15.53%**	15.81%
CIFAR-100	ResNet 110	27.83%	34.78%	28.41%	28.56%	27.83%	**27.82%**	38.77%
CIFAR-100	ResNet 110 (SD)	**24.91%**	33.78%	25.42%	25.17%	**24.91%**	24.99%	35.09%
CIFAR-100	Wide ResNet 32	**28.0%**	34.29%	28.61%	29.08%	**28.0%**	28.45%	37.4%
CIFAR-100	DenseNet 40	26.45%	34.78%	26.73%	26.4%	26.45%	**26.25%**	36.14%
CIFAR-100	LeNet 5	**44.92%**	54.06%	45.77%	46.82%	**44.92%**	45.53%	52.44%
ImageNet	DenseNet 161	22.57%	48.32%	23.2%	47.58%	22.57%	**22.54%**	-
ImageNet	ResNet 152	**22.31%**	48.1%	22.94%	47.6%	**22.31%**	22.56%	-
SVHN	ResNet 152 (SD)	**1.98%**	2.06%	2.04%	2.04%	**1.98%**	2.0%	2.08%
20 News	DAN 3	20.06%	25.12%	20.29%	20.81%	20.06%	**19.89%**	22.0%
Reuters	DAN 3	2.97%	7.81%	3.52%	3.93%	2.97%	**2.83%**	3.52%
SST 二分类	TreeLSTM	11.81%	12.08%	11.75%	**11.26%**	11.81%	11.81%	11.81%
SST 细粒度	TreeLSTM	49.5%	49.91%	48.55%	49.86%	49.5%	49.77%	**48.51%**

表 S2: 标准视觉与自然语言处理数据集上，校准前及使用不同校准方法后的测试错误率（%）。模型名称后的数字表示网络深度。温度缩放的错误率与未校准时完全相同。

数据集	模型	未校准	直方图分箱	保序回归	BBQ	温度缩放	向量缩放	矩阵缩放
Birds	ResNet 50	0.9786	1.6226	1.4128	1.2539	**0.8792**	0.9021	2.334
Cars	ResNet 50	0.5488	0.7977	0.8793	0.6986	0.5311	**0.5299**	1.0206
CIFAR-10	ResNet 110	0.3285	0.2532	0.2237	0.263	0.2102	0.2088	**0.2048**
CIFAR-10	ResNet 110 (SD)	0.2959	0.2027	0.1867	0.2159	0.1718	**0.1709**	0.1766
CIFAR-10	Wide ResNet 32	0.3293	0.2778	0.2428	0.2774	0.2283	0.2275	**0.2229**
CIFAR-10	DenseNet 40	0.2228	0.212	0.1969	0.2087	**0.1750**	0.1757	0.176
CIFAR-10	LeNet 5	0.4688	0.529	0.4757	0.4984	0.459	**0.4568**	0.4607
CIFAR-100	ResNet 110	1.4978	1.4379	1.207	1.5466	**1.0442**	1.0485	2.5637
CIFAR-100	ResNet 110 (SD)	1.1157	1.1985	1.0317	1.1982	**0.8613**	0.8655	1.8182
CIFAR-100	Wide ResNet 32	1.3434	1.4499	1.2086	1.459	**1.0565**	1.0648	2.5507
CIFAR-100	DenseNet 40	1.0134	1.2156	1.0615	1.1572	0.9026	**0.9011**	1.9639
CIFAR-100	LeNet 5	1.6639	2.2574	1.8173	1.9893	**1.6560**	1.6648	2.1405
ImageNet	DenseNet 161	0.9338	1.4716	1.1912	1.4272	0.8885	**0.8879**	-
ImageNet	ResNet 152	0.8961	1.4507	1.1859	1.3987	**0.8657**	0.8742	-
SVHN	ResNet 152 (SD)	0.0842	0.1137	0.095	0.1062	**0.0821**	0.0844	0.0924
20 News	DAN 3	0.7949	1.0499	0.8968	0.9519	0.7387	**0.7296**	0.9089
Reuters	DAN 3	0.102	0.2403	0.1475	0.1167	0.0994	**0.0990**	0.1491
SST 二分类	TreeLSTM	0.3367	0.2842	0.2908	0.2778	**0.2739**	**0.2739**	**0.2739**
SST 细粒度	TreeLSTM	1.1475	1.1717	1.1661	1.149	1.1168	**1.1085**	1.1112

表 S3: 标准视觉与自然语言处理数据集上，校准前及使用不同校准方法后的 NLL（%，沿用原文表题；单位问题见译者校注）。模型名称后的数字表示网络深度。总体而言，NLL 的变化趋势与 ECE 大体一致。

S4. 更多可靠性图

我们补充了其他数据集的可靠性图：CIFAR-10（图 S2）与 SST（图 S3 和图 S4）。 请注意，正如正文第 2 节所述，可靠性图并不表示落入某一分箱的预测所占的比例。

图 S2–S4 的共用文字对照： Accuracy：准确率；Confidence：置信度；Outputs：模型输出（各分箱的准确率）； Gap：差距（置信度与准确率之差）；ECE：期望校准误差； Uncal.：未校准；Temp. Scale：温度缩放；Hist. Bin.：直方图分箱；Iso. Reg.：保序回归。 SST-FG：SST 细粒度分类；SST-BIN：SST 二分类；Tree LSTM：树结构 LSTM； ResNet-110 (SD)：采用随机深度的 110 层 ResNet。

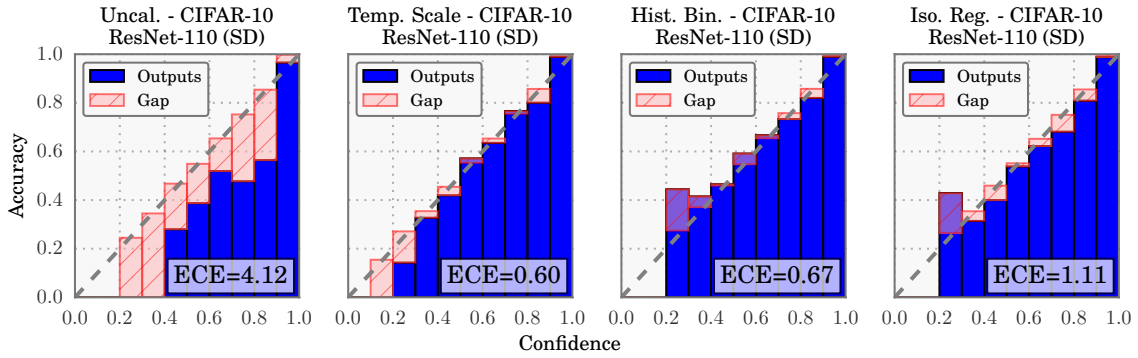


图 S2: CIFAR-10 上校准前（最左）及校准后（中左、中右、最右）的可靠性图。

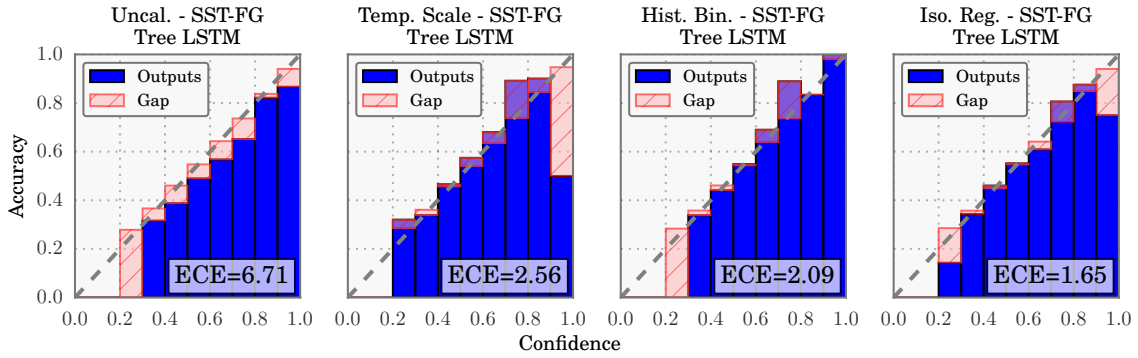


图 S3: SST 二分类与 SST 细粒度分类上校准前（最左）及校准后（中左、中右、最右）的可靠性图。

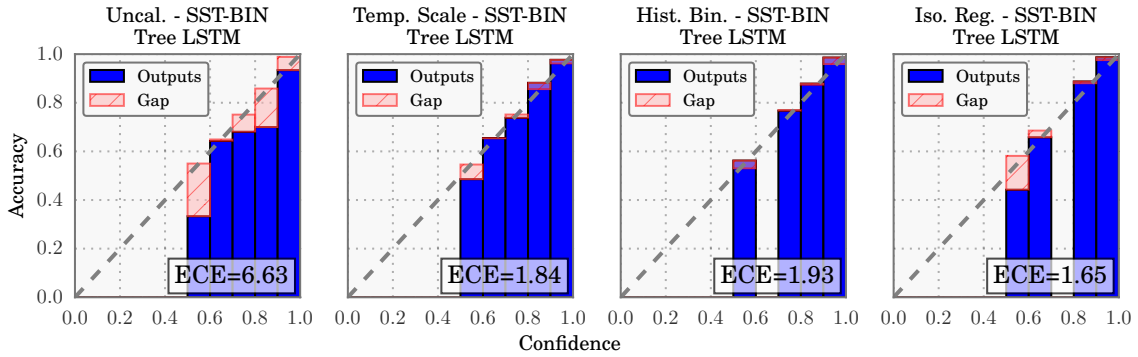


图 S4: SST 二分类与 SST 细粒度分类上校准前（最左）及校准后（中左、中右、最右）的可靠性图。

译者校注（非原文）

以下校注用于区分原文内容与必要的符号说明，不改写上述原文推导或实验数据。

1. **S1 的区间端点与近似。** 原文写作 $F_{\widehat{P}}(b) - F_{\widehat{P}}(a) = \mathbb{P}(\widehat{P} \in [a, b])$。对于通常定义的累积分布函数，严格等式应使用区间 $(a, b]$；只有在 a 处没有概率质量时，才可直接换成 $[a, b]$。原文的 $\widehat{p}(B_m)$ 表示分箱内平均置信度，与正文的 $\mathrm{conf}(B_m)$ 对应。此外，固定分箱下，大样本收敛的是分箱内的条件平均量；将它们视为某个代表点 p_m 的条件准确率及置信度，仍涉及分箱近似，并不意味着仅增大 n 就消除了有限分箱带来的误差。

2. **S2 的非负约束漏字与拉格朗日式。** 原文证明第一句提到“忽略约束 $q(\mathbf{z}_i)^{(k)}$”，漏写了关系 ≥ 0；译文补出这一已在命题中给出的非负性约束。原文拉格朗日函数的最后一项写成 $\sum_i \beta_i \sum_k (q(\mathbf{z}_i)^{(k)} - 1)$，这与命题中的归一化约束不一致。正确对应的项应为

$$\sum_{i=1}^{n} \beta_i \left(\sum_{k=1}^{K} q(\mathbf{z}_i)^{(k)} - 1 \right).$$

   即 -1 应位于对 k 的求和之外。对某个坐标 $q(\mathbf{z}_i)^{(k)}$ 求偏导时，熵项的导数是 $-1 - \log q(\mathbf{z}_i)^{(k)}$，并非原文的 $-nK - \log q(\mathbf{z}_i)^{(k)}$。相应地，指数式中的 $\beta_i - nK$ 应为 $\beta_i - 1$。该与类别无关的常数在归一化时被消去，因此经上述修正后，仍得到原文最后的指数族形式。

3. **S2 的温度范围。** 命题及证明把 λ 设为实数，没有给出足以保证 $\lambda > 0$ 的条件。因此，$T = 1/\lambda$ 本身不能证明正文所用的 $T > 0$；$\lambda = 0$ 对应均匀分布，可视作无限温度的极限，而有限乘子推导也未覆盖所有边界情形。这里保留原文命题和证明，不额外断言这些约束对任意数据都能产生有限的正温度。

4. **表 S3 的单位。** 原文表题写作“NLL (%)”，但表内数据没有百分号，NLL 也不是百分比。译文保留表题中的原标记并明确提示这一单位疑点；所有数值均按原文录入，没有乘以或除以 100。

5. **图 S3 与图 S4 的图题。** 原文这两幅图的图题完全相同，都提及 SST 二分类与 SST 细粒度分类。从各面板标题可见，图 S3 实际展示 SST-FG（细粒度分类），图 S4 展示 SST-BIN（二分类）。译文保留两条原图题，并在此说明对应关系。