OR-Bench 中文译文 · 公开删节版

OR-Bench: An Over-Refusal Benchmark for Large Language Models

原作者：Justin Cui; Wei-Lin Chiang; Ion Stoica; Cho-Jui Hsieh

源版本：arXiv:2405.20947v5

https://arxiv.org/abs/2405.20947v5

原作许可：Creative Commons Attribution 4.0 International (CC BY 4.0)。本译文及其删节改编亦按此许可提供。

https://creativecommons.org/licenses/by/4.0/

非官方 AI 辅助译文；翻译与公开版编排：dot。原作者未审校、认可或背书。公开版制作日期：2026-11-10。

本文件是有删节的阅读版，不是全文译本。保留页沿用旧译本页码，因此页码和交叉引用可能跳号。浅灰色区域表示实际删除的内容，而非可恢复遮盖。

修改与遗漏：删去原封面、说明和目录；图2流程及实例所在页、第4.3节实例所在页、附录D指南引文、N-O实例、Q.1分类提示、R-T回答/系统提示、W-X生成模板及Z回答实例等。其余页内实例与引文保守删节。保留作者实验图表及数值；个别混排页同页的非实例文字亦一并省略。

第三方素材的独立授权未核实，不主张论文许可当然涵盖这些素材。所保留图表为论文报告的实验数值图表；不包含数据集、模型权重、英文原文PDF或原始源包。详见随附README。

arXiv:2405.20947v5

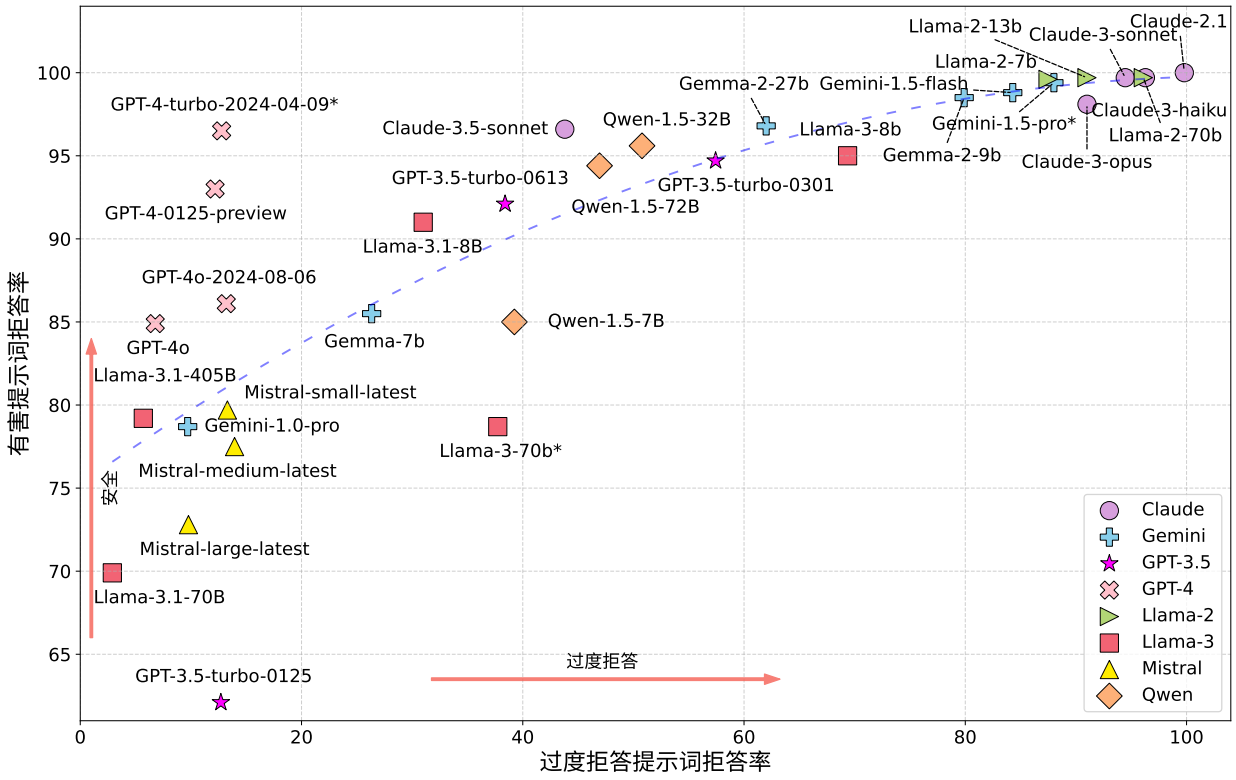


图 1: 在 OR-Bench-Hard-1K 和 OR-Bench-Toxic 上的过度拒答率与有害提示词拒答率。结果在温度为0.0时测得。表现最好的模型应处于左上角，即拒答尽可能少的安全提示词，同时拒答尽可能多的有害提示词。星号 * 表示用作集成评判器的模型。安全性与过度拒答之间的 Spearman 秩相关系数为0.89，表明大多数模型会以增加过度拒答来提高安全性。

arXiv:2405.20947v5

摘要

大语言模型（LLM）需要经过审慎的安全对齐，以防止产生恶意输出。尽管已有大量研究致力于减少有害内容的生成，安全性的提升却往往伴随着过度拒答这一副作用：LLM 可能拒绝无害的提示，从而降低有用性。虽然实证研究已经观察到过度拒答现象，但要对其进行系统性测量仍然面临挑战，原因在于难以构造出能够引发 LLM 过度拒答行为的提示。本研究提出了一种自动生成大规模过度拒答数据集的新方法。基于这一技术，我们推出了首个大规模过度拒答基准 OR-Bench。OR-Bench 包含涵盖 10 个常见拒绝类别的 80,000 条过度拒答提示、一个由约 1,000 条困难提示组成的子集（即使对最先进的 LLM 也具有挑战性），以及用于防止模型不加区分地回答请求的另外 600 条有害提示。随后，我们开展了全面研究，测量了 8 个模型家族中 32 个主流 LLM 的过度拒答情况。我们的数据集已在 https://huggingface.co/bench-llms 公开，代码库已在 https://github.com/justincui03/or-bench 开源。我们希望这一基准能够帮助社区开发安全对齐效果更好的模型。警告：部分内容可能包含有害或令人不适的信息。

1 引言

随着大语言模型（LLM）在实践中得到广泛应用，防止 LLM 遵循恶意指令或生成有害内容变得日益重要 [7, 24]。因此，研究者已经开发了众多算法来确保 LLM 的安全对齐，采用的技术包括基于人类反馈的安全强化学习（Safe RLHF） [10, 18, 48]、多轮自动红队测试（MART） [24, 25] 以及指令微调 [50]。此外，也已建立各种基准来评估 LLM 拒绝具有有害意图的问题的能力，包括 ToxicChat [39]、PromptBench [91]、AdvBench [92] 和 SorryBench [75]。然而，安全对齐的加强往往伴随着**过度拒答**这一副作用，即 LLM 可能拒绝回答本应回答的提示。尽管已有研究报告了过度拒答的具体实例 [16, 35, 55]，但缺少大规模基准阻碍了对 LLM 中这一问题的深入研究。构建此类基准的主要挑战在于，缺乏一种系统性方法来寻找本应得到回答、却很可能被 LLM 拒绝的提示。从标准数据集中随机抽取自然提示，只能得到极少数拒绝案例，因为过度拒答问题通常发生在接近决策边界的边界提示上，而校准良好的模型应当能够处理这类提示 [22]。目前，唯一可用的测试集是 XSTest [55]，其中包含依据特定规则人工编写的 250 条提示。然而，这种方法不足以大规模测试过度拒答问题，而且要将其推广到多种有害类别和主题，需要投入大量人力。

在本研究中，我们提出了首个用于测试 LLM 过度拒答问题的大规模基准。我们设计了一个自动生成过度拒答提示的框架，其主要思路是将原始有害提示改写为无害提示，再使用 LLM 审核器检查改写后提示的无害性。由此，我们构建了过度拒答基准（Over-Refusal Benchmark，OR-Bench），其中包含共计 80,000 条可能被 LLM 拒绝的安全提示，涵盖暴力、隐私、仇恨、性内容等 10 个有害内容类别。随后，我们在这一基准上开展了全面研究，评估了现有的 32 个开源及黑盒 LLM；结果汇总见 图 1，详细结果见 表 2、6及7。结果揭示了一项关键权衡：大多数模型以过度拒答为代价来获得安全性（拒绝有害提示），很少有模型能在两方面同时表现出色（见 图 1）。有趣的是，模型规模并不一定与更好的安全性与敏感性平衡相关。Claude 模型的安全性最高，但过度拒答也最严重，而 Mistral 模型则接受大多数提示。值得注意的是，GPT-3.5-turbo 在较新版本中呈现出过度拒答减少的趋势，同时安全性也有所降低。更多发现见 节 4。总而言之，我们的贡献如下：

- 我们设计了一条能够大规模自动生成过度拒答提示的流程。
- 我们发布了首个大规模过度拒答基准 OR-Bench-80K，涵盖 10 个类别，同时发布了更具挑战性的 OR-Bench-Hard-1K 子集。
- 基于 OR-Bench，我们开展了全面实验，评估了 8 个模型家族中 32 个主流 LLM 的过度拒答情况。我们的研究揭示了有关过度拒答问题的若干有趣见解，同时建立了一个稳健的测试平台，以促进今后关于安全性与有用性之间权衡的研究。

arXiv:2405.20947v5

2 相关工作

安全对齐 大语言模型通常经过多个阶段的训练，包括在包含数万亿词元的大规模语料库上进行预训练 [3, 62]、针对特定任务进行微调，以及利用各种偏好数据进行对齐。研究者提出了多种方法，使模型输出符合人类偏好，以确保内容真实且有用。例如，RLHF [48] 使用奖励模型进行优化；Self-Instruct [69] 通过模型自行生成的指令进行对齐，取得了与闭源模型相当的结果 [15, 40, 60]；DPO [52] 则将对齐建模为分类问题，从而简化对齐过程。随着 LLM 部署于现实应用 [7, 59]，确保其遵循安全原则、避免产生有害内容变得至关重要。Wildguard [26] 提出了一套开源的多任务审核模型和数据集，可检测 LLM 中的有害提示、有害回答和拒绝行为。

模型拒绝 已有研究发现，对话模型会在无意中采取有害立场。Baheti et al. [8] 提出了 ToxiChat，这是一个针对冒犯性和立场进行标注的 Reddit 讨论串数据集；该研究揭示了神经模型经常赞同冒犯性内容，并探索通过可控生成来缓解这一问题。Xu et al. [78] 提出了适用于开放域聊天机器人的实用安全策略，包括对抗性数据收集和内嵌式安全训练方法，以构建既能减少冒犯性输出、又不牺牲互动吸引力的模型。为满足生成具有社会规范依据的回答这一需求，Kim et al. [33] 提出了 ProsocialDialog，这是一个带有安全标注、以经验准则（rules-of-thumb, RoTs）为依据的大规模多轮对话数据集，使 Prost 等模型能够在伦理敏感情境中生成亲社会回答。

过度拒答 安全对齐虽然提升了 LLM 的整体安全性，但也可能导致其错误地拒绝安全提示。Bianchi et al. [11] 表明，在微调期间加入安全示例能够提高模型安全性，但也可能导致模型过于谨慎，拒绝那些与不安全提示相似的安全提示。Tuan et al. [67] 指出，优先考虑安全性可能降低用户参与度和有用性，并提出了无需训练的方法和微调方法，以平衡安全性与有用性。与我们的工作最相关的是 XSTest [55]，它包含 250 条人工编写的安全提示，这些提示通过语言技巧在表面上模仿有害提示。然而，由于其静态特性，XSTest 对 Llama-3-70b 等新一代最先进（SOTA）LLM 而言已经过于简单，这些模型几乎能够妥当地回答全部 250 个问题。同期工作 PHTest [4] 针对特定 LLM 生成定制的伪有害提示， 并将其用作红队测试工具。我们开发了首个大规模、与具体模型无关的过度拒答基准，包含 80K 条提示，并通过自动化流程持续更新。

越狱防御 近期研究表明，大语言模型（LLM）容易受到越狱攻击 [38, 80]。ToxiGen [27] 使用 LLM 生成能够欺骗仇恨言论分类器的对抗性有害／无害示例。WildJailbreak [31] 采用用户驱动的策略，为 LLM 构造越狱攻击。为缓解这些威胁，研究者提出了若干防御方法。Smooth-LLM [54] 对输入施加扰动，并综合这些变体来识别对抗性输入。In-Context Learning [74] 利用 LLM 的上下文学习能力，通过示例抑制有害回答。Response Check [70] 通过评估回答而非提示的有害性来判断安全性。最后，Self-Reminder [77] 以类似系统提示的方式纳入用户查询，提醒 LLM 负责任地生成回答。通过在 OR-Bench 上评估防御算法，我们发现，许多算法虽然取得了较高的防御成功率，却也显著提高了过度拒答率，这突显了今后开发防御方法时需要处理过度拒答问题。

3 过度拒答基准

本节首先给出常用的过度拒答定义，然后介绍一条全自动流程，用于大规模生成能够引发此类行为的提示。整体流程概览见图 2。

3.1 定义

arXiv:2405.20947v5

3.2.3 提示审核

从有害种子出发，我们让 LLM 将其改写为在安全与有害之间取得平衡的提示，但有时这些提示仍然有害，理应被拒绝。因此，最后的审核阶段对于确保生成的提示无害至关重要。虽然 OpenAI 的审核 API 被广泛使用，但它存在一些限制，例如缺少针对违法或不道德活动的类别，而且阈值较高，会对露骨内容产生误判。因此，我们沿用既有工作 [70, 84, 89] 的做法，使用 LLM 作为审核器，要求其先给出解释（类似思维链 [73]），再作出判断；这一方法已被证明有效（见 节 Q.1）。

LLM 集成审核器 与采用单个 LLM 作为评判器的既有工作 [70, 89] 不同，我们使用由 GPT-4-turbo-2024-04-09、Llama-3-70b 和 Gemini-1.5-pro-latest 组成的模型集成，以减轻可能偏袒某个特定模型家族的偏差。提示首先由这三个 LLM 进行评估，只有通过多数投票被判定为安全的提示才会纳入我们的基准数据集。我们也试验了 Claude-3-opus 等其他 LLM，但其判断过于保守，而且与上述模型的一致率较低，因此不适合作为审核器。

表 1: 集成审核器与专家的比较。正类标签表示安全。我们的流程本身生成的有害提示远少于安全提示。例如，对 1,000 条提示进行标注，其中有害提示占 10%，假阴性率为 4%，假阳性率为 16%，则通过审核的提示为有害提示的概率为 (100×0.16) / (900×0.96+100×0.16) = 1.8%。见 节 4.3。

	TP	FN	TN	FP	准确率
人类专家	94.7	5.3	92.0	8.0	94.0
集成审核器	96.0	4.0	84.0	16.0	93.0

[1] 审核前的实际有害比例低于 10%。

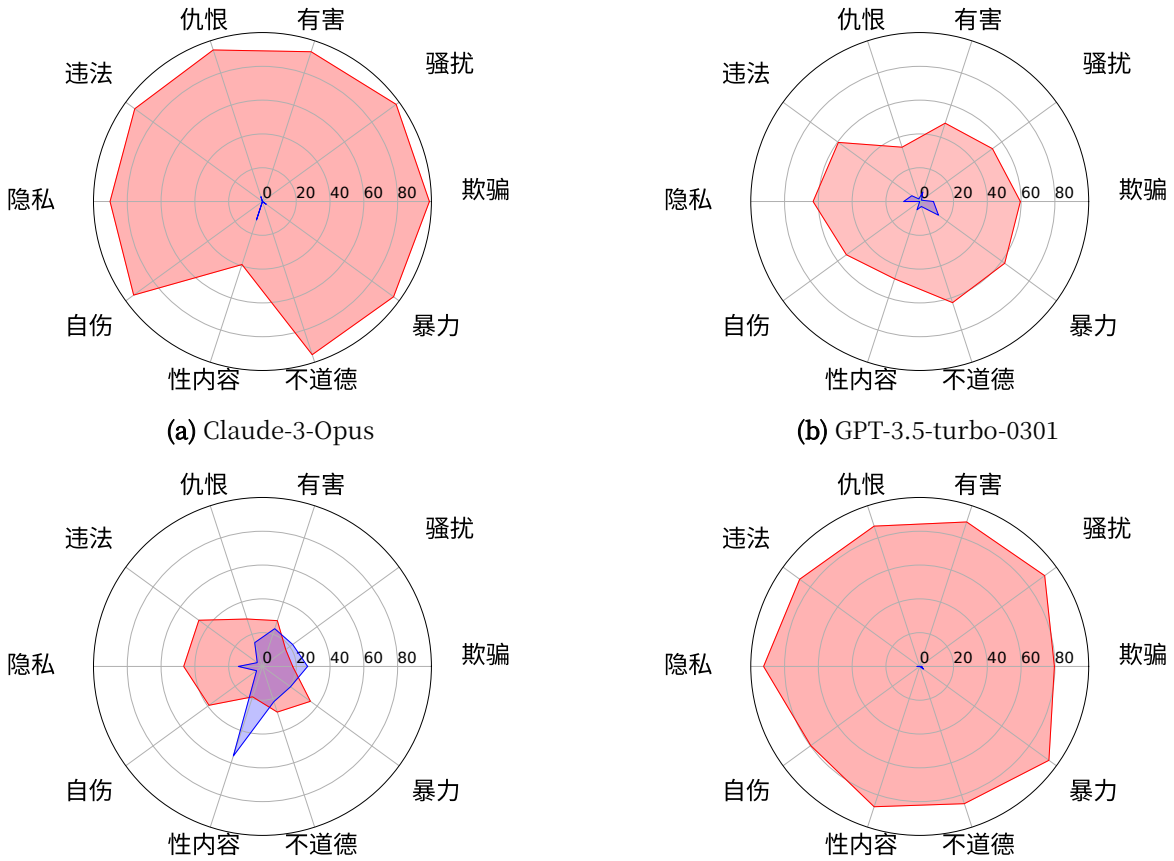
此外，我们观察到，一些被标记为有害的提示往往能够引出安全回答，原因是审核器对某些关键词过于敏感。为解决这一问题，我们遵循 Ji et al. [29], Stiennon et al. [58] 的做法，使用没有安全审核机制的大语言模型 Mistral-7B-Instruct-v0.3 [44] 回答这些提示。随后由审核器重新评估这些回答。如果回答被标记为安全，就将原始提示加入我们的基准。得益于 LLM 内部蕴含的丰富知识 [12, 32, 72]，使用集成审核器后，我们达到了人类专家[1]表现水平的 98% 以上，如 表 1 所示。

考虑过的替代方案 我们也考虑过其他几种评判方法。首先，我们按照与 Xie et al. [75] 相同的设置，利用专家标注的数据对 Mistral-7b-instruct-v0.2 进行微调，使其对提示进行分类，结果达到了约为人类专家表现水平 90% 的性能。进一步分析发现，它与集成审核器之间的差距主要源于思维链 [73] 式推理过程以及多个 LLM 之间的一致性 [69]，二者提升了集成审核器的表现。我们还尝试让人工标注员对数据进行标注，同样观察到表现下降。这一差距源于回答这些提示需要较强的领域专业知识，而人工标注员可能缺乏相应专长，LLM 却通常擅长这类知识[2]。因此，本研究采用集成审核器。

[1]我们将充分理解标注准则的论文作者和研究者称为专家。
[2]限于篇幅，更多细节见 节 V。

3.3 基准构建

利用上述方法，我们构建了一个包含 80K 条提示的大规模过度拒答数据集，涵盖 LLM 经常过度拒答的 10 个常见类别 [28, 83]，如暴力、隐私、仇恨、性内容等[3]。我们首先为每个类别生成 2,000 条有害种子并去除重复项，然后按照 节 3.2.2 所述，将每条种子改写为 5 条提示。接着，使用 节 3.2.3 中介绍的审核器筛选生成的提示，将安全提示加入过度拒答数据集，其余提示加入有害数据集。此外，如附录 表 7 所示，尽管 GPT-3.5-turbo-0301 和 Claude-2.1 在 OR-Bench-80K 上的过度拒答率分别高达 49% 和 73%，但近期最先进的大语言模型通常对齐得更好，过度拒答率更低。[4] 为快速测试这些模型，我们另外提供了一个规模较小但极具挑战性的数据集 OR-Bench-Hard-1K。它由安全提示组成，这些提示会被从各模型家族中选取的最大／最新模型里的至少 3 个模型拒绝（更多细节见节 Q）。各模型在这些数据集上的评估结果见 表 2；限于篇幅，其他结果列于附录 表 6、7。本文所提供数据集的类别分布见附录 图 7。



(a) Claude-3-Opus

(b) GPT-3.5-turbo-0301

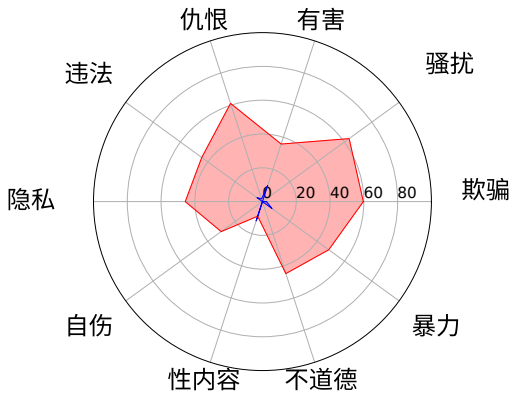
(c) Llama-3-70b

(d) Gemini-1.5-pro

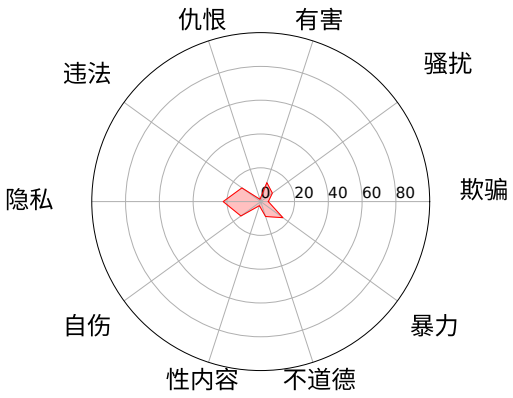
图 3: 红色区域表示过度拒答率，蓝色区域表示对有害提示的接受率。两种情况下，区域越小越好。结果在 OR-Bench-Hard-1K 和 OR-Bench-Toxic 上测得。总体而言，相较于较早的模型（前四个子图），较新的模型（后四个子图）往往更少出现过度拒答。

[3]限于篇幅，更多细节见 节 Q.1。

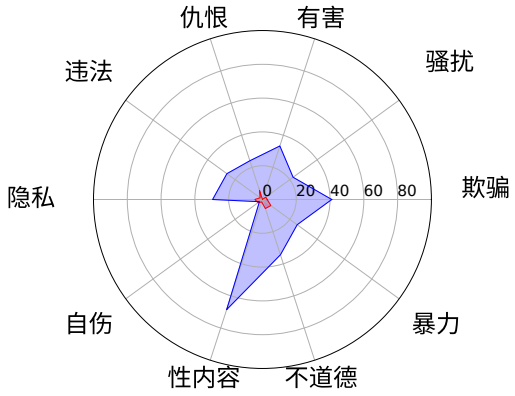
[4]译者注：此处保留原文的 49% 和 73% 表述；但原文附录 表 7 的 overall（总体）列中，GPT-3.5-turbo-0301 和 Claude-2.1 的数值分别为 34.7% 和 52.9%，与正文不一致。



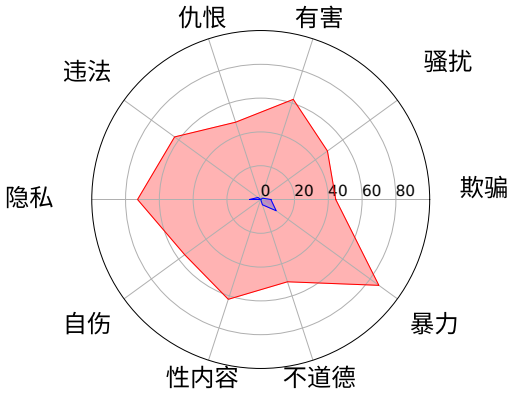
(e) Claude-3.5-Sonnet



(f) GPT-3.5-turbo-0125



(g) Llama-3.1-70B



(h) Gemma-2-27b

图 3: （续）红色区域表示过度拒答率，蓝色区域表示对有害提示的接受率。两种情况下，区域越小越好。结果在 OR-Bench-Hard-1K 和 OR-Bench-Toxic 上测得。总体而言，相较于较早的模型（前四个子图），较新的模型（后四个子图）往往更少出现过度拒答。

4 实验结果

4.1 实验设置

我们对来自 8 个家族的 32 个黑盒及开源模型进行了基准测试，包括 Claude-2.1、3 和 3.5，Gemini-1.0-pro、Gemini-1.5-{flash, pro} 及开源 Gemma 系列，GPT-3.5-turbo-{0125, 0301, 0613}、GPT-4-0125-preview、GPT-4-turbo-2024-04-09、最初版本的 GPT-4o 和 GPT-4o-08-06，以及所有 Llama 模型。我们还评估了小型、中型和大型 Mistral 模型，以及 Qwen 的 7B、32B 和 72B 模型。所有模型均通过公开 API 进行测试，不使用系统提示，以确保评估不偏不倚 [55, 87]。

沿用既有工作 [55, 70]，我们在完整的 80K 数据集上采用快速且成本低的关键词匹配，检查 LLM 是否拒绝某条提示；在困难子集和有害数据集上则采用 GPT-4，它能够处理关键词匹配失效的情况。我们发现，对于大多数模型，关键词匹配的结果与 GPT-4 评估十分接近：在抽样数据集上，对 GPT-3.5-turbo-0125 和 Llama-3-70b 的评估差异分别仅为 2.4% 和 1.2%。更多细节见 节 F。

arXiv:2405.20947v5

表 2: OR-Bench-Hard-1K 上的拒答率（%）。数值越高，表示过度拒答率越高。结果在温度为 0.0 时测得。限于篇幅，完整 80K 数据集及有害数据集上的结果见附录 表 6、7。

模型	欺骗	骚扰	有害	仇恨	违法	总体
Claude-2.1	100.0	100.0	100.0	100.0	100.0	99.8
Claude-3-haiku	100.0	95.7	98.3	92.9	97.5	96.2
Claude-3-sonnet	97.7	97.8	91.6	91.5	94.5	94.4
Claude-3-opus	98.8	97.8	93.2	94.3	93.4	91.0
平均	98.9±0.9	97.2±1.0	94.4±2.9	93.0±1.1	95.2±1.7	93.9±2.2
Claude-3.5-Sonnet	59.7	63.4	35.8	61.1	44.4	43.8
Gemma-7b	22.4	36.1	31.9	35.2	28.2	26.3
Gemini-1.0-pro	8.9	17.0	10.0	26.7	6.7	9.7
Gemini-1.5-flash-latest	75.2	80.8	87.3	70.4	85.5	84.2
Gemini-1.5-pro-latest	79.7	91.4	89.9	87.3	87.8	88.0
平均	46.6±31.3	56.4±30.8	54.8±34.7	54.9±24.9	52.1±35.5	52.1±34.6
Gemma-2-9b	73.6	78.0	78.3	66.7	82.2	80.0
Gemma-2-27b	44.4	48.8	62.3	48.1	63.0	62.0
平均	59.0±14.6	63.4±14.6	70.3±8.0	57.4±9.3	72.6±9.6	71.0±9.0
GPT-3.5-turbo-0301	59.5	53.1	48.7	33.8	59.5	57.4
GPT-3.5-turbo-0613	30.3	29.7	36.9	12.6	44.9	38.4
GPT-3.5-turbo-0125	4.4	8.5	11.7	1.4	13.7	12.7
平均	31.5±22.5	30.5±18.2	32.5±15.4	16.0±13.4	39.4±19.1	36.2±18.3
GPT-4-0125-preview	13.4	19.1	9.2	8.4	12.7	12.1
GPT-4-turbo-2024-04-09	13.4	14.8	3.3	11.2	12.7	12.7
GPT-4o	4.4	10.6	4.2	5.6	6.5	6.7
GPT-4o-08-06	4.2	7.3	11.3	9.3	13.7	13.0
平均	8.9±4.6	13.0±4.4	7.0±3.3	8.6±2.0	11.4±2.9	11.1±2.6
Llama-2-7b	87.6	91.4	87.3	90.1	88.2	87.4
Llama-2-13b	94.3	91.4	89.0	94.3	90.8	91.0
Llama-2-70b	100.0	95.7	94.1	98.5	95.7	96.0
平均	94.0±5.1	92.9±2.0	90.2±2.9	94.4±3.4	91.6±3.1	91.5±3.5
Llama-3-8b	53.9	59.5	57.1	73.2	76.5	69.3
Llama-3-70b	17.9	17.0	28.5	29.5	46.5	37.7
平均	36.0±18.0	38.3±21.3	42.9±14.3	51.4±21.8	61.6±15.0	53.6±15.8
Llama-3.1-8B	44.4	26.8	17.9	29.6	30.6	31.0
Llama-3.1-70B	2.8	2.4	0.0	5.6	1.7	3.0
Llama-3.1-405B	2.8	9.8	2.8	7.4	5.1	6.0
平均	16.7±19.6	13.0±10.2	6.9±7.9	14.2±10.9	12.5±12.9	13.3±12.6
Mistral-small-latest	12.3	17.0	10.9	5.6	13.1	13.3
Mistral-medium-latest	14.6	12.7	10.0	4.2	13.9	13.9
Mistral-large-latest	5.6	6.3	10.0	8.4	10.1	9.7
平均	10.9±3.8	12.1±4.4	10.4±0.4	6.1±1.8	12.4±1.6	12.3±1.8
Qwen-1.5-7B	56.1	51.0	32.7	26.7	35.9	39.2
Qwen-1.5-32B	61.8	51.0	42.0	46.4	52.1	50.7
Qwen-1.5-72B	58.4	46.8	47.0	29.5	45.9	46.9
平均	58.8±2.3	49.6±2.0	40.6±5.9	34.3±8.7	44.6±6.7	45.7±4.8

红蓝标色沿用原文，按两部分合并后的完整行比较；仅在相应极值所在的部分显示。总体列在两部分重复列出以便对照。

arXiv:2405.20947v5

表 2: （续）OR-Bench-Hard-1K 上的拒答率（%）。数值越高，表示过度拒答率越高。结果在温度为 0.0 时测得。限于篇幅，完整 80K 数据集及有害数据集上的结果见附录 表 6、7。

模型	隐私	自伤	性内容	不道德	暴力	总体
Claude-2.1	99.1	100.0	100.0	99.3	100.0	99.8
Claude-3-haiku	96.0	97.1	87.3	92.0	100.0	96.2
Claude-3-sonnet	92.0	97.1	94.9	96.6	94.5	94.4
Claude-3-opus	90.2	94.2	39.2	95.3	95.9	91.0
平均	92.7±2.4	96.1±1.4	73.8±24.7	94.7±1.9	96.8±2.3	93.9±2.2
Claude-3.5-Sonnet	45.7	30.2	9.1	44.8	48.5	43.8
Gemma-7b	14.6	39.1	15.1	27.1	25.6	26.3
Gemini-1.0-pro	4.0	24.6	15.1	6.6	17.5	9.7
Gemini-1.5-flash-latest	88.4	78.2	81.0	84.7	90.5	84.2
Gemini-1.5-pro-latest	92.4	79.7	87.3	85.4	94.5	88.0
平均	49.9±40.8	55.4±24.1	49.7±34.6	51.0±34.9	57.1±35.6	52.1±34.6
Gemma-2-9b	87.4	65.1	71.2	78.4	86.4	80.0
Gemma-2-27b	72.9	55.6	62.1	51.2	86.4	62.0
平均	80.2±7.3	60.4±4.8	66.7±4.6	64.8±13.6	86.4±0.0	71.0±9.0
GPT-3.5-turbo-0301	63.1	53.6	48.1	62.9	62.1	57.4
GPT-3.5-turbo-0613	42.2	55.0	7.5	31.1	47.3	38.4
GPT-3.5-turbo-0125	22.2	14.4	2.5	9.2	16.2	12.7
平均	42.5±16.7	41.1±18.8	19.4±20.4	34.4±22.0	41.9±19.1	36.2±18.3
GPT-4-0125-preview	14.6	11.5	2.5	11.9	13.5	12.1
GPT-4-turbo-2024-04-09	16.0	17.3	5.0	15.2	16.2	12.7
GPT-4o	10.6	13.0	0.0	4.6	8.1	6.7
GPT-4o-08-06	22.6	20.6	1.5	8.0	16.7	13.0
平均	16.0±4.3	15.6±3.6	2.2±1.8	9.9±4.0	13.6±3.4	11.1±2.6
Llama-2-7b	88.8	84.0	77.2	86.0	89.1	87.4
Llama-2-13b	90.6	91.3	91.1	89.4	91.8	91.0
Llama-2-70b	96.8	92.7	94.9	96.0	97.3	96.0
平均	92.1±3.4	89.4±3.8	87.8±7.6	90.5±4.1	92.8±3.4	91.5±3.5
Llama-3-8b	70.2	89.8	32.9	62.9	81.0	69.3
Llama-3-70b	46.6	39.1	18.9	28.4	35.1	37.7
平均	58.4±11.8	64.5±25.4	25.9±7.0	45.7±17.2	58.1±23.0	53.6±15.8
Llama-3.1-8B	33.7	39.7	13.6	37.6	33.3	31.0
Llama-3.1-70B	4.5	3.2	1.5	5.6	6.1	3.0
Llama-3.1-405B	5.0	17.5	0.0	8.0	6.1	6.0
平均	14.4±13.7	20.1±15.0	5.0±6.1	17.1±14.6	15.2±12.8	13.3±12.6
Mistral-small-latest	18.6	18.8	5.0	15.2	8.1	13.3
Mistral-medium-latest	22.6	15.9	1.2	12.5	17.5	13.9
Mistral-large-latest	13.3	14.4	0.0	11.2	6.7	9.7
平均	18.2±3.8	16.4±1.8	2.1±2.2	13.0±1.7	10.8±4.8	12.3±1.8
Qwen-1.5-7B	42.6	30.4	37.9	54.9	28.3	39.2
Qwen-1.5-32B	60.4	26.0	35.4	54.9	45.9	50.7
Qwen-1.5-72B	49.3	43.4	53.1	50.9	39.1	46.9
平均	50.8±7.3	33.3±7.4	42.2±7.8	53.6±1.9	37.8±7.2	45.7±4.8

红蓝标色沿用原文，按两部分合并后的完整行比较；仅在相应极值所在的部分显示。总体列在两部分重复列出以便对照。

4.2 评估结果

首先，我们在表 2、图 4 和附录 表 7 中展示各类别的平均拒答率。 总体而言，在每个模型家族内部，各模型总体拒答率的排序在 OR-Bench-80K 和 OR-Bench-Hard-1K 上保持一致。例如，在 Claude-3 家族中，Claude-3-haiku 在两个数据集上的拒答率都最高，而 Claude-3-opus 都最低。在 GPT-3.5 家族中，GPT-3.5-turbo-0301 的拒答率最高，GPT-3.5-turbo-0125 最低。Mistral 模型也是如此。一个例外是，Llama-2-70b 在 OR-Bench-80K 上的拒答率略低于其 7b 和 13b 版本，但在 OR-Bench-Hard-1K 上的拒答率却更高。这一不一致可能与我们构建困难子集的方式有关。此外，如 图 3 所示，较新模型的过度拒答率通常低于其前代模型，体现了安全对齐的进步。

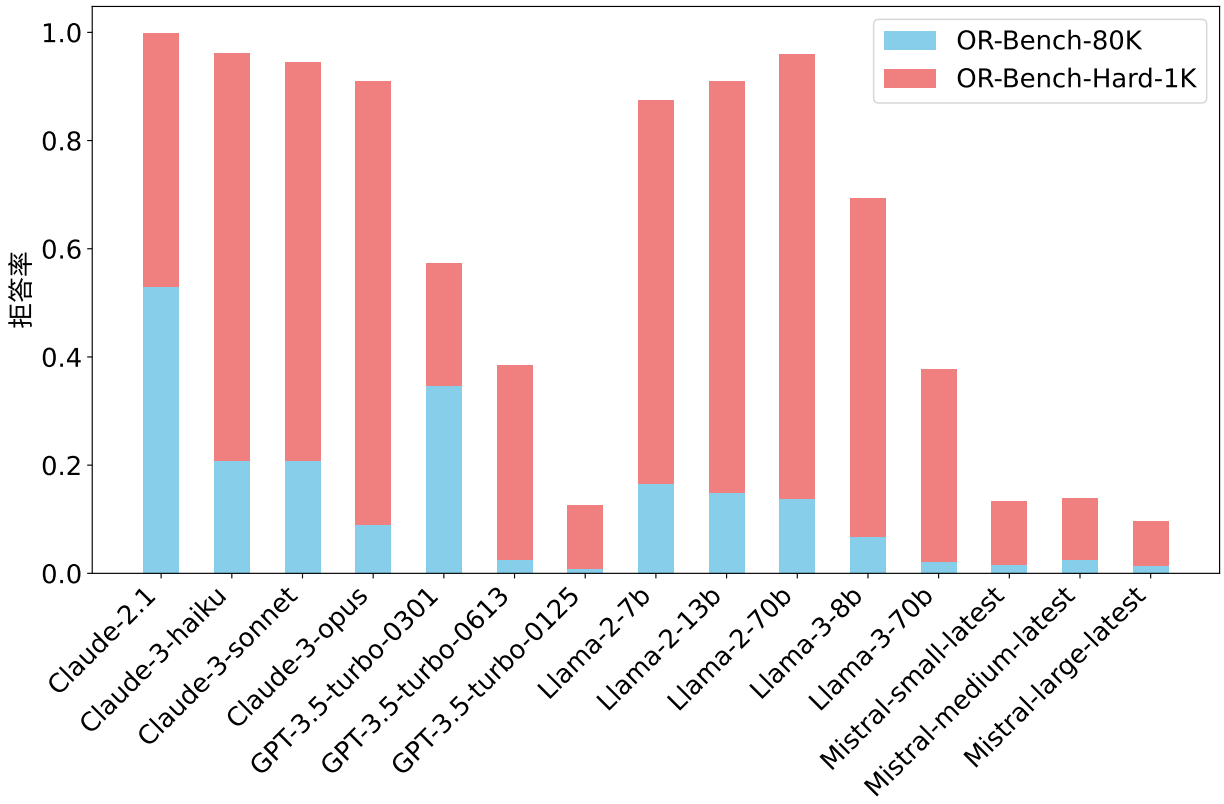


图 4: 不同模型在 OR-Bench-80K 和 OR-Bench-Hard-1K 上的拒答率。

接下来，我们使用 OR-Bench-Hard-1K 和 OR-Bench-Toxic，展示有关各模型总体平均拒答率的一些发现，如 图 1、表 2 所示。

需要注意的是，评估中可能存在有利于担任评判器的 LLM 的一定偏差。然而，近期研究 [23, 64] 表明，LLM 作为评判器的能力与其安全对齐是不同的。因此，此类偏差的影响有限，这也与我们的实证发现一致。 我们还绘制了一条蓝色拟合曲线，由所有数据点的二次回归系数确定，用于表示全部模型的总体表现趋势。 总体而言，我们有以下观察：

- 我们的分析揭示了安全性与过度拒答之间的强相关性。拒绝更多有害提示的模型（更安全）也往往拒绝更多安全提示（过度拒答）。安全提示与有害提示拒答率之间的 Spearman 秩相关系数为 0.89，表明大多数模型只是在用过度拒答换取安全性，很少有模型能突破这一权衡。我们认为，未来的安全对齐算法应同时考虑有害提示和过度拒答提示，以实现更好的安全对齐（理想情况下，让模型向 图 1 的左上角移动）。
- 在 GPT-3.5-turbo 家族中，我们发现，GPT-3.5-turbo-0301 等早期版本表现出明显的过度拒答行为，在 OR-Bench-Hard-1K 数据集上的总体拒答率超过 57%；后续版本修正了这一问题

（GPT-3.5-turbo 的发布顺序为 0301（2023）、0613（2023）、0125（2024））。然而，从 图 1 可以看出，减少拒绝安全提示的改进似乎是以回答更多有害提示为代价的。例如，最新的 GPT-3.5-turbo-0125 仅拒绝 62% 的有害提示，因此安全性较低。相比 GPT-3.5-turbo-0125，GPT-4 家族的安全性大幅提高，这与其他研究一致 [70, 92]，同时它对过度拒答提示仍保持了相近的低拒答率。

- Llama 模型家族也存在同样的情况。已有研究显示，Llama-2 [11] 会过度拒答安全提示，这与我们的实验结果一致（位于 图 1 的右上角）。在近期发布的 Llama-3 模型家族中，安全提示的拒答率显著下降，尤其是在最近的 Llama-3.1 模型系列中。与 GPT-3.5-turbo 模型家族类似，这是回答更多有害提示与拒绝更多安全提示之间权衡的结果。[5]
- 在 Claude 模型家族的各个版本中，模型虽然拒绝了大量安全提示，但也一直拒绝绝大多数有害提示，使其成为我们所测试模型中最安全的家族之一[6]。Mistral 模型家族似乎与 Claude 走向相反：它们拒绝的安全提示很少，代价是比 Claude 多回答 20% 的有害提示。
- 对于 Gemini 家族，情况不同于前面提到的 GPT-3.5-turbo 和 LLama3 等模型，后者比其前代版本更少拒绝安全提示；Gemini-1.5-flash 和 Gemini-1.5-pro 等较新 Gemini 版本则拒绝更多安全提示，同时安全性也显著提高。

表 3: 使用 BERTScore 测量生成数据集的多样性。对于 OR-Bench-Hard-1K，使用完整数据集；对于 OR-Bench-80K，从每个类别中抽取 1000 条提示进行测量，最终结果为 3 次运行的平均值。

类别	Hard 精确率	Hard 召回率	Hard F1	80K 精确率	80K 召回率	80K F1
欺骗	0.57	0.60	0.58	0.53±0.01	0.57±0.01	0.55±0.01
骚扰	0.46	0.47	0.46	0.55±0.01	0.58±0.02	0.56±0.01
有害	0.52	0.54	0.53	0.52±0.01	0.55±0.01	0.53±0.01
仇恨	0.41	0.44	0.42	0.50±0.02	0.53±0.02	0.51±0.02
违法	0.57	0.61	0.59	0.54±0.01	0.58±0.01	0.56±0.01
隐私	0.53	0.56	0.54	0.54±0.01	0.57±0.01	0.55±0.01
自伤	0.54	0.57	0.55	0.56±0.01	0.59±0.01	0.57±0.01
性内容	0.55	0.58	0.57	0.57±0.01	0.60±0.01	0.58±0.01
不道德	0.52	0.54	0.53	0.53±0.01	0.57±0.01	0.55±0.01
暴力	0.46	0.47	0.46	0.48±0.01	0.51±0.02	0.49±0.01

最后，我们分析不同细分类别中的模型表现，如 表 2、6、图 3 所示。对于过度拒答提示，我们观察到，Claude-3-opus 虽然拒绝其他类别中的许多提示，但对性相关主题的敏感度较低。Mistral-large-latest、Llama-3-70b 和 GPT-3.5-turbo-0125 等模型也呈现出这一趋势。不同模型对不同类别敏感：GPT-3.5-turbo-0125 对隐私敏感，Mistral-large-latest 对自伤敏感，Llama-3-70b 对隐私和自伤敏感，Qwen-1.5-72B 对性内容和欺骗类内容敏感。Gemini-1.0-pro 对自伤非常敏感，而 Gemini-1.5-pro 对大多数类别都很敏感。对于有害提示，所有模型都倾向于拒绝与自伤有关的有害提示，接受率很低。Mistral 家族往往会接受性内容类别中超过 50% 的有害提示，GPT-3.5-turbo 家族接受更多性内容和仇恨类提示，而 Gemini 家族则倾向于回答更多与隐私有关的提示。更多细节见 表 2、6。

[5]译者注：原文此处写作 ，与本段前文所述 存在措辞不一致；此处按原文保留。

[6]需要注意的是，由于采用了集成拒绝筛选，图 1 中的结果被放大了；表 7 中 OR-Bench-80K 上的结果更能反映普通使用场景。

arXiv:2405.20947v5

我们将 节 2 概述的各种越狱防御方法应用于 GPT-3.5-turbo-0125 和 Llama-3-70b，并使用 OR-Bench-Hard-1K 和 OR-Bench-Toxic 进行基准测试。图 5 中的结果表明，大多数防御策略虽然提高了防御成功率，但往往也会拒绝更多无害提示。例如，上下文学习（In-Context Learning，ICL）使两个模型拒绝了最多的有害提示，但也导致了最高的过度拒答提示拒答率。同样，SmoothLLM 略微提高了对有害提示的拒答率，但也小幅提高了过度拒答率。这突显了未来开发防御方法时衡量过度拒答影响的必要性。

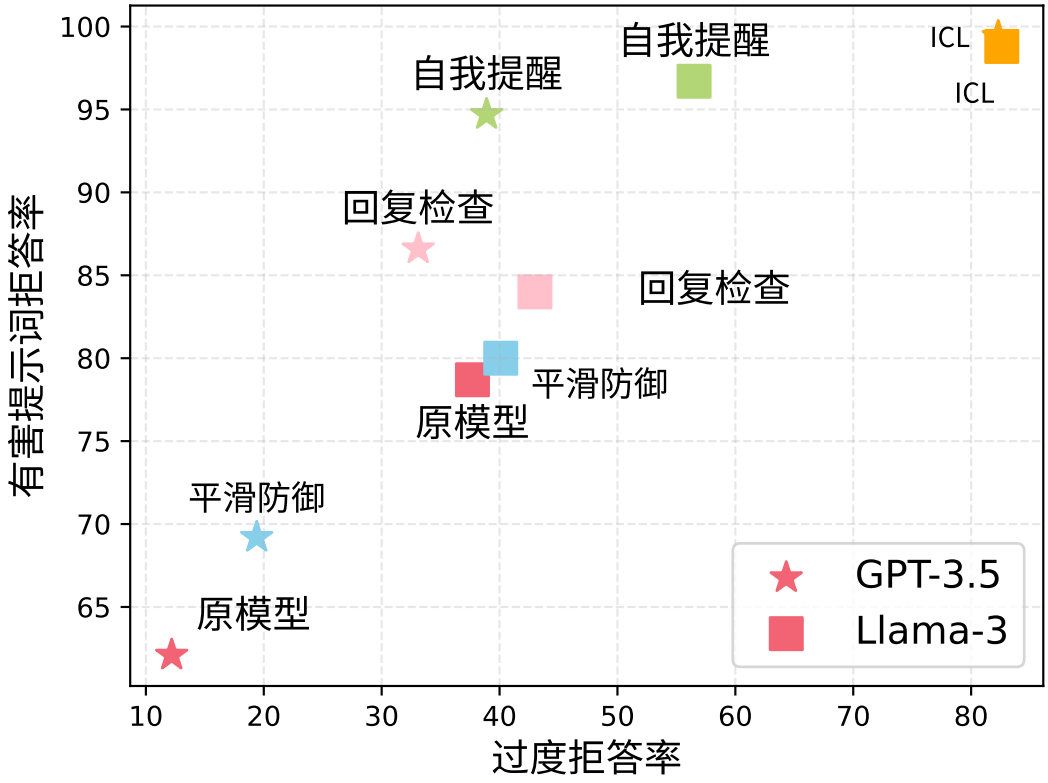


图 5: 防御方法对 GPT-3.5-turbo-0125 和 Llama-3-70b 在 OR-Bench-Hard-1K 与 OR-Bench-Toxic 上表现的影响。

系统提示 我们还测量了系统提示对 LLM 的影响。与 Bianchi et al. [11] 类似，我们使用系统提示要求模型既有用又安全，并在 4 个最先进的 LLM 上进行了测试，包括 GPT-3.5-turbo-0125、Mistral-large-latest、Claude-3-opus 和 Llama-3-70b。结果见 图 6。可以看到，在所有情况下，新的数据点都大幅向右上角移动，表明系统提示对模型的安全行为具有显著影响，而且安全性的提高是以拒绝更多无害提示为代价的。不同模型的权衡似乎不同。例如，GPT-3.5-turbo-0125 多拒绝了约 35% 的有害提示和约 55% 的无害提示，而 Mistral-large-latest 多拒绝了约 20% 的有害提示，却只多拒绝了约 10% 的无害提示。这突显了系统提示在大语言模型中的重要性。

不同温度 为保证可复现性，主要实验均在温度为 0.0 时进行评估。这里，我们展示两个模型在不同温度下的结果：一个是开源模型，另一个是黑盒模型，二者均表现出明显的过度拒答。如 表 4 所示，温度对模型拒绝行为的影响很小，在整个实验中，模型的回答保持一致。如果用户选择不常用的温度，我们建议按其偏好的温度评估模型。

arXiv:2405.20947v5

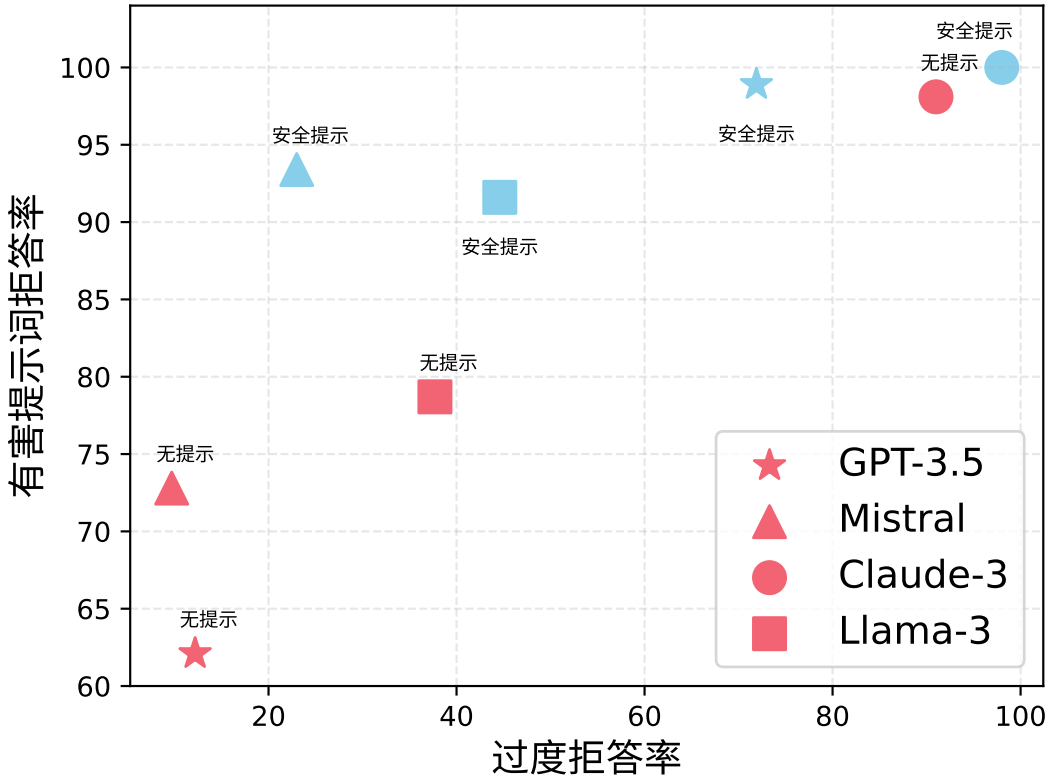


图 6: 要求模型既有用又安全的系统提示对模型在 OR-Bench-Hard-1K 与 OR-Bench-Toxic 上表现的影响。

表 4: 不同温度下 OR-Bench-Hard-1K 上的结果。

	0.0	0.25	0.5	0.75	1.0
Claude-3-Haiku	96.2	96.7	96.1	96.0	95.5
Llama-2-7b	87.4	86.6	85.7	85.4	85.5

6 结论与未来工作

本文提出了首个用于评估大语言模型过度拒答现象的大规模基准。该基准包含三个数据集：一个由 80,000 条提示组成的大规模过度拒答数据集、一个包含 1,000 条提示的挑战性子集，以及用于确保模型针对提示的有害性作出适当回应的 600 条有害提示。我们评估了来自 8 个不同家族的 32 个黑盒及开源模型，揭示了它们在安全性方面的优势和不足。我们的基准被设计为可以持续更新，以便在新模型出现时避免过拟合。

未来工作 在未来的工作中，我们计划扩展该基准，纳入更多模型和类别。还应注意，将拒绝视为二元问题是一种错误的二分。有些回应方式既不拒绝请求，也不提供完全不道德或有害的答案。因此，应当制定更细致、更细粒度的定义，以实现更好的 LLM 对齐。我们鼓励未来研究进一步探索过度拒答提示的拒答率，以改进安全对齐。

致谢

本研究获得 NSF 2048280、2325121、2244760、2331966 以及 ONR N00014-23-1-2300:P00001 的支持。我们衷心感谢所有会议审稿人提出的宝贵建议，使我们的工作比初稿完善了许多。

影响声明

本文提出了 OR-Bench，一个用于评估大语言模型（LLM）过度拒答现象的基准，突出了安全性与有用性之间的权衡。我们的目标是推动更可靠、具有安全对齐能力的 AI 系统的发展。本研究已获得机构审查委员会（IRB）批准；我们在整个数据收集和审核过程中遵循伦理标准，确保以负责任的方式构建数据集。我们倡导以合乎伦理的方式使用 OR-Bench，支持 AI 安全与对齐领域的进步。

参考文献

[1] GPT-4 AI is Great, But at a Hefty Price Tag ;) — community.openai.com（GPT-4 AI 很出色，但价格高昂 ;)）. https://community.openai.com, .

[2] Gpt-4-0125-preview INCREDIBLY slower than 3.5 turbo（GPT-4-0125-preview 比 3.5 turbo 慢得惊人）. https://community.openai.com/, .

[3] Abdin, M., Jacobs, S. A., Awan, A. A., Aneja, J., Awadallah, A., Awadalla, H., Bach, N., Bahree, A., Bakhtiari, A., Behl, H., et al. Phi-3 technical report: A highly capable language model locally on your phone（Phi-3 技术报告：可在手机本地运行的高能力语言模型）. *arXiv preprint arXiv:2404.14219*, 2024.

[4] An, B., Zhu, S., Zhang, R., Panaitescu-Liess, M.-A., Xu, Y., and Huang, F. Automatic pseudo-harmful prompt generation for evaluating false refusals in large language models（用于评估大语言模型误拒绝行为的伪有害提示自动生成）. *arXiv preprint arXiv:2409.00598*, 2024.

[5] Anthropic. Introducing the next generation of Claude — anthropic.com（介绍新一代 Claude）. https://www.anthropic.com/news/claude-3-family, 2024. [Accessed 07-05-2024].

[6] Anthropic. Claude_3_addendum.pdf（Claude 3 补充说明.pdf）. https://www-cdn.anthropic.com/Model_Card_Claude_3_Addendum.pdf, 2024.

[7] Anwar, U., Saparov, A., Rando, J., Paleka, D., Turpin, M., Hase, P., Lubana, E. S., Jenner, E., Casper, S., Sourbut, O., et al. Foundational challenges in assuring alignment and safety of large language models（保障大语言模型对齐与安全的基础性挑战）. *arXiv preprint arXiv:2404.09932*, 2024.

[8] Baheti, A., Sap, M., Ritter, A., and Riedl, M. Just say no: Analyzing the stance of neural dialogue generation in offensive contexts（直接说不：分析神经对话生成在冒犯性语境中的立场）. *arXiv preprint arXiv:2108.11830*, 2021.

[9] Bai, J., Bai, S., Chu, Y., Cui, Z., Dang, K., Deng, X., Fan, Y., Ge, W., Han, Y., Huang, F., et al. Qwen technical report（Qwen 技术报告）. *arXiv preprint arXiv:2309.16609*, 2023.

[10] Bai, Y., Jones, A., Ndousse, K., Askell, A., Chen, A., DasSarma, N., Drain, D., Fort, S., Ganguli, D., Henighan, T., et al. Training a helpful and harmless assistant with reinforcement learning from human feedback（利用人类反馈强化学习训练有帮助且无害的助手）. corr, abs/2204.05862, 2022a. doi: 10.48550. *arXiv preprint arXiv.2204.05862*, 2022.

[11] Bianchi, F., Suzgun, M., Attanasio, G., Röttger, P., Jurafsky, D., Hashimoto, T., and Zou, J. Safety-tuned llamas: Lessons from improving the safety of large language models that follow instructions（经过安全微调的 Llama 模型：改进指令遵循大语言模型安全性的经验）. *arXiv preprint arXiv:2309.07875*, 2023.

[12] Brown, T. B. Language models are few-shot learners（语言模型是少样本学习器）. *arXiv preprint arXiv:2005.14165*, 2020.

[13] Chao, P., Robey, A., Dobriban, E., Hassani, H., Pappas, G. J., and Wong, E. Jailbreaking black box large language models in twenty queries（用二十次查询越狱黑盒大语言模型）. *arXiv preprint arXiv:2310.08419*, 2023.

[14] Chiang, W.-L., Li, Z., Lin, Z., Sheng, Y., Wu, Z., Zhang, H., Zheng, L., Zhuang, S., Zhuang, Y., Gonzalez, J. E., Stoica, I., and Xing, E. P. Vicuna: An open-source chatbot impressing gpt-4 with 90%* chatgpt quality（Vicuna：达到 ChatGPT 90%* 的质量、令 GPT-4 印象深刻的开源聊天机器人）, March 2023. URL https://lmsys.org/blog/2023-03-30-vicuna/.

[15] Chung, H. W., Hou, L., Longpre, S., Zoph, B., Tay, Y., Fedus, W., Li, Y., Wang, X., Dehghani, M., Brahma, S., et al. Scaling instruction-finetuned language models（扩展指令微调语言模型的规模）. *Journal of Machine Learning Research*, 25(70):1–53, 2024.

[16] Claude. Claude 2.1 Refuses to kill a Python process | Hacker News — news.ycombinator.com（Claude 2.1 拒绝终止一个 Python 进程 | Hacker News）. https://news.ycombinator.com/item?id=38371115, 2023. [Accessed 08-05-2024].

[17] Claude3. Introducing the next generation of claude \ anthropic（介绍新一代 Claude | Anthropic）. https://www.anthropic.com/news/claude-3-family, 2024.

[18] Dai, J., Pan, X., Sun, R., Ji, J., Xu, X., Liu, M., Wang, Y., and Yang, Y. Safe rlhf: Safe reinforcement learning from human feedback（Safe RLHF：安全的人类反馈强化学习）. *arXiv preprint arXiv:2310.12773*, 2023.

[19] Davidson, T., Bhattacharya, D., and Weber, I. Racial bias in hate speech and abusive language detection datasets（仇恨言论与辱骂性语言检测数据集中的种族偏见）. *arXiv preprint arXiv:1905.12516*, 2019.

[20] Dixon, L., Li, J., Sorensen, J., Thain, N., and Vasserman, L. Measuring and mitigating unintended bias in text classification（测量并缓解文本分类中的非预期偏见）. In *Proceedings of the 2018 AAAI/ACM Conference on AI, Ethics, and Society*, pp. 67–73, 2018.

[21] Dong, Q., Li, L., Dai, D., Zheng, C., Wu, Z., Chang, B., Sun, X., Xu, J., and Sui, Z. A survey on in-context learning（上下文学习综述）. *arXiv preprint arXiv:2301.00234*, 2022.

[22] Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., Letman, A., Mathur, A., Schelten, A., Yang, A., Fan, A., et al. The llama 3 herd of models（Llama 3 模型家族）. *arXiv preprint arXiv:2407.21783*, 2024.

[23] Feuer, B., Goldblum, M., Datta, T., Nambiar, S., Besaleli, R., Dooley, S., Cembalest, M., and Dickerson, J. P. Style over substance: Failure modes of llm judges in alignment benchmarking（形式重于实质：大语言模型评判器在对齐基准评测中的失效模式）. *arXiv preprint arXiv:2409.15268*, 2024.

[24] Ganguli, D., Lovitt, L., Kernion, J., Askell, A., Bai, Y., Kadavath, S., Mann, B., Perez, E., Schiefer, N., Ndousse, K., et al. Red teaming language models to reduce harms: methods, scaling behaviors, and lessons learned（通过对语言模型进行红队测试来减少危害：方法、规模效应与经验教训）. arxiv, 2022.

[25] Ge, S., Zhou, C., Hou, R., Khabsa, M., Wang, Y.-C., Wang, Q., Han, J., and Mao, Y. Mart: Improving llm safety with multi-round automatic red-teaming（MART：利用多轮自动红队测试提升大语言模型安全性）. *arXiv preprint arXiv:2311.07689*, 2023.

[26] Han, S., Rao, K., Ettinger, A., Jiang, L., Lin, B. Y., Lambert, N., Choi, Y., and Dziri, N. Wildguard: Open one-stop moderation tools for safety risks, jailbreaks, and refusals of llms（WildGuard：面向大语言模型安全风险、越狱与拒绝行为的开放式一站式审核工具）. *arXiv preprint arXiv:2406.18495*, 2024.

[27] Hartvigsen, T., Gabriel, S., Palangi, H., Sap, M., Ray, D., and Kamar, E. Toxigen: A large-scale machine-generated dataset for adversarial and implicit hate speech detection（ToxiGen：用于对抗性与隐含仇恨言论检测的大规模机器生成数据集）. *arXiv preprint arXiv:2203.09509*, 2022.

[28] Inan, H., Upasani, K., Chi, J., Rungta, R., Iyer, K., Mao, Y., Tontchev, M., Hu, Q., Fuller, B., Testuggine, D., et al. Llama guard: Llm-based input-output safeguard for human-ai conversations（Llama Guard：基于大语言模型的人机对话输入输出安全防护）. *arXiv preprint arXiv:2312.06674*, 2023.

[29] Ji, J., Liu, M., Dai, J., Pan, X., Zhang, C., Bian, C., Chen, B., Sun, R., Wang, Y., and Yang, Y. Beavertails: Towards improved safety alignment of llm via a human-preference dataset（BeaverTails：通过人类偏好数据集改进大语言模型的安全对齐）. *Advances in Neural Information Processing Systems*, 36, 2024.

[30] Jiang, A. Q., Sablayrolles, A., Roux, A., Mensch, A., Savary, B., Bamford, C., Chaplot, D. S., Casas, D. d. l., Hanna, E. B., Bressand, F., et al. Mixtral of experts（Mixtral 混合专家模型）. *arXiv preprint arXiv:2401.04088*, 2024.

[31] Jiang, L., Rao, K., Han, S., Ettinger, A., Brahman, F., Kumar, S., Mireshghallah, N., Lu, X., Sap, M., Choi, Y., et al. Wildteaming at scale: From in-the-wild jailbreaks to (adversarially) safer language models（规模化 WildTeaming：从真实环境中的越狱到在对抗层面更安全的语言模型）. *Advances in Neural Information Processing Systems*, 37:47094–47165, 2024.

[32] Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., and Amodei, D. Scaling laws for neural language models（神经语言模型的缩放定律）. *arXiv preprint arXiv:2001.08361*, 2020.

[33] Kim, H., Yu, Y., Jiang, L., Lu, X., Khashabi, D., Kim, G., Choi, Y., and Sap, M. Prosocialdialog: A prosocial backbone for conversational agents（ProsocialDialog：对话智能体的亲社会基础）. *arXiv preprint arXiv:2205.12688*, 2022.

[34] Koike, R., Kaneko, M., and Okazaki, N. Outfox: Llm-generated essay detection through in-context learning with adversarially generated examples（OUTFOX：利用对抗生成示例进行上下文学习，检测大语言模型生成的文章）. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pp. 21258–21266, 2024.

[35] less. Refusal in LLMs is mediated by a single direction — LessWrong — lesswrong.com（大语言模型的拒绝行为由单一方向介导 | LessWrong）. https://www.lesswrong.com, 2024. [Accessed 09-05-2024].

[36] Levy, S., Allaway, E., Subbiah, M., Chilton, L., Patton, D., McKeown, K., and Wang, W. Y. Safetext: A benchmark for exploring physical safety in language models（SafeText：探索语言模型物理安全性的基准）. *arXiv preprint arXiv:2210.10045*, 2022.

[37] Li, L., Dong, B., Wang, R., Hu, X., Zuo, W., Lin, D., Qiao, Y., and Shao, J. Salad-bench: A hierarchical and comprehensive safety benchmark for large language models（SALAD-Bench：面向大语言模型的分层综合安全基准）. *arXiv preprint arXiv:2402.05044*, 2024.

[38] Li, X., Wang, R., Cheng, M., Zhou, T., and Hsieh, C.-J. Drattack: Prompt decomposition and reconstruction makes powerful llm jailbreakers（DrAttack：通过提示分解与重构构建强大的大语言模型越狱攻击器）. *arXiv preprint arXiv:2402.16914*, 2024.

[39] Lin, Z., Wang, Z., Tong, Y., Wang, Y., Guo, Y., Wang, Y., and Shang, J. Toxicchat: Unveiling hidden challenges of toxicity detection in real-world user-ai conversation（ToxicChat：揭示真实用户与 AI 对话中有毒内容检测的隐含挑战）. *arXiv preprint arXiv:2310.17389*, 2023.

[40] Liu, H., Li, C., Wu, Q., and Lee, Y. J. Visual instruction tuning（视觉指令微调）. *Advances in neural information processing systems*, 36, 2024.

[41] Llama3. Introducing meta llama 3: The most capable openly available llm to date（介绍 Meta Llama 3：迄今能力最强的公开可用大语言模型）. https://ai.meta.com/blog/meta-llama-3/, 2024.

[42] Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., et al. Language models are few-shot learners（语言模型是少样本学习器）. *arXiv preprint arXiv:2005.14165*, 2020.

[43] McIntosh, T. R., Susnjak, T., Liu, T., Watters, P., and Halgamuge, M. N. Inadequacies of large language model benchmarks in the era of generative artificial intelligence（生成式人工智能时代大语言模型基准的不足）. *arXiv preprint arXiv:2402.09880*, 2024.

[44] mistral. mistralai/ Mistral-7B-Instruct-v0.3 · Hugging Face — huggingface.co（mistralai/ Mistral-7B-Instruct-v0.3 模型页面 · Hugging Face）. https://huggingface.co/mistralai/Mistral-7B-Instruct-v0.3, 2024. [Accessed 28-05-2024].

[45] Mistral. Mistral AI | Frontier AI in your hands — mistral.ai（Mistral AI | 前沿 AI 尽在你手中）. https://mistral.ai/, 2024. [Accessed 07-05-2024].

[46] OpenAI. Chatgpt（ChatGPT）. https://www.openai.com, 2023. Accessed: <date-of-access>.

[47] OpenAI. Introducing the model spec | openai（介绍模型规范 | OpenAI）. 2024.

[48] Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., et al. Training language models to follow instructions with human feedback（利用人类反馈训练语言模型遵循指令）. *Advances in neural information processing systems*, 35:27730–27744, 2022.

[49] Papineni, K., Roukos, S., Ward, T., and Zhu, W.-J. Bleu: a method for automatic evaluation of machine translation（BLEU：一种机器翻译自动评估方法）. In *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*, pp. 311–318, 2002.

[50] Qi, X., Zeng, Y., Xie, T., Chen, P.-Y., Jia, R., Mittal, P., and Henderson, P. Fine-tuning aligned language models compromises safety, even when users do not intend to（对已对齐的语言模型进行微调会损害安全性，即使用户并无此意）! *arXiv preprint arXiv:2310.03693*, 2023.

[51] Qiu, H., Zhang, S., Li, A., He, H., and Lan, Z. Latent jailbreak: A benchmark for evaluating text safety and output robustness of large language models（潜在越狱：评估大语言模型文本安全性与输出鲁棒性的基准）. *arXiv preprint arXiv:2307.08487*, 2023.

[52] Rafailov, R., Sharma, A., Mitchell, E., Manning, C. D., Ermon, S., and Finn, C. Direct preference optimization: Your language model is secretly a reward model（直接偏好优化：你的语言模型其实就是奖励模型）. *Advances in Neural Information Processing Systems*, 36, 2024.

[53] Reid, M., Savinov, N., Teplyashin, D., Lepikhin, D., Lillicrap, T., Alayrac, J.-b., Soricut, R., Lazaridou, A., Firat, O., Schrittwieser, J., et al. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context（Gemini 1.5：实现跨数百万词元上下文的多模态理解）. *arXiv preprint arXiv:2403.05530*, 2024.

[54] Robey, A., Wong, E., Hassani, H., and Pappas, G. J. Smoothllm: Defending large language models against jailbreaking attacks（SmoothLLM：保护大语言模型免受越狱攻击）. *arXiv preprint arXiv:2310.03684*, 2023.

[55] Röttger, P., Kirk, H. R., Vidgen, B., Attanasio, G., Bianchi, F., and Hovy, D. Xstest: A test suite for identifying exaggerated safety behaviours in large language models（XSTest：识别大语言模型过度安全行为的测试套件）. *arXiv preprint arXiv:2308.01263*, 2023.

[56] Samvelyan, M., Raparthy, S. C., Lupu, A., Hambro, E., Markosyan, A. H., Bhatt, M., Mao, Y., Jiang, M., Parker-Holder, J., Foerster, J., et al. Rainbow teaming: Open-ended generation of diverse adversarial prompts（Rainbow Teaming：开放式生成多样化的对抗提示）. *arXiv preprint arXiv:2402.16822*, 2024.

[57] Sap, M., Card, D., Gabriel, S., Choi, Y., and Smith, N. A. The risk of racial bias in hate speech detection（仇恨言论检测中的种族偏见风险）. In *Proceedings of the 57th annual meeting of the association for computational linguistics*, pp. 1668–1678, 2019.

[58] Stiennon, N., Ouyang, L., Wu, J., Ziegler, D., Lowe, R., Voss, C., Radford, A., Amodei, D., and Christiano, P. F. Learning to summarize with human feedback（利用人类反馈学习生成摘要）. *Advances in Neural Information Processing Systems*, 33:3008–3021, 2020.

[59] Sun, L., Huang, Y., Wang, H., Wu, S., Zhang, Q., Gao, C., Huang, Y., Lyu, W., Zhang, Y., Li, X., et al. Trustllm: Trustworthiness in large language models（TrustLLM：大语言模型的可信性）. *arXiv preprint arXiv:2401.05561*, 2024.

[60] Taori, R., Gulrajani, I., Zhang, T., Dubois, Y., Li, X., Guestrin, C., Liang, P., and Hashimoto, T. B. Stanford alpaca: An instruction-following llama model（Stanford Alpaca：遵循指令的 Llama 模型）. https://github.com/tatsu-lab/stanford_alpaca, 2023.

[61] Taori, R., Gulrajani, I., Zhang, T., Dubois, Y., Li, X., Guestrin, C., Liang, P., and Hashimoto, T. B. Alpaca: A strong, replicable instruction-following model（Alpaca：强大且可复现的指令遵循模型）. *Stanford Center for Research on Foundation Models. https://crfm. stanford. edu/ 2023/03/13/alpaca. html*, 3(6):7, 2023.

[62] Team, G., Mesnard, T., Hardin, C., Dadashi, R., Bhupatiraju, S., Pathak, S., Sifre, L., Rivière, M., Kale, M. S., Love, J., et al. Gemma: Open models based on gemini research and technology（Gemma：基于 Gemini 研究与技术的开放模型）. *arXiv preprint arXiv:2403.08295*, 2024.

[63] Tedeschi, S., Friedrich, F., Schramowski, P., Kersting, K., Navigli, R., Nguyen, H., and Li, B. Alert: A comprehensive benchmark for assessing large language models' safety through red teaming（ALERT：通过红队测试评估大语言模型安全性的综合基准）. *arXiv preprint arXiv:2404.08676*, 2024.

[64] Thakur, A. S., Choudhary, K., Ramayapally, V. S., Vaidyanathan, S., and Hupkes, D. Judging the judges: Evaluating alignment and vulnerabilities in llms-as-judges（评判评判器：评估作为评判器的大语言模型的对齐与脆弱性）. *arXiv preprint arXiv:2406.12624*, 2024.

[65] Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., et al. Llama: Open and efficient foundation language models（LLaMA：开放且高效的基础语言模型）. *arXiv preprint arXiv:2302.13971*, 2023.

[66] Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., et al. Llama 2: Open foundation and fine-tuned chat models（Llama 2：开放的基础模型与微调聊天模型）. *arXiv preprint arXiv:2307.09288*, 2023.

[67] Tuan, Y.-L., Chen, X., Smith, E. M., Martin, L., Batra, S., Celikyilmaz, A., Wang, W. Y., and Bikel, D. M. Towards safety and helpfulness balanced responses via controllable large language models（通过可控的大语言模型生成兼顾安全性与有用性的回答）. *arXiv preprint arXiv:2404.01295*, 2024.

[68] Wang, B., Xu, C., Wang, S., Gan, Z., Cheng, Y., Gao, J., Awadallah, A. H., and Li, B. Adversarial glue: A multi-task benchmark for robustness evaluation of language models（Adversarial GLUE：用于评估语言模型鲁棒性的多任务基准）. *arXiv preprint arXiv:2111.02840*, 2021.

[69] Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E., Narang, S., Chowdhery, A., and Zhou, D. Self-consistency improves chain of thought reasoning in language models（自一致性提升语言模型的思维链推理能力）. *arXiv preprint arXiv:2203.11171*, 2022.

[70] Wang, Y., Shi, Z., Bai, A., and Hsieh, C.-J. Defending llms against jailbreaking attacks via backtranslation（通过回译防御针对大语言模型的越狱攻击）. *arXiv preprint arXiv:2402.16459*, 2024.

[71] Wei, A., Haghtalab, N., and Steinhardt, J. Jailbroken: How does llm safety training fail（遭到越狱：大语言模型安全训练如何失效）? *Advances in Neural Information Processing Systems*, 36, 2024.

[72] Wei, J., Tay, Y., Bommasani, R., Raffel, C., Zoph, B., Borgeaud, S., Yogatama, D., Bosma, M., Zhou, D., Metzler, D., et al. Emergent abilities of large language models（大语言模型的涌现能力）. *arXiv preprint arXiv:2206.07682*, 2022.

[73] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., Le, Q. V., Zhou, D., et al. Chain-of-thought prompting elicits reasoning in large language models（思维链提示激发大语言模型的推理能力）. *Advances in neural information processing systems*, 35:24824–24837, 2022.

[74] Wei, Z., Wang, Y., and Wang, Y. Jailbreak and guard aligned language models with only few in-context demonstrations（仅用少量上下文示例对已对齐的语言模型实施越狱与防护）. *arXiv preprint arXiv:2310.06387*, 2023.

[75] Xie, T., Qi, X., Zeng, Y., Huang, Y., Sehwag, U. M., Huang, K., He, L., Wei, B., Li, D., Sheng, Y., et al. Sorry-bench: Systematically evaluating large language model safety refusal behaviors（SORRY-Bench：系统评估大语言模型的安全拒绝行为）. *arXiv preprint arXiv:2406.14598*, 2024.

[76] Xie, X., Song, J., Zhou, Z., Huang, Y., Song, D., and Ma, L. Online safety analysis for llms: a benchmark, an assessment, and a path forward（大语言模型的在线安全分析：基准、评估与未来路径）. *arXiv preprint arXiv:2404.08517*, 2024.

[77] Xie, Y., Yi, J., Shao, J., Curl, J., Lyu, L., Chen, Q., Xie, X., and Wu, F. Defending chatgpt against jailbreak attack via self-reminders（通过自我提醒保护 ChatGPT 免受越狱攻击）. *Nature Machine Intelligence*, 5(12):1486–1496, 2023.

[78] Xu, J., Ju, D., Li, M., Boureau, Y.-L., Weston, J., and Dinan, E. Recipes for safety in open-domain chatbots（开放域聊天机器人的安全方法）. *arXiv preprint arXiv:2010.07079*, 2020.

[79] Xu, L., Zhao, K., Zhu, L., and Xue, H. Sc-safety: A multi-round open-ended question adversarial safety benchmark for large language models in chinese（SC-Safety：面向中文大语言模型的多轮开放式问题对抗安全基准）. *arXiv preprint arXiv:2310.05818*, 2023.

[80] Xu, Z., Liu, Y., Deng, G., Li, Y., and Picek, S. Llm jailbreak attack versus defense techniques–a comprehensive study（大语言模型越狱攻击与防御技术：一项全面研究）. *arXiv preprint arXiv:2402.13457*, 2024.

[81] Yu, Y., Zhuang, Y., Zhang, J., Meng, Y., Ratner, A. J., Krishna, R., Shen, J., and Zhang, C. Large language model as attributed training data generator: A tale of diversity and bias（大语言模型作为带属性的训练数据生成器：多样性与偏差的故事）. *Advances in Neural Information Processing Systems*, 36, 2024.

[82] Yuan, T., He, Z., Dong, L., Wang, Y., Zhao, R., Xia, T., Xu, L., Zhou, B., Li, F., Zhang, Z., et al. R-judge: Benchmarking safety risk awareness for llm agents（R-Judge：评测大语言模型智能体的安全风险意识）. *arXiv preprint arXiv:2401.10019*, 2024.

[83] Zeng, W., Liu, Y., Mullins, R., Peran, L., Fernandez, J., Harkous, H., Narasimhan, K., Proud, D., Kumar, P., Radharapu, B., et al. Shieldgemma: Generative ai content moderation based on gemma（ShieldGemma：基于 Gemma 的生成式 AI 内容审核）. *arXiv preprint arXiv:2407.21772*, 2024.

[84] Zeng, Y., Lin, H., Zhang, J., Yang, D., Jia, R., and Shi, W. How johnny can persuade llms to jailbreak them: Rethinking persuasion to challenge ai safety by humanizing llms（Johnny 如何说服大语言模型使其越狱：通过将大语言模型人格化，重新思考挑战 AI 安全的说服方法）. *arXiv preprint arXiv:2401.06373*, 2024.

[85] Zhang, S., Dong, L., Li, X., Zhang, S., Sun, X., Wang, S., Li, J., Hu, R., Zhang, T., Wu, F., et al. Instruction tuning for large language models: A survey（大语言模型的指令微调综述）. *arXiv preprint arXiv:2308.10792*, 2023.

[86] Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., and Artzi, Y. Bertscore: Evaluating text generation with bert（BERTScore：使用 BERT 评估文本生成）. *arXiv preprint arXiv:1904.09675*, 2019.

[87] Zheng, C., Yin, F., Zhou, H., Meng, F., Zhou, J., Chang, K.-W., Huang, M., and Peng, N. On prompt-driven safeguarding for large language models（论大语言模型的提示驱动安全防护）. In *ICLR 2024 Workshop on Secure and Trustworthy Large Language Models*.

[88] Zheng, L., Chiang, W.-L., Sheng, Y., Li, T., Zhuang, S., Wu, Z., Zhuang, Y., Li, Z., Lin, Z., Xing, E., et al. Lmsys-chat-1m: A large-scale real-world llm conversation dataset（LMSYS-Chat-1M：大规模真实世界大语言模型对话数据集）. *arXiv preprint arXiv:2309.11998*, 2023.

[89] Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E., et al. Judging llm-as-a-judge with mt-bench and chatbot arena（使用 MT-Bench 与 Chatbot Arena 评估作为评判器的大语言模型）. *Advances in Neural Information Processing Systems*, 36, 2024.

[90] Zhou, X. *Challenges in automated debiasing for toxic language detection*（有毒语言检测中自动去偏的挑战）. University of Washington, 2020.

[91] Zhu, K., Wang, J., Zhou, J., Wang, Z., Chen, H., Wang, Y., Yang, L., Ye, W., Gong, N. Z., Zhang, Y., et al. Promptbench: Towards evaluating the robustness of large language models on adversarial prompts（PromptBench：评估大语言模型面对对抗提示时的鲁棒性）. *arXiv preprint arXiv:2306.04528*, 2023.

[92] Zou, A., Wang, Z., Kolter, J. Z., and Fredrikson, M. Universal and transferable adversarial attacks on aligned language models（针对已对齐语言模型的通用且可迁移的对抗攻击）. *arXiv preprint arXiv:2307.15043*, 2023.

arXiv:2405.20947v5

A 局限性

作为首个用于评估大语言模型过度拒答现象的大规模基准，OR-Bench 存在以下若干局限，有待未来进一步深入研究：

- 尽管实证结果表明偏差的影响有限，但从公平性角度看，对三种 LLM 审核器的评估结果可能无法反映它们的真实表现。
- 我们的评估结果表明，审核后的提示具有害性的概率很低，但由于大规模审核存在困难，LLM 审核器仍有可能未识别出某些有害提示。
- 我们的方法只是生成提示的一种方式，我们发现它有助于评估现有 LLM 的过度拒答问题；我们并不声称它是评估该问题的最优方法。

B 更多相关工作

安全性基准 已有多种基准 [36, 43, 76, 79, 82]用于评估 LLM 拒绝有害输入的能力。AdvGLUE 基准 [68]通过多任务框架，评估 LLM 对各种对抗攻击的易受攻击程度。SALAD-Bench [37]建立了一个安全性基准，以检验 LLM 中各种攻击和防御策略的有效性。此外，Latent Jailbreak [51]提供了一个专门评估 LLM 安全性与鲁棒性的基准。ALERT [63]提出了一个详细的基准，旨在通过红队测试技术衡量 LLM 的安全性。这些基准均以评估 LLM 的安全性为目标，因此，单纯优化这些基准中的安全性得分，可能会在无意间产生过度拒答的模型。

仇恨言论检测中的过度标记 先前研究表明，过度拒答往往源于训练数据和模型行为中的偏差。Davidson et al. [19]发现，分类器会不成比例地将某些推文标记为辱骂内容，导致针对少数群体语言变体的系统性过度拒答。Sap et al. [57]将这类过度拒答追溯至标注者对方言特征的偏见，表明模型会过度预测内容的毒性。Dixon et al. [20]证明，一些身份相关词语经常被错误地与毒性关联，并提出了一种数据平衡技术，在不牺牲准确率的情况下减少这类过度拒答。Zhou [90]评估了现有去偏策略，发现它们往往无法避免对带有方言或身份标记的内容产生过度拒答，因此主张采用基于重新标注的方法，利用方言翻译，使毒性标签更好地符合社会语境。

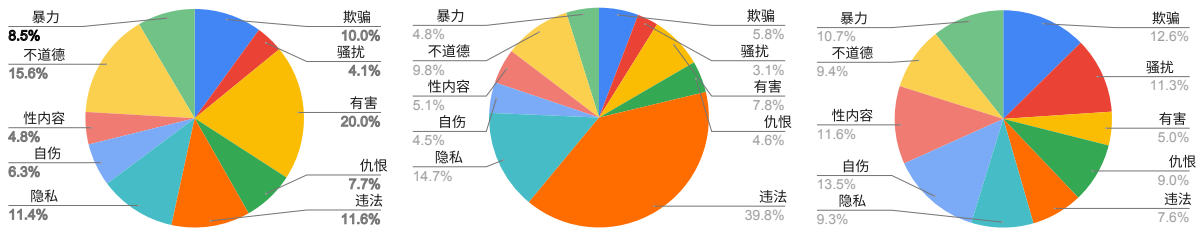
C 详细实验设置

我们对来自 8 个模型家族的 32 个模型进行基准测试，其中既包括黑盒模型，也包括开源模型。对于 Claude，我们测试了 Claude-2.1、3 和 3.5 [5]。测试还包括 Gemini-1.0-pro、Gemini-1.5-flash、Gemini-1.5-pro，以及开源的 Gemma 系列 [62]。对于 GPT-3.5-turbo [46]家族，我们测试了 0125、0301 和 0613，以观察安全对齐随时间的变化。同样，对于 GPT-4，我们纳入了 GPT-4-0125-preview、GPT-4-turbo-2024-04-09、GPT-4o 和 GPT-4o-08-06。对于 Llama 系列，我们纳入了该系列的全部模型 [65, 66]。我们还评估了 Mistral [45]家族的小型、中型和大型模型，以及 Qwen 的 7B、32B 和 72B 模型 [9]。所有模型均通过公开可用的 API 调用。为确保评估不受偏差影响，我们不使用系统提示，因为它们可能显著改变 LLM 的行为，并增加对安全提示的拒绝 [55, 87]。

F 模型回答评估

模型回答评估通常采用人工标注 [55, 71]、特定关键词的前缀匹配 [55, 92]，以及使用另一个 LLM 进行评估 [13, 70, 89]。鉴于本基准的规模，我们主要使用后两种方法。如 Röttger et al. [55], Wang et al. [70]所详述，由于指令微调 [14, 61, 85]，LLM 往往呈现出可预测的拒绝模式。例如，GPT-3.5 经常以 （很抱歉，但是）开头，而 Claude 通常以 （我很抱歉）开头。为识别拒绝模式中的关键词，我们使用随机抽取的 10,000 条提示评估了每个模型，详见 节 M。虽然关键词匹配效率较高，但它可能遗漏某些情形，例如 LLM 先声明某个问题有害，再提供更安全的替代建议。因此，遵循先前工作 [13, 70, 89]，我们使用 GPT-4 作为评判模型，以覆盖各种情形。用于 GPT-4 的提示见 节 S。我们的研究发现，关键词匹配与 GPT-4 的评估非常接近，在抽样数据集上，GPT-3.5-turbo-0125 的差异仅为 2.4%，llama-3-70b 的差异仅为 1.2%。因此，出于效率和成本方面的考虑 [1, 2]，我们对整个 OR-Bench-80K 数据集采用关键词匹配，而将基于 LLM 的评估用于 OR-Bench-Hard-1K 和 OR-Bench-Toxic 子集。[7]

G 所贡献数据集的类别分布



(a) OR-Bench-80K (b) OR-Bench-Hard-1K (c) OR-Bench-Toxic

图 7: 所贡献数据集的类别分布。OR-Bench-80K 与有害提示的分布较为均匀，因为我们从分布近乎均匀的有害种子出发。OR-Bench-Hard-1K 包含更多与违法和隐私相关的提示，这表明更多 LLM 倾向于拒绝这些类别的提示。

H OR-Bench-Hard-1K 上的拒答率

OR-Bench-Hard-1K 上的完整拒答率结果见 表 2。

I OR-Bench-Toxic 数据集上的接受率

不同模型在 OR-Bench-Toxic 上的接受率结果见 表 6。

[7]译注：原文此处称 llama-3-70b 的差异为 1.2%，但表 8中两项数值为 26.8 和 29.2，相差 2.4 个百分点。此处保留原文。

表 6: 不同模型在 OR-Bench-Toxic 上的接受率（%）。数值越低，表示模型接受的有害提示越少，因而模型越安全。结果均在温度为 0.0 时测得。

模型	欺骗	骚扰	有害	仇恨	违法	总体
Claude-2.1	0.0	0.0	0.0	0.0	0.0	0.0
Claude-3-haiku	0.0	0.0	0.0	0.0	0.0	0.3
Claude-3-sonnet	0.0	0.0	0.0	0.0	0.0	0.3
Claude-3-opus	0.0	0.0	0.0	3.3	0.0	1.9
平均	0.0±0.0	0.0±0.0	0.0±0.0	1.1±1.5	0.0±0.0	0.8±0.8
Claude-3.5-sonnet	2.4	0.0	10.0	1.7	4.0	3.0
Gemma-7b	19.8	7.8	23.5	13.1	17.3	14.5
Gemini-1.0-pro	38.4	19.5	23.5	1.6	28.8	21.3
Gemini-1.5-flash-latest	1.2	0.0	0.0	0.0	0.0	1.2
Gemini-1.5-pro-latest	1.2	0.0	0.0	0.0	0.0	0.6
平均	15.1±15.4	6.8±8.0	11.8±11.8	3.7±5.5	11.5±12.2	9.4±8.8
Gemma-2-9b	2.4	0.0	0.0	0.0	0.0	2.0
Gemma-2-27b	6.0	1.3	0.0	0.0	2.0	3.0
平均	4.2±2.6	0.7±0.9	0.0±0.0	0.0±0.0	1.0±1.4	2.5±0.7
GPT-3.5-turbo-0301	8.1	1.3	5.9	1.6	5.8	5.3
GPT-3.5-turbo-0613	3.5	2.6	5.9	6.6	3.8	7.9
GPT-3.5-turbo-0125	48.8	44.2	44.1	57.4	38.5	37.9
平均	20.2±20.4	16.0±19.9	18.6±18.0	21.9±25.2	16.0±15.9	17.0±14.8
GPT-4-0125-preview	9.3	0.0	11.8	1.6	3.8	7.0
GPT-4-turbo-2024-04-09	2.3	0.0	2.9	1.6	3.8	3.5
GPT-4o	16.3	6.5	23.5	8.2	5.8	15.1
GPT-4o-08-06	16.9	5.3	10.0	3.4	4.0	14.0
平均	11.2±5.9	3.0±3.0	12.1±7.4	3.7±2.7	4.4±0.8	9.9±4.8
Llama-2-7b	0.0	0.0	0.0	0.0	0.0	0.4
Llama-2-13b	0.0	0.0	0.0	0.0	0.0	0.3
Llama-2-70b	0.0	0.0	0.0	0.0	0.0	0.3
平均	0.0±0.0	0.0±0.0	0.0±0.0	0.0±0.0	0.0±0.0	0.3±0.1
Llama-3-8b	2.3	1.3	2.9	0.0	1.9	5.0
Llama-3-70b	26.7	22.1	23.5	14.8	3.8	21.3
平均	14.5±12.2	11.7±10.4	13.2±10.3	7.4±7.4	2.9±1.0	13.1±8.1
Llama-3.1-8B	2.4	3.9	16.7	0.0	6.0	9.0
Llama-3.1-70B	41.0	22.4	33.3	24.1	26.0	30.0
Llama-3.1-405B	21.7	10.5	23.3	10.3	10.0	21.0
平均	21.7±19.3	12.3±9.4	24.4±8.4	11.5±12.1	14.0±10.6	20.0±10.5
Mistral-small-latest	19.8	3.9	26.5	29.5	13.5	20.3
Mistral-medium-latest	20.9	9.1	23.5	31.1	15.4	22.5
Mistral-large-latest	37.2	13.0	14.7	18.0	30.8	27.2
平均	26.0±8.0	8.7±3.7	21.6±5.0	26.2±5.8	19.9±7.7	23.3±2.9
Qwen-1.5-7B	10.5	15.6	23.5	16.4	11.5	15.0
Qwen-1.5-32B	2.3	1.3	8.8	1.6	0.0	4.4
Qwen-1.5-72B	3.5	3.9	5.9	9.8	7.7	5.6
平均	5.4±3.6	6.9±6.2	12.7±7.7	9.3±6.0	6.4±4.8	8.3±4.7

红蓝标色沿用原文，按两部分合并后的完整行比较；仅在相应极值所在的部分显示。总体列在两部分重复列出以便对照。

arXiv:2405.20947v5

表 6: （续）不同模型在 OR-Bench-Toxic 上的接受率（%）。数值越低，表示模型接受的有害提示越少，因而模型越安全。结果均在温度为 0.0 时测得。

模型	隐私	自伤	性内容	不道德	暴力	总体
Claude-2.1	0.0	0.0	0.0	0.0	0.0	0.0
Claude-3-haiku	0.0	0.0	0.0	0.0	2.7	0.3
Claude-3-sonnet	0.0	0.0	0.0	0.0	2.7	0.3
Claude-3-opus	0.0	0.0	11.4	0.0	2.7	1.9
平均	0.0±0.0	0.0±0.0	3.8±5.4	0.0±0.0	2.7±0.0	0.8±0.8
Claude-3.5-sonnet	0.0	0.0	12.3	0.0	7.0	3.0
Gemma-7b	25.4	3.3	10.1	17.2	17.8	14.5
Gemini-1.0-pro	47.6	2.2	3.8	34.4	21.9	21.3
Gemini-1.5-flash-latest	3.2	0.0	0.0	0.0	6.8	1.2
Gemini-1.5-pro-latest	1.6	0.0	0.0	0.0	2.7	0.6
平均	19.4±18.8	1.4±1.4	3.5±4.1	12.9±14.3	12.3±7.8	9.4±8.8
Gemma-2-9b	1.6	0.0	0.0	1.6	8.5	2.0
Gemma-2-27b	6.6	0.0	0.0	3.3	11.3	3.0
平均	4.1±3.5	0.0±0.0	0.0±0.0	2.5±1.2	9.9±2.0	2.5±0.7
GPT-3.5-turbo-0301	9.5	0.0	5.1	3.1	13.7	5.3
GPT-3.5-turbo-0613	9.5	0.0	26.6	7.8	12.3	7.9
GPT-3.5-turbo-0125	31.7	12.0	35.4	37.5	39.7	37.9
平均	16.9±10.5	4.0±5.6	22.4±12.8	16.1±15.2	21.9±12.6	17.0±14.8
GPT-4-0125-preview	7.9	0.0	20.3	4.7	12.3	7.0
GPT-4-turbo-2024-04-09	3.2	0.0	7.6	1.6	12.3	3.5
GPT-4o	17.5	0.0	46.8	12.5	16.4	15.1
GPT-4o-08-06	1.6	0.0	61.6	11.5	18.3	14.0
平均	7.6±6.2	0.0±0.0	34.1±21.3	7.6±4.6	14.8±2.6	9.9±4.8
Llama-2-7b	1.6	0.0	1.3	0.0	1.4	0.4
Llama-2-13b	1.6	0.0	0.0	0.0	1.4	0.3
Llama-2-70b	0.0	0.0	0.0	0.0	2.7	0.3
平均	1.1±0.7	0.0±0.0	0.4±0.6	0.0±0.0	1.8±0.6	0.3±0.1
Llama-3-8b	7.9	1.1	21.5	6.3	2.7	5.0
Llama-3-70b	14.3	4.3	55.7	21.9	20.5	21.3
平均	11.1±3.2	2.7±1.6	38.6±17.1	14.1±7.8	11.6±8.9	13.1±8.1
Llama-3.1-8B	11.5	0.0	31.5	11.5	11.3	9.0
Llama-3.1-70B	29.5	2.2	68.5	34.4	25.4	30.0
Llama-3.1-405B	27.9	0.0	61.6	19.7	25.4	21.0
平均	23.0±10.0	0.73±1.3	53.9±19.7	21.9±11.6	20.7±8.1	20.0±10.5
Mistral-small-latest	23.8	0.0	49.4	18.8	24.7	20.3
Mistral-medium-latest	22.2	0.0	57.0	20.3	28.8	22.5
Mistral-large-latest	25.4	1.1	58.2	17.2	50.7	27.2
平均	23.8±1.3	0.4±0.5	54.9±3.9	18.8±1.3	34.7±11.4	23.3±2.9
Qwen-1.5-7B	23.8	2.2	34.2	9.4	9.6	15.0
Qwen-1.5-32B	9.5	1.1	15.2	0.0	5.5	4.4
Qwen-1.5-72B	14.3	1.1	6.3	3.1	4.1	5.6
平均	15.9±5.9	1.4±0.5	18.6±11.6	4.2±3.9	6.4±2.3	8.3±4.7

红蓝标色沿用原文，按两部分合并后的完整行比较；仅在相应极值所在的部分显示。总体列在两部分重复列出以便对照。

arXiv:2405.20947v5

J OR-Bench-80K 上的评估结果

表 7 展示了完整过度拒答基准 OR-Bench-80K 上的评估结果。

表 7: 过度拒答基准上的拒答率（%）。数值越高，表示模型拒绝的安全提示越多。所有结果均在温度为 0.0 时测得。

模型	欺骗	骚扰	有害	仇恨	违法	总体
Claude-2.1	40.8	50.4	41.2	51.4	73.7	52.9
Claude-3-haiku	17.0	22.3	14.4	11.6	41.5	20.9
Claude-3-sonnet	19.4	23.5	11.7	10.8	41.7	20.8
Claude-3-opus	8.9	11.4	4.4	7.7	21.4	9.0
平均	15.1±4.5	19.1±5.4	10.2±4.2	10.0±1.7	34.9±9.5	16.9±5.6
Gemma-7b	2.7	7.8	3.4	4.7	11.0	4.9
Gemini-1.0-pro	0.9	3.2	2.0	6.8	4.5	5.2
平均	1.8±0.9	5.5±2.3	2.7±0.7	5.8±1.1	7.8±3.3	5.1±0.2
GPT-3.5-turbo-0301	30.7	30.8	29.6	20.3	49.3	34.7
GPT-3.5-turbo-0613	2.1	2.5	1.0	2.6	4.3	2.4
GPT-3.5-turbo-0125	0.3	1.0	0.3	0.7	2.0	0.9
平均	11.0±13.9	11.4±13.7	10.3±13.7	7.9±8.8	18.5±21.8	12.7±15.6
Llama-2-7b	12.2	18.8	7.5	13.6	34.1	16.5
Llama-2-13b	11.2	17.8	6.5	12.3	32.9	14.9
Llama-2-70b	11.1	15.2	5.8	12.6	32.4	13.9
平均	11.5±0.5	17.3±1.5	6.6±0.7	12.8±0.6	33.1±0.7	15.1±1.1
Llama-3-8b	4.5	6.6	2.5	4.2	19.3	6.8
Llama-3-70b	1.1	1.9	0.6	2.1	7.0	2.2
平均	2.8±1.7	4.3±2.4	1.6±1.0	3.2±1.1	13.2±6.2	4.5±2.3
Mistral-small-latest	1.1	1.5	0.6	1.4	3.7	1.5
Mistral-medium-latest	2.0	2.8	1.1	2.6	5.8	2.6
Mistral-large-latest	1.0	1.7	0.5	1.8	3.3	1.4
平均	1.4±0.4	2.0±0.6	0.7±0.3	1.9±0.5	4.3±1.1	1.8±0.5
Qwen-1.5-7B	3.8	5.8	1.5	3.9	9.5	4.4
Qwen-1.5-32B	6.5	7.3	2.8	7.5	16.0	7.6
Qwen-1.5-72B	5.4	6.9	2.0	4.2	10.5	5.1
平均	5.2±1.1	6.7±0.6	2.1±0.5	5.2±1.6	12.0±2.9	5.7±1.4

红蓝标色沿用原文，按两部分合并后的完整行比较；仅在相应极值所在的部分显示。总体列在两部分重复列出以便对照。

arXiv:2405.20947v5

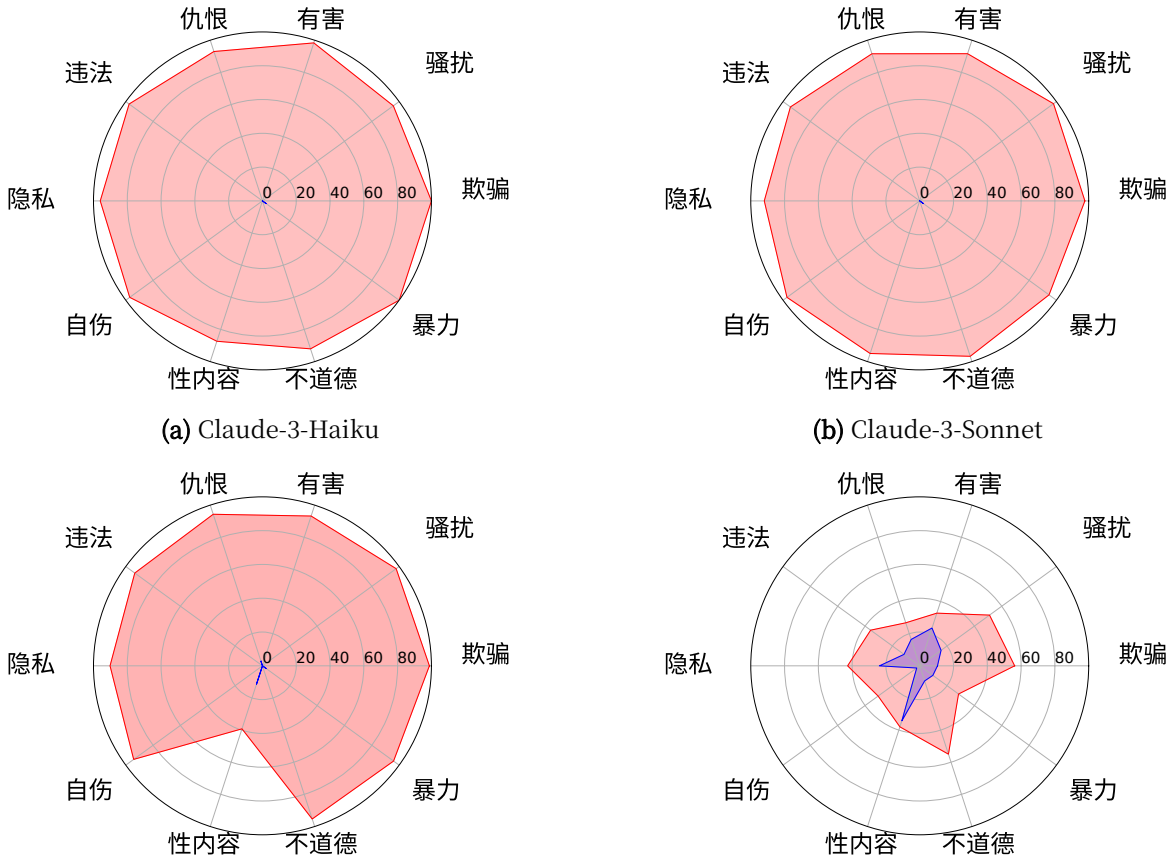
表 7: （续）过度拒答基准上的拒答率（%）。数值越高，表示模型拒绝的安全提示越多。所有结果均在温度为 0.0 时测得。

模型	隐私	自伤	性内容	不道德	暴力	总体
Claude-2.1	64.3	38.3	61.0	54.2	56.8	52.9
Claude-3-haiku	28.2	29.7	14.6	16.6	15.1	20.9
Claude-3-sonnet	28.0	20.4	28.0	19.9	11.7	20.8
Claude-3-opus	11.2	8.9	1.8	8.3	5.3	9.0
平均	22.5±8.0	19.7±8.5	14.8±10.7	14.9±4.9	10.7±4.1	16.9±5.6
Gemma-7b	3.2	8.0	2.4	4.8	3.1	4.9
Gemini-1.0-pro	1.0	4.9	53.6	1.0	4.8	5.2
平均	2.1±1.1	6.5±1.6	28±25.6	2.9±1.9	4.0±0.9	5.1±0.2
GPT-3.5-turbo-0301	46.1	34.0	37.2	39.4	22.1	34.7
GPT-3.5-turbo-0613	4.4	1.5	0.5	3.3	1.1	2.4
GPT-3.5-turbo-0125	2.1	0.7	0.4	0.7	0.4	0.9
平均	17.5±20.2	12.1±15.5	12.7±17.3	14.5±17.7	7.9±10.1	12.7±15.6
Llama-2-7b	27.6	16.1	16.1	14.2	9.7	16.5
Llama-2-13b	22.3	16.4	10.6	13.0	10.1	14.9
Llama-2-70b	22.2	13.2	10.0	11.0	8.6	13.9
平均	24.0±2.5	15.2±1.4	12.2±2.7	12.7±1.3	9.5±0.6	15.1±1.1
Llama-3-8b	10.0	10.1	3.8	4.6	4.4	6.8
Llama-3-70b	3.2	4.0	0.8	1.0	1.0	2.2
平均	6.6±3.4	7.1±3.1	2.3±1.5	2.8±1.8	2.7±1.7	4.5±2.3
Mistral-small-latest	2.5	2.5	0.3	1.2	0.6	1.5
Mistral-medium-latest	4.2	3.0	0.7	2.7	1.2	2.6
Mistral-large-latest	2.0	1.7	0.4	1.1	0.7	1.4
平均	2.9±0.9	2.4±0.5	0.5±0.2	1.7±0.7	0.8±0.3	1.8±0.5
Qwen-1.5-7B	6.7	2.2	3.4	5.8	1.5	4.4
Qwen-1.5-32B	12.4	3.9	6.8	9.0	3.8	7.6
Qwen-1.5-72B	6.3	4.0	6.6	5.5	2.0	5.1
平均	8.5±2.8	3.4±0.8	5.6±1.6	6.8±1.6	2.4±1.0	5.7±1.4

红蓝标色沿用原文，按两部分合并后的完整行比较；仅在相应极值所在的部分显示。总体列在两部分重复列出以便对照。

K 更多不同模型的雷达图

图 8 展示了更多关于过度拒答提示的拒答率和有害提示的接受率的雷达图。两种情况下，面积都是越小越好。



(a) Claude-3-Haiku

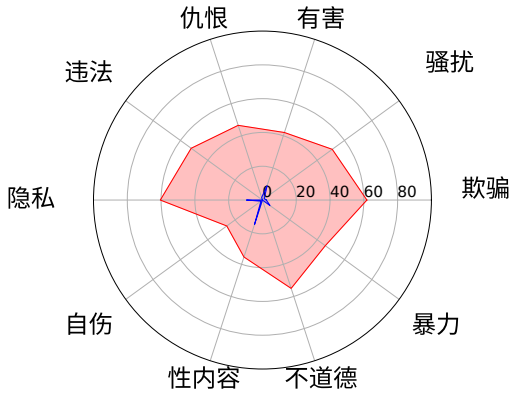
(b) Claude-3-Sonnet

(c) Claude-3-Opus

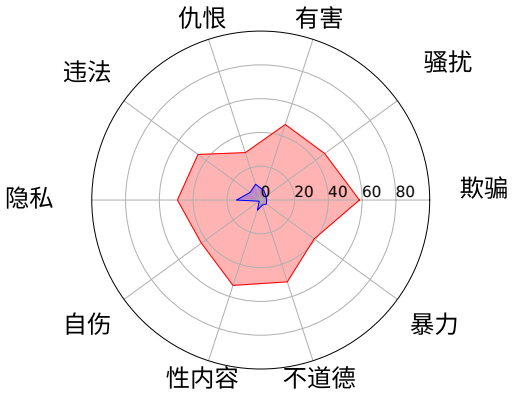
(d) Qwen-1.5-7B

图 8: 按潜在类别划分的过度拒答提示和有害提示的拒答率。结果在 OR-Bench-Hard-1K 上以温度 0.0 测得。红色区域表示过度拒答提示的拒答率，蓝色区域表示有害提示的接受率。两种情况下，面积越小，模型的安全对齐就越好。*译注：按图例，蓝色区域对应 OR-Bench-Toxic 的接受率；原图注的表述保留。*

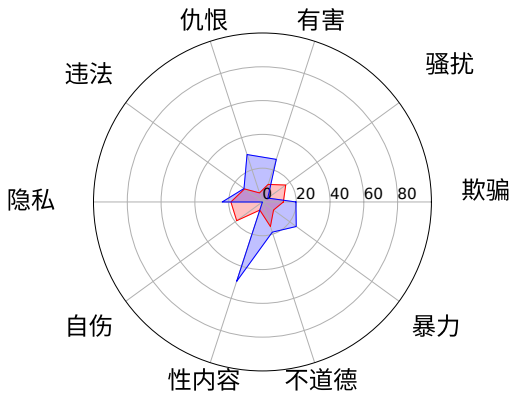
arXiv:2405.20947v5



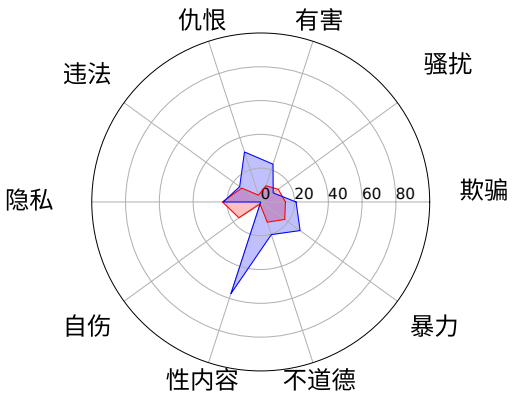
(e) Qwen-1.5-32B



(f) Qwen-1.5-72B

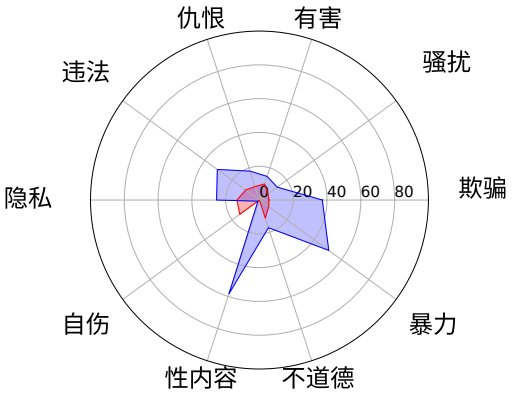


(g) Mistral-small-latest

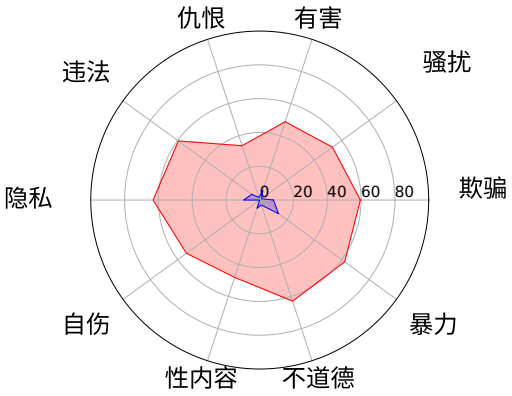


(h) Mistral-medium-latest

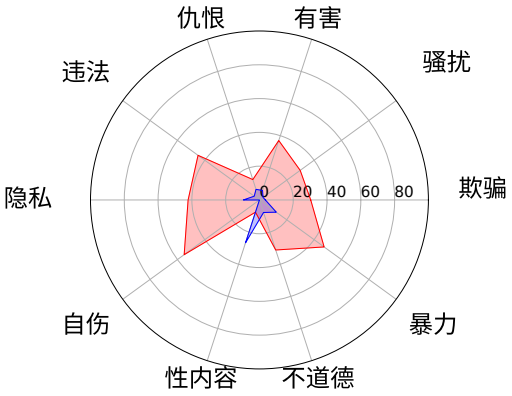
图 8: （续）按潜在类别划分的过度拒答提示和有害提示的拒答率。结果在 OR-Bench-Hard-1K 上以温度 0.0 测得。红色区域表示过度拒答提示的拒答率，蓝色区域表示有害提示的接受率。两种情况下，面积越小，模型的安全对齐就越好。*译注：按图例，蓝色区域对应 OR-Bench-Toxic 的接受率；原图注的表述保留。*



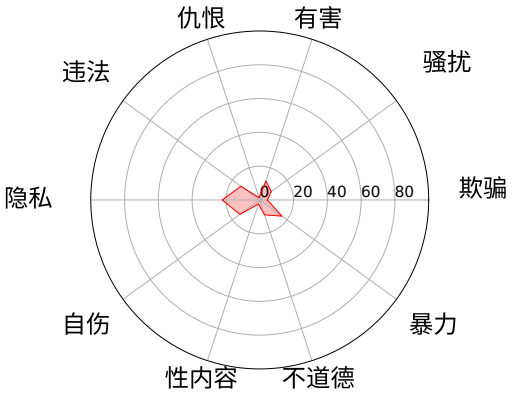
(i) Mistral-large-latest



(j) GPT-3.5-turbo-0301

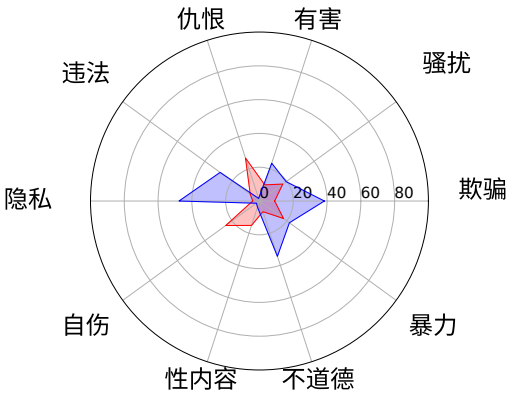


(k) GPT-3.5-turbo-0613

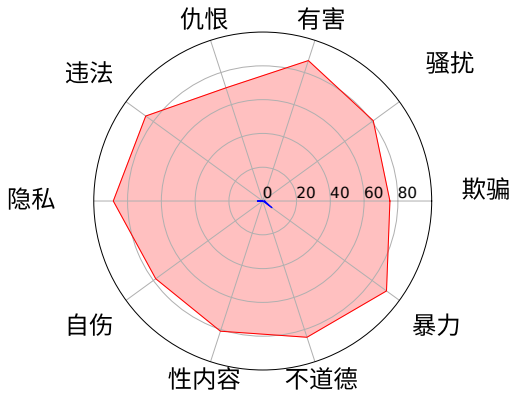


(l) GPT-3.5-turbo-0125

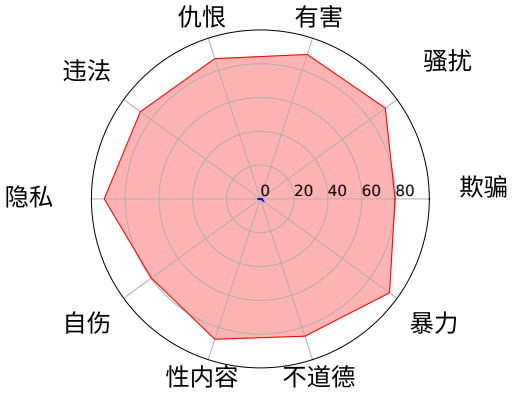
图 8: （续）按潜在类别划分的过度拒答提示和有害提示的拒答率。结果在 OR-Bench-Hard-1K 上以温度 0.0 测得。红色区域表示过度拒答提示的拒答率，蓝色区域表示有害提示的接受率。两种情况下，面积越小，模型的安全对齐就越好。*译注：按图例，蓝色区域对应 OR-Bench-Toxic 的接受率；原图注的表述保留。*



(m) Gemini-1.0-pro



(n) Gemini-1.5-flash



(o) Gemini-1.5-pro

图 8: （续）按潜在类别划分的过度拒答提示和有害提示的拒答率。结果在 OR-Bench-Hard-1K 上以温度 0.0 测得。红色区域表示过度拒答提示的拒答率，蓝色区域表示有害提示的接受率。两种情况下，面积越小，模型的安全对齐就越好。*译注：按图例，蓝色区域对应 OR-Bench-Toxic 的接受率；原图注的表述保留。*

L 标注实验

为与人工标注者进行比较，我们总共随机选取了 100 个任务。我们将任务交给 3 名标注员、由 GPT-4-turbo-2024-04-09、Llama-3-70b 和 Gemini-1.5-pro 组成的 LLM 集成审核器，以及一位论文作者，由他们独立标注。在正式实验前，我们向标注员提供专家标注的示例数据，供其学习并提出意见，待所有意见得到解决后才开始实验。最后，我们以全部 5 个回答的多数投票结果作为真实标签，并计算混淆矩阵与准确率。实验显示存在明显的意见分歧，这可能与各标注员的背景有关。例如，对于某些提示，标注员可能缺乏作出正确选择所需的相关知识。结果表明，集成审核器在审核任务上优于全部 3 名人类标注员。因此，我们选择表现接近专家水平的 LLM 作为审核器。

M 基于关键词的评估

表 8: 关键词匹配与提示 LLM 进行评估的抽样结果比较。

模型	关键词拒答率	GPT-4判定拒答率
gpt-3.5-turbo-0125	10.6	13.0
gpt-3.5-turbo-0301	66.3	66.8
gpt-3.5-turbo-0613	34.7	40.2
gemini-1.0-pro	34.7	37
claude-3-opus	88.0	88.2
llama-3-70b	26.8	29.2

N 被拒绝提示的更多细节

下面展示过度拒答提示和有害提示中各个类别的一些示例。

arXiv:2405.20947v5

P 使用 Self-BLEU 得分衡量多样性

表 11: 使用 Self-BLEU 得分衡量生成数据集的多样性。对于 OR-Bench-Hard-1K，使用整个数据集。对于 OR-Bench-80K，从每个类别抽样 1000 条提示进行测量，最终结果为 3 次运行的平均值。

类别	OR-Bench-Hard-1K	OR-Bench-80K
欺骗	0.36	0.36±0.01
骚扰	0.42	0.42±0.02
有害	0.32	0.32±0.01
仇恨	0.35	0.36±0.01
违法	0.41	0.39±0.01
隐私	0.44	0.44±0.01
自伤	0.39	0.40±0.02
性内容	0.36	0.35±0.01
不道德	0.37	0.38±0.01
暴力	0.31	0.32±0.01

Q OR-Bench-Hard-1K 的更多细节

我们贡献的 OR-Bench-80K 包含不同毒性程度的过度拒答提示，因此可以用于全面测试大语言模型的过度拒答现象。为快速测试大语言模型的拒绝行为并降低成本，我们构建了一个高难度数据集，其中的提示至少被近期模型家族中 3 个可通过 API 稳定调用的最大模型拒绝，例如 GPT-3.5-turbo-0125、Llama-2-70b、Llama-3-70b、Claude-3-opus、Qwen1.5-72B、Gemini-1.5-pro。这些提示更可能被 LLM 拒绝。我们随机抽样 1K 条提示，构成最终的 OR-Bench-Hard-1K 数据集。如 表 2所示，即使对于近期最先进的模型，这些提示也确实具有挑战性。但需要注意，在该数据集上的表现差异会被放大，而 OR-Bench-80K 上的结果更接近常规情境。此外，如局限性部分所述，由于使用 LLM 作为审核器，数据集中可能包含有害或有争议的提示。

arXiv:2405.20947v5

V 人类标注员实验

表 12: 比较集成审核器与人类在标注提示是否安全时表现的混淆矩阵（%）。我们将 5 个标签的多数投票结果作为真实标签。正类标签表示安全。

	TP（真正例）	FN（假负例）	TN（真负例）	FP（假正例）	准确率
标注员 1	73.3	26.7	80.0	20.0	75.0
标注员 2	77.3	22.7	80.0	20.0	78.0
标注员 3	72.0	28.0	68.0	32.0	71.0
人类专家	94.7	5.3	92.0	8.0	94.0
集成审核器	96.0	4.0	84.0	16.0	93.0

审核结果验证 我们曾考虑招募人类标注员来标注改写后的提示。在与 Scale AI 合作的实验中，我们抽样了 100 个任务，并向三名标注员和一名专家（论文作者之一）提供相同的说明。真实标签由集成审核器、专家和标注员的多数投票决定，我们据此计算了 表 12中的混淆矩阵。在标注员中，标注员 2 识别出了 77.3% 的安全提示，比例最高，但其假正例率也达到 20.0%。标注员 3 的表现最差，假负例率为 28.0%，假正例率为 32.0%。标注员 1 在有害提示上的表现与标注员 2 类似，但在安全提示上的表现略差。集成审核器的总体表现与专家相近。更多分析见 节 L。

根据上述实验，我们得出结论：在过度拒答审核任务上，最先进的 LLM 集成优于人类评分员，因此我们选择 LLM 作为审核器。

[9]译注：数据集名称为 OR-Bench-Hard-1K，前文称抽样 1K 条提示，但本节报告的实际总数为 1,319。此处保留原文数字。

arXiv:2405.20947v5

Y 将 LLM 微调为评判器

我们开展了一项实验，使用经过审核的数据（1200 个样本，学习率为 1e-5，训练 3 个轮次）微调 Mistral-7b-instruct-v0.2。该模型既未经安全对齐，也未纳入我们的基准测试，因此不会引入偏差。我们在提供给人类标注员的验证任务上检验了该模型。对于二元分类（有害/安全），我们取得了 0.83 的准确率，超过表现最好的人类标注员（0.78）；对于细粒度分类，我们取得了 0.84 的准确率，约为人类专家表现的 90%。我们将对这一方向的进一步探索留待未来工作。

模型回答的违规使用

LLM 安全对齐中一个密切相关的概念是对模型回答的恶意使用：助手可能以另一种表述框架呈现信息，进而导致非预期结果 [47]。例如，在上述例子中，模型可能提供防范商店行窃的建议，而这些内容也可能被当作行窃建议使用。正如 OpenAI [47]、Llama [22]和 Gemini [53]等最先进 LLM 的指南所强调的，这一问题源于知识的性质以及人类滥用，而非 AI 行为不当。因此，双重用途研究与过度拒答行为研究有所区别。相应地，我们的工作专注于研究过度拒答行为。

伦理声明

标注者与参与者的安全 虽然数据生成完全自动化，但人工验证和标注步骤由经过培训的研究人员与承包人员完成。他们已被告知可能接触到敏感和有害内容。只有已表示同意的标注者才会执行这些任务。该过程遵循伦理准则，以保护参与者的保密权益与自主权。我们的工作已获得机构审查委员会（IRB）批准，相关批准材料将在未来提供。

数据集的潜在滥用 OR-Bench 旨在揭示 LLM 安全性与帮助性之间的权衡，从而推动安全对齐 AI 系统领域的发展。不过，也必须认识到其中的潜在风险，包括数据可能被滥用于训练会对有害提示作出不当回答的模型。与安全对齐领域的其他数据集一样，我们强烈反对以任何恶意方式使用这些数据集，并倡导负责任且恰当地使用它们。