语言模型 · 强化学习 · 可靠性

超越二元奖励

训练语言模型推理自身的不确定性

Beyond Binary Rewards
Training LMs to Reason About Their Uncertainty

Mehul Damani* · Isha Puri* · Stewart Slocum
Idan Shenfeld · Leshem Choshen
Yoon Kim · Jacob Andreas

Massachusetts Institute of Technology · 麻省理工学院
* 同等贡献
联系邮箱：mehul42@mit.edu；ishapuri@mit.edu

中文公开删节版

正文、经筛选的附录、公式与实验图表
arXiv:2507.16806v2 · ICLR 2026 版本
底本修订日期：2026 年 5 月 15 日

译文公开版 1.1 · 2026 年 11 月 10 日
中文翻译与编排：dot · 非官方译文

公开版范围说明

公开版暂不收录图 1 及其实例中文对照，以及完整译本末尾 N–P 的 SimpleQA、HotpotQA-Modified、数学逐字示例。该范围含第三方数据集问题和维基百科支持文本。方法、数学推导、实验数据、其余统计图、系统提示与参考文献保留。未收录不表示认定其原有引用侵权。

本版本是独立的公开发布版本，不是完整译文。原论文引用及各处图表编号沿用原文；被移除项目保留占位说明，便于核对。原作者未审校或认可本译文。

版本与版权说明

本译文以 arXiv:2507.16806v2 的正式 PDF 与官方 LaTeX 源文件为底本，原完整译本覆盖原文 39 页的摘要、正文、致谢、参考文献、附录、系统提示以及模型输出示例。本公开版保留的方法、推导与实验论述译为中文；作者名、模型名、数据集名、程序标签与文献著录等检索标识保留原样，逐字数据集示例不在收录范围内。参考文献保留英文完整著录，便于定位和核验。中文重排页码不与原文逐页对应。为便于检索跳转，原文末尾三个无编号示例在本译文中编为附录 N–P，并修复了原文重复或错位的交叉引用锚点。

公式使用 LaTeX 重新排版，表格数值不作改写。图件使用原始 PDF 或 PNG，保留原始曲线、英文标识与图例；下页给出全部通用图内标识中文对照，图 1 的原始实例及逐字对照未在本公开版收录。本公开版不收录逐字模型生成示例。可核实的公式排印错误、标签问题和文字矛盾以“译注”明确区分。

原文引用： Mehul Damani, Isha Puri, Stewart Slocum, Idan Shenfeld, Leshem Choshen, Yoon Kim, Jacob Andreas. Beyond Binary Rewards: Training LMs to Reason About Their Uncertainty. arXiv:2507.16806v2, 2026.

原文：https://arxiv.org/abs/2507.16806v2

PDF：https://arxiv.org/pdf/2507.16806v2

源文件：https://arxiv.org/src/2507.16806v2

项目网页：https://rl-calibration.github.io/

许可与改动说明： 原文 arXiv 页面标示 Creative Commons Attribution 4.0 International（CC BY 4.0）。该许可允许在署名、提供许可链接并注明改动的条件下分享及改编。本译文为中文翻译与重新排版，添加了译注与中文图例说明，并同样以 CC BY 4.0 提供。版权属于相应权利人；原作者、所属机构及会议没有参与或认可本译文。许可不提供担保。

https://creativecommons.org/licenses/by/4.0/

原图标识中文对照

Accuracy / Acc. 准确率；Accuracy (%) 为准确率（%）。

Calibration Score (1-ECE) 校准得分（1 减期望校准误差）。

Brier Score / Log Score Brier 评分／对数评分。

Reward / Expected Reward 奖励／期望奖励。

Verbalized confidence / Confidence 显式表达的置信度／置信度。

Correctness / answer correct / answer wrong 正确性／答案正确／答案错误。

Base / Ours / Classifier 基础模型／本文方法／分类器。

Example Output 输出示例。

In-distribution / Out-of-distribution Evaluation 分布内／分布外评估。

Max-Confidence / Majority Vote 最大置信度选择／多数投票。

Confidence-Weighted Maj.Vote 置信度加权多数投票。

Gen Likelihood-Weighted Maj.Vote 生成似然加权多数投票。

Max Gen Likelihood 最大生成似然选择。

Number of Samples / Ensemble Size 样本数／集成规模。

Proportion of Samples / Density 样本比例／密度。

Standard Deviation of Confidence 置信度标准差。

Sum of Confidences per Example 每道题不同答案置信度之和。

Expected Sum (y=1) 期望之和（$y = 1$，即水平参考线）。

Dataset / Classifier Size 数据集／分类器规模。

Baseline Classifier / Analysis Classifier 基线分类器／包含不确定性分析的分类器。

Confidence frequency / Count 置信度频数／计数。

Accuracy per bin / Ideal calibration 各分箱准确率／理想校准。

Answer-Conditioned / Answer-Independent 以答案为条件／不区分答案。

Distribution of Standard Deviation of Confidence Scores 置信度分数标准差的分布。

Correctness Reward / Brier Reward 正确性奖励／Brier 奖励。

Completion Length (tokens) / Step 生成长度（词元数）／训练步。

目录

公开版范围说明 **1**

版本与版权说明 **2**

原图标识中文对照 **3**

1 引言 **6**

2 预备知识 **7**

3 方法 **8**

4 实验 **9**

4.1 实验设置 9
4.2 HotPotQA 10
4.3 数学 12
4.4 显式表达的置信度能否用于测试时扩展? 12
4.5 显式表达的置信度是否自洽? 13
4.6 校准收益来自何处? 14

5 相关工作 **15**

6 结论 **16**

参考文献 **17**

A 定理 1 的证明 **21**

B 实验设置 **23**

B.1 训练数据集 23
B.2 补充训练细节 23
B.3 评估数据集 24
B.4 评估细节 24

C 系统提示 **25**

D LLM 使用情况 **26**

E 对数评分与 Brier 评分的比较 **26**

E.1 直观解释 26
E.2 简化实验 27
E.3 HotPot 上的实验 28

F 向其他模型的泛化 **29**
F.1 OlMo-2 29
F.2 Qwen3 29

G 推理是否改善校准? **30**

H 置信度分布 **31**
H.1 不同输入之间的置信度分布 31
H.2 单个输入的置信度分布 32

I 与 RL 校准基线的比较 **32**

J SFT+RLCR 分析 **34**

K HotPot 训练结果 **34**

L 完整结果：在 HotpotQA 上训练的模型 **35**

M 完整结果：在 Math 上训练的模型 **37**

N SimpleQA 示例的公开版说明 **39**

O HotpotQA 示例的公开版说明 **39**

P 数学示例的公开版说明 **39**

摘要

通过强化学习（RL）训练语言模型（LM），使其生成自然语言推理链，可以提升它们在多种高难度问答任务上的表现。目前，几乎所有成功的推理强化学习应用都采用二元奖励函数来评估语言模型输出的正确性。 由于此类奖励函数不会惩罚猜测或低置信度输出，它们往往带来意料之外的副作用：降低校准程度，并提高语言模型在其他问题领域生成错误回答（即产生“幻觉”）的比例。 本文提出**RLCR**（Reinforcement Learning with Calibration Rewards，校准奖励强化学习），一种能够同时提高准确率和置信度估计校准程度的推理模型训练方法。在 RLCR 中，语言模型在推理后同时生成预测结果与数值化的置信度估计。训练时，模型优化的奖励函数在二元正确性分数上加入 Brier 评分，这是一种能够激励校准预测的置信度评分规则。我们首先证明，这一奖励函数（或任何采用有界适当评分规则的类似奖励函数）能使模型的预测既准确又具有良好的校准性。 随后，我们在多种数据集上表明，RLCR 在显著改善校准的同时，在域内与域外评测中均保持较高的准确率，优于普通强化学习训练，也优于经过训练、用于事后赋予置信度分数的分类器。普通强化学习会损害校准，而RLCR 则能够改善校准。 最后，我们证明，在测试时可以利用显式表达的置信度，通过置信度加权的扩展方法提升准确率和校准程度。 我们的结果表明，显式优化校准能够得到在更广泛场景中可靠的推理模型。 代码、模型、演示及更多信息见https://rl-calibration.github.io/。

1 引言

语言模型（LM）研究近期取得的许多进展，都由推理模型所推动。这类语言模型通过强化学习（RL）训练，在回答问题之前先用自然语言“说出思考过程”，并在数学和编程等具有挑战性的任务上达到当前最先进的水平 (Guo et al., 2025)。

标准的推理训练方法（通常称为**可验证奖励强化学习**，简称**RLVR**）使用一个简单的二元正确性奖励来进行强化学习： $R_{\text{correctness}}(y, y^*) = \mathbf{1}_{y \equiv y^*}$，其中，$\equiv$ 用于检查模型输出 y 是否与真实答案 y^* 相匹配。 这种奖励虽然简单且能有效提高准确率，却存在一个关键局限：无论模型是信心十足地答对，还是仅仅猜中，都会获得相同的奖励；无论模型选择弃答，还是给出错误答案，也都会受到相同的惩罚。这会鼓励过度自信的猜测。

与这一担忧一致，研究表明，即使模型最初校准良好，在强化学习训练后也往往变得过度自信(Choshen et al., 2019; Leng et al., 2025)。尤其是推理模型，与基础模型相比，其校准通常更差，幻觉率也更高；在训练所用奖励信号仅强调正确性时，这一现象尤为明显(Kirichenko et al., 2025; Yao et al., 2025; OpenAI, 2025)。在医疗或法律等高风险领域，这是一个严重的局限，因为模型不仅必须准确，还必须在适当情况下表达不确定性(Omar et al., 2024)。

本文旨在通过回答以下两个问题来解决这些局限：

(1) 能否同时针对正确性和校准优化推理模型?

(2) 推理链的内容本身能否改善校准?

原图含数据集实例，公开版暂不收录。

图 1：原图内容说明（原图未收录）。(a): 使用 RLCR 训练的模型所生成的思维链示例，采用<think>、<answer>、<analysis> 和<confidence> 标签。 **(b)** 在域内评测任务上，RLCR 优于标准推理训练（RLVR ），甚至略优于RLVR 与专门预测RLVR 答案正确性的分类器的组合。**(c)** 在评估对新任务的泛化时，RLCR 同时提高了准确率和校准程度，而其他方法未改变准确率，有时还会损害校准。图中所有结果均基于 HotpotQA，更多结果见节 4。

我们从统计决策理论，具体而言是**适当评分规则**理论的视角，研究这些问题。对于一个同时生成输出 y 和置信度 q 的预测器，当 q 反映 y 与真实结果 y^* 一致的真实概率时，适当评分规则取最小值 (Gneiting & Raftery, 2007)。一个典型例子是**Brier 评分** (Brier, 1950)： $R_{\text{Brier}}(y, q, y^*) =$

$-(q-\mathbf{1}_{y\equiv y^*})^2$。[1]适当评分规则广泛用于预测 (Waghmare & Ziegel, 2025)，但在通过强化学习训练大语言模型方面的应用仍然很少。

我们的方法**RLCR（校准奖励强化学习）**对推理训练加以修改，鼓励模型同时对任务正确性和不确定性进行推理。为此，我们只需训练模型同时输出答案 y 和（显式表达的）置信度分数 q，并优化以下组合奖励函数：

$$\begin{aligned} R_{\text{RLCR}}(y,q,y^*) &= R_{\text{correctness}}(y,y^*) + R_{\text{Brier}}(y,q,y^*) \\ &= \mathbf{1}_{y\equiv y^*} - (q-\mathbf{1}_{y\equiv y^*})^2 \,. \end{aligned} \tag{1}$$

我们表明，这种方法具有以下几项有吸引力的理论与实证性质：

- 可以证明，RLCR 同时激励准确性和校准：当模型输出最可能正确的答案，同时给出对成功概率的校准估计时，R_{RLCR} 达到最大值。换言之，当语言模型输出 (y,q) 满足 $y=\arg\max_{y'} p(y'\equiv y^*)$ 且 $q=p(y\equiv y^*)$ 时，R_{RLCR} 最大，其中 p 表示正确性标签背后的真实概率分布。更一般地，我们证明，只要校准项采用有界的适当评分规则，就能构造类似的目标。值得注意的是，对数似然虽然是一种适当评分规则，却是无界的，因此可能激励模型输出错误答案（节 3）。
- 在事实问答与数学推理任务的实验中，对于域内问题，RLCR 在达到与RLVR 相当的任务准确率的同时，显著改善了校准，使 HotpotQA 上的期望校准误差显著下降（$0.37\to 0.03$）(Yang et al., 2018)，并使一组数学数据集上的期望校准误差下降（$0.26\to 0.10$）（节 4）。
- RLCR 改善了域外任务上的校准：RLVR 会显著损害校准对新领域的泛化，而RLCR 则改善校准，其表现优于RLVR 模型、基础模型，以及配备了第二个模型的预测器，其中第二个模型仅经过微调以输出置信度分数。
- 显式表达的置信度可以纳入测试时扩展，从而改进集成与 best-of-N 方法。这可能归因于RLVR 还提高了模型预测在不同样本之间的一致性[2]：对于给定问题，当生成多条推理链和多个预测时，RLCR 减少了导向同一答案的推理链之间的置信度分数方差，也降低了模型对相互矛盾的答案均赋予高置信度的频率（节 4.4）。

综合而言，这些结果表明，只需直接修改现有推理训练方法，就可以额外优化校准，进而提高其准确率、鲁棒性和可扩展性。

2 预备知识

设 π_θ 为一个语言模型，将提示 $x\in X$ 映射为输出 $y\in Y$，输出之前可能还包含一条自然语言推理链，其中 x、y 和推理链均表示为字符串。给定提示与输出配对的数据集 $D=\{(x_i,y_i^*)\}$（例如问题及其真实答案），以及一个用于比较预测输出与真实输出的奖励函数 $R: Y\times Y\to\mathbb{R}$，我们的目标是通过优化以下目标来改善语言模型的输出：

$$\arg\max_\theta \; \mathbb{E}_{(x,y^*)\sim D,\; y\sim\pi_\theta(\cdot|x)}\, R(y,y^*)\,. \tag{2}$$

可验证奖励强化学习（RLVR） 训练推理模型时，R 的一种标准选择是二元正确性奖励：

$$R_{\text{correctness}}(y,y^*)=\mathbf{1}_{y\equiv y^*}\,, \tag{3}$$

其中，$\mathbf{1}_{y\equiv y^*}\in\{0,1\}$ 是判断 y 是否正确的示性函数，即判断 y 是否与 y^* 等价（可能忽略格式细节）。

[1]译注：原文此处将“最小化”的表述与负平方误差写在一起，本文予以保留。负平方误差作为奖励时应最大化其期望；正的 Brier 损失才应最小化。

[2]译注：原文此处写作 RLVR，而本条后文及全文所述的改进方法为 RLCR，疑为缩写笔误，此处保留原文。

适当评分规则 我们通常希望预测器不仅输出答案 y，还输出某个标量 q，用于衡量对该答案的置信度。[3]

评分规则衡量置信度估计的质量。在对二元结果建模的情况下（例如对给定答案 y 是否正确的置信度），评分规则是一个函数 $S : \mathbb{R} \times \{0, 1\} \to \mathbb{R}$，将置信度估计 q 和结果 a 映射为一个标量分数。如果当置信度分数与结果的真实概率一致时，其期望值达到最小，则称该评分规则是**适当的**：

$$\mathbb{E}_{a\sim p(a)}\, S(p(a), a) \le \mathbb{E}_{a\sim p(a)}\, S(q, a) \;\; \forall q \; . \tag{4}$$

[4] 这里，p 表示正确性标签背后的真实概率分布。最为人熟知的适当评分规则或许是对数损失：

$$\textbf{对数评分：} \qquad S(q, a) = -a \log q - (1 - a) \log(1 - q) \; . \tag{5}$$

除此以外还有许多例子，包括

$$\textbf{Brier 评分：} \qquad S(q, a) = (a - q)^2 \; , \tag{6}$$

$$\textbf{球面评分：} \qquad S(q, a) = -\frac{qa + (1 - q)(1 - a)}{\sqrt{q^2 + (1 - q)^2}} \; . \tag{7}$$

这些分数的共同性质是，当置信度 q 与真实概率 $p(a = 1)$ 一致时，它们达到最小值。

3 方法

我们方法的核心思想是，将标准正确性奖励与基于 Brier 评分的奖励相结合，通过同时激励正确性与校准的奖励来对语言模型进行强化学习训练。在该方法中，首先提示模型生成能够同时得出答案和置信度估计的推理链（如图 1a 所示），随后训练模型优化以下目标：

$$R_{\text{RLCR}}(y, q, y^*) = \mathbf{1}_{y\equiv y^*} - (q - \mathbf{1}_{y\equiv y^*})^2 \; . \tag{8}$$

直观地说，这一奖励激励正确性，同时惩罚模型以高置信度输出错误答案，或以低置信度输出正确答案。

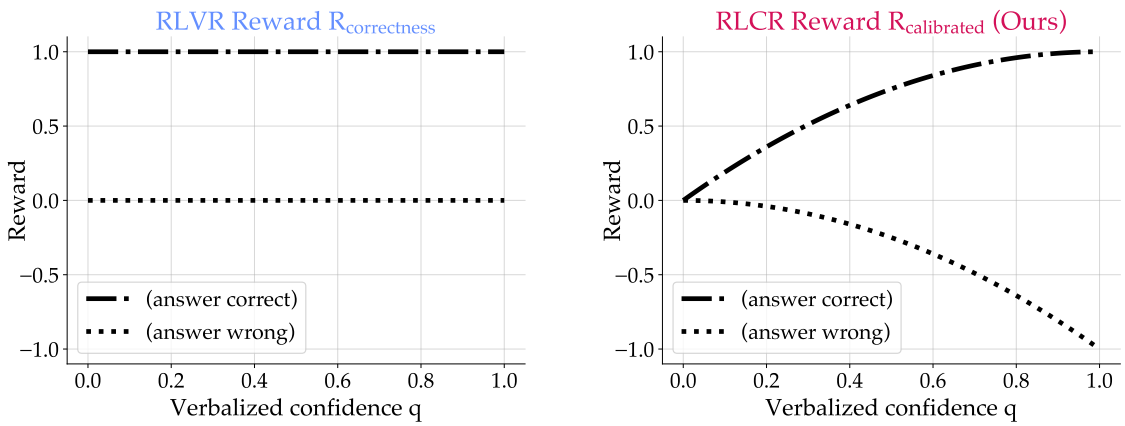


图 2: (a)：RLVR 只关注正确性，这可能会激励猜测。**(b)：**RLCR 使用校准奖励，同时优化正确性与校准。

这一奖励函数是否能激励我们期望的语言模型行为，并非一目了然。因为它涉及准确性（第一项）与校准（第二项）之间的权衡，我们可能担心模型会学会输出确定错误的答案，以获得较小的校准损失。但实际上，式 (8)中的校准项不会以牺牲准确性为代价：

[3] 有时，训练模型在一大组可能答案 y 上给出完整的分布会更加有用。但对于非常大的答案空间，或计算代价高昂的预测器，例如执行思维链推理的语言模型，枚举所有可能答案并对其评分通常并不现实。本文主要关注生成一个答案和一个置信度分数的模型，不过节 4.5介绍了一种利用这种方法生成多个答案并对其评分的方式。

[4] 译注：式中的 $S(p(a), a)$ 沿用原文记号；按照此处对二元置信度的定义，其概率参数通常应写为 $p(a = 1)$。

定理 1. 假设对于任意预测 y，成功示性变量 $\mathbf{1}_{y\equiv y^*}$ 服从 Bernoulli(p_y) 分布。 那么，式 (8)中的 R_{RLCR} 满足以下两条性质：

1. **校准激励**。对于任意 y，当 $q = p_y$ 时，期望奖励 $\mathbb{E}_{\mathbf{1}_{y\equiv y^*}} R_{\text{RLCR}}(y, q, y^*)$ 达到最大。
2. **正确性激励**。在所有经过校准的预测 (y, p_y) 中，成功概率 p_y 最大的预测使期望奖励达到最大。[5]

证明见附录 A。

定理 1的一个重要性质是，我们不能用任意一种适当评分规则来替换 Brier 项 $(q - \mathbf{1}_{y\equiv y^*})^2$。例如，对数损失 $\mathbf{1}_{y\equiv y^*} \log q + (1 - \mathbf{1}_{y\equiv y^*}) \log(1 - q)$ 并不能激励正确性。[6]不过，对于任何满足 $S(p, 1) - S(p, 0) < \lambda$（其中 λ 为某个常数）的有界适当评分规则，都存在与定理 1类似的版本。

4 实验

我们的主要实验旨在评估RLCR 在实践中如何改变语言模型的准确率和校准程度，既包括在用于强化学习的任务上的“域内”评测，也包括在其他问答任务上的“域外”评测。 额外实验评估了 RLCR 与其他测试时推理范式之间的相互作用，以及RLCR 在多大程度上使语言模型的不同预测彼此更加一致。

4.1 实验设置

训练细节 我们采用组相对策略优化（Group Relative Policy Optimization，GRPO）(Shao et al., 2024)作为基础强化学习算法，并进行了一些修改（见节 B.2）。 我们使用 Qwen2.5-7B 基础模型，该模型属于在强化学习任务中广泛使用的 Qwen 系列 (Hu et al., 2025; Gandhi et al., 2025)。 遵循近期关于语言模型推理强化学习训练的工作 (Hu et al., 2025; Guo et al., 2025)，我们直接从基础模型开始强化学习，不采用任何 KL 正则化。

方法 我们评估以下方法：

1. **基础模型（Base）：** 预训练的基础模型。实验中使用Qwen2.5-7B Base。 我们提示模型同时输出答案与置信度，详细设置见节 B.4。
2. **RLVR：** 从基础模型初始化，使用 $R_{\text{correctness}}$ 训练，并采用<think> 和<answer> 标签。在评估时，还会提示模型输出显式表达的置信度。
3. **RLVR + BCE 分类器：** 在RLVR 模型输出上训练的置信度分类器。具体而言，给定问题、解答思维链（由RLVR 生成）及正确性标签 $(x, y, \mathbf{1}_{y\equiv y^*})$，我们使用二元交叉熵（BCE）损失训练置信度分类器 $f_\theta(x, y)$：

$$\mathcal{L}_{\text{BCE}}(\theta) = -\mathbb{E}_{(x,y,\mathbf{1}_{y\equiv y^*})} \left[\mathbf{1}_{y\equiv y^*} \log f_\theta(x, y) + (1 - \mathbf{1}_{y\equiv y^*}) \log(1 - f_\theta(x, y))\right] \tag{9}$$

该分类器从Qwen2.5-7B Base初始化，因此具有很强的表达能力。这种方法开销较高，因为训练与推理都需要使用两个大模型。

4. **RLVR + Brier 分类器：** 我们不使用二元交叉熵（BCE）损失训练分类器，而是使用均方误差（MSE），从而更直接地优化 Brier 评分：

$$\mathcal{L}_{\text{Brier}}(\theta) = \mathbb{E}_{(x,y,\mathbf{1}_{y\equiv y^*})} \left[(f_\theta(x, y) - \mathbf{1}_{y=y^*})^2\right] \tag{10}$$

[5]注意，这一问题表述并未区分与成功相关的认知不确定性和偶然不确定性。显然，一旦预测出 y，评估结果就完全确定，$y \equiv y^*$ 的客观概率只能是 0 或 1。但受到信息或计算约束的预测器仍可能存在主观不确定性。

[6]译注：原文将所列公式称为“对数损失”，但该式为对数似然；标准对数损失应为其相反数，此处保留原式。

5. **RLVR + 探针（Probe）：** 给定RLVR 模型的最后一层嵌入 $\phi(x, y)$，我们训练一个线性探针来预测置信度。在式 (9)中，我们将经过微调的语言模型替换为一个线性模型：$f_\theta(x, y) = \log \sigma(\theta^\top \phi(x, y))$，其中 $\sigma(\cdot)$ 表示 sigmoid 函数。[7]
6. **答案概率（Answer Probability）：** 我们使用RLVR 生成输出，提取<answer> 标签内的词元，并计算这些词元的平均概率：$\text{AnswerProb}(y) = \frac{1}{|\mathcal{A}|} \sum_{t \in \mathcal{A}} P_\theta(y_t \mid y_{<t}, x)$。这里，集合 $\mathcal{A} \subseteq \{1, \ldots, T\}$ 表示<answer> 标签之间出现的词元位置。$P_\theta(y_t \mid y_{<t}, x)$ 表示模型生成词元 y_t 的概率。
7. **RLCR（我们的方法）：** 从基础模型初始化，使用 R_{RLCR} 进行训练。

评估指标

我们使用以下评估指标：

1. **准确率（↑）：** 衡量任务表现。
2. **ROC 曲线下面积（AUROC）（↑）：** 衡量置信度分数区分正确答案与错误答案的能力，将正确性视为二元标签，并在所有阈值上对 TPR/FPR（真正率与假正率）取平均。$\text{AUROC} = \int_0^1 \text{TPR}(\text{FPR}^{-1}(t))\, dt$
3. **Brier 评分（↓）：** 置信度与真实标签之差的平方。
   Brier 评分 = $\frac{1}{N} \sum_{i=1}^{N} (q_i - \mathbf{1}_{y_i \equiv y_i^*})^2$
4. **期望校准误差（ECE）（↓）：** 一种校准指标，将置信度分箱，并计算各箱中平均正确率与平均置信度之间的差异。$\text{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{N} \left|\text{acc}(B_m) - \text{conf}(B_m)\right|$，其中 M 为箱数，B_m 为第 m 个箱中的样本集合，N 为样本数。我们取 $M = 10$。

评估数据集

我们在突出不同不确定性来源的基准上评估RLCR，包括含糊证据、冷僻事实和复杂推理。HotPotQA (Yang et al., 2018)测试证据不完整或存在干扰证据时的校准，而 SimpleQA (Wei et al., 2024)和 TriviaQA (Joshi et al., 2017)考察模型在冷僻事实知识上的过度自信；GPQA (Rein et al., 2024)、Math500 (Hendrycks et al., 2021)、GSM8K (Cobbe et al., 2021)和 Big-Math (Albalak et al., 2025)评估复杂、多步或科学推理中的校准，这类任务的不确定性会在各步骤之间累积。CommonsenseQA (Talmor et al., 2019)考察模型在含糊、隐含的推理情境中的置信度。

4.2 HotPotQA

数据集 我们使用经过修改的 HotPotQA 干扰项数据集 (Yang et al., 2018)，其中包含多跳问题和 10 个段落（2 个相关段落、8 个干扰段落）。为检验不确定性推理能力，HotPotQA-Modified 会移除 0 个、1 个或全部 2 个相关段落，从而构造信息完整程度不同的情形。示例见附录 O。数据集在这几种情形之间均匀分配，每个样本包含 8 个段落。我们使用 20,000 个样本进行训练，并通过字符串精确匹配判断答案是否正确。

结果 在分布内的 HotpotQA 干扰项数据集上（表 1），经过 RL 训练的模型在多跳问题准确率上优于现成的基线模型，其中 RLCR 的准确率与 RLVR 相当，表明校准项不会损害任务表现。基础模型和 RLVR 仍然过度自信且校准较差，而我们的方法与分类器的校准表现显著更好，其中 RLCR 略占优势。答案概率基线表现较差，因为模型通常在 CoT 推理过程中便已确定某个答案，从而使输出置信度虚高。图 11 显示，在训练过程中，RLCR 的正确性奖励与校准奖励均平稳提升。

[7]译注：原式含有 log，因而输出并不位于通常置信度所要求的 $[0, 1]$ 区间，且无法直接作为上述 BCE 公式中的概率。若输出用于表示置信度，通常应去掉该 log；此处保留原式。

(a) 在 HotpotQA 上训练的模型

方法	HotpotQA				分布外平均值			
	准确率 (↑)	AUROC (↑)	Brier (↓)	ECE (↓)	准确率 (↑)	AUROC (↑)	Brier (↓)	ECE (↓)
基础模型	39.7%	0.54	0.53	0.53	53.3%	0.54	0.41	0.40
RLVR		0.50	0.37	0.37		0.50	0.46	0.46
RLVR + BCE 分类器		0.66	0.22	0.07		0.58	0.27	0.24
RLVR + Brier 分类器	**63.0%**	0.65	0.22	0.09	53.9%	0.60	0.32	0.33
RLVR + 探针		0.55	0.24	0.10		0.53	0.38	0.38
答案概率		**0.72**	0.36	0.36		0.60	0.42	0.42
RLCR（**本文方法**）	62.1%	0.69	**0.21**	**0.03**	**56.2%**	**0.68**	**0.21**	**0.21**

(b) 在 Big-Math 上训练的模型

方法	数学				分布外平均值			
	准确率 (↑)	AUROC (↑)	Brier (↓)	ECE (↓)	准确率 (↑)	AUROC (↑)	Brier (↓)	ECE (↓)
基础模型	56.1%	0.56	0.40	0.39	47.8%	0.53	0.46	0.45
RLVR		0.47	0.28	0.26		0.52	0.49	0.49
RLVR + BCE 分类器		**0.78**	0.15	0.10		0.55	0.34	0.33
RLVR + Brier 分类器	**72.9%**	**0.78**	0.15	0.10	**52.5%**	0.57	0.28	0.27
RLVR + 探针		0.65	0.19	0.13		0.53	0.33	0.30
答案概率		0.52	0.26	0.26		0.52	0.44	0.43
RLCR （**本文方法**）	72.7%	0.67	0.17	0.10	50.9%	0.60	0.28	0.25
SFT+RLCR （**本文方法**）	72.2%	**0.78**	**0.14**	**0.08**	43.8%	**0.66**	**0.24**	**0.18**

表 1: 在 HotpotQA 和 Big-Math 上训练的模型的准确率与校准指标。最优数值以粗体标出。各数据集的具体结果见附录 L。
(a) 在 HotpotQA 和 6 个分布外（O.O.D.）数据集上的表现。 RLCR 的准确率具有竞争力，校准表现则显著优于所有基线，尤其是在分布外数据集上，体现出联合优化准确率与校准的益处。
(b) 在数学数据集和 5 个分布外（O.O.D.）数据集上的表现。 数学结果是 3 个数据集（Math-500、GSM8K 和 Big-Math）的平均值。SFT+RLCR 变体在分布内和分布外条件下都实现了最佳校准。但这以泛化准确率下降为代价，原因可能是灾难性遗忘。RLCR 在分布外条件下实现了更好的权衡，在改善校准的同时保持了具有竞争力的准确率。

接下来，我们在六个分布外数据集（TriviaQA、SimpleQA、MATH500、GSM8K、CommonsenseQA、GPQA）上开展评估。我们发现，在 HotpotQA 上进行 RL 训练并未改善分布外准确率，基础模型的表现与经过 RL 训练的模型相当。然而，相比基础模型，RLVR 的校准表现变差，而 RLCR 在各项校准指标上均显著优于所有基线，同时保持了任务准确率，或使其略有提高。我们推测，RLCR 更好的校准泛化能力可能源于：

1. **围绕不确定性的思维链推理。** 对不确定性进行推理，使模型能够反思置信度，从而改善校准，这与近期研究 (Yoon et al., 2025) 一致。
2. **RL 的训练动态。** 在 RL 训练过程中，模型的置信度分析与评分必须不断适应其逐渐提升的任务表现。这种非平稳性可能带来更加稳健的学习和更好的泛化能力。
3. **共享表征。** 使用同一模型生成解答并进行校准，使校准任务能够利用解答生成过程中所使用的内部表征。

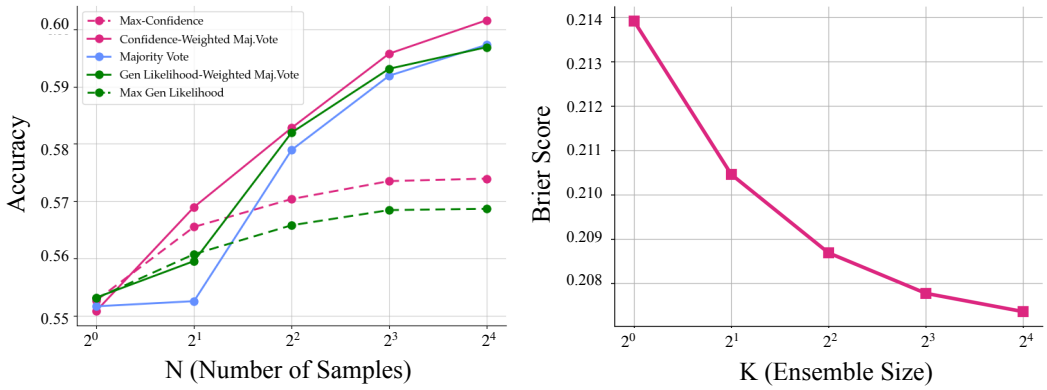


图 3: 测试时扩展曲线。(a) 准确率与采样数量（N）的关系。 随着计算量增加，所有方法的准确率均有所提升。置信度加权多数投票优于普通的多数投票和最大置信度方法，说明投票与置信度评分的结合能够产生互补收益。**(b) Brier 评分与集成规模（K）的关系。** 这里我们仅对置信度估计进行测试时扩展，通过重新采样生成多份分析（图 1 中的蓝色文本）来评估其效果。随着分析集成规模增大，校准有所改善，但幅度较小。

4.3 数学

训练细节 我们使用 Big-Math (Albalak et al., 2025) 数据集的一个子集，其中包含按节 B.1 所定义的标准筛选出的 15,000 道题。 我们使用 math-verify 判断答案是否正确。[8]

为提高不确定性推理的质量，我们还训练了一个带有轻量级 SFT 预热阶段的变体。 我们先用基础模型为 500 个样本生成解答，再使用 Deepseek-R1 为这些解答生成不确定性分析。 更多细节见节 B.2。

结果 在数学基准上（GSM8K、Math 和 Big-Math 的平均值），所有 RL 方法的准确率均显著高于基础模型。 SFT+RLCR 实现了最佳校准，略优于分类器，而基础模型和 RLVR 的校准仍然较差。

在分布外数据集（TriviaQA、SimpleQA、CommonsenseQA、GPQA、HotPotQA）上，RLCR 和 RLVR 的准确率略高于基础模型，但出乎意料的是，SFT+RLCR 模型的准确率明显下降，原因可能是 SFT 预热导致了灾难性遗忘。 尽管如此，SFT+RLCR 仍实现了最佳校准。 总体而言，RLCR 在分布外条件下实现了更好的权衡，在保持准确率的同时，其校准表现达到或超过了所有基线。

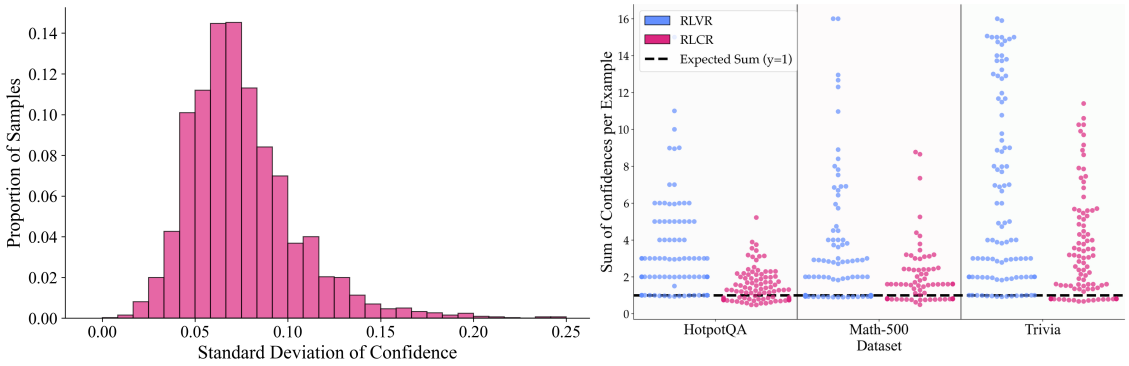
4.4 显式表达的置信度能否用于测试时扩展?

接下来，我们评估能否将 RLCR 生成的置信度评分纳入测试时扩展算法，以同时改善准确率与校准。

准确率 Best-of-N 或多数投票等测试时扩展方法通过汇总多个响应来提升模型表现，已得到广泛应用。 给定 N 个响应 $y_1, y_2, \ldots y_N$ 和奖励模型 $r(x, y)$，**Best-of-N** 选择奖励最高的响应：$y_{\text{chosen}} = \arg\max_{\{y_1,\ldots,y_N\}\sim p(\cdot|x)} R(x, y_i)$. 同样，**多数投票**从 N 个响应中选择出现次数最多的答案。 以往研究还探索了**加权多数投票**，使用奖励模型的评分对投票加权。

我们的关键见解是，模型输出的显式表达的置信度 q 可以充当有效的代理奖励 (Taubenfeld et al., 2025)。 如果模型校准良好，那么选择置信度更高的响应自然会提升表现。 这一见解导出了两种简单算法： 从 N 个候选响应中选择显式表达的置信度最高的响应（**最大置信度**），或用每个

[8] https://github.com/huggingface/Math-Verify



(a) (b)

图 4: (a)：针对同一解答／答案的多条不确定性推理链之间，置信度标准差的分布。 多数样本的标准差较低，表明模型的置信度估计具有自洽性。(b) 3 **个数据集上的置信度总和蜂群图。** RLCR 始终更接近理想总和 1。不过，过度自信仍然存在，表明还有进一步改善的空间。

响应的置信度评分对其投票加权（**置信度加权多数投票**）。 这两种算法分别是 Best-of-N 和加权多数投票的置信度评分版本。 值得注意的是，这两种方法均不需要额外监督或外部奖励模型。

对于任何开放模型，基于似然的选择方法始终可计算。为将上述方法与此类方法进行比较，我们还加入了两个基于似然的基线：**最大生成似然**，使用平均句子似然 $R = p(y|x)/|y|$ 作为奖励分数执行 Best-of-N；以及**生成似然加权多数投票**，使用这些似然分数对投票加权。[9]

我们使用在 Hotpot 上训练的 RLCR 模型生成响应，以评估上述方法，并绘制表 1 所用 7 个数据集上的平均准确率。 如图 3a 所示，随着样本数量增加，准确率持续提升，其中置信度加权多数投票优于普通多数投票、最大置信度方法以及两个似然基线。这些提升表明，校准能够直接为测试时扩展提供支撑：校准更好的置信度估计可以带来更准确的聚合预测。

校准 在我们结构化的 RLCR CoT 中，模型先输出解答，再输出分析与置信度评分。 为改善固定答案 y 的置信度评分，我们采样 K 条分析 CoT，即 $z_1, \ldots, z_K \sim p(\cdot \mid x, y)$，每条分析生成一个显式表达的置信度 q_i。 随后，我们集成这些置信度，得到聚合的置信度估计 $\bar{q} = \frac{1}{K}\sum_i q_i$。

图 3b 绘制了 Brier 评分（7 个数据集上的平均值）随集成规模 K 的变化。 我们观察到，随着集成规模增大，校准表现有所改善，但绝对提升幅度较小。 这反映出，对多数问题而言，“关于不确定性的不确定性”较低，因此平均操作不会显著改变估计值。 尽管如此，集成仍提供了一种减少残余噪声的轻量级机制，尤其适用于置信度变动更大的困难问题。

4.5 显式表达的置信度是否自洽?

同一解答内部的自洽性 不确定性感知推理的一项理想性质是：针对同一答案生成多条不确定性推理链时，模型应给出一致的置信度估计。 也就是说，模型应具有较低的“关于不确定性的不确定性”。 给定固定答案 y，我们采样 K 条分析 CoT，即 $z_1, \ldots, z_K \sim p(\cdot \mid x, y)$，其中每条推理链生成一个显式表达的置信度评分 q_i。 理想情况下，这些置信度评分的变动应当较小。 图 4a 绘制了七个数据集上的标准差，所用的分析 CoT 由在 HotpotQA 上训练的 RLCR 模型生成。大多数样本的标准差较低，说明模型的置信度估计总体上是一致的。

不同解答之间的一致性 对于答案互斥的任务，即每个样本只有一个正确答案的任务，理想情况下，模型应在不同答案之间分配置信度，使总置信度小于或等于 1；当答案集合穷尽所有可能性时，应取等号。 设模型生成 N 个响应 $\{y_i\}_{i=1}^N$，其对应的置信度评分为 $\{q_i\}_{i=1}^N$，其中 $q_i \in [0, 1]$。

[9]译注：此处公式按原文保留。原文称其为“平均句子似然”，但将序列概率直接除以长度，并不等同于通常的长度归一化对数似然或逐词元概率的几何平均值。

在 HotpotQA 上训练的模型

方法	HotpotQA				分布外平均值			
	准确率 (↑)	词元数 (↓)	Brier (↓)	ECE (↓)	准确率 (↑)	词元数 (↓)	Brier (↓)	ECE (↓)
RLCR（**本文方法**）	62.1%	249	**0.21**	**0.03**	56.2%	300	**0.21**	**0.21**
RLCR（不含分析）	61.7%	113	0.23	0.09	**56.5**%	179	0.26	0.26
RLVR（含分析）	62.3%	224	0.35	0.34	52.6%	221	0.41	0.39
RLVR	**63.0**%	**92**	0.37	0.37	53.9%	**142**	0.46	0.46

表 2: 校准消融实验，评估 (i) 校准感知奖励学习和 (ii) 显式不确定性推理各自的贡献。 加入不确定性分析可以改善 RLCR 和 RLVR 的校准，而从 RLCR 中移除分析后，仍能保留显著的校准收益。综合这些结果可知，两个组成部分都能够独立改善校准，同时使用二者则可取得最佳表现。

令 $\mathcal{A} = \{a_1, \ldots, a_K\}$ 表示这些 y_i 中 $K \leq N$ 个不同答案组成的集合。分配给答案 a_k 的平均置信度为：

$$\bar{q}_k = \frac{\sum_i \mathbf{1}_{y_i \equiv a_k} \cdot q_i}{\sum_i \mathbf{1}_{y_i \equiv a_k}} \tag{11}$$

为了让模型给出一致的答案，我们希望满足：$\sum_{k=1}^{K} \bar{q}_k \leq 1$。

图 4b 展示了三个代表性数据集上预测置信度总和的蜂群图。 在分布内的 HotpotQA 数据集上，RLCR 的置信度总和紧密聚集在 1 附近，表明其信念分布校准良好。在分布外数据集上，RLCR 和 RLVR 都表现出过度自信，置信度总和超过 1，但 RLCR 明显更接近理想值。 这体现出 RLCR 的校准有所改善，同时也表明仍有提升空间，尤其是在分布外情形下。

4.6 校准收益来自何处?

RLCR 与 RLVR 的关键区别有两点：(1) RLCR 的奖励函数直接激励模型给出经过校准的置信度估计；(2) RLCR 模型会被提示显式地对不确定性进行推理。为区分这两个组成部分各自的贡献，我们对 CoT 提示中的不确定性推理部分进行消融，并在用 HotpotQA 训练的模型上评估以下四个变体：

1. **RLCR：** 标准 RLCR，如表 1 所示。
2. **RLCR（不含分析）：** 在不进行不确定性推理的情况下评估 RLCR 模型。推理时，模型被要求只输出 <think>、<answer> 和 <confidence>，并且不进行任何不确定性推理。
3. **RLVR：** 标准 RLVR，如表 1 所示。
4. **RLVR（含分析）：** 在进行不确定性推理的情况下评估 RLVR 模型，所用分析提示与训练／评估 RLCR 时完全相同（参见附录 C 中较长的 RLCR 提示）。

表 2 的结果揭示了若干关键发现。

(1) 显式不确定性推理能够改善 RLCR 和 RLVR 二者的校准。 无论是在训练分布还是分布外条件下，带有不确定性推理的变体，其 Brier 评分与 ECE 都低于对应的不含分析变体。这与以往研究 (Yoon et al., 2025) 一致，附录 G 中的分类器消融实验也进一步佐证了这一点。

(2) 基于奖励的校准明显比仅靠提示更加有效。 尽管 RLVR（含分析）优于标准 RLVR，但它仍远逊于两个 RLCR 变体，包括 RLCR（不含分析）。因此，与明确使用校准奖励进行训练相比，提示模型对不确定性进行推理只能带来有限的收益。

(3) RLCR（不含分析）的准确率与词元开销几乎与 RLVR 相当，同时显著改善了校准。 在 HotpotQA 上，RLCR（不含分析）使用的词元数量与 RLVR 接近（113 对 92），准确率也相当（61.7% 对 63.0%），但其校准表现远好于 RLVR（ECE：0.09 对 0.37）。

总体而言。 显式分析和校准感知奖励学习这两个组成部分都有助于改善校准。当效率至关重要时，RLCR（不含分析）可作为直接替代方案，在保持准确率和词元效率的同时，相比 RLVR 显著改善校准。

5 相关工作

构建可靠的推理模型，不仅需要高准确率，还需要经过校准的不确定性估计。然而，标准 RL 目标往往会削弱这一性质 (Achiam et al., 2023)，使模型过度自信 (Xiong et al., 2024)，并容易产生幻觉 (Jaech et al., 2024)。我们回顾 LLM 置信度估计领域的四类既有研究：

事后语言表达方法在模型回答后提示其陈述置信度 (Xiong et al., 2024; Yang et al., 2024; Tanneru et al., 2024; Lin et al., 2022)。Lin et al. (2022) 对 GPT-3 进行微调，使其根据给定的问题和答案预测置信度，并使用经验准确率作为目标标签。Xiong et al. (2024) 发现，LM 在用语言表达置信度时会表现出过度自信。Tian et al. (2023) 发现，RLHF 模型显式表达的置信度评分，比其条件概率具有更好的校准表现。Mei et al. (2025) 发现，即使推理模型也存在过度自信问题，而且随着推理加深，过度自信可能愈发严重。同样，Kirichenko et al. (2025) 提出了 AbstentionBench，并表明 LM 难以恰当地拒答，而推理微调往往会降低拒答表现。积极的一面是，Yoon et al. (2025) 和 Mei et al. (2025) 发现，推理模型可以通过内省与慢速思考改善校准。

基于采样的方法使用响应的一致性（例如多数投票或 best-of-N）作为置信度的替代指标，但成本高昂，而且需要明确的真实答案 (Kang et al., 2025)。Aichberger et al. (2025) 通过生成多样且合理的响应并衡量它们的一致性来估计不确定性。Kuhn et al. (2023) 提出了语义熵，这是一种利用语言不变性更好地估计自然语言生成不确定性的采样方法。

内部探测方法从词元概率等模型特征中提取置信度 (Gupta et al., 2024)，可以提供细粒度评分，但通用性不足。Kadavath et al. (2022) 提示语言模型输出“true”或“false”，并使用这些输出的概率作为模型置信度的替代指标。Mielke et al. (2022) 训练 LM，使其根据外部探针提供的置信度估计生成响应。Fadeeva et al. (2024) 提出了一种词元级不确定性方法，利用模型内部信号对陈述进行事实核查并检测幻觉。Azaria & Mitchell (2023) 在隐藏层激活上训练分类器，以根据 LLM 的内部状态检测陈述的真实性。Orgad et al. (2025) 表明，内部表征编码了丰富的词元级真实性信号，能够检测并分类那些未在输出中体现的错误。

基于 RL 的方法通过 RL 训练模型，使其输出经过校准的显式表达的置信度。Stengel-Eskin et al. (2024) 提出了说话者—听者框架，其中说话者的奖励由听者对说话者响应所推断出的置信度决定。Leng et al. (2025) 将显式表达的置信度评分引入奖励模型训练。

与本文最密切相关的是，Xu et al. (2024) 和 Stangel et al. (2025) 使用适当评分规则作为奖励函数，通过 RL 训练 LM。Xu et al. (2024) 采用 Brier 评分，而 Stangel et al. (2025) 使用经过截断的对数损失。这些方法虽然有效，但只优化校准，因而可能无意中损害任务准确率。尤其是较大的模型，可能会通过故意输出错误答案并赋予零置信度来进行奖励投机，从而获得完美的校准奖励。此外，这两种方法都仅针对非推理任务进行开发与评估。相比之下，我们的方法同时激励正确性与校准，并在推理和非推理基准上进行了评估。

6 结论

我们表明，通过称为 RLCR 的目标将适当评分规则纳入 RL，能够使推理模型同时改善准确率与校准。我们的方法训练模型对不确定性进行推理并用语言表达不确定性，在保持任务表现的同时，显著改善分布内和分布外的校准。我们证明，对不确定性进行推理可以改善校准，而我们的方法能够提升置信度的自洽性，并能通过测试时扩展进一步改善表现。不过，仍然存在很大的提升空间：即使经过 RLCR 训练，领域外的校准误差在绝对数值上往往仍然较高，而且模型仍可能为多个互相矛盾的答案赋予较高置信度。 尽管如此，这些结果仍为构建一类推理系统指明了方向：它们不仅准确，还能可靠地对不确定性进行推理并将其传达出来。

致谢

本研究获得 MIT-IBM Watson AI Lab 及 DARPA AIQ 项目的支持，后者通过 DARPA CMO 合同 HR00112520025 提供资助。

参考文献

Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt4. arXiv preprint arXiv:2303.08774, 2023.

Lukas Aichberger, Kajetan Schweighofer, Mykyta Ielanskyi, and Sepp Hochreiter. Improving uncertainty estimation through semantically diverse language generation. In The Thirteenth International Conference on Learning Representations, 2025.

Alon Albalak, Duy Phung, Nathan Lile, Rafael Rafailov, Kanishk Gandhi, Louis Castricato, Anikait Singh, Chase Blagden, Violet Xiang, Dakota Mahan, et al. Big-math: A large-scale, high-quality math dataset for reinforcement learning in language models. arXiv preprint arXiv:2502.17387, 2025.

Amos Azaria and Tom Mitchell. The internal state of an llm knows when it's lying. Empirical Methods in Natural Language Processing Findings, 2023. URL https://arxiv.org/abs/2304.13734.

Glenn W Brier. Verification of forecasts expressed in terms of probability. Monthly weather review, 78(1):1–3, 1950.

Yanda Chen, Joe Benton, Ansh Radhakrishnan, Jonathan Uesato, Carson Denison, John Schulman, Arushi Somani, Peter Hase, Misha Wagner, Fabien Roger, Vlad Mikulik, Samuel R. Bowman, Jan Leike, Jared Kaplan, and Ethan Perez. Reasoning models don't always say what they think, 2025. URL https://arxiv.org/abs/2505.05410.

Leshem Choshen, Lior Fox, Zohar Aizenbud, and Omri Abend. On the weaknesses of reinforcement learning for neural machine translation. In International Conference on Learning Representations 2020, 2019.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems. CoRR, abs/2110.14168, 2021. URL https://arxiv.org/abs/2110.14168.

Ekaterina Fadeeva, Aleksandr Rubashevskii, Artem Shelmanov, Sergey Petrakov, Haonan Li, Hamdy Mubarak, Evgenii Tsymbalov, Gleb Kuzmin, Alexander Panchenko, Timothy Baldwin, Preslav Nakov, and Maxim Panov. Fact-checking the output of large language models via token-level uncertainty quantification. In Lun-Wei Ku, Andre Martins, and Vivek Srikumar (eds.), Findings of the Association for Computational Linguistics: ACL 2024, pp. 9367–9385, Bangkok, Thailand, August 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.findings-acl.558. URL https://aclanthology.org/2024.findings-acl.558/.

Kanishk Gandhi, Ayush K Chakravarthy, Anikait Singh, Nathan Lile, and Noah Goodman. Cognitive behaviors that enable self-improving reasoners, or, four habits of highly effective STars. In Second Conference on Language Modeling, 2025. URL https://openreview.net/forum?id=QGJ9ttXLTy.

Tilmann Gneiting and Adrian E Raftery. Strictly proper scoring rules, prediction, and estimation. Journal of the American statistical Association, 102(477):359–378, 2007.

Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948, 2025.

Neha Gupta, Harikrishna Narasimhan, Wittawat Jitkrittum, Ankit Singh Rawat, Aditya Krishna Menon, and Sanjiv Kumar. Language model cascades: Token-level uncertainty and beyond. In The Twelfth International Conference on Learning Representations, 2024. URL https://openreview.net/forum?id=KgaBScZ4VI.

Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the MATH dataset. In Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2), 2021. URL https://openreview.net/forum?id=7Bywt2mQsCe.

Jingcheng Hu, Yinmin Zhang, Qi Han, Daxin Jiang, Xiangyu Zhang, and Heung-Yeung Shum. Open-reasoner-zero: An open source approach to scaling up reinforcement learning on the base model. arXiv preprint arXiv:2503.24290, 2025.

Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helyar, Aleksander Madry, Alex Beutel, Alex Carney, et al. Openai o1 system card. arXiv preprint arXiv:2412.16720, 2024.

Mandar Joshi, Eunsol Choi, Daniel Weld, and Luke Zettlemoyer. TriviaQA: A large scale distantly supervised challenge dataset for reading comprehension. In Regina Barzilay and Min-Yen Kan (eds.), Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pp. 1601–1611, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-1147. URL https://aclanthology.org/P17-1147/.

Saurav Kadavath, Tom Conerly, Amanda Askell, Tom Henighan, Dawn Drain, Ethan Perez, Nicholas Schiefer, Zac Hatfield-Dodds, Nova DasSarma, Eli Tran-Johnson, Scott Johnston, Sheer El Showk, Andy Jones, Nelson Elhage, Tristan Hume, Anna Chen, Yuntao Bai, Sam Bowman, Stanislav Fort, Deep Ganguli, Danny Hernandez, Josh Jacobson, Jackson Kernion, Shauna Kravec, Liane Lovitt, Kamal Ndousse, Catherine Olsson, Sam Ringer, Dario Amodei, Tom Brown, Jack Clark, Nicholas Joseph, Ben Mann, Sam McCandlish, Chris Olah, and Jared Kaplan. Language models (mostly) know what they know. CoRR, abs/2207.05221, 2022. URL https://doi.org/10.48550/arXiv.2207.05221.

Zhewei Kang, Xuandong Zhao, and Dawn Song. Scalable best-of-n selection for large language models via self-certainty. In 2nd AI for Math Workshop @ ICML 2025, 2025. URL https://openreview.net/forum?id=nddwJseiiy.

Polina Kirichenko, Mark Ibrahim, Kamalika Chaudhuri, and Samuel J. Bell. Abstentionbench: Reasoning LLMs fail on unanswerable questions. In ICML 2025 Workshop on Reliable and Responsible Foundation Models, 2025. URL https://openreview.net/forum?id=kYbojsAOBj.

Lorenz Kuhn, Yarin Gal, and Sebastian Farquhar. Semantic uncertainty: Linguistic invariances for uncertainty estimation in natural language generation. In The Eleventh International Conference on Learning Representations, 2023. URL https://openreview.net/forum?id=VD-AYtP0dve.

Jixuan Leng, Chengsong Huang, Banghua Zhu, and Jiaxin Huang. Taming overconfidence in LLMs: Reward calibration in RLHF. In The Thirteenth International Conference on Learning Representations, 2025. URL https://openreview.net/forum?id=l0tg0jzsdL.

Stephanie Lin, Jacob Hilton, and Owain Evans. Teaching models to express their uncertainty in words. Transactions on Machine Learning Research, 2022. ISSN 2835-8856. URL https://openreview.net/forum?id=8s8K2UZGTZ.

Zhiting Mei, Christina Zhang, Tenny Yin, Justin Lidard, Ola Shorinwa, and Anirudha Majumdar. Reasoning about uncertainty: Do reasoning models know when they don't know? arXiv preprint arXiv:2506.18183, 2025.

Sabrina J. Mielke, Arthur Szlam, Emily Dinan, and Y-Lan Boureau. Reducing conversational agents' overconfidence through linguistic calibration. Transactions of the Association for Computational Linguistics, 10:857–872, 2022. doi: 10.1162/tacl_a_00494. URL https://aclanthology.org/2022.tacl-1.50/.

Mohamad Amin Mohamadi, Tianhao Wang, and Zhiyuan Li. Honesty over accuracy: Trustworthy language models through reinforced hesitation, 2025. URL https://arxiv.org/abs/2511.11500.

Sagnik Mukherjee, Lifan Yuan, Dilek Hakkani-Tur, and Hao Peng. Reinforcement learning finetunes small subnetworks in large language models. arXiv preprint arXiv:2505.11711, 2025.

Team OLMo, Pete Walsh, Luca Soldaini, Dirk Groeneveld, Kyle Lo, Shane Arora, Akshita Bhagia, Yuling Gu, Shengyi Huang, Matt Jordan, et al. 2 olmo 2 furious. arXiv preprint arXiv:2501.00656, 2024.

M Omar, BS Glicksberg, GN Nadkarni, and E Klang. Overconfident ai? benchmarking llm self-assessment in clinical scenarios. medRxiv, 2024.

OpenAI. Openai o3 and o4-mini system card. 2025.

Hadas Orgad, Michael Toker, Zorik Gekhman, Roi Reichart, Idan Szpektor, Hadas Kotek, and Yonatan Belinkov. LLMs know more than they show: On the intrinsic representation of LLM hallucinations. In The Thirteenth International Conference on Learning Representations, 2025. URL https://openreview.net/forum?id=KRnsX5Em3W.

David Rein, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael, and Samuel R Bowman. Gpqa: A graduate-level google-proof q&a benchmark. In First Conference on Language Modeling, 2024.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. arXiv preprint arXiv:2402.03300, 2024.

Idan Shenfeld, Jyothish Pari, and Pulkit Agrawal. Rl's razor: Why online reinforcement learning forgets less. arXiv preprint arXiv:2509.04259, 2025.

Linxin Song, Taiwei Shi, and Jieyu Zhao. The hallucination tax of reinforcement finetuning. arXiv preprint arXiv:2505.13988, 2025.

Paul Stangel, David Bani-Harouni, Chantal Pellegrini, Ege Özsoy, Kamilia Zaripova, Matthias Keicher, and Nassir Navab. Rewarding doubt: A reinforcement learning approach to confidence calibration of large language models. CoRR, abs/2503.02623, March 2025. URL https://doi.org/10.48550/arXiv.2503.02623.

Elias Stengel-Eskin, Peter Hase, and Mohit Bansal. LACIE: Listener-aware finetuning for calibration in large language models. In The Thirty-eighth Annual Conference on Neural Information Processing Systems, 2024. URL https://openreview.net/forum?id=RnvgYd9RAh.

Alon Talmor, Jonathan Herzig, Nicholas Lourie, and Jonathan Berant. CommonsenseQA: A question answering challenge targeting commonsense knowledge. In Jill Burstein, Christy Doran, and Thamar Solorio (eds.), Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), pp. 4149–4158, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1421. URL https://aclanthology.org/N19-1421/.

Sree Harsha Tanneru, Chirag Agarwal, and Himabindu Lakkaraju. Quantifying uncertainty in natural language explanations of large language models. In International Conference on Artificial Intelligence and Statistics, pp. 1072–1080. PMLR, 2024.

Amir Taubenfeld, Tom Sheffer, Eran Ofek, Amir Feder, Ariel Goldstein, Zorik Gekhman, and Gal Yona. Confidence improves self-consistency in llms. arXiv preprint arXiv:2502.06233, 2025.

Katherine Tian, Eric Mitchell, Allan Zhou, Archit Sharma, Rafael Rafailov, Huaxiu Yao, Chelsea Finn, and Christopher D Manning. Just ask for calibration: Strategies for eliciting calibrated confidence scores from language models fine-tuned with human feedback. In The 2023 Conference on Empirical Methods in Natural Language Processing, 2023. URL https://openreview.net/forum?id=g3faCfrwm7.

Benjamin Turtel, Danny Franklin, Kris Skotheim, Luke Hewitt, and Philipp Schoenegger. Outcome-based reinforcement learning to predict the future. arXiv preprint arXiv:2505.17989, 2025.

Kartik Waghmare and Johanna Ziegel. Proper scoring rules for estimation and forecast evaluation. arXiv preprint arXiv:2504.01781, 2025.

Jason Wei, Nguyen Karina, Hyung Won Chung, Yunxin Joy Jiao, Spencer Papay, Amelia Glaese, John Schulman, and William Fedus. Measuring short-form factuality in large language models. arXiv preprint arXiv:2411.04368, 2024.

Zhepei Wei, Xiao Yang, Kai Sun, Jiaqi Wang, Rulin Shao, Sean Chen, Mohammad Kachuee, Teja Gollapudi, Tony Liao, Nicolas Scheffer, et al. Truthrl: Incentivizing truthful llms via reinforcement learning. arXiv preprint arXiv:2509.25760, 2025.

Changyi Xiao, Mengdi Zhang, and Yixin Cao. Bnpo: Beta normalization policy optimization. arXiv preprint arXiv:2506.02864, 2025.

Miao Xiong, Zhiyuan Hu, Xinyang Lu, YIFEI LI, Jie Fu, Junxian He, and Bryan Hooi. Can LLMs express their uncertainty? an empirical evaluation of confidence elicitation in LLMs. In The Twelfth International Conference on Learning Representations, 2024. URL https://openreview.net/forum?id=gjeQKFxFpZ.

Tianyang Xu, Shujin Wu, Shizhe Diao, Xiaoze Liu, Xingyao Wang, Yangyi Chen, and Jing Gao. Sayself: Teaching llms to express confidence with self-reflective rationales. In Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, pp. 5985–5998, 2024.

Daniel Yang, Yao-Hung Hubert Tsai, and Makoto Yamada. On verbalized confidence scores for llms, 2024. URL https://arxiv.org/abs/2412.14737.

Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. HotpotQA: A dataset for diverse, explainable multi-hop question answering. In Ellen Riloff, David Chiang, Julia Hockenmaier, and Jun'ichi Tsujii (eds.), Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, pp. 2369–2380, Brussels, Belgium, October-November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-1259. URL https://aclanthology.org/D18-1259/.

Zijun Yao, Yantao Liu, Yanxu Chen, Jianhui Chen, Junfeng Fang, Lei Hou, Juanzi Li, and Tat-Seng Chua. Are reasoning models more prone to hallucination? arXiv preprint arXiv:2505.23646, 2025.

Dongkeun Yoon, Seungone Kim, Sohee Yang, Sunkyoung Kim, Soyeon Kim, Yongil Kim, Eunbi Choi, Yireun Kim, and Minjoon Seo. Reasoning models better express their confidence. arXiv preprint arXiv:2505.14489, 2025.

A 定理 1 的证明

我们考虑一个比正文稍一般的奖励函数族。与上文一样，假设预测器产生回答 y 和置信度 $q \in [0,1]$；现在进一步假设，评分还依赖任意二元正确性信号 c，其分布由 $p_y := p(c=1 \mid y)$ 给出。 我们考虑所有如下形式的奖励函数：

$$R(c,q) = \lambda c - S(q,c),$$

其中 $S(q,c)$ 是一个评分规则，$\lambda > 0$ 是产生正确答案时获得的标量奖励。 对于给定回答 y，选择置信度 q 的期望奖励定义为

$$V(y,q) = \mathbb{E}_c\, R(c,q) = \lambda p_y - \left[p_y S(q,1) + (1-p_y) S(q,0)\right] .$$

引理 1 (校准激励)**.** 对于任意回答 y，期望奖励 $V(y,q)$ 在 $q = p_y$ 时达到最大值，当且仅当 $S(q,c)$ 是适当评分规则。

证明. 奖励函数中的正确性项 λp_y 不依赖 q，因此

$$\arg\max_q \; V(y,q) = \arg\max_q \; -p_y S(q,1) + (1-p_y) S(q,0) = \arg\min_q \; \mathbb{E}_c\, S(q,c) .$$

译注： 原文中间表达式的第二项符号有误。由上面的 V 定义可知，这里应为 $-p_y S(q,1) - (1-p_y) S(q,0)$，即负的期望评分；本译文保留原式并指出此处排印错误。

根据定义，评分规则是适当的，当且仅当 $\mathbb{E}_{c\sim\text{Bernoulli}(p_y)}\, S(q,c)$ 在 $q = p_y$ 时最小。因此，引理立即成立。 □

引理 2 (正确性激励)**.** 考虑成功概率分别为 $p_y \geq p_{y'}$ 的 y、y'。那么，$V(y,p_y) \geq V(y',p_{y'})$ 当且仅当

$$S(p,1) - S(p,0) \leq \lambda \quad \text{对所有 } p \in [0,1] .$$

证明. 首先定义

$$W(p) = \lambda p - p S(p,1) + (1-p) S(p,0) .$$

译注： 原文 W 定义中的最后一项也漏了负号。与 $V(y,p_y) = W(p_y)$ 一致的定义应为 $W(p) = \lambda p - p S(p,1) - (1-p) S(p,0)$。下文第一行导数实际采用的是这个正确的定义。

注意，$V(y,p_y) = W(p_y)$；$W(p)$ 表示对任何对应成功概率为 y_p 的 y 所能达到的最大奖励。因此，要证明引理，只需证明 $W(p) \geq W(p')$ 当且仅当 $p \geq p'$，这又等价于证明 $W(p)$ 关于 p 单调不减。[10] 先计算 W 的导数：

$$W'(p) = \lambda - S(p,1) + S(p,0) - p S'(p,1) - (1-p) S'(p,0) .$$

根据适当评分规则的 Savage-Dawid 表示 (Gneiting & Raftery, 2007)，存在非负权重函数 $\omega(t) \geq 0$，使得

$$S'(p,1) = -(1-p)\cdot\omega(p) , \qquad S'(p,0) = p\cdot\omega(p) .$$

代入可得

$$\begin{aligned} W'(p) &= \lambda - S(p,1) + S(p,0) + p\cdot(1-p)\cdot\omega(p) - (1-p)\cdot p\cdot\omega(p) \\ &= S(p,1) - S(p,0) . \end{aligned}$$

译注： 上式原文最后一行简化有误，应为 $W'(p) = \lambda - S(p,1) + S(p,0)$。采用此式才能得到紧随其后的正确性条件。该导数论证也隐含所讨论评分规则具有相应可微性。

因此，W 的导数非负（W 单调不减），当且仅当对于 $p \in [0,1]$，有 $S(p,1) - S(p,0) \leq \lambda$。 □

[10] 译注：这里 y_p 应为 p_y。若只要求单调不减，所需方向是 $p \geq p' \Rightarrow W(p) \geq W(p')$；原文写成“当且仅当”过强，因为函数可以有平坦区间。引理应理解为对所有概率对成立的单调性结论。

由这两个引理可立即得到节 3中的主定理:

定理 1 的证明. 首先注意，R_{RLCR} 满足引理 2的条件，其中 $\lambda = 1$，$S(q, \mathbf{1}_{y\equiv y^*}) = (q - \mathbf{1}_{y\equiv y^*})^2$，并且 $\max_p\ S(p,1) - S(p,0) = 1$。因此，条件 1（校准）由引理 1以及 Brier 评分是适当评分规则这一事实得到；条件 2（正确性）由引理 2以及 $S(p,1) - S(p,0)$ 的有界性得到。 □

推论 1. 设 $S(q,c)$ 为严格适当评分规则。

1. 若 $S(p,1) - S(p,0)$ 有界，则存在有限的 $\lambda > 0$，使奖励函数 $R(c,q) = \lambda c - S(q,c)$ 满足正确性条件:
$$S(p,1) - S(p,0) \le \lambda \quad \text{对所有 } p \in [0,1],$$
从而同时激励校准与正确性。

2. 若 $S(p,1) - S(p,0)$ 无界，则对于任意有限的 $\lambda > 0$，可能存在某些 $y \ge y'$，使 $W(p_y) < W(p_{y'})$，且 R_{RLCR} 相比 (y, p_y) 更偏好 $(y', p_{y'})$。

译注: 原文第 2 条把答案直接写成 $y \ge y'$；结合语义应比较成功概率，即 $p_y \ge p_{y'}$。此外，此处阻碍有限 λ 的是评分差无上界；仅仅无下界并不能推出这一障碍。以上均保留原文并提示阅读时区分。

示例。 Brier 评分有界：$S(p,1) = (1-p)^2$，$S(p,0) = p^2$，因此

$$S(p,1) - S(p,0) = 1 - 2p \le 1 \quad \text{对所有 } p \in [0,1]\,.$$

所以，$\lambda = 1$ 时条件成立。相反，对数评分无界:

$$S(p,1) = -\log p, \quad S(p,0) = -\log(1-p),$$

$$S(p,1) - S(p,0) = \log\left(\frac{1-p}{p}\right) \to \infty \quad \text{当 } p \to 0\,.$$

故任何有限的 λ 都无法满足该条件。

B 实验设置

B.1 训练数据集

HotpotQA-Modified：我们使用 HotPotQA 干扰项数据集的一个修改版本，该数据集包含需要多跳推理的事实性问题 (Yang et al., 2018)。 在这一设置中，每个样本提供十个段落，其中只有两个包含回答问题所需的信息；其余八个段落包含与问题密切相关、但对作答无用的细节。 因此，要解决这一任务，模型必须识别相关段落并据此推理。

为更充分地培养不确定性推理能力，我们构建了一个新数据集 HotPotQA-Modified，系统地移除回答每个问题所需的关键段落中的 0 个、1 个或全部两个。 这一修改引入了不同程度的信息完整性，模型必须对此进行推理。 我们将问题平均分为三组：三分之一不含相关段落（0/8），三分之一含 1 个相关段落（1/7），三分之一含两个相关段落（2/6）。每个问题始终包含总共 8 个段落。 训练数据集包含 20,000 个样本。 我们使用字符串精确匹配来衡量正确性。

Big-Math Digits： 我们使用 Big-Math (Albalak et al., 2025)，这是一个经过筛选的大规模 RL 训练数据集，包含超过 250,000 道数学题，其中包括来自 Math 和 GSM8K 等基准的问题。

为确保难度范围适当，我们保留 LLaMA-8B 解题成功率（由数据集提供）在 0-70% 之间的问题。

我们还发现，数学数据集中的验证器噪声可能很大，并可能导致训练不稳定。 为减少验证器噪声，我们进一步将数据集限定为答案为数值的问题，从而实现近乎完美的自动验证。 最终训练集包含 15,000 道题。 我们使用 math-verify 计算正确性。

B.2 补充训练细节

遵循 Turtel et al. (2025)，我们移除了优势计算中除以标准差的操作，这可能有助于学习那些存在极端失准的样本。 我们使用 BNPO 损失函数，该函数根据本地训练批次中有效 token 的数量聚合 token 级损失 (Xiao et al., 2025)。 对每个提示，我们生成 32 个回答，温度为 0.7，有效批次大小为 2048。实验分别在 NVIDIA A100 和 H100 GPU 上进行（我们观察到不同硬件类型上的结果一致）。我们采用带预热的恒定学习率，HotpotQA 的学习率为 1e-06，Math 的学习率为 5e-06。预热比例为 0.1。 对 Hotpot，我们将最大生成长度设为 1536；对 Math，我们使用 4096 的生成长度。 Hotpot 所需的推理明显更少，使用较短的生成长度有助于缩短训练时间。 我们训练 1 个轮次。

在训练 RLCR 时，Hotpot 使用长版 RLCR 系统提示，Math 使用简版 RLCR 提示（长版在 Math 上没有带来额外收益）。 RLVR 使用简单生成提示。 所有提示见附录 C。

格式奖励： 我们使用格式奖励，鼓励模型遵循图 1 所示的结构化格式。 在 RLVR 中，模型必须用 <think> 和 <answer> 标签组织输出。 在 RLCR 中，除 <think> 和 <answer> 标签外，我们还要求使用 <analysis> 标签包裹不确定性推理，并使用 <confidence> 标签包裹显式表达的置信度。 有效回答必须按正确顺序包含所有这些标签。 格式奖励与校准奖励的权重相同。

数学任务中的 SFT 预热： 虽然直接对基础模型进行 RL 能提高校准奖励，但在数学任务中生成的不确定性分析在内容上仍较为泛泛，往往缺少与具体解题步骤相联系的推理（示例见附录 P）。

为改善其质量，我们训练了一个变体，在 RL 之前加入轻量级 SFT 预热阶段，以获得更高质量的不确定性分析。 我们让基础模型为 500 个样本生成解答，并使用专家 SFT 提示提示 Deepseek-R1 为这些解答生成不确定性分析。 随后，我们将基础模型生成的 <think> 和 <answer> 与 Deepseek-R1 生成的 <analysis> 拼接，进行 SFT。 请注意，我们并未要求 Deepseek-R1 输出置信度分数。

B.3 评估数据集

我们在大量数据集上进行评估：

1. **HotPotQA（干扰项）：**我们使用原始 HotpotQA 干扰项数据集中的 1000 个验证样本。我们对该数据集作了轻微修改，从每个问题中移除 2 个不相关段落。因此，每个问题包含 8 个段落，且两个支持段落均保留。我们使用精确匹配来衡量正确性 (Yang et al., 2018)。
2. **HotPotQA-Modified：**我们在 500 个留出的验证样本上进行评估。我们使用精确匹配来衡量正确性。
3. **TriviaQA：**我们使用 TriviaQA 数据集验证集中的 2000 个样本 (Joshi et al., 2017)。我们采用无上下文划分，以单独检验事实准确率。我们使用 LLM 作为裁判进行评估。
4. **SimpleQA：**我们使用完整的 SimpleQA 数据集，其中包含 4326 个事实性问题 (Wei et al., 2024)。我们使用 LLM 作为裁判进行评估。
5. **Math-500：**我们使用广泛使用的 MATH-500 数据集，其中包含原始 MATH 数据集的一部分题目 (Hendrycks et al., 2021)。我们使用 math-verify 进行评估，这是 huggingface 发布的数学表达式评估系统。
6. **GSM8K：**我们使用广泛使用的 Grade School Math 8K 数据集的测试集（1319 道题）(Cobbe et al., 2021)。我们使用 math-verify 进行评估。
7. **Big-Math-Digits：**我们在 1000 个留出的验证样本上进行评估。我们使用 math-verify 进行评估。
8. **CommonSenseQA：**我们使用 CommonsenseQA 数据集的验证集（1220 道题）(Talmor et al., 2019)。这是一个多项选择问答数据集，需要运用不同类型的常识知识来预测正确答案。我们使用 LLM 作为裁判进行评估。
9. **GPQA：**我们使用 GPQA 主数据集，其中包含生物学、物理学和化学专家编写的 448 道多项选择题 (Rein et al., 2024)。我们使用 LLM 作为裁判进行评估。

B.4 评估细节

所有模型均在温度为 0 时进行评估。 除 Math 和 GSM8K 外，所有数据集的最大 token 预算均为 4096。 评估用的系统提示，以及提取答案和置信度分数的流程，会根据所评估的方法略有不同：

1. **RLCR （本文方法）：**RLCR 模型使用 <think>、<answer>、<analysis> 和 <confidence> 标签。评估时使用与训练相同的系统提示。我们从 <answer> 标签中提取答案，从 <confidence> 标签中提取置信度。
2. **RLVR ：**RLVR 模型使用 <think> 和 <answer>。评估时使用相同的系统提示，并从 <answer> 标签中提取答案。为获得其显式表达的置信度，我们在生成输出后附加“思考时间已结束。我以 0 到 100 之间的数字显式表达的对答案的置信度等于”。
3. **分类器／探针：**两种方法均以问题和 RLVR 模型生成的内容（解题过程和答案）为条件。因此，这两种方法都使用 RLVR 模型作为生成器，结果表中报告的准确率也相同。
4. **基础模型：**基础模型不擅长遵循指令，因此使用一个更简单的系统提示（简单置信度提示），引导它使用 <think>、<answer> 和 <confidence> 标签。若无法提取有效置信度，我们就在其输出后附加“思考时间已结束。我以 0 到 100 之间的数字显式表达的对答案的置信度等于”，然后再次调用模型以提取置信度。

对所有方法，若无法从 <answer> 标签中提取有效答案，我们就在其输出后附加“思考时间已结束。我的最终答案是”，然后再次调用模型。 这些定制流程的主要目的是公平地提取答案和置信度，并尽可能减少格式错误对性能的不利影响。

请注意，由于训练中使用了格式奖励，两种经过 RL 训练的模型几乎都能完美遵循所需格式，因而只需极少干预。 不过，基础模型能从这套完整的提取流程中获益。

重要的是，一旦提取出答案和置信度，所有方法就采用相同的评估方式，并根据数据集使用精确匹配、LLM 裁判或 math-verify。

LLM 裁判：我们使用温度设为 0 的 Llama-3.1-8B-Instruct 作为裁判。 裁判会获得问题、标准答案以及从评估流程中提取的答案。 提示要求它根据答案是否正确回答“YES”或“NO”。 由于所评估数据集的答案简短且客观，我们不向裁判提供思维轨迹作为条件，以免引入偏差。

C 系统提示

长版 RLCR 提示

“用户与助手之间的一段对话。用户提出问题，助手解决问题。助手首先在心中思考推理过程，向用户给出最终答案，随后分析自己对解答的置信度，再向用户给出置信度水平。置信度水平是 0 到 1 之间（含两端）的数字，用 <confidence> </confidence> 标签包裹。最终答案用 <answer> </answer> 标签包裹。关于置信度和不确定性的分析用 <analysis> </analysis> 标签包裹。助手应在这些标签内推理自己对解答的置信度及解答中的不确定性。以下是分析指南：
1. 你的任务是指出模型在思考中可能出错之处，或解题步骤、推理过程本身可能存在歧义之处。
2. 你不应提出修正回答的方法，你的工作 仅仅是对不确定性进行推理。
3. 对某些问题，回答可能是正确的。在这种情况下，只列出少量不确定性，再明确说明我无法发现更多不确定性，也完全可以。
4. 不确定性可能不同于错误。例如，不确定性可能来自问题中的歧义，或某个特定引理／证明的应用。
5. 如果存在可能导向不同答案的其他潜在方法，应当提及。
6. 列出合理的不确定性，不要泛泛而谈，尽可能具体地说明不确定性。
7. 将这一不确定性分析包裹在 <analysis> </analysis> 标签内。 必须遵循的最终格式为：<think> 此处填写推理过程 </think> <answer> 此处填写最终答案 </analysis> <analysis> 此处填写关于置信度和不确定性的分析 </analysis> <confidence> 此处填写置信度水平（0 到 1 之间的数字）</confidence>[11])

简版 RLCR 提示

用户与助手之间的一段对话。用户提出问题，助手解决问题。助手首先在心中思考推理过程，向用户给出最终答案，随后分析自己对解答的置信度，并向用户给出置信度水平。 置信度水平是 0 到 1 之间（含两端）的数字，用 <confidence> </confidence> 标签包裹。最终答案用 <answer> </answer> 标签包裹。关于置信度和不确定性的分析用 <analysis> </analysis> 标签包裹。助手应在这些标签内推理自己对解答的置信度及解答中的不确定性。 必须遵循的最终格式为： <think> 此处填写推理过程 </think><answer> 此处填写最终答案 </answer><analysis> 此处

[11]译者注：原文长版提示在最终答案后使用了 </analysis>，与前面的 <answer> 不匹配；此处保留原文标签。原文的起始引号与末尾右括号亦未配对。

填写关于置信度和不确定性的分析 </analysis><confidence> 此处填写置信度水平（0 到 1 之间的数字）</confidence>

简单置信度提示

用户与助手之间的一段对话。用户提出问题，助手解决问题。助手首先在心中思考推理过程，并分析自己对解答的置信度，然后向用户给出最终答案以及置信度水平。置信度水平是 0 到 1 之间（含两端）的数字，用 <confidence> </confidence> 标签包裹。最终答案用 <answer> </answer> 标签包裹。必须遵循的最终格式为：<think> 此处填写推理过程 <//think><answer> 此处填写最终答案 </answer> <confidence> 此处填写置信度水平（0 到 1 之间的数字）</confidence>。[12]

RLVR 提示

用户与助手之间的一段对话。用户提出问题，助手解决问题。助手首先在心中思考推理过程，然后向用户给出答案。推理过程和答案分别用 <think> </think> 和 <answer> </answer> 标签包裹，即 <think> 此处填写推理过程 </think><answer> 此处填写答案 </answer>。

专家 SFT 提示

你会获得一个问题及其解答。你必须验证解答是否正确，并将验证推理包裹在 <analysis> </analysis> 标签内。你的分析应至少包含 300 个字符，并按顺序逐步检查解题思路。以下是分析指南：
1. 你的分析也应使用“我”的形式，仿佛这份解答是你写的，而你现在正在验证它。
2. 你的目标不是解题，而是验证给定解答中的步骤是否正确。
3. 如果解题步骤存在歧义，或某一步引入了不确定性，应在分析中提及。
4. 按顺序逐步检查解答。
5. 分析应至少包含 300 个字符。
6. 将这一不确定性分析包裹在 <analysis> </analysis> 标签内。

D LLM 使用情况

作者有限度地使用 ChatGPT 来润色措辞、提高清晰度。ChatGPT 未用于研究构思、相关工作检索或实质性内容生成。

E 对数评分与 Brier 评分的比较

E.1 直观解释

对数评分和 Brier 评分都是广泛使用的适当评分规则。 引理 1 表明，将适当评分规则与正确性奖励结合能够保留校准激励。 无论使用对数评分还是 Brier 评分，模型都有动机输出真实的正确概率 $q = p_y$。 由此，当模型输出答案 y 并如实报告置信度 $q = p_y$ 时，其期望奖励可以写为：

$$\mathbb{E}_{\text{brier}}[R(y)] = p_y\big(1 - (1 - p_y)^2\big) + (1 - p_y)(-p_y^2) \tag{12}$$

$$\mathbb{E}_{\log}[R(y)] = p_y(1 + \log p_y) + (1 - p_y)\log(1 - p_y). \tag{13}$$

[12]译者注：原文简单置信度提示将思考结束标签写为 <//think>；此处保留原文。

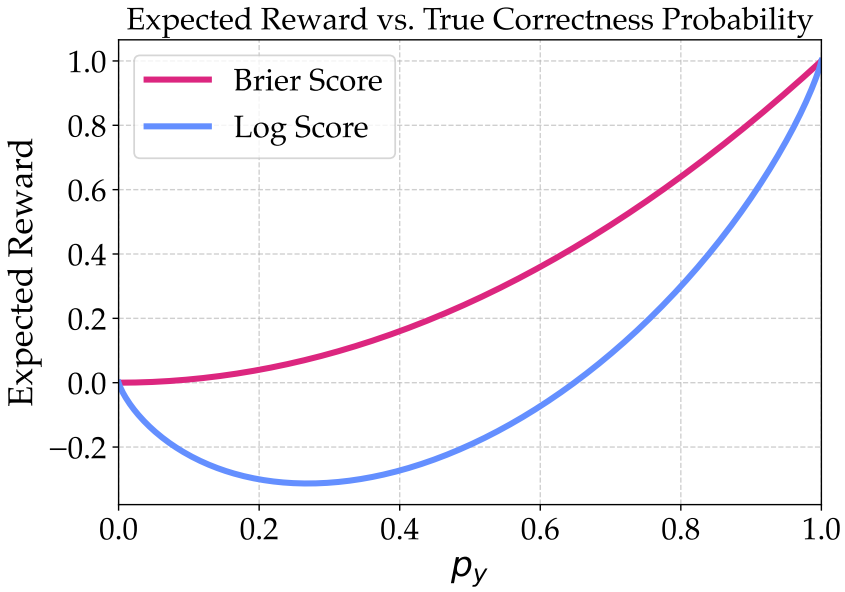


图 5: 期望奖励随正确概率 p_y 的变化。

图 5 绘制了期望奖励关于 p_y 的函数。基于 Brier 评分的期望奖励随 p_y 严格递增，而对数评分下的期望奖励则不然。 这意味着，将对数评分与正确性奖励结合时，在某些 p_y 区间内，模型报告真实正确概率更低的答案，反而可以获得更高的期望奖励。 直观而言，对数评分中的校准项可能压过正确性加分，形成非单调的奖励函数，从而削弱模型偏好更准确答案的动力。

E.2 简化实验

环境设置。 为通过实验验证这一现象，我们构建了一个简单的 K 臂预测任务。 对每个实例，自然环境采样一个概率向量

$$\mathbf{p} = (p_1, \ldots, p_K), \qquad p_i \geq 0, \sum_{i=1}^{K} p_i = 1,$$

该向量对模型而言是未知的。 提示中向模型展示由 N 次独立同分布采样得到的序列

$$x_1, \ldots, x_N \sim \mathbf{p}, \qquad x_t \in \{1, \ldots, K\},$$

N 的值均匀采样自

$$N \sim \mathrm{Unif}\{0, 1, 2, 3, 4, 5\}.$$

模型的任务是预测下一次采样

$$x_{N+1} \sim \mathbf{p},$$

即输出一个臂索引 $\hat{y} \in \{1, \ldots, K\}$，同时给出置信度值 $q \in [0, 1]$。 如果希望弃答，模型可以自由输出无效答案 $\hat{y} = -1$，并令 $q = 0$。 我们始终使用 $K = 5$。 下面给出一个任务实例。

简化多臂任务实例

有 5 个臂，每个臂被采样到的概率不同。你将获得从这一 5 臂分布中抽取的一些样本。你的任务是预测下一次采样将来自哪个臂。如果你确实不确定，也可以自由输出 -1，置信度为 0。 观察到的采样结果（按顺序）： 1, 1, 0。 展示的已观察采样次数：3 请用你预测下一次采样所属的臂索引（0-4）作答。[13]

[13]译者注：原文数学定义使用从 1 到 K 的臂索引，而任务实例使用 0-4；两种编号均按原文保留。

由于观测序列很短，而且不同任务的 $\mathbf{p}$ 可以任意变化，这一设置会引入显著的偶然不确定性。给定观测数据，贝叶斯最优预测为经验频率最高的臂，[14]

$$\hat{y}^\star = \arg\max_{i\in\{1,\dots,K\}} \sum_{t=1}^{N} \mathbf{1}\{x_t = i\}.$$

这一环境是刻意设计的，使模型常常对正确的臂高度不确定。参照图 5，我们观察到，在对数评分规则下，这种低置信度情形中的期望奖励，会在模型故意输出错误答案并将置信度设为 0 时达到最大，而不是在模型认真尝试预测时达到最大。

训练设置。我们使用上述数据集中的 $10,000$ 个样本训练 RLCR-Brier 和 RLCR-Log。模型采用 Qwen-2.5-7B，训练配置与节 B.2 相同。为简化实验，我们不要求模型进行任何不确定性推理。

结果。

方法	准确率	Brier	ECE
RLCR-Brier （**本文方法**）	**34.4%**	0.22	0.02
RLCR-Log	0	**0.00**	**0.00**

图 6: 简化多臂任务数据集上的性能。RLCR-Log 坍缩为退化解，而 RLCR-Brier 实现了非平凡的准确率和校准表现。

图 6 展示了简化多臂任务上的评估结果。下面还展示了两个模型的输出示例。实验发现与我们的理论预测高度一致。

在对数评分规则下，模型迅速收敛到一种退化策略：对几乎所有任务都输出无效的臂（-1），并报告置信度 $q = 0$。在较低 p_y 的情形下，这一策略能获得对数评分下可能的最大期望奖励，因此模型的校准指标几乎完美。然而，由于模型从不预测有效的臂，它在底层任务上的准确率坍缩为 0。

相比之下，RLCR-Brier 的行为在性质上截然不同。由于期望 Brier 奖励随真实正确概率严格递增，坍缩为无效的低置信度答案是明显次优的。因此，经 RLCR-Brier 训练的模型会继续认真预测下一个臂，同时实现非平凡的准确率和稳定的校准。

RLCR-Brier 输出示例

<think> 分析每个臂的频率 </think><answer> 1 </answer> <confidence> 0.25 </confidence>

RLCR-Log 输出示例

<think> 根据给定信息，没有可用于预测下一次采样的数据。</think><answer> -1 </answer> <confidence> 0</confidence>

E.3 HotPot 上的实验

我们还在真实的问答设置中评估这两种评分规则。为此，我们训练了一个 RLCR-Log 模型，其训练配置与 HotpotQA 主要结果中所用的 RLCR 模型相同（见表 1）。表 3 给出了 RLCR-Brier 与 RLCR-Log 的直接比较；其中 RLCR-Brier 和 RLVR 的数值复制自主要结果表。

[14]译者注：原文未说明概率向量 $\mathbf{p}$ 的先验分布。将经验频率最高的臂视为贝叶斯最优选择，通常还需要对称先验等条件；这里保留原文结论。

方法	HotpotQA				分布外（O.O.D）平均			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
RLVR	**63.0**%	0.50	0.37	0.37	53.9%	0.50	0.46	0.46
RLCR-Brier（**本文方法**）	62.1%	**0.69**	**0.21**	**0.03**	**56.2**%	**0.68**	**0.21**	**0.21**
RLCR-Log	59.5%	0.68	0.22	0.07	53.6%	0.67	0.22	**0.21**

表 3: RLCR-Brier 与 RLCR-Log 在 HotpotQA 和 6 个分布外（O.O.D.）数据集上的比较。RLCR-Brier 在准确率和校准方面均略优于 RLCR-Log。

总体而言，RLCR-Log 在准确率和校准方面均略逊于 RLCR-Brier。但与简化多臂老虎机设置不同，我们没有观察到任何奖励投机的证据：RLCR-Log 模型保持了合理的准确率，并未坍缩为退化预测。

这表明，尽管使用对数评分可能导致奖励投机，但对许多数据集而言，实践中可能并不会发生这种投机。我们认为，奖励投机是否出现取决于数据分布和模型规模两者。

F 向其他模型的泛化

F.1 OlMo-2

方法	HotpotQA				分布外（O.O.D）平均			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	16.4%	0.55	0.78	0.79	47.8%	0.56	0.48	0.48
RLVR	**61.7%**	0.51	0.38	0.38	**50.8**%	0.53	0.48	0.48
RLCR（**本文方法**）	61.3%	**0.58**	**0.24**	**0.09**	49.3%	**0.65**	**0.22**	**0.20**

表 4: 使用 OlMo-2-7B-Instruct 进行 RLCR 和 RLVR 训练的结果。RLCR 的准确率与 RLVR 相当，但校准表现显著优于 RLVR。

设置：为评估 RLCR 框架在不同模型家族之间的泛化能力，我们以 OlMo-2-7B-Instruct 模型 (OLMo et al., 2024) 为起点，在 HotpotQA-Modified 数据集上训练 RLCR 和 RLVR 变体。

结果：表 4 报告了最终性能。总体趋势与我们的主要发现一致：RLCR 和 RLVR 达到了相近的准确率，二者相较基础模型都大幅提高了准确率。RLCR 的校准表现也明显优于 RLVR 和基础模型。

F.2 Qwen3

我们进一步评估了新发布的 Qwen3 模型家族上的性能。在分布内评估中，RLCR 的准确率与 RLVR 相当，并在 AUROC、Brier 和 ECE 上优于 RLVR。在所有分布外基准上取平均后，RLCR 在 AUROC、Brier 和 ECE 上仍优于 RLVR，而准确率基本相同。

方法	HotpotQA				分布外（O.O.D）平均			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	61.1%	0.53	0.35	0.34	62.8%	0.59	0.28	0.28
RLVR	**62.7%**	0.53	0.36	0.36	65.5%	0.62	0.28	0.29
RLCR（**本文方法**）	61.8%	**0.58**	**0.28**	**0.23**	**65.6%**	**0.71**	**0.17**	**0.17**

表 5: 使用 Qwen-3-8B 进行 RLCR 和 RLVR 训练的结果。RLCR 在保持准确率的同时，显著改善了分布内和分布外设置中的校准表现。

G 推理是否改善校准?

近期工作表明，CoT 推理可能是不忠实的，即生成的 CoT 并不会影响最终答案 (Chen et al., 2025)。这意味着，不确定性分析可能并未为显式表达的置信度分数提供有意义的信息。 为检验这一点，我们在 HotPotQA-Modified 上训练了两种分类器:

1. **基线分类器:** 使用 RLVR 的输出训练（这些输出不包含不确定性分析）。
2. **分析分类器:** 使用 RLCR 的输出训练，并移除其中的置信度分数（位于 <confidence> 标签内），以防止直接利用该信息取巧。

由于两个 RL 模型的任务准确率相当，分类器性能上的差异将表明，经过 RLCR 训练的模型的推理链包含了对校准特别有用的信息。

我们针对 Qwen-base 的 3 种模型规模训练分类器：0.5B、1.5B 和 7B。 图 7 展示了 HotPotQA-Modified 上的 Brier 和 ECE 分数。有趣的是，虽然两种 7B 分类器表现相近，但在较小规模下，分析分类器优于基线分类器，表明分类器容量是关键因素。

对于表达能力足够强的分类器（如 7B 模型），可以直接从解题过程中推断与置信度相关的特征。 相比之下，较小的分类器能够更好地利用 RLCR 的推理链。

我们认为，分类器容量与 CoT 内容之间关系的更广泛问题，是未来工作的重要课题。

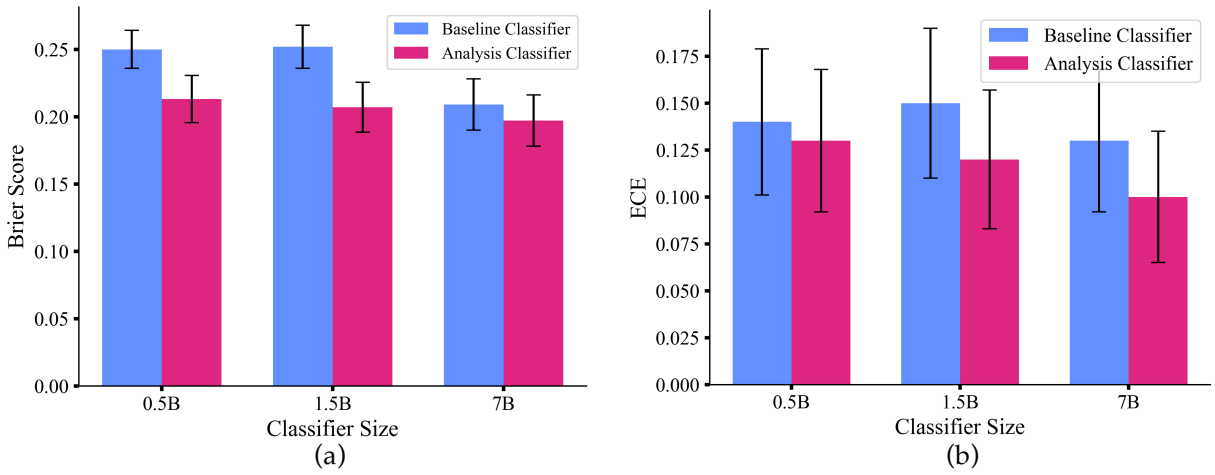


图 7: 三种模型规模下，基线分类器／分析分类器在 HotPotQA-Modified 上的 Brier 评分（a）和 ECE（b）。在较小规模下，分析分类器优于基线，表明容量受限时，不确定性 CoT 对实现更好的校准至关重要。

H 置信度分布

H.1 不同输入之间的置信度分布

(a) RLCR (b) 带分析的 RLVR (c) RLVR + BCE 置信度分类器

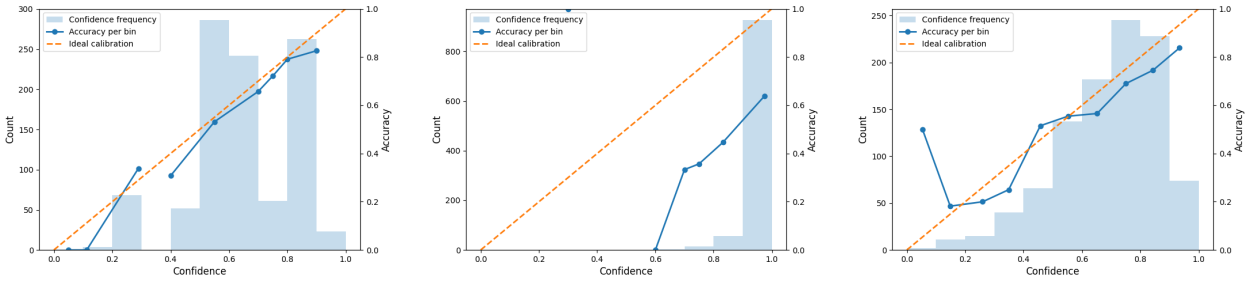


图 8: 分布内 HotpotQA：RLCR、RLVR 和 RLVR+BCE 置信度分类器的校准图，叠加置信度频率直方图。

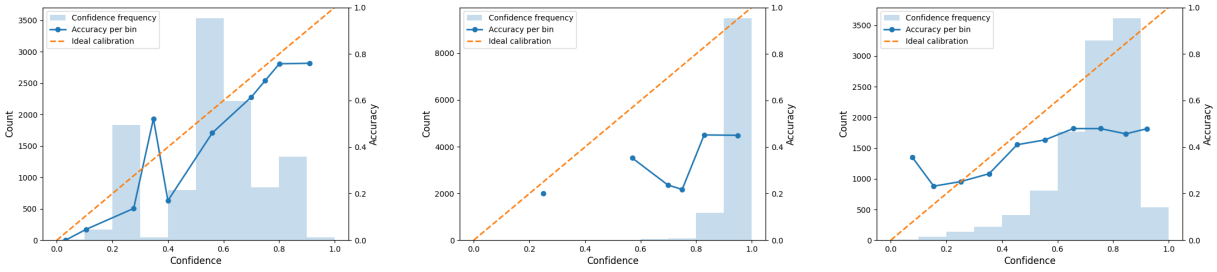
这里，我们展示叠加了置信度频率直方图的校准图。 对一个理想校准的模型，准确率校准曲线应接近橙色虚线。 直方图直接展示了模型的置信度值是否确实具有多样性，抑或聚集在一个狭窄范围内。

在图 8a 中，我们展示了 HotpotQA 的分布内评估结果。

对 RLCR，直方图表明模型使用了整个置信度范围：中等置信度分箱（0.4–0.8）中有相当大的质量，较低和较高分箱也均被相当程度地使用。这说明 RLCR 生成的置信度分数依赖于输入，而非坍缩到一个类似总体准确率的单一数值。各分箱准确率曲线也紧密跟随理想对角线，表明这些不同置信度水平对应着答案正确可能性的有意义差异。

相比之下，RLVR（图 8b）几乎将所有预测都集中在 0.9–1.0 区间，较低分箱中只有极少的预测。这种聚集表明，RLVR 的输出大体一致且过度自信，其置信度并未随输入产生有意义的变化。

最后，当我们以经 RLVR 训练的模型作为 BCE 置信度分类器的基础时（图 8c），相比 RLVR 的图，各分箱准确率曲线更加贴近理想线，说明该分类器也有效。 不过，它的表现仍逊于 RLCR。



(a) RLCR (b) RLVR+分析 (c) RLVR+BCE 分类器

图 9: 在 6 个分布外数据集上取平均：RLCR、RLVR 和 RLVR+BCE 置信度分类器的校准图，叠加置信度频率直方图。

我们在分布外评估中观察到了相似模式，结果见图 9。无论准确率如何，RLVR（图 9b）输出的置信度仍坍缩到 1.0，其各分箱准确率曲线也显著偏离理想校准。例如，显式表达的置信度为 0.8–0.9 的预测，平均准确率仅约为 0.3。在 RLVR 模型之上训练 BCE 置信度分类器（图 9c），可以在一定程度上缓解这种行为，使置信度值的分布略微分散，各分箱准确率曲线也稍稍更接近理想线。然而，RLCR（图 9a）仍表现最佳：它的置信度值在整个范围（0–1）内分布较为充分，各分箱准确率曲线也比 RLVR 及其 BCE 分类器变体更接近理想校准。

H.2 单个输入的置信度分布

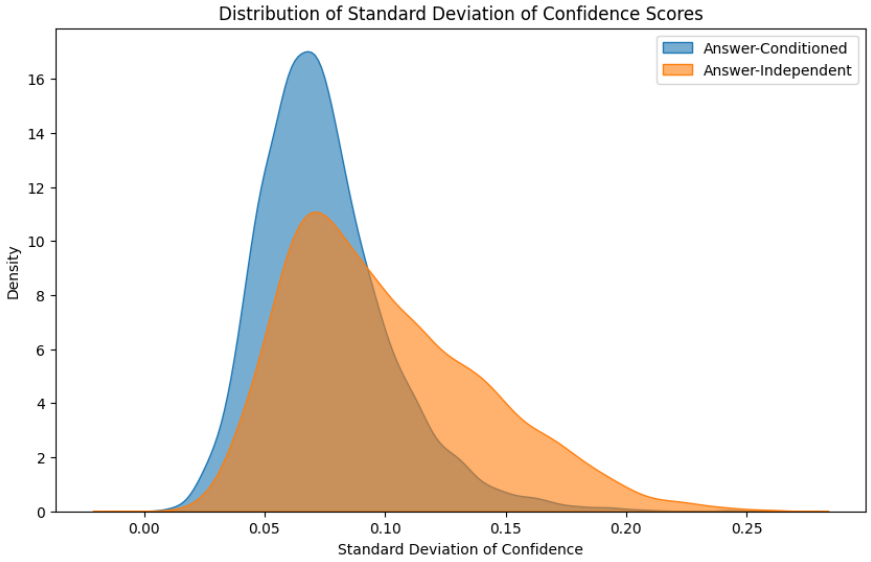


图 10: 以答案为条件和不以答案为条件的置信度分数的标准差分布

为分析给定问题下模型置信度值的分布，我们考察了逐输入的置信度变异性。对每个问题，我们计算模型在多次采样生成中所得置信度分数的标准差，图中展示了这些逐问题标准差的分布。

我们绘制了两种分布：

1. **以答案为条件的分布：** $p(c|x, y, a)$。对于给定的问题、解题过程和最终答案，我们采样 $N = 16$ 条分析／CoT 轨迹，并计算其置信度分数的标准差。这反映了模型针对给定推理轨迹和答案时，置信度的稳定程度。直观而言，这里的标准差较高并不理想，因为这意味着，对于给定解答，模型对自身置信度的判断在内部不一致或处于“困惑”状态。

2. **不以答案为条件的分布：** $p(c|x)$。我们采样 N = 16 条完整的 CoT，每条都有独特的推理路径。这些轨迹对应多种不同的推理路径（也可能包含多个不同答案）。随后，我们计算同一问题下这些轨迹的置信度标准差，以刻画针对某个特定问题，模型生成不同解答时置信度如何变化。

如图 10 所示，不以答案为条件的分布（橙色）在右侧有显著更多的质量，表明不同推理轨迹之间的置信度变化明显更大。相比之下，以答案为条件的分布（蓝色）更窄，反映出固定答案后噪声有所减少；但重要的是，它仍有相当程度的分散，而非坍缩到接近零的位置。

综合来看，这些发现表明，为同一问题生成多条推理轨迹时，置信度分数的方差明显高于对固定推理轨迹生成多个置信度分数时的方差。

I 与 RL 校准基线的比较

基线。 我们将 RLCR 与最相关的 RL 校准基线经细致调整后的变体进行比较。若干先前方法主要关注校准，并未显式优化准确率。为确保公平比较，我们使用已经为准确率进行训练的 RLVR 模型来初始化这些基线，将这些方法适配到推理设置中。

1. **校准 RL（完整序列）** (Stangel et al., 2025; Xu et al., 2024)：我们训练了一个仅优化 Brier 评分奖励、不包含任何准确率相关项的变体。我们在整个生成序列（think、answer、analysis、confidence）上施加损失。这是在推理 LLM 设置中应用适当评分规则奖励的最直接方式。我们从 RLVR 模型进行初始化。

方法	HotpotQA				分布外（O.O.D）平均			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
校准 RL（完整序列）	0.00	不适用	**0.00**	**0.00**	0.00	不适用	**0.00**	**0.00**
校准 RL（分析 + 置信度）	62.0%	0.53	0.24	0.08	52.8%	0.57	0.27	0.25
弃答 RL	62.1%	0.61	0.32	0.31	54%	0.59	0.35	0.35
RLVR	**63.0**%	0.50	0.37	0.37	53.9%	0.50	0.46	0.46
RLCR（**本文方法**）	62.1%	**0.69**	0.21	0.03	**56.2**%	**0.68**	0.21	0.21

表 6: RL 校准基线的结果。 所有基线的校准表现都显著优于 RLVR，但在准确率和校准方面都逊于 RLCR。只使用校准奖励训练会导致退化解。通过屏蔽 answer 和 think token 上的损失，可以避免这种坍缩。训练模型弃答从未明确教授置信度估计，也可能抑制探索。

2. **校准 RL（仅分析+置信度）**。 先前工作 (Stangel et al., 2025) 表明，仅对分析和置信度部分施加校准奖励，可以稳定训练并保持任务准确率。因此，我们实现了上述基线的一个更强、能够保持准确率的变体：将奖励限制在分析和置信度片段内，不在思考／答案部分计算损失。与上述基线类似，我们从 RLVR 模型进行初始化。

3. **弃答 RL** (Wei et al., 2025; Mohamadi et al., 2025; Song et al., 2025)：近期论文提出了三值奖励，对正确答案给予 $+1$，对错误答案给予 0，对明确弃答（例如“我不知道”）给予中间奖励 λ。我们采用这类方法，并将 $\lambda = 0.5$ 设为标准的中点值。由于弃答模型不会生成置信度分数，我们在测试时使用要求模型绝不弃答的提示来评估校准。由于该方法也直接优化准确率，我们从标准的 Qwen2.5-7B 模型进行初始化。

结果。 表 6 报告了完整结果。所有基线的校准表现都显著优于普通 RLVR，但在所有指标上均逊于 RLCR。[15]

校准 RL（完整序列）的准确率坍缩到接近零：由于没有针对正确性的奖励塑形，模型很快收敛到一种退化但能最大化奖励的行为，即输出空答案或无实质内容的答案，并将置信度设为 0。这会在 Brier 评分下得到完美校准，实质上也是仅使用校准奖励时的最优策略。 虽然 KL 正则化可能减轻这种坍缩，但这一变体始终存在降低任务准确率的压力。

校准 RL（仅分析+置信度）能够防止坍缩，并保持与 RLCR 相当的准确率，但校准表现仍明显较弱。我们推测有两个原因。首先，RLVR 模型可能并不适合作为进一步 RL 优化的起点。与基础模型相比，它们可能具有更低的熵，或差异很大的输出分布。其次，像 RLCR 那样联合优化准确率与校准，可能产生相互强化的互补梯度信号，使置信度估计的学习更加有效。

弃答 RL的校准表现逊于 RLCR。由于弃答奖励只教会模型判断其内部置信度是否超过阈值 λ，模型从未学会细粒度的置信度估计。此外，奖励弃答也可能抑制探索：一旦模型学会对困难问题弃答，它可能就不再尝试这些问题，从而同时限制推理能力的提升和校准学习。弃答奖励更适合主要目标并非提高准确率、而是教会模型弃答技能的设置。

[15]译者注：原文此处及表注中的概括与表中部分数值不完全一致。完整序列校准 RL 的 Brier 和 ECE 均为 0，数值优于 RLCR，但这是准确率为 0 的退化结果；弃答 RL 的 HotpotQA 准确率则与 RLCR 同为 62.1%。此处保留原文表述及数值。

J SFT+RLCR 分析

方法	HotpotQA				分布外（O.O.D）平均			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	56.1%	0.56	0.40	0.39	47.8%	0.53	0.46	0.45
RLVR	**72.9%**	0.47	0.28	0.26	**52.5%**	0.52	0.49	0.49
RLCR	72.7%	0.67	0.17	0.10	50.9%	0.60	0.28	0.25
SFT+RLCR （原始提示）	72.2%	**0.78**	**0.14**	**0.08**	43.8%	**0.66**	**0.24**	**0.18**
SFT+RLCR （调整后提示）	72.5%	0.75	0.15	0.09	49.8%	0.62	0.25	0.21

表 7: 对提示作简单修改后的 SFT+RLCR 结果。在提示中仅增加一行，就能使分布外准确率从 43.8% 提升到 48%。

译者注：原文表注写为 48%，而表中数值及后文均为 49.8%；此处分别保留原文数值。此外，左半表的表头原文为 HotpotQA，但其中已有模型的数值与主结果表中 Math（三个数学数据集的平均值）一致，疑为表头误标；此处亦予以保留。

表 1 的结果表明，我们的 SFT+RLCR 模型在分布外准确率上出现了显著下降。 RLVR 和普通 RLCR 的分布外准确率分别为 52.5% 和 50.9%，而 SFT+RLCR 仅为 43.8%。

为调查这种退化，我们人工检查了 SFT+RLCR 的生成内容，发现了一种仅见于该模型的稳定异常：模型常常在推理过程中识别出正确答案，却随后在答案标签内填入一个错误、看起来随机的数字。 这种行为表明，在数学题占比较高的数据上长期进行 RL 训练，可能使模型在最终答案的格式化方式上产生过拟合或领域特定偏差。

为检验这一问题究竟反映了灾难性遗忘，还是更表层的不匹配，我们对提示稍作修改后重新进行了评估。 我们增加了一条澄清指令： “请留意你在答案标签内填写的内容。如果问题与数学无关，不要随意在其中填写数字。”

值得注意的是，这一简单改动将分布外准确率从 43.8% 提升到了 49.8%，如表 7 所示。 这表明，性能退化并不完全源于灾难性遗忘；相反，大部分失败来自以数学为中心的 RL 训练中学到的格式偏差，而这种偏差很容易逆转。

我们推测，加入少量 KL 正则化，或采用不限于数学、更加多样化的 RL 数据集进行训练，会减轻这些影响。 先前工作也观察到，SFT 可能比 RL 导致更多遗忘 (Shenfeld et al., 2025; Mukherjee et al., 2025)，剩余的性能差距也确实可能反映了残余遗忘，但程度远小于我们最初的怀疑。

K HotPot 训练结果

图 11 展示了 RLCR 和 RLVR 的训练曲线。 RLCR 的正确性奖励和校准奖励均平稳上升，表明模型能够同时提高准确率和校准表现。 值得注意的是，随着不确定性推理能力改善，我们的方法的生成长度在训练过程中逐渐增加。

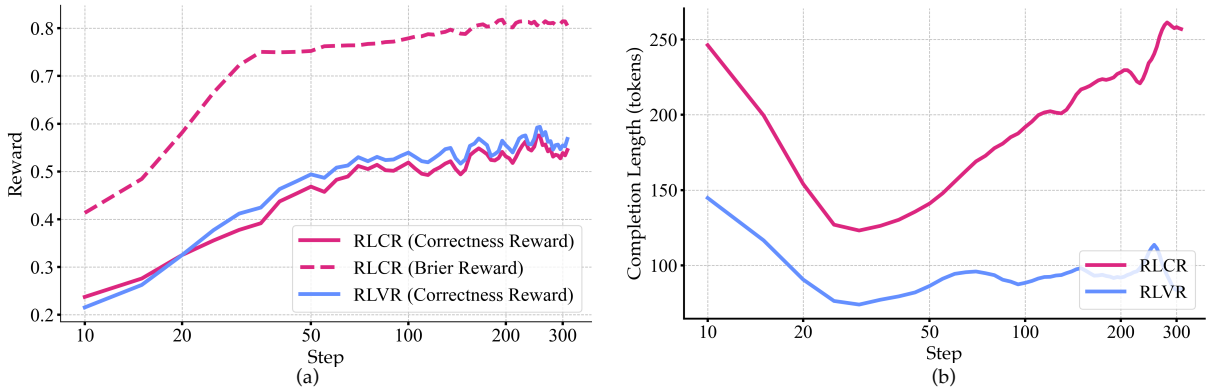


图 11: (a) RLCR（本文方法）和 RLVR 的奖励曲线。我们的方法同时提高了正确性奖励与校准奖励，体现出正确性和校准的同步改善。为便于观察，Brier 奖励整体向上平移了 1。**(b) 训练过程中的生成长度**。随着不确定性推理能力改善，我们的方法的生成长度在训练过程中逐渐增加。

L 完整结果：在 HotpotQA 上训练的模型

讨论 下面给出各数据集上的完整结果。 尽管 RLCR 的平均表现优于各基线，但在单个分布外（O.O.D.）数据集上，校准表现可能存在相当大的差异。 CommonsenseQA 是一个尤其有代表性的例子：所有方法在该数据集上的准确率均约为 90%。 RLVR 严重过度自信，在所有问题和数据集上始终预测 85–100% 的置信度。 在 CommonsenseQA 上，这种过度自信恰好与该数据集上的高准确率相吻合，从而呈现出具有误导性的良好校准表现。需要强调的是，这种吻合是由 RLVR 普遍偏高的置信度造成的虚假相关，而非真正的不确定性建模。 同时，我们承认，包括 RLCR 在内的所有方法在分布外校准方面都还有很大的改进空间。我们认为，延长强化学习训练并纳入更加多样化的训练数据集，可以进一步增强鲁棒性并改善校准。

方法	SimpleQA				Trivia			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	**13.5% ± 1.0**	0.50 ± 0.01	0.77 ± 0.01	0.81	57.8% ± 2.2	0.51 ± 0.01	0.38 ± 0.02	0.37
RLVR		0.50 ± 0.00	0.88 ± 0.01	0.88		0.50 ± 0.00	0.38 ± 0.02	0.38
RLVR+BCE 分类器		0.48 ± 0.03	0.53 ± 0.01	0.64		0.57 ± 0.03	0.26 ± 0.01	0.15
RLVR+Brier 分类器	12.4% ± 1.0	**0.60 ± 0.03**	**0.11 ± 0.01**	**0.06**	**62.2% ± 2.1**	0.57 ± 0.03	0.37 ± 0.01	0.37
RLVR+探针		0.51 ± 0.03	0.14 ± 0.01	0.12		0.47 ± 0.03	0.43 ± 0.01	0.41
答案概率		0.42 ± 0.03	0.83 ± 0.01	0.85		0.50 ± 0.03	0.37 ± 0.02	0.36
RLCR (**本文**)	12.1% ± 1.0	**0.60 ± 0.02**	0.24 ± 0.01	0.34	60.8% ± 2.1	**0.73 ± 0.03**	**0.20 ± 0.01**	**0.06**

表 8: 在 SimpleQA 和 Trivia 数据集上的表现。 数值表示均值，误差范围为 95% 自助法置信区间的半宽。最优值以粗体标出。

方法	CommonsenseQA				GPQA			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	88.6% ± 1.8	0.62 ± 0.05	0.10 ± 0.01	**0.00**	39.5% ± 4.4	0.49 ± 0.05	0.50 ± 0.04	0.51
RLVR		0.50 ± 0.00	0.09 ± 0.02	0.09		0.50 ± 0.00	0.60 ± 0.05	0.60
RLVR+BCE 分类器		0.65 ± 0.06	0.12 ± 0.01	0.18		0.52 ± 0.05	0.28 ± 0.02	**0.16**
RLVR+Brier 分类器	90.8% ± 1.6	0.65 ± 0.05	0.26 ± 0.01	0.42	39.5% ± 4.6	0.52 ± 0.06	0.29 ± 0.03	0.21
RLVR+探针		0.50 ± 0.06	0.75 ± 0.01	0.81		0.50 ± 0.05	0.33 ± 0.04	0.29
答案概率		0.60 ± 0.06	**0.08 ± 0.01**	0.03		0.53 ± 0.05	0.54 ± 0.04	0.54
RLCR (**本文**)	**91.3% ± 1.6**	**0.73 ± 0.06**	0.17 ± 0.01	0.30	**41.5% ± 4.7**	**0.55 ± 0.05**	**0.27 ± 0.01**	**0.16**

表 9: 在 CommonsenseQA 和 GPQA 数据集上的表现。 数值表示均值，误差范围为 95% 自助法置信区间的半宽。最优值以粗体标出。

方法	MATH-500				GSM8K			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	46.8% ± 4.30	0.59 ± 0.05	0.48 ± 0.04	0.49	73.5% ± 2.50	0.52 ± 0.03	0.24 ± 0.02	0.22
RLVR		0.50 ± 0.01	0.61 ± 0.04	0.61		0.50 ± 0.00	0.20 ± 0.02	0.20
RLVR + 分类器		0.70 ± 0.05	0.26 ± 0.02	0.22		0.57 ± 0.04	0.16 ± 0.02	**0.07**
RLVR + Brier 分类器	38.6% ± 4.20	0.58 ± 0.05	0.32 ± 0.03	0.29	80.1% ± 2.10	0.66 ± 0.04	0.55 ± 0.02	0.63
RLVR + 探针		0.67 ± 0.05	**0.24 ± 0.03**	**0.15**		0.53 ± 0.04	0.41 ± 0.01	0.48
答案概率		**0.79 ± 0.05**	0.51 ± 0.04	0.55		**0.78 ± 0.02**	0.16 ± 0.02	0.17
RLCR (**本文**)	**45.4% ± 4.50**	0.72 ± 0.05	0.25 ± 0.02	0.19	**86.3% ± 1.75**	0.74 ± 0.04	**0.14 ± 0.01**	0.20

表 10: 在 Math-500 和 GSM8K 数据集上的表现。 数值表示均值，误差范围为 95% 自助法置信区间的半宽。最优值以粗体标出。

译注：本表粗体标记沿用原文；MATH-500 列中，基础模型的准确率为 46.8%，高于原文以粗体标出的 45.4%。

方法	HotpotQA				HotpotQA-Modified			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	39.7% ± 3.10	0.54 ± 0.02	0.53 ± 0.03	0.53	30.4% ± 4.30	0.59 ± 0.04	0.57 ± 0.04	0.59
RLVR		0.50 ± 0.00	0.37 ± 0.03	0.37		0.50 ± 0.00	0.54 ± 0.05	0.54
RLVR +BCE 分类器		0.66 ± 0.04	0.22 ± 0.01	0.07		0.77 ± 0.05	0.21 ± 0.02	0.13
RLVR +Brier 分类器	63.0% ± 3.05	0.65 ± 0.04	0.22 ± 0.02	0.09	46.0% ± 4.30	0.79 ± 0.05	0.20 ± 0.02	0.12
RLVR +探针		0.55 ± 0.04	0.24 ± 0.01	0.10		0.57 ± 0.05	0.26 ± 0.01	0.12
答案概率		**0.72 ± 0.04**	0.36 ± 0.03	0.36		0.61 ± 0.05	0.52 ± 0.04	0.53
RLCR (**本文**)	62.1% ± 3.05	0.69 ± 0.04	**0.21 ± 0.01**	**0.03**	44.4% ± 4.20	**0.80 ± 0.05**	**0.19 ± 0.02**	**0.08**

表 11: 在 HotpotQA 和 HotpotQA-Modified 数据集上的表现。 数值表示均值，误差范围为 95% 自助法置信区间的半宽。最优值以粗体标出。

M 完整结果：在 Math 上训练的模型

译注：本节表格中的 RLCR+SFT 与 SFT+RLCR 写法均沿用原文。

方法	SimpleQA				TriviaQA			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	13.5% ± 1.01	0.50 ± 0.01	0.77 ± 0.01	0.81	57.8% ± 2.25	0.51 ± 0.01	0.38 ± 0.02	0.37
RLVR		0.53 ± 0.02	0.83 ± 0.01	0.84		0.50 ± 0.02	0.43 ± 0.02	0.43
RLVR+BCE 分类器		0.45 ± 0.02	0.57 ± 0.01	0.64		0.57 ± 0.03	0.29 ± 0.01	0.22
RLVR+Brier 分类器	**15.2% ± 1.05**	0.49 ± 0.02	**0.15 ± 0.01**	**0.11**	58.3% ± 2.20	0.61 ± 0.03	0.30 ± 0.01	0.25
RLVR+探针		0.44 ± 0.02	0.58 ± 0.01	0.66		0.56 ± 0.03	0.30 ± 0.01	0.23
答案概率		0.45 ± 0.02	0.80 ± 0.01	0.81		0.48 ± 0.02	0.40 ± 0.02	0.38
RLCR (**本文**)	12.0% ± 0.95	0.52 ± 0.02	0.43 ± 0.01	0.54	**61.0% ± 2.13**	0.67 ± 0.02	0.22 ± 0.01	0.10
RLCR+SFT (**本文**)	11.4% ± 0.94	**0.60 ± 0.03**	0.29 ± 0.01	0.40	55.6% ± 2.20	**0.72 ± 0.02**	**0.21 ± 0.01**	**0.06**

表 12: 在 SimpleQA 和 TriviaQA 数据集上的表现。 数值表示均值，误差范围为 95% 自助法置信区间的半宽。最优值以粗体标出。

方法	CommonsenseQA				GPQA			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	88.6% ± 1.76	0.62 ± 0.05	**0.10 ± 0.01**	**0.00**	39.5% ± 4.35	0.49 ± 0.05	0.50 ± 0.04	0.51
RLVR		0.55 ± 0.02	0.13 ± 0.02	0.13		0.50 ± 0.02	0.53 ± 0.04	0.53
RLVR+BCE 分类器		0.61 ± 0.05	0.23 ± 0.01	0.34		0.51 ± 0.05	0.33 ± 0.03	0.27
RLVR+Brier 分类器	89.3% ± 1.88	0.60 ± 0.05	0.30 ± 0.01	0.45	**50.0% ± 4.91**	0.53 ± 0.05	0.33 ± 0.03	0.28
RLVR+探针		0.57 ± 0.05	0.19 ± 0.01	0.28		0.50 ± 0.05	0.30 ± 0.02	0.19
答案概率		0.56 ± 0.05	0.10 ± 0.02	0.09		0.53 ± 0.06	0.44 ± 0.04	0.40
RLCR (**本文**)	**90.1% ± 1.68**	0.62 ± 0.05	0.21 ± 0.01	0.34	43.3% ± 4.46	0.57 ± 0.05	0.26 ± 0.02	0.10
SFT+RLCR (**本文**)	77.6% ± 2.17	**0.73 ± 0.04**	0.22 ± 0.02	0.25	32.6% ± 4.35	**0.60 ± 0.06**	**0.23 ± 0.02**	**0.08**

表 13: 在 CommonsenseQA 和 GPQA 数据集上的表现。 数值表示均值，误差范围为 95% 自助法置信区间的半宽。最优值以粗体标出。

方法	MATH-500				GSM8K			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	46.8% ± 4.20	0.59 ± 0.05	0.48 ± 0.04	0.49	73.5% ± 2.46	0.52 ± 0.03	0.24 ± 0.02	0.22
RLVR		0.45 ± 0.04	0.44 ± 0.04	0.43		0.47 ± 0.05	0.09 ± 0.01	**0.05**
RLVR +BCE 分类器		0.77 ± 0.05	0.22 ± 0.03	0.18		**0.77 ± 0.05**	**0.08 ± 0.01**	0.06
RLVR +Brier 分类器	59.2% ± 4.10	0.79 ± 0.05	0.22 ± 0.03	0.18	**90.6% ± 1.57**	0.76 ± 0.05	**0.08 ± 0.01**	**0.05**
RLVR +探针		0.67 ± 0.05	0.26 ± 0.03	0.20		0.56 ± 0.05	0.11 ± 0.01	0.14
答案概率		0.54 ± 0.05	0.39 ± 0.04	0.39		0.48 ± 0.02	0.09 ± 0.02	0.09
RLCR (**本文**)	**59.8% ± 4.20**	0.67 ± 0.04	0.23 ± 0.02	**0.12**	89.6% ± 1.71	0.63 ± 0.03	0.10 ± 0.01	0.12
SFT+RLCR (**本文**)	55.8% ± 4.40	**0.81 ± 0.05**	**0.19 ± 0.03**	0.16	90.4% ± 1.67	0.73 ± 0.04	**0.08 ± 0.01**	0.06

表 14: 在 MATH-500 和 GSM8K 数据集上的表现。 数值表示均值，误差范围为 95% 自助法置信区间的半宽。最优值以粗体标出。

方法	Big-Math Digits				HotpotQA			
	准确率	AUROC	Brier	ECE	准确率	AUROC	Brier	ECE
基础模型	48.1% ± 3.10	0.56 ± 0.03	0.47 ± 0.03	0.47	39.7% ± 3.10	0.54 ± 0.02	0.53 ± 0.03	0.53
RLVR		0.50 ± 0.03	0.32 ± 0.03	0.30		0.50 ± 0.01	0.55 ± 0.03	0.55
RLVR+BCE 分类器		**0.81 ± 0.04**	0.16 ± 0.02	0.05		0.58 ± 0.03	0.28 ± 0.01	0.20
RLVR+Brier 分类器	68.8% ± 2.90	0.79 ± 0.04	0.17 ± 0.02	0.05	**49.7% ± 3.15**	0.60 ± 0.04	0.30 ± 0.02	0.24
RLVR+探针		0.72 ± 0.04	0.19 ± 0.02	0.07		0.58 ± 0.04	0.28 ± 0.01	0.16
答案概率		0.53 ± 0.04	0.30 ± 0.03	0.30		0.60 ± 0.03	0.47 ± 0.03	0.47
RLCR (**本文**)	68.7% ± 2.75	0.73 ± 0.03	0.18 ± 0.01	0.05	48.3% ± 3.00	0.61 ± 0.04	0.27 ± 0.01	0.18
RLCR+SFT (**本文**)	**70.5% ± 2.70**	0.79 ± 0.04	**0.15 ± 0.02**	**0.03**	41.6% ± 3.15	**0.65 ± 0.04**	**0.24 ± 0.01**	**0.09**

表 15: 在 Big-Math Digits 和 HotpotQA 上的表现。 数值表示均值，误差范围为 95% 自助法置信区间的半宽。最优值以粗体标出。

N SimpleQA 示例的公开版说明

第三方数据集逐字实例及对应输出暂不收录。

O HotpotQA 示例的公开版说明

第三方数据集逐字实例及对应输出暂不收录。

P 数学示例的公开版说明

第三方数据集逐字实例及对应输出暂不收录。