语言模型与推理

自一致性提升语言模型的思维链推理能力

Self-Consistency Improves Chain of Thought Reasoning in Language Models

Xuezhi Wang · Jason Wei · Dale Schuurmans
Quoc Le · Ed H. Chi · Sharan Narang
Aakanksha Chowdhery · Denny Zhou

Google Research, Brain Team
谷歌研究院 Brain 团队

联系邮箱：xuezhiw@google.com；dennyzhou@google.com

中文公开删节版

正文、参考文献与经筛选的附录
ICLR 2023 · arXiv:2203.11171v4
底本更新日期：2023 年 3 月 7 日

译文公开版 1.1 · 2026 年 11 月 10 日
中文翻译与编排：dot · 非官方译文

公开版范围说明

公开版暂不收录图 1 的原数据集实例与逐字中文对照、正文中的数据集实例引文和示例表、附录两张补充逐字示例表及完整提示集。方法、实验数据、统计图、计算资源说明和参考文献保留。被移除实例的第三方材料授权尚未逐项核实；未收录不表示认定其原有引用侵权。

本版本是独立的公开发布版本，不是完整译文。原论文引用及各处图表编号沿用原文；被移除项目保留占位说明，便于核对。原作者未审校或认可本译文。

版本与版权说明

本译文以 arXiv:2203.11171v4 的 ICLR 2023 定稿及其官方 LaTeX 源文件为底本，原完整译本覆盖原文 24 页中的摘要、第 1–5 节、可复现性声明、伦理声明、65 条参考文献及完整附录。本公开版保留的方法正文和表格说明译成中文；逐字数据集示例与完整提示集不在收录范围内。参考文献保留完整英文著录，便于检索和核验。模型名、数据集名、引用键及研究中使用的 API 字符串保留原样。

公式使用 LaTeX 重新排版；实验数据与原图矢量内容保留，不重新估计或生成曲线。AQuA 原图的右边界略作扩展，以显示原先被边界裁切的完整图例。原图的英文坐标和图例保留，并在本页提供中文对照；图 1 的原始实例及逐字对照未在本公开版收录。本公开版保留的原文论述与译者说明用明确译注区分。原文以“+%”表达的准确率绝对提升应理解为百分点。中文重排页码不与原文逐页对应。

原文引用： Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed H. Chi, Sharan Narang, Aakanksha Chowdhery, Denny Zhou. Self-Consistency Improves Chain of Thought Reasoning in Language Models. ICLR 2023. arXiv:2203.11171v4.

原文：https://arxiv.org/abs/2203.11171v4

PDF：https://arxiv.org/pdf/2203.11171v4

源文件：https://arxiv.org/src/2203.11171v4

许可： 原文 arXiv 页面链接至 Creative Commons Attribution 4.0 International（CC BY 4.0），允许在署名、提供许可链接并说明改动的条件下分享和改编。本译文是中文翻译和重新排版，同以 CC BY 4.0 提供。版权归相应权利人所有；原作者及会议并未参与或认可本译文。许可不提供担保。

https://creativecommons.org/licenses/by/4.0/

原图标识中文对照

Accuracy / Accuracy (%) / Test accuracy 准确率／准确率（%）／测试准确率。

Number of reasoning paths / # Reasoning paths 推理路径数。

#Sampled Reasoning Paths / #Sampled Reasoning Chains 采样推理路径数／采样思维链数。

Number of samples / # Samples 样本数。

Self-Consistency / Self-consistency 自一致性。

CoT-prompting / Chain-of-thought / Greedy 思维链提示／思维链／贪心解码。

Greedy Decode (Single-path) 贪心解码（单路径）。

Self Consistency (Multi-path) 自一致性（多路径）。

Sample-and-rank / Sample & Rank (Multi-path) 采样后排序／采样后排序（多路径）。

Model size / Model parameters 模型规模／模型参数量。

Model size (#param in billions) 模型规模（参数量，以十亿为单位）。

Consistency / Consistency (%) 一致性／一致性（%）。

Temperature / Top-k / Nucleus 温度／top-k 采样／核采样。

no top k 不进行 top-k 截断。

ARC (Easy) / ARC (Challenge) ARC（简单）／ARC（挑战）。

目录

公开版范围说明 **1**

版本与版权说明 **2**

摘要 **5**

1 引言 **5**

2 多样化推理路径上的自一致性 **6**

3 实验 **7**

3.1 实验设置 7
3.2 主要结果 8
3.3 当思维链损害表现时自一致性仍有帮助 10
3.4 与其他现有方法比较 10
3.5 补充研究 11

4 相关工作 **13**

5 结论与讨论 **14**

可复现性声明 **14**

伦理声明 **14**

参考文献 **14**

A 附录 **21**

A.1 补充实验结果 21
A.1.1 对采样策略和参数的鲁棒性 21
A.1.2 对不同提示集的鲁棒性 21
A.1.3 与模型集成的比较 22
A.1.4 将自一致性与其他集成策略相结合 23
A.2 计算资源与推断细节 23
A.3 完整提示集的公开版说明 23

摘要

思维链提示与预训练大语言模型相结合，已在复杂推理任务上取得令人鼓舞的结果。本文提出一种新的解码策略，即自一致性（self-consistency），以替代思维链提示中使用的朴素贪心解码。它首先采样一组多样化的推理路径，而不是只采用贪心路径，然后通过对采样得到的推理路径进行边缘化，选出一致性最高的答案。自一致性利用了这样一种直觉：复杂推理问题通常允许通过多种不同思路得到其唯一的正确答案。广泛的实证评估表明，自一致性能显著提升思维链提示在一系列常用算术与常识推理基准上的表现，包括 GSM8K（+17.9%）、SVAMP（+11.0%）、AQuA（+12.2%）、StrategyQA（+6.4%）和 ARC-challenge（+3.9%）。

1 引言

虽然语言模型已在许多自然语言处理（NLP）任务上取得显著成功，但推理能力通常仍被视为它们的一项局限，而且这一局限无法仅靠增大模型规模来克服(Rae et al., 2021; BIG-bench collaboration, 2021, 等)。为解决这一不足，Wei et al. (2022)提出了思维链提示：通过提示让语言模型生成一系列短句，模仿人类解决任务时可能采用的推理过程。〔公开版编注：此处逐字算术示例暂不收录。〕已有研究发现，思维链提示能显著改善模型在多种多步推理任务上的表现(Wei et al., 2022)。

本文引入一种称为自一致性的新解码策略，替代思维链提示中使用的贪心解码(Wei et al., 2022)，进一步大幅提升语言模型的推理表现。自一致性利用了这样一种直觉：复杂推理任务通常存在多条能够得到正确答案的推理路径(Stanovich & West, 2000)。问题越需要审慎思考与分析(Evans, 2010)，能推导出答案的推理路径就越多样。

图 1 用一个例子说明自一致性方法。我们首先对语言模型使用思维链提示；随后，不再以贪心方式解码最优推理路径，而是采用“采样并边缘化”的解码过程：先从语言模型的解码器中采样，生成一组多样化的推理路径。每条路径可能导向不同的最终答案，因此我们对采样得到的推理路径进行边缘化，在最终答案集合中找出一致性最高的答案，从而确定最优答案。这类似于人类的经验：如果多种不同思路都得到同一个答案，我们就会更有信心认为该答案正确。与其他解码方法相比，自一致性避免了困扰贪心解码的重复性和局部最优问题，同时减轻了单次采样生成所带来的随机性。

原图内的数据集实例未在公开版收录。

图 1: 自一致性方法包含三个步骤：（1）使用思维链（CoT）提示来提示语言模型；（2）用从语言模型解码器中采样、生成多样化推理路径的方式，替代 CoT 提示中的“贪心解码”；（3）对推理路径进行边缘化，并选择最终答案集合中一致性最高的答案完成聚合。原图及逐字中文对照未收录；本图号只用于对应原文。

自一致性远比以往方法简单，后者或者需要额外训练验证器(Cobbe et al., 2021)，或者需要借助额外的人工标注训练重排序器，以改善生成质量(Thoppilan et al., 2022)。相比之下，自一致性完全无监督，可直接用于现成的预训练语言模型，无须额外人工标注，也不需要额外训练、辅助模型或微调。它还不同于训练多个模型并聚合各模型输出的典型集成方法，而更像是建立在单个语言模型之上的“自集成”。

我们在广泛的算术与常识推理任务上评估了自一致性，涉及四种不同规模的语言模型：公开的 UL2-20B(Tay et al., 2022) 和 GPT-3-175B(Brown et al., 2020)，以及两个稠密激活、仅含解码器的语言模型 LaMDA-137B(Thoppilan et al., 2022) 和 PaLM-540B(Chowdhery et al., 2022)。在全部四种语言模型上，自一致性都在各项任务中相较思维链提示取得了显著提升。尤其是结合 PaLM-540B 或 GPT-3 时，自一致性在多项算术推理任务上达到新的最先进水平，包括 GSM8K(Cobbe et al., 2021)（准确率绝对提升 17.9 个百分点）、SVAMP(Patel et al., 2021)（+11.0%）、AQuA(Ling et al., 2017)（+12.2%）；在 StrategyQA(Geva et al., 2021)

（+6.4%）和 ARC-challenge(Clark et al., 2018)（+3.9%）等常识推理任务上也是如此。在补充实验中，我们表明：即使在加入思维链反而可能使表现低于标准提示的 NLP 任务上(Ye & Durrett, 2022)，自一致性也能稳健地提升性能。我们还证明，自一致性显著优于采样后排序、束搜索及基于集成的方法，并且对采样策略和不完善提示具有鲁棒性。

2 多样化推理路径上的自一致性

人类的一个显著特点是思考方式各不相同。很自然地可以认为，需要审慎思考的任务通常存在多种解题方式。我们提出，通过对语言模型的解码器进行采样，可以在语言模型中模拟这一过程。例如，如图 1 所示，模型可以对一道数学题生成多个看似合理的回答，它们都得到了相同的正确答案（输出 1 和输出 3）。语言模型并非完美的推理者，因此也可能生成错误的推理路径，或在某个推理步骤上出错（如输出 2）；但这些错误解法较不容易得到相同的答案。换言之，我们假设：正确的推理过程即使彼此不同，其最终答案的一致程度通常也高于错误的推理过程。

基于这一直觉，我们提出如下自一致性方法。首先，用一组人工编写的思维链示例提示语言模型(Wei et al., 2022)。接着，从语言模型的解码器中采样一组候选输出，从而生成多样化的候选推理路径。自一致性兼容大多数现有采样算法，包括温度采样(Ackley et al., 1985; Ficler & Goldberg, 2017)、top-k 采样(Fan et al., 2018; Holtzman et al., 2018; Radford et al., 2019) 和核采样(Holtzman et al., 2020)。最后，对采样得到的推理路径进行边缘化，并选择生成答案中一致性最高的答案，以完成答案聚合。

更具体地，假设生成的答案 $\mathbf{a}_i$ 来自一个固定答案集合，即 $\mathbf{a}_i \in \mathbb{A}$，其中 $i = 1, \ldots, m$ 对从解码器采样得到的 m 个候选输出编号。给定提示和问题，自一致性引入额外的潜变量 $\mathbf{r}_i$，它是一串词元，表示第 i 个输出中的推理路径；然后耦合生成 $(\mathbf{r}_i, \mathbf{a}_i)$，其中 $\mathbf{r}_i \to \mathbf{a}_i$，也就是说，生成推理路径 $\mathbf{r}_i$ 是可选的，其目的只是得到最终答案 $\mathbf{a}_i$。〔公开版编注：此处针对图 1 数据集实例的逐字引用暂不收录。〕[1]

从模型解码器中采样多个 $(\mathbf{r}_i, \mathbf{a}_i)$ 后，自一致性通过对 $\mathbf{a}_i$ 进行多数投票来实现对 $\mathbf{r}_i$ 的边缘化，即

$$\arg\max_a \sum_{i=1}^{m} \mathbf{1}(\mathbf{a}_i = a),$$

也就是我们所定义的最终答案集合中“最一致”的答案。[2]

表 1 展示了不同答案聚合策略在一组推理任务上的测试准确率。除多数投票外，聚合答案时也可以用 $P(\mathbf{r}_i, \mathbf{a}_i \mid \text{prompt}, \text{question})$ 为每个 $(\mathbf{r}_i, \mathbf{a}_i)$ 加权。计算这个概率时，可以直接使用模型在给定 $(\text{prompt}, \text{question})$ 的条件下生成 $(\mathbf{r}_i, \mathbf{a}_i)$ 的未归一化概率，也可以按输出长度对条件概率进行归一化(Brown et al., 2020)，即

$$\begin{aligned} &P(\mathbf{r}_i, \mathbf{a}_i \mid \text{prompt}, \text{question}) \\ &\quad = \exp\left[\frac{1}{K}\sum_{k=1}^{K} \log P(t_k \mid \text{prompt}, \text{question}, t_1, \ldots, t_{k-1})\right], \end{aligned} \tag{1}$$

其中 $\log P(t_k \mid \text{prompt}, \text{question}, t_1, \ldots, t_{k-1})$ 是在给定之前各词元的条件下，生成 $(\mathbf{r}_i, \mathbf{a}_i)$ 中第 k 个词元 t_k 的对数概率，K 是 $(\mathbf{r}_i, \mathbf{a}_i)$ 的词元总数。表 1 表明，“不加权求和”，即直接对 $\mathbf{a}_i$ 进行多数投票，所得准确率与“归一化加权求和”非常接近。进一步检查模型的输出概率后，我们发现其原因是：各个 $(\mathbf{r}_i, \mathbf{a}_i)$ 的归一化条件概率 $P(\mathbf{r}_i, \mathbf{a}_i \mid \text{prompt}, \text{question})$ 彼此十分接近，也就是

[1]解析器依任务而定。对于算术推理，我们在模型生成“The answer is ”之后，将第一个数值部分解析为最终答案；对于常识推理，则将之后的完整答案字符串解析为最终答案。如果使用这种格式提示语言模型，大多数生成输出都会采用一致的“{推理路径}. The answer is X.”格式。

[2]译注：这里的 majority vote 实际指选择得票最多的答案，即相对多数投票，并不要求得票超过全部样本的一半。

	GSM8K	MultiArith	AQuA	SVAMP	CSQA	ARC-c
贪心解码	56.5	94.7	35.8	79.0	79.0	85.2
加权平均（未归一化）	56.3 ± 0.0	90.5 ± 0.0	35.8 ± 0.0	73.0 ± 0.0	74.8 ± 0.0	82.3 ± 0.0
加权平均（归一化）	22.1 ± 0.0	59.7 ± 0.0	15.7 ± 0.0	40.5 ± 0.0	52.1 ± 0.0	51.7 ± 0.0
加权求和（未归一化）	59.9 ± 0.0	92.2 ± 0.0	38.2 ± 0.0	76.2 ± 0.0	76.2 ± 0.0	83.5 ± 0.0
加权求和（归一化）	74.1 ± 0.0	99.3 ± 0.0	48.0 ± 0.0	86.8 ± 0.0	80.7 ± 0.0	88.7 ± 0.0
不加权求和（多数投票）	74.4 ± 0.1	99.3 ± 0.0	48.3 ± 0.5	86.6 ± 0.1	80.7 ± 0.1	88.7 ± 0.1

表 1: PaLM-540B 上不同答案聚合策略的准确率比较。

说，语言模型认为这些生成结果“同样可能”。[3] 此外，表 1 还显示，聚合答案时，“归一化”加权求和（即式 (1)）的准确率显著高于未归一化的对应方法。为完整起见，表 1 中还报告了“加权平均”的结果：每个 a 的分数等于其加权和除以 $\sum_{i=1}^{m} \mathbf{1}(\mathbf{a}_i = a)$，但这种方法的表现要差得多。

自一致性探索了开放式文本生成与具有固定答案的最优文本生成之间一片有趣的空间。推理任务通常具有固定答案，因此研究者一般考虑使用贪心解码(Radford et al., 2019; Wei et al., 2022; Chowdhery et al., 2022)。然而，我们发现：即使所需答案是固定的，在推理过程中引入多样性仍然大有裨益。因此，我们采用开放式文本生成中常用的采样方法(Radford et al., 2019; Brown et al., 2020; Thoppilan et al., 2022)来实现这一目标。需要注意，自一致性只适用于最终答案来自固定答案集合的问题；不过原则上，如果能为多个生成结果定义良好的一致性度量，例如两个答案是相互一致还是相互矛盾，就可以将这一方法扩展到开放式文本生成问题。

3 实验

我们开展了一系列实验，在多种推理基准上比较所提出的自一致性方法与现有方法。结果表明，在所考察的所有语言模型上，自一致性都能稳健地提升推理准确率，覆盖了广泛的模型规模。

3.1 实验设置

任务与数据集。 我们在以下推理基准上评估自一致性。[4]

- **算术推理。** 使用数学应用题资源库(Koncel-Kedziorski et al., 2016)，包括 AddSub(Hosseini et al., 2014)、MultiArith(Roy & Roth, 2015) 和 ASDiv(Miao et al., 2020)。我们还纳入 AQUA-RAT(Ling et al., 2017)、当时新发布的小学数学题基准 GSM8K(Cobbe et al., 2021)，以及数学应用题挑战数据集 SVAMP(Patel et al., 2021)。
- **常识推理。** 使用 CommonsenseQA(Talmor et al., 2019)、StrategyQA(Geva et al., 2021) 和 AI2 推理挑战（ARC）(Clark et al., 2018)。
- **符号推理。** 评估Wei et al. (2022)中的两个符号推理任务：末字母拼接（例如输入“Elon Musk”，输出应为“nk”），以及抛硬币（例如硬币开始正面朝上，翻转几次后是否仍然正面朝上）。

语言模型与提示。 我们评估了四种不同规模、基于 Transformer 的语言模型：

[3]这也意味着语言模型的校准并不好，无法很好地区分正确解法和错误解法；这也解释了为什么已有工作需要额外训练重排序器，以更好地判断解法质量(Cobbe et al., 2021; Thoppilan et al., 2022)。

[4]默认情况下，只要评估标签可用，我们都使用数据集的测试集。CommonsenseQA 使用开发集；StrategyQA 使用BIG-bench collaboration (2021)的仅问题集合：https://github.com/google/BIG-bench/tree/main/bigbench/benchmark_tasks/strategyqa。

- UL2(Tay et al., 2022) 是一个具有 200 亿参数的编码器–解码器模型，采用混合去噪器目标训练。UL2 完全开源[5]，在零样本 SuperGLUE 上与 GPT-3 表现相当或更好，却只有 20B 参数，因此计算成本更友好。
- GPT-3(Brown et al., 2020) 具有 1750 亿参数。为便于复现，我们使用 Codex 系列(Chen et al., 2021)中的两个公开引擎 code-davinci-001 和 code-davinci-002。[6]
- LaMDA-137B(Thoppilan et al., 2022) 是一个具有 1370 亿参数、从左到右生成的稠密仅解码器语言模型，在网页文档、对话数据和维基百科的混合数据上预训练。
- PaLM-540B(Chowdhery et al., 2022) 是一个具有 5400 亿参数、从左到右生成的稠密仅解码器语言模型，在包含 7800 亿词元的高质量语料库上预训练，语料涵盖筛选后的网页、书籍、维基百科、新闻文章、源代码和社交媒体对话。

所有实验均采用少样本设置，不训练或微调语言模型。为公平比较，我们使用与Wei et al. (2022)相同的提示：所有算术推理任务都使用同一组 8 个人工编写的示例；每项常识推理任务从训练集中随机选取 4–7 个示例，再人工编写思维链提示。[7]提示的完整细节见附录 A.3。

采样方案。 为采样多样化推理路径，我们采用与Radford et al. (2019); Holtzman et al. (2020)针对开放式文本生成所建议方案相近的设置。具体而言，UL2-20B 和 LaMDA-137B 使用温度 $T = 0.5$，并截断为概率最高的 top-k 个词元（$k = 40$）；PaLM-540B 使用 $T = 0.7, k = 40$；GPT-3 使用 $T = 0.7$，不进行 top-k 截断。第 3.5 节的消融研究表明，自一致性总体上对采样策略和参数具有鲁棒性。

3.2 主要结果

我们报告自一致性在 10 次运行上的平均结果，每次运行均从解码器独立采样 40 个输出。比较基线是采用贪心解码的思维链提示(Wei et al., 2022)，简称 **CoT 提示**；这一策略此前已用于大语言模型的解码(Chowdhery et al., 2022)。

算术推理。 结果见表 2。[8] 相比思维链提示，自一致性显著提升了**全部四种语言模型**的算术推理表现。更出人意料的是，语言模型规模越大，收益越显著：例如，UL2-20B 的准确率绝对提升约为 3–6 个百分点，而 LaMDA-137B 和 GPT-3 则为 9–23 个百分点。

对于已在多数任务上取得高准确率的大模型（如 GPT-3 和 PaLM-540B），自一致性依然带来显著额外收益：AQuA 和 GSM8K 等任务的准确率绝对提升 12–18 个百分点，SVAMP 和 ASDiv 则提升 7–11 个百分点。借助自一致性，我们在几乎所有任务上取得了新的最先进结果。尽管自一致性无监督、且与具体任务无关，这些结果仍优于需要任务专属训练、或需要用数千个示例进行微调的已有方法（如 GSM8K 上的方法）。

译注： 表 2、表 3 的所有数值均按原文保留。其中，表 2 的 GPT-3 code-davinci-002 在 ASDiv 上由 80.1 升至 87.8，原表却将提升写为 +7.6；表 3 的 UL2-20B 在 ARC-c 上由 42.9 升至 49.5，原表将提升写为 +6.8。这两处原表括号内提升值与所列准确率的直接差分不一致。

[5]模型检查点：https://github.com/google-research/google-research/tree/master/ul2。
[6]公开 API：https://openai.com/api/。
[7]自一致性对不同提示集合具有鲁棒性，相关研究见附录 A.1.2。
[8]所有任务上自一致性的标准差均不超过 0.5，因此表中省略。不同采样路径数下的标准差见图 2、图 7 和图 8。

	方法	AddSub	MultiArith	ASDiv	AQuA	SVAMP	GSM8K
	此前最佳	**94.9**[a]	60.5[a]	75.3[b]	37.9[c]	57.4[d]	35[e] / 55[g]
UL2-20B	CoT 提示	18.2	10.7	16.9	23.6	12.6	4.1
	自一致性	24.8 (+6.6)	15.0 (+4.3)	21.5 (+4.6)	26.9 (+3.3)	19.4 (+6.8)	7.3 (+3.2)
LaMDA-137B	CoT 提示	52.9	51.8	49.0	17.7	38.9	17.1
	自一致性	63.5 (+10.6)	75.7 (+23.9)	58.2 (+9.2)	26.8 (+9.1)	53.3 (+14.4)	27.7 (+10.6)
PaLM-540B	CoT 提示	91.9	94.7	74.0	35.8	79.0	56.5
	自一致性	93.7 (+1.8)	99.3 (+4.6)	81.9 (+7.9)	48.3 (+12.5)	86.6 (+7.6)	74.4 (+17.9)
GPT-3 Code-davinci-001	CoT 提示	57.2	59.5	52.7	18.9	39.8	14.6
	自一致性	67.8 (+10.6)	82.7 (+23.2)	61.9 (+9.2)	25.6 (+6.7)	54.5 (+14.7)	23.4 (+8.8)
GPT-3 Code-davinci-002	CoT 提示	89.4	96.2	80.1	39.8	75.8	60.1
	自一致性	91.6 (+2.2)	**100.0** (+3.8)	**87.8** (+7.6)	**52.0** (+12.2)	**86.8** (+11.0)	**78.0** (+17.9)

表 2: 自一致性与思维链提示(Wei et al., 2022)的算术推理准确率比较。此前最佳基线来源：a：相关性与 LCA 运算分类器(Roy & Roth, 2015)；b：Lan et al. (2021)；c：Amini et al. (2019)；d：Pi et al. (2022)；e：使用 7500 个示例微调的 GPT-3 175B(Cobbe et al., 2021)；g：微调后的 GPT-3 175B 加一个额外的 175B 验证器(Cobbe et al., 2021)。各任务最佳结果以粗体标出。

	方法	CSQA	StrategyQA	ARC-e	ARC-c	字母（4）	翻转（4）
	此前最佳	**91.2**[a]	73.9[b]	86.4[c]	75.0[c]	不适用	不适用
UL2-20B	CoT 提示	51.4	53.3	61.6	42.9	0.0	50.4
	自一致性	55.7 (+4.3)	54.9 (+1.6)	69.8 (+8.2)	49.5 (+6.8)	0.0 (+0.0)	50.5 (+0.1)
LaMDA-137B	CoT 提示	57.9	65.4	75.3	55.1	8.2	72.4
	自一致性	63.1 (+5.2)	67.8 (+2.4)	79.3 (+4.0)	59.8 (+4.7)	8.2 (+0.0)	73.5 (+1.1)
PaLM-540B	CoT 提示	79.0	75.3	95.3	85.2	65.8	88.2
	自一致性	80.7 (+1.7)	**81.6** (+6.3)	**96.4** (+1.1)	**88.7** (+3.5)	70.8 (+5.0)	91.2 (+3.0)
GPT-3 Code-davinci-001	CoT 提示	46.6	56.7	63.1	43.1	7.8	71.4
	自一致性	54.9 (+8.3)	61.7 (+5.0)	72.1 (+9.0)	53.7 (+10.6)	10.0 (+2.2)	75.9 (+4.5)
GPT-3 Code-davinci-002	CoT 提示	79.0	73.4	94.0	83.6	70.4	99.0
	自一致性	81.5 (+2.5)	79.8 (+6.4)	96.0 (+2.0)	87.5 (+3.9)	**73.4** (+3.0)	**99.5** (+0.5)

表 3: 自一致性与思维链提示(Wei et al., 2022)的常识及符号推理准确率比较。此前最佳基线来源：a：DeBERTaV3-large + KEAR(Xu et al., 2021b)；b：Chowdhery et al. (2022)；c：UnifiedQA-FT(Khashabi et al., 2020)。各任务最佳结果以粗体标出。

常识与符号推理。 表 3 给出了常识与符号推理任务的结果。类似地，自一致性在全部四种语言模型上都带来了明显收益，并在 6 项任务中的 5 项上达到了最先进水平。对于符号推理，我们考察分布外（OOD）设置：输入提示包含 2 个字母或 2 次翻转的示例，测试时则使用 4 个字母或 4 次翻转的示例（这一设置更具挑战，因为 PaLM-540B 或 GPT-3 已能在分布内任务上达到完美准确率）。在这一具有挑战性的 OOD 设置下，只要模型规模足够大，自一致性相对 CoT 提示的收益仍十分显著。

为展示采样推理路径数的影响，我们在图 2 中绘制了不同采样路径数（1、5、10、20、40）对应的准确率，即 10 次运行的均值和标准差。结果表明，采样更多推理路径（例如 40 条）能持续带来更好表现，进一步说明引入推理路径多样性的重要性。表 4 用来自两项任务的几个示例问题说明，自一致性能比贪心解码产生更丰富的推理路径。

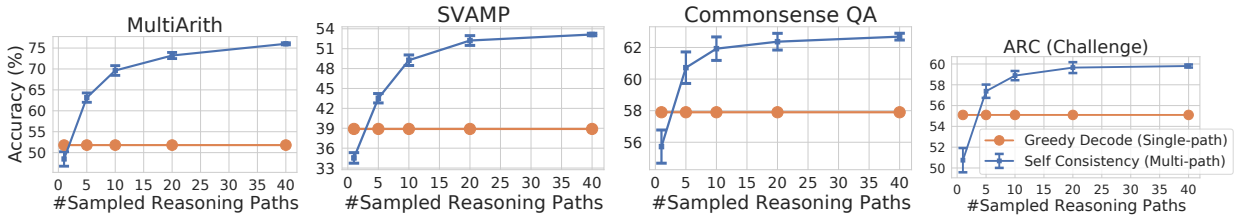


图 2: 在 LaMDA-137B 上，自一致性（蓝色）在算术与常识推理任务中的准确率均显著高于使用贪心解码的 CoT 提示（橙色）。采样更多多样化推理路径能持续提高推理准确率。

	ANLI R1 / R2 / R3	e-SNLI	RTE	BoolQ	HotpotQA (EM/F1)
标准提示（无推理说明）	69.1 / 55.8 / 55.8	85.8	84.8	71.3	27.1 / 36.8
CoT 提示 (Wei et al., 2022)	68.8 / 58.9 / 60.6	81.0	79.1	74.2	28.9 / 39.8
自一致性	**78.5 / 64.5 / 63.4**	**88.4**	**86.3**	**78.4**	**33.8 / 44.6**

表 5: 常见 NLP 任务中标准提示、CoT 提示与自一致性的比较。

原文数据集实例与逐字模型回复未收录。

表 4: 公开版未收录的原文实例或界面。

3.3 当思维链损害表现时自一致性仍有帮助

Ye & Durrett (2022)表明，在少样本上下文学习中，思维链提示有时会比标准提示表现更差。这里，我们在一组常见 NLP 任务上研究自一致性能否弥补这一差距，包括：（1）闭卷问答：BoolQ(Clark et al., 2019)、HotpotQA(Yang et al., 2018)；（2）自然语言推断：e-SNLI(Camburu et al., 2018)、ANLI(Nie et al., 2020) 和 RTE(Dagan et al., 2005; Bar-Haim et al., 2006; Giampiccolo et al., 2007; Bentivogli et al., 2009)。

PaLM-540B 上的结果见表 5。在某些任务上（如 ANLI-R1、e-SNLI 和 RTE），加入思维链确实会使表现低于标准提示(Brown et al., 2020)；但自一致性能够稳健地提升表现，并超过标准提示。因此，对于常见 NLP 任务，它是在少样本上下文学习中加入推理说明的一种可靠方式。

3.4 与其他现有方法比较

我们还开展了一组补充研究，表明自一致性显著优于采样后排序、束搜索和基于集成的现有方法。

与采样后排序比较。 采样后排序是一种常用的生成质量改善方法：从解码器采样多个序列，再根据各序列的对数概率排序(Adiwardana et al., 2020)。我们在 GPT-3 code-davinci-001 上比较自一致性与采样后排序：后者从解码器采样与自一致性相同数量的序列，并采用排名第一的序列中的最终答案。结果见图 3。虽然额外采样序列并排序确实能提高准确率，但其收益远小于自一致性。

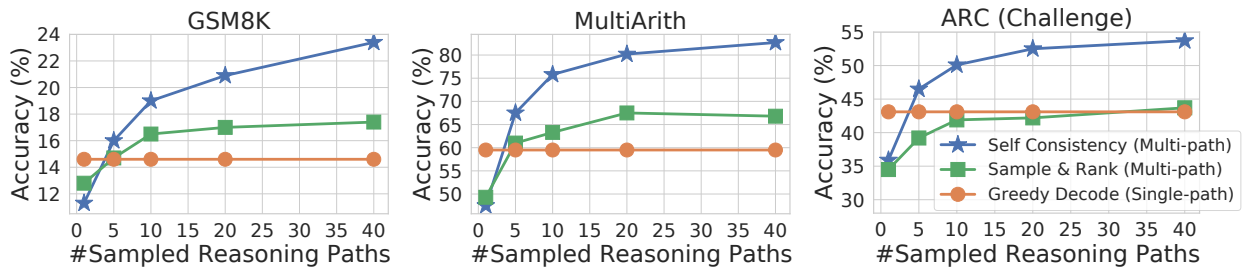


图 3: 在相同样本数量下，自一致性显著优于采样后排序。

	束宽／自一致性路径数	1	5	10	20	40
AQuA	束搜索解码（最优束）	23.6	19.3	16.1	15.0	10.2
	使用束搜索的自一致性	23.6	19.8 ± 0.3	21.2 ± 0.7	24.6 ± 0.4	24.2 ± 0.5
	使用采样的自一致性	19.7 ± 2.5	**24.9 ± 2.6**	**25.3 ± 1.8**	**26.7 ± 1.0**	**26.9 ± 0.5**
MultiArith	束搜索解码（最优束）	10.7	12.0	11.3	11.0	10.5
	使用束搜索的自一致性	10.7	11.8 ± 0.0	11.4 ± 0.1	12.3 ± 0.1	10.8 ± 0.1
	使用采样的自一致性	9.5 ± 1.2	11.3 ± 1.2	**12.3 ± 0.8**	**13.7 ± 0.9**	**14.7 ± 0.3**

表 6: UL2-20B 上自一致性与束搜索解码的比较。

	GSM8K	MultiArith	SVAMP	ARC-e	ARC-c
CoT (Wei et al., 2022)	17.1	51.8	38.9	75.3	55.1
集成（3 组提示）	18.6 ± 0.5	57.1 ± 0.7	42.1 ± 0.6	76.6 ± 0.1	57.0 ± 0.2
集成（40 次提示置换）	19.2 ± 0.1	60.9 ± 0.2	42.7 ± 0.1	76.9 ± 0.1	57.0 ± 0.1
自一致性（40 条采样路径）	**27.7 ± 0.2**	**75.7 ± 0.3**	**53.3 ± 0.2**	**79.3 ± 0.3**	**59.8 ± 0.2**

表 7: 在 LaMDA-137B 上，自一致性优于提示顺序集成和多组提示集成。

与束搜索比较。 表 6 在 UL2-20B 模型上比较了自一致性与束搜索解码。为公平比较，我们报告相同束宽和推理路径数下的准确率。两项任务上，自一致性均显著优于束搜索。需要注意，自一致性也可以使用束搜索解码每条推理路径（表中“使用束搜索的自一致性”），但其表现不如采用采样的自一致性。原因在于束搜索输出的多样性较低(Li & Jurafsky, 2016)，而推理路径的多样性正是自一致性取得更好表现的关键。

与基于集成的方法比较。 我们进一步将自一致性与用于少样本学习的集成方法比较。具体考察两种集成方式：（1）提示顺序置换：将提示中的示例随机重排 40 次，以减轻模型对提示顺序的敏感性(Zhao et al., 2021; Lu et al., 2021)；（2）多组提示(Gao et al., 2021)：人工编写 3 组不同提示。两种方法都对贪心解码得到的答案进行多数投票，形成集成结果。

表 7 表明，与自一致性相比，现有集成方法的收益要小得多。[9] 还应注意，自一致性不同于训练多个模型并聚合其输出的典型模型集成方法；它更像是建立在单个语言模型之上的“自集成”。附录 A.1.3 还报告了多个模型的集成结果，其表现明显不如自一致性。

3.5 补充研究

我们开展了一系列补充实验，分析自一致性方法的不同方面，包括它对采样策略和参数的鲁棒性，以及面对不完善提示与非自然语言推理路径时的表现。

自一致性对采样策略和模型规模具有鲁棒性。 在 PaLM-540B 上，我们改变温度采样中的 T(Ackley et al., 1985; Ficler & Goldberg, 2017)、top-k 采样中的 k(Fan et al., 2018; Holtzman et al., 2018; Radford et al., 2019) 和核采样中的 p(Holtzman et al., 2020)，表明自一致性对采样策略及参数具有鲁棒性，见图 4（左）。图 4（右）表明，自一致性能稳健地改善 LaMDA-137B 模型系列各个规模的表现。较小模型的收益相对有限，因为某些能力（如算术）只有当模型达到足够规模时才会涌现(Brown et al., 2020)。

[9] 自一致性与两种集成方法都兼容，相关结果见附录 A.1.4。

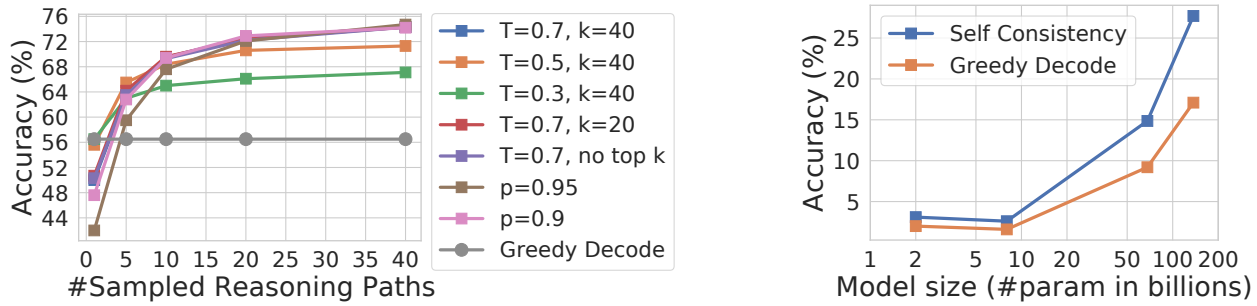


图 4: GSM8K 准确率。左：自一致性对多种采样策略和参数具有鲁棒性。右：自一致性在不同语言模型规模上都能提升性能。

LaMDA-137B	正确思维链提示	17.1
	不完善思维链提示	14.9
	+ 自一致性（40 条路径）	**23.4**
	等式提示	5.0
	+ 自一致性（40 条路径）	**6.5**
PaLM-540B	零样本 CoT (Kojima et al., 2022)	43.0
	+ 自一致性（40 条路径）	**69.2**

表 8: 在 GSM8K 上，自一致性适用于不完善提示、等式提示和零样本思维链。

自一致性提高对不完善提示的鲁棒性。 在使用人工构造提示的少样本学习中，标注者编写提示时偶尔会出现小错误。我们进一步研究自一致性能否提高语言模型对不完善提示的鲁棒性。[10] 结果见表 8：虽然不完善提示降低了贪心解码的准确率（17.1 → 14.9），自一致性却能弥补这一差距，稳健地改善结果。

此外，我们发现，一致性（以赞同最终聚合答案的解码结果占比衡量）与准确率高度相关，图 5 给出了 GSM8K 上的结果。这表明，自一致性可用于为模型生成的解法提供不确定性估计。换言之，可以把低一致性视为模型置信度低的信号；也就是说，自一致性赋予模型一定程度的“知道自己何时不知道”的能力。

[10] 我们使用与之前相同的提示，但保留最终答案不变，将推理路径中的所有数字替换为随机数字。例如，把“停车场里原来有 3 辆车。又来了 2 辆车。现在有 $3+2=5$ 辆车。”改为“停车场里原来有 7 辆车。又来了 6 辆车。现在有 $7+6=5$ 辆车。”

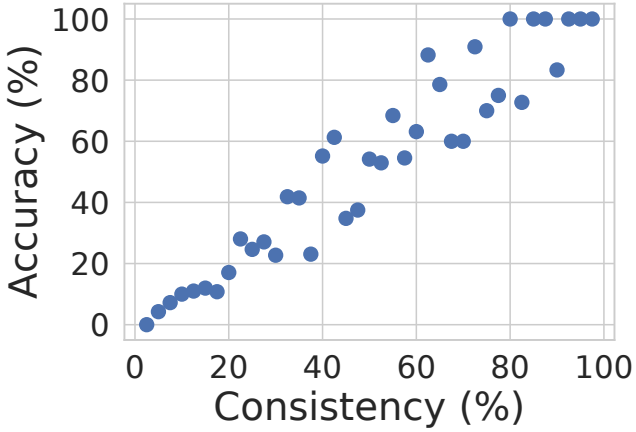


图 5: 一致性与模型的准确率相关。

自一致性适用于非自然语言推理路径和零样本 CoT。 我们还考察了自一致性概念对其他中间推理形式（如等式）的通用性。例如，把“停车场里原来有 3 辆车。又来了 2 辆车。现在有 $3+2=5$ 辆车。”换成“$3+2=5$”。表 8 的“等式提示”一行给出了结果：在生成中间等式时，自一致性仍能提高准确率；但相较生成自然语言推理路径，收益更小，因为等式短得多，解码过程中产生多样性的机会也较少。

此外，我们还测试了自一致性与零样本思维链(Kojima et al., 2022)的结合。表 8 表明，自一致性同样适用于零样本 CoT，并显著改善结果（+26.2%）。

4 相关工作

语言模型中的推理。 众所周知，语言模型难以应对第二类（Type 2）任务，例如算术、逻辑和常识推理(Evans, 2010)。已有工作主要关注改善推理的专门化方法(Andor et al., 2019; Ran et al., 2019; Geva et al., 2020; Piękos et al., 2021)。与已有工作相比，自一致性无须额外监督或微调，便能适用于广泛的推理任务，同时仍能大幅提升Wei et al. (2022)所提出思维链提示方法的表现。

语言模型中的采样与重排序。 文献中已提出多种语言模型解码策略，如温度采样(Ackley et al., 1985; Ficler & Goldberg, 2017)、top-k 采样(Fan et al., 2018; Holtzman et al., 2018; Radford et al., 2019)、核采样(Holtzman et al., 2020)、最小贝叶斯风险解码(Eikema & Aziz, 2020; Shi et al., 2022) 和典型解码(Meister et al., 2022)。另一些工作则尝试在解码过程中显式促进多样性(Batra et al., 2012; Li et al., 2016; Vijayakumar et al., 2018)。

重排序是另一种改善语言模型生成质量的常用方法(Adiwardana et al., 2020; Shen et al., 2021)。Thoppilan et al. (2022)收集额外人工标注，训练重排序器来筛选回答。Cobbe et al. (2021)训练“验证器”对生成解法重新排序，相较仅微调语言模型，显著提高了数学任务的解题率。Elazar et al. (2021)在预训练中加入额外的一致性损失，改善事实知识提取的一致性。所有这些方法或者需要训练额外重排序器，或者需要收集额外人工标注；自一致性则无须额外训练、微调或数据收集。

提取推理路径。 一些已有工作考虑了针对特定任务识别推理路径的方法，例如构建语义图(Xu et al., 2021a)、学习循环神经网络（RNN）来检索维基百科图中的推理路径(Asai et al., 2020)、利用数学题的人工标注推理路径微调模型(Cobbe et al., 2021)，或使用基于启发式的伪推理路径来训练提取器(Chen et al., 2019)。较近的工作开始关注推理过程多样性的重要性，但仍只通过任务专属训练来利用它：或者在提取出的推理路径之上添加额外问答模型(Chen et al., 2019)，或者向常识知识图谱中引入潜变量(Yu et al., 2022)。相比这些方法，自一致性简单得多，也无须额外训练。我们的方法仅通过从解码器采样来耦合推理路径和最终答案的生成，再通过聚合找出一致性最高的答案，不需要额外模块。

语言模型中的一致性。 已有研究表明，语言模型在对话(Adiwardana et al., 2020)、解释生成(Camburu et al., 2020) 和事实知识提取(Elazar et al., 2021) 中可能存在不一致。Welleck et al. (2020)使用“一致性”一词来讨论循环语言模型中无限长度序列的生成。Nye et al. (2021)通过添加受系统 2 启发的逻辑推理模块，改善系统 1 模型所生成样本的逻辑一致性。本文关注的“一致性”概念略有不同，即利用不同推理路径间的答案一致性来提高准确率。

5 结论与讨论

我们提出了一种简单而有效的方法，称为自一致性。实验表明，在四种不同规模的大语言模型上，它都能显著提高一系列算术与常识推理任务的准确率。除了提升准确率，自一致性还可用于在语言模型执行推理任务时收集推理说明、提供不确定性估计，并改善语言模型输出的校准。

自一致性的一个局限是增加了计算成本。实际应用中，可以先尝试较少的路径数（如 5 条或 10 条），在不增加过多成本的情况下获得大部分收益，因为多数情况下性能会很快趋于饱和（图 2）。未来工作可以使用自一致性生成更好的监督数据来微调模型，使模型在微调后只需一次推断就能给出更准确的预测。此外，我们发现语言模型有时会生成错误或不合逻辑的推理路径，例如表 4 的 StrategyQA 示例中，两个人口数字并不完全准确；因此，还需要进一步研究如何让模型生成的推理说明具有更可靠的事实依据。

可复现性声明

实验纳入了四种不同规模的语言模型。其中两个是公开模型：UL2 完全开源，其模型检查点见 https://github.com/google-research/google-research/tree/master/ul2；GPT-3 也是公开模型，公开 API 见 https://openai.com/api/。对于 GPT-3，我们纳入了两个公开引擎（“code-davinci-001”和“code-davinci-002”），进一步便利复现，因为 Codex 当时免费，任何人都可以复现结果。[11] 此外，由于结果还使用了未公开的 LaMDA-137B 和 PaLM-540B，我们在附录 A.3 中给出所有任务的确切输入提示；同时强调，我们没有进行任何微调，只对现成的语言模型使用提示。

伦理声明

正如讨论部分所述，语言模型有时会生成无意义或不符合事实的推理路径，因此使用其输出时应格外谨慎。我们主要处理推理任务，生成的推理说明仅用于考察模型如何得到答案。也可以进一步利用这些推理说明，检查模型为何犯下某些错误，或判断模型在执行特定任务时是否存在偏见。对于语言模型的现实应用，还需要进一步研究，让模型预测具有更充分依据，并提高事实准确性与安全性，以确保模型不会对用户造成伤害。

参考文献

David H. Ackley, Geoffrey E. Hinton, and Terrence J. Sejnowski. A learning algorithm for boltzmann machines. Cognitive Science, 9(1):147–169, 1985. ISSN 0364-0213. URL https://www.sciencedirect.com/science/article/pii/S0364021385800124.

Daniel Adiwardana, Minh-Thang Luong, David R. So, Jamie Hall, Noah Fiedel, Romal Thoppilan, Zi Yang, Apoorv Kulshreshtha, Gaurav Nemade, Yifeng Lu, and Quoc V. Le. Towards a human-like open-domain chatbot, 2020.

Aida Amini, Saadia Gabriel, Shanchuan Lin, Rik Koncel-Kedziorski, Yejin Choi, and Hannaneh Hajishirzi. MathQA: Towards interpretable math word problem solving with operation-based formalisms. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), pp. 2357–2367. Association for Computational Linguistics, June 2019. URL https://aclanthology.org/N19-1245.

[11] 译注：本段描述论文发表时的模型与 API 状态，不代表译文制作时这些引擎仍可用或仍然免费。

Daniel Andor, Luheng He, Kenton Lee, and Emily Pitler. Giving BERT a calculator: Finding operations and arguments with reading comprehension. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), 2019. URL https://aclanthology.org/D19-1609.

Akari Asai, Kazuma Hashimoto, Hannaneh Hajishirzi, Richard Socher, and Caiming Xiong. Learning to retrieve reasoning paths over wikipedia graph for question answering. In International Conference on Learning Representations, 2020. URL https://openreview.net/forum?id=SJgVHkrYDH.

Roy Bar-Haim, Ido Dagan, Bill Dolan, Lisa Ferro, Danilo Giampiccolo, Bernardo Magnini, and Idan Szpektor. The second pascal recognising textual entailment challenge. In Proceedings of the second PASCAL challenges workshop on recognising textual entailment, 2006.

Dhruv Batra, Payman Yadollahpour, Abner Guzman-Rivera, and Gregory Shakhnarovich. Diverse m-best solutions in markov random fields. In Proceedings of the 12th European Conference on Computer Vision - Volume Part V, ECCV'12, pp. 1–16, Berlin, Heidelberg, 2012. Springer-Verlag. ISBN 9783642337147. URL https://doi.org/10.1007/978-3-642-33715-4_1.

Luisa Bentivogli, Peter Clark, Ido Dagan, and Danilo Giampiccolo. The fifth pascal recognizing textual entailment challenge. In TAC, 2009.

BIG-bench collaboration. Beyond the imitation game: Measuring and extrapolating the capabilities of language models. In preparation, 2021. URL https://github.com/google/BIG-bench/.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. In Advances in Neural Information Processing Systems, 2020. URL https://proceedings.neurips.cc/paper/2020/file/1457c0d6bfcb4967418bfb8ac142f64a-Paper.pdf.

Oana-Maria Camburu, Tim Rocktäschel, Thomas Lukasiewicz, and Phil Blunsom. e-snli: Natural language inference with natural language explanations. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett (eds.), Advances in Neural Information Processing Systems 31, pp. 9539–9549. Curran Associates, Inc., 2018. URL http://papers.nips.cc/paper/8163-e-snli-natural-language-inference-with-natural-language-explanations.pdf.

Oana-Maria Camburu, Brendan Shillingford, Pasquale Minervini, Thomas Lukasiewicz, and Phil Blunsom. Make up your mind! adversarial generation of inconsistent natural language explanations. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pp. 4157–4165, Online, July 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.382. URL https://aclanthology.org/2020.acl-main.382.

Jifan Chen, Shih-Ting Lin, and Greg Durrett. Multi-hop question answering via reasoning chains. CoRR, abs/1910.02610, 2019. URL http://arxiv.org/abs/1910.02610.

Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. arXiv preprint arXiv:2107.03374, 2021.

Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, Parker Schuh, Kensen Shi, Sasha Tsvyashchenko, Joshua Maynez, Abhishek Rao, Parker Barnes, Yi Tay, Noam

Shazeer, Vinodkumar Prabhakaran, Emily Reif, Nan Du, Ben Hutchinson, Reiner Pope, James Bradbury, Jacob Austin, Michael Isard, Guy Gur-Ari, Pengcheng Yin, Toju Duke, Anselm Levskaya, Sanjay Ghemawat, Sunipa Dev, Henryk Michalewski, Xavier Garcia, Vedant Misra, Kevin Robinson, Liam Fedus, Denny Zhou, Daphne Ippolito, David Luan, Hyeontaek Lim, Barret Zoph, Alexander Spiridonov, Ryan Sepassi, David Dohan, Shivani Agrawal, Mark Omernick, Andrew M. Dai, Thanumalayan Sankaranarayana Pillai, Marie Pellat, Aitor Lewkowycz, Erica Moreira, Rewon Child, Oleksandr Polozov, Katherine Lee, Zongwei Zhou, Xuezhi Wang, Brennan Saeta, Mark Diaz, Orhan Firat, Michele Catasta, Jason Wei, Kathy Meier-Hellstern, Douglas Eck, Jeff Dean, Slav Petrov, and Noah Fiedel. Palm: Scaling language modeling with pathways, 2022. URL https://arxiv.org/abs/2204.02311.

Christopher Clark, Kenton Lee, Ming-Wei Chang, Tom Kwiatkowski, Michael Collins, and Kristina Toutanova. Boolq: Exploring the surprising difficulty of natural yes/no questions. In NAACL, 2019.

Peter Clark, Isaac Cowhey, Oren Etzioni, Tushar Khot, Ashish Sabharwal, Carissa Schoenick, and Oyvind Tafjord. Think you have solved question answering? try arc, the ai2 reasoning challenge. ArXiv, abs/1803.05457, 2018.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems, 2021.

Ido Dagan, Oren Glickman, and Bernardo Magnini. The pascal recognising textual entailment challenge. In Machine Learning Challenges Workshop, pp. 177–190. Springer, 2005.

Bryan Eikema and Wilker Aziz. Is MAP decoding all you need? the inadequacy of the mode in neural machine translation. In Proceedings of the 28th International Conference on Computational Linguistics, pp. 4506–4520, Barcelona, Spain (Online), December 2020. International Committee on Computational Linguistics. URL https://aclanthology.org/2020.coling-main.398.

Yanai Elazar, Nora Kassner, Shauli Ravfogel, Abhilasha Ravichander, Eduard Hovy, Hinrich Schütze, and Yoav Goldberg. Measuring and improving consistency in pretrained language models. Transactions of the Association for Computational Linguistics, 9:1012–1031, 2021. doi: 10.1162/tacl_a_00410. URL https://aclanthology.org/2021.tacl-1.60.

Jonathan St BT Evans. Intuition and reasoning: A dual-process perspective. Psychological Inquiry, 21(4):313–326, 2010.

Angela Fan, Mike Lewis, and Yann Dauphin. Hierarchical neural story generation. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pp. 889–898, Melbourne, Australia, July 2018. Association for Computational Linguistics. doi: 10.18653/v1/P18-1082. URL https://aclanthology.org/P18-1082.

Jessica Ficler and Yoav Goldberg. Controlling linguistic style aspects in neural language generation. In Proceedings of the Workshop on Stylistic Variation, pp. 94–104, Copenhagen, Denmark, September 2017. Association for Computational Linguistics. doi: 10.18653/v1/W17-4912. URL https://aclanthology.org/W17-4912.

Tianyu Gao, Adam Fisch, and Danqi Chen. Making pre-trained language models better few-shot learners. In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), pp. 3816–3830, Online, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.acl-long.295. URL https://aclanthology.org/2021.acl-long.295.

Mor Geva, Ankit Gupta, and Jonathan Berant. Injecting numerical reasoning skills into language models. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.acl-main.89. URL https://aclanthology.org/2020.acl-main.89.

Mor Geva, Daniel Khashabi, Elad Segal, Tushar Khot, Dan Roth, and Jonathan Berant. Did aristotle use a laptop? A question answering benchmark with implicit reasoning strategies. Transactions of the Association for Computational Linguistics, 2021. URL https://aclanthology.org/2021.tacl-1.21.

Danilo Giampiccolo, Bernardo Magnini, Ido Dagan, and Bill Dolan. The third pascal recognizing textual entailment challenge. In Proceedings of the ACL-PASCAL workshop on textual entailment and paraphrasing, pp. 1–9. Association for Computational Linguistics, 2007.

Ari Holtzman, Jan Buys, Maxwell Forbes, Antoine Bosselut, David Golub, and Yejin Choi. Learning to write with cooperative discriminators. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pp. 1638–1649, Melbourne, Australia, July 2018. Association for Computational Linguistics. doi: 10.18653/v1/P18-1152. URL https://aclanthology.org/P18-1152.

Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, and Yejin Choi. The curious case of neural text degeneration. In International Conference on Learning Representations, 2020. URL https://openreview.net/forum?id=rygGQyrFvH.

Mohammad Javad Hosseini, Hannaneh Hajishirzi, Oren Etzioni, and Nate Kushman. Learning to solve arithmetic word problems with verb categorization. In Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014. doi: 10.3115/v1/D14-1058. URL https://aclanthology.org/D14-1058.

Daniel Khashabi, Sewon Min, Tushar Khot, Ashish Sabharwal, Oyvind Tafjord, Peter Clark, and Hannaneh Hajishirzi. UNIFIEDQA: Crossing format boundaries with a single QA system. In Findings of the Association for Computational Linguistics: EMNLP 2020, pp. 1896–1907, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.findings-emnlp.171. URL https://aclanthology.org/2020.findings-emnlp.171.

Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. Large language models are zero-shot reasoners. In Alice H. Oh, Alekh Agarwal, Danielle Belgrave, and Kyunghyun Cho (eds.), Advances in Neural Information Processing Systems, 2022. URL https://openreview.net/forum?id=e2TBb5y0yFf.

Rik Koncel-Kedziorski, Subhro Roy, Aida Amini, Nate Kushman, and Hannaneh Hajishirzi. MAWPS: A math word problem repository. In Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2016. doi: 10.18653/v1/N16-1136. URL https://aclanthology.org/N16-1136.

Yihuai Lan, Lei Wang, Qiyuan Zhang, Yunshi Lan, Bing Tian Dai, Yan Wang, Dongxiang Zhang, and Ee-Peng Lim. MWPToolkit: An open-source framework for deep learning-based math word problem solvers. arXiv preprint arXiv:2109.00799, 2021. URL https://arxiv.org/abs/2109.00799.

Jiwei Li and Dan Jurafsky. Mutual information and diverse decoding improve neural machine translation, 2016. URL https://arxiv.org/abs/1601.00372.

Jiwei Li, Will Monroe, and Dan Jurafsky. A simple, fast diverse decoding algorithm for neural generation. CoRR, abs/1611.08562, 2016. URL http://arxiv.org/abs/1611.08562.

Wang Ling, Dani Yogatama, Chris Dyer, and Phil Blunsom. Program induction by rationale generation: Learning to solve and explain algebraic word problems. In Proceedings of the 55th Annual

Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2017. doi: 10.18653/v1/P17-1015. URL https://aclanthology.org/P17-1015.

Yao Lu, Max Bartolo, Alastair Moore, Sebastian Riedel, and Pontus Stenetorp. Fantastically ordered prompts and where to find them: Overcoming few-shot prompt order sensitivity. ArXiv, abs/2104.08786, 2021.

Clara Meister, Tiago Pimentel, Gian Wiher, and Ryan Cotterell. Typical decoding for natural language generation. arXiv preprint arXiv:2202.00666, 2022.

Shen Yun Miao, Chao Chun Liang, and Keh Yih Su. A diverse corpus for evaluating and developing English math word problem solvers. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020. URL https://aclanthology.org/2020.acl-main.92.

Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston, and Douwe Kiela. Adversarial NLI: A new benchmark for natural language understanding. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2020.

Maxwell Nye, Michael Henry Tessler, Joshua B. Tenenbaum, and Brenden M. Lake. Improving coherence and consistency in neural sequence models with dual-system, neuro-symbolic reasoning. In A. Beygelzimer, Y. Dauphin, P. Liang, and J. Wortman Vaughan (eds.), Advances in Neural Information Processing Systems, 2021. URL https://openreview.net/forum?id=uyKk_avJ-p4.

Arkil Patel, Satwik Bhattamishra, and Navin Goyal. Are NLP models really able to solve simple math word problems? In Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, pp. 2080–2094, Online, June 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.naacl-main.168. URL https://aclanthology.org/2021.naacl-main.168.

Xinyu Pi, Qian Liu, Bei Chen, Morteza Ziyadi, Zeqi Lin, Yan Gao, Qiang Fu, Jian-Guang Lou, and Weizhu Chen. Reasoning like program executors, 2022.

Piotr Piękos, Mateusz Malinowski, and Henryk Michalewski. Measuring and improving BERT's mathematical abilities by predicting the order of reasoning. In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 2: Short Papers), 2021. doi: 10.18653/v1/2021.acl-short.49. URL https://aclanthology.org/2021.acl-short.49.

Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. 2019.

Jack W Rae, Sebastian Borgeaud, Trevor Cai, Katie Millican, Jordan Hoffmann, Francis Song, John Aslanides, Sarah Henderson, Roman Ring, Susannah Young, et al. Scaling language models: Methods, analysis & insights from training gopher. arXiv preprint arXiv:2112.11446, 2021.

Qiu Ran, Yankai Lin, Peng Li, Jie Zhou, and Zhiyuan Liu. NumNet: Machine reading comprehension with numerical reasoning. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), 2019. doi: 10.18653/v1/D19-1251. URL https://aclanthology.org/D19-1251.

Subhro Roy and Dan Roth. Solving general arithmetic word problems. In Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015. doi: 10.18653/v1/D15-1202. URL https://aclanthology.org/D15-1202.

Jianhao Shen, Yichun Yin, Lin Li, Lifeng Shang, Xin Jiang, Ming Zhang, and Qun Liu. Generate & rank: A multi-task framework for math word problems. In Findings of the Association for Computational Linguistics: EMNLP 2021, pp. 2269–2279, Punta Cana, Dominican Republic, November 2021. Association for Computational Linguistics. URL https://aclanthology.org/2021.findings-emnlp.195.

Freda Shi, Daniel Fried, Marjan Ghazvininejad, Luke Zettlemoyer, and Sida I. Wang. Natural language to code translation with execution. In Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, pp. 3533–3546, Abu Dhabi, United Arab Emirates, December 2022. Association for Computational Linguistics. URL https://aclanthology.org/2022.emnlp-main.231.

Keith E Stanovich and Richard F West. Individual differences in reasoning: Implications for the rationality debate? Behavioral and brain sciences, 23(5):645–665, 2000. URL https://pubmed.ncbi.nlm.nih.gov/11301544/.

Alon Talmor, Jonathan Herzig, Nicholas Lourie, and Jonathan Berant. CommonsenseQA: A question answering challenge targeting commonsense knowledge. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), 2019. URL https://aclanthology.org/N19-1421.

Yi Tay, Mostafa Dehghani, Vinh Q. Tran, Xavier Garcia, Jason Wei, Xuezhi Wang, Hyung Won Chung, Dara Bahri, Tal Schuster, Steven Zheng, Denny Zhou, Neil Houlsby, and Donald Metzler. Unifying language learning paradigms, 2022. URL https://arxiv.org/abs/2205.05131.

Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam Shazeer, Apoorv Kulshreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, et al. Lamda: Language models for dialog applications. arXiv preprint arXiv:2201.08239, 2022. URL https://arxiv.org/abs/2201.08239.

Ashwin Vijayakumar, Michael Cogswell, Ramprasaath Selvaraju, Qing Sun, Stefan Lee, David Crandall, and Dhruv Batra. Diverse beam search for improved description of complex scenes. Proceedings of the AAAI Conference on Artificial Intelligence, 32, Apr. 2018. URL https://ojs.aaai.org/index.php/AAAI/article/view/12340.

Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. Chain of thought prompting elicits reasoning in large language models. Conference on Neural Information Processing Systems (NeurIPS), 2022. URL https://arxiv.org/pdf/2201.11903.

Sean Welleck, Ilia Kulikov, Jaedeok Kim, Richard Yuanzhe Pang, and Kyunghyun Cho. Consistency of a recurrent language model with respect to incomplete decoding. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 5553–5568, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.448. URL https://aclanthology.org/2020.emnlp-main.448.

Weiwen Xu, Yang Deng, Huihui Zhang, Deng Cai, and Wai Lam. Exploiting reasoning chains for multi-hop science question answering. In Findings of the Association for Computational Linguistics: EMNLP 2021, pp. 1143–1156, Punta Cana, Dominican Republic, November 2021a. Association for Computational Linguistics. URL https://aclanthology.org/2021.findings-emnlp.99.

Yichong Xu, Chenguang Zhu, Shuohang Wang, Siqi Sun, Hao Cheng, Xiaodong Liu, Jianfeng Gao, Pengcheng He, Michael Zeng, and Xuedong Huang. Human parity on commonsenseqa: Augmenting self-attention with external attention, 2021b. URL https://arxiv.org/abs/2112.03254.

Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. HotpotQA: A dataset for diverse, explainable multi-hop question answering. In Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, pp. 2369–2380, Brussels, Belgium, October-November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-1259. URL https://aclanthology.org/D18-1259.

Xi Ye and Greg Durrett. The unreliability of explanations in few-shot prompting for textual reasoning. In Alice H. Oh, Alekh Agarwal, Danielle Belgrave, and Kyunghyun Cho (eds.), Advances in Neural Information Processing Systems, 2022. URL https://openreview.net/forum?id=Bct2f8fRd8S.

Wenhao Yu, Chenguang Zhu, Lianhui Qin, Zhihan Zhang, Tong Zhao, and Meng Jiang. Diversifying content generation for commonsense reasoning with mixture of knowledge graph experts. In Findings of Annual Meeting of the Association for Computational Linguistics (ACL), 2022.

Zihao Zhao, Eric Wallace, Shi Feng, Dan Klein, and Sameer Singh. Calibrate before use: Improving few-shot performance of language models. In Marina Meila and Tong Zhang (eds.), Proceedings of the 38th International Conference on Machine Learning, volume 139 of Proceedings of Machine Learning Research. PMLR, 2021. URL https://proceedings.mlr.press/v139/zhao21c.html.

A 附录

A.1 补充实验结果

A.1.1 对采样策略和参数的鲁棒性

在图 6 中，我们在 LaMDA-137B 上改变温度采样中的 T 和 Top-k 采样中的 k，针对不同采样策略和参数进行消融实验。结果表明，自一致性对各种采样策略和参数均具有鲁棒性。

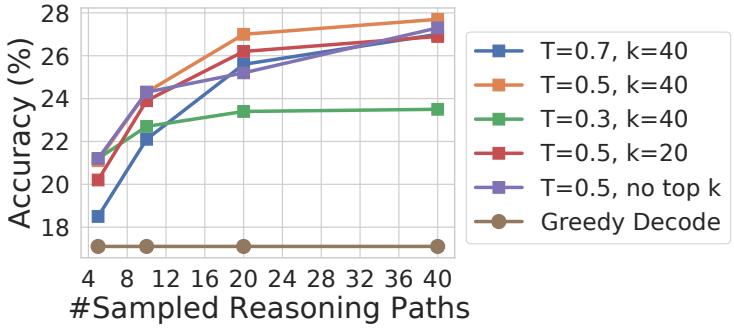


图 6: LaMDA-137B 在 GSM8K 上的准确率。自一致性在各种采样策略和采样参数下均有效。

图 7 和图 8 分别展示了在 LaMDA-137B 和 PaLM-540B 上，自一致性与对单条路径进行贪心解码的比较结果。 在扩大模型规模已经带来较高准确率的基础上，自一致性在这两个模型上仍以相当显著的幅度优于贪心解码。

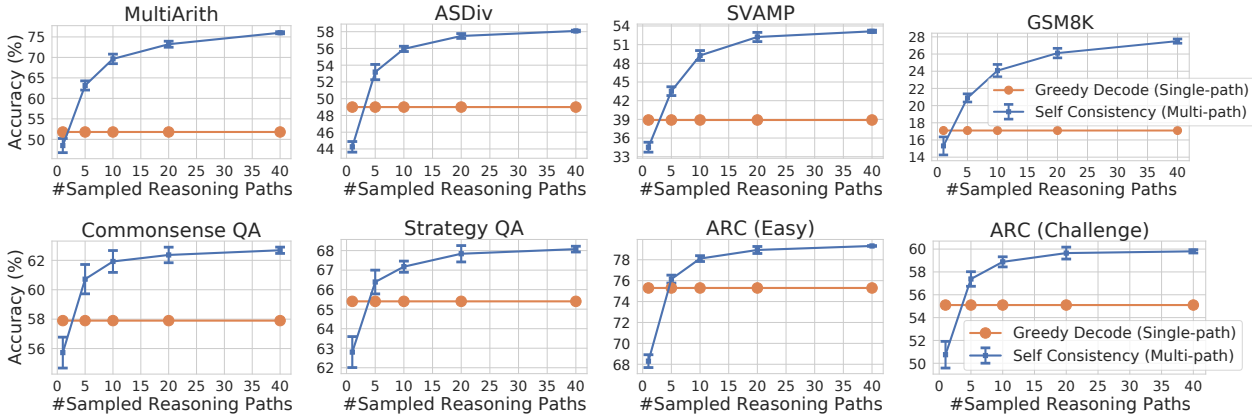


图 7: 在 LaMDA-137B 上，自一致性（蓝色）显著提高了多种算术推理与常识推理任务的准确率。采样更多不同的推理路径能够持续提高推理准确率。

此外，我们在表 12 中展示了从 LaMDA-137B 模型采样得到的更多推理路径，并在表 13 中展示了从 PaLM-540B 模型采样得到的推理路径。 可以看到，额外采样的推理路径所具有的多样性，确实有助于模型在聚合后得出更准确的最终答案。

A.1.2 对不同提示集的鲁棒性

表 9 进一步表明，自一致性对不同输入提示集具有较强的鲁棒性。我们手工编写了 3 组不同的思维链，作为模型的提示。对于所有提示集，自一致性均相较于原始 CoT 方法取得了稳定的提升。

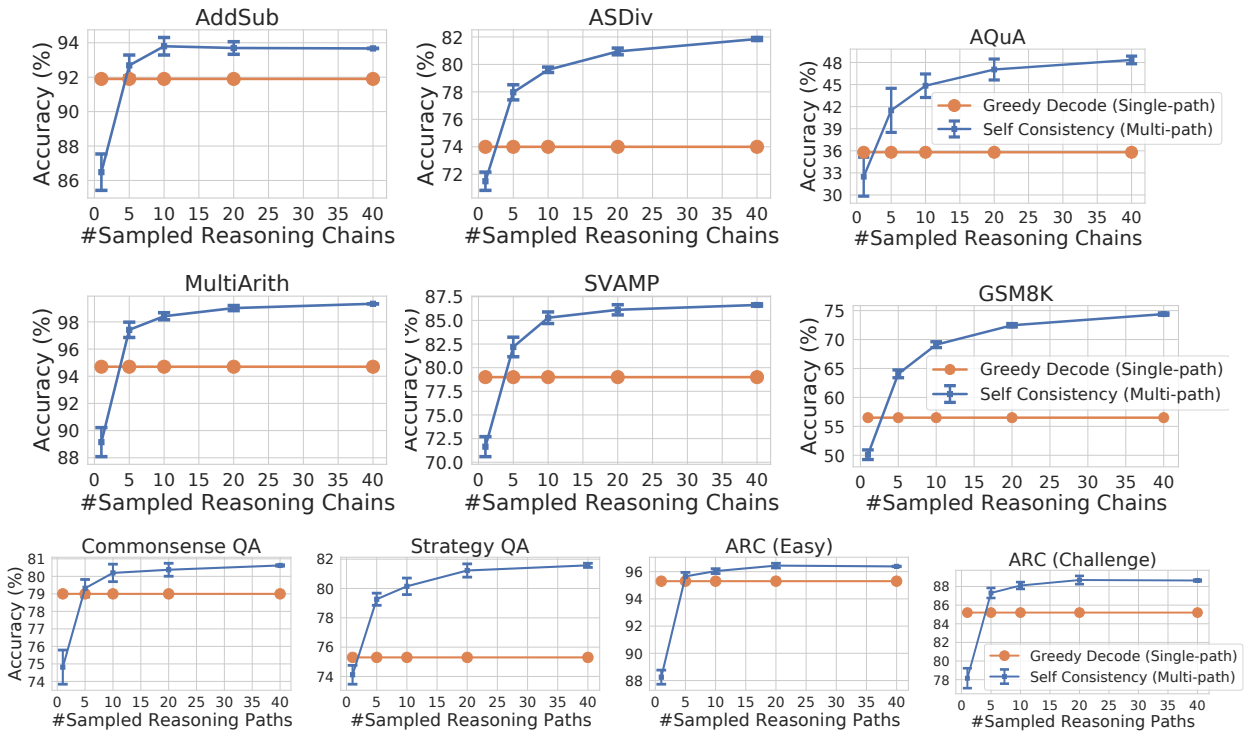


图 8: 在 PaLM-540B 上，自一致性（蓝色）显著提高了多种算术推理与常识推理任务的准确率。采样更多不同的推理路径能够持续有助于提高推理准确率。

	提示集 1（正文所用）	提示集 2	提示集 3
CoT (Wei et al., 2022)	56.5	54.6	54.0
自一致性	74.4 (+17.9)	72.1 (+17.5)	70.4 (+16.4)

表 9: PaLM-540B 在 GSM8K 上的准确率。结果表明，自一致性对不同输入提示具有鲁棒性。

A.1.3 与模型集成的比较

此外，我们提供了直接集成**多个语言模型**输出的结果。表 10 展示了对 3 个语言模型进行贪心解码并取多数投票的结果（对 10 次运行取平均）。需要注意的是，这是一种典型的集成方法（对多个模型的预测进行平均），但由于能力较弱的模型拖累了能力较强模型的表现，其性能明显差于自一致性（PaLM-540B 上的自一致性准确率为 74.4%）。此外，该方法还存在两方面局限：1）它需要多个模型来构建集成，而这些模型未必总是可用；自一致性则只需要单个模型进行“自集成”；2）如果其中一个模型明显较弱，反而可能损害最终性能。

	方法	GSM8K 准确率
单个模型	PaLM-540B，贪心解码 / 自一致性	56.5 / 74.4
模型集成	LaMDA-137B + PaLM-540B	36.9 ± 0.5
	PaLM-540B + GPT-3 (code-davinci-001, 175B)	36.6 ± 0.4
	LaMDA-137B + GPT-3 (code-davinci-001, 175B)	16.0 ± 0.8
	LaMDA-137B + PaLM-540B + GPT-3 (code-davinci-001, 175B)	33.3 ± 0.7

表 10: 多个模型集成在 GSM8K 上的准确率比较。

A.1.4 将自一致性与其他集成策略相结合

自一致性与其他集成策略完全兼容，尽管自一致性带来的增益显著高于其他集成策略（并且可能“覆盖”其他集成策略带来的性能增益）。我们进一步开展了实验，并在表 11 中给出结果（为公平比较，我们使用 40 组提示，或 40 种提示排列，与采用 40 条路径的自一致性进行比较；所有实验均基于 PaLM-540B）。

	GSM8K 准确率
不同提示集（x40）	58.9
提示排列（x40）	59.6
自一致性（x40）	74.4
自一致性 + 不同提示集（x40）	75.4
自一致性 + 提示排列（x40）	73.8

表 11: 将自一致性与其他集成策略相结合。

A.2 计算资源与推断细节

对于全部四个语言模型，我们都仅进行基于提示的推断。 对于 UL2，我们使用 TPU v3（2x2 配置，4 个芯片，8 个核心）。 对于 GPT-3 模型，实验通过公开 API 完成。[12] 对于 LaMDA-137B，我们使用 TPU v3（8x8 配置，64 个芯片，128 个核心）。 对于 PaLM-540B，我们使用 TPU v4（4x4x12 配置，192 个芯片，384 个核心）。对每个任务（约 1,000 个样例），大多数推断作业在 UL2 和 LaMDA-137B 上耗时 1 至 4 小时，在 PaLM-540B 上耗时约 2 至 12 小时。有些任务（例如常识推理）耗时更长，但每个任务均不超过 2 天。

对于 GPT-3 模型，所有方法的最大生成词元数均设为 128，不使用频率惩罚或出现惩罚。对于所有模型，我们截取下一个“Q:”开始之前的生成输出，以解析最终答案，这与我们的提示格式保持一致。

LaMDA 补充逐字样例未收录。

表 12: 公开版未收录的原文实例或界面。

PaLM 补充逐字样例未收录。

表 13: 公开版未收录的原文实例或界面。

A.3 完整提示集的公开版说明

原文完整提示集含多种第三方数据集文字，暂不收录。

[12] https://beta.openai.com/docs/api-reference/making-requests