伪奖励：重新思考 RLVR 的训练信号

Spurious Rewards: Rethinking Training Signals in RLVR

Rulin Shao[*1]、Shuyue Stella Li[*1]、Rui Xin[*1]、Scott Geng[*1]、 Yiping Wang[1]、Sewoong Oh[1]、Simon Shaolei Du[1]、Nathan Lambert[2]、 Sewon Min[3]、Ranjay Krishna[1,2]、Yulia Tsvetkov[1]、Hannaneh Hajishirzi[1,2]、 Pang Wei Koh[1,2]、Luke Zettlemoyer[1]

[*] 同等贡献；[1] 华盛顿大学；[2] 艾伦人工智能研究所；[3] 加州大学伯克利分校。

中文公开删节版 · v1.1 · 2026年11月10日

原文：https://proceedings.mlr.press/v306/shao26d.html。 本文件为非官方 AI 辅助中文公开删节版，翻译与排版：dot。保留公式、经筛选的图表及参考文献；图内英文保留以便对照。原文作者保留版权，依 PMLR 的 CC BY 4.0 授权翻译。 原文刊载于第 43 届国际机器学习大会（ICML 2026，韩国首尔），PMLR 第 306 卷。 项目代码：https://github.com/ruixin31/Spurious_Rewards。 通信邮箱：{rulins,stelli,rx31,sgeng}@cs.washington.edu。

版本与许可说明：本译本底本为 PMLR 306:110167–110207（2026）的 41 页正式版。许可依据是 PMLR 出版协议第 2–3 条：https://proceedings.mlr.press/pmlr-license-agreement.html。其 CC BY 4.0 授权与 arXiv:2506.10947v2 所列 CC BY-NC-SA 4.0 不同，不应混用不同版本的许可。本译文的翻译与排版贡献同以 CC BY 4.0 提供；不以本译文替换原权利人的权利或通知。

改动与范围：改动包括中文翻译、重新排版、图内术语对照、明确标记的译注，以及公开发布删节；并修复重复的图内交叉引用锚点，不改变研究数据。暂不收录正文缩略代码推理实例、附录末尾九个逐字定性实例和对应模型输出，以及提示比较表中的完整提示原串和逐字中文转写。研究方法、推导、实验数据、统计图及分析保留。被移除图表保留编号占位。本版本不是完整译文。

使用说明：原作者、所属机构和会议未审校或认可本译文。再次传播请保留作者、题名、PMLR 出版来源、原论文链接和许可链接，并说明翻译、删节等改动。独立的代码、模型、数据集或第三方材料需各自核实许可。本次删节不认定原论文引用侵权；此说明不是法律意见或无侵权保证。此发布包仅含译文 PDF 和说明，不含原文或源码。

目录

译者附页：原图英文标记对照 **4**

1 引言 **5**

2 伪奖励带来显著的 RLVR 增益 **6**
2.1 实验设置 6
2.2 从标准奖励到弱奖励再到伪奖励 7

3 对其他模型的泛化及其局限 **8**

4 理解 GRPO 中随机奖励产生的训练信号 **9**

5 案例研究：作为代表性既有行为的代码推理 **10**
5.1 不同模型的既有推理策略存在差异 11
5.2 伪奖励 RLVR 提高既有推理策略的权重 11
5.3 显式干预代码推理频率 11

6 相关工作 **15**

7 结论 **15**

A 实验设置 **21**
A.1 GRPO 预备知识 21
A.2 数据集与模型 21
A.3 训练配置 21
A.4 解码配置 21
A.5 计算资源 21
A.6 可视化 22
A.7 TTRL 与单样本强化学习的实验设置 22

B 随机奖励这一奇特案例 **22**
B.1 猜想：裁剪偏置在随机奖励下带来训练信号 23
B.1.1 随机奖励的期望优势 23
B.1.2 随机奖励下裁剪偏置的梯度推导 23
B.1.3 裁剪产生偏向模型先验知识的不对称更新 25
B.2 无裁剪 RLVR 的高度随机性 26

C AMC 补充结果 **27**

D AIME 2024 与 AIME 2025 补充结果 **27**
D.1 伪奖励使 Qwen2.5-Math 获得显著 RLVR 增益 28
D.2 对其他模型的泛化及其局限 28

E 在 Qwen 以外的模型上检验现有方法 **30**

F 抑制代码推理的复合奖励 **30**

G 代码推理之外：RLVR 易于诱发的另一种有益模式 **30**

H RLVR 期间的推理策略转换 **30**

I 伪提示：Qwen2.5-Math-7B 对提示异乎寻常的高度敏感性 **31**
I.1 现有提示 32
I.2 伪提示 32

J 已接受强化学习训练模型的补充结果 32
K Qwen2.5-Math-7B 代码推理行为的定性分析 33

译者附页：原图英文标记对照

本译本保留原始图形，以免重新绘制造成数值或曲线失真。图题、图注已译为中文；图内常见英文如下。模型和数据集名称不译。此表不属于原论文。

英文标记	中文含义
Accuracy / Acc.	准确率
Overall Accuracies	总体准确率
Avg Acc. @ 8	8 次采样的平均准确率（不是 pass@8）
Training Step / Step	训练步数 / 步
Before RL	强化学习之前
Ground Truth / GT	标准答案（真实标签）
Incorrect Label / Incorrect	错误标签 / 错误标签奖励
Format Reward / Format	格式奖励
Random Reward	随机奖励
Python Reward / Python	Python 代码奖励
Majority Vote	多数投票
Most common label	出现次数最多的标签
One-Shot RL	单样本强化学习
Test Time RL	测试时强化学习
Code Frequency / Code Frequencies	代码推理频率
Frequency	频率
Token Probability	token 概率
All / Code / Lang	全部 / 代码推理 / 自然语言推理
C / L	代码推理 / 自然语言推理
C→L、L→C	代码转向语言、语言转向代码推理
C→C、L→L	前后均使用代码、前后均使用语言推理
With Clipping / No Clipping	使用裁剪 / 不使用裁剪
No Repetition	无重复（重复惩罚奖励设置）
w/o / w/o Python	不含 / 禁止 Python 代码推理
Batch Size	批大小
Rollout / Rollout Size	采样生成的轨迹 / 每个提示的采样数量
Standard / Weak / Spurious	标准 / 弱 / 伪（奖励）
Reward = 1	奖励值为 1
Correct answer	正确答案
1 example w/ correct label	1 个带正确标签的样本
Response contains `\boxed{}`	回答包含 `\boxed{}` 格式
Use an incorrect rollout as ground truth	将一条错误生成轨迹当作标准答案
50% of the time	以 50% 的概率
from 64 rollouts	从 64 条采样轨迹中选取
Gains from ground truth only	仅来自标准答案的增益
Significant gains from most training signals	大多数训练信号都能带来显著增益
Weak & Spurious Rewards Work!	弱奖励与伪奖励也有效！
on Certain Models, but Not All	只对某些模型有效，并非所有模型

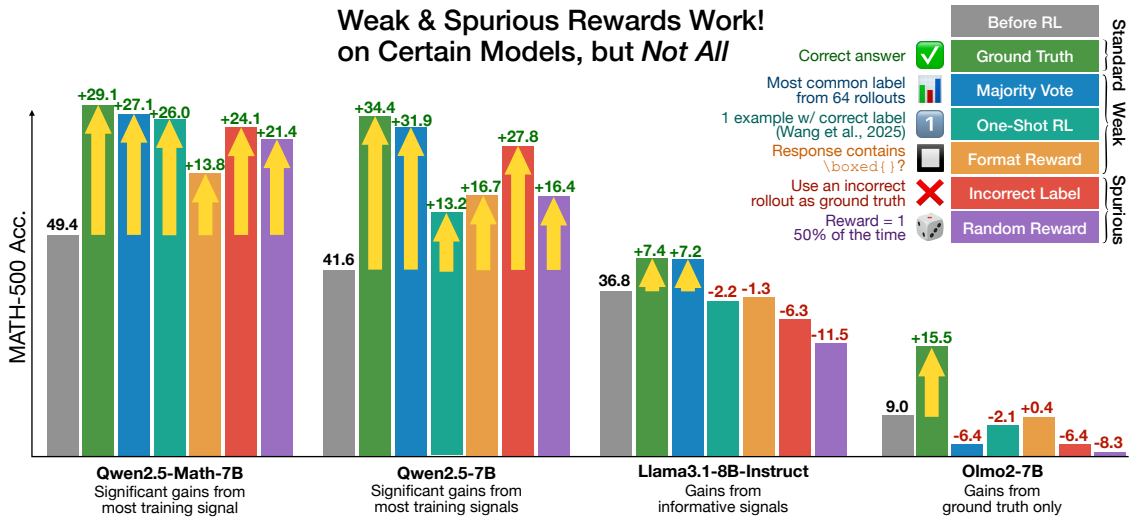


图 1: 采用不同训练信号进行 300 步 RLVR 后的 MATH-500 准确率。即使是“伪奖励”（例如奖励错误标签，或完全随机的奖励），也能使 Qwen 模型在 MATH-500 上取得显著增益。值得注意的是，这些奖励信号对 Llama3.1-8B-Instruct 和 OLMo2-7B 等推理先验不同的其他模型不起作用。

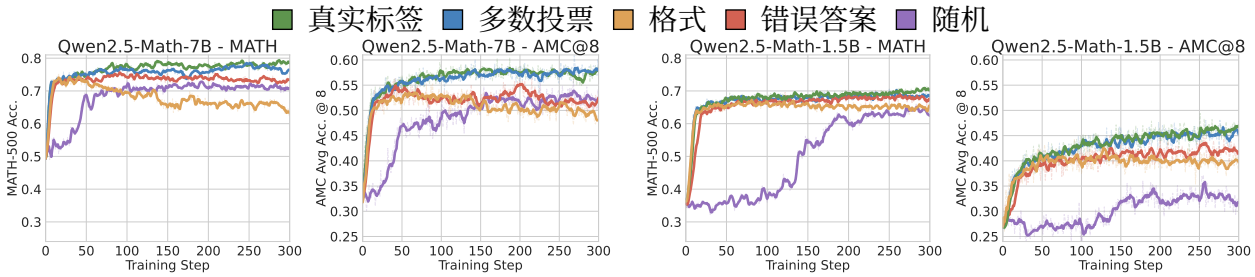
摘要

我们表明，即使使用与正确答案几乎不相关、完全无关，甚至负相关的伪奖励（spurious rewards），可验证奖励强化学习（RLVR）仍能激发某些语言模型强大的数学推理能力。例如，采用 GRPO 的 RLVR 训练，在随机分配奖励时便能使 Qwen2.5-Math-7B 的 MATH-500 表现提高 21.4 个百分点，几乎接近真实标签奖励带来的 29.1 个百分点增益。为解释这一反直觉现象，我们表明，GRPO 的裁剪项会产生一种裁剪偏置；即使奖励不含有效信息，它也能放大预训练时学到的高先验概率行为。作为案例研究，我们识别了 Qwen2.5-Math 模型的一种此类行为，并将其称为代码推理，即用代码进行推理，却并不真正执行代码。使用伪奖励后，代码推理的频率从 65% 提升至 90% 以上。然而，是否存在这种可被放大的行为，在很大程度上取决于模型。实践中，对 Qwen 模型有效的伪奖励，往往无法为 Llama3 或 OLMo2 等其他模型家族带来增益。我们的结果凸显了在多种模型上验证强化学习方法的重要性，而不能仅依赖某一种事实上的默认选择：Qwen 模型即使采用随机奖励也能获得显著的性能提升，但这并不反映真正的能力改进。

1 引言

可验证奖励强化学习（RLVR）能够十分有效地改善语言模型的推理表现 (Lambert et al., 2024; Guo et al., 2025; Zeng et al., 2025; Luo et al., 2025)，但产生这些增益的机制仍未得到充分理解。本文揭示了一个反直觉现象：即使采用一类几乎不含或完全不含任务相关信号的伪奖励，RLVR 也能大幅改善数学推理表现，而且这一效应高度依赖基础模型。例如，对于 RLVR 文献中广泛使用的 Qwen2.5-Math 模型 (Yang et al., 2024a,b)，随机分配的奖励能使 MATH-500 准确率绝对提升 21.4 个百分点，而真实标签奖励的提升为 29.1 个百分点（第 2 节）。我们在 AMC 和 AIME 等更具挑战性的数学基准上观察到类似趋势。相反，在 Qwen2.5 (Yang et al., 2024b)、OLMo2 (OLMo et al., 2024) 和 Llama3 (Dubey et al., 2024) 等其他模型家族上，伪奖励训练带来的改善很小，甚至会导致性能下降（第 3 节）。这种结果分歧表明，各个模型不同的预训练先验会强烈影响强化学习的训练动态。

为进一步研究这种虚假提升背后的机制，我们剖析 GRPO 训练目标 (Shao et al., 2024)，发现裁剪函数会系统性地放大基础模型中先验概率较高的词元（第 4 节）。为帮助解释这种差异，我们还分析了在这些情况下 RLVR 学会偏好的推理模式（第 5 节）。具体而言，我们发现，尽管无法执行代码，Qwen2.5-Math-7B 在 MATH-500 上的大多数回答仍包含以 Python 表达的推理链，我们把这种行为称为代码推理。代码推理对整体表现具有很强的预测性：包含代码推理的回答准确率为 60.9%，远高于不包含它的回答（28.0%）。在 RLVR 训练过程中，代码推理也与 MATH-500 准确率相关。在任一种伪奖励下，这两个指标都会随训练持续上升，训练后的代码出现频率达到约



(a) Qwen2.5-Math-7B (b) Qwen2.5-Math-1.5B

图 2: 采用不同训练奖励时，模型在 MATH 与 AMC 上的表现，使用大小为 10 的窗口平滑（虚线表示未平滑值）。MATH 报告 pass@1，AMC 报告 average@8。从有意义的奖励到伪奖励，各类奖励信号下的 RLVR 都能显著改善 Qwen2.5-Math-7B 与 Qwen2.5-Math-1.5B 。随机奖励的收敛速度慢于其他伪奖励，但它居然也能带来显著增益，本身就令人意外。

90% 或更高。除代码推理外，我们发现词汇重复在 Qwen2.5-Math-7B 模型中也与 MATH 表现存在类似但较弱的相关性。根据这一观察，我们进一步假设：采用其他方法进行干预，只要能增加任意一种有益行为，也应当提高测试表现。实验验证了这一假设：我们设计了基于提示和基于强化学习的诱发方法，以增加代码推理与词汇重复；所有这些方法都显著提升了 Qwen2.5-Math-7B 的表现。[1]我们表明，这些结果对提示变化具有稳健性，尽管模型的初始表现对提示十分敏感，而且有时敏感的方式出人意料（附录 I）。

我们的发现不仅提出了新问题，也具有实践意义。总体而言，我们应当更加关注预训练植入的推理模式如何深刻影响下游 RLVR 训练行为。Qwen 模型凭借开放权重和优异的推理任务表现，已成为开源社区开展 RLVR 研究时事实上的默认选择。近期一系列 RLVR 研究都基于以 Qwen2.5-Math-7B 为中心的实验得出结论 (Zuo et al., 2025; Zhao et al., 2025b; Wang et al., 2024; Xie et al., 2025; Hu et al., 2025b; Zhang et al., 2025; Shafayat et al., 2025; Prabhudesai et al., 2025; Gao et al., 2025; Wang et al., 2025a)。然而，我们表明，即使使用完全虚假的奖励信号，也很容易在 Qwen 模型上获得显著的性能提升。因此，我们建议，今后的 RLVR 研究应在其他模型上加以验证，并将伪奖励作为无信息对照基线。我们强调，提出伪奖励纯粹是出于分析目的，不应将其视为发展模型真实能力的推荐方法。

2 伪奖励带来显著的 RLVR 增益

我们设计了一组逐步弱化的奖励函数来替代标准的真实标签奖励：弱奖励（多数投票奖励与格式奖励），以及伪奖励（随机奖励与错误答案奖励）。值得注意的是，我们发现所有弱奖励与伪奖励都足以让 RLVR 显著改善 Qwen2.5-Math 的数学表现；该模型是 RLVR 训练中广受欢迎的起点。

2.1 实验设置

遵循近期的 RLVR 工作 (Wang et al., 2025b; Zuo et al., 2025; Zeng et al., 2025)，我们使用 GRPO (Guo et al., 2025) 微调 Qwen2.5-Math 模型 (Yang et al., 2024a)。标准 RLVR 方法使用由问题及其真实标签组成的数据集。训练时，根据生成答案是否可验证为正确，为模型采样轨迹赋予二元（0–1）奖励。我们把这种基于真实标签的奖励替换为一系列虚假程度逐步增加、无需真实标签的二元 0–1 奖励函数。设计这些替代奖励，是为了探索有效 RLVR 训练所需监督究竟可以少到什么程度。我们在 DeepScaleR 数据 (Luo et al., 2025)上使用这些奖励进行训练，其他实验细节全部保持不变。

正文在两个标准数学推理基准上评估性能：MATH-500 (Hendrycks et al., 2021) 报告 pass@1 准确率，AMC (Li et al., 2024) 报告 average@8 准确率。AIME 2024 与 2025 的补充结果见附录 D。按照流行强化学习框架 OpenRLHF (Hu et al., 2025a) 的默认评估设置，主实验对 Qwen2.5-Math 和所有指令模型使用默认聊天模板，对其他基础模型使用 Olmo 提供的聊天模

[1]译注：原文引言称干预会“增加代码推理与词汇重复”，而附录 G 研究的是减少重复。本译文保留这一原文表述差异。

板 (OLMo et al., 2024)。不同提示影响的补充分析见附录 I。其中我们表明，Qwen2.5-Math-7B 对提示非常敏感，甚至与任务无关的提示（我们称之为伪提示）有时也会带来很高的初始表现。训练与评估设置的完整细节见附录 A。

2.2 从标准奖励到弱奖励再到伪奖励

我们考虑以下奖励：

1. **真实标签奖励：**作为基线，我们采用标准 RLVR 方法 (Lambert et al., 2024)，利用真实标签奖励答案可验证为正确的回答。此设置代表奖励监督质量的上限。
2. **多数投票奖励：**我们不使用真实标签计算奖励，而是使用 RLVR 训练前的模型为训练集生成伪标签：每个提示采样 64 个回答，选择出现次数最多的答案。随后在标准的在线 RLVR 训练中，用这些可能错误的标签奖励回答。
3. **格式奖励：**我们进一步弱化奖励信号，完全不考虑回答在数学上是否正确。取而代之的是采用启发式规则：只要回答包含至少一个非空的 `\boxed{}` 表达式就给予奖励，不论框内答案是否正确。Qwen2.5-Math 的系统提示要求包含 `\boxed{}`，因此这种奖励会在一定程度上鼓励遵循提示。
4. **随机奖励：**我们研究，在奖励过程中完全不提供指导，是否也足以产生有意义的数学性能增益。为此，我们随机分配奖励。给定固定的概率超参数 γ，所有回答均以该参数指定的概率获得奖励 1，否则获得 0。主实验使用 $\gamma = 0.5$；附录 B 表明，使用 $\gamma \in \{0.001, 0.3, 0.7\}$ 也能获得类似改善，只是收敛速度不同。同时我们验证了 $\gamma = 0$ 时不会产生变化，这符合解析预期（此时损失为常数，所有梯度均为零）。
5. **（多数投票得到的）错误答案奖励：**我们还故意提供错误监督，只奖励错误答案。首先通过多数投票为全部训练数据标注，然后选取标签错误的子集进行训练，从而得到仍属于模型高概率输出的错误标签。训练时，奖励答案可验证为与这些错误标签一致的回答。这一设计能够区分，多数投票奖励有效，究竟是因为标签更可能正确，还是因为它们代表模型高概率的输出。我们奖励特定的错误答案，而不是任意错误答案，以使奖励稀疏程度与其他实验条件相近。

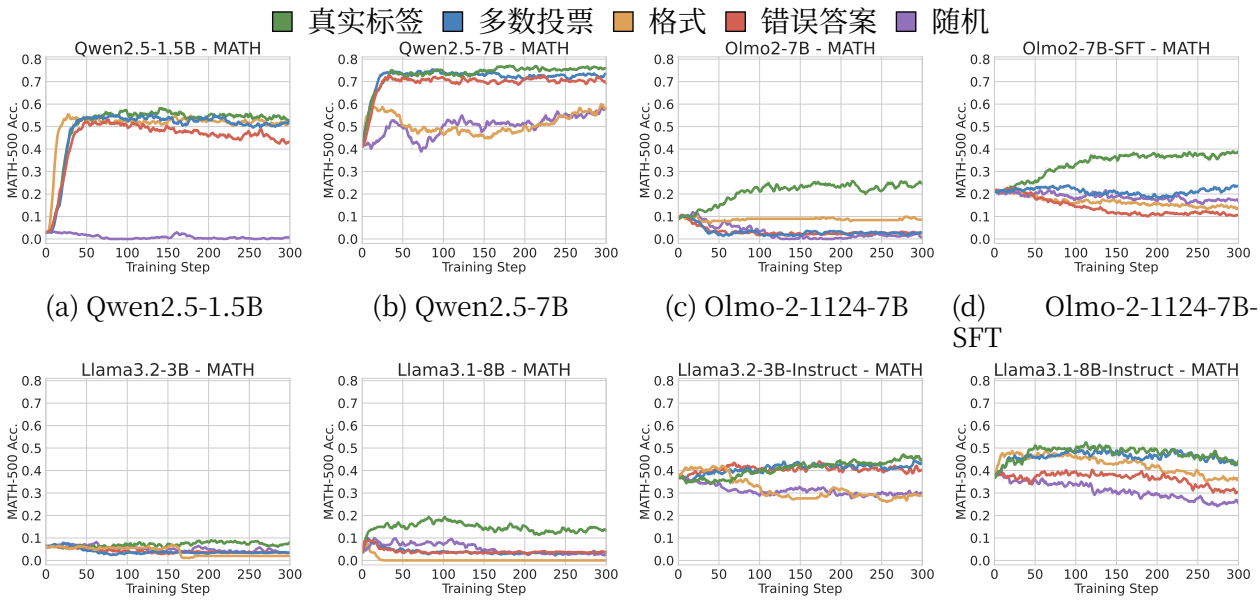
说明：我们强调，伪奖励，特别是随机奖励与错误答案奖励，纯粹用于分析，不应被视为发展模型真实能力的推荐方法。

图 2 展示了 Qwen2.5-Math 模型在各类奖励函数下进行 RLVR 训练后的表现。总体而言，与未调优基线相比，即使是刻意设计得不合理的奖励函数，也都能在前 50 个训练步内显著提高各项基准的数学表现。一个例外是，Qwen2.5-Math-1.5B 使用随机奖励时提升慢得多（100 步之后才出现），在 AMC 上的增益也较小（仅 4.9 个百分点）。值得注意的是，伪奖励带来的性能增益，往往与使用真实标签的 RLVR 增益只相差几个百分点。例如，错误标签奖励使 Qwen2.5-Math-7B 在 MATH-500 上提高 24.1 个百分点，而真实答案奖励带来的提升为 29.1 个百分点。即使是设计上仅向奖励过程注入纯噪声的随机奖励，也仍能使性能提升 21.4 个百分点。我们在 AMC 上观察到类似趋势：采用格式、错误答案或随机奖励训练，分别带来 13.8、24.1 或 21.4 个百分点的增益，接近使用多数投票标签和真实标签训练带来的约 27–29 个百分点提升。[2]

附录 D 补充了 AIME24 与 AIME25 的结果。在 AIME2024 上，格式奖励（+10.3 个百分点）接近真实标签奖励（+15.3 个百分点）；伪奖励（错误答案和随机）也仍使 Qwen2.5-Math-7B 获得显著增益，分别为 10.2 和 10.2 个百分点。AIME2025 的问题写于本文所有模型的知识截止日期之后，在这一基准上，真实标签相对其他奖励显示出明确优势。不过，其他奖励仍能带来 -0.4 至 4.5 个百分点的性能变化。

这些简单奖励的结果，为文献中一个新近出现的假说提供了进一步证据：至少在开源后训练流程的计算规模下 (Lambert et al., 2024)，RLVR 并未教会模型新的推理能力，而是在触发基础模型中已经存在的潜在能力 (Wang et al., 2025b; Liu et al., 2025; Gandhi et al., 2025; Yue et al., 2025; AI et al., 2025; Choshen et al., 2020)。此前的工作通过数量有限的真实标签 (Wang et al., 2024)或带噪声的标签 (Zuo et al., 2025)暗示了这种效应，而我们的结果把这一观点推到了极限：即使是完全错误的奖励或不含信息的奖励（即随机奖励），也能激发 Qwen2.5-Math 模型的性能

[2]译注：原文此处将 AMC 的三项增益写为 13.8%、24.1%、21.4%；其中后两项与前述 MATH-500 数值相同。此处按原文保留，未自行改写。本文将准确率的绝对百分比变化译为“百分点”。



(a) Qwen2.5-1.5B (b) Qwen2.5-7B (c) Olmo-2-1124-7B (d) Olmo-2-1124-7B-SFT

(e) Llama3.2-3B (f) Llama3.1-8B (g) Llama3.2-3B-Instruct (h) Llama3.1-8B-Instruct

图 3: 其他模型类别在 MATH-500 上采用不同奖励的结果。伪奖励对通用的 Qwen2.5 模型仍然有效，但通常无法为其他模型家族带来任何增益。非 Qwen2.5 模型的性能改善远小于 Qwen2.5 家族。附录 C 中的 AMC 结果也呈现类似趋势。

提升。下文将表明，这种诱发效应依赖于模型（第 3 节），并追溯 Qwen2.5-Math 模型中可能使伪奖励产生这种诱发作用的具体特性（第 5 节）。

3 对其他模型的泛化及其局限

伪奖励信号在提高 Qwen2.5-Math 模型表现方面出人意料地有效，这促使我们研究这些奖励能否推广到其他模型的训练。我们从数学专用的 Qwen2.5-Math 模型扩展到通用变体（Qwen2.5-7B、Qwen2.5-1.5B (Yang et al., 2024b)），并纳入另外两个模型家族：（a）广泛使用的 Llama3.1-8B（及其 Instruct 版本）和 Llama3.2-3B（及其 Instruct 版本）(Dubey et al., 2024)；（b）OLMo2-7B 与 OLMo2-7B-SFT (OLMo et al., 2024)。OLMo2-7B-SFT 是对 OLMo2-7B 进行指令微调得到的；同时纳入二者，有助于理解监督微调（SFT）对 RLVR 训练的影响。此外，我们期待 OLMo 开放的训练数据能帮助未来研究更好地追溯下文观察到的推理行为（或其缺失）的来源。我们采用第 2 节相同的设置和奖励，训练这 8 个额外模型。正文报告 MATH-500 表现；附录 C 报告呈现相同趋势的 AMC 结果。AIME 2024 和 2025 基准上的趋势相似，但噪声较大（附录 D）。

伪奖励可以使 Qwen2.5 模型受益，却很少帮助非 Qwen 模型。图 3 显示出两种趋势。首先，同一家族内的模型行为相似：对于 Qwen2.5，所有非随机奖励（甚至包括伪造的错误答案奖励）都能改善 MATH-500 表现；而 OLMo 在伪奖励下表现基本不变，主要在真实标签奖励下获得提升。我们猜测，这种家族层面的一致性反映了共享预训练分布带来的相似强化学习前行为。其次，小模型从伪奖励（如随机奖励）中获益更少；我们猜测，大模型保留了更多可被这些奖励放大的预训练先验。第 5 节进一步分析既有行为如何影响 RLVR 结果。重要的是，这些奖励信号不能可靠地迁移到其他家族。虽然错误答案伪奖励和其他弱奖励持续改善 Qwen，但每一种弱奖励或伪奖励都至少无法帮助另一个模型，结果可能毫无变化，甚至有害。总体而言，Qwen 对奖励强度表现出异乎寻常的稳健性。附录 J 进一步表明，已经经过强化学习后训练的模型，在几乎所有奖励下的增益都很小。

实践警示 ⚠️：提出的 RLVR 奖励信号应在多种模型上测试！许多近期面向推理的 RLVR 方法，主要甚至完全依据 Qwen 模型上的增益得出结论（非穷尽示例见 Zuo et al. (2025); Zhao et al. (2025b); Wang et al. (2024); Xie et al. (2025); Hu et al. (2025b); Zhang et al. (2025)）。作为案例，我们实验考察了近期的（1）测试时训练 (Zuo et al., 2025)与（2）单样本强化学习 (Wang

et al., 2025b)（设置详见附录 A.7）。这些方法表现出与上述结果相似的模式：提出的训练信号在 Qwen2.5-Math 或 Qwen2.5 模型中产生显著提升，达到真实标签奖励的表现（附录 E，图 15）。然而，相同信号往往不能改善其他模型家族。我们的发现表明，现有以 Qwen 为中心的 RLVR 研究可能需要在非 Qwen 模型上进一步验证。

4 理解 GRPO 中随机奖励产生的训练信号

此前的研究已经表明，在 GRPO 中使用多数投票标签或格式奖励的 RLVR，可以改善模型表现 (Zuo et al., 2025; Zhao et al., 2025b; Wang et al., 2025b)。因此，多数投票奖励（即使标签错误[3]）与格式奖励有效，并不那么令人意外。然而，随机奖励的有效性仍令人困惑，因为它在构造上不包含任何信息。本节提出关于随机奖励如何在 GRPO 中诱发有意义训练信号的假说，并通过消融实验验证。

去掉 GRPO 的裁剪后，随机奖励不再提供训练信号。我们分析移除裁剪项后的 GRPO，表明仅凭随机奖励无法产生有效训练。裁剪项出现在 GRPO 目标中[4]：

$$J(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_{\text{old}}(\cdot|x)} \left[\sum_{t=1}^{|y|} \min\Big(\rho_t(y;\theta)\, \hat{A}(x,y), \; \text{clip}\big(\rho_t(y;\theta), 1-\epsilon_c, 1+\epsilon_c\big)\hat{A}(x,y) \Big) \right], \tag{1}$$

其中，x 表示输入，y 表示生成序列，π_{old} 是行为策略；$\rho_t(y;\theta) = \pi_\theta(y_t \mid x, y_{<t}) / \pi_{\text{old}}(y_t \mid x, y_{<t})$ 是第 t 步（对应第 t 个生成词元）的重要性比率，ϵ_c 是裁剪阈值。优势 $\hat{A}(x,y)$ 通过在每个提示内对奖励 $r(x,y)$ 做中心化得到：$\hat{A}(x,y) = r(x,y) - \mathbb{E}_{y'\sim\pi_{\text{old}}(\cdot|x)}[r(x,y')]$。移除裁剪（式 1 的红色项）后，若奖励的采样独立于回答，则训练目标的期望为零，无法提供有意义的学习信号。为展示这一点，我们考虑 GRPO 的三种不同**无裁剪变体**：在实现中禁用裁剪；增大小批次，使其与轨迹采样批次大小一致；或减小轨迹采样批次，使每批轨迹只进行一次梯度更新。[5]如图 4 前三个面板所示（无裁剪变体），随机奖励无法带来一致的表现改善。相比之下，启用裁剪（右下）会产生稳定且一致的提升。

GRPO 的裁剪偏置可以诱发随机奖励训练信号。我们分析随机奖励下 GRPO 中裁剪的作用，完整推导见附录 B。概括而言，裁剪会在梯度更新中引入偏置，该偏置取决于当前策略的词元概率偏离行为策略词元概率的程度。提取出与奖励无关的标量项后，随机奖励诱导的期望梯度可写为（忽略一个正的常数因子）：

$$\mathbb{E}[\nabla_\theta J(\theta)] \propto \mathbb{E}_{x,y}\left[\begin{cases} \nabla_\theta \log \pi_{\theta,x}(y_t), & R_\theta < 1-\epsilon_c, \\ 0, & |R_\theta - 1| \le \epsilon_c, \\ -\nabla_\theta \log \pi_{\theta,x}(y_t), & R_\theta > 1+\epsilon_c, \end{cases} \right], \tag{2}$$

其中 $R_\theta = \pi_{\theta,x}(y_t)/\pi_{\text{old},x}(y_t)$。[6]这一形式表明，即使奖励不含信息，裁剪也会提高策略下本已具有较高概率的词元的概率，同时抑制过大的偏离。下面用一个例子说明这一效应：

> **示例**。设裁剪阈值 $\epsilon_c = 0.2$，考虑策略下概率不同的两个词元。对于低概率与高概率词元，相同的相对裁剪阈值会在 $[0,1]$ 内产生不对称的绝对裁剪范围。 若 $\pi_{\text{old},x}(y_t) = 0.85$（经常被采样），则策略概率必须超过 $\pi_{\text{old},x}(y_t)\cdot(1+\epsilon_c) = 1.02$，才会触发上侧裁剪。由于 $\pi_{\theta,x}(y_t) \le 1$，永远不可能达到这一阈值。因此，该词元受到非负的梯度偏置，其高概率得到强化。 相反，若 $\pi_{\text{old},x}(y_t) = 0.02$（很少被采样），当 $\pi_{\theta,x}(y_t) > 0.024$ 时便会触发上侧裁剪。$\pi_{\theta,x}(y_t)$ 的小幅增加就很容易越过阈值，使该词元受到压低其概率的负梯度偏置。 因此，裁剪偏置会不对称地抑制低概率词元，并强化高概率词元。

[3]我们假设，错误答案奖励能够提供训练信号，是因为许多错误答案仍接近真实答案，而且它们隐式地充当格式奖励，鼓励模型给出可提取的答案。

[4]这里省略 KL 正则项；实验中禁用了该项。

[5]后两种变体使每批轨迹更新时满足 $\pi_\theta = \pi_{\text{old}}$，从而 $\rho_t = 1$，因此从构造上消除了裁剪的作用。

[6]译注：正文以 $\nabla_\theta \log \pi_{\theta,x}(y_t)$ 表示梯度方向，而附录 B.1.2 的完整推导使用 $\nabla_\theta R_\theta$。二者满足 $\nabla_\theta R_\theta = R_\theta \nabla_\theta \log \pi_{\theta,x}(y_t)$；原文在正文中略去因子后的比例写法未进一步说明，译文保留两处原式。

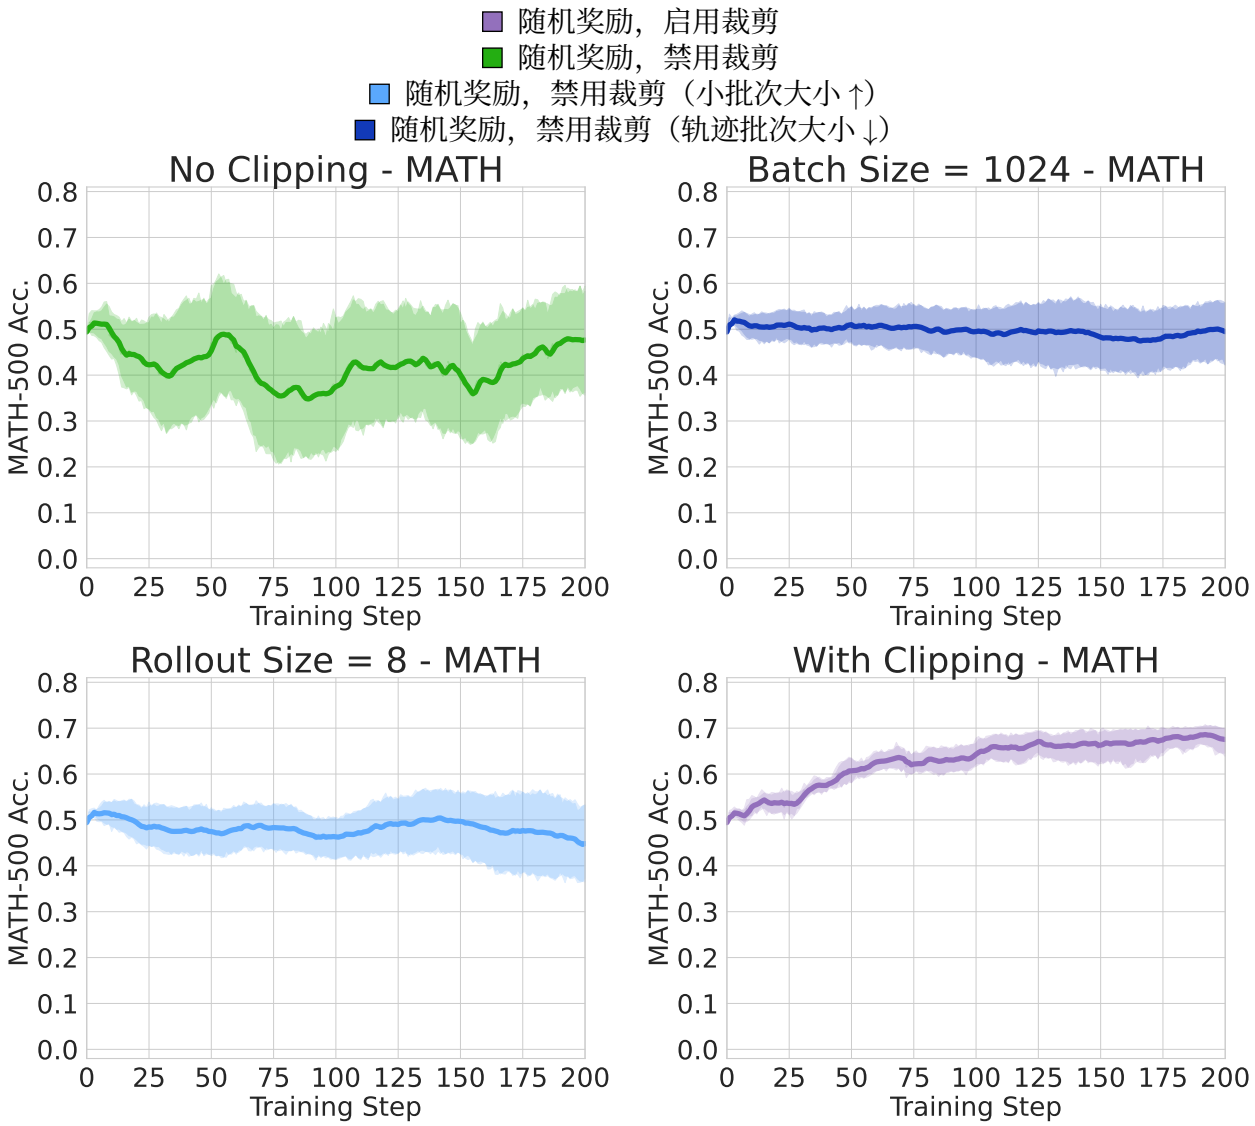


图 4: Qwen2.5-Math-7B 使用随机奖励时，对 GRPO 裁剪项进行消融的多随机种子平均表现。前三个面板对应无裁剪变体（见正文），最后一个面板启用裁剪。只有存在裁剪时，随机奖励才能带来一致的改善。

附录 B 表明，这一效应在不同随机奖励分布下均持续存在，说明其具有稳定性。我们的发现呼应了 Yu et al. (2025) 的直觉；他们表明，在使用真实标签的 RLVR 中，裁剪偏置会减少探索、增加利用。

5 案例研究：作为代表性既有行为的代码推理

前文表明，在相同弱奖励或伪奖励信号下训练，不同模型的结果可能有显著差异。本节提出一个解释这些差异的一般假说，并通过聚焦于 Qwen 模型中一种具有代表性的既有行为的案例研究来检验它。我们的核心假说是：RLVR 结果的差异源自预训练中获得的推理策略不同。有些策略很容易被 RLVR 放大，而另一些策略可能难以诱发，或者根本不存在，从而使不同模型家族的训练动态出现分歧。

我们研究其中一种策略：利用代码支持数学推理。Qwen-Math 模型能够有效地使用这一策略，而其他模型家族的运用程度较低（第 5.1 节）。追踪 RLVR 训练过程中代码推理的普及程度后，我们发现与这一假说一致的证据（第 5.2 节）。需要指出，我们将代码推理作为一个可控、可观察的例子，用于研究 RLVR 与既有内部策略之间的相互作用，而不是把它当作对模型行为的穷尽描述。

表 2: 强化学习训练前，MATH-500 回答中包含 Python 代码的比例，以及代码回答和纯自然语言回答各自的准确率。Qwen2.5-Math 模型在使用代码时准确率更高，而其他模型无法从代码推理中受益。其余模型（Qwen2.5-1.5B 、OLMo2-7B 、Llama3.1-8B-Instruct 、Llama3.2-3B-Instruct ）从不生成代码。译注：本表 Qwen2.5-Math-7B 纯自然语言准确率为 35.0%，引言中同一项写为 28.0%；按原文分别保留。

模型	Qwen2.5-Math-7B	Qwen2.5-Math-1.5B	Qwen2.5-7B	OLMo2-7B-SFT
代码频率	65.0	53.6	92.2	98.0
代码准确率	60.9	52.6	39.9	21.0
语言准确率	35.0	17.2	61.5	40.0

5.1 不同模型的既有推理策略存在差异

我们分析不同模型在 MATH-500 上的推理轨迹，观察到既有策略之间的明显差异。尽管无法执行代码，Qwen2.5-Math-7B 仍经常在推理中生成 Python 代码（占回答的 65.0%）；我们将这一行为称为代码推理。

逐字数据集实例及对应模型输出未在公开版收录。

图 5: 原文定性实例的公开版占位。

关键的是，Qwen2.5-Math-7B 的代码推理与正确性高度相关。如表 2 所示，包含代码的回答，其准确率显著高于不含代码的回答。Qwen2.5-Math-1.5B 也表现出类似行为，但其他模型并非如此。我们把这些模型分为无代码型（No-Code，例如 Llama、Qwen2.5-1.5B 、OLMo2-7B ）和低效代码型（Bad-Code，例如 OLMo2-7B-SFT 、Qwen2.5-7B ）：前者不生成代码，后者频繁生成代码，但表现反而更差。因此，在 RLVR 之前，有效代码推理似乎是 Qwen2.5-Math 的一项独特既有能力。

附录 K 给出进一步分析，为 Qwen2.5-Math-7B 模型代码推理的来源提供线索。注意，代码推理并非完整解释：其他行为也容易被诱发，且往往与性能相关。附录 G 简要讨论了另一种此类行为，即无重复生成。此外，我们发现 Qwen2.5-Math-7B 的初始表现对评估提示敏感；附录 I 补充讨论了这一影响。

5.2 伪奖励 RLVR 提高既有推理策略的权重

受上述观察启发，我们沿两个维度追踪 RLVR 训练过程中模型推理行为的变化：（1）**准确率**：模型在 MATH-500 上的平均准确率；（2）**代码推理频率**：包含字符串“`python`”的模型回答比例。我们发现，本文采用的奖励，包括随机和错误答案等伪奖励，主要通过诱发正确的推理策略，使 Qwen2.5-Math 和 Qwen2.5 获得准确率提升。

性能与代码推理频率相关。如图 6 所示，RLVR 训练前，Qwen2.5-Math-7B 在 65.0% 的 MATH-500 解答中使用代码推理。在采用弱奖励或伪奖励的 RLVR 下，代码频率迅速上升（15 步内达到约 90%，随机奖励下最高达到 95.6%），并与准确率增益紧密同步。采用真实标签奖励时，代码频率最初也上升，但随着自然语言推理改善，随后开始下降，说明学习已不再仅仅依赖代码。对于低效代码型模型，性能增益反而与代码使用减少相关。附录 H 对这些策略转换给出更多分析，表明伪奖励的增益主要出现在模型从文本推理转向代码推理时。

5.3 显式干预代码推理频率

通过观察，我们已表明，代码推理频率在 RLVR 期间上升，并与测试表现改善相关。本节研究显式诱发或抑制代码推理的影响。正文展示增加代码推理的结果，抑制代码推理的实验则放在附录 F。

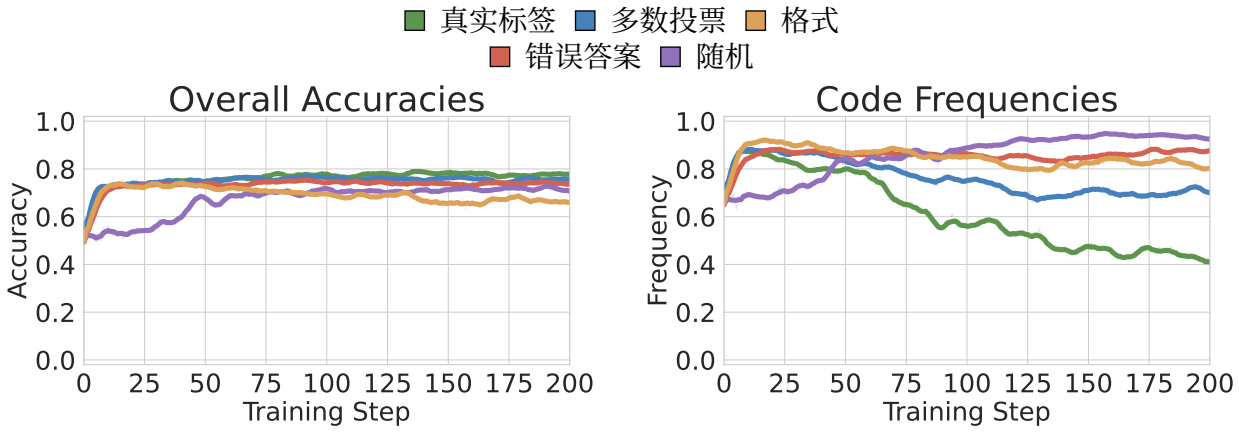
表 3: 增强提示以鼓励代码推理后，模型在 MATH-500 上的表现。本实验强制模型生成的第一句话为“Let’s solve this using Python.”（让我们用 Python 来解决这个问题）。对于代码推理先验较强的 Qwen2.5-Math 模型，这种“强制代码”提示策略显著提高测试准确率。

模型	原始	提示诱发	绝对差值
Qwen2.5-Math-1.5B	36.2%	60.4%	+24.2%
Qwen2.5-Math-7B	49.4%	64.4%	+15.0%
Qwen2.5-1.5B	3.0%	13.0%	+10.0%
Qwen2.5-7B	41.6%	22.2%	–19.4%
Llama3.2-3B-Instruct	36.8%	8.2%	–28.6%
Llama3.1-8B-Instruct	36.8%	15.2%	–21.6%
OLMo2-7B	9.0%	7.8%	–1.2%
OLMo2-7B-SFT	21.4%	18.6%	–2.8%

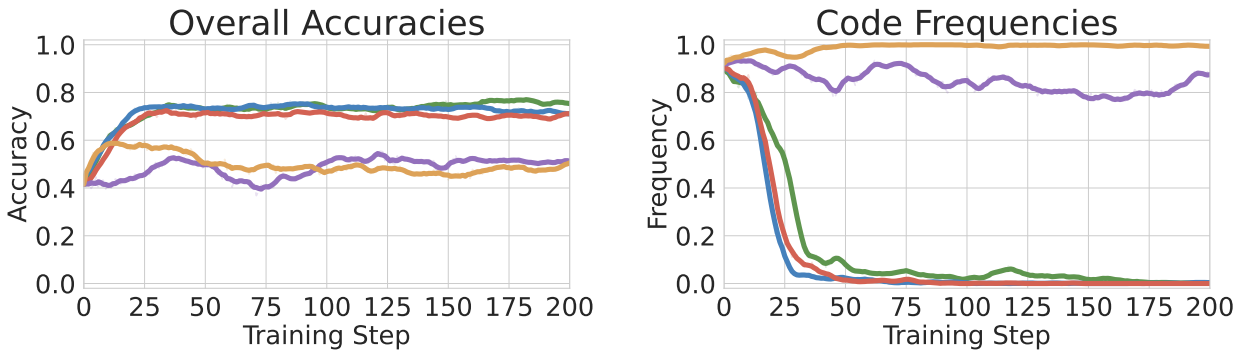
在这两个方向上，干预产生的结果均与我们的假说一致。

诱发代码推理改善 Qwen2.5-Math，却损害其他模型。我们通过（1）提示和（2）RLVR 诱发代码推理。使用提示（强制回答以“Let’s solve this using Python.”，即“让我们用 Python 来解决这个问题。”开头）后，Qwen2.5-Math-1.5B、Qwen2.5-Math-7B 和 Qwen2.5-1.5B 的 MATH-500 准确率分别提高 24.2、15.0 和 10.0 个百分点（表 3），而 Llama、OLMo2 等其他模型的表现下降，这与它们缺乏有效代码推理的观察一致（第 5.1 节）。

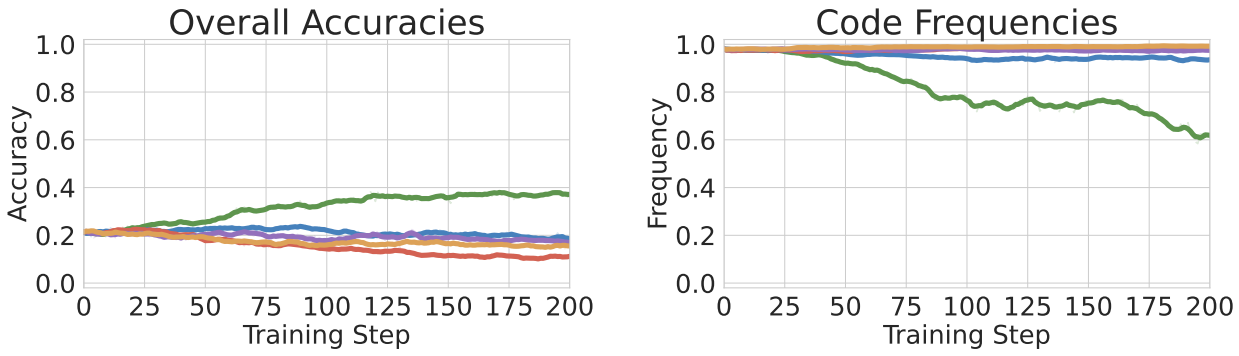
为了通过 RLVR 诱发代码推理，我们当且仅当回答包含字符串“`python`”时赋予正奖励（称为Python 奖励）。这使 Qwen2.5-Math-7B 的代码使用率在 20 个训练步内迅速超过 99%（图 7），并主要在 Qwen2.5-Math 中产生性能增益。对于这些模型，基于 RLVR 的诱发效果达到或超过了提示带来的增益，而其他模型的改善有限。



(a) Qwen2.5-Math-7B



(b) Qwen2.5-7B



(c) OLMo2-7B-SFT

图 6: 追踪采用不同奖励信号训练的 Qwen2.5-Math-7B 模型的 MATH-500 准确率（左）及包含 Python 代码的回答比例（右）。在弱奖励（格式）或伪奖励（随机、错误答案）下，准确率和代码频率均提高。相比之下，真实标签奖励训练在提高准确率的同时，代码频率最终下降，提示其改进机制不同。译注：图中还包括 Qwen2.5-7B 与 OLMo2-7B-SFT 两组面板，原图说明仅提及 Qwen2.5-Math-7B 。

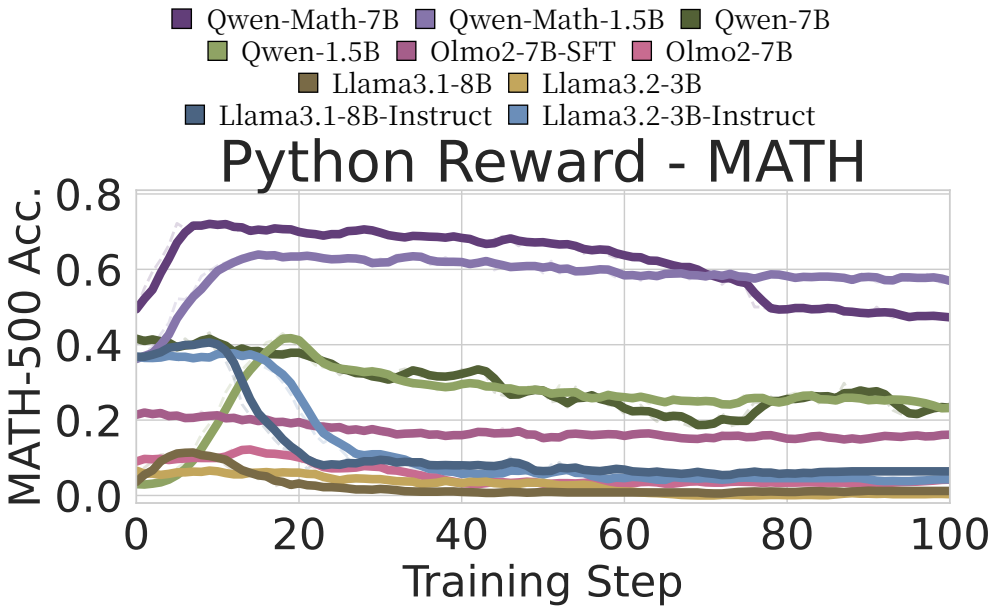


图 7: 使用 Python 奖励显式鼓励模型进行代码推理时的表现。这仅改善 Qwen2.5-Math 的表现。Qwen2.5-Math-7B 在 20 个训练步内，代码推理的生成比例就超过 99%。

6 相关工作

无监督强化学习。已有多种方法探索了无监督强化学习。Prasad et al. (2024) 提出自一致性偏好优化（ScPO），针对无监督问题，训练模型偏好一致的答案而非不一致的答案。类似地，测试时强化学习（TTRL）(Zuo et al., 2025) 利用采样输出的多数投票估计伪奖励，在数学推理任务上展现出显著提升。EMPO (Zhang et al., 2025) 改造 PPO (Schulman et al., 2017) 或 GRPO (Shao et al., 2024)，通过最小化查询在语义空间中的熵来计算奖励，从而实现无监督 RLVR。这些方法表明，模型内部一致性可以作为正确性的有效代理，但它们并未系统研究 RLVR 中不同种类的训练奖励如何影响不同模型家族。

面向语言模型的强化学习。强化学习方法显著推动了语言模型能力的发展。RLHF 已成为使模型与人类偏好对齐的标准技术 (Ouyang et al., 2022; Bai et al., 2022)，而 RLVR 已被证明对答案确定的任务有效 (Guo et al., 2025; Gao et al., 2024; Wen et al., 2025; Lambert et al., 2024; Luo et al., 2025)。传统上，这些方法依赖准确的监督信号，无论来自人类反馈还是可验证奖励。近期研究通过 AI 反馈机制 (Bai et al., 2022)探索减少对人工标注的依赖，并通过训练动态分析 (Zhao et al., 2025a)支持如下发现：强化学习主要是在放大预训练模型中已经潜藏的行为或能力 (Liu et al., 2025; Yue et al., 2025)。

7 结论

我们的发现具有三项主要含义：基础模型的预训练显著影响 RLVR 的结果；即使监督被破坏或是虚假的，只要它触发了已有的有益行为，也能增强推理表现；在一个模型家族中观察到的效应，可能无法推广到其他模型家族。我们的工作强调，在评估强化学习技术时，应当（1）在预训练分布不同的多种模型上测试；（2）与格式奖励、随机奖励等多种不同基线进行比较。

本研究并不倡导将伪奖励作为提升模型能力的训练策略。相反，引入伪奖励仅为进行受控分析，因为在部署系统中误用它们可能导致不可靠或不理想的行为。总体而言，本研究的预期影响是提高强化学习研究的严谨性与稳健性，而非促成新的应用。

致谢

感谢 Hamish Ivison 和 Trung Vu 富有启发性的讨论。本研究部分由美国国防高级研究计划局（DARPA）的 SciFy 项目资助（协议编号 HR00112520300）。文中观点仅代表作者，不代表美国国防部或美国政府的官方政策或立场。本工作获得新加坡国家研究基金会、新加坡数字发展与新闻部国家 AI 小组的 AI 访问教授计划（项目编号 AIVP-2024-001），以及 Schmidt Sciences 的 AI2050 计划支持。本工作还获得 NSF 项目 2112471 和 2134012 支持。SG 获得 NSF GRFP 支持。SSD 感谢 NSF IIS-2110170、NSF DMS-2134106、NSF CCF-2212261、NSF IIS-2143493、NSF CCF-2019844、NSF IIS-2229881 以及斯隆研究奖学金的支持。

参考文献

AI, E., :, Shah, D. J., Rushton, P., Singla, S., Parmar, M., Smith, K., Vanjani, Y., Vaswani, A., Chaluvaraju, A., Hojel, A., Ma, A., Thomas, A., Polloreno, A., Tanwer, A., Sibai, B. D., Mansingka, D. S., Shivaprasad, D., Shah, I., Stratos, K., Nguyen, K., Callahan, M., Pust, M., Iyer, M., Monk, P., Mazarakis, P., Kapila, R., Srivastava, S., and Romanski, T. Rethinking reflection in pre-training, 2025. URL https://arxiv.org/abs/2504.04022.

Bai, Y., Kadavath, S., Kundu, S., Askell, A., Kernion, J., Jones, A., Chen, A., Goldie, A., Mirhoseini, A., McKinnon, C., Chen, C., Olsson, C., Olah, C., Hernandez, D., Drain, D., Ganguli, D., Li, D., Tran-Johnson, E., Perez, E., Kerr, J., Mueller, J., Ladish, J., Landau, J., Ndousse, K., Lukosuite, K., Lovitt, L., Sellitto, M., Elhage, N., Schiefer, N., Mercado, N., DasSarma, N., Lasenby, R., Larson, R., Ringer, S., Johnston, S., Kravec, S., Showk, S. E., Fort, S., Lanham, T., Telleen-Lawton, T., Conerly, T., Henighan, T., Hume, T., Bowman, S. R., Hatfield-Dodds, Z., Mann, B., Amodei, D., Joseph, N., McCandlish, S., Brown, T., and Kaplan, J. Constitutional ai: Harmlessness from ai feedback, 2022. URL https://arxiv.org/abs/2212.08073.

Choshen, L., Fox, L., Aizenbud, Z., and Abend, O. On the weaknesses of reinforcement learning for neural machine translation, 2020. URL https://arxiv.org/abs/1907.01752.

Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., Letman, A., Mathur, A., Schelten, A., Yang, A., Fan, A., Goyal, A., Hartshorn, A. S., Yang, A., Mitra, A., Sravankumar, A., Korenev, A., Hinsvark, A., Rao, A., Zhang, A., Rodriguez, A., Gregerson, A., Spataru, A., Rozière, B., Biron, B., Tang, B., Chern, B., Caucheteux, C., Nayak, C., Bi, C., Marra, C., McConnell, C., Keller, C., Touret, C., Wu, C., Wong, C., tian Cantón Ferrer, C., Nikolaidis, C., Allonsius, D., Song, D., Pintz, D., Livshits, D., Esiobu, D., Choudhary, D., Mahajan, D., Garcia-Olano, D., Perino, D., Hupkes, D., Lakomkin, E., AlBadawy, E. A., Lobanova, E., Dinan, E., Smith, E. M., Radenovic, F., Zhang, F., Synnaeve, G., Lee, G., Anderson, G. L., Nail, G., Mialon, G., Pang, G., Cucurell, G., Nguyen, H., Korevaar, H., Xu, H., Touvron, H., Zarov, I., Ibarra, I. A., Kloumann, I. M., Misra, I., Evtimov, I., Copet, J., Lee, J., Geffert, J., Vranes, J., Park, J., Mahadeokar, J., Shah, J., van der Linde, J., Billock, J., Hong, J., Lee, J., Fu, J., Chi, J., Huang, J., Liu, J., Wang, J., Yu, J., Bitton, J., Spisak, J., Park, J., Rocca, J., Johnstun, J., Saxe, J., Jia, J.-Q., Alwala, K. V., Upasani, K., Plawiak, K., Li, K., neth Heafield, K.-, Stone, K. R., El-Arini, K., Iyer, K., Malik, K., ley Chiu, K., Bhalla, K., Rantala-Yeary, L., van der Maaten, L., Chen, L., Tan, L., Jenkins, L., Martin, L., Madaan, L., Malo, L., Blecher, L., Landzaat, L., de Oliveira, L., Muzzi, M., Pasupuleti, M., Singh, M., Paluri, M., Kardas, M., Oldham, M., Rita, M., Pavlova, M., Kambadur, M. H. M., Lewis, M., Si, M., Singh, M. K., Hassan, M., Goyal, N., Torabi, N., lay Bashlykov, N., Bogoychev, N., Chatterji, N. S., Duchenne, O., cCelebi, O., Alrassy, P., Zhang, P., Li, P., Vasic´, P., Weng, P., Bhargava, P., Dubal, P., Krishnan, P., Koura, P. S., Xu, P., He, Q., Dong, Q., Srinivasan, R., Ganapathy, R., Calderer, R., Cabral, R. S., Stojnic, R., Raileanu, R., Girdhar, R., Patel, R., main Sauvestre, R., nie Polidoro, R., Sumbaly, R., Taylor, R., Silva, R., Hou, R., Wang, R., Hosseini, S., hana Chennabasappa, S., Singh, S., Bell, S., Kim, S. S., Edunov, S., Nie, S., Narang, S., Raparthy, S. C., Shen, S., Wan, S., Bhosale, S., Zhang, S., Vandenhende, S., Batra, S., Whitman, S., Sootla, S., Collot, S., Gururangan, S., Borodinsky, S., Herman, T., Fowler, T., Sheasha, T., Georgiou, T., Scialom, T., Speckbacher, T., Mihaylov, T., Xiao, T., Karn, U., Goswami, V., Gupta, V., Ramanathan, V., Kerkez, V., Gonguet, V., ginie Do, V., Vogeti, V., Petrovic, V., Chu, W., Xiong, W., Fu, W., ney Meers, W., Martinet, X., Wang, X., Tan, X. E., Xie, X., Jia, X., Wang, X., Goldschlag, Y., Gaur, Y., Babaei, Y., Wen, Y., Song, Y., Zhang, Y., Li, Y., Mao, Y., Coudert, Z. D., Yan, Z., Chen, Z., Papakipos, Z., Singh, A. K., Grattafiori, A., Jain, A., Kelsey, A., Shajnfeld, A., Gangidi, A., Victoria, A., Goldstand, A., Menon, A., Sharma, A., Boesenberg, A., Vaughan, A., Baevski, A., Feinstein, A., Kallet, A., Sangani, A., Yunus, A., Lupu, A., Alvarado, A., Caples, A., Gu, A., Ho, A., Poulton, A., Ryan, A., Ramchandani, A., Franco, A., Saraf, A., Chowdhury, A., Gabriel, A., Bharambe, A., Eisenman, A., Yazdan, A., James, B., Maurer, B., Leonhardi, B., Huang, P.-Y. B., Loyd, B., de Paola, B., Paranjape, B., Liu, B., Wu, B., Ni, B., Hancock, B., Wasti, B., Spence, B., Stojkovic, B., Gamido, B., Montalvo, B., Parker, C., Burton, C., Mejia, C., Wang, C., Kim, C., Zhou, C., Hu, C., Chu, C.-H., Cai, C., Tindal, C., Feichtenhofer, C., Civin, D., Beaty, D., Kreymer, D., Li, S.-W., Wyatt, D., Adkins, D., Xu, D., Testuggine, D., David, D., Parikh, D., Liskovich, D., Foss, D., Wang, D., Le, D., Holland, D., Dowling, E., Jamil, E., Montgomery, E., Presani, E., Hahn, E., Wood, E., Brinkman, E., Arcaute, E., Dunbar, E., Smothers, E., Sun, F., Kreuk, F., Tian, F., Ozgenel, F., Caggioni, F., Guzm' an, F., Kanayet, F. J., Seide, F., Florez, G. M., Schwarz, G., Badeer, G., Swee, G., Halpern, G., Thattai, G., Herman, G., Sizov, G. G., Zhang, G., Lakshminarayanan, G., Shojanazeri, H., Zou, H., Wang, H., Zha, H., Habeeb, H., Rudolph, H., Suk, H., Aspegren, H., Goldman, H., Molybog, I., Tufanov, I., Veliche, I.-E., Gat, I., Weissman, J., Geboski, J., Kohli, J., Asher, J., Gaya, J.-B., Marcus, J., Tang, J., Chan, J., Zhen, J., Reizenstein, J., Teboul, J., Zhong, J., Jin, J., Yang, J., Cummings, J., Carvill, J., Shepard, J., McPhie, J., Torres, J., Ginsburg, J., Wang, J., Wu, K., KamHou, U., Saxena, K., Prasad, K., Khandelwal, K., Zand, K., Matosich, K., Veeraraghavan, K., Michelena, K., Li, K., Huang, K., Chawla, K., Lakhotia, K., Huang, K., Chen, L., Garg, L., Lavender, A., Silva, L., Bell, L., Zhang, L., Guo, L., Yu, L., Moshkovich, L., Wehrstedt, L., Khabsa, M., Avalani, M., Bhatt, M., Tsimpoukelli, M., Mankus, M., Hasson, M., Lennie, M., Reso, M., Groshev, M., Naumov, M., Lathi, M., Keneally, M., Seltzer, M. L., Valko, M., Restrepo, M., Patel, M., Vyatskov, M., Samvelyan, M., Clark, M., Macey, M., Wang, M., Hermoso, M. J., Metanat, M., Rastegari, M., Bansal, M., Santhanam, N., Parks, N., White, N., Bawa, N., Singhal, N., Egebo, N., Usunier, N., Laptev, N. P., Dong, N., Zhang, N., Cheng, N., Chernoguz, O., Hart, O., Salpekar, O., Kalinli, O., Kent, P., Parekh, P., Saab, P., Balaji, P., dro Rittner, P., Bontrager, P., Roux, P., Dollár, P., Zvyagina, P., Ratanchandani, P., Yuvraj, P., Liang, Q., Alao, R., Rodriguez, R., Ayub, R., Murthy, R., Nayani, R., Mitra, R., Li, R., Hogan, R., Battey, R., Wang, R., Maheswari, R., Howes, R., Rinott, R., Bondu, S. J., Datta, S., Chugh, S., Hunt, S., Dhillon, S., Sidorov, S., Pan, S., Verma, S., Ya-

mamoto, S., Ramaswamy, S., Lindsay, S., Feng, S., Lin, S., Zha, S. C., Shankar, S., Zhang, S., Wang, S., Agarwal, S., Sajuyigbe, S., Chintala, S., Max, S., Chen, S., Kehoe, S., Satterfield, S., Govindaprasad, S., Gupta, S., Cho, S.-B., Virk, S., Subramanian, S., Choudhury, S., Goldman, S., Remez, T., Glaser, T., Best, T., Kohler, T., Robinson, T., Li, T., Zhang, T., Matthews, T., Chou, T., Shaked, T., Vontimitta, V., Ajayi, V., Montanez, V., Mohan, V., Kumar, V. S., Mangla, V., Ionescu, V., Poenaru, V. A., Mihailescu, V. T., Ivanov, V., Li, W., Wang, W., Jiang, W., Bouaziz, W., Constable, W., Tang, X., Wang, X., Wu, X., Wang, X., Xia, X., Wu, X., Gao, X., Chen, Y., Hu, Y., Jia, Y., Qi, Y., Li, Y., Zhang, Y., Zhang, Y., Adi, Y., Nam, Y., Wang, Y., Hao, Y., Qian, Y., He, Y., Rait, Z., DeVito, Z., Rosnbrick, Z., Wen, Z., Yang, Z., and Zhao, Z. The llama 3 herd of models. ArXiv, abs/2407.21783, 2024. URL https://api.semanticscholar.org/CorpusID:271571434.

Gandhi, K., Chakravarthy, A., Singh, A., Lile, N., and Goodman, N. D. Cognitive behaviors that enable self-improving reasoners, or, four habits of highly effective stars. arXiv preprint arXiv:2503.01307, 2025.

Gao, J., Xu, S., Ye, W., Liu, W., He, C., Fu, W., Mei, Z., Wang, G., and Wu, Y. On designing effective rl reward at training time for llm reasoning. arXiv preprint arXiv:2410.15115, 2024.

Gao, Z., Chen, L., Zhou, J., and Dai, B. One-shot entropy minimization, 2025. URL https://arxiv.org/abs/2505.20282.

Guo, D., Yang, D., Zhang, H., Song, J., Wang, P., Zhu, Q., Xu, R., Zhang, R., Ma, S., Bi, X., Zhang, X., Yu, X., Wu, Y., Wu, Z. F., Gou, Z., Shao, Z., Li, Z., Gao, Z., Liu, A., Xue, B., Wang, B., Wu, B., Feng, B., Lu, C., Zhao, C., Deng, C., Ruan, C., Dai, D., Chen, D., Ji, D., Li, E., Lin, F., Dai, F., Luo, F., Hao, G., Chen, G., Li, G., Zhang, H., Xu, H., Ding, H., Gao, H., Qu, H., Li, H., Guo, J., Li, J., Chen, J., Yuan, J., Tu, J., Qiu, J., Li, J., Cai, J. L., Ni, J., Liang, J., Chen, J., Dong, K., Hu, K., You, K., Gao, K., Guan, K., Huang, K., Yu, K., Wang, L., Zhang, L., Zhao, L., Wang, L., Zhang, L., Xu, L., Xia, L., Zhang, M., Zhang, M., Tang, M., Zhou, M., Li, M., Wang, M., Li, M., Tian, N., Huang, P., Zhang, P., Wang, Q., Chen, Q., Du, Q., Ge, R., Zhang, R., Pan, R., Wang, R., Chen, R. J., Jin, R. L., Chen, R., Lu, S., Zhou, S., Chen, S., Ye, S., Wang, S., Yu, S., Zhou, S., Pan, S., Li, S. S., Zhou, S., Wu, S., Yun, T., Pei, T., Sun, T., Wang, T., Zeng, W., Liu, W., Liang, W., Gao, W., Yu, W., Zhang, W., Xiao, W. L., An, W., Liu, X., Wang, X., Chen, X., Nie, X., Cheng, X., Liu, X., Xie, X., Liu, X., Yang, X., Li, X., Su, X., Lin, X., Li, X. Q., Jin, X., Shen, X., Chen, X., Sun, X., Wang, X., Song, X., Zhou, X., Wang, X., Shan, X., Li, Y. K., Wang, Y. Q., Wei, Y. X., Zhang, Y., Xu, Y., Li, Y., Zhao, Y., Sun, Y., Wang, Y., Yu, Y., Zhang, Y., Shi, Y., Xiong, Y., He, Y., Piao, Y., Wang, Y., Tan, Y., Ma, Y., Liu, Y., Guo, Y., Ou, Y., Wang, Y., Gong, Y., Zou, Y., He, Y., Xiong, Y., Luo, Y., You, Y., Liu, Y., Zhou, Y., Zhu, Y. X., Huang, Y., Li, Y., Zheng, Y., Zhu, Y., Ma, Y., Tang, Y., Zha, Y., Yan, Y., Ren, Z. Z., Ren, Z., Sha, Z., Fu, Z., Xu, Z., Xie, Z., Zhang, Z., Hao, Z., Ma, Z., Yan, Z., Wu, Z., Gu, Z., Zhu, Z., Liu, Z., Li, Z., Xie, Z., Song, Z., Pan, Z., Huang, Z., Xu, Z., Zhang, Z., and Zhang, Z. Deepseek-r1 incentivizes reasoning in llms through reinforcement learning. Nature, 645(8081):633–638, September 2025. ISSN 1476-4687. doi: 10.1038/s41586-025-09422-z. URL http://dx.doi.org/10.1038/s41586-025-09422-z.

Hendrycks, D., Burns, C., Kadavath, S., Arora, A., Basart, S., Tang, E., Song, D., and Steinhardt, J. Measuring mathematical problem solving with the math dataset. arXiv preprint arXiv:2103.03874, 2021.

Hochlehnert, A., Bhatnagar, H., Udandarao, V., Albanie, S., Prabhu, A., and Bethge, M. A sober look at progress in language model reasoning: Pitfalls and paths to reproducibility, 2025. URL https://arxiv.org/abs/2504.07086.

Hu, J., Wu, X., Shen, W., Liu, J. K., Zhu, Z., Wang, W., Jiang, S., Wang, H., Chen, H., Chen, B., Fang, W., Xianyu, Cao, Y., Xu, H., and Liu, Y. Openrlhf: An easy-to-use, scalable and high-performance rlhf framework, 2025a. URL https://arxiv.org/abs/2405.11143.

Hu, J., Zhang, Y., Han, Q., Jiang, D., Zhang, X., and Shum, H.-Y. Open-reasoner-zero: An open source approach to scaling up reinforcement learning on the base model. arXiv preprint arXiv:2503.24290, 2025b.

Lambert, N., Morrison, J., Pyatkin, V., Huang, S., Ivison, H., Brahman, F., Miranda, L. J. V., Liu, A., Dziri, N., Lyu, S., Gu, Y., Malik, S., Graf, V., Hwang, J. D., Yang, J., Bras, R. L., Tafjord, O., Wilhelm, C., Soldaini, L., Smith, N. A., Wang, Y., Dasigi, P., and Hajishirzi, H. Tülu 3: Pushing frontiers in open language model post-training. 2024.

Li, J., Beeching, E., Tunstall, L., Lipkin, B., Soletskyi, R., Huang, S. C., Rasul, K., Yu, L., Jiang, A., Shen, Z., Qin, Z., Dong, B., Zhou, L., Fleureau, Y., Lample, G., and Polu, S. Numinamath. [https://huggingface.co/AI-MO/NuminaMath-CoT](https://github.com/project-numina/aimo-progress-prize/blob/main/report/numina_dataset.pdf), 2024.

Lightman, H., Kosaraju, V., Burda, Y., Edwards, H., Baker, B., Lee, T., Leike, J., Schulman, J., Sutskever, I., and Cobbe, K. Let' s verify step by step. In The Twelfth International Conference on Learning Representations, 2023.

Liu, Z., Chen, C., Li, W., Qi, P., Pang, T., Du, C., Lee, W. S., and Lin, M. Understanding r1-zero-like training: A critical perspective. arXiv preprint arXiv:2503.20783, 2025.

Luo, M., Tan, S., Wong, J., Shi, X., Tang, W. Y., Roongta, M., Cai, C., Luo, J., Li, L. E., Popa, R. A., and Stoica, I. Deepscaler: Surpassing o1-preview with a 1.5b model by scaling rl. https://pretty-radio-b75.notion.site/DeepScaleR-Surpassing-O1-Preview-with-a-1-5B-Model-by-Scaling-RL-19681902c1468005bed8ca303013a4e2, 2025. Notion Blog.

OLMo, T., Walsh, P., Soldaini, L., Groeneveld, D., Lo, K., Arora, S., Bhagia, A., Gu, Y., Huang, S., Jordan, M., Lambert, N., Schwenk, D., Tafjord, O., Anderson, T., Atkinson, D., Brahman, F., Clark, C., Dasigi, P., Dziri, N., Guerquin, M., Ivison, H., Koh, P. W., Liu, J., Malik, S., Merrill, W., Miranda, L. J. V., Morrison, J. D., Murray, T. C., Nam, C., Pyatkin, V., Rangapur, A., Schmitz, M., Skjonsberg, S., Wadden, D., Wilhelm, C., Wilson, M., Zettlemoyer, L. S., Farhadi, A., Smith, N. A., and Hajishirzi, H. 2 olmo 2 furious. ArXiv, abs/2501.00656, 2024. URL https://api.semanticscholar.org/CorpusID:275213098.

Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J., and Lowe, R. Training language models to follow instructions with human feedback. Advances in neural information processing systems, 35:27730–27744, 2022.

Prabhudesai, M., Chen, L., Ippoliti, A., Fragkiadaki, K., Liu, H., and Pathak, D. Maximizing confidence alone improves reasoning, 2025. URL https://arxiv.org/abs/2505.22660.

Prasad, A., Yuan, W., Pang, R. Y., Xu, J., Fazel-Zarandi, M., Bansal, M., Sukhbaatar, S., Weston, J., and Yu, J. Self-consistency preference optimization. arXiv preprint arXiv:2411.04109, 2024.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. Proximal policy optimization algorithms, 2017. URL https://arxiv.org/abs/1707.06347.

Sclar, M., Choi, Y., Tsvetkov, Y., and Suhr, A. Quantifying language models' sensitivity to spurious features in prompt design or: How i learned to start worrying about prompt formatting, 2024. URL https://arxiv.org/abs/2310.11324.

Shafayat, S., Tajwar, F., Salakhutdinov, R., Schneider, J., and Zanette, A. Can large reasoning models self-train?, 2025. URL https://arxiv.org/abs/2505.21444.

Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y. K., Wu, Y., and Guo, D. Deepseekmath: Pushing the limits of mathematical reasoning in open language models, 2024. URL https://arxiv.org/abs/2402.03300.

Wang, J., Fang, M., Wan, Z., Wen, M., Zhu, J., Liu, A., Gong, Z., Song, Y., Chen, L., Ni, L. M., Yang, L., Wen, Y., and Zhang, W. Openr: An open source framework for advanced reasoning with large language models, 2024. URL https://arxiv.org/abs/2410.09671.

Wang, S., Yu, L., Gao, C., Zheng, C., Liu, S., Lu, R., Dang, K., Chen, X., Yang, J., Zhang, Z., Liu, Y., Yang, A., Zhao, A., Yue, Y., Song, S., Yu, B., Huang, G., and Lin, J. Beyond the 80/20 rule: High-entropy minority tokens drive effective reinforcement learning for llm reasoning, 2025a. URL https://arxiv.org/abs/2506.01939.

Wang, Y., Yang, Q., Zeng, Z., Ren, L., Liu, L., Peng, B., Cheng, H., He, X., Wang, K., Gao, J., Chen, W., Wang, S., Du, S. S., and Shen, Y. Reinforcement learning for reasoning in large language models with one training example, 2025b. URL https://arxiv.org/abs/2504.20571.

Wen, L., Cai, Y., Xiao, F., He, X., An, Q., Duan, Z., Du, Y., Liu, J., Tang, L., Lv, X., Zou, H., Deng, Y., Jia, S., and Zhang, X. Light-r1: Curriculum SFT, DPO and RL for long COT from scratch and beyond. In Rehm, G. and Li, Y. (eds.), Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 6: Industry Track), pp. 318–327, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-288-6. doi: 10.18653/v1/2025.acl-industry.24. URL https://aclanthology.org/2025.acl-industry.24/.

Xie, T., Gao, Z., Ren, Q., Luo, H., Hong, Y., Dai, B., Zhou, J., Qiu, K., Wu, Z., and Luo, C. Logic-rl: Unleashing llm reasoning with rule-based reinforcement learning. arXiv preprint arXiv:2502.14768, 2025.

Yang, A., Zhang, B., Hui, B., Gao, B., Yu, B., Li, C., Liu, D., Tu, J., Zhou, J., Lin, J., Lu, K., Xue, M., Lin, R., Liu, T., Ren, X., and Zhang, Z. Qwen2.5-math technical report: Toward mathematical expert model via self-improvement, 2024a. URL https://arxiv.org/abs/2409.12122.

Yang, Q. A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Li, C., Liu, D., Huang, F., Dong, G., Wei, H., Lin, H., Yang, J., Tu, J., Zhang, J., Yang, J., Yang, J., Zhou, J., Lin, J., Dang, K., Lu, K., Bao, K., Yang, K., Yu, L., Li, M., Xue, M., Zhang, P., Zhu, Q., Men, R., Lin, R., Li, T., Xia, T., Ren, X., Ren, X., Fan, Y., Su, Y., Zhang, Y.-C., Wan, Y., Liu, Y., Cui, Z., Zhang, Z., Qiu, Z., Quan, S., and Wang, Z. Qwen2.5 technical report. ArXiv, abs/2412.15115, 2024b. URL https://api.semanticscholar.org/CorpusID:274859421.

Yu, Q., Zhang, Z., Zhu, R., Yuan, Y., Zuo, X., YuYue, Dai, W., Fan, T., Liu, G., Liu, J., Liu, L., Liu, X., Lin, H., Lin, Z., Ma, B., Sheng, G., Tong, Y., Zhang, C., Zhang, M., Zhang, R., Zhang, W., Zhu, H., Zhu, J., Chen, J., Chen, J., Wang, C., Yu, H., Song, Y., Wei, X., Zhou, H., Liu, J., Ma, W.-Y., Zhang, Y.-Q., Yan, L., Wu, Y., and Wang, M. DAPO: An open-source LLM reinforcement learning system at scale. In The Thirty-ninth Annual Conference on Neural Information Processing Systems, 2025. URL https://openreview.net/forum?id=2a36EMSSTp.

Yue, Y., Chen, Z., Lu, R., Zhao, A., Wang, Z., Song, S., and Huang, G. Does reinforcement learning really incentivize reasoning capacity in llms beyond the base model? arXiv preprint arXiv:2504.13837, 2025.

Zeng, W., Huang, Y., Liu, Q., Liu, W., He, K., Ma, Z., and He, J. Simplerl-zoo: Investigating and taming zero reinforcement learning for open base models in the wild. arXiv preprint arXiv:2503.18892, 2025.

Zhang, Q., Wu, H., Zhang, C., Zhao, P., and Bian, Y. Right question is already half the answer: Fully unsupervised llm reasoning incentivization. arXiv preprint arXiv:2504.05812, 2025.

Zhao, R., Meterez, A., Kakade, S., Pehlevan, C., Jelassi, S., and Malach, E. Echo chamber: Rl post-training amplifies behaviors learned in pretraining. arXiv preprint arXiv:2504.07912, 2025a.

Zhao, X., Kang, Z., Feng, A., Levine, S., and Song, D. Learning to reason without external rewards. arXiv preprint arXiv:2505.19590, 2025b.

Zuo, Y., Zhang, K., Qu, S., Sheng, L., Zhu, X., Qi, B., Sun, Y., Cui, G., Ding, N., and Zhou, B. Ttrl: Test-time reinforcement learning. arXiv preprint arXiv:2504.16084, 2025.

附录

A 实验设置 **21**
A.1 GRPO 预备知识 21
A.2 数据集与模型 21
A.3 训练配置 21
A.4 解码配置 21
A.5 计算资源 21
A.6 可视化 22
A.7 TTRL 与单样本强化学习的实验设置 22

B 随机奖励这一奇特案例 **22**
B.1 猜想：裁剪偏置在随机奖励下带来训练信号 23
B.2 无裁剪 RLVR 的高度随机性 26

C AMC 补充结果 **27**

D AIME 2024 与 AIME 2025 补充结果 **27**
D.1 伪奖励使 Qwen2.5-Math 获得显著 RLVR 增益 28
D.2 对其他模型的泛化及其局限 28

E 在 Qwen 以外的模型上检验现有方法 **30**

F 抑制代码推理的复合奖励 **30**

G 代码推理之外：RLVR 易于诱发的另一种有益模式 **30**

H RLVR 期间的推理策略转换 **30**

I 伪提示：Qwen2.5-Math-7B 对提示异乎寻常的高度敏感性 **31**
I.1 现有提示 32
I.2 伪提示 32

J 已接受强化学习训练模型的补充结果 **32**

K Qwen2.5-Math-7B 代码推理行为的定性分析 **33**

A 实验设置

A.1 GRPO 预备知识

记输入提示为 x，对应的模型采样轨迹为 y。记第 i 条轨迹 y 的第 t 个词元为 y_t，其中 $1 \le t \le |y|$。Shao et al. (2024) 提出的 GRPO 损失包含以下组成部分：对于每个提示 x，计算组内均值 $\bar{r}_x$ 与标准差 σ_x。归一化的组相对优势为 $\hat{A}(x,y) = \frac{r(x,y)-\bar{r}_x}{\sigma_x}$。令 π_{old} 为生成这些轨迹的行为策略，π_{ref} 为冻结的参考策略（例如初始监督模型）。记词元级重要性比率为 $\rho_t(y;\theta) = \frac{\pi_\theta(y_t|x,y_{<t})}{\pi_{\text{old}}(y_t|x,y_{<t})}$，其中 t 为词元索引。给定 PPO 式裁剪阈值 ϵ_c 和 KL 惩罚权重 λ，要最大化的代理目标为：

$$
\begin{aligned}
J(\theta) =& \mathbb{E}_{x\sim\mathcal{D},y\sim\pi_{\text{old}}(\cdot|x)}\left[\sum_{t=1}^{|y|}\min\Big(\rho_t(y;\theta)\,\hat{A}(x,y),\,\text{clip}\big(\rho_t(y;\theta),1-\epsilon_c,1+\epsilon_c\big)\,\hat{A}(x,y)\Big)\right] \\
&- \lambda\,\mathbb{E}_{x\sim\mathcal{D}}\Big[\text{KL}\big(\pi_\theta\|\pi_{\text{ref}}\big)\Big].
\end{aligned}
\tag{3}
$$

通常采用 KL 正则化来确保模型不会偏离冻结参考模型太远。不过，由于我们主要关注可验证奖励及其产生的信号，遵循 Liu et al. (2025)，我们认为分布偏移的影响相对次要。此外，KL 正则化会给分析引入混杂因素。近期工作也表明，移除 KL 项能获得更好的表现 (Hu et al., 2025b)。因此，本文设定 $\lambda = 0$。

A.2 数据集与模型

我们在三个典型的数学推理基准上开展实验：

- **MATH-500** (Hendrycks et al., 2021; Lightman et al., 2023)：MATH 数据集的一个标准化子集，侧重高级数学推理，包含代数、微积分和数论问题。
- **AMC** (Li et al., 2024)：美国数学竞赛数据集，包含从代数到组合数学和几何学的多样数学问题。此基准报告模型 8 次试验的平均表现（avg@8）。
- **AIME** (Li et al., 2024)：美国数学邀请赛数据集，由需要多步推理、具有挑战性的高中水平数学题组成。我们使用 2024 年与 2025 年的 AIME 题目评估，并报告模型 8 次试验的平均表现（avg@8）。

初始实验主要使用 Qwen2.5-Math-7B，这是一个专门针对数学推理任务调优、拥有 70 亿参数的语言模型。选择它的原因有二：（1）它在数学问题上的基线表现很强，同时计算效率足以支持多轮实验迭代；（2）此前研究经常使用该模型 (Zuo et al., 2025; Wang et al., 2025b)。

A.3 训练配置

除非另有说明，我们使用 8 块 GPU 训练每个模型，恒定学习率为 5×10^{-7}，小批次大小（梯度更新前处理的轨迹数量）为 128，轨迹采样批次大小（同时进行采样的提示数量）为 64。每个提示采集 16 条轨迹，用于计算 GRPO 更新的优势。采样温度设为 $\tau = 1$。训练中不使用 KL 散度损失或熵损失。

A.4 解码配置

解码时，pass@1 使用温度 0.0，pass@k 使用温度 0.6。其他超参数均遵循 Zuo et al. (2025) 代码库的默认值。

A.5 计算资源

实验中，每次 RLVR 运行在 8 块 A100 上约需 24 小时。

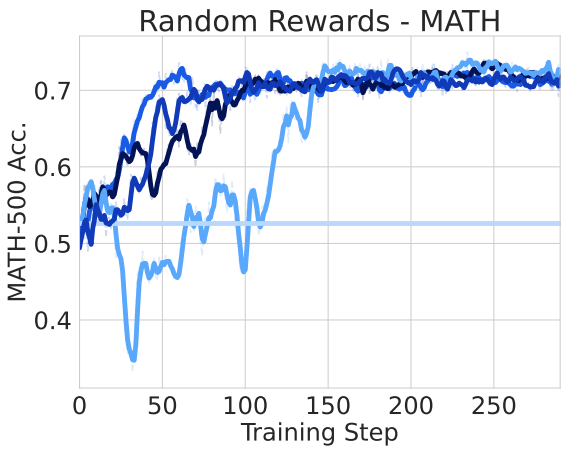


图 8: 使用 GRPO 和不同概率 $\gamma \in \{0.7, 0.5, 0.3, 0.001, 0\}$ 的随机奖励训练 Qwen2.5-Math-7B。除 $\gamma = 0$ 使模型完全不学习外，其他概率配置均使模型在一段随机游走后获得显著性能增益。而且，一旦进入高准确率区间，训练过程就能维持模型表现。

- 随机 $\gamma = 0.7$
- 随机 $\gamma = 0.5$
- 随机 $\gamma = 0.3$
- 随机 $\gamma = 0.001$
- 随机 $\gamma = 0$

A.6 可视化

所有图中，关注的指标均以 10 个训练步为窗口进行平滑，并叠加半透明虚线表示原始曲线。不平滑第 0 步的表现，它对应训练前基础模型的表现。最终表现报告最后一个训练步的平滑值。

A.7 TTRL 与单样本强化学习的实验设置

TTRL 设置。 我们遵循原 TTRL 论文 (Zuo et al., 2025) 的全部超参数，并使用其公开实现训练所有模型。由于计算资源有限，我们没有针对新纳入的基础模型广泛搜索超参数。注意，TTRL 的准确率不能与我们的多数投票奖励结果直接比较，因为：（a）TTRL 在无标签的测试提示上训练，而我们在规模大得多且与测试集不同的训练提示集上训练；（b）TTRL 根据在线策略的多数投票在训练期间更新标签，而我们仅在离线阶段赋予一次标签。

本文单样本强化学习设置与 Wang et al. (2025b) 的差异。 本文的单样本强化学习设置不使用熵损失，以便与其他实验设置保持一致并提高稳定性。然而，Wang et al. (2025b) 表明，熵损失可能进一步改善单样本强化学习的表现，以及饱和后的泛化。与 Wang et al. (2025b) 一样，我们对所有模型的单样本 RLVR 实验使用相同的训练样本 π_1（定义见 Wang et al. (2025b)）。该研究讨论了不同模型可能应当选择不同样本以获得更好的单样本 RLVR 训练效果，但由于尝试不同单样本示例的成本较高，所有实验均使用 π_1。特别是，与 Wang et al. (2025b) 使用熵损失的设置相比，这种设置差异可能使 Qwen2.5-7B 的性能出现明显差距（有熵损失时为 71.2%，无熵损失时为 54.8%）。

B 随机奖励这一奇特案例

本节研究伪奖励的一种特殊情形：随机奖励，即奖励随机分配且独立于模型采样轨迹。我们首先表明，随机奖励在多种非零奖励概率下均有效（图 8），确认这一观察具有稳定性。随后给出这一特殊情形下的详细梯度推导，并讨论我们关于随机奖励训练信号的一种潜在来源的假说：GRPO 更新中的裁剪偏置。

不同概率的随机奖励均能持续改善表现。 我们使用 GRPO 训练 Qwen2.5-Math-7B，以 $\texttt{Bernoulli}(\gamma)$ 随机变量分配奖励，其中 $\gamma \in \{0.7, 0.5, 0.3, 0.001, 0\}$。每个回答以概率 γ 获得奖励 1，否则获得 0。我们发现，所有非零概率配置在经历初始探索阶段后，都能成功产生显著性能增益，达到与真实标签奖励相近的表现（图 8）。$\gamma = 0$ 如预期一样没有带来改善，因为常数奖励不提供学习信号。收敛速度随 γ 变化，但各非零配置最终都达到相近的高性能区间，MATH-500 准确率提升 15–20 个百分点。

符号回顾。 输入提示记为 x，对应的模型采样轨迹记为 $\{y^{(1)}, \cdots, y^{(G)}\}$，其中 $G \in \mathbb{N}^+$ 为轨迹数量。此外，第 i 条轨迹 $y^{(i)}$ 的第 t 个词元记为 $y_t^{(i)}$，其中 $t \in \mathbb{N}^+$ 且 $1 \le t \le |y^{(i)}|$。GRPO 中归一化的组相对优势为 $\hat{A}(x,y) = \frac{r(x,y)-\bar{r}_x}{\sigma_x}$，其中 $\bar{r}_x$ 是组内均值，σ_x 是组内标准差。词元级重要性比率[7]为 $\rho_t(y;\theta) = \frac{\pi_{\theta,x}(y_t)}{\pi_{\text{old},x}(y_t)}$，其中 t 为词元索引。

B.1 猜想：裁剪偏置在随机奖励下带来训练信号

B.1.1 随机奖励的期望优势

我们考察奖励信号由随机变量 $\texttt{Bernoulli}(\gamma)$ 分配时的期望优势。对于提示 x 和轨迹 $\{y^{(i)}\}_{i=1}^G$，每个 $y^{(i)}$ 的奖励为 $r(x,y^{(i)}) \sim \texttt{Bernoulli}(\gamma)$，因此 x 的平均奖励的期望为 γ。假设 $\sigma_x = 0$ 时 $\hat{A}_i = 0$，则根据构造，G 条轨迹的归一化优势之和为

$$\sum_{i=1}^{G} \hat{A}(x,y^{(i)}) := \sum_{i=1}^{G} \frac{r(x,y^{(i)}) - \bar{r}_x}{\sigma_x} = \frac{\sum_{i=1}^{G} r(x,y^{(i)}) - G\bar{r}_x}{\sigma_x} = 0.$$

进一步，对于独立同分布且独立于给定样本的奖励，例如实验使用的随机奖励，有

$$\mathbb{E}\left(\sum_{i=1}^{G} \hat{A}(x,y^{(i)})\right) = G\mathbb{E}(\hat{A}) = 0 \quad \Longrightarrow \quad \mathbb{E}(\hat{A}) = 0.$$

GRPO 损失（式 3）中的裁剪项可以防止策略过度偏离先前策略，使训练稳定。近期研究指出，该项作用于比率 $\rho_t(y;\theta) = \pi_{\theta,x}(y_t)/\pi_{\text{old},x}(y_t)$，在真实标签奖励下会引入偏向利用的偏置 (Yu et al., 2025)。这里，我们分析随机奖励设置中的偏置，其中每条轨迹获得的优势与轨迹本身独立。

注意，引入裁剪后，损失不再处处可微。在 PyTorch 等实际实现中，数值被裁剪时，梯度会自动设为 0。为简便起见，我们假设不可微点处梯度为 0，并据此讨论损失函数的梯度。

B.1.2 随机奖励下裁剪偏置的梯度推导

本节推导裁剪因子所诱导的训练信号，并将其称为“裁剪偏置”。具体而言，我们把裁剪偏置定义为向 GRPO 目标加入裁剪后，期望梯度的差值[8]：

$$\texttt{Bias}(\nabla_\theta J(\theta)) = \mathbb{E}_{x,y}[\nabla_\theta J(\theta)] - \mathbb{E}_{x,y}[\nabla_\theta L^{\text{unclipped}}(\theta)].$$

如前文推导，$\mathbb{E}(\hat{A}(x,y_j)) = 0$。假设采用不含裁剪的简单损失，由于 $\hat{A}$ 独立于其他变量，不含裁剪项的策略梯度期望也显然为零：

$$\begin{aligned}
&\mathbb{E}_{x,y}[\nabla_\theta L^{\text{unclipped}}(\theta)] \\
=&\mathbb{E}_{x,y}\left[\frac{1}{|y|}\sum_{t=1}^{|y|} \nabla_\theta \rho_t(y;\theta)\,\hat{A}(x,y)\right] \\
=&\mathbb{E}(\hat{A})\mathbb{E}_{x,y}\left[\frac{1}{|y|}\sum_{t=1}^{|y|} \nabla_\theta \rho_t(y;\theta)\right] \\
=&0.
\end{aligned}$$

因此，随机奖励下的裁剪偏置为

$$\texttt{Bias}(\nabla_\theta J(\theta)) = \mathbb{E}[\nabla_\theta J(\theta)] - \mathbb{E}[\nabla_\theta L^{\text{unclipped}}(\theta)] = \mathbb{E}[\nabla_\theta J(\theta)].$$

[7]为简便起见，将 $\pi(y_t|x,y_{<t})$ 记为 $\pi_x(y_t)$；类似地，将 $\pi_\theta(y_t|x,y_{<t})$ 记为 $\pi_{\theta,x}(y_t)$，将 $\pi_{\text{old}}(y_t|x,y_{<t})$ 记为 $\pi_{\text{old},x}(y_t)$。

[8]为简便起见，将 $\mathbb{E}_{x\sim\mathcal{D},y\sim\pi_{\text{old}}(\cdot|x)}$ 记为 $\mathbb{E}_{x,y}$。

接下来计算裁剪偏置的精确形式，即随机奖励下 GRPO 的梯度。回顾式 3，我们要最大化的代理目标为：

$$J(\theta) = \min\Big(\rho_t(y;\theta)\,\hat{A}(x,y), \mathrm{clip}\big(\rho_t(y;\theta), 1-\epsilon_c, 1+\epsilon_c\big)\,\hat{A}(x,y)\Big).$$

为简便起见，进一步记词元级重要性比率为 $R_\theta = \rho_t(y;\theta) = \frac{\pi_{\theta,x}(y_t)}{\pi_{\mathrm{old},x}(y_t)}$，裁剪项为 $C = \mathrm{clip}(R_\theta, 1-\epsilon_c, 1+\epsilon_c)$，并把 $\hat{A}(x,y)$ 简记为 $\hat{A}$。于是有 $J(\theta) = \min(R_\theta \cdot \hat{A}, C \cdot \hat{A})$。下面根据 $\hat{A}$ 的符号，分析 GRPO 损失相对于策略模型参数 θ 的梯度。

如第 B.1 节所述，损失函数并非处处可微。因此，下文先讨论可微区域内的梯度，最后将不可微点的梯度设为 0。

情形 1： $\hat{A} \geq 0$**.** 当 $\hat{A} \geq 0$ 时，可以直接把 $\hat{A}$ 提到 min 函数外。因此，

$$J(\theta) = \min\big(R_\theta \cdot \hat{A}, C \cdot \hat{A}\big) = \hat{A} \cdot \min(R_\theta, C).$$

由于 C 定义为 $C = \mathrm{clip}(R_\theta, 1-\epsilon_c, 1+\epsilon_c)$，有：

- 若 $R_\theta < 1-\epsilon_c$，则 $C = 1-\epsilon_c$。于是，$\min(R_\theta, C) = R_\theta$.
- 若 $1-\epsilon_c \leq R_\theta \leq 1+\epsilon_c$，则 $C = R_\theta$。于是，$\min(R_\theta, C) = R_\theta$.
- 若 $R_\theta > 1+\epsilon_c$，则 $C = 1+\epsilon_c$。于是，$\min(R_\theta, C) = 1+\epsilon_c$.

综合以上情况，当 $\hat{A} \geq 0$ 时，目标为：

$$L^+(\theta) = \hat{A} \cdot \begin{cases} R_\theta, & \text{if } R_\theta < 1+\epsilon_c, \\ 1+\epsilon_c, & \text{if } R_\theta > 1+\epsilon_c. \end{cases}$$

此时相对于 θ 的梯度为：

$$\nabla_\theta L^+(\theta) = \hat{A} \cdot \begin{cases} \nabla_\theta R_\theta, & \text{if } R_\theta < 1+\epsilon_c, \\ 0, & \text{if } R_\theta > 1+\epsilon_c. \end{cases}$$

情形 2： $\hat{A} < 0$**.** 当 $\hat{A} < 0$ 时，乘以 $\hat{A}$ 会使 min 变为 max。因此，

$$L^-(\theta) = \min(R_\theta \cdot \hat{A}, C \cdot \hat{A}) = \hat{A} \cdot \max(R_\theta, C).$$

作类似分析，当 $\hat{A} < 0$ 时，相对于 θ 的梯度为：

$$\nabla_\theta L^-(\theta) = \hat{A} \cdot \begin{cases} 0, & \text{if } R_\theta < 1-\epsilon_c, \\ \nabla_\theta R_\theta, & \text{if } R_\theta > 1-\epsilon_c. \end{cases}$$

合并两种情形。 合并后，梯度为：

$$\nabla_\theta J(\theta) = \hat{A} \cdot \begin{cases} \nabla_\theta R_\theta, & \text{if } \hat{A} \geq 0 \text{ and } R_\theta < 1+\epsilon_c, \\ 0, & \text{if } \hat{A} \geq 0 \text{ and } R_\theta > 1+\epsilon_c, \\ 0, & \text{if } \hat{A} < 0 \text{ and } R_\theta < 1-\epsilon_c, \\ \nabla_\theta R_\theta, & \text{if } \hat{A} < 0 \text{ and } R_\theta > 1-\epsilon_c. \end{cases}$$

于是，裁剪偏置 $\texttt{Bias}(\nabla_\theta J(\theta))$ 为

$$
\begin{aligned}
&\texttt{Bias}(\nabla_\theta J(\theta)) \\
=&\mathbb{E}_{\hat{A},x,y}\left[\nabla_\theta J(\theta)\right] \\
=&P(\hat{A}\geq 0)\cdot\mathbb{E}_{\hat{A}>0,x,y}[\nabla_\theta L^{+}(\theta)]+P(\hat{A}<0)\cdot\mathbb{E}_{\hat{A}<0,x,y}[\nabla_\theta L^{-}(\theta)]+0 \\
=&\mathbb{E}_{x,y}\left[\begin{cases}P(\hat{A}\geq 0)\cdot\mathbb{E}_{\hat{A}\geq 0}[\hat{A}]\cdot\nabla_\theta R_\theta, & \text{if } R_\theta<1+\epsilon_c,\\ 0, & \text{if } R_\theta>1+\epsilon_c.\end{cases}\right] \\
&+\mathbb{E}_{x,y}\left[\begin{cases}0, & \text{if } R_\theta<1-\epsilon_c,\\ P(\hat{A}<0)\cdot\mathbb{E}_{\hat{A}<0}[\hat{A}]\cdot\nabla_\theta R_\theta, & \text{if } R_\theta>1-\epsilon_c.\end{cases}\right] \\
=&\mathbb{E}_{x,y}\left[\begin{cases}P(\hat{A}\geq 0)\cdot\mathbb{E}_{\hat{A}\geq 0}[\hat{A}]\cdot\nabla_\theta R_\theta, & \text{if } R_\theta<1-\epsilon_c,\\ (P(\hat{A}\geq 0)\cdot\mathbb{E}_{\hat{A}\geq 0}[\hat{A}]+P(\hat{A}<0)\cdot\mathbb{E}_{\hat{A}<0}[\hat{A}])\cdot\nabla_\theta R_\theta, & \text{if } 1-\epsilon_c<R_\theta<1+\epsilon_c,\\ P(\hat{A}<0)\cdot\mathbb{E}_{\hat{A}<0}[\hat{A}]\cdot\nabla_\theta R_\theta, & \text{if } R_\theta>1+\epsilon_c.\end{cases}\right]
\end{aligned}
$$

根据定义，$\hat{A}$ 服从归一化的分布，且由附录 B.1.1 知 $\mathbb{E}(\hat{A})=0$，因此

$$\mathbb{E}(\hat{A})=P(\hat{A}\geq 0)\,\mathbb{E}_{\hat{A}\geq 0}(\hat{A})+P(\hat{A}<0)\,\mathbb{E}_{\hat{A}<0}(\hat{A})=0,\text{ and}$$

$$P(\hat{A}\geq 0)\,\mathbb{E}_{\hat{A}\geq 0}(\hat{A})=-P(\hat{A}<0)\,\mathbb{E}_{\hat{A}<0}(\hat{A})\geq 0.$$

记 $\mu=P(\hat{A}\geq 0)\,\mathbb{E}_{\hat{A}\geq 0}(\hat{A})=-P(\hat{A}<0)\,\mathbb{E}_{\hat{A}<0}(\hat{A})$，根据定义它为正值。将 $R_\theta=\frac{\pi_{\theta,x}(y_t)}{\pi_{\text{old},x}(y_t)}$ 代入各条件，最后将不可微点的梯度设为 0，得到

$$\texttt{Bias}(\nabla_\theta J(\theta))=\mu\cdot\mathbb{E}_{x,y}\left[\begin{cases}\nabla_\theta R_\theta, & \text{if } \pi_{\theta,x}(y_t)<\pi_{\text{old},x}(y_t)\cdot(1-\epsilon_c),\\ 0, & \text{if } \pi_{\text{old},x}(y_t)\cdot(1-\epsilon_c)\leq\pi_{\theta,x}(y_t)\\ & \quad\leq\pi_{\text{old},x}(y_t)\cdot(1+\epsilon_c),\\ -\nabla_\theta R_\theta, & \text{if } \pi_{\theta,x}(y_t)>\pi_{\text{old},x}(y_t)\cdot(1+\epsilon_c).\end{cases}\right]$$

回顾 $R_\theta=\rho_t(y;\theta)=\frac{\pi_{\theta,x}(y_t)}{\pi_{\text{old},x}(y_t)}$，且 $\pi_{\theta,x}(y_t)$ 与 $\pi_{\text{old},x}(y_t)$ 均位于 $[0,1]$。因此，当 $R_\theta<1-\epsilon_c$ 时，存在正梯度（使 $\pi_{\theta,x}(y_t)$ 增大的梯度）；当 $R_\theta>1+\epsilon_c$ 时，存在负梯度（使 $\pi_{\theta,x}(y_t)$ 减小的梯度）。这意味着裁剪偏置会阻止模型离开裁剪区域。为简便起见，下文把前一种情况称为“正梯度偏置”，反之称为“负梯度偏置”。

B.1.3 裁剪产生偏向模型先验知识的不对称更新

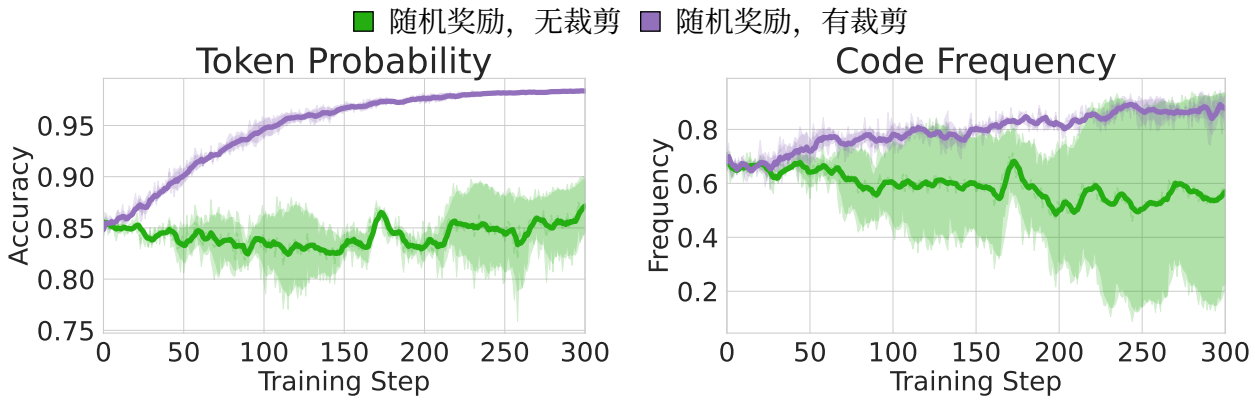
本节为我们的假说提供进一步证据：裁剪偏置会提高高概率轨迹的可能性，这与 Yu et al. (2025) 对真实标签 GRPO 的分析类似。我们用一个简单例子展示这一趋势。考虑某词元的概率很高，$\pi_{\text{old},x}(y_t)=0.85$，并使用实验采用的 $\epsilon_c=0.2$。此时偏置公式的上阈值为 $\pi_{\text{old},x}(y_t)(1+\epsilon_c)=1.02$。由于策略模型输出的概率不可能超过 1，永远不可能达到 1.02 的上裁剪阈值。因此，该词元的梯度偏置非负，给策略模型带来净正梯度偏置，从而提高该词元的概率。

另一方面，对于概率较低的词元 $\pi_{\text{old},x}(y_t)=0.02$，当 $\pi_{\theta,x}(y_t)>\pi_{\text{old},x}(y_t)(1+\epsilon_c)=0.024$ 时，策略模型受到负梯度偏置；当 $\pi_{\theta,x}(y_t)<\pi_{\text{old},x}(y_t)(1-\epsilon_c)=0.016$ 时，受到正梯度偏置。负梯度偏置阈值较低，使得惩罚比高概率情形更容易发生。

裁剪范围的宽度随原始概率线性变化：高概率词元拥有更宽的范围，受到的惩罚更少。这种不对称处理使低概率样本在训练中难以被大幅上调权重，从而令模型的概率质量集中于已有分布。

实证验证。 我们通过禁用 GRPO 损失中的裁剪项，观察训练动态的差异，对上述猜想进行实证验证。具体关注下面定义的词元概率 π_θ 和代码频率。

回顾 π_{old} 是前一训练步的旧策略，π_θ 是当前策略。令 G 为每个提示生成的轨迹数量，B 为小批次大小，即单次梯度更新所使用的提示数量；令 M 为从旧策略 π_{old} 到新策略模型 π_θ 的梯度更



(a) 词元概率　　(b) 代码频率

图 9: Qwen2.5-Math-7B 使用随机奖励时，有裁剪（紫色）和无裁剪（绿色）的词元概率与代码频率。

新次数。注意，$G \cdot B \cdot M$ 是 π_{old} 生成的轨迹总数。在任意一步，π_θ 在全部轨迹 $\{y^{(k)}\}$ 上的平均词元概率可表示为：[9]

$$\pi_{\theta,x}(y) = \frac{1}{M}\sum_{i=1}^{M}\frac{1}{B}\sum_{j=1}^{B}\frac{1}{G}\sum_{k=1}^{G}\pi_{\theta_i,x_j}(y^{(k)}).$$

图 9(a) 表明，采用含裁剪的标准 GRPO 损失（紫线）时，平均词元概率质量上升；禁用裁剪时则保持相对稳定。此外，图 9(b) 记录了 RLVR 训练过程中的代码推理频率。我们假设，平均词元概率的增加与代码推理行为增加相关；正如第 5 节猜测的那样，这种行为会改善模型表现，第 5.2 节图 6 给出了实证结果。

为何只有 Qwen-Math 模型受益。 裁剪偏置机制对所有模型都起作用，但其有效性取决于哪些行为被放大。它系统性偏好模型中既有的高概率行为，但只有这些行为与正确性相关时，才会改善性能。对于 Qwen2.5-Math，代码推理出现在 65% 的回答中，并与正确性高度相关（代码准确率 64%，无代码时 29%）。[10]我们观察到，当含裁剪偏置的 RLVR 把模型代码推理频率提升到 90% 以上时，性能明显改善。无代码型模型（Llama、OLMo2-7B）不生成代码推理，因此裁剪偏置没有可以放大的有益模式。另一方面，低效代码型模型（OLMo2-7B-SFT）在 98% 的情况下生成代码，但其准确率仅为 21%，而自然语言准确率为 40%，说明优秀表现并不依赖代码推理。总之，裁剪偏置具有普遍性，但它对性能的影响完全取决于模型占主导地位的既有行为是否恰好是有效推理策略。

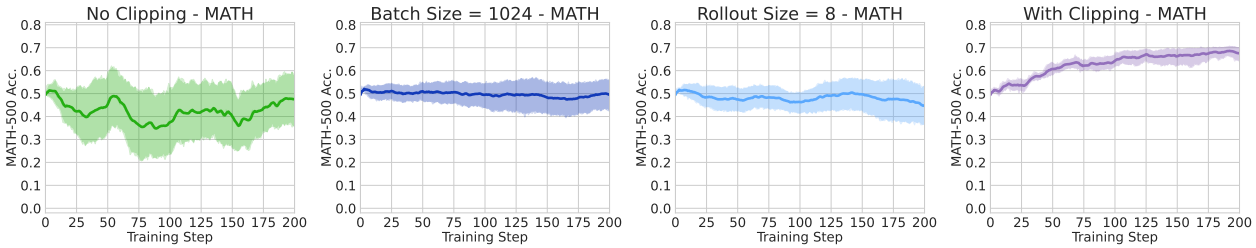
启示。 我们的发现揭示，GRPO 的裁剪机制通过系统性偏好模型既有的行为模式，即使从纯噪声奖励中也能提供有意义的训练信号。这说明随机奖励训练中表面上的“奖励信号”，实际上是优化算法偏向利用已学先验、而非探索新行为所产生的现象。该机制解释了为什么随机奖励对具有强代码推理先验的 Qwen2.5-Math 有效，却对缺乏这些既有能力的其他模型家族无效。无论奖励信号实际含有多少信息，训练算法都会放大那些原本就与正确性相关的推理模式。

B.2 无裁剪 RLVR 的高度随机性

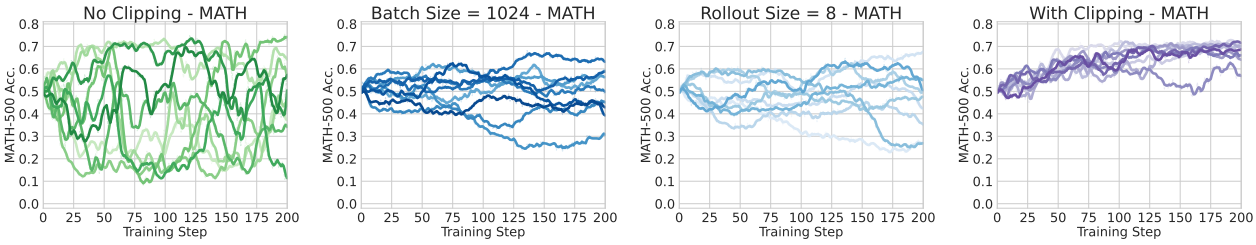
本节实证表明，无裁剪训练具有随机的训练动态，即使期望梯度为零，有时也能获得性能改善。遵循第 4 节的实验设置，我们在多个随机种子下通过以下干预禁用裁剪效果：（i）从损失实现中移除裁剪；（ii）增大小批次，使其与轨迹批次匹配；（iii）减小轨迹批次，使其与小批次匹配。不同随机种子的结果见图 10。

[9]译注：此处原文将 B 定义为提示数量，而附录训练配置把 mini batch size 定义为梯度更新前的轨迹数量。保留原文两处定义。

[10]译注：这里的 64% 与 29% 与正文表格的 60.9% 和 35.0%、以及引言的 60.9% 和 28.0% 不一致，按原文保留。



(a) 每个设置在多个随机种子下的平均结果。



(b) 禁用裁剪，每批轨迹进行 8 次梯度更新。

(c) 增大批次，确保每批轨迹仅进行 1 次梯度更新。

(d) 减小轨迹批次，确保每批轨迹仅进行 1 次梯度更新。

(e) 随机奖励与默认 GRPO 损失。

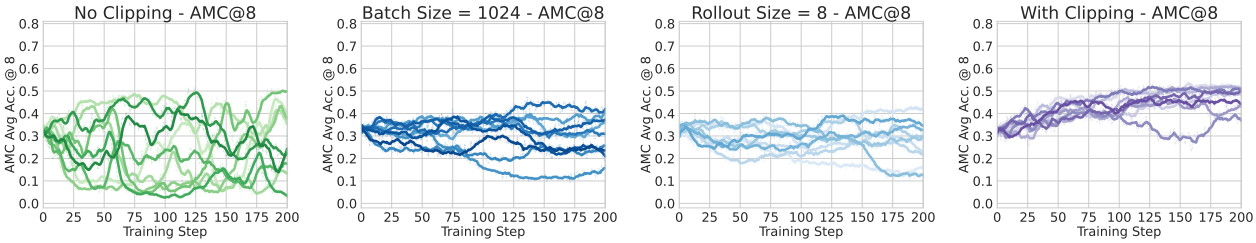


图 10: 多个不同随机种子下，禁用裁剪时随机奖励 RLVR 的表现。无裁剪模型平均而言没有有意义的性能改善，而有裁剪模型使用随机奖励时表现出一致的性能增益。在实现中禁用裁剪会使结果具有高方差，偶尔产生较高准确率。调整批次大小的实验更稳定，但梯度更新次数仅为直接禁用裁剪实验的八分之一。

通过调整批次大小禁用裁剪后，模型表现稳定在一个一致的范围内，不会向准确率范围的任何一端收敛。由于批次配置不同，这些运行的梯度更新次数减少为原来的八分之一。

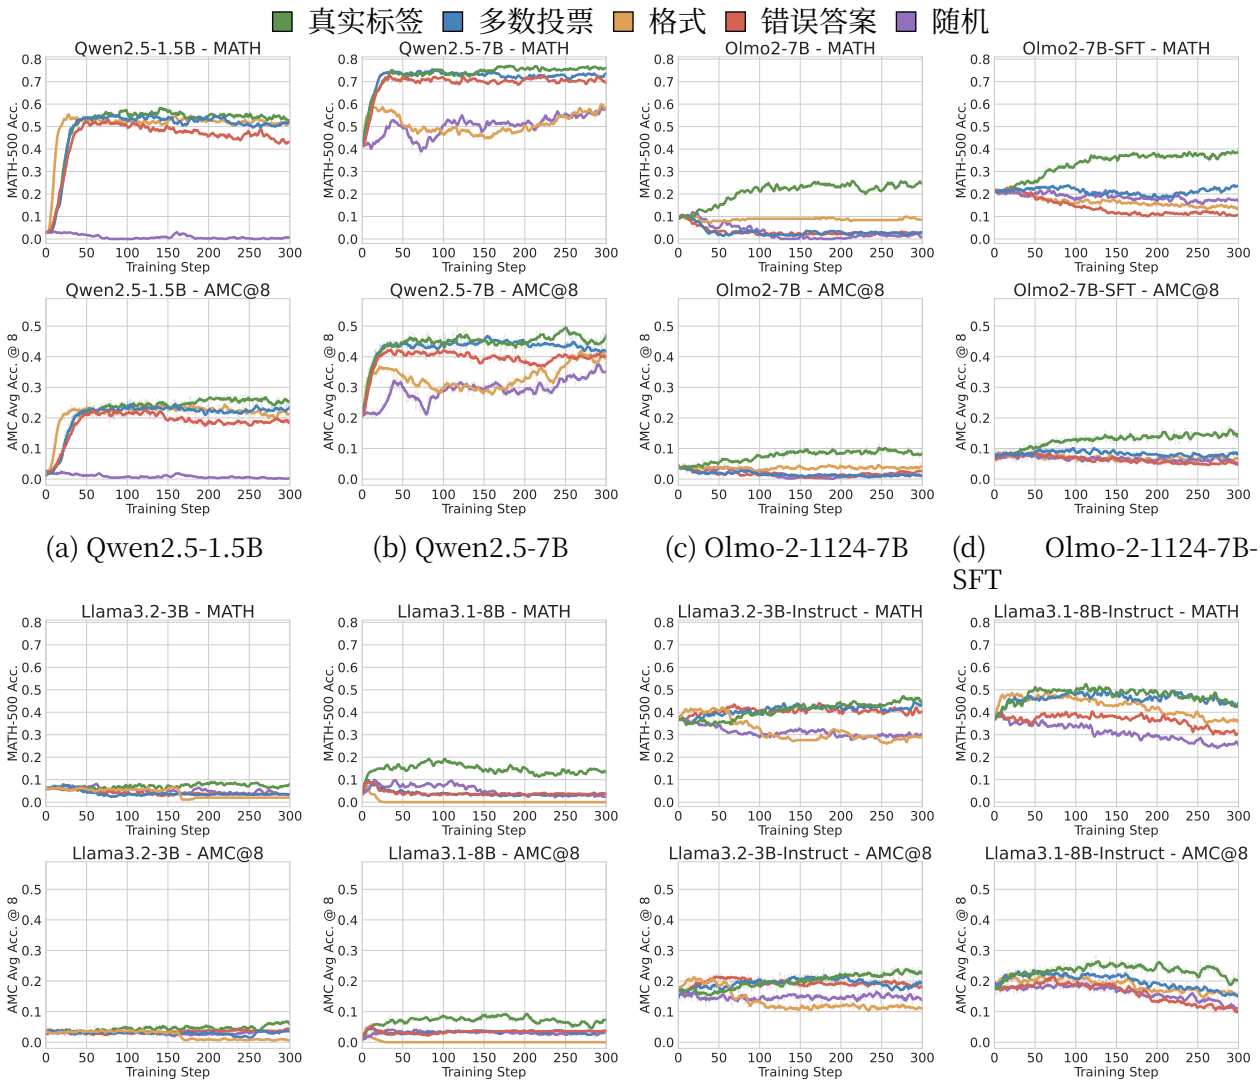
相比之下，直接从实现中移除裁剪会产生极强的随机性，多个运行中偶尔会收敛到高性能状态。虽然确切机制尚不清楚，我们猜测 RLVR 训练固有的随机性促成了这些观察。GRPO 训练使用组大小 $G = 16$，使梯度更新具有高方差。这种方差与无裁剪训练的不稳定性相结合，可能会偶然强化某些推理模式，使部分运行的表现改善。对这一行为的系统分析留待未来研究。

C AMC 补充结果

图 11 补充了非 Qwen 模型在 AMC 上的结果，其趋势与第 3 节展示的 MATH-500 结果一致。

D AIME 2024 与 AIME 2025 补充结果

我们展示 AIME 基准上的补充结果。AIME 是具有挑战性的数学奥赛测试，其问题显著难于 MATH-500 或 AMC。我们在 AIME24 与 AIME25 (Li et al., 2024) 上评估 average@8 准确率。AIME25 的创建时间晚于本研究所有模型的发布日，因此在 AIME25 上评估，有助于控制模型在网页预训练期间见过相似问题的风险。我们评估第 2 节和第 3 节训练得到的模型。Qwen2.5-Math 模型的结果见图 12，第 3 节额外 8 个模型的结果见图 13。



(a) Qwen2.5-1.5B (b) Qwen2.5-7B (c) Olmo-2-1124-7B (d) Olmo-2-1124-7B-SFT

(e) Llama3.2-3B (f) Llama3.1-8B (g) Llama3.2-3B-Instruct (h) Llama3.1-8B-Instruct

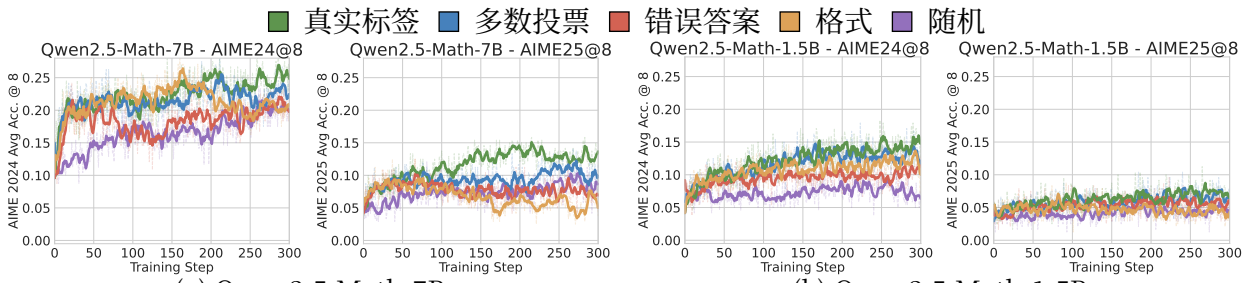
图 11: 其他模型类别采用不同奖励的结果。伪奖励对通用的 Qwen2.5 模型仍有效，但通常无法为其他模型家族带来任何增益。非 Qwen2.5 模型的性能改善远小于 Qwen2.5 家族。

D.1 伪奖励使 Qwen2.5-Math 获得显著 RLVR 增益

如图 12 所示，伪奖励能够稳定改善 Qwen-Math 模型的 AIME24 表现。有趣的是，采用伪奖励训练 Qwen 模型在 AIME24 上获得的增益，在 AIME 2025 上评估时大多消失。我们推测，相对于 Qwen 的预训练知识，AIME25 的问题更偏离训练分布；伪奖励主要用于诱发已有知识，因此不再提供益处。

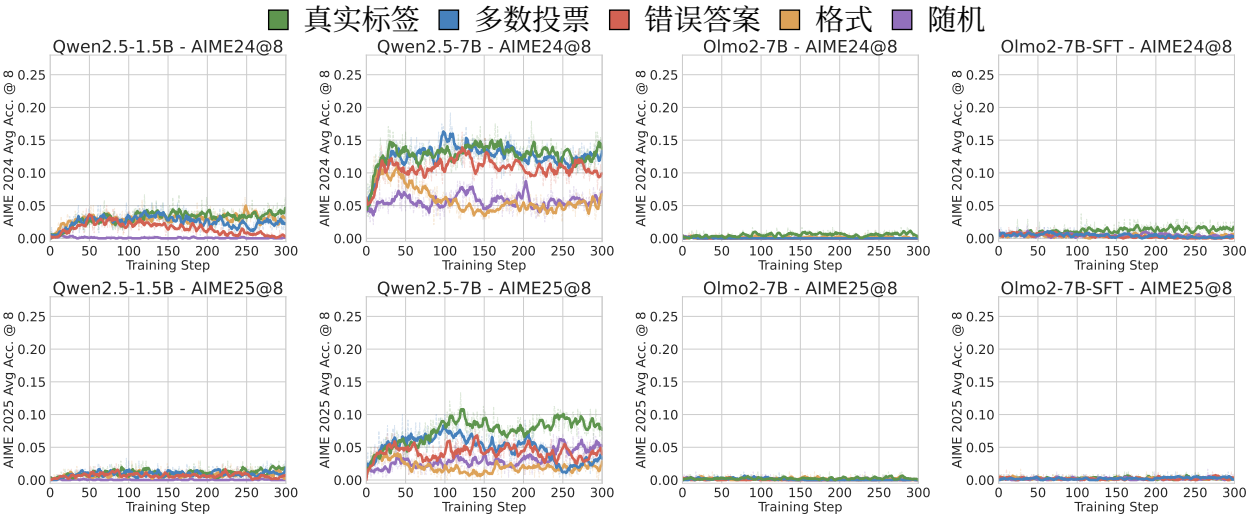
D.2 对其他模型的泛化及其局限

总体而言，其他模型的结果与之前在 AMC 和 MATH-500 上的发现大致一致（第 3 节）。只有 Qwen2.5-7B 、Qwen2.5-1.5B 和 Llama3.1-8B-Instruct 能在 AIME 上从某些奖励信号获得明显增益。对于 Qwen2.5 ，弱奖励和伪奖励能够带来增益，例如 Qwen2.5-1.5B 的格式奖励和 Qwen2.5-7B 的错误答案奖励。对于 Llama3.1-8B-Instruct ，只有标准奖励（如真实标签和多数投票）能带来增益。如前文观察，在 AIME25 上，所有模型的性能及 RLVR 训练增益都普遍较低。

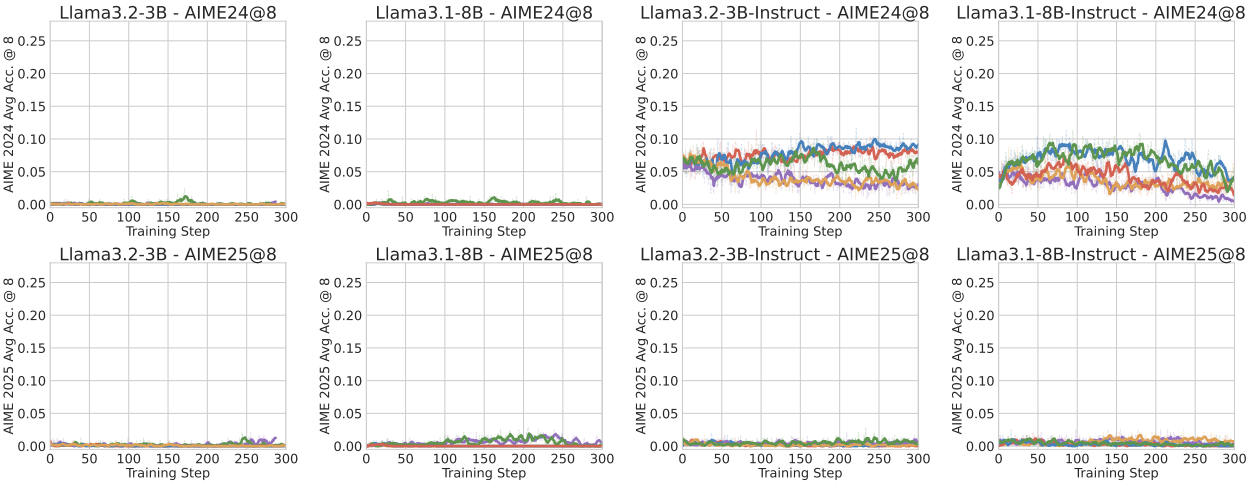


(a) Qwen2.5-Math-7B (b) Qwen2.5-Math-1.5B

图 12: Qwen2.5-Math 模型在 AIME 2024 和 AIME 2025 上的表现。



(a) Qwen2.5-1.5B (b) Qwen2.5-7B (c) Olmo-2-1124-7B (d) Olmo-2-1124-7B-SFT



(e) Llama3.2-3B (f) Llama3.1-8B (g) Llama3.2-3B-Instruct (h) Llama3.1-8B-Instruct

图 13: 其他模型类别在 AIME 2024 与 AIME 2025 基准上采用不同奖励的结果。AIME 2025 发布于所有模型发布日之后，因此适合用于检验数据集污染现象。弱奖励和伪奖励（除随机奖励外）对通用的 Qwen2.5 仍有效，但通常无法为其他模型家族带来任何增益。非 Qwen2.5 模型的性能改善远小于 Qwen2.5 家族。注意，两个 AIME 基准各只有 30 题，因此较小的准确率差异（小于约 2 个百分点）可能不显著。

E 在 Qwen 以外的模型上检验现有方法

本节检验在强化学习期间采用弱监督的现有方法：TTRL 和单样本强化学习，结果见图 15。我们发现，两种方法都对 Qwen 模型显著有效，对其他模型则不然。

F 抑制代码推理的复合奖励

在伪奖励 RLVR 期间抑制代码推理，会减少 Qwen2.5-Math-7B 的增益，却可能增加其他模型的增益。 我们假设，代码推理是弱奖励与伪奖励增益的一部分来源。反过来，惩罚代码频率可能减少这些奖励在 Qwen2.5-Math 中产生的增益。为检验这一点，我们设计复合奖励，把每一种弱奖励或伪奖励与无 Python 奖励取交集：当且仅当回答（1）满足原始伪奖励条件，并且（2）不包含字符串“`python`”时，才给予奖励。与假说一致，格式奖励与无代码奖励组合后，不再改善 Qwen2.5-Math-7B （图 16c）。错误答案伪奖励的复合版本在 MATH-500 上达到原始错误答案奖励的表现；在 AMC 和 AIME 等更难的基准上，增益仍然存在，但有所减少（图 16b、14）。因此，虽然消融代码推理确实如预期那样削弱了错误答案奖励的效果，我们认为，其他有益行为（例如减少重复，见附录 G）仍可能被浅层地诱发。此外，真实标签奖励仍带来增益，说明其益处不止于诱发代码推理，这也与图 6 中代码频率的趋势一致。

有趣的是，对于低效代码型模型 Qwen2.5-7B 和 OLMo2-7B-SFT ，复合奖励往往优于原始奖励。最显著的是，OLMo2-7B-SFT 在单独采用格式奖励或错误答案奖励时表现下降，但加入无代码奖励后，分别提高 8.9 和 5.5 个百分点。我们假设，这是因为 Qwen2.5-7B 和 OLMo2-7B-SFT 在 RLVR 训练前的代码推理较弱，而复合奖励显式降低了这种对它们而言次优行为的权重。

图 14 展示复合奖励在（1）更多模型（Qwen2.5-1.5B 、Qwen2.5-Math-1.5B ）和（2）更多基准（AIME24、AIME25）上的补充结果。总体上，结果支持第 5.3 节的分析；Qwen2.5-Math-1.5B 遵循与 Qwen2.5-Math-7B 相同的总体趋势。复合奖励也持续帮助 Qwen2.5-1.5B ，增益与使用原始奖励相当。这与 Qwen2.5-7B 的观察略有不同，后者使用复合奖励时往往增益更强。我们猜测 Qwen2.5-1.5B 的代码推理更强，这与第 5.3 节的发现一致：通过提示诱发代码推理能改善 Qwen2.5-1.5B ，却不能改善 Qwen2.5-7B 。这两个模型的预训练数据相同，我们尚不确定这一差异的确切原因，留待未来研究。

G 代码推理之外：RLVR 易于诱发的另一种有益模式

正文表明，伪奖励 RLVR 可以通过激活预训练中学到的有益推理模式，改善 Qwen2.5-Math 的表现，并将代码推理作为一个突出例子。代码推理是一种独特的推理表示，但并非唯一一种。本节简要讨论代码推理之外另一种也容易被 RLVR 诱发的模式：无重复。

我们观察到，相比 Llama3 与 Olmo2，Qwen2.5-Math 更容易生成重复输出，而带有代码推理的答案往往没有这一问题。因此，我们进一步研究单纯抑制回答重复的影响。为此，设计一种新的重复奖励：如果答案中任意字符串重复超过 10 次，返回 0 分；否则给予模型满分 1 分。

如图 17 所示，RLVR 的无重复奖励改善了 Qwen2.5-Math-7B 和 Qwen2.5-Math-1.5B 在 MATH 与 AMC 上的表现。其他模型的改善很小，甚至为负。根据这些发现，我们假设存在多种其出现与答案正确性相关的模式。即使奖励完全不提供真实答案的信息，RLVR 也很容易诱发这些模式，包括代码推理和无重复。不过，诱发这些模式的有效性高度依赖模型。

H RLVR 期间的推理策略转换

本节进一步分析 Qwen2.5-Math 和 Qwen2.5 模型在 RLVR 期间推理策略的变化。

RLVR 期间的推理策略转换。 在不同训练信号下，Qwen2.5-Math-7B 的准确率平均绝对提高 23.5 个百分点。为进一步分解这一增益，我们追踪每种训练信号训练的模型在四个互不重叠的测试提示子集上的表现：**（1）Code→Code**：模型在 RLVR 前后均使用代码推理；**（2）Code→Lang**：模型最初使用代码推理，随后转向自然语言推理；**（3）Lang→Code**：模型最初

使用自然语言推理，随后转向代码推理；（4）**Lang→Lang**：模型在 RLVR 前后均使用自然语言推理。具体关注每个子集的频率与准确率这两个相互关联的指标。为了系统量化每个子集对性能增益的贡献，对于整个测试集 $\mathcal{D}$ 的任意子集 $d \subseteq \mathcal{D}$，定义部分贡献分数 C_d：子集 d 中正确作答题数的净增量，除以整个 $\mathcal{D}$ 中正确作答题数的净增量，即

$$C_d = \frac{\sum_{x \in d} \mathbb{I}[\text{correct}(x_t)] - \mathbb{I}[\text{correct}(x_0)]}{\sum_{x \in \mathcal{D}} \mathbb{I}[\text{correct}(x_t)] - \mathbb{I}[\text{correct}(x_0)]},$$

其中 x_0 与 x_t 分别为初始答案和最终答案。[11]

频率。 图 18 展示 Qwen2.5-Math-7B 的推理策略转换模式。在所有弱奖励和伪奖励下，模型在 RLVR 后都更多地使用代码推理。只有少数原先使用代码推理的问题转向语言推理（Code→Lang），而大部分原先使用语言推理的问题都转向代码推理（Lang→Code）。真实标签奖励不符合这一模式。对于低效代码型模型（Qwen2.5-7B 和 OLMo2-7B-SFT ），有意义的奖励会引导模型远离低效的代码推理。Qwen2.5-7B 使用真实标签、多数投票和错误答案奖励时，代码推理都会减少；OLMo2-7B-SFT 则只有在真实标签和多数投票下减少（图 6b 与 6c）。对于无代码型模型，RLVR 无法诱发有意义的推理策略变化，因为它们很可能没有在预训练期间学到这种能力。

表 4: 对成功引导模型推理策略的奖励取平均后，各子集对整体性能增益的部分贡献（图 6）。

模型	Qwen2.5-Math-7B	Qwen2.5-Math-1.5B	Qwen2.5-7B
平均总增益	↑ 23.5%	↑ 28.5%	↑ 30.6%
$\mathbf{C_{Code \to Code}}$	11.6%	2.8%	0.2%
$\mathbf{C_{Code \to Lang}}$	8.6%	2.0%	**93.9%**
$\mathbf{C_{Lang \to Code}}$	**58.3%**	**78.7%**	0.0%
$\mathbf{C_{Lang \to Lang}}$	21.4%	16.5%	5.9%

准确率。图 18 表明，在所有训练信号下，Lang→Code 子集的准确率都会在 RLVR 后大幅提高。表 4 反映了这一点：Qwen2.5-Math-7B 的性能增益中有 58.3% 来自该子集。类似地，在 Qwen2.5-Math-1.5B 中，从自然语言推理转向代码推理贡献了 78.7% 的性能增益。对于低效代码型模型，Code→Lang 贡献了 Qwen2.5-7B 性能增益的 93.9%。这符合直觉：该模型的语言推理准确率高于代码推理，RLVR 训练实际上是在鼓励模型使用自己更擅长的推理策略。对于无代码型模型，由于 RLVR 前后均不存在代码推理，全部性能增益（或损失）都来自 **Lang→Lang** 子集。这些结果表明，在 Qwen2.5-Math 和 Qwen2.5 上，使用这些伪奖励的 RLVR 所带来的大部分准确率增益，只是诱发了模型中正确的推理策略。

I 伪提示：Qwen2.5-Math-7B 对提示异乎寻常的高度敏感性

完整提示原串与逐字中文转写暂不收录。

表 5: 原文提示比较表的公开版占位。

公开版编注：表中引用了其他研究的提示模板与占位文本，其独立再传播许可未逐项核实。提示名称、实验统计及作者对方法的分析保留。

如第 5.3 节所示，提示模型使用代码推理能使 Qwen2.5-Math-7B 提高 15.0 个百分点。这说明，提示工程是一种无需更新参数即可诱发期望行为的有效方法。本节进一步分析选择不同的现有提示如何影响模型行为，以及这类技术与 RLVR 如何相互作用。此外，我们表明，即使使用某些与任务无关、没有信息的提示，模型表现也可以改善；我们将其称为“伪提示”。

[11]译注：原式求和符号之后没有用括号显式包住两个指标函数；此处保留其排印形式。按紧邻的文字定义，分子与分母均指相应集合内正确题数的净增量。

	Default	MathProblem	SimpleRL-Zoo	Sober	Spurious
MATH 准确率	49.4	55.8	63.2	61.60	**68.8**
可解析比例（%）	78.9	72.1	85.4	**93.1**	84.1

表 6: Qwen2.5-Math-7B 使用表 5 各种提示时的 MATH-500 准确率与可解析（遵循格式）回答的百分比。即使采用伪提示，模型仍有 84.1% 的回答遵循格式。因此，不能显然地认为大部分表现都能用格式遵循来解释。

I.1 现有提示

我们收集流行强化学习训练框架和近期评估工作中的不同提示：Qwen 默认提示 (Yang et al., 2024a)、SimpleRL-Zoo (Zeng et al., 2025)、Sober Reasoning (Hochlehnert et al., 2025)，以及我们手工构造的提示（详见表 5）。具体来说，我们引入两个新提示：第一个是数学提示（Math Prompt），指明评估领域，但不提供额外格式信息；第二个是伪提示（Spurious Prompt），它是随机选取的、由 lipsum 生成的 LaTeX 占位文本。尽管已知大语言模型评估可能对评估提示敏感 (Sclar et al., 2024)，我们引入这两种特定提示的动机，是研究简洁的领域知识，甚至上下文中的随机扰动，如何影响评估表现。强化学习训练期间，轨迹采样与评估均使用这些提示。

如表 6 所示，Sober 提示带来最高的答案可解析率，而我们的伪提示带来最高的 MATH-500 准确率。结果表明，模型对提示非常敏感；最佳表现并不一定要求最高可解析率，也不一定要求上下文包含任务相关信息。

图 19 进一步展示不同提示下的训练轨迹。我们发现，在相同训练设置下，采用 Qwen 默认提示、`Math Problem:` 和 SimpleRL-Zoo 的模型，经 RLVR 后会收敛到相近表现。我们猜测，通过提示能诱发的行为，往往是 RLVR 易于诱发行为的一个子集；而 RLVR 还能诱发提示中未预先指定的其他行为。

I.2 伪提示

鉴于 Qwen2.5-Math-7B 对提示高度敏感，我们好奇那些与任务毫无关联的提示会对它产生多大影响，例如 lipsum 生成的 LaTeX 占位文本。具体而言，我们使用 lipsum 构造了一个长度与表 5 中 Sober 提示相近的伪提示。令人意外的是，如图 19e 所示，与其他常用的任务特定提示相比，该伪提示带来的初始表现最高。虽然我们发现，随机选取提示并不总能改善表现，但该伪提示的高性能说明，模型可能对上下文扰动非常敏感，有时收益可能来自这种敏感性，而不是提示中与任务相关的内容。

J 已接受强化学习训练模型的补充结果

本节给出已经接受过强化学习训练的模型的补充结果，包括两个 Qwen Instruct 模型（Qwen2.5-Math-7B-Instruct (Yang et al., 2024a) 与 Qwen2.5-7B-Instruct (Yang et al., 2024b)）和一个 Tulu3 模型（Llama-3.1-Tulu-3-8B (Lambert et al., 2024)）。我们表明，这些强化学习后模型在 RLVR 中的行为，可能不同于其他基础模型或指令微调模型。

如图 20 所示，在我们的设置中，即使使用真实标签奖励，Qwen Instruct 模型从各类奖励的 RLVR 训练中获得的改善也很小。其他模型中也观察到同样模式：经过足够多 RLVR 训练步后，性能进入平台期。因此，我们猜测，Qwen2.5-Math-7B-Instruct 在本文 RLVR 实验中获益较少，是因为它在此前的强化学习训练中已经达到饱和。更好的 RLVR 算法或更高质量的训练数据，仍可能改善目前饱和的模型，但我们将此留待未来探索。

此外，我们考察 Llama-3.1-Tulu-3-8B 的 RLVR 行为（图 20c），发现与 Qwen2.5 Instruct 模型不同，真实标签奖励训练在 MATH 上带来小幅增益，在 AMC 和 AIME 上带来有限增益。[12]Llama-3.1-Tulu-3-8B 的趋势与其基础模型 Llama-3.1-8B 相似。我们猜测，这可能是因为它们在强化学习训练前具有相似先验知识，因而产生相似的 RLVR 行为。不过，与 Qwen

[12]译注：原文此处将 AMC 误写为 ACM；根据全文基准名称译为 AMC。

Instruct 不同，尽管 Llama-3.1-Tulu-3-8B 已经在 Tulu3 数据集上进行过 RLVR 训练，它在 MATH 上仍然有所提升。

K Qwen2.5-Math-7B 代码推理行为的定性分析

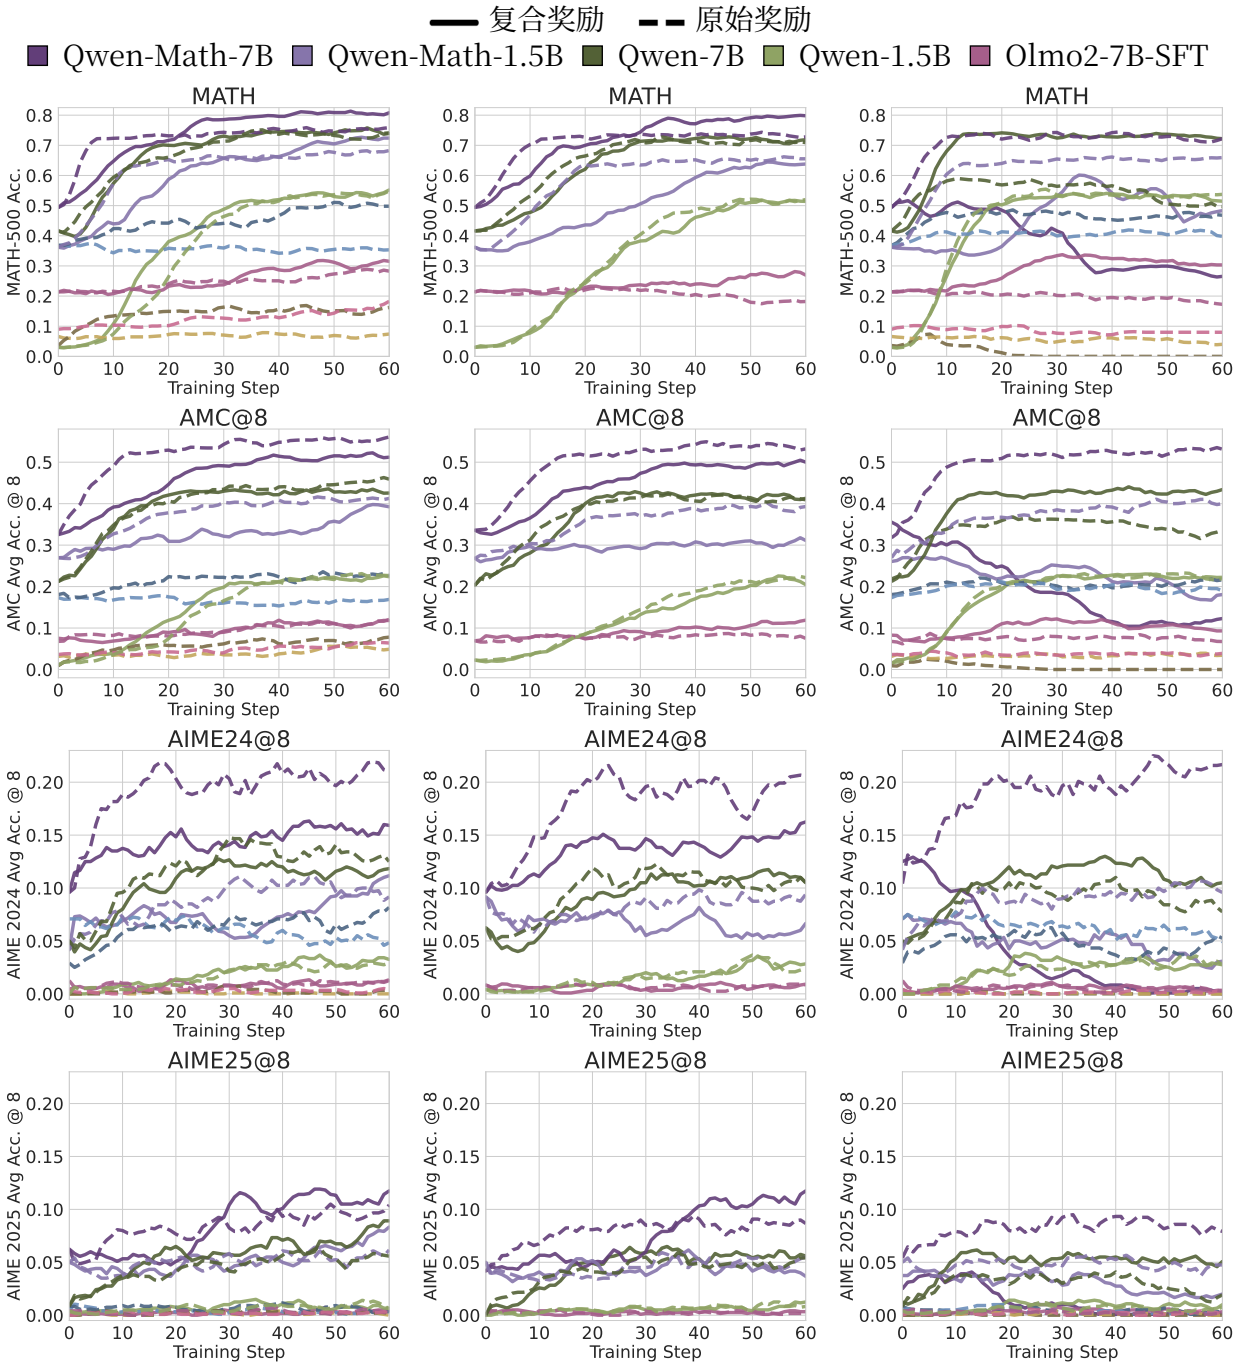
本节通过若干定性示例，展示 Qwen2.5-Math-7B 如何用代码推理。此外，我们表明其代码推理行为对数值扰动具有稳健性：模型会生成相似代码，解决数值经过扰动的问题。然而，当我们用另一种叙述方式改写问题时，Qwen2.5-Math-7B 只使用自然语言解答。

Qwen2.5-Math-7B 能够用代码推理。 图 22 至图 23 展示了从 MATH-500 随机选取的三个问题上，Qwen2.5-Math-7B 输出的三个定性示例。我们发现，Qwen2.5-Math-7B 能够进行代码推理，即通过编写代码解决问题，并预测代码执行结果。令人意外的是，模型预测代码执行结果的准确性相对较高：在图 22 与图 21 中，即使**无法**访问任何代码解释器，Qwen2.5-Math-7B 也能以 16 位浮点精度算出执行答案。[13]在图 23 的示例中，Qwen2.5-Math-7B 给出了错误答案 4323，但仍非常接近真实答案 4343。

Qwen2.5-Math-7B 的代码推理行为对数值扰动具有稳健性。 我们进一步把图 23 问题中的数字 999，扰动为 100 到 1000 范围内的几个随机整数，见图 24 至图 26。我们发现，Qwen2.5-Math-7B 能够在答案中使用相似代码片段，解决这些扰动后的问题。例如，图 24 展示，Qwen2.5-Math-7B 能为图 23 问题的数值扰动版本推导出正确答案 4344：我们将输入数字从 999 改为 1000，相应真实答案由 4343_6 变为 4344_6。Qwen2.5-Math-7B 使用了同一个代码函数解决问题。有趣的是，尽管它对图 23 原问题预测了不准确的答案，却对扰动后的问题预测正确。

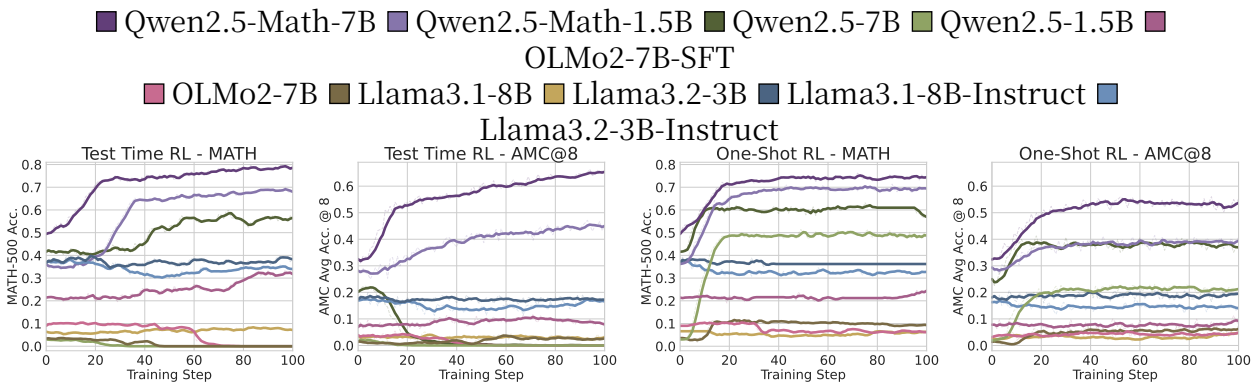
Qwen2.5-Math-7B 的代码推理行为可能无法直接推广到改写问题。 我们还分别以另一种叙述方式，改写图 23、图 25 和图 26 的问题。如图 27 至图 29 所示，Qwen2.5-Math-7B 先在回答第一句话中识别并概括出相同的核心问题，但它没有使用任何代码回答改写后的问题。我们假设，Qwen2.5-Math-7B 是否使用代码推理，取决于具体提示分布，即问题是否接近某些用代码解答增强过的训练数据，而不是取决于问题本身。

[13]译注：原文写作“16-float precision”，未严格定义其含义；此处按字面译为 16 位浮点精度，不等同于明确声称使用 FP16 格式。



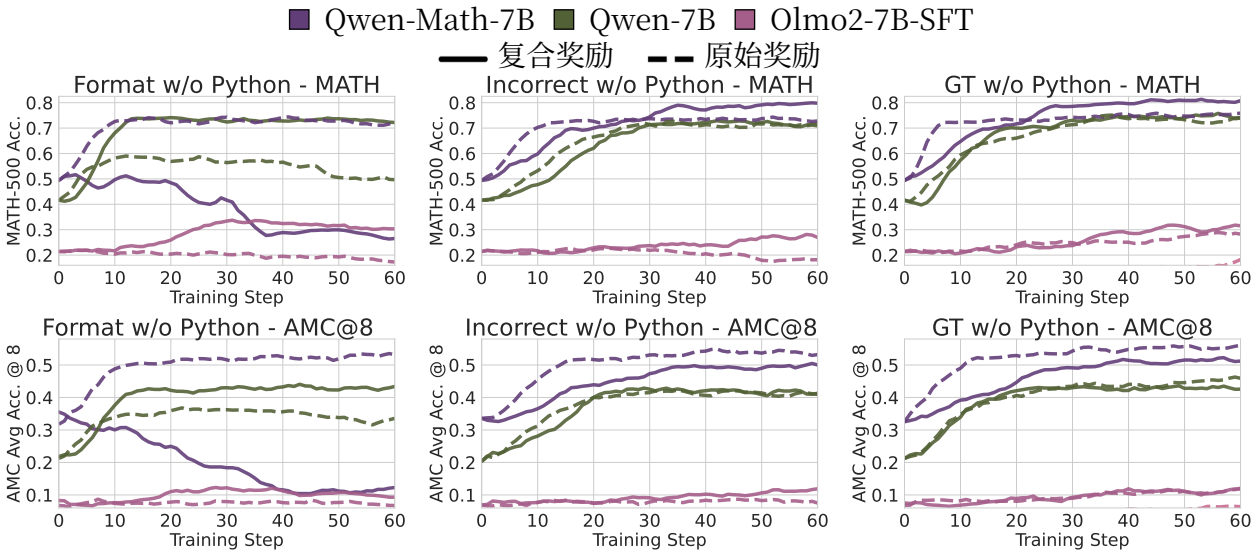
(a) 真实标签奖励且无 Python　(b) 错误答案奖励且无 Python　(c) 格式奖励且无 Python

图 14: 复合奖励在（1）较小的 1.5B Qwen 模型和（2）AMC 与 AIME 基准上的补充结果。完整设置见第 5.3 节。复合奖励把（a）原始奖励与（b）仅奖励不含 Python 代码回答的无 Python 奖励取交集。总体发现与正文大致一致。注意，AIME 测试集非常小，因此较小的准确率差异（小于约 2 个百分点）可能没有实际意义。



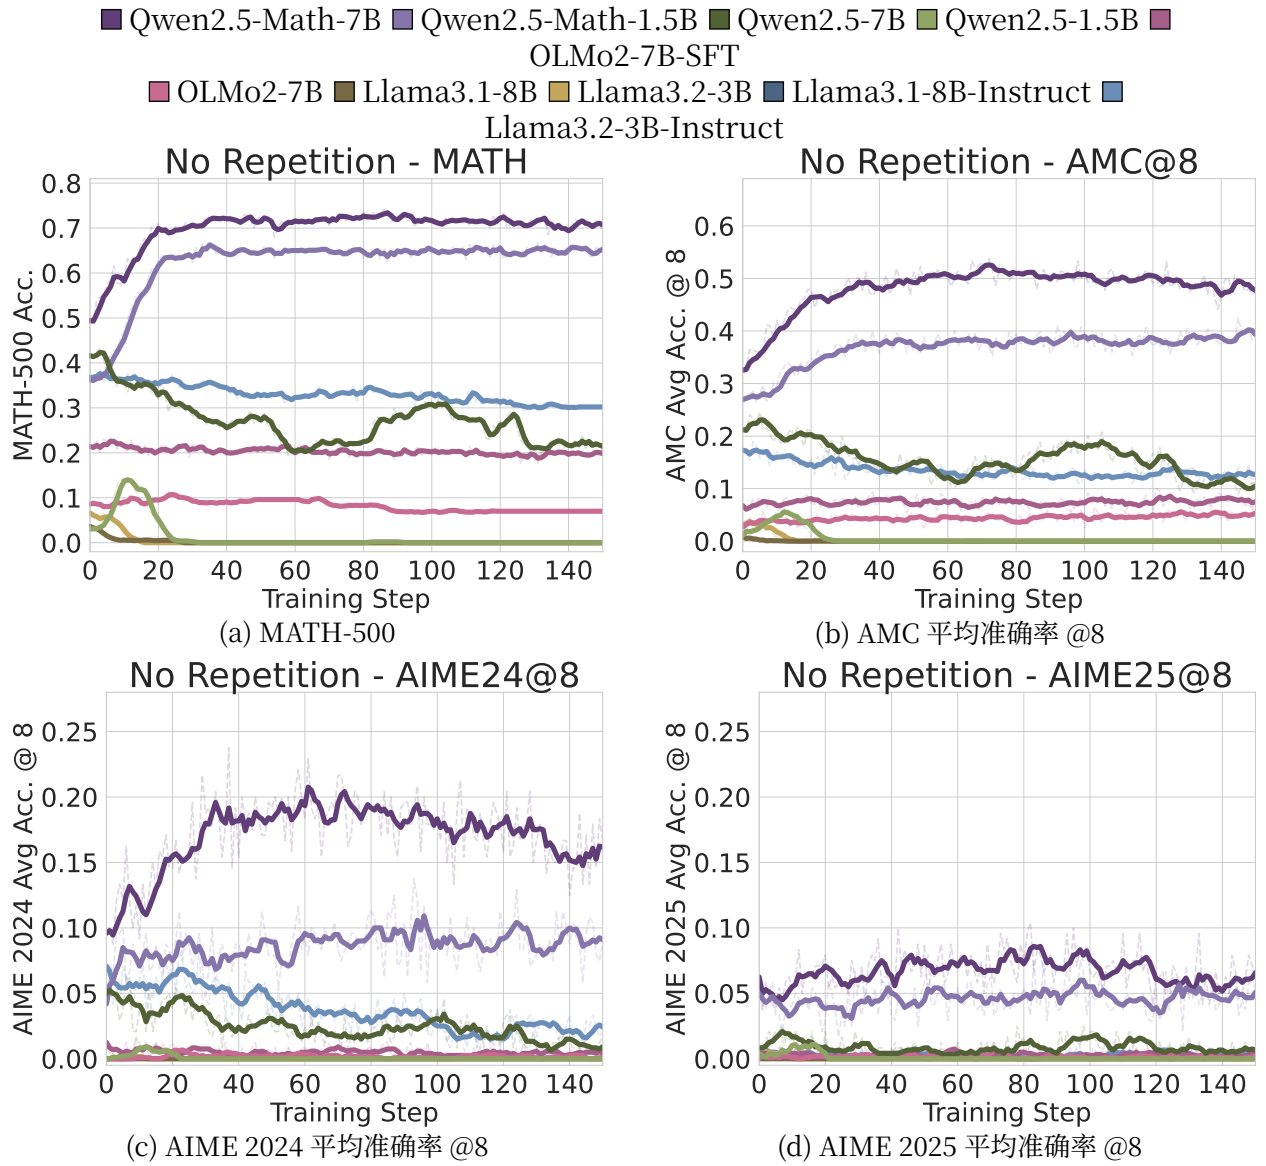
(a) TTRL 结果　　(b) 单样本强化学习结果

图 15: 在多种基础模型上评估两种近期弱监督强化学习方法：TTRL (Zuo et al., 2025) 和单样本强化学习 (Wang et al., 2025b)。我们发现，这些训练奖励在 Qwen 模型上持续有效。然而，除少数例外，相同信号往往无法改善其他模型家族，这与我们自己的伪奖励训练所体现的有限泛化一致。设置详见附录 A.7。



(a) 格式奖励且无 Python　　(b) 错误答案奖励且无 Python　　(c) 真实标签奖励且无 Python

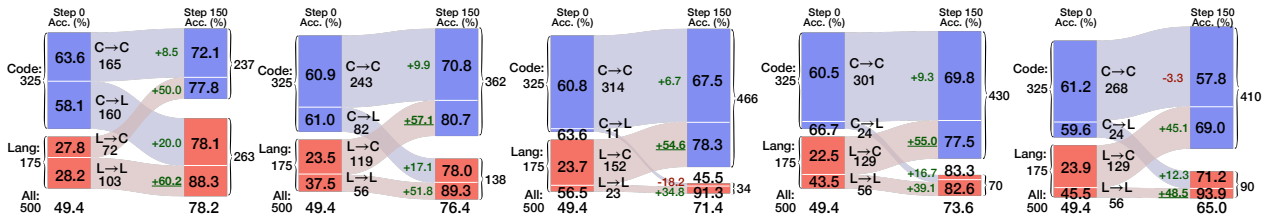
图 16: 采用复合奖励的 RLVR：把（i）原始奖励与（ii）仅奖励不含 Python 代码回答的无 Python 奖励取交集。AIME 和更多模型上的佐证结果见附录 F。



(a) MATH-500 (b) AMC 平均准确率 @8

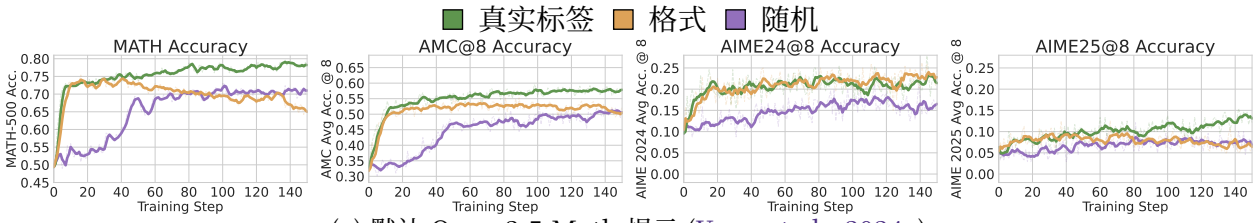
(c) AIME 2024 平均准确率 @8 (d) AIME 2025 平均准确率 @8

图 17: 设计一种新的无重复奖励：不含明显重复的回答得 1 分，包含明显字符串重复的回答得 0 分。无重复奖励能够有效改善 Qwen2.5-Math 的表现，但不能改善其他模型。

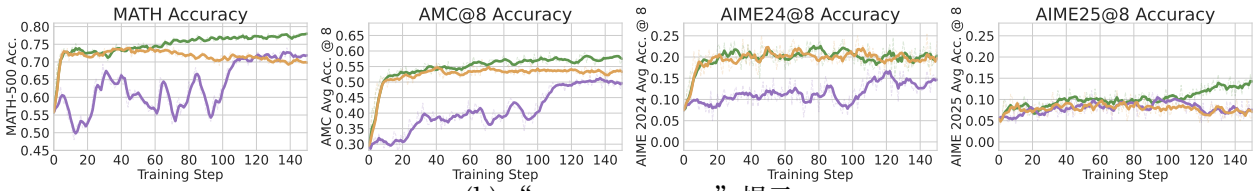


(a) 真实标签 (b) 多数投票 (c) 格式 (d) 错误答案 (e) 随机

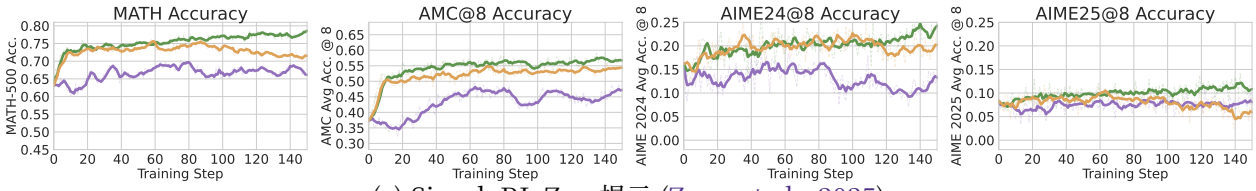
图 18: 不同训练信号的 RLVR 前后，Qwen2.5-Math-7B 在 MATH-500 测试集上的推理策略转换与细粒度表现。蓝色标签表示模型使用代码推理的问题，红色标签表示仅使用自然语言的推理轨迹。两端阴影区域显示各互不重叠问题子集在 RLVR 前后的准确率，中间浅色区域显示各子集大小及准确率变化。对于所有弱奖励与伪奖励，模型在 RLVR 后倾向于使用更多代码推理。少量原先使用代码推理的问题转向语言推理（Code→Lang）；大部分原先使用语言推理的问题转向代码推理（Lang→Code），这一子集在 RLVR 后的性能提升最显著。



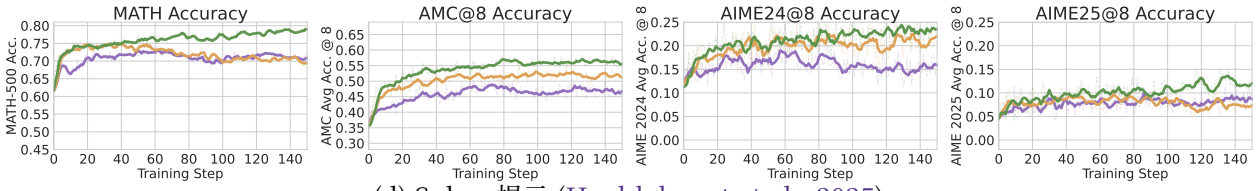
(a) 默认 Qwen2.5-Math 提示 (Yang et al., 2024a)



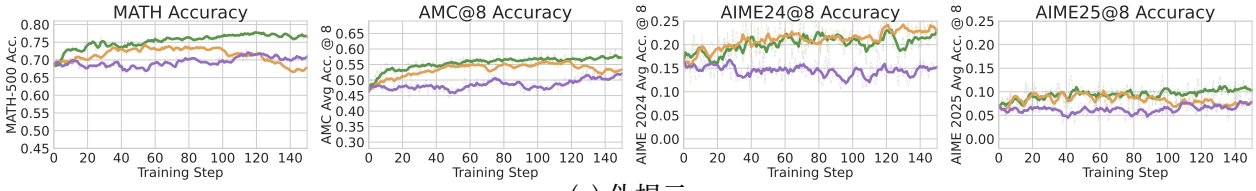
(b) “`Math Problem:`”提示



(c) SimpleRL-Zoo 提示 (Zeng et al., 2025)

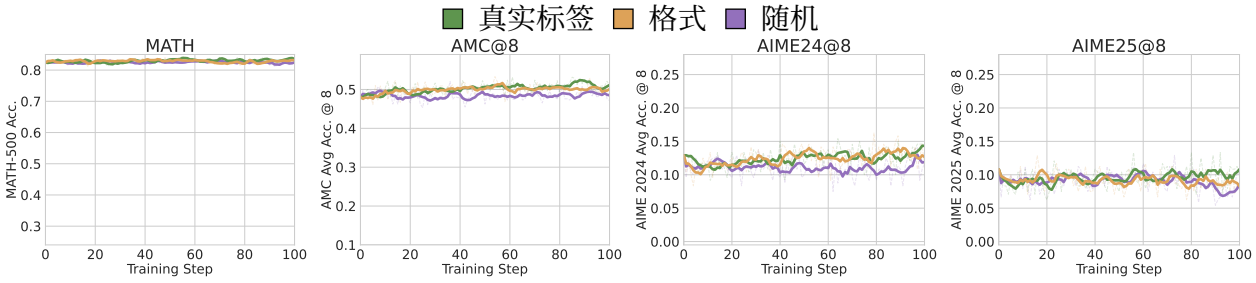


(d) Sober 提示 (Hochlehnert et al., 2025)

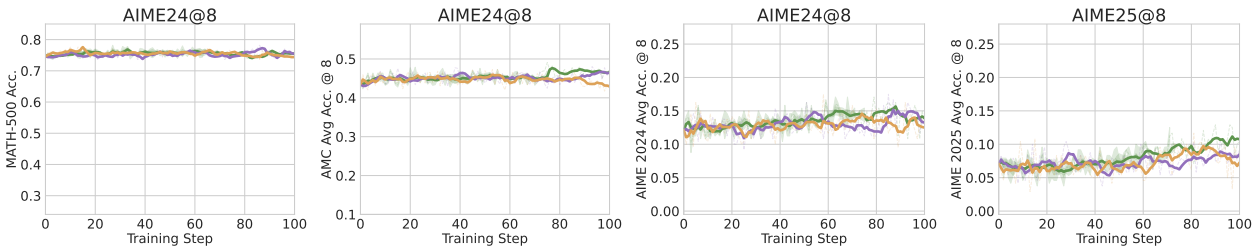


(e) 伪提示

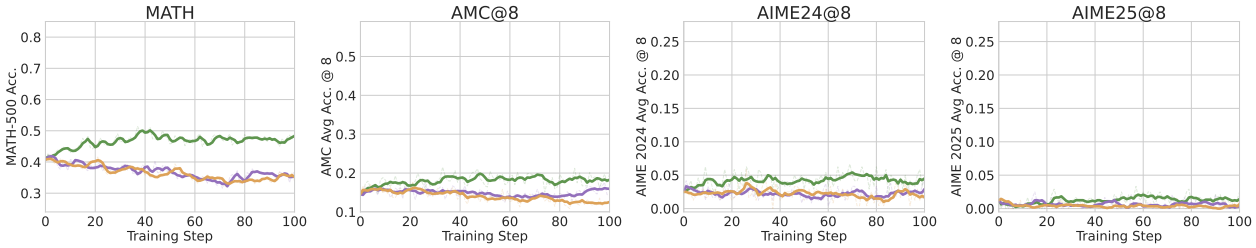
图 19: Qwen2.5-Math-7B 使用不同提示模板时的 RLVR 表现。提示选择既影响训练前表现，也影响 RLVR 训练轨迹。Qwen2.5-Math 提供的默认提示 (Yang et al., 2024a) 导致较低初始表现；其他提示的初始表现更高，其中伪提示最高。



(a) Qwen2.5-Math-7B-Instruct



(b) Qwen2.5-7B-Instruct 结果



(c) Llama-3.1-Tulu-3-8B 结果

图 20: 已经接受过强化学习训练的模型的 RLVR 表现。Qwen Instruct 模型在本文 RLVR 下的改善很小，而 Llama-3.1-Tulu-3-8B 呈现与 OLMo 相似的模式（图 3）。对 Llama-3.1-Tulu-3-8B 而言，真实标签训练带来明显的性能差异，但 Qwen Instruct 模型没有这种差异。

逐字数据集实例及对应模型输出未在公开版收录。

图 21: 原文定性实例的公开版占位。

逐字数据集实例及对应模型输出未在公开版收录。

图 22: 原文定性实例的公开版占位。

逐字数据集实例及对应模型输出未在公开版收录。

图 23: 原文定性实例的公开版占位。

逐字数据集实例及对应模型输出未在公开版收录。

图 24: 原文定性实例的公开版占位。

逐字数据集实例及对应模型输出未在公开版收录。

图 25: 原文定性实例的公开版占位。

逐字数据集实例及对应模型输出未在公开版收录。

图 26: 原文定性实例的公开版占位。

逐字数据集实例及对应模型输出未在公开版收录。

图 27: 原文定性实例的公开版占位。

逐字数据集实例及对应模型输出未在公开版收录。

图 28: 原文定性实例的公开版占位。

逐字数据集实例及对应模型输出未在公开版收录。

图 29: 原文定性实例的公开版占位。