公开发布与许可说明

原文作者：Hieu Trung Nguyen、Bao Nguyen、Wenao Ma、Yuzhi Zhao、Ruifeng She、Viet Anh Nguyen。原题：Adaptive Rollout Allocation for Online Reinforcement Learning with Verifiable Rewards。底本为 arXiv:2602.01601v3，2026 年 3 月 5 日修订，ICLR 2026 会议论文，共 33 页。

原文链接：https://arxiv.org/abs/2602.01601v3。该具体版本的 arXiv 页面标示 Creative Commons Attribution 4.0 International（CC BY 4.0）：https://creativecommons.org/licenses/by/4.0/。

本文件为 dot 制作的非官方 AI 辅助中文翻译与重新排版。改动包括中文翻译、重新排版、明确标记的译注以及本许可说明；保留公式、实验数值、原图和原文书目信息。此公开版未额外删去研究内容。本译文的翻译与排版贡献同以 CC BY 4.0 提供，原文内容由原权利人依其许可直接授权。原作者、机构及会议未审校或认可本译文。

再传播时，请注明原作者、原题、具体版本、来源与许可链接，并说明本译本及后续改动。论文的许可不自动覆盖独立的模型、软件仓库或数据集；此发布包只含译文 PDF 和说明，不附原文、代码或源文件。

本次核查未发现文中另行标注的第三方图文许可例外。此说明是基于可见内容与公开许可的核查，不是法律意见或无侵权保证。

中文公开版 v1.1，2026 年 11 月 10 日。

可验证奖励在线强化学习的自适应采样分配

Adaptive Rollout Allocation for Online Reinforcement Learning with Verifiable Rewards

Hieu Trung Nguyen[C,*], Bao Nguyen[C,†], Wenao Ma[H,‡]
Yuzhi Zhao[H], Ruifeng She[H], Viet Anh Nguyen[C]
[C]香港中文大学 [H]华为香港研究中心
{thnguyen,nbnguyen,nguyen}@se.cuhk.edu.hk
{ma.wenao,she.ruifeng}@huawei.com
yzzhao2-c@my.cityu.edu.hk

中文公开版 v1.1 原文版本 arXiv:2602.01601v3 2026年3月5日

源代码：https://github.com/HieuNT91/VIP
原文：https://arxiv.org/abs/2602.01601v3

译本说明：本译本包含正文、伦理与可复现性等声明、全部附录、算法、图表说明及参考文献。公式、实验数值与原始矢量图保留；参考文献保留英文以便检索。原文可疑笔误以“译注”说明，不作静默修正。图内英文坐标与图例保留以维护原图的可核验性。

摘要

采样效率是可验证奖励强化学习的一项关键瓶颈。现有的基于组的策略优化方法（如 GRPO）为所有训练提示分配固定数量的采样轨迹。这种均匀分配隐含地将所有提示视为具有相同的信息量，可能导致计算预算使用低效并妨碍训练进展。我们提出方差信息驱动的预测式分配策略（Variance-Informed Predictive allocation，VIP），将给定的采样预算分配给当前批次中的提示，以最小化策略更新的期望梯度方差。在每次迭代中，VIP 使用轻量级高斯过程模型，依据近期采样轨迹预测每个提示的成功概率。随后，将这些概率预测转化为方差估计，并输入一个凸优化问题，从而在硬性计算预算约束下确定最优采样分配。实验结果表明，VIP 能够持续提升采样效率，并在多个基准上取得优于均匀分配或启发式分配策略的性能。

1 引言

语言模型（Language Models，LMs）的出现开启了人工智能的新阶段，使模型从静态知识库转变为能够进行复杂推理、创造性生成和精细问题求解的动态智能体。这一演进在很大程度上得益于后训练方法 (Tong et al., 2024; Rafailov et al., 2023; Shao et al., 2024)和测试时扩展方法 (Snell et al., 2024; Feng et al., 2023; Nguyen et al., 2025a,b)的进步。这些方法对于将基础语言模型庞大的通用知识与具体的人类意图、伦理准则及期望的任务导向行为相对齐至关重要。这样的优化过程弥合了两类模型之间的差距：一类能够理解语言，另一类则能够可靠且安全地充当协作者、模拟器或自主智能体。随着语言模型日益融入现实应用，后训练阶段的效果和效率已成为研究与开发的主要关注点。

尽管测试时扩展方法无需训练，并且在许多场景中有效，但后训练通常能够在更低的推理预算下带来更大的性能提升。语言模型的后训练主要采用两种范式：监督微调（Supervised Fine-Tuning，SFT）和强化学习（Reinforcement Learning，RL）。SFT 是一种计算效率较高的方

*本工作在华为香港研究中心实习期间完成。
† 共同贡献。
‡ 通讯作者。

法，它在经过筛选的输入输出配对数据集上训练模型，从而有效赋予模型领域知识。然而，其效果往往受到高质量、全面数据集难以构建的限制。相比之下，基于 RL 的方法将模型视为智能体，使其优化来自人类偏好（基于人类反馈的强化学习，RLHF）或外部验证机制（基于可验证奖励的强化学习，RLVR）的奖励信号，因此能够探索更广泛的动作空间，并在复杂、开放式任务上取得更优表现。其中，RLVR 因对人工输入依赖较低而受到广泛关注。不过，RL 方法的性能收益伴随着显著的计算成本。近端策略优化等算法（PPO，Schulman et al. (2015)）需要同时训练一个独立的价值模型来估计动作的优势，这在资源受限的情形下可能带来难以承受的显存开销。为解决这一问题，一类“无评论家”（critic-free）或基于组的 RL 方法应运而生：它们将优势估计为一组采样轨迹内部的相对量，本质上是以速度换取显存效率。这类方法包括 GRPO (Shao et al., 2024)、Dr. GRPO (Liu et al., 2025)、RLOO (Ahmadian et al., 2024)及其他变体。这些方法的直接缺点是：为每个训练样例生成多条轨迹需要额外计算时间。为了获得稳定的训练过程，生成次数通常必须足够多（例如 16 次），这会进一步增加生成开销，并最终使系统受内存瓶颈限制。因此，如此高的计算需求凸显了提高 RL 训练采样效率的必要性。

RL 算法的高计算需求催生了大量旨在优化性能与成本权衡的研究。其中一条路线采用混合方法，将初始 SFT 阶段与后续 RL 优化阶段相结合 (Chen et al., 2025a)，或将两个阶段整合为单一方法 (Fu et al., 2025)。这些方法能够使训练过程更平稳，甚至加快训练，但往往无法根据模型解决训练问题的能力变化来动态调整训练过程。已有观察表明，仅仅过滤掉准确率接近 0 或 1 的问题就能提升性能 (Yu et al., 2025)，这暗示了更具适应性的控制策略所蕴含的潜力。据我们所知，目前仍缺少衡量此类能力的关键指标，因此也缺少对 GRPO 过程进行自适应控制的机制。

为应对这些挑战，我们提出方差信息驱动的预测式分配策略（VIP），这是一个具有理论依据的训练框架，用于在基于组的策略优化中高效、自适应地分配采样轨迹。我们首先对三种主流 RL 算法的梯度方差进行理论分析，建立每个提示所贡献的梯度方差与当前模型解决该提示的概率之间的关系。基于这一认识，在每次训练迭代开始时，VIP 预测小批次中各提示的期望梯度方差。随后，VIP 根据这些预测求解一个凸优化问题，再采用整数舍入启发式方法，在各提示之间分配采样轨迹，从而在给定计算预算下最小化总期望梯度方差。本文的核心贡献如下：

- **梯度方差分析**。我们严格分析梯度方差对 RL 训练过程的影响，并推导包括 Dr. GRPO 和 RLOO 在内的主流基于组的 RL 方法中，梯度方差与成功概率之间的联系。这为在训练过程中自适应控制预算分配奠定了理论基础。
- **方差预测**。VIP 在提示嵌入上使用高斯过程（Gaussian Process，GP），对任意训练步中每个提示的成功概率建模。这使得递归贝叶斯更新能够同时利用过去的采样结果与提示的相似性结构。借助 GP 预测，该框架能够在每个训练步估计小批次内各提示的梯度方差。
- **最小化方差的采样分配**。给定预测方差，VIP 构建一个凸优化问题，以确定各提示的最优采样分配。该分配在采样预算约束下最小化梯度方差。我们推导了一个高效算法，能够精确求解其连续松弛问题；并进一步提出基于贪心收益的舍入启发式方法，以获得可行的整数解。该过程支持在计算预算约束下快速分配资源。

本文结构如下。第 2 节讨论 RLVR 中基于组的 RL 框架之上的自适应策略相关工作；第 3 节介绍 RLVR 的技术背景。第 4 节给出逐提示梯度方差分析。第 5 节介绍 VIP 框架，包括利用高斯过程预测方差，以及用于采样分配的优化问题。第 6 节给出数学推理和信息检索数据集上的实验结果。

2 相关工作

近期，面向语言模型的基于组的强化学习研究进展，主要关注通过自适应策略同时提高训练效率与性能。这些方法通过动态选择和管理用于策略更新的数据，突破了静态训练流程的局限。 早期研究从经验上表明，过滤掉模型准确率为 0 或 1 的“无信息”问题能够提高训练效率，因为这些问题产生的采样轨迹批次方差为零，因而不对梯度信号作出贡献(Yu et al., 2025)。 沿着类似思路，(Lin et al., 2025)过滤掉绝对优势较低的采样轨迹，而(Xu et al., 2025)提出保留方差最高的样本。由于缺少对训练提示信息量的先验度量，这些方法需要在每次更新迭代之前预先采样一大批轨迹；显著的采样开销可能抵消其效率收益。

一些工作在生成采样轨迹之前估计提示的信息量。(Zheng et al., 2025)提出，以一个由近期连续无信息采样轨迹次数决定的概率跳过每个问题。(Zhang et al., 2025)提出用信噪比表示问题对梯度的贡献，并表明：先生成一个小型试探轨迹批次，以识别并过滤无信息问题，再对中等难度问题继续采样，能够加快训练。(Sun et al., 2025)设计了一种以难度为目标的在线选择算法，结合了基于注意力的难度预测和采样轨迹回放。(Liao et al., 2025)以过去采样轨迹的平均奖励表征难度，对问题排序，并分配资源，为困难提示采样更大的批次。(Yang et al., 2025)采用与(Zhang et al., 2025)类似的方法估计问题难度，并为困难提示分配更大的预算和更高的梯度权重。(Kong et al., 2025)通过汇总问题的历史表现差异来估计提示难度，然后自适应地选择难度与模型当前能力相匹配的问题集合。另一些工作还考虑了熵与奖励之间的权衡，以降低过早收敛的风险。(Liao et al., 2025)将难度感知的重新分配与稳定熵的温度调度相结合，以有效平衡效率与探索。另一种方法则通过在整个训练过程中最大化信息增益来引导探索(Lee et al., 2024)。

3 RLVR 背景

我们研究一类重要的强化学习训练方法，它们采用基于组的优势估计来稳定学习，并更充分地利用奖励信号。这类方法包括组相对策略优化（Group Relative Policy Optimization，GRPO）(Shao et al., 2024)及其变体，如 Dr. GRPO (Liu et al., 2025) 和 RLOO (Ahmadian et al., 2024)。给定包含 Q 个提示的数据集 $\mathcal{Q} = \{q_1, q_2, \ldots, q_Q\}$，基于组的策略优化方法的一般目标函数为

$$J(\theta) = \mathbb{E}_{q\sim\mathcal{Q}}\mathbb{E}_{\pi_{\text{old}}^{\otimes n}}\left[\frac{1}{n}\sum_{j=1}^{n}\frac{1}{|\tilde{o}_j|}\sum_{\tau=1}^{|\tilde{o}_j|}\left(A'_{j,\tau} - \beta\, D_{\text{KL}}\big(\pi_\theta(\cdot \mid q, \tilde{o}_{j,<\tau}) \,\big\|\, \pi_{\text{ref}}(\cdot \mid q, \tilde{o}_{j,<\tau})\big)\right)\right], \tag{1}$$

其中，n 为每个提示的采样轨迹数，$\tilde{o}_j$ 是从策略 π_{old} 生成的第 j 条采样轨迹，$|\tilde{o}_j|$ 为 $\tilde{o}_j$ 中的词元数，π_θ 为具有可学习参数 θ 的当前策略。这里，$D_{\text{KL}}\left(\pi_\theta(\cdot \mid q, \tilde{o}_{j,<\tau}) \,\|\, \pi_{\text{ref}}(\cdot \mid q, \tilde{o}_{j,<\tau})\right)$ 是策略 π_θ 与参考策略 π_{ref} 之间的 Kullback–Leibler 散度；两者都以提示 q 和截至当前已生成的词元 $\tilde{o}_{j,<\tau}$ 为条件。我们使用波浪号（$\sim$）强调这些量的随机性。

对于提示 q，$A'_{j,\tau}$ 是输出 $\tilde{o}_j$ 在词元 τ 处的截断代理项：

$$A'_{j,\tau} = \min\left(r_{j,\tau}\tilde{A}_{j,\tau},\ \text{clip}(r_{j,\tau}, 1-\epsilon, 1+\epsilon)\,\tilde{A}_{j,\tau}\right), \quad \text{其中} \quad r_{j,\tau}(\theta) = \frac{\pi_\theta(\tilde{o}_{j,\tau} \mid q, \tilde{o}_{j,<\tau})}{\pi_{\text{old}}(\tilde{o}_{j,\tau} \mid q, \tilde{o}_{j,<\tau})}. \tag{2}$$

注意，为避免符号繁杂，我们暂时省略下标 q。这里，$r_{j,\tau}$ 是当前策略与生成数据的策略之间的相对比率；$\tilde{A}_{j,\tau}$ 则是输出 $\tilde{o}_j$ 中词元 τ 的优势估计量。令 $R(\tilde{o}_j)$ 为提示 q 上输出 $\tilde{o}_j$ 的奖励，其取值为 -1（错误）或 1（正确）。基于全部 n 条采样轨迹 $\{\tilde{o}_j\}$，有两种常用的优势估计量：

- 在 Dr. GRPO (Liu et al., 2025) 中，$\tilde{A}_j = \tilde{A}_{j,\tau} = R(\tilde{o}_j) - \frac{1}{n}\sum_k R(\tilde{o}_k)$，即使用所有采样轨迹计算均值。
- 在 RLOO (Ahmadian et al., 2024) 中，$\tilde{A}_j = \tilde{A}_{j,\tau} = R(\tilde{o}_j) - \frac{1}{n-1}\sum_{k\neq j} R(\tilde{o}_k)$，即计算均值时排除第 j 个输出。

两种优势估计量都与词元位置无关：第 j 条采样轨迹的所有词元具有相同的优势 $\tilde{A}_j$。本文将重点研究满足下述假设的一种特定训练设定。

假设 3.1. 我们将 KL 正则化项设为零，即 $\beta = 0$。

假设 3.1 既实用，也不会造成限制，原因如下。在 RLHF 中，奖励模型仅在参考策略分布附近可靠(Gao et al., 2023; Chen et al., 2024; Huang et al., 2024; Ramé et al., 2024)，因此 KL 正则化对于防止奖励投机至关重要(Laidlaw et al., 2024; Song et al., 2024; Skalse et al., 2022)。相比之下，本文关注 RLVR 设定，其中的奖励由基于规则的验证器计算。这些可验证奖励消除了对奖励失准的担忧。事实上，近期 RLVR 研究已经成功移除 KL 项，同时仍取得了最先进的性能(Yu et al., 2025; Liu et al., 2025)。

假设 3.1 通过消除 KL 项简化了训练目标。目标函数简化为：

$$J(\theta)=\mathbb{E}_{q\in\mathcal{Q}}\mathbb{E}_{\pi_{\text{old}}^{\otimes n}}\left[\frac{1}{n}\sum_{j=1}^{n}\frac{1}{|\tilde{o}_j|}\sum_{\tau=1}^{|\tilde{o}_j|}\min\left(r_{j,\tau}\tilde{A}_j,\ \text{clip}(r_{j,\tau},1-\epsilon,1+\epsilon)\,\tilde{A}_j.\right)\right]$$

只要 $r_{j,\tau}$ 沿着使代理项变差的方向落到截断区间之外，$\min\left(r_{j,\tau}\tilde{A}_j,\ \text{clip}(r_{j,\tau},1-\epsilon,1+\epsilon)\,\tilde{A}_j\right)$ 就退化为截断项，不贡献梯度。为精确区分梯度何时有效，我们引入指示量

$$\mathbb{I}_{j,\tau}^{\text{unc}}=1-\Big(\mathbf{1}\{r_{j,\tau}>1+\varepsilon\}\,\mathbf{1}\{\tilde{A}_j\geq 0\}+\mathbf{1}\{r_{j,\tau}<1-\varepsilon\}\,\mathbf{1}\{\tilde{A}_j<0\}\Big).$$

利用该指示量，我们定义 $\bar{r}_j=\frac{1}{|\tilde{o}_j|}\sum_{\tau=1}^{|\tilde{o}_j|}\mathbb{I}_{j,\tau}^{\text{unc}}\,r_{j,\tau}$，并将目标重写为：

$$J(\theta)=\mathbb{E}_{q\in\mathcal{Q}}\mathbb{E}_{\pi_{\text{old}}^{\otimes n}}\left[\frac{1}{n}\sum_{j=1}^{n}\tilde{A}_j\bar{r}_j\right]=\mathbb{E}_{q\in\mathcal{Q}}\mathbb{E}_{\pi_{\text{old}}^{\otimes n}}\left[\frac{1}{n}\sum_{j=1}^{n}A_j(\{\tilde{o}_k\})\bar{r}_j\right]. \tag{3}$$

译注：式 (3) 按原文保留。将被截断项置零通常保留的是梯度，而非目标函数本身的严格相等；被省略的截断项仍可具有非零函数值。

下一节研究 J 的梯度方差。

4 梯度方差分析

本节分析 GRPO 和 RLOO 等 RLVR 算法中，采样轨迹所引起的梯度估计量方差。每次更新结合两类数据：从以往批次收集的采样轨迹（异策略），以及针对当前提示批次 $\mathcal{B}$ 新生成的采样轨迹（同策略）。然而，如后文第 5 节所述，我们的研究目标是确定应为 $\mathcal{B}$ 中的提示分配多少条采样轨迹。这项分配决策只影响梯度的同策略部分。异策略部分虽然存在于整体更新中，但完全由历史数据决定，因此不受我们选择新采样的轨迹数影响。因此，要理解分配如何影响梯度方差，只需分离并研究当前策略 π_θ 生成的同策略采样轨迹所产生的方差，这既自然又充分。对于这些同策略样本，行为策略与目标策略一致，即 $\pi_{\text{old}}=\pi_\theta$，因此 $\bar{r}_j=1$。

这些同策略采样轨迹的梯度贡献为：

$$\nabla_\theta J^{\text{on}}(\theta)=\mathbb{E}_{q\in\mathcal{B}}\mathbb{E}_{\pi_\theta^{\otimes n}}\left[\frac{1}{n}\sum_{j=1}^{n}A_j(\{\tilde{o}_k\})\underbrace{\frac{1}{|\tilde{o}_j|}\sum_{\tau=1}^{|\tilde{o}_j|}\nabla_\theta\log\pi_\theta(\tilde{o}_{j,\tau}|q,\tilde{o}_{j,<\tau})}_{\triangleq H(\tilde{o}_j)}\right]. \tag{4}$$

上式中，$H(\tilde{o}_j)$ 是平均对数似然梯度，其中对第 j 条采样轨迹的所有词元取平均。考虑一个具体提示 q 及其 n 条采样轨迹 $\{\tilde{o}_k\}$，q 对样本梯度计算的贡献为 $\frac{1}{n}\sum_{j=1}^{n}A_j(\{\tilde{o}_k\})H(\tilde{o}_j)$，为避免符号繁杂，我们省略下标 q。由于 $H(\tilde{o}_j)$ 是随机向量，这个量也是随机向量。为使方差分析在数学上可处理，同时准确表征参数更新的尺度，我们将研究这一梯度贡献的 L_2 范数。为此，我们关注以下（一维）随机变量：

$$\tilde{G}\triangleq\frac{1}{n}\sum\nolimits_{j=1}^{n}A_j(\{\tilde{o}_k\})\|H(\tilde{o}_j)\|_2.$$

译注：原文此处有重复词“gradient gradient”，中文仅保留一次。原文将分析对象描述为梯度贡献的 L_2 范数；但所定义的 $\tilde{G}$ 实际上是以优势加权的各轨迹梯度范数之和，一般不等于向量梯度贡献整体的 L_2 范数。公式按原文保留。

为简化记号，对所有 j，我们定义随机变量 $\tilde{R}_j=R(\tilde{o}_j)$ 和 $\tilde{Z}_j=\|H(\tilde{o}_j)\|_2$。我们首先考虑 Dr. GRPO。梯度 $\tilde{G}$ 的具体形式为：

$$\tilde{G}\triangleq\frac{1}{n}\sum\nolimits_{j=1}^{n}\big(\tilde{R}_j-\frac{1}{n}\sum\nolimits_{k=1}^{n}\tilde{R}_k\big)\tilde{Z}_j.$$

为严格分析 $\tilde{G}$ 的方差，我们明确提出以下假设。

假设 4.1. (i) $\tilde{R}_1, \ldots, \tilde{R}_n$ 是 $\tilde{R}$ 的独立同分布（i.i.d.）副本，$\tilde{Z}_1, \ldots, \tilde{Z}_n$ 也是 $\tilde{Z}$ 的独立同分布副本；

(ii) $\{\tilde{Z}_j\}$ 与 $\{\tilde{R}_j\}$ 直到二阶均不相关：对任意 (k, j)，有 $\mathrm{Cov}(\tilde{R}_k, \tilde{Z}_j) = 0$；对任意 (k, j, k', j')，有 $\mathrm{Cov}(\tilde{R}_k \tilde{R}_{k'}, \tilde{Z}_j \tilde{Z}_{j'}) = 0$。

假设 4.1 在常见设定下是现实的：给定相同提示及固定采样流程，不同采样轨迹是来自同一分布 π_θ 的独立样本。因此，假定 $\{\tilde{o}_j\}$ 独立同分布是合理的，这也导出了假设 4.1(i)。假设 4.1(ii) 需要进一步论证，因为对于第 j 条采样轨迹，奖励 $\tilde{R}_j$ 可能与平均梯度 $\tilde{Z}_j$ 相关。不过，我们有充分理由相信该假设成立，因为 $\tilde{R}$ 服从伯努利分布，而 $\tilde{Z}_j$ 同时汇总了词元维度上的变化（由 $H(\tilde{o}_j)$ 的定义可见）与高维参数空间中的变化（由 $\|H(\tilde{o}_j)\|_2$ 可见）。在经验层面，我们在附录 B 中给出了支持该假设的统计检验。

下面的结果给出了 Dr. GRPO 情况下的方差。

命题 4.2 (Dr. GRPO 的梯度方差)**.** 考虑一个具有二元奖励 $R(\tilde{o}_j) \in \{1, -1\}$ 的提示，其中 $\mathbb{P}(R(\tilde{o}_j) = 1) = p$。若假设 4.1 成立，且投影梯度 $\tilde{Z}$ 的方差为 σ_Z^2，则使用 n 条采样轨迹时，每个提示的投影 Dr. GRPO 梯度估计量的方差为

$$\mathrm{Var}(\tilde{G}) = \frac{(n-1)}{n^2} 4\sigma_Z^2 p(1-p).$$

现在转向 RLOO。RLOO 梯度 $\tilde{G}$ 的具体形式为：

$$\tilde{G} \triangleq \frac{1}{n} \sum_{j=1}^{n} \big(\tilde{R}_j - \frac{1}{n} \sum_{\substack{k=1 \\ k \neq j}}^{n} \tilde{R}_k\big) \tilde{Z}_j.$$

译注：紧邻上式中留一均值的系数原文为 $1/n$，与第 3 节 RLOO 定义中的 $1/(n-1)$ 不一致，疑为笔误。此处保留原式。

命题 4.3 (RLOO 的梯度方差)**.** 考虑一个具有二元奖励 $R(\tilde{o}_j) \in \{1, -1\}$ 的提示，其中 $\mathbb{P}(R(\tilde{o}_j) = 1) = p$。若假设 4.1 成立，且投影梯度 $\tilde{Z}$ 的方差为 σ_Z^2，则使用 n 条采样轨迹时，每个提示的投影 RLOO 梯度估计量的方差为

$$\mathrm{Var}(\tilde{G}) = \frac{1}{n-1} 4\sigma_Z^2 p(1-p).$$

5 预测式采样轨迹分配策略

考虑某次迭代 t，我们已从训练提示集合中抽取一个小批次 $\mathcal{B}_t$。命题 4.2–4.3 表明，一个提示的梯度方差取决于采样轨迹数。因此，为每个提示统一分配 n 条采样轨迹可能并不高效。第 4 节揭示，每个提示的梯度方差取决于成功概率 p_q，即模型 θ_t 正确回答提示 q 的概率。然而，在不生成采样轨迹的情况下，事先无法观察这一概率，因此必须借助估计值 $\hat{p}_q$ 作出分配决策。构建成功概率估计器至少面临两项挑战：第一，遗憾的是，成功概率并非静态，它取决于每次训练迭代后都会变化的模型权重。随着权重更新，输出分布发生改变，成功概率也随之漂移。第二，提示嵌入可能不包含对参数化分类器而言信息量足够的信号。

为提高采样轨迹效率，我们提出 VIP，即方差信息驱动的预测式分配策略。该策略为小批次中的每个提示分配不同数量的采样轨迹 $\{n_q\}$，从而最小化小批次梯度方差。图 1 展示了 VIP从预测到优化采样轨迹分配的完整流程。VIP由两个主要部分组成：（i）用于预测当前模型在每个训练提示上成功概率的非参数高斯过程模型（绿色框）；（ii）在给定计算预算下作出最优分配决策的优化模型（蓝色框）。在迭代 t 开始时，我们首先按第 5.1 节所述方法，预测所有 $q \in \mathcal{B}_t$ 的成功概率。这些概率估计值将作为第 5.2 节优化框架的输入，用于在各提示之间分配采样轨迹。

5.1 高斯过程先验与递归后验更新

给定训练提示 $\mathcal{Q} = \{q_1, q_2, \ldots, q_Q\}$，记其嵌入为 $\mathcal{D} = \{x_q\}_{q=1}^{Q}$。每次迭代 t，通过对潜在值 $g_t(x_q)$ 应用 sigmoid 链接函数，建模当前模型在提示 q 上的成功概率：

$$p_{q,t} = \mathrm{sigmoid}(g_t(x_q)) = 1/[1 + \exp(-g_t(x_q))] \in (0, 1),$$

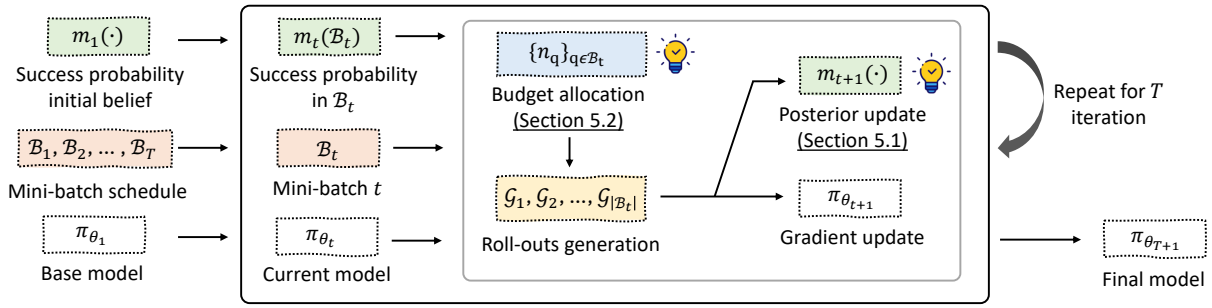


图 1: 流程从关于提示成功概率的初始信念开始。每个步骤 t 选择一个小批次 $\mathcal{B}_t$，并由信念函数 $m_t(\cdot)$ 预测 $\mathcal{B}_t$ 中各提示的成功概率。预算分配模块分配采样轨迹预算 $\{n_q\}$，随后生成采样轨迹，并利用所得数据更新模型与信念。重复 T 步之后，得到性能改善且采样轨迹使用高效的微调模型 $\pi_{\theta_{T+1}}$。

其中，$g_t : \mathbb{R}^d \to \mathbb{R}$ 是定义在提示嵌入上的潜在函数。由于 g_t 为实值函数，在 g_t 上建立高斯过程更为简单。为此，我们设 $g_t \sim \mathrm{GP}(m_t(\cdot), \mathcal{K}(\cdot,\cdot))$，其中 m_t 为均值函数，$\mathcal{K}$ 为带宽 $h > 0$ 的径向基函数（RBF）核：$\mathcal{K}(x, x') = \exp(-\|x - x'\|_2^2/(2h^2))$。

初始化。 在 $t = 1$ 时，采用零均值先验 $g_1 \sim \mathrm{GP}(0, \mathcal{K})$。在数据集 $\mathcal{D} = \{x_q\}_{q=1}^{Q}$ 上，这给出 $g_1(\mathcal{D}) \sim \mathcal{N}(0, \Sigma)$，其中 $\Sigma = \mathcal{K}(\mathcal{D}, \mathcal{D})$ 为所有提示上的核矩阵。

预测。 在迭代 t，使用先验 m_t，对 $q \in \mathcal{B}_t$ 预测 $\hat{p}_{q,t} = \mathrm{sigmoid}(m_t(x_q))$。这些预测值将输入优化问题，以计算采样轨迹分配。

序贯更新。 在迭代 $t \geq 1$，所有提示的潜在值由随机向量 $[g_t(x_1), \ldots, g_t(x_Q)]^\top \sim \mathcal{N}(m_t, \Sigma)$ 表示。对于 $q \in \mathcal{B}_t$，我们观测到 n_q 条采样轨迹，以及奖励 $\tilde{R}_{q,j} \in \{-1, 1\}$，其中 $j = 1, \ldots, n_q$。然后计算截断后的平均值：

$$\bar{R}_q = \frac{1}{n_q} \sum\nolimits_{j=1}^{n_q} \tilde{R}_{q,j} \in [-1, 1], \quad \hat{p}_{q,t} = \mathrm{clip}\Big(\frac{\bar{R}_q + 1}{2}, \epsilon, 1 - \epsilon\Big) \in (\epsilon, 1 - \epsilon),$$

由此得到 $q \in \mathcal{B}_t$ 的潜在值观测 $\hat{g}_{q,t} = \mathrm{sigmoid}^{-1}(\hat{p}_{q,t}) \in \mathbb{R}$。这里必须进行截断，以避免 $\bar{R}_{q,t} = -1$ 或 1 时潜在变量取无穷值的情况。将这些潜在值的集合记为 $\hat{g}_{\mathcal{B}_t}$。令 $\mathcal{B}_t^c$ 为补集，包含所有不在小批次 $\mathcal{B}_t$ 中的提示。我们可将均值向量与协方差矩阵分块表示为：

$$m_t = \begin{bmatrix} m_{t,\mathcal{B}_t} \\ m_{t,\mathcal{B}_t^c} \end{bmatrix}, \qquad \Sigma = \begin{bmatrix} \Sigma_{\mathcal{B}_t\mathcal{B}_t} & \Sigma_{\mathcal{B}_t\mathcal{B}_t^c} \\ \Sigma_{\mathcal{B}_t^c\mathcal{B}_t} & \Sigma_{\mathcal{B}_t^c\mathcal{B}_t^c} \end{bmatrix},$$

在迭代 t，未查询提示上的后验为 $g_{t,\mathcal{B}_t^c} \mid \hat{g}_{\mathcal{B}_t} \sim \mathcal{N}(m_t^\star, \Sigma^\star)$，其中

$$m_{t,\mathcal{B}_t^c}^\star = m_{t,\mathcal{B}_t^c} + \Sigma_{\mathcal{B}_t^c\mathcal{B}_t} \Sigma_{\mathcal{B}_t\mathcal{B}_t}^{-1} (\hat{g}_{\mathcal{B}_t} - m_{t,\mathcal{B}_t}), \quad \Sigma^\star = \Sigma_{\mathcal{B}_t^c\mathcal{B}_t^c} - \Sigma_{\mathcal{B}_t^c\mathcal{B}_t} \Sigma_{\mathcal{B}_t\mathcal{B}_t}^{-1} \Sigma_{\mathcal{B}_t\mathcal{B}_t^c}.$$

下一步的先验。 将迭代 t 的先验均值更新为后验均值，方法如下：若 $q \in \mathcal{B}_t$，则设 $m_{t+1}(x_q) = \hat{g}_{q,t}$；若 $q \in \mathcal{B}_t^c$，则设 $m_{t+1}(x_q) = m_{t,\mathcal{B}_t^c}^\star(x_q)$。此后验均值 m_{t+1} 将作为迭代 $t+1$ 的先验。

5.2 用于最小化梯度方差的自适应预算分配

考虑一个包含 B 个提示的小批次 $\mathcal{B}_t$，每个提示 $q \in \mathcal{B}_t$ 都有第 5.1 节高斯过程模型给出的预测成功概率 $\hat{p}_q$。现在，我们关注在总预算为 C 条采样轨迹的硬约束下，如何决定为批次 $\mathcal{B}_t$ 中每个提示分配的采样轨迹数 $\{n_q\}$。此外，我们要求采样轨迹数介于下界 L 与上界 U 之间：采样轨迹数过少，不太可能获得具有区分力的奖励信号；采样轨迹数过多，则可能导致过拟合。为使问题设定有意义，我们要求 $L \geq 3$，并假定 $BL \leq C \leq BU$。

我们的目标是最小化小批次 $\mathcal{B}_t$ 中各提示产生的梯度方差之和。该问题可表示为整数优化问题：

$$\min \Big\{ \sum\nolimits_{q\in\mathcal{B}_t} \mathrm{Var}(\tilde{G}_q) \;:\; \sum\nolimits_{q\in\mathcal{B}_t} n_q = C, \quad n_q \in \{L, L+1, \ldots, U\} \quad \forall q \in \mathcal{B}_t \Big\}. \tag{5}$$

方差 $\mathrm{Var}(\tilde{G}_q)$ 很可能是采样轨迹分配 n_q 的非线性函数，因此式 (5) 成为非线性整数优化问题。为解决这一问题，我们将先求解其连续松弛，再应用启发式取整算法。

预算分配的松弛解。 命题 4.2 给出了 Dr. GRPO 中每个提示的梯度方差 $\mathrm{Var}(\tilde{G}_q)$。对每个 $q \in \mathcal{B}_t$ 定义 $a_q \triangleq 4\,\sigma_{Z_q}^2 \hat{p}_q(1-\hat{p}_q)$，则 Dr. GRPO 下问题 (5) 的连续松弛为

$$\min \left\{ \sum\nolimits_{q\in\mathcal{B}_t} a_q \frac{n_q - 1}{n_q^2} \;:\; \sum\nolimits_{q\in\mathcal{B}_t} n_q = C, \quad L \le n_q \le U, \quad n_q \in \mathbb{R}\ \forall q \in \mathcal{B}_t \right\}. \tag{6}$$

下面的定理给出求解式 (6) 的一种计算高效的方法。

定理 5.1 (连续分配，Dr. GRPO)**.** 对于每个 $q \in \mathcal{B}_t$，令 $n_q^\star$ 为以下函数：

$$n_q^\star(\lambda) = \begin{cases} U & \text{若 } \lambda \le a_q \frac{U-2}{U^3}, \\ \lambda = a_q \frac{n_q - 2}{n_q^3} \text{ 的唯一解} & \text{若 } a_q \frac{U-2}{U^3} < \lambda < a_q \frac{L-2}{L^3}, \\ L & \text{若 } \lambda \ge a_q \frac{L-2}{L^3}. \end{cases} \tag{7}$$

若 $BL \le C \le BU$，则代数方程 $\sum_q n_q^\star(\lambda^\star) = C$ 有唯一解 $\lambda^\star$。于是，式 (6) 的唯一最小化解对所有 q 均由 $n_q^\star = n_q^\star(\lambda^\star)$ 给出。此外，$\lambda^\star$ 可通过二分法求得。

类似地，对于 RLOO，我们可利用命题 4.3，对 $q \in \mathcal{B}_t$ 定义相同的参数 $a_q \triangleq 4\,\sigma_{Z_q}^2 \hat{p}_q(1-\hat{p}_q)$。RLOO 下式 (5) 的连续松弛为

$$\min \left\{ \sum\nolimits_{q\in\mathcal{B}_t} a_q \frac{1}{n_q - 1} \;:\; \sum\nolimits_{q\in\mathcal{B}_t} n_q = C, \quad L \le n_q \le U, \quad n_q \in \mathbb{R}\ \forall q \in \mathcal{B}_t \right\}. \tag{8}$$

借助下述结果，我们能够高效求解式 (8)。

定理 5.2 (连续分配，RLOO)**.** 对于每个 $q \in \mathcal{B}_t$，令 $n_q^\star$ 为以下函数：

$$n_q^\star(\lambda) = \begin{cases} U & \text{若 } \lambda \le a_q/(U-1)^2, \\ 1 + \sqrt{a_q/\lambda} & \text{若 } a_q/(U-1)^2 < \lambda < a_q/(L-1)^2, \\ L & \text{若 } \lambda \ge a_q/(L-1)^2 \end{cases} \tag{9}$$

若 $BL \le C \le BU$，则代数方程 $\sum_q n_q^\star(\lambda^\star) = C$ 有唯一解 $\lambda^\star$。于是，式 (8) 的唯一最小化解对所有 q 均由 $n_q^\star = n_q^\star(\lambda^\star)$ 给出。此外，$\lambda^\star$ 可通过二分法求得。

译注：上述两个定理的“$\lambda^\star$ 唯一”表述按原文保留。在 $C = BL$ 或 $C = BU$ 等边界情形，乘子可能不唯一；若存在 $a_q = 0$ 等退化情形，最小化解的唯一性也需额外条件。

启发式取整。 首先，将 $n_q^\star$ 向下取整为 $\lfloor n_q^\star \rfloor$。令 $f_q(n)$ 表示每个提示的目标函数：对于 Dr. GRPO，$f_q(n) = a_q \frac{n-1}{n^2}$；对于 RLOO，$f_q(n) = a_q \frac{1}{n-1}$。随后，将剩余预算迭代地分配给那些在增加一条采样轨迹时能使 f_q 降幅最大的提示。该过程持续到总预算 C 耗尽，并保证每个提示的上下界约束 $L \le \hat{n}_q \le U$ 得到满足。具体流程见附录 D。

6 数值实验

现在，我们展示 VIP 框架在数学推理任务和工具增强推理任务上的实验收益。两项任务的共同设置如下：我们使用 `all-MiniLM-L6-v2` 将每个提示 q 编码为 384 维向量 x_q。训练前，预先计算并缓存所有提示对之间的欧氏距离，使运行时开销可以忽略。我们使用中位数启发式方法设定核 $\mathcal{K}$ 的带宽 h。计算分配时，我们还假设所有 q 对应的 $\tilde{Z}_q$ 方差相同；附录 B.3 中的统计检验为这一假设提供支持。在两种总采样预算 $8 \times Q$ 和 $16 \times Q$ 下，所有模型均训练两个轮次（epoch），其中 Q 是数据集大小。我们将 VIP 集成到 RLOO 和 Dr. GRPO 两种组相对策略优化基线之上：数学实验使用 VERL (Sheng et al., 2024) 实现，工具增强任务则遵循 (Chen et al., 2025b; Jin et al., 2025)。我们严格遵循 RL 训练所采用的默认超参数设置。

数学推理任务。 在数学推理任务中，我们在 DAPO-MATH-17k (Yu et al., 2025) 上训练，并在 AIME2024 和 AIME2025 上评估。我们比较 Dr. GRPO 和 RLOO 在使用与不使用自适应采样分配方法时的表现，以评估 VIP。实验采用三个骨干语言模型（`Qwen2.5-Math-1.5B`、`Qwen2.5-Math-7B` 和 `Llama-3.2-3B-Instruct`），在 AIME24/25 上使用两种采样预算设置 $C \in \{8 \times Q, 16 \times Q\}$。我们报告 Pass@32、Mean@32 和 Maj@32，以反映多条采样轨迹的准确率与共识程度。结果汇总于表 1。总体而言，在三个基础模型和两种预算下，加入 VIP 都能持续改善 Pass@32 和 Mean@32。例如，在 $8 \times Q$ 预算下的 Qwen2.5-Math-1.5B 上，$\text{RLOO}_{\text{+VIP}}$ 相较于 RLOO，使 Pass@32 提高 12.3 个百分点、Mean@32 提高 6.3 个百分点。Llama-3.2-3B-Instruct 和 Qwen2.5-Math-7B 上也呈现类似模式。

我们发现，VIP 在 1.5B 和 3B 模型上的相对性能提升大于在 7B 模型上的提升。这表明，VIP 考虑预算的方差降低机制，可能尤其有助于那些原本无法充分利用采样预算的较弱骨干模型。

表 1: AIME24 和 AIME25 上的百分比结果。上半部分使用总采样预算 $C = 8 \times Q$，下半部分使用 $C = 16 \times Q$。对于每组配对（Dr. GRPO 与 Dr. $\text{GRPO}_{\text{+VIP}}$，以及 RLOO 与 $\text{RLOO}_{\text{+VIP}}$），较高数值以绿色标出。

模型	方法	AIME24			AIME25		
		Pass@32	Mean@32	Maj@32	Pass@32	Mean@32	Maj@32
Qwen2.5-Math-1.5B	Dr. GRPO	34.56	7.91	11.26	24.03	7.62	4.89
	Dr. GRPO+VIP	33.63	9.167	15.5	29.82	6.14	10.76
	RLOO	18.29	3.43	6.88	15.90	2.29	8.04
	RLOO+VIP	30.55	9.68	15.65	26.54	6.35	13.72
Qwen2.5-Math-7B	Dr. GRPO	50.0	19.0	34.0	34.0	10.0	15.0
	Dr. GRPO+VIP	58.98	23.65	38.15	36.08	10.0	19.74
	RLOO	53.0	18.0	24.0	45.0	11.0	16.0
	RLOO+VIP	58.0	20.0	35.0	34.0	11.0	18.0
Llama-3.2-3B-Instruct	Dr. GRPO	24.68	6.25	10.62	4.28	0.21	0.07
	Dr. GRPO+VIP	29.18	8.85	17.21	9.37	0.94	2.35
	RLOO	28.84	8.229	13.95	9.157	0.5208	0.3633
	RLOO+VIP	35.59	9.479	19.0	9.99	0.625	0.61
Qwen2.5-Math-1.5B	Dr. GRPO	23.96	9.479	13.64	28.21	5.83	9.97
	Dr. GRPO+VIP	27.37	12.08	15.01	33.05	8.43	13.77
	RLOO	18.0	3.0	7.0	22.0	2.0	3.0
	RLOO+VIP	27.0	6.0	14.0	26.0	8.0	4.0
Qwen2.5-Math-7B	Dr. GRPO	52.0	19.0	35.0	36.0	10.0	20.0
	Dr. GRPO+VIP	57.0	20.0	33.0	36.0	13.0	21.0
	RLOO	37.43	14.79	21.93	41.51	10.0	19.44
	RLOO+VIP	53.85	21.77	35.59	38.32	10.31	21.4
Llama-3.2-3B-Instruct	Dr. GRPO	23.26	6.35	10.09	5.49	0.63	1.31
	Dr. GRPO+VIP	32.34	8.23	14.96	10.67	0.52	0.05
	RLOO	29.3	6.88	1.74	9.57	0.73	1.68
	RLOO+VIP	31.32	7.71	1.77	11.42	0.63	0.32

译注：本表保留原文数值与绿色标记。原表中部分绿色标记与“较高值”说明不一致，例如上半部分 Qwen2.5-Math-1.5B 的 Dr. GRPO 配对在 AIME25 Mean@32 上将 6.14 标绿，而基线为 7.62；正文的总体改善表述也存在例外，均未擅自修改。

工具增强推理任务。 我们应用所提出的分配策略，训练语言模型在生成过程中使用检索工具。遵循 Chen et al. (2025b)，我们在 MuSiQue（19,938 个提示）(Trivedi et al., 2022) 上训练，并在 Bamboogle 基准 (Press et al., 2022) 和 MuSiQue 测试集上评估。训练期间，检索模型使用 `intfloat/e5-base-v2` 嵌入 (Wang et al., 2022)。本实验选用 `Qwen2.5-3B-Instruct` 作为基础模型。我们采用 Precision@5 和 F1@5 衡量检索质量，并以完全匹配（Exact Match，EM）衡量最终生成结果的正确性。结果汇总于表 2。

在固定采样预算下，VIP 以联动的方式同时改善答案准确率和检索质量。在 Bamboogle 上，

表 2: Bamboogle 和 MuSiQue 上的性能。绿色单元格表示 +VIP 变体相较于其基础方法有所提升。

方法	Bamboogle			MuSiQue		
	EM	F1@5	Precision@5	EM	F1@5	Precision@5
Dr. GRPO	20	0.282	0.293	6	0.123	0.126
Dr. GRPO+VIP	23.2	0.333	0.353	10.5	0.214	0.225
RLOO	10.4	0.190	0.225	8.5	0.178	0.179
RLOO+VIP	17.6	0.264	0.294	11	0.209	0.211

表 3: AIME24 和 AIME25 上的消融研究。所有数值均为百分比。每项指标中，各方法的最高值以绿色标出。

方法	AIME24			AIME25		
	Pass@32	Mean@32	Maj@32	Pass@32	Mean@32	Maj@32
RLOO	18.29	3.43	6.88	15.90	2.29	8.04
RLOO+GP+Inverse Acc	24.61	6.77	7.90	19.10	3.33	5.03
RLOO+GP+Inverse Var	25.83	4.90	10.90	21.11	2.08	3.79
RLOO+Ridge+Allocation	29.90	6.97	14.79	24.85	5.20	12.12
RLOO+VIP	30.55	9.68	15.65	26.54	6.35	13.72

Dr. $\text{GRPO}_{\text{+VIP}}$ 将 EM 从 20 提升至 23.2，同时使 F1@5/Precision@5 分别提高 $+0.051/+0.060$；$\text{RLOO}_{\text{+VIP}}$ 的绝对提升更大（EM 从 $10.4 \to 17.6$，F1@5 从 $0.190 \to 0.264$，Precision@5 从 $0.225 \to 0.294$）。F1@5 和 Precision@5 的同步提升意味着误报更少、对有用上下文的排序更好；EM 的提升则表明，检索到的证据能够更可靠地融入最终答案。这些现象支持将 VIP 视为一种采样高效、领域无关的工具增强推理机制。

消融研究。我们对 VIP 的两个核心组件进行消融：(i) 方差预测器，以及 (ii) 自适应预算分配器。我们以岭回归基线替代高斯过程预测器（第 5.1 节），并用逆准确率和逆方差两种启发式策略替代自适应分配器（第 5.2 节），细节见附录。Qwen2.5-Math-1.5B 上的消融结果汇总于表 3。RLOO+VIP 在所有指标上均取得最佳表现，优于每一种消融变体。在各组件中，自适应分配最为关键：以启发式策略替换它，会使所有指标显著下降。以岭回归替换高斯过程造成的退化较小，但同样一致存在，这说明经过校准的不确定性能够进一步提高分配效果。总体而言，这些结果证实，VIP 的收益主要来自考虑方差的预算分配。

运行时间比较。表 4 报告了本方法在单次梯度步中各组件的平均运行时间。总计算开销极小：计入训练前缓存的计算后，在 1.5B 参数和 7B 参数模型上，本方法仅分别增加整体 RL 训练时间的 1.12% 和 0.83%。若不计缓存计算，额外开销进一步降至 0.79% 和 0.58%。由于模型前向计算与采样成本在更大规模下占主导地位，这一相对开销会随着模型规模增大而降低。

表 4: Qwen2.5-Math-1.5B 和 Qwen2.5-Math-7B 的核心计算组件及模型相关操作的实际运行时间，在单张 GPU 上测得。

模型	**操作**	**时间（秒）**
—	核矩阵计算（算法 1）*	10.652
—	高斯过程训练与预测（算法 1）	0.745
—	采样分配（第 5.2 节 + 算法 2）	29.956
Qwen2.5-Math-1.5B	轨迹采样	2781.2
Qwen2.5-Math-1.5B	对数概率计算	627.68
Qwen2.5-Math-1.5B	策略更新	263.9
Qwen2.5-Math-7B	轨迹采样	3134.4
Qwen2.5-Math-7B	对数概率计算	1388.8
Qwen2.5-Math-7B	策略更新	713.5

*训练前缓存。

成功概率预测质量。为评估高斯过程预测器的质量，我们使用 RLOO 对 Qwen2.5-Math-1.5B

和 Qwen2.5-Math-7B 训练 55 个梯度步，并在每一步记录逐提示成功概率，以构建时间序列数据集。由于策略在每次更新后都会变化，底层成功概率也随时间漂移，因此预测器必须能够适应这种非平稳性。我们将 VIP 的 GP 预测器与移动平均和岭回归两种基线比较，使用最近的 1024 个样本预测下一个小批次的成功概率。图 3 报告了各步的平均绝对误差（MAE）。移动平均和岭回归基线难以跟踪模型行为的快速变化，而 GP 在两种模型规模的整个训练过程中始终保持较低的 MAE。这表明，在 RL 训练的非平稳动态下，GP 提供了更准确、更具适应性的估计器。

7 结论

本文提出方差信息驱动的预测式分配框架，用于最小化基于组的强化学习中的梯度方差。VIP 将基于高斯过程的提示成功概率预测与采样分配优化方法相结合，更高效地利用有限的采样预算。数学推理和工具增强基准上的实验表明，与启发式或均匀分配策略相比，该方法能够带来持续收益。VIP 朝着更具适应性、更节省资源且更有理论依据的大语言模型训练流程迈出了一步。未来工作将探索将其与不可验证或带噪声的奖励相结合，从而拓展到 RLHF 及其他对齐范式。

伦理声明。所有作者均已阅读并同意，在本研究的开展、投稿及可能的发表过程中遵守 ICLR 伦理准则。本研究不涉及人类受试者、个人数据或任何敏感信息。所有使用的数据集均公开可得，且不包含可识别个人身份的信息。我们已审慎确保本方法不会引入或放大偏见、歧视或不公平，因为 RLVR 中的奖励信号由基于规则的验证器决定，而非主观的人类判断。我们公开全部代码与实验规程，以促进透明性和可复现性。据我们所知，本研究不存在潜在利益冲突、法律合规问题或研究诚信方面的疑虑。

可复现性声明。我们已尽一切努力确保结果可复现。论文中描述的所有模型、算法和实验，均在正文与附录中附有详细说明。为进一步支持复现，我们提供了一个匿名代码仓库，其中包含完整源代码，以及运行实验和复现结果的说明。所用数据集均公开可得，附录清楚说明了相关预处理步骤。对于所有理论结果，我们均明确陈述了假设，并在补充材料中给出了完整证明。

大语言模型使用声明。在论文准备过程中，我们将大语言模型用作通用工具，用于校对、改写，以及检查部分章节的表述是否清晰。研究构想、实验、分析和主要写作均由作者完成。

致谢。Viet Anh Nguyen 感谢香港中文大学提升新聘教师竞争力资助计划、UGC ECS Grant 24210924 和 UGC GRF Grant 14208625 的支持。作者感谢 Dongxuan Zhu 和 Hongzheng Yang 就资源分配与强化学习所进行的有益讨论。

参考文献

Arash Ahmadian, Chris Cremer, Matthias Gallé, Marzieh Fadaee, Julia Kreutzer, Olivier Pietquin, Ahmet Üstün, and Sara Hooker. Back to basics: Revisiting reinforce style optimization for learning from human feedback in LLMs. arXiv preprint arXiv:2402.14740, 2024.

Jack Chen, Fazhong Liu, Naruto Liu, Yuhan Luo, Erqu Qin, Harry Zheng, Tian Dong, Haojin Zhu, Yan Meng, and Xiao Wang. Step-wise adaptive integration of supervised fine-tuning and reinforcement learning for task-specific llms. arXiv preprint arXiv:2505.13026, 2025a.

Lichang Chen, Chen Zhu, Davit Soselia, Jiuhai Chen, Tianyi Zhou, Tom Goldstein, Heng Huang, Mohammad Shoeybi, and Bryan Catanzaro. Odin: Disentangled reward mitigates hacking in rlhf. arXiv preprint arXiv:2402.07319, 2024.

Mingyang Chen, Tianpeng Li, Haoze Sun, Yijie Zhou, Chenzheng Zhu, Haofen Wang, Jeff Z Pan, Wen Zhang, Huajun Chen, Fan Yang, et al. Learning to reason with search for LLMs via reinforcement learning. arXiv preprint arXiv:2503.19470, 2025b.

Xidong Feng, Ziyu Wan, Muning Wen, Stephen Marcus McAleer, Ying Wen, Weinan Zhang, and Jun Wang. Alphazero-like tree-search can guide large language model decoding and training. arXiv preprint arXiv:2309.17179, 2023.

Yuqian Fu, Tinghong Chen, Jiajun Chai, Xihuai Wang, Songjun Tu, Guojun Yin, Wei Lin, Qichao Zhang, Yuanheng Zhu, and Dongbin Zhao. Srft: A single-stage method with supervised and reinforcement fine-tuning for reasoning. arXiv preprint arXiv:2506.19767, 2025.

Leo Gao, John Schulman, and Jacob Hilton. Scaling laws for reward model overoptimization. In International Conference on Machine Learning, pp. 10835–10866. PMLR, 2023.

Audrey Huang, Wenhao Zhan, Tengyang Xie, Jason D Lee, Wen Sun, Akshay Krishnamurthy, and Dylan J Foster. Correcting the mythos of kl-regularization: Direct alignment without overoptimization via chi-squared preference optimization. arXiv preprint arXiv:2407.13399, 2024.

Jiajie Jin, Yutao Zhu, Zhicheng Dou, Guanting Dong, Xinyu Yang, Chenghao Zhang, Tong Zhao, Zhao Yang, and Ji-Rong Wen. Flashrag: A modular toolkit for efficient retrieval-augmented generation research. In Companion Proceedings of the ACM on Web Conference 2025, pp. 737–740, 2025.

Deyang Kong, Qi Guo, Xiangyu Xi, Wei Wang, Jingang Wang, Xunliang Cai, Shikun Zhang, and Wei Ye. Rethinking the sampling criteria in reinforcement learning for llm reasoning: A competence-difficulty alignment perspective. arXiv preprint arXiv:2505.17652, 2025.

Cassidy Laidlaw, Shivam Singhal, and Anca Dragan. Correlated proxies: A new definition and improved mitigation for reward hacking. arXiv preprint arXiv:2403.03185, 2024.

Min Lee, Jinsu Kim, Seongmin Park, Young Choi, Sungmin Jung, and Sangjun Han. MaxInfoRL: Boosting exploration in reinforcement learning through information gain maximization. arXiv preprint arXiv:2412.12098, 2024.

Mengqi Liao, Xiangyu Xi, Chen Ruinian, Jia Leng, Yangen Hu, Ke Zeng, Shuai Liu, and Huaiyu Wan. Enhancing efficiency and exploration in reinforcement learning for llms. In Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, pp. 1451–1463, 2025.

Zhihang Lin, Mingbao Lin, Yuan Xie, and Rongrong Ji. Cppo: Accelerating the training of group relative policy optimization-based reasoning models. arXiv preprint arXiv:2503.22342, 2025.

Zichen Liu, Changyu Chen, Wenjun Li, Penghui Qi, Tianyu Pang, Chao Du, Wee Sun Lee, and Min Lin. Understanding r1-zero-like training: A critical perspective. arXiv preprint arXiv:2503.20783, 2025.

Bao Nguyen, Hieu Trung Nguyen, Ruifeng She, Xiaojin Fu, and Viet Anh Nguyen. Reasoning planning for language models. In The Thirty-ninth Annual Conference on Neural Information Processing Systems, 2025a.

Hieu Trung Nguyen, Bao Nguyen, and Viet Anh Nguyen. Structured pruning for diverse best-of-n reasoning optimization. In Findings of the Association for Computational Linguistics: ACL 2025, pp. 23911–23922, 2025b.

Ofir Press, Muru Zhang, Sewon Min, Ludwig Schmidt, Noah A Smith, and Mike Lewis. Measuring and narrowing the compositionality gap in language models. arXiv preprint arXiv:2210.03350, 2022.

Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D Manning, Stefano Ermon, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. volume 36, pp. 53728–53741, 2023.

Alexandre Ramé, Nino Vieillard, Léonard Hussenot, Robert Dadashi, Geoffrey Cideron, Olivier Bachem, and Johan Ferret. Warm: On the benefits of weight averaged reward models. arXiv preprint arXiv:2401.12187, 2024.

John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In International Conference on Machine Learning, pp. 1889–1897. PMLR, 2015.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. arXiv preprint arXiv:2402.03300, 2024.

Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. Hybridflow: A flexible and efficient RLHF framework. arXiv preprint arXiv: 2409.19256, 2024.

Joar Skalse, Nikolaus Howe, Dmitrii Krasheninnikov, and David Krueger. Defining and characterizing reward gaming. Advances in Neural Information Processing Systems, 35:9460–9471, 2022.

Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. Scaling llm test-time compute optimally can be more effective than scaling model parameters. arXiv preprint arXiv:2408.03314, 2024.

Yuda Song, Gokul Swamy, Aarti Singh, J Bagnell, and Wen Sun. The importance of online data: Understanding preference fine-tuning via coverage. Advances in Neural Information Processing Systems, 37:12243–12270, 2024.

Yifan Sun, Jingyan Shen, Yibin Wang, Tianyu Chen, Zhendong Wang, Mingyuan Zhou, and Huan Zhang. Improving data efficiency for llm reinforcement fine-tuning through difficulty-targeted online data selection and rollout replay. arXiv preprint arXiv:2506.05316, 2025.

Yuxuan Tong, Xiwen Zhang, Rui Wang, Ruidong Wu, and Junxian He. Dart-math: Difficulty-aware rejection tuning for mathematical problem-solving. volume 37, pp. 7821–7846, 2024.

Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. Musique: Multihop questions via single-hop question composition. Transactions of the Association for Computational Linguistics, 10:539–554, 2022.

Liang Wang, Nan Yang, Xiaolong Huang, Binxing Jiao, Linjun Yang, Daxin Jiang, Rangan Majumder, and Furu Wei. Text embeddings by weakly-supervised contrastive pre-training. arXiv preprint arXiv:2212.03533, 2022.

Yixuan Even Xu, Yash Savani, Fei Fang, and J Zico Kolter. Not all rollouts are useful: Down-sampling rollouts in llm reinforcement learning. arXiv preprint arXiv:2504.13818, 2025.

Zhicheng Yang, Zhijiang Guo, Yinya Huang, Yongxin Wang, Dongchun Xie, Yiwei Wang, Xiaodan Liang, and Jing Tang. Depth-breadth synergy in rlvr: Unlocking llm reasoning gains with adaptive exploration. arXiv preprint arXiv:2508.13755, 2025.

Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, et al. Dapo: An open-source LLM reinforcement learning system at scale. arXiv preprint arXiv:2503.14476, 2025.

Ruiqi Zhang, Daman Arora, Song Mei, and Andrea Zanette. Speed-rl: Faster training of reasoning models via online curriculum learning. arXiv preprint arXiv:2506.09016, 2025.

Haizhong Zheng, Yang Zhou, Brian R Bartoldson, Bhavya Kailkhura, Fan Lai, Jiawei Zhao, and Beidi Chen. Act only when it pays: Efficient reinforcement learning for llm reasoning via selective rollouts. arXiv preprint arXiv:2506.02177, 2025.

A 技术结果的证明

A.1 第 4 节的证明

命题 4.2 的证明. 回顾 $\tilde{G}_q$ 的表达式:

$$\tilde{G}_q = \frac{1}{n}\sum_{j=1}^{n}(\tilde{R}_j - \frac{1}{n}\sum_{k=1}^{n}\tilde{R}_k)\tilde{Z}_j.$$

$\tilde{G}_q$ 的期望为:

$$\begin{aligned}
\mathbb{E}[\tilde{G}_q] &= \mathbb{E}[\frac{1}{n}\sum_{j=1}^{n}(\tilde{R}_j - \frac{1}{n}\sum_{k=1}^{n}\tilde{R}_k)\tilde{Z}_j] \\
&= \mathbb{E}[\frac{1}{n}\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j - \frac{1}{n^2}\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j] \\
&= \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}[\tilde{R}_j\tilde{Z}_j] - \frac{1}{n^2}\sum_{j=1}^{n}\sum_{k=1}^{n}\mathbb{E}[\tilde{R}_k\tilde{Z}_j] \\
&= \mathbb{E}[\tilde{R}\tilde{Z}] - \mathbb{E}[\tilde{R}\tilde{Z}] = 0 \qquad \text{(由假设 4.1}(i)\text{)}.
\end{aligned}$$

$\tilde{G}_q$ 的方差为:

$$\begin{aligned}
&\mathrm{Var}(\tilde{G}_q) \\
&= \mathbb{E}[\tilde{G}_q^2] - (\mathbb{E}[\tilde{G}_q])^2 = \mathbb{E}[\tilde{G}_q^2] - 0 = \mathbb{E}[\tilde{G}_q^2] \\
&= \mathbb{E}\left[\left(\frac{1}{n}\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j - \frac{1}{n^2}\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)^2\right] \\
&= \mathbb{E}\left[\frac{1}{n^2}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)^2 + \frac{1}{n^4}\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)^2 - \frac{2}{n^3}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)\right] \\
&= \underbrace{\mathbb{E}\left[\frac{1}{n^2}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)^2\right]}_{\triangleq C_1} + \underbrace{\mathbb{E}\left[\frac{1}{n^4}\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)^2\right]}_{\triangleq C_2} - \underbrace{\mathbb{E}\left[\frac{2}{n^3}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)\right]}_{\triangleq C_3}.
\end{aligned}$$

下面逐项计算。对于 C_1，有:

$$\begin{aligned}
C_1 &= \mathbb{E}\left[\frac{1}{n^2}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)^2\right] = \frac{1}{n^2}\mathbb{E}\left[\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)^2\right] \\
&= \frac{1}{n^2}\mathbb{E}\left[\sum_{j=1}^{n}\tilde{R}_j^2\tilde{Z}_j^2 + 2\sum_{1\le j<k\le n}\tilde{R}_j\tilde{Z}_j\tilde{R}_k\tilde{Z}_k\right] \\
&= \frac{1}{n^2}\left(\sum_{j=1}^{n}\mathbb{E}\left[\tilde{R}_j^2\tilde{Z}_j^2\right] + 2\sum_{1\le j<k\le n}\mathbb{E}\left[\tilde{R}_j\tilde{Z}_j\tilde{R}_k\tilde{Z}_k\right]\right) \\
&= \frac{1}{n^2}\left(\sum_{j=1}^{n}\mathbb{E}\left[\tilde{R}_j^2\tilde{Z}_j^2\right] + 2\sum_{1\le j<k\le n}\mathbb{E}\left[\tilde{R}_j\tilde{Z}_j\right]\mathbb{E}\left[\tilde{R}_k\tilde{Z}_k\right]\right) \qquad (j \text{ 与 } k \text{ 之间独立}) \\
&= \frac{1}{n^2}\left(n\mathbb{E}\left[\tilde{R}^2\tilde{Z}^2\right] + n(n-1)(\mathbb{E}[\tilde{R}\tilde{Z}])^2\right) \qquad (\text{同分布})
\end{aligned}$$

$$
\begin{aligned}
&= \frac{1}{n}\mathbb{E}\left[\tilde{R}^2\tilde{Z}^2\right] + \frac{(n-1)}{n}(\mathbb{E}[\tilde{R}\tilde{Z}])^2 \\
&= \frac{1}{n}\mathbb{E}[\tilde{R}^2](\mu_Z^2+\sigma_Z^2) + \frac{n-1}{n}\mu_z^2(\mathbb{E}[\tilde{R}])^2 \\
&= \mathbb{E}[\tilde{R}^2](\frac{1}{n}\mu_Z^2+\frac{1}{n}\sigma_Z^2) + (\mathbb{E}[\tilde{R}])^2(\frac{n-1}{n}\mu_z^2).
\end{aligned}
$$

接下来计算 C_2:

$$
C_2 = \mathbb{E}\left[\frac{1}{n^4}\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)^2\right] = \frac{1}{n^4}\mathbb{E}\left[\sum_{k=1}^{n}\sum_{k'=1}^{n}\sum_{j=1}^{n}\sum_{j'=1}^{n}\tilde{R}_k\tilde{R}_{k'}\tilde{Z}_j\tilde{Z}_{j'}\right].
$$

可以根据下标是否相等，将四重求和分解。 共有以下四类下标组合:

· 当 $k=k'$ 且 $j=j'$ 时: 共有 n^2 项，每一项为 $\mathbb{E}[\tilde{R}^2\tilde{Z}^2] = (\mu_Z^2+\sigma_Z^2)\mathbb{E}[\tilde{R}^2]$. 对 C_2 的总贡献为

$$
T_1 = n^2(\mu_Z^2+\sigma_Z^2)\mathbb{E}[\tilde{R}^2].
$$

· 当 $k=k'$ 且 $j\neq j'$ 时: 共有 $n^2(n-1)$ 项。对于任意固定的 k 以及互不相同的 j,j'， $\mathbb{E}[\tilde{R}_k^2\tilde{Z}_j\tilde{Z}_{j'}] = \mathbb{E}[\tilde{R}_k^2]\mathbb{E}[\tilde{Z}_j\tilde{Z}_{j'}] = \mu_Z^2\mathbb{E}[\tilde{R}^2]$. 对 C_2 的总贡献为

$$
T_2 = n^2(n-1)\mu_Z^2\mathbb{E}[\tilde{R}^2].
$$

· 当 $k\neq k'$ 且 $j=j'$ 时: 共有 $n^2(n-1)$ 项。对于互不相同的 k,k'， $\mathbb{E}[\tilde{R}_k\tilde{R}_{k'}\tilde{Z}^2] = \mathbb{E}[\tilde{R}_k\tilde{R}_{k'}]\mathbb{E}[\tilde{Z}^2] = (\mu_Z^2+\sigma_Z^2)(\mathbb{E}[\tilde{R}])^2$. 对 C_2 的总贡献为

$$
T_3 = n^2(n-1)(\mu_Z^2+\sigma_Z^2)(\mathbb{E}[\tilde{R}])^2.
$$

· 当 $k\neq k'$ 且 $j\neq j'$ 时: 共有 $n^2(n-1)^2$ 项。 当所有下标互不相同时， $\mathbb{E}[\tilde{R}_k\tilde{R}_{k'}\tilde{Z}_j\tilde{Z}_{j'}] = \mu_Z^2(\mathbb{E}[\tilde{R}])^2$. 对 C_2 的总贡献为

$$
T_4 = n^2(n-1)^2\mu_Z^2(\mathbb{E}[\tilde{R}])^2.
$$

因此，有

$$
\begin{aligned}
C_2 &= \frac{1}{n^4}(T_1+T_2+T_3+T_4) \\
&= \frac{1}{n^4}\Big[n^2(\mu_Z^2+\sigma_Z^2)\mathbb{E}[\tilde{R}^2] + n^2(n-1)\mu_Z^2\mathbb{E}[\tilde{R}^2] \\
&\quad + n^2(n-1)(\mu_Z^2+\sigma_Z^2)(\mathbb{E}[\tilde{R}])^2 + n^2(n-1)^2\mu_Z^2(\mathbb{E}[\tilde{R}])^2\Big] \\
&= \mathbb{E}[\tilde{R}^2]\left(\frac{\mu_Z^2}{n}+\frac{\sigma_Z^2}{n^2}\right) + (\mathbb{E}[\tilde{R}])^2\left(\frac{n-1}{n}\mu_Z^2+\frac{n-1}{n^2}\sigma_Z^2\right).
\end{aligned}
$$

接下来计算 C_3:

$$
C_3 = \mathbb{E}\left[\frac{2}{n^3}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_{j'}\right)\right] = \frac{2}{n^3}\mathbb{E}\Big[\sum_{j=1}^{n}\sum_{j'=1}^{n}\sum_{k=1}^{n}\tilde{R}_j\tilde{Z}_j\tilde{R}_k\tilde{Z}_{j'}\Big].
$$

可以根据下标是否相等，将三重求和分解为以下五类下标组合:

· 当 $j=k=j'$ 时: 共有 n 项。 对每个 j， $\mathbb{E}[\tilde{R}_j^2\tilde{Z}_j^2] = \mathbb{E}[\tilde{R}_j^2]\mathbb{E}[\tilde{Z}_j^2] = (\mu_Z^2+\sigma_Z^2)\mathbb{E}[\tilde{R}^2]$. 总贡献为:

$$
T_1 = n(\mu_Z^2+\sigma_Z^2)\mathbb{E}[\tilde{R}^2].
$$

· 当 $j = k \neq j'$ 时：共有 $n(n-1)$ 项。对于每个 j 及 $j' \neq j$，$\mathbb{E}[\tilde{R}_j^2 \tilde{Z}_j \tilde{Z}_{j'}] = \mathbb{E}[\tilde{R}_j^2]\mathbb{E}[\tilde{Z}_j \tilde{Z}_{j'}] = \mathbb{E}[\tilde{R}^2]\mathbb{E}[\tilde{Z}_j]\mathbb{E}[\tilde{Z}_{j'}] = \mathbb{E}[\tilde{R}^2]\mu_Z^2$. 总贡献为

$$T_2 = n(n-1)\mathbb{E}[\tilde{R}^2]\mu_Z^2.$$

· 当 $j = j' \neq k$ 时：共有 $n(n-1)$ 项。对于每个 j 及 $k \neq j$，$\mathbb{E}[\tilde{R}_j \tilde{Z}_j^2 \tilde{R}_k] = \mathbb{E}[\tilde{R}_j \tilde{R}_k]\mathbb{E}[\tilde{Z}_j^2] = (\mu_Z^2 + \sigma_Z^2)(\mathbb{E}[\tilde{R}])^2$. 总贡献为

$$T_3 = n(n-1)(\mu_Z^2 + \sigma_Z^2)(\mathbb{E}[\tilde{R}])^2.$$

· 当 $k = j' \neq j$ 时：共有 $n(n-1)$ 项。对于每个 j 及 $k \neq j$，$\mathbb{E}[\tilde{R}_j \tilde{Z}_j \tilde{R}_k \tilde{Z}_k] = \mathbb{E}[\tilde{R}_j \tilde{R}_k]\mathbb{E}[\tilde{Z}_j \tilde{Z}_k] = \mu_Z^2(\mathbb{E}[\tilde{R}])^2$. 总贡献为

$$T_4 = n(n-1)\mu_Z^2(\mathbb{E}[\tilde{R}])^2.$$

· 当 j, j', k 互不相同时：共有 $n(n-1)(n-2)$ 项。对于每组三个不同的下标，$\mathbb{E}[\tilde{R}_j \tilde{Z}_j \tilde{R}_k \tilde{Z}_{j'}] = \mu_Z^2(\mathbb{E}[\tilde{R}])^2$. 总贡献为

$$T_5 = n(n-1)(n-2)\mu_Z^2(\mathbb{E}[\tilde{R}])^2.$$

因此，有

$$\begin{aligned}
C_3 &= \frac{2}{n^3}\left(T_1 + T_2 + T_3 + T_4 + T_5\right) \\
&= \frac{2}{n^3}\Bigg[n(\mu_Z^2 + \sigma_Z^2)\mathbb{E}[\tilde{R}^2] + n(n-1)\mathbb{E}[\tilde{R}^2]\mu_Z^2 \\
&\qquad + n(n-1)(\mu_Z^2 + \sigma_Z^2)\left(\mathbb{E}[\tilde{R}]\right)^2 + n(n-1)\mu_Z^2\left(\mathbb{E}[\tilde{R}]\right)^2 \\
&\qquad + n(n-1)(n-2)\mu_Z^2\left(\mathbb{E}[\tilde{R}]\right)^2\Bigg] \\
&= \mathbb{E}[\tilde{R}^2]\left(\frac{2}{n}\mu_Z^2 + \frac{2}{n^2}\sigma_Z^2\right) + (\mathbb{E}[\tilde{R}])^2\left(\frac{2n-2}{n}\mu_Z^2 + \frac{2n-2)}{n^2}\sigma_Z^2\right).
\end{aligned}$$

按 $\mathbb{E}[\tilde{R}^2]$ 和 $(\mathbb{E}[\tilde{R}])^2$ 合并同类项：

$$\begin{aligned}
C_1 + C_2 - C_3 = \mathbb{E}[\tilde{R}^2]&\left[\left(\frac{1}{n}\mu_Z^2 + \frac{1}{n}\sigma_Z^2\right) + \left(\frac{\mu_Z^2}{n} + \frac{\sigma_Z^2}{n^2}\right) - \left(\frac{2}{n}\mu_Z^2 + \frac{2}{n^2}\sigma_Z^2\right)\right] \\
&+ (\mathbb{E}[\tilde{R}])^2\left[\frac{n-1}{n}\mu_Z^2 + \left(\frac{n-1}{n}\mu_Z^2 + \frac{n-1}{n^2}\sigma_Z^2\right) - \left(\frac{2n-2}{n}\mu_Z^2 + \frac{2n-2}{n^2}\sigma_Z^2\right)\right].
\end{aligned}$$

化简各括号内的表达式，得到：

$$\mathrm{Var}(\tilde{G}_q) = C_1 + C_2 - C_3 = \frac{n-1}{n^2}\sigma_Z^2\left(\mathbb{E}[\tilde{R}^2] - (\mathbb{E}[\tilde{R}])^2\right) = \frac{n-1}{n^2}\sigma_Z^2\sigma_R^2.$$

对于给定提示，$\tilde{R}$ 以概率 p 取值 1，以概率 $1-p$ 取值 -1，因此其方差为 $4p(1-p)$。最终得到单提示梯度估计量的方差：

$$\mathrm{Var}(\tilde{G}_q) = \frac{\sigma_Z^2(n-1)}{n^2} \cdot 4p(1-p).$$

证毕。 □

命题 4.3 的证明. 回顾 $\tilde{G}_q$ 的表达式:

$$\tilde{G}_q = \frac{1}{n}\sum_{j=1}^{n}\left(\tilde{R}_j - \frac{1}{n-1}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\right)\tilde{Z}_j.$$

$\tilde{G}_q$ 的期望为:

$$\begin{aligned}
\mathbb{E}[\tilde{G}_q] &= \mathbb{E}\left[\frac{1}{n}\sum_{j=1}^{n}\left(\tilde{R}_j - \frac{1}{n-1}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\right)\tilde{Z}_j\right] \\
&= \mathbb{E}\left[\frac{1}{n}\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j - \frac{1}{n(n-1)}\sum_{j=1}^{n}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\tilde{Z}_j\right] \\
&= \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}[\tilde{R}_j\tilde{Z}_j] - \frac{1}{n(n-1)}\sum_{j=1}^{n}\sum_{\substack{k=1\\k\neq j}}^{n}\mathbb{E}[\tilde{R}_k\tilde{Z}_j] \\
&= \mathbb{E}[\tilde{R}\tilde{Z}] - \mathbb{E}[\tilde{R}\tilde{Z}] && \text{(由假设 4.1}(i)\text{)} \\
&= 0.
\end{aligned}$$

$\tilde{G}_q$ 的方差为:

$$\begin{aligned}
&\mathrm{Var}(\tilde{G}_q) \\
&= \mathbb{E}[\tilde{G}_q^2] - (\mathbb{E}[\tilde{G}_q])^2 = \mathbb{E}[\tilde{G}_q^2] - 0 = \mathbb{E}[\tilde{G}_q^2] \\
&= \mathbb{E}\left[\left(\frac{1}{n}\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j - \frac{1}{n(n-1)}\sum_{j=1}^{n}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\tilde{Z}_j\right)^2\right] \\
&= \mathbb{E}\left[\frac{1}{n^2}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)^2 + \frac{1}{n^2(n-1)^2}\left(\sum_{j=1}^{n}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\tilde{Z}_j\right)^2 - \frac{2}{n^2(n-1)}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j=1}^{n}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\tilde{Z}_j\right)\right] \\
&= \underbrace{\mathbb{E}\left[\frac{1}{n^2}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)^2\right]}_{\triangleq C_1} + \underbrace{\mathbb{E}\left[\frac{1}{n^2(n-1)^2}\left(\sum_{j=1}^{n}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\tilde{Z}_j\right)^2\right]}_{\triangleq C_2} - \underbrace{\mathbb{E}\left[\frac{2}{n^2(n-1)}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j=1}^{n}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\tilde{Z}_j\right)\right]}_{\triangleq C_3}.
\end{aligned}$$

第一项 C_1 已在命题 4.2 的证明中计算, 结果为:

$$C_1 = \mathbb{E}[\tilde{R}^2](\frac{1}{n}\mu_Z^2 + \frac{1}{n}\sigma_Z^2) + (\mathbb{E}[\tilde{R}])^2(\frac{n-1}{n}\mu_z^2).$$

接下来考虑 C_2:

$$\begin{aligned}
C_2 &= \mathbb{E}\left[\frac{1}{n^2(n-1)^2}\left(\sum_{j=1}^{n}\sum_{\substack{k=1\\k\neq j}}^{n}\tilde{R}_k\tilde{Z}_j\right)^2\right] \\
&= \mathbb{E}\left[\frac{1}{n^2(n-1)^2}\left(\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right) - \left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\right)^2\right]
\end{aligned}$$

$$= \frac{1}{n^2(n-1)^2}\left(\mathbb{E}\left[\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)^2\right] - 2\,\mathbb{E}\left[\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\tilde{R}_{j'}\tilde{Z}_{j'}\right)\right] + \mathbb{E}\left[\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)^2\right]\right).$$

利用命题 4.2 证明中的计算结果，有：

$$\mathbb{E}\left[\frac{1}{n^4}\left(\sum_{j=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_j\right)^2\right] = \mathbb{E}[\tilde{R}^2]\left(\frac{\mu_Z^2}{n} + \frac{\sigma_Z^2}{n^2}\right) + (\mathbb{E}[\tilde{R}])^2\left(\frac{n-1}{n}\mu_Z^2 + \frac{n-1}{n^2}\sigma_Z^2\right),$$

$$\mathbb{E}\left[\frac{2}{n^3}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_{j'}\right)\right] = \mathbb{E}[\tilde{R}^2]\left(\frac{2}{n}\mu_Z^2 + \frac{2}{n^2}\sigma_Z^2\right) + (\mathbb{E}[\tilde{R}])^2\left(\frac{2n-2}{n}\mu_Z^2 + \frac{2n-2}{n^2}\sigma_Z^2\right),$$

$$\mathbb{E}\left[\frac{1}{n^2}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)^2\right] = \mathbb{E}[\tilde{R}^2]\left(\frac{1}{n}\mu_Z^2 + \frac{1}{n}\sigma_Z^2\right) + (\mathbb{E}[\tilde{R}])^2\left(\frac{n-1}{n}\mu_Z^2\right).$$

因此，

$$\begin{aligned}
C_2 &= \mathbb{E}[\tilde{R}^2]\left[\frac{n}{(n-1)^2}\mu_Z^2 + \frac{1}{(n-1)^2}\sigma_Z^2 - \left(\frac{2}{(n-1)^2}\mu_Z^2 + \frac{2}{n(n-1)^2}\sigma_Z^2\right) + \frac{1}{n(n-1)^2}\mu_Z^2 + \frac{1}{n(n-1)^2}\sigma_Z^2\right] \\
&+ (\mathbb{E}[\tilde{R}])^2\left[\frac{n}{(n-1)}\mu_Z^2 + \frac{1}{(n-1)}\sigma_Z^2 - \left(\frac{2}{n-1}\mu_Z^2 + \frac{2}{n(n-1)}\sigma_Z^2\right) + \frac{1}{n(n-1)}\mu_Z^2\right] \\
&= \mathbb{E}[\tilde{R}^2]\left[\frac{n^2-2n+1}{n(n-1)^2}\mu_Z^2 + \frac{n-1}{n(n-1)^2}\sigma_Z^2\right] + (\mathbb{E}[\tilde{R}])^2\left[\frac{n^2-2n+1}{n(n-1)}\mu_Z^2 + \frac{n-2}{n(n-1)}\sigma_Z^2\right] \\
&= \mathbb{E}[\tilde{R}^2]\left[\frac{1}{n}\mu_Z^2 + \frac{1}{n(n-1)}\sigma_Z^2\right] + (\mathbb{E}[\tilde{R}])^2\left[\frac{n-1}{n}\mu_Z^2 + \frac{n-2}{n(n-1)}\sigma_Z^2\right].
\end{aligned}$$

如下计算 C_3：

$$\begin{aligned}
C_3 &= \mathbb{E}\left[\frac{2}{n^2(n-1)}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\sum_{\substack{k=1\\k\neq j'}}^{n}\tilde{R}_k\tilde{Z}_{j'}\right)\right] \\
&= \mathbb{E}\left[\frac{2}{n^2(n-1)}\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_{j'} - \sum_{j'=1}^{n}\tilde{R}_{j'}\tilde{Z}_{j'}\right)\right] \\
&= \frac{2}{n^2(n-1)}\Big(\mathbb{E}\left[\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_{j'}\right)\right] - \mathbb{E}\left[\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\tilde{R}_{j'}\tilde{Z}_{j'}\right)\right]\Big).
\end{aligned}$$

利用命题 4.2 证明中 $\frac{n^3}{2}C_3$ 和 n^2C_1 的计算结果，有：

$$\mathbb{E}\left[\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\sum_{k=1}^{n}\tilde{R}_k\tilde{Z}_{j'}\right)\right] = \mathbb{E}[\tilde{R}^2]\left(n^2\mu_Z^2 + n\sigma_Z^2\right) + (\mathbb{E}[\tilde{R}])^2\left(n^2(n-1)\mu_Z^2 + n(n-1)\sigma_Z^2\right),$$

$$\mathbb{E}\left[\left(\sum_{j=1}^{n}\tilde{R}_j\tilde{Z}_j\right)\left(\sum_{j'=1}^{n}\tilde{R}_{j'}\tilde{Z}_{j'}\right)\right] = \mathbb{E}[\tilde{R}^2](n\mu_Z^2 + n\sigma_Z^2) + (\mathbb{E}[\tilde{R}])^2(n(n-1)\mu_z^2).$$

将这些项代入 C_3 的计算，得到：

$$\begin{aligned}
C_3 = \frac{2}{n^2(n-1)}\Big\{&\mathbb{E}[\tilde{R}^2]\left(n^2\mu_Z^2 + n\sigma_Z^2\right) + (\mathbb{E}[\tilde{R}])^2\left(n^2(n-1)\mu_Z^2 + n(n-1)\sigma_Z^2\right) \\
&- \left[\mathbb{E}[\tilde{R}^2]\left(n\mu_Z^2 + n\sigma_Z^2\right) + (\mathbb{E}[\tilde{R}])^2\left(n(n-1)\mu_Z^2\right)\right]\Big\}
\end{aligned}$$

$$= \mathbb{E}[\tilde{R}^2] \cdot \frac{2(n^2-n)}{n^2(n-1)}\mu_Z^2 + (\mathbb{E}[\tilde{R}])^2 \cdot \frac{2n(n-1)}{n^2(n-1)}\left((n-1)\mu_Z^2 + \sigma_Z^2\right)$$
$$= \mathbb{E}[\tilde{R}^2]\left(\frac{2}{n}\mu_Z^2\right) + (\mathbb{E}[\tilde{R}])^2\left(\frac{2n-2}{n}\mu_Z^2 + \frac{2}{n}\sigma_Z^2\right).$$

于是有：

$$\begin{aligned}\mathrm{Var}(\tilde{G}_q) = C_1 + C_2 - C_3 &= \mathbb{E}[\tilde{R}^2]\left(\frac{1}{n-1}\sigma_Z^2\right) + (\mathbb{E}[\tilde{R}])^2\left(-\frac{1}{n-1}\sigma_Z^2\right) \\ &= \frac{\sigma_Z^2}{n-1}(\mathbb{E}[\tilde{R}])^2 - (\mathbb{E}[\tilde{R}])^2) \\ &= \frac{\sigma_Z^2}{n-1}\mathrm{Var}(\tilde{R}).\end{aligned}$$

对于给定提示，$\tilde{R}$ 以概率 p 取值 1，以概率 $1-p$ 取值 -1，因此其方差为 $4p(1-p)$。最终得到单提示梯度估计量的方差：

$$\mathrm{Var}(\tilde{G}_q) = \frac{\sigma_Z^2}{n-1} \cdot 4p(1-p).$$

证毕。 □

译注（原文公式勘误）： 上述推导中，C_3 展开式的 $2n-2)$ 多出一个右括号；RLOO 方差化简倒数第二行原文写为两个相同的一阶矩平方相减，并缺少左括号。按上下文，该行应为 $\frac{\sigma_Z^2}{n-1}(\mathbb{E}[\tilde{R}^2] - (\mathbb{E}[\tilde{R}])^2)$，才能得到下一行的方差。上文保留原文公式以便核对。原文的 μ_z 与 μ_Z 在这里表示同一均值。

A.2 第 5 节的证明

定理 5.1 的证明. 为清楚且连贯地展开证明，先重述问题 (6)：

$$\begin{aligned}\min \quad & \sum_{q\in\mathcal{B}_t} a_q \frac{n_q - 1}{n_q^2} \\ \text{s.t.} \quad & \sum_{q\in\mathcal{B}_t} n_q = C \\ & L \le n_q \le U \quad \forall q \in \mathcal{B}_t.\end{aligned} \tag{10}$$

记上述问题的目标函数为 $V(\{n_q\})$。计算目标函数关于各坐标 n_q 的一阶与二阶导数：

$$\frac{\partial V}{\partial n_q} = -a_q \frac{n_q - 2}{n_q^3}.$$

由于 $n_q \ge L \ge 3$，对所有 q 有 $\frac{\partial V}{\partial n_q} < 0$。因此，在可行集上，$V$ 关于每个 n_q 单调递减。

二阶导数为：

$$\frac{\partial^2 V}{\partial n_q \partial n_{q'}} = 0 \quad \forall q \ne q', \quad \frac{\partial^2 V}{\partial n_q^2} = a_q \frac{2n_q - 6}{n_q^4} \ge 0 \quad \forall q \quad (\text{由于 } n_q \ge L \ge 3, \text{ 且 } a_q \ge 0)$$

因此，在以下可行集上，V 是凸函数，且关于每个 n_q 单调递减：

$$\left\{ n \in \mathbb{R}^B : \sum_{q\in\mathcal{B}_t} n_q = C, \quad L \le n_q \le U \ \forall q \right\}.$$

所以，只要可行集非空，即 $BL \le C \le BU$，最小化解就存在且唯一。

拉格朗日函数为

$$\mathcal{L} = \sum_{q\in\mathcal{B}_t} a_q \frac{n_q - 1}{n_q^2} + \lambda \left(\sum_{q\in\mathcal{B}_t} n_q - C \right) + \sum_{q\in\mathcal{B}_t} \mu_q (L - n_q) + \sum_{q\in\mathcal{B}_t} \nu_q (n_q - U)$$

其中 $\lambda \in \mathbb{R}$ 以及 $\mu_q, \nu_q \geq 0$ 为拉格朗日乘子。 KKT 条件为:

$$\begin{aligned}
& - a_q \frac{n_q - 2}{n_q^3} + \lambda - \mu_q + \nu_q = 0 && \forall q, \\
& \mu_q \geq 0, \quad \nu_q \geq 0 && \forall q, \\
& \mu_q (n_q - L) = 0, \quad \nu_q (n_q - U) = 0 && \forall q, \\
& L \leq n_q \leq U && \forall q, \\
& \sum_{q\in\mathcal{B}_t} n_q = C.
\end{aligned}$$

分别考虑 n_q 的三种情况:

· 对于满足 $L < n_q < U$ 的每个 q，KKT 驻点条件为

$$\lambda = a_q \frac{n_q - 2}{n_q^3},$$

其中 λ 是总和约束对应的拉格朗日乘子。注意，右侧关于 n_q 单调递减。

当 $n_q = L$ 时，右侧为 $a_q \frac{L-2}{L^3}$；当 $n_q = U$ 时，右侧为 $a_q \frac{U-2}{U^3}$。因此，对每个 q 和任意 $\lambda \in (a_q \frac{U-2}{U^3}, a_q \frac{L-2}{L^3})$，方程 $a_q \frac{n_q-2}{n_q^3} = \lambda$ 在内部区间 (L, U) 至多有一个解。若 $\lambda \geq a_q \frac{L-2}{L^3}$ 或 $\lambda \leq a_q \frac{U-2}{U^3}$，则不存在内部解，$n_q$ 的最优值必在边界上。

· 若 $n_q = L$，则 $\mu_q \geq 0$ 且 $\nu_q = 0$。由 KKT 条件得到:

$$\lambda = a_q \frac{L - 2}{L^3} + \mu_q \geq a_q \frac{L - 2}{L^3}.$$

· 若 $n_q = U$，则 $\mu_q = 0$ 且 $\nu_q \geq 0$。由 KKT 条件得到:

$$\lambda = a_q \frac{U - 2}{U^3} - \nu_q \leq a_q \frac{U - 2}{U^3}.$$

给定 λ，每个坐标 n_q 的 KKT 解定义为:

$$n_q^\star(\lambda) = \begin{cases} U & \text{若 } \lambda \leq a_q \frac{U-2}{U^3}, \\ \text{满足下式的唯一解: } \lambda = a_q \frac{n_q-2}{n_q^3} & \text{若 } a_q \frac{U-2}{U^3} < \lambda < a_q \frac{L-2}{L^3}, \\ L & \text{若 } \lambda \geq a_q \frac{L-2}{L^3}. \end{cases}$$

为满足耦合约束 $\sum_{q\in\mathcal{B}_t} n_q = C$，选取 λ 使得

$$S(\lambda) \triangleq \sum_{q\in\mathcal{B}_t} n_q^\star(\lambda) = C.$$

由于 $a_q \frac{n_q-2}{n_q^3}$ 单调递减且投影保持单调性，每个 $n_q^\star(\lambda)$ 都关于 λ 单调不增。因此，$S(\lambda)$ 也单调不增。特别地:

· 当 $\lambda \to -\infty$ 时， $n_q^\star(\lambda) \to U$，因此 $S(-\infty) = BU$.

· 当 $\lambda \to +\infty$ 时， $n_q^\star(\lambda) \to L$，因此 $S(+\infty) = BL$.

因此，对于任何满足 $BL \le C \le BU$ 的可行预算 C，存在唯一的 $\lambda^\star$ 使 $S(\lambda^\star) = C$。又因为 S 单调不增，可以用二分法求解 $\lambda^\star$。若 $C > BU$ 或 $C < BL$，问题不可行。 □

定理 5.2 的证明. 为清楚且连贯地展开证明，先重述问题 8:

$$\begin{aligned} \min \quad & \sum_{q\in\mathcal{B}_t} a_q \frac{1}{n_q} \\ \text{s.t.} \quad & \sum_{q\in\mathcal{B}_t} n_q = C \\ & L \le n_q \le U \quad \forall q \in \mathcal{B}_t \end{aligned} \tag{11}$$

记上述问题的目标函数为 $V(\{n_q\})$。计算目标函数关于各坐标 n_q 的一阶与二阶导数:

$$\frac{\partial V}{\partial n_q} = -a_q \frac{1}{(n_q-1)^2}$$

由于 $n_q \ge L \ge 3$ 且 $a_q > 0$，对所有 q 均有 $\frac{\partial V}{\partial n_q} \le 0$。因此，在可行集上 V 关于每个 n_q 单调递减。

二阶导数为:

$$\frac{\partial^2 V}{\partial n_q \partial n_{q'}} = 0 \quad \forall q \ne q', \qquad \frac{\partial^2 V}{\partial n_q^2} = 2a_q \frac{1}{(n_q-1)^3} > 0 \quad \forall q$$

因此，在以下可行集上，V 是凸函数，且关于每个 n_q 单调递减:

$$\left\{ n \in \mathbb{R}^B : \sum_{q\in\mathcal{B}_t} n_q = C, \quad L \le n_q \le U \right\}.$$

因此，只要可行集非空（$BL \le C \le BU$），最小化解就存在且唯一。

拉格朗日函数为

$$\mathcal{L} = \sum_{q\in\mathcal{B}_t} a_q \frac{1}{n_q - 1} + \lambda \left(\sum_{q\in\mathcal{B}_t} n_q - C \right) + \sum_{q\in\mathcal{B}_t} \mu_q (L - n_q) + \sum_{q\in\mathcal{B}_t} \nu_q (n_q - U)$$

其中 $\lambda \in \mathbb{R}$，$\mu_q, \nu_q \ge 0$。KKT 条件为:

$$\begin{aligned} & -a_q \frac{1}{(n_q-1)^2} + \lambda - \mu_q + \nu_q = 0 && \forall q \\ & \mu_q \ge 0, \quad \nu_q \ge 0 && \forall q \\ & \mu_q (n_q - L) = 0, \quad \nu_q (n_q - U) = 0 && \forall q \\ & L \le n_q \le U && \forall q \\ & \sum_{q\in\mathcal{B}_t} n_q = C. \end{aligned}$$

分别考虑 n_q 的三种情况:

· 对于满足 $L < n_q < U$ 的每个 q，KKT 驻点条件为

$$\lambda = a_q \frac{1}{(n_q-1)^2},$$

其中 λ 是总和约束的拉格朗日乘子。由于 $n_q \geq L \geq 3$，右侧关于 n_q 单调递减。

当 $n_q = L$ 时，右侧为 $a_q \frac{1}{(L-1)^2}$；当 $n_q = U$ 时，右侧为 $a_q \frac{1}{(U-1)^2}$。因此，对于每个 q 及任意 $\lambda \in (a_q \frac{1}{(U-1)^2}, a_q \frac{1}{(L-1)^2})$，方程 $a_q \frac{1}{(n_q-1)^2} = \lambda$ 在内部区间 (L, U) 有一个解 $n_q = \sqrt{a_q/\lambda} + 1$。若 $\lambda \geq a_q \frac{1}{(L-1)^2}$ 或 $\lambda \leq a_q \frac{1}{(U-1)^2}$，则没有内部解，$n_q$ 的最优值必在边界上。

- 若 $n_q = L$，则 $\mu_q \geq 0$ 且 $\nu_q = 0$。由 KKT 条件得到：

$$\lambda = a_q \frac{1}{(L-1)^2} + \mu_q \geq a_q \frac{1}{(L-1)^2}.$$

- 若 $n_q = U$，则 $\mu_q = 0$ 且 $\nu_q \geq 0$。由 KKT 条件得到：

$$\lambda = a_q \frac{1}{(U-1)^2} - \nu_q \leq a_q \frac{1}{(U-1)^2}.$$

给定 λ，每个坐标 n_q 的 KKT 解定义为：

$$n_q^\star(\lambda) = \begin{cases} U & \text{若 } \lambda \leq a_q \frac{1}{(U-1)^2}, \\ \sqrt{\frac{a_q}{\lambda}} + 1 & \text{若 } a_q \frac{1}{(U-1)^2} < \lambda < a_q \frac{1}{(L-1)^2}, \\ L & \text{若 } \lambda \geq a_q \frac{1}{(L-1)^2}. \end{cases}$$

为满足耦合约束 $\sum_{q \in \mathcal{B}_t} n_q = C$，选取 λ 使得

$$S(\lambda) := \sum_{q \in \mathcal{B}_t} n_q^\star(\lambda) = C.$$

每个 $n_q^\star(\lambda)$ 都关于 λ 单调不增（因为 $a_q \frac{1}{(n_q-1)^2}$ 单调递减，且投影保持单调性），所以 $S(\lambda)$ 也单调不增。特别地：

- 当 $\lambda \to -\infty$ 时，$n_q^\star(\lambda) \to U$，因此 $S(-\infty) = BU$.
- 当 $\lambda \to +\infty$ 时，$n_q^\star(\lambda) \to L$，因此 $S(+\infty) = BL$.

因此，对任何满足 $BL \leq C \leq BU$ 的可行预算 C，存在唯一的 λ 使 $S(\lambda) = C$。若 $C > BU$ 或 $C < BL$，问题不可行。 □

译注（可行性与唯一性）： 原文 RLOO 问题重述式 (11) 将分母写成 n_q，但正文、随后导数及拉格朗日函数均使用 $n_q - 1$，应属排版笔误。关于 DrGRPO，若允许 $a_q = 0$，严格递减及最优解唯一性的表述需要额外条件；关于两种算法，$S(\lambda)$ 单调不增不等于严格递减，在 $C = BL$ 或 $C = BU$ 的边界，以及可能的平坦区间上，满足预算的乘子未必唯一。此处保留原文论述；二分搜索应理解为寻找满足预算的乘子，而非无条件证明乘子唯一。

B 二阶不相关性的统计检验

本节通过统计检验来验证本文中的假设。

译注：下文对统计结论的表述按原文翻译。未拒绝零假设，并不等于证明零相关或等方差，也不能单独证明全部二阶不相关性条件成立。

B.1 使用 Fisher 方法的一阶相关性检验

对于每个问题 q，考虑两个随机变量 $\tilde{R}_q$ 与 $\tilde{Z}_q$，以及 n 个独立观测

$$\{(\tilde{R}_{q,j}, \tilde{Z}_{q,j})\}_{j=1}^{n}.$$

计算每个问题的 Pearson 相关系数。 问题 q 的样本 Pearson 相关系数为

$$\hat{\rho}_q = \frac{\sum_{j=1}^{n}(\tilde{R}_{q,j} - \bar{\tilde{R}}_q)(\tilde{Z}_{q,j} - \bar{Z}_q)}{\sqrt{\sum_{j=1}^{n}(\tilde{R}_{q,j} - \bar{R}_q)^2 \sum_{j=1}^{n}(\tilde{Z}_{q,j} - \bar{Z}_q)^2}},$$

其中

$$\bar{R}_q = \frac{1}{n}\sum_{j=1}^{n}\tilde{R}_{q,j}, \qquad \bar{Z}_q = \frac{1}{n}\sum_{j=1}^{n}\tilde{Z}_{q,j}.$$

计算每个问题的 p 值。 对于每个问题 q，我们检验零假设

$$H_{0,q} : \rho_q = 0.$$

p 值 p_q 直接由标准 Pearson 相关性检验获得。

使用 Fisher 方法合并各问题的 p 值。 令 Q 为问题总数。Fisher 方法将各问题的 p 值 $\{p_q\}_{q=1}^{Q}$ 合并为一个检验统计量：

$$\chi^2_{\text{Fisher}} = -2\sum_{q=1}^{Q}\ln p_q.$$

在全局零假设

$$H_0 : \rho_q = 0 \quad \forall q,$$

下，统计量 χ^2_{Fisher} 服从自由度为 $2Q$ 的卡方分布：

$$\chi^2_{\text{Fisher}} \sim \chi^2_{2Q}.$$

全局 p 值与决策规则。 在所有问题上检验 H_0 的全局 p 值为

$$p_{\text{global}} = \Pr\left(\chi^2_{2Q} \geq \chi^2_{\text{Fisher}}\right).$$

给定显著性水平 α（例如 $\alpha = 0.05$），我们按以下规则作出决策：

- 若 $p_{\text{global}} < \alpha$，则拒绝全局零假设 H_0，这表明各问题中至少有一部分相关系数 ρ_q 显著不为零。
- 若 $p_{\text{global}} \geq \alpha$，则无法拒绝 H_0，这在显著性水平 α 下支持所有问题的相关系数 ρ_q 均为零的假设。

我们在包含 $Q = 600$ 个问题的基准上进行上述相关性检验，每个问题有 $n = 16$ 条独立采样轨迹。对于每个问题 q，计算 $\tilde{R}_q$ 与 $\tilde{Z}_q$ 的 Pearson 相关系数，获得相应的 p 值 p_q，并利用 Fisher 方法汇总所有问题，以计算全局 p 值 p_{global}。

我们在 `Qwen2.5-Math-1.5B` 训练过程的四个检查点上评估策略模型 π_{θ_t}，对应训练轮数为 0.0、0.5、1.0。每个检查点所得的 p_{global} 值见表 5。由于所有全局 p 值均超过选定的显著性水平 $\alpha = 0.05$，我们不拒绝零假设，这支持了所有问题的相关系数 ρ_q 均为零的假设。

译注：原文称“四个检查点”，但这里只列出 0.0、0.5、1.0 三个训练轮数，表中也只有三行；后文 Levene 检验部分存在相同不一致。Pearson 公式中的 $\bar{\tilde{R}}_q$ 与 $\bar{R}_q$ 等记号差异均按原文保留。

训练轮数	全局 p 值
	$\tilde{Z}_j = \|H(\tilde{o}_j)\|_2$
0.0	0.7322
0.5	0.1108
1.0	0.2186

表 5: Qwen2.5-Math-1.5B 在不同训练轮数下的全局 p 值（p_{global}）。

B.2 使用 Edgington 方法的一阶相关性检验

对于每个问题 q，令 $\hat{\rho}_q$ 表示由 n 条独立采样轨迹计算得到的样本 Pearson 相关系数，令 p_q 为检验下述零假设所对应的双侧 p 值

$$H_{0,q} : \rho_q = 0.$$

为汇总全部 Q 个问题的证据，我们采用 Edgington 的 p 值求和方法。

p 值求和。 在各自的零假设下，每个问题的 p_q 都被视为一个 $\text{Uniform}(0,1)$ 随机变量的实现。Edgington 统计量定义为简单求和

$$S_{\text{Ed}} \;=\; \sum_{q=1}^{Q} p_q.$$

零假设下的分布。 在全局零假设

$$H_0 : \rho_q = 0 \quad \forall q,$$

下，每个 $p_q \sim \text{Uniform}(0,1)$，因此

$$S_{\text{Ed}} \;\sim\; \text{Irwin–Hall}(Q),$$

其均值和方差为

$$\mathbb{E}[S_{\text{Ed}}] = \frac{Q}{2}, \qquad \text{Var}(S_{\text{Ed}}) = \frac{Q}{12}.$$

当 Q 较大时，S_{Ed} 可由正态分布很好地近似：

$$S_{\text{Ed}} \;\approx\; \mathcal{N}\!\left(\frac{Q}{2},\, \frac{Q}{12}\right).$$

全局 p 值与决策规则。 较小的 S_{Ed} 值表示存在反对 H_0 的联合证据。相应的单侧全局 p 值为

$$p_{\text{global}} = \Phi\!\left(\frac{S_{\text{Ed}} - Q/2}{\sqrt{Q/12}}\right),$$

其中，Φ 表示标准正态分布的累积分布函数。给定显著性水平 $\alpha = 0.5$，当 $p_{\text{global}} < \alpha$ 时，我们拒绝 H_0。

译注：此处原文为 $\alpha = 0.5$，而下文实验结论采用 $\alpha = 0.05$，两者不一致，均原样保留。

实验设置与附录 B.1 中的 Fisher 方法检验相同，使用同一组包含 $Q = 600$ 个问题的基准，每个问题有 $n = 16$ 条独立采样轨迹。对于策略模型 π_{θ_t} 的每个检查点，我们计算 Edgington 统计量并报告全局 p 值。由于所有全局 p 值均超过选定的显著性水平 $\alpha = 0.05$，我们不拒绝零假设，这支持了所有问题的相关系数 ρ_q 均为零的假设。

训练轮数	全局 p 值
	$\tilde{Z}_j = \|H(\tilde{o}_j)\|_2$
0.0	0.7894
0.5	0.3964
1.0	0.2148

表 6: 使用 Edgington 方法得到的 `Qwen2.5-Math-1.5B` 在不同训练轮数下的全局 p 值（p_{global}）。

B.3 使用 Levene 检验的等方差检验

在数值实验中，我们假定 $\tilde{Z}_q$ 的方差在不同提示 q 之间保持不变。为此进行如下假设检验：

$$H_0 : \sigma^2_{Z_q} = \sigma^2_{Z_{q'}} \ \forall q \neq q', \qquad H_1 : \text{至少有一个 } \sigma^2_{Z_q} \neq \sigma^2_{Z_{q'}}$$

对于每个问题 q，考虑随机变量 $\tilde{Z}_q$ 及其 n_q 个独立观测 $\{\tilde{Z}_{q,j}\}_{j=1}^{n_q}$。

为 Levene 检验变换观测值。 令 $Y_{q,j}$ 表示相对于每个问题中位数的绝对偏差：

$$Y_{q,j} = \left|\tilde{Z}_{q,j} - \text{median}(\tilde{Z}_{q,1}, \ldots, \tilde{Z}_{q,n_q})\right|.$$

计算变换后观测值的组均值。 问题 q 的变换后观测值均值为

$$\bar{Y}_q = \frac{1}{n_q} \sum_{j=1}^{n_q} Y_{q,j},$$

所有问题的总体均值为

$$\bar{Y} = \frac{1}{N} \sum_{q=1}^{Q} \sum_{j=1}^{n_q} Y_{q,j}, \qquad N = \sum_{q=1}^{Q} n_q.$$

计算 Levene 检验统计量。 检验统计量为

$$W = \frac{(N-Q) \sum_{q=1}^{Q} n_q (\bar{Y}_q - \bar{Y})^2}{(Q-1) \sum_{q=1}^{Q} \sum_{j=1}^{n_q} (Y_{q,j} - \bar{Y}_q)^2}.$$

在各问题方差相等的零假设

$$H_0 : \sigma^2_{Z_q} = \sigma^2_{Z_{q'}} \quad \forall q \neq q',$$

下，统计量 W 近似服从自由度为 $Q-1$ 和 $N-Q$ 的 F 分布，即 $W \sim F_{Q-1,N-Q}$。

计算 p 值并确定决策规则。 检验 H_0 的 p 值为

$$p_{\text{Levene}} = \Pr(F_{Q-1,N-Q} \geq W).$$

给定显著性水平 α（例如 $\alpha = 0.05$），我们按以下规则作出决策：

- 若 $p_{\text{Levene}} < \alpha$，则拒绝 H_0，表明不同问题的 $\tilde{Z}_q$ 方差存在差异。
- 若 $p_{\text{Levene}} \geq \alpha$，则在显著性水平 α 下无法拒绝 H_0，即所有问题方差相等的假设。

我们在包含 $Q = 600$ 个问题的基准上进行上述方差齐性检验，每个问题有 $n = 16$ 条独立采样轨迹。我们对所有问题进行 Levene 检验，以评估方差是否相等。在 `Qwen2.5-Math-1.5B` 训练过程的四个检查点上评估策略模型 π_{θ_t}，对应训练轮数为 0.0、0.5、1.0。每个检查点所得的全局 p 值 p_{Levene} 见表 7。由于所有 p_{Levene} 均超过选定的显著性水平 $\alpha = 0.05$，我们不能拒绝零假设，这支持了所有问题的方差 $\sigma^2_{Z_q}$ 相等的假设。

训练轮数	全局 p 值	
	$\tilde{Z}_j = \mathbb{1}^\top H(\tilde{o}_j)$	$\tilde{Z}_j = \|H(\tilde{o}_j)\|_2$
0.0	0.5019	0.2705
0.5	0.4132	0.4785
1.0	0.3847	0.3847

表 7: 对 Qwen2.5-Math-1.5B 在不同训练轮数进行 Levene 检验所得的 p_{Levene}，用于评估 $\tilde{Z}_q$ 的方差齐性。

B.4 使用 O'Brien 检验的等方差检验

在数值实验中，我们假定 $\tilde{Z}_q$ 的方差在不同提示 q 之间保持不变。为此进行如下假设检验：

$$H_0 : \sigma^2_{Z_q} = \sigma^2_{Z_{q'}} \ \forall q \neq q', \qquad H_1 : \text{至少有一个 } \sigma^2_{Z_q} \neq \sigma^2_{Z_{q'}}$$

对于每个问题 q，考虑随机变量 $\tilde{Z}_q$ 及其 n_q 个独立观测 $\{\tilde{Z}_{q,j}\}_{j=1}^{n_q}$。

为 O'Brien 检验变换观测值。 令 $Y_{q,j}$ 表示观测值的 O'Brien 变换：

$$Y_{q,j} = \frac{(n_q - 1.5)n_q(\tilde{Z}_{q,j} - \bar{\tilde{Z}}_q)^2 - 0.5 s_q^2(n_q - 1)}{(n_q - 1)(n_q - 2)},$$

其中，$\bar{\tilde{Z}}_q$ 是问题 q 的样本均值，s_q^2 是问题 q 的无偏样本方差。

计算变换后观测值的组均值。 问题 q 的变换后观测值均值为

$$\bar{Y}_q = \frac{1}{n_q} \sum_{j=1}^{n_q} Y_{q,j},$$

所有问题的总体均值为

$$\bar{Y} = \frac{1}{N} \sum_{q=1}^{Q} \sum_{j=1}^{n_q} Y_{q,j}, \qquad N = \sum_{q=1}^{Q} n_q.$$

计算 O'Brien 检验统计量。 检验统计量为

$$W_{\text{OB}} = \frac{(N - Q) \sum_{q=1}^{Q} n_q (\bar{Y}_q - \bar{Y})^2}{(Q - 1) \sum_{q=1}^{Q} \sum_{j=1}^{n_q} (Y_{q,j} - \bar{Y}_q)^2}.$$

在各问题方差相等的零假设

$$H_0 : \sigma^2_{Z_q} = \sigma^2_{Z_{q'}} \quad \forall q \neq q',$$

下，统计量 W_{OB} 近似服从自由度为 $Q - 1$ 和 $N - Q$ 的 F 分布，即 $W_{\text{OB}} \sim F_{Q-1, N-Q}$。

计算 p 值并确定决策规则。 检验 H_0 的 p 值为

$$p_{\text{OB}} = \Pr(F_{Q-1,N-Q} \geq W_{\text{OB}}).$$

给定显著性水平 α（例如 $\alpha = 0.05$），我们按以下规则作出决策：

- 若 $p_{\text{OB}} < \alpha$，则拒绝 H_0，表明不同问题的 $\tilde{Z}_q$ 方差存在差异。
- 若 $p_{\text{OB}} \geq \alpha$，则在显著性水平 α 下无法拒绝 H_0，即所有问题方差相等的假设。

我们在包含 $Q = 600$ 个问题的基准上进行上述方差齐性检验，每个问题有 $n = 16$ 条独立采样轨迹。我们对所有问题进行 O'Brien 检验，以评估方差是否相等。在 Qwen2.5-Math-1.5B 训练过程的三个检查点上评估策略模型 π_{θ_t}，对应训练轮数为 0.0、0.5、1.0。每个检查点所得的全局 p 值 p_{OB} 见表 8。由于所有 p_{OB} 均超过选定的显著性水平 $\alpha = 0.05$，我们不能拒绝零假设，这支持了所有问题的方差 $\sigma^2_{Z_q}$ 相等的假设。

训练轮数	全局 p 值
	$\tilde{Z}_j = \|H(\tilde{o}_j)\|_2$
0.0	0.3009
0.5	0.2563
1.0	0.2420

表 8: 对 `Qwen2.5-Math-1.5B` 在不同训练轮数进行 O’Brien 检验所得的 p_{OB}，用于评估 $\tilde{Z}_q$ 的方差齐性。

C 数值实验补充信息

超参数。表 9 整理了本实验的重要训练超参数。

表 9: 超参数配置。

类别	超参数	数值／设置
优化器	优化器	AdamW
	学习率	1×10^{-6}
	预热	20 个采样步
采样	提示批次大小	512
	每个提示的回复数	6/8/动态
训练	小批次大小	512
	最大生成长度	10 240 个词元
	温度	1.0

C.1 消融研究补充信息

逆准确率分配。 我们向经验准确率较低的提示分配更多采样预算。具体而言，令 acc_i 表示提示 i 的动态准确率估计，设定目标权重 $w_i \propto (1 - \mathrm{acc}_i + \epsilon)$，然后进行归一化，使其满足总预算及每个提示的上下界约束。

逆方差分配。 我们向答案方差较低的提示分配更多采样预算。令 σ_i^2 表示动态答案方差估计，设定 $w_i \propto 1/(\sigma_i^2 + \epsilon)$，并采用相同的归一化方式。

这两种启发式方法都通过连续松弛的约束优化实现，强制满足总预算约束和区间约束。我们使用在线求解器求解，再通过舍入启发式方法将分数解映射为整数解。

C.2 提示模板

译注：以下模板中的自然语言已译为中文，代码占位符、格式标记和示例数值按原文保留。原数学模板称有“两个示例”，但实际仅列出一个；此处不改。若需严格复现实验，请使用原论文仓库中的英文模板。 训练期间，数据集中的所有提示均只采用同一种提示模板。共有两种模板：一种用于数学推理，另一种用于工具增强推理。

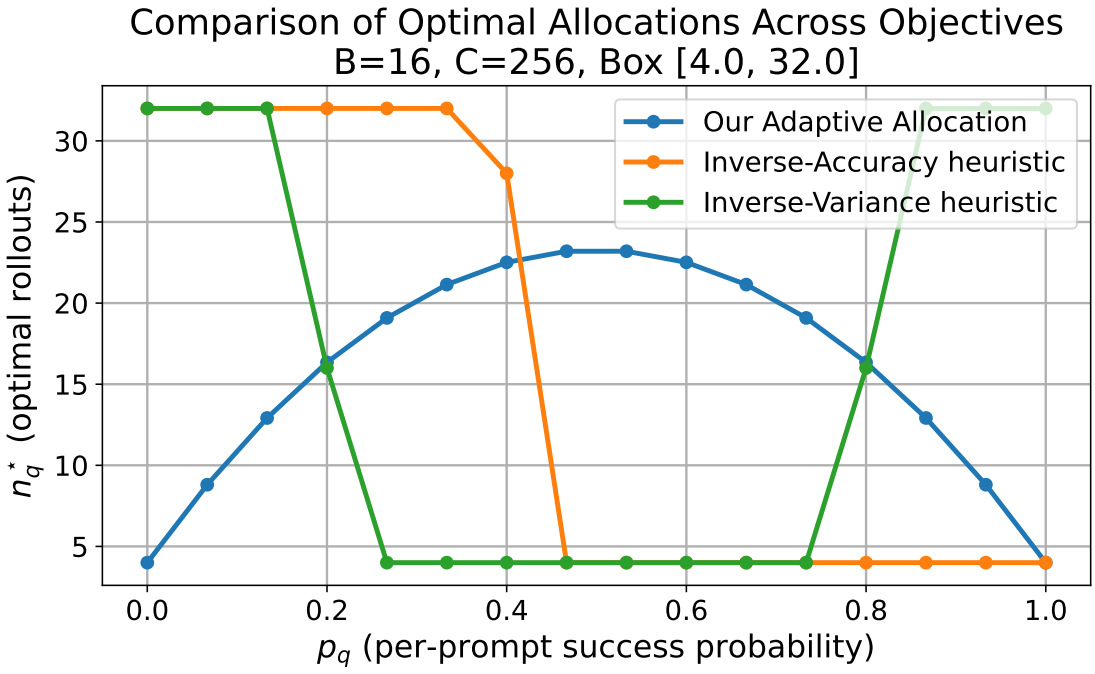
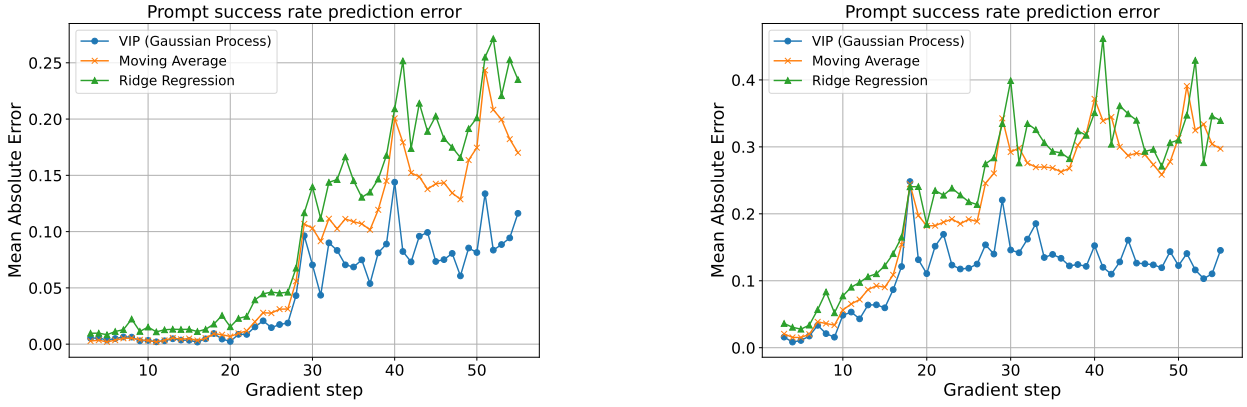


图 2: 不同启发式方法与所提出的方差感知分配策略的最优采样分配比较。图中绘制了最优采样条数 $n_i^\star$ 随提示难度 p_i 的变化，突出了本方法与逆准确率、逆方差基线在预算分配上的不同。



(a) Qwen2.5-Math-1.5B **(b)** Qwen2.5-Math-7B

图 3: 两种模型规模下，预测平均绝对误差（MAE）随训练步数的变化。对于 1.5B 和 7B 模型，基于高斯过程回归（GPR）的预测器均持续获得低于移动平均和岭回归基线的 MAE。

图 4: 数学推理提示模板

```
请逐步解答下面的数学题。回复的最后一行应采用 Answer: $Answer 的形式（不加引号），其中 $Answer
↪  是问题的答案。不要用 \boxed{} 包裹 $Answer。

当前问题: {{question}}

下面给出两个示例，供格式参考。
示例问题 1: 求解 x: 3x - 5 = 16。

回复:
等式两边加 5: 3x = 21。
等式两边除以 3: x = 7。
Answer: 7

解答当前问题。记住在单独一行的 "Answer:" 后写出答案。
```

图 5: 工具增强推理提示模板

```
在此环境中，你可以使用一组工具来帮助处理用户的查询。

你可以进行多轮函数调用。

每一轮中，你可以调用一个或多个函数。

以下是以 JSONSchema 格式给出的可用函数: \n```json\n{func_schemas}\n```

回复时，你需要先在心中思考推理过程，然后在必要时调用函数，以获取信息或执行操作。 \
推理过程和函数调用分别用 <think> </think> 和 <tool_call> </tool_call> 标签包裹。 \
函数执行后，结果将返回给你， \
你可以继续调用函数，直到获得用户问题的最终答案。 \
最后，如果你已得到答案，用 LaTeX 格式的 \\boxed{{}} 将其包裹，并停止继续调用函数， \
例如: <think> 根据函数调用的回复，我得到了天气信息。 </think> 北京在 2025-04-01 的天气为 \\[
↪  \\boxed{{20C}} \\]。

每次函数调用都应在 <tool_call></tool_call> XML 标签内返回包含函数名和参数的 JSON 对象:
<tool_call>
{{"name": <function-name>, "arguments": <args-json-object>}}
</tool_call>
```

D 算法

算法 1 给出了高斯过程后验更新的完整流程。

算法 1 递归 GP 后验更新

输入： 小批次 $\mathcal{B}_t$；采样分配 $\{n_q\}_{q=1}^{\mathcal{B}_t}$；先验均值 $m_t(\mathcal{D}) \in \mathbb{R}^Q$，核矩阵 $\Sigma \in \mathbb{R}^{Q\times Q}$；

对于 每个 $q \in \mathcal{B}_t$ **执行**
  # 执行 n_q 次采样并观测结果 $\tilde{R}_j \in \{-1, 1\}$
  $\bar{R}_q \leftarrow \frac{1}{n_q}\sum_{j=1}^{n_q} \tilde{R}_j$
  $\hat{g}_q \leftarrow \text{sigmoid}^{-1}\Big(\text{clip}\left(\frac{\bar{R}_q+1}{2}, \epsilon, 1-\epsilon\right)\Big)$
结束 对于
$g_t^{\text{observe}} \leftarrow (\hat{g}_q)_{q\in\mathcal{B}_t}$
根据 $\mathcal{B}_t$ 与 $\mathcal{B}_t^c$ 对 m_t 和 Σ 分块
$m^\star_{t,\mathcal{B}_t^c} \leftarrow m_{t,\mathcal{B}_t^c} + \Sigma_{\mathcal{B}_t^c\mathcal{B}_t}\Sigma^{-1}_{\mathcal{B}_t\mathcal{B}_t}(g_t^{\text{observe}} - m_{t,\mathcal{B}_t})$
$\Sigma^\star \leftarrow \Sigma_{\mathcal{B}_t^c\mathcal{B}_t^c} - \Sigma_{\mathcal{B}_t^c\mathcal{B}_t}\Sigma^{-1}_{\mathcal{B}_t\mathcal{B}_t}\Sigma_{\mathcal{B}_t\mathcal{B}_t^c}$
对于 $q = 1$ **至** Q **执行**
  若 $q \in \mathcal{B}_t$ **则** $m_{t+1}(x_q) \leftarrow \hat{g}_q$ **否则** $m_{t+1}(x_q) \leftarrow m^\star_{t,\mathcal{B}_t^c}(x_q)$ **结束判断**
结束 对于
$\hat{p}_{t+1} = \text{sigmoid}(m_{t+1}(\mathcal{D}))$
返回$\{\hat{p}_{t+1}\}, m_{t+1}$

算法 2 给出了启发式舍入流程，它将连续解映射为离散解，同时确保预算约束仍然成立。

算法 2 用于整数采样分配的启发式舍入

输入： 解 $\{n_q^\star\}$、总预算 C、界限 $\{L, U\}$，以及每个 q 的目标函数 $f_q(\cdot)$

对每个 q，令 $\hat{n}_q \leftarrow \lfloor n_q^\star \rfloor$
$C_{\text{rem}} \leftarrow C - \sum_{q\in\mathcal{B}_t} \hat{n}_q$
对于 满足 $\hat{n}_q < U$ 的每个 q **执行**
  计算收益： $\Delta_q \leftarrow f_q(\hat{n}_q) - f_q(\hat{n}_q + 1)$
结束 对于
当 $C_{\text{rem}} > 0$ **执行**
  选择 $q^\star = \arg\max_{q:\hat{n}_q<U} \Delta_q$
  令 $\hat{n}_{q^\star} \leftarrow \hat{n}_{q^\star} + 1$
  重新计算 $\Delta_{q^\star} \leftarrow f_{q^\star}(\hat{n}_{q^\star}) - f_{q^\star}(\hat{n}_{q^\star} + 1)$
  $C_{\text{rem}} \leftarrow C_{\text{rem}} - 1$
结束 当
返回整数分配 $\{\hat{n}_q\}$，满足 $\sum_{q\in\mathcal{B}_t} \hat{n}_q = C$，且对所有 q 均有 $L \le \hat{n}_q \le U$

E 连续奖励扩展

本节详细说明当奖励 $R(\tilde{o}_j)$ 为实值随机变量时，预测式采样分配策略所需的调整。除非另有说明，所有定义、假设和记号均与正文一致。

E.1 连续奖励下的梯度方差

我们首先给出连续奖励情形下相应的方差命题。它们的证明是附录 A 中二元奖励情形证明的中间结果。

命题 E.1 (Dr. GRPO 梯度方差，连续奖励)**.** 令 $R(\tilde{o}_j) = \tilde{R}$ 为方差为 $\mathrm{Var}(\tilde{R})$ 的实值随机变量。若假设 4.1 成立且 $\mathrm{Var}(\tilde{Z}) = \sigma_Z^2$，则使用 n 条采样轨迹时，逐提示投影 Dr. GRPO 梯度估计量的方差为

$$\mathrm{Var}(\tilde{G}) = \frac{(n-1)\sigma_Z^2}{n^2}\mathrm{Var}(\tilde{R}).$$

命题 E.2 (RLOO 梯度方差，连续奖励)**.** 令 $R(\tilde{o}_j) = \tilde{R}$ 为方差为 $\mathrm{Var}(\tilde{R})$ 的实值随机变量。若假设 4.1 成立且 $\mathrm{Var}(\tilde{Z}) = \sigma_Z^2$，则使用 n 条采样轨迹时，逐提示投影 RLOO 梯度估计量的方差为

$$\mathrm{Var}(\tilde{G}) = \frac{\sigma_Z^2}{n-1}\mathrm{Var}(\tilde{R}).$$

E.2 奖励方差的高斯过程预测

对于连续奖励，逐提示梯度方差取决于 $\mathrm{Var}(\tilde{R}_q)$，而这一量在采样前无法直接观测。为了预测它，我们将成功概率的 GP 模型替换为奖励方差的 GP 模型。具体而言，对于每个提示 q，将奖励方差建模为 $v_{q,t} = \mathrm{softplus}(g_t(x_q)) = \log(1 + \exp(g_t(x_q)))$，其中 g_t 与正文一样是潜在 GP。观测到奖励 $\{\tilde{R}_{q,j}\}_{j=1}^{n_q}$ 后，我们计算样本方差 $\hat{s}_q^2$，并将潜变量的观测值设为 $\hat{g}_{q,t} = \log(\exp(\hat{s}_q^2) - 1)$。GP 后验更新和递归预测步骤保持不变，仅将 sigmoid 链接替换为 softplus 链接。

E.3 预算分配优化

给定预测奖励方差 $\widehat{\mathrm{Var}}(\tilde{R}_q)$，定义 $a_q := \sigma_{Z_q}^2 \widehat{\mathrm{Var}}(\tilde{R}_q)$。Dr. GRPO 的采样分配问题的连续松弛形式为

$$\min\left\{\sum\nolimits_{q\in\mathcal{B}_t} a_q \frac{n_q - 1}{n_q^2} \;:\; \sum\nolimits_{q\in\mathcal{B}_t} n_q = C,\; L \le n_q \le U,\; n_q \in \mathbb{R}\;\forall q\right\},$$

对于 RLOO，则为

$$\min\left\{\sum\nolimits_{q\in\mathcal{B}_t} a_q \frac{1}{n_q - 1} \;:\; \sum\nolimits_{q\in\mathcal{B}_t} n_q = C,\; L \le n_q \le U,\; n_q \in \mathbb{R}\;\forall q\right\}.$$

最优解由正文中的定理 5.1 和 5.2 给出，但此时采用上述更新后的 a_q 定义。附录 D 所述的舍入流程无需修改即可适用。

F 训练演进比较

本节比较 `Qwen2.5-Math-1.5B` 使用 GRPO 和 GRPO+VIP 时的训练演进。图 6 报告训练指标（平均优势、平均奖励）和多项性能指标（best@32、maj@32、mean@32）。

为确保所有训练轨迹可直接比较，**每个模型都在同一数据集上、使用完全相同的优化设置进行训练**：17k 个训练提示采用相同的固定顺序；训练两轮；批次大小为 512，小批次大小为 64；每批次采样预算为 512 * 8 和 512 * 16。因此，在所有方法中，每个梯度步对应相同的数据量和计算量。

在大多数评估检查点，使用 VIP 都带来一致且显著的提升。训练中，我们观察到，使用 VIP 可持续获得显著远离零的优势和更高的奖励。这表明，学习算法提供了更丰富的学习信号，采样分配策略也确实有效。图 7 提供了进一步的实证：在多数训练步，VIP 的性能超过 GRPO。

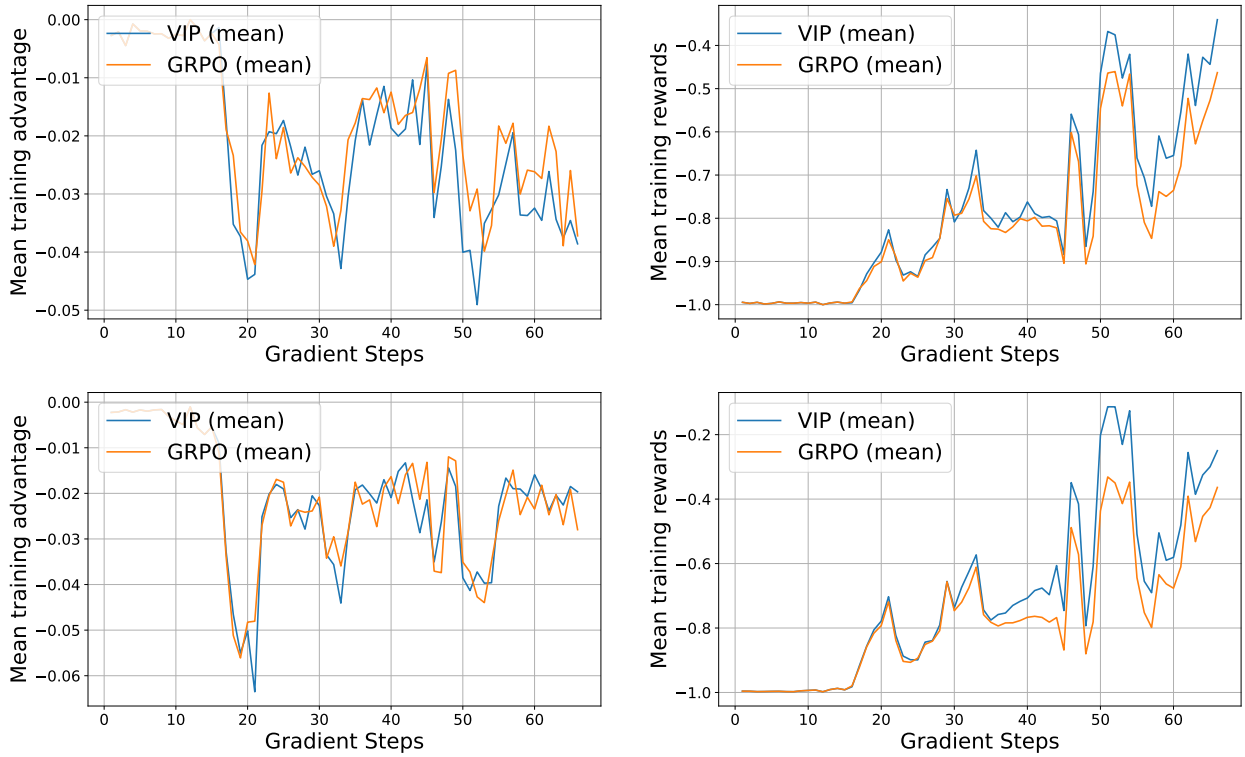
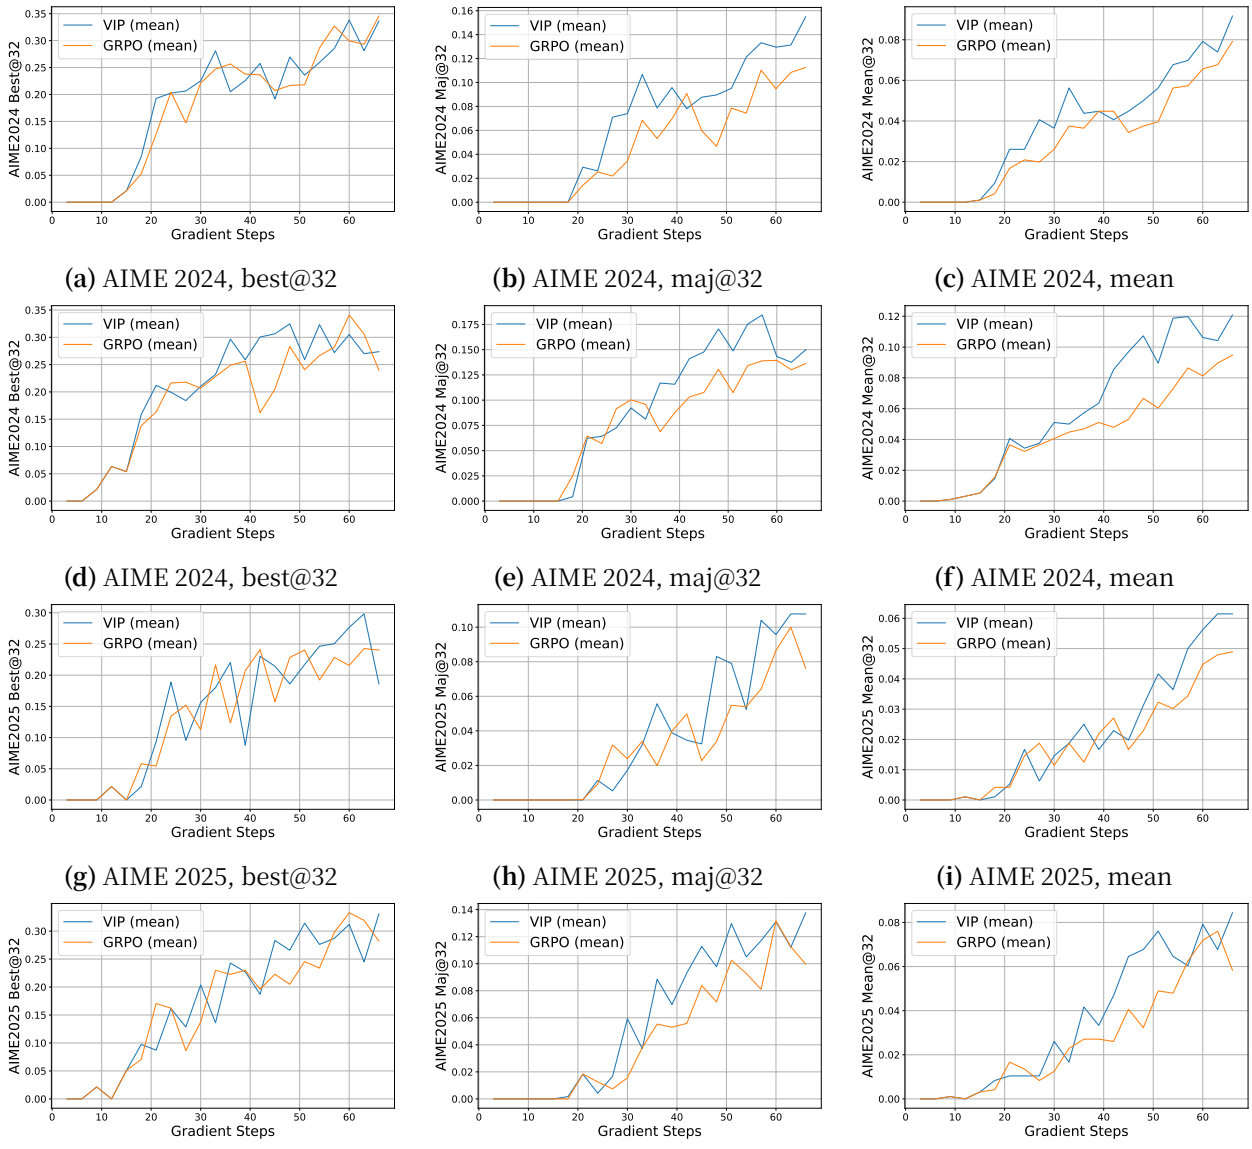


图 6: 在采样预算为 8（第一行）和 16（第二行）时，GRPO 与 GRPO+VIP 的平均优势和平均奖励比较。



(a) AIME 2024, best@32 **(b)** AIME 2024, maj@32 **(c)** AIME 2024, mean

(d) AIME 2024, best@32 **(e)** AIME 2024, maj@32 **(f)** AIME 2024, mean

(g) AIME 2025, best@32 **(h)** AIME 2025, maj@32 **(i)** AIME 2025, mean

(j) AIME 2025, best@32 **(k)** AIME 2025, maj@32 **(l)** AIME 2025, mean

图 7: 在 AIME 2024 和 AIME 2025 上，使用采样预算 8（a、b、c、g、h、i）和 16（d、e、f、j、k、l）时，GRPO 与 GRPO+VIP 在不同准确率指标上的比较。