# WildGuard 中文译文 · 公开删节版

WildGuard: Open One-Stop Moderation Tools for Safety Risks, Jailbreaks, and Refusals of LLMs

原作者：Seungju Han; Kavel Rao; Allyson Ettinger; Liwei Jiang; Bill Yuchen Lin; Nathan Lambert; Yejin Choi; Nouha Dziri

源版本：arXiv:2406.18495v3

https://arxiv.org/abs/2406.18495v3

原作许可：Creative Commons Attribution 4.0 International (CC BY 4.0)。本译文及其删节改编亦按此许可提供。

https://creativecommons.org/licenses/by/4.0/

非官方 AI 辅助译文；翻译与公开版编排：dot。原作者未审校、认可或背书。公开版制作日期：2026-11-10。

本文件是有删节的阅读版，不是全文译本。保留页沿用旧译本页码，因此页码和交叉引用可能跳号。浅灰色区域表示实际删除的内容，而非可恢复遮盖。

修改与遗漏：删去原封面、目录、图1所在页、附录提示/示例/模板、拒绝字符串表、图3-9标注界面和图文译文。保留正文、数值图2、数值结果表及所选基准说明。既有的表11安全删节仍有效：整张表11不收录，危险清单不恢复。正文双引号实例保守删节。

第三方素材的独立授权未核实，不主张论文许可当然涵盖这些素材。所保留图表为论文报告的实验数值图表；不包含数据集、模型权重、英文原文PDF或原始源包。详见随附README。

arXiv:2406.18495v3

**摘要**

我们提出 WildGuard ，这是一款开放、轻量级的 LLM 安全内容审核工具，可实现三个目标：（1）识别用户提示中的恶意意图；（2）检测模型回答中的安全风险；（3）确定模型的拒绝率。WildGuard 将这些功能整合为一站式工具，以更高的准确率和对 13 个风险类别的广泛覆盖，满足日益增长的 LLM 交互自动安全内容审核与评估需求。现有开放内容审核工具（例如 Llama-Guard2 [16]）在对直接的模型交互进行分类时表现尚可，但远远落后于通过提示使用的 GPT-4 ，尤其是在识别对抗性越狱以及评估模型拒绝行为方面；后者是评估模型回答中安全行为的一项关键指标。

为应对这些挑战，我们构建了 WildGuardMix：一个包含 92K 个已标注样本、规模庞大且经过精心平衡的多任务安全内容审核数据集，覆盖常规（直接）提示和对抗性越狱，并为其配对了多种拒绝和遵从回答。WildGuardMix 由 WildGuard 的训练数据 WildGuardTrain ，以及高质量的人工标注内容审核测试集 WildGuardTest 共同组成；后者包含 5K 个已标注条目，覆盖广泛的风险情境。 通过在 WildGuardTest 和十个现有公开基准上进行广泛评估，我们表明，与十个现有的强大开源内容审核模型相比，WildGuard 在全部三项任务上均取得了开源安全内容审核领域的最先进性能（例如，拒绝检测性能提升最高达 26.4%）。重要的是，WildGuard 的性能与 GPT-4 相当，有时甚至更高（例如，提示有害性识别性能提升最高达 3.9%）。WildGuard 可在 LLM 界面中充当高效的安全审核器，将越狱攻击的成功率从 79.8% 降至 2.4%。

**模型**: https://github.com/allenai/wildguard
🤗 **数据**: https://huggingface.co/datasets/allenai/wildguardmix

# 1 引言

如果缺乏充分的防护，使用现代语言模型（LM）的系统会带来相当大的风险 [4, 8, 15, 39, 44]。有效的内容审核对于缓解这些风险至关重要，其方式包括过滤不期望的输入 [24]、监测有害的模型生成内容 [16]，以及通过衡量模型对有害提示和无害提示的拒绝率来评估模型安全防护措施的有效性 [30]。

在本研究中，我们提出 WildGuard ，一款用于评估用户与 LLM 交互安全性的轻量级、多用途内容审核工具。WildGuard 为三项安全内容审核任务提供一站式资源：提示有害性检测、回答有害性检测和回答拒绝检测。 我们表明，WildGuard 在全部三项任务上都推进了开源安全内容审核工具的最先进水平，相较于成本高昂且不断变化的 API 内容审核工具，提供了一种更开放、一致且经济的替代方案，其性能达到或超过 GPT-4 评判器。

开发 WildGuard 尤其受到以下两项观察的推动。 首先，与常规（即直接）请求相比，现有开放工具（如 Llama-Guard2 [16]）在辨识*对抗性*提示（即 越狱）中的危害时效果要差得多，而且在这两类请求上都远远落后于 GPT-4 。 其次，尽管现有开放工具在一定程度上可以识别回答中的危害，但回答的*有害性*并不足以确定模型是否*拒绝*回答用户的提示。 例如，这一点对于测试过度安全行为至关重要：如果用户问 ，无论模型过度拒绝（ ），还是正确遵从（ ），其回答通常都是无害的。 因此，仅对危害进行分类不足以评估安全性，有必要独立评估拒绝行为。 表 1 显示，大多数现有内容审核模型并未单独考虑这项任务，而唯一这样做的模型与 GPT-4 相比表现不佳（§ 2）。

为弥补这些不足，我们构建了 WildGuardMix ，这是一个经过精心平衡的多任务内容审核数据集，包含覆盖 13 个风险类别的 92K 个已标注样本，是迄今规模最大的多任务安全数据集。图 1 概述了数据构成及示例。数据来自四类来源（见 § 3.1），以尽可能扩大覆盖范围，同时精心平衡提示有害性、常规与对抗性结构，并为各类提示配对拒绝和遵从回答。 WildGuardMix 包含 WildGuard

**表 1:** 比较各模型在提示有害性（PH）、回答有害性（RH）与拒绝检测（RR）方面的能力，以及权重（Open）和训练数据（Data）的开放情况。只有 WildGuard 在完全开放的同时支持全部任务。

| 模型 | PH | RH | RR | 权重开放 | 数据开放 |
|---|---|---|---|---|---|
| Llama-Guard | ✓ | ✓ | × | ✓ | × |
| Llama-Guard 2 | ✓ | ✓ | × | ✓ | × |
| Aegis-Guard | ✓ | ✓ | × | ✓ | ✓ |
| HarmB | × | ✓ | × | ✓ | × |
| MD-Judge | × | ✓ | × | ✓ | × |
| LibrAI-harm | × | ✓ | × | ✓ | × |
| LibrAI-ref | × | × | ✓ | ✓ | × |
| BeaverDam | × | ✓ | × | ✓ | ✓ |
| OAI Mod. API | ✓ | ✓ | × | × | × |
| GPT-4 | ✓ | ✓ | ✓ | × | × |
| WildGuard | ✓ | ✓ | ✓ | ✓ | ✓ |

**测试基准** 为评估对抗性提示中的危害检测，我们从 WildJailbreak （WJ ） [20] 的验证集中抽取了 250 条无害提示和 250 条有害提示，组成均衡混合样本；该大型数据集包含来自不同危害类别的对抗性和常规请求。 为评估细微复杂的拒绝行为检测，我们使用新提出的基准 XSTest-Resp ，具体见 §3.2。作为对照，我们还使用 XSTest-Resp 展示第三项任务，即回答有害性的结果。

**模型** 我们在这些测试中评估了开源和闭源工具。在开源工具中，我们测试了四个经过指令微调、可识别提示和回答有害性的模型：Llama-Guard [16]、Llama-Guard2 [26]、Aegis-Guard-Defensive [13] 和 Aegis-Guard-Permissive [13]。 对于这些模型，在标注拒绝行为时，若输出被判为有害，我们就将回答标记为遵从；若输出标签为安全，则将回答标记为拒绝。我们仅展示有害提示上的结果（表 2 中的 RR(h)），因为这种映射在这一设置下更有可能奏效。 我们还测试了 LibrAI-LongFormer-ref ，该模型在 Do-Not-Answer 基准 [38] 上接受拒绝检测训练，并用于 TrustLLM [32] 的评估。最后，我们测试了一个基于关键词的分类器，它使用预定义的拒绝关键词列表来识别拒绝行为（关键词列表见附录 D.3）。后两个模型仅用于拒绝检测评估。我们还评估了两种基于 API 的工具：GPT-4[1] [1] 和 OpenAI Moderation API [28]。对于 GPT-4 ，我们尝试了多种提示，并选择性能最佳的一种。该提示列于附录 D.2 的表 15 中。OpenAI Moderation API 返回毒性标签，我们用这些标签判断提示和回答的有害性。

**发现 1：现有开放工具在对抗性提示上不可靠，且远远落后于 GPT-4 。** 从图 2 可以看出，现有开放工具在常规提示的危害检测上表现尚可，但难以检测对抗性提示中的危害。在这两类提示上，开放工具与 GPT-4 之间都存在显著的性能差距，因此仍然必须依赖成本高昂的 API 工具。

**发现 2：现有开放工具难以衡量模型回答中的拒绝行为。** 表 2 显示，开放工具也难以识别模型生成内容中的拒绝行为。表现最好的危害检测模型 Llama-Guard2 落后于 GPT-4 15.1%，验证了回答有害性不足以胜任这项任务；然而，即使是专门针对拒绝检测训练的模型 LibrAI-LongFormer-ref ，也仅略优于简单的关键词基线，并落后于 GPT-4 24.3%。

[1]所有实验均使用 `gpt-4-0125-preview`。

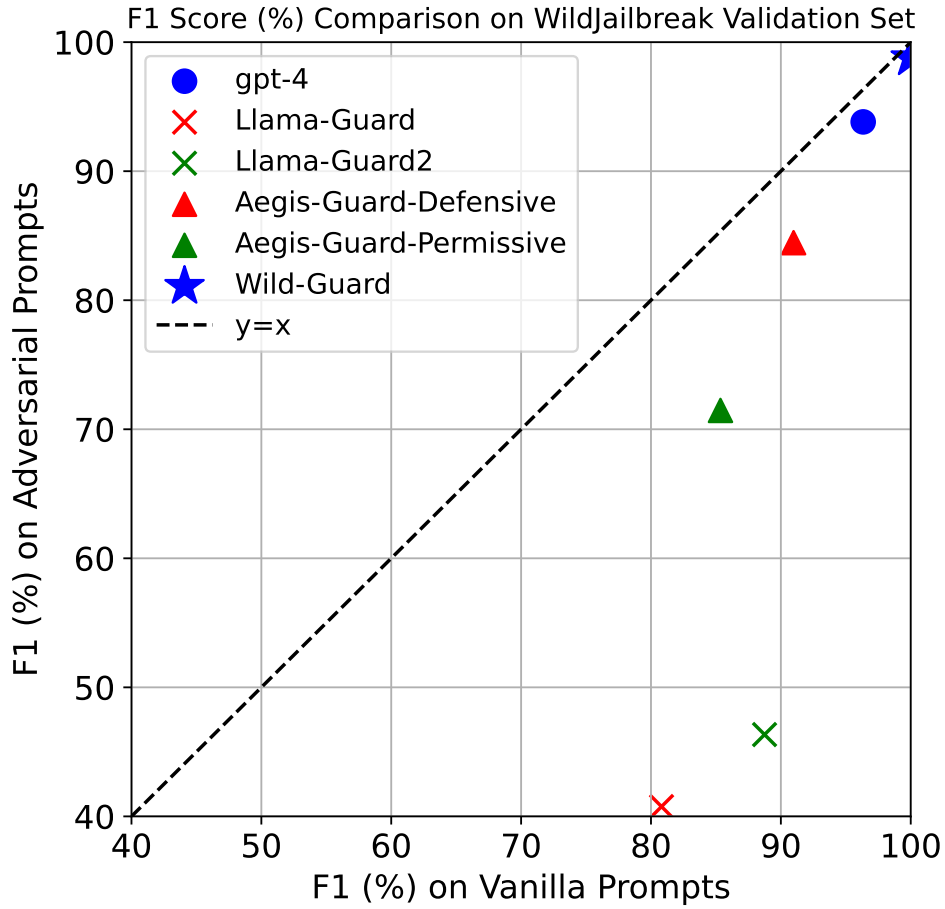



**图 2:** 在 WJ 评估集上对抗性提示与常规提示的有害性检测表现。

**表 2:** 在 XSTest-Resp 上回答有害性与拒绝检测的 F1 分数。**最优**分数以粗体表示，次优分数加下划线。

| | RH | RR | RR(h) |
|---|---|---|---|
| Llama-Guard | 82.0 | 62.9 | 81.2 |
| Llama-Guard2 | 90.8 | 64.1 | 85.0 |
| Aegis-Guard-D | 52.8 | 44.2 | 36.9 |
| Aegis-Guard-P | 60.4 | 48.5 | 49.0 |
| LibrAI-LongFormer-ref | - | 74.3 | 80.5 |
| 关键词检测器 | - | 71.0 | 70.2 |
| OAI Mod. API | 46.6 | 58.6 | 70.5 |
| GPT-4 | 91.3 | **98.1** | **95.4** |
| WildGuard | **94.7** | 92.8 | 93.4 |

总而言之，这些表现说明，现有开源工具仍有相当大的改进空间，而高质量的多用途内容审核分类器可以满足一系列相关需求。

# 3 构建 WildGuardMix 与 WildGuard

受到 §2 中分析的启发，并考虑到现有内容审核工具训练过程缺乏透明度，我们开发了 WildGuardTrain 和 WildGuardTest 两个数据集，作为 WildGuardMix 的组成部分。本节介绍我们如何整理构建这些数据集，以及如何训练 WildGuard 。

## 3.1 WildGuardTrain：多任务内容审核训练数据集

WildGuardTrain （WGTrain ）是一个综合训练数据集，共包含 86,759 个条目，数据来自不同来源，其中有 48,783 条独立提示和 37,976 个提示—回答对。该数据集覆盖无害和有害情境下的常规（直接请求）提示及对抗性提示，也涵盖多种类型的拒绝和遵从回答。WGTrain 包括四类来源的数据：合成对抗性数据、合成常规数据、真实世界用户与 LLM 的交互数据（In-the-Wild ），以及现有的标注员编写数据。所有数据的选择都旨在优化这三项任务的覆盖范围、多样性和平衡性。图 1 概述了数据集的构成。

### 3.1.1 提示构建

**常规有害合成提示。** 我们通过合成方式生成覆盖广泛风险情境的有害提示。受 Weidinger et al. [39] 启发，我们考虑了四个高层类别下的 13 个危害子类别；这四个高层类别是*隐私*、*错误信息*、*有害语言*和*恶意用途*。附录 A.6 的表 10 列出了危害类别及我们的数据统计。为生成具有针对性、真实且多样的有害情境，我们设计了一套结构化生成流程，详见附录 A.1。

**常规无害合成提示。** 与 WildJailbreak [20] 类似，为尽可能精确地检测提示有害性，我们还纳入了两种无害的对照提示：1）表面上类似于不安全提示的无害提示，其设计受到 XSTest [30] 中 10 个过度安全类别[2]的启发；2）讨论敏感但安全话题的无害提示。这些常规无害对照提示使用 GPT-4 生成。用于生成这些请求的 GPT-4 提示见附录 A.2 的表 9，示例见表 7。

**对抗性无害与有害合成提示。** 我们采用 WildTeaming [20] 框架，将生成的常规提示（包括有害和无害提示）转换为对抗性提示。该框架从真实场景中的用户与 LLM 交互中挖掘越狱策略，并将选出的策略组合起来，将常规请求转换为多样化的对抗性版本。具体而言，WildTeaming 首先使用 OpenAI Moderation API 从 LMSYS-Chat-1M 和 WildChat 中寻找可能有害的用户请求。随后，我们通过提示使用 GPT-4 ，从这些请求中分解出意图和越狱策略。这一挖掘过程最终得到一个越狱策略池；接着，我们从中随机抽取 2–7 种 In-the-Wild 策略，最后使用所抽取的策略将常规提示转换为对抗性提示。

**来自 In-the-Wild 和现有标注员编写数据的提示。** 我们考虑了两类公开数据：1）由我们标注有害性的真实场景数据；2）现有的标注员编写安全数据。 为覆盖真实世界用户请求中的危害风险，我们纳入了 LMSYS-Chat-1M [42] 和 WildChat [41] 数据集中的提示。这两个数据集都记录了真

[2]同形或同音异义词、比喻性语言、安全目标、安全情境、定义、真实歧视／无意义群体、无意义歧视／真实群体、历史事件、公共隐私和虚构隐私。

实场景中人类与 LLM 的交互，其危害标签根据 OpenAI Moderation API 分配。 此外，我们还加入了现有标注员编写安全数据集的子样本，以进一步增强覆盖范围。这包括来自 HH-RLHF [5] 和 Anthropic Red-Teaming 数据集 [11] 的提示，其中也包括构成 AegisSafetyTrain [13] 和 Safety-Tuned Llamas [7] 的子集。

#### 3.1.2 遵从与拒绝回答的构建

**LLM 回答生成。** 对于合成的对抗性和常规提示，我们生成配对的拒绝与遵从回答。我们将每条提示提交给一组 LLM，[3]同时附上提示后缀，指示 LLM 拒绝或遵从该提示。这样，我们就获得了一组拒绝和遵从候选回答。

**GPT-4 复杂回答生成。** 对于已观察到的拒绝分类难点，我们还使用 GPT-4 生成涵盖一组特定回答类型的条目。我们对一个使用 WGTrain 早期原型训练的分类器进行错误分析，识别出若干类被分类器错误标注的细微复杂回答。这些类别大多是包含注意事项、警告等内容的遵从回答。随后，我们为 GPT-4 构造单样本提示，以生成具有类似特征的合成回答，从而增强对复杂回答的覆盖。[4]

#### 3.1.3 筛选、审查与抽样

我们使用 GPT-4 为开放 LM 生成的回答标注三项目标任务的标签，并重新归类未能匹配预期标签的条目，以此进一步筛选回答。随后，我们抽取 500 个条目，并按照 §3.2 所述方法收集人工标注，以审查这些 GPT-4 标签的质量。这项审查证实了 GPT-4 标签的高质量：在提示危害、回答危害和拒绝标签上，其分别有 92%、82% 和 95% 的条目与标注员投票得到的标签一致。筛选和审查之后，我们从这些集合中抽取了以下数量的提示，并为其配对拒绝和遵从回答：6,062 条常规有害提示、2,931 条常规无害提示、4,489 条对抗性有害提示和 4,339 条对抗性无害提示，总计得到 35,642 个提示与回答条目。我们还纳入了仅包含提示的条目，包括 10,451 条常规有害提示、3,086 条常规无害提示、11,289 条对抗性有害提示和 11,411 条对抗性无害提示。

我们从其他数据来源（无需筛选／审查）中的抽样情况如下：复杂回答数据中的拒绝、遵从和仅含提示的条目各 1,167 个；In-the-Wild 数据中的有害提示 944 条和无害提示 944 条；标注员编写数据中的无害提示 7,361 条、有害提示 2,130 条。[5] In-the-Wild 和标注员编写的条目仅包含提示。

### 3.2 WildGuardTest：高质量人工标注内容审核测试数据集

我们构建 WildGuardTest （WGTest ），以解决 §2 中讨论的现有内容审核工具评估的局限，包括对抗性输入的危害分类和拒绝检测。

为构建 WGTest ，我们首先从 §3.1 所述的合成常规与对抗性数据中划分出包含 1,725 个提示—回答对的测试集。 随后，对于每个提示—回答对，我们收集三位独立标注员对提示有害性、回答拒绝和回答有害性的标注。 这三项任务的 Fleiss Kappa [10] 分数分别为 0.55、0.72 和 0.50，表明一致性程度从中等到较高。 我们采用多数投票来获得金标准标签，并删除未能获得至少两位标注员一

[3]OLMo-7B-Instruct、GPT-3.5 、Vicuna-7b-v1.5、Llama3-8B-Instruct、Mistral-7B-Instruct-v0.2, 以及 Dolphin 的以下变体：`dolphin-2.9.1-llama-3-8b`、`dolphin-2.8-gemma-7b` 和 `dolphin-2.8-mistral-7b-v02`。

[4]多数条目按 XSTest 类别从常规无害提示集中选取用户提示；少数类别中的用户提示也通过合成方式生成。所有类别及提示见附录 A.5。

[5]更详细的分类统计见附录 A.7。

**表 3:** 在现有公开基准上评估提示与回答有害性的 F1 分数（%）。

| 模型 | 提示有害性 (F1) | | | | | | 回答有害性 (F1) | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| | ToxiC | OAI | Aegis | SimpST | HarmB | **平均** | HarmB | S-RLHF | BeaverT | XST | **平均** |
| Llama-Guard | 61.6 | 75.8 | 74.1 | 93.0 | 67.2 | 74.4 | 52.0 | 48.4 | 67.1 | 82.0 | 62.4 |
| Llama-Guard2 | 47.1 | 76.1 | 71.8 | 95.8 | 94.0 | 77.0 | 77.8 | 51.6 | 71.8 | 90.8 | 73.0 |
| Aegis-Guard-D | 70.0 | 67.5 | 84.8 | 100 | 77.7 | 80.0 | 62.2 | 59.3 | 74.7 | 52.8 | 62.3 |
| Aegis-Guard-P | 73.0 | 74.7 | 82.9 | 99.0 | 70.5 | 80.0 | 60.8 | 55.9 | 73.8 | 60.4 | 62.7 |
| HarmB-Llama | - | - | - | - | - | - | 84.3 | 60.0 | 77.1 | 64.5 | 71.5 |
| HarmB-Mistral | - | - | - | - | - | - | 87.0 | 52.4 | 75.2 | 72.0 | 71.7 |
| MD-Judge | - | - | - | - | - | - | 81.6 | 64.7 | 86.7 | 90.4 | 80.9 |
| LibrAI-LongFormer | - | - | - | - | - | - | 62.1 | 50.6 | 67.1 | 70.9 | 62.7 |
| BeaverDam | - | - | - | - | - | - | 58.4 | 72.1 | 89.9 | 83.6 | 76.0 |
| OAI Mod. API | 25.4 | 79.0 | 31.9 | 63.0 | 9.6 | 41.8 | 20.6 | 10.1 | 15.7 | 46.6 | 23.2 |
| GPT-4 | 68.3 | 70.5 | 84.4 | 100 | 100 | 84.6 | 86.1 | 67.9 | 86.1 | 91.3 | 82.0 |
| WildGuard | 70.8 | 72.1 | 89.4 | 99.5 | 98.9 | **86.1** | 86.3 | 64.2 | 84.4 | 94.7 | **82.4** |

致意见的条目。[6] 最后，我们在该数据集上运行一个通过提示使用的 GPT-4 分类器，并人工检查其输出与选定标注员标签不匹配的条目，以进一步审查真实标签。WGTest 的标签分布及依据我们风险分类体系划分的危害类别见附录 A.5 的表 10；更多标注细节见附录 E。

XSTest-Resp： **带有回答的 XSTest。** 我们还通过为 XSTest 扩充模型回答来创建 XSTest-Resp，以直接评估内容审核器在真实安全基准上为模型评分的准确性。 我们使用前文回答生成所用的同一组 LLM，为 XSTest [30] 中的提示生成回答，从这些输出中随机抽样，再按照与 WGTest 相似的方式收集回答危害和拒绝标签的人工标注。 根据标注员间一致性筛选后，我们总共得到 446 条用于回答有害性评估的提示（368 条有害回答、78 条无害回答），以及 449 条用于拒绝检测的提示（178 次拒绝、271 次遵从）。

### 3.3 使用 WildGuardTrain 训练 WildGuard

我们使用 WGTrain ，以 `Mistral-7b-v0.3` [19] 为基础模型，对 WildGuard 进行指令微调。[7]我们设计了统一的输入和输出格式以涵盖这三项任务，将用户提示和模型回答作为输入，并训练模型输出与全部三项任务对应的内容。 更多训练细节见附录 B。

## 4 对照现有 LLM 安全内容审核工具评估 WildGuard

我们表明，在现有基准和新提出的 WGTest 评估集上，WildGuard 在*提示危害*、*回答危害*和*拒绝检测*全部三项任务中，相较于现有 LLM 安全内容审核工具都显著提升了性能。

[6]由于我们提供了 这一答案选项，因此可能出现无法达成一致的情况。

[7]我们尝试了多种基础模型（比较结果见附录 F.1）。`Mistral-7b-v0.3` 表现最佳，但各模型间差距较小，凸显了 WildGuardTrain 的首要重要性。

**表 4:** 在 WildGuardTest 上的 F1 分数（%）。 与 分别表示对抗性和常规提示，二者均包含无害与有害提示。 表示仅在有害提示上进行拒绝检测。

| 模型 | 提示有害性 | | | 回答有害性 | | | 拒绝检测 | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| | 对抗 | 常规 | **总体** | 对抗 | 常规 | **总体** | *有害* | 对抗 | 常规 | **总体** |
| Llama-Guard | 32.6 | 70.5 | 56.0 | 25.8 | 66.7 | 50.5 | 76.5 | 45.1 | 56.9 | 51.4 |
| Llama-Guard2 | 46.1 | 85.6 | 70.9 | 47.9 | 78.2 | 66.5 | 82.2 | 47.9 | 58.8 | 53.8 |
| Aegis-Guard-D | 74.5 | 82.0 | 78.5 | 40.4 | 57.6 | 49.1 | 56.1 | 38.9 | 44.0 | 41.8 |
| Aegis-Guard-P | 62.9 | 77.9 | 71.5 | 49.0 | 62.4 | 56.4 | 67.1 | 45.4 | 48.2 | 46.9 |
| HarmB-Llama | - | - | - | 41.9 | 50.2 | 45.7 | 89.8 | 74.0 | 72.5 | 73.1 |
| HarmB-Mistral | - | - | - | 51.8 | 70.3 | 60.1 | 79.3 | 56.1 | 60.5 | 58.6 |
| MD-Judge | - | - | - | 67.7 | **85.0** | 76.8 | 85.7 | 50.6 | 59.4 | 55.5 |
| BeaverDam | - | - | - | 51.2 | 74.3 | 63.4 | 80.7 | 48.4 | 59.4 | 54.1 |
| LibrAI-LongFormer-harm | - | - | - | 61.7 | 64.2 | 63.2 | 79.2 | 61.7 | 62.7 | 62.3 |
| LibrAI-LongFormer-ref | - | - | - | - | - | - | 84.1 | 71.2 | 69.3 | 70.1 |
| 基于关键词 | - | - | - | - | - | - | 67.8 | 67.0 | 65.9 | 66.3 |
| OAI Mod. API | 6.8 | 16.3 | 12.1 | 14.7 | 18.8 | 16.9 | 71.4 | 44.5 | 54.3 | 49.8 |
| GPT-4 | 81.6 | **93.4** | 87.9 | **73.6** | 81.3 | **77.3** | 93.9 | **91.4** | **93.5** | **92.4** |
| WildGuard | **85.5** | 91.7 | **88.9** | 68.4 | 81.5 | 75.4 | **94.0** | 88.5 | 88.6 | 88.6 |

## 4.1 评估设置

**评估基准。** 我们在十个公开安全基准以及 WGTest 上，针对全部三项任务测试 WildGuard 和相关基线。对于提示有害性的公开基准，我们使用 ToxicChat [23]、OpenAI Moderation [24]、AegisSafetyTest [13]、SimpleSafetyTests [36] 和 HarmBenchPrompt [25]。对于回答有害性的公开基准，我们使用 HarmBenchResponse [25]、SafeRLHF [9]、BeaverTails [18] 和 XSTest-Resp[8]。 除 WGTest 外，唯一用于拒绝检测的评估集是 XSTest-Resp ，我们在 §2 中对其进行了讨论。 附录 C 的表 14 列出了各基准的统计信息。所有评估均报告 F1 分数。

**现有安全内容审核模型。** 与第 2 节相同，我们测试了四个经过训练、用于提示和回答有害性检测的基于 LM 的内容审核工具：Llama-Guard 、Llama-Guard2 、Aegis-Guard-Defensive 和 Aegis-Guard-Permissive [13, 16, 26]。 我们还测试了五个回答有害性分类模型：BeaverDam [18]、LibrAI-LongFormer-harm [38]、MD-Judge-v0.1 [22]， 以及 Mazeika et al. [25] 提出的两个 Harmbench 分类器（HarmBench-Llama、HarmBench-Mistral）。对于拒绝检测，我们测试了 LibrAI-LongFormer-ref [38]。更多模型细节见附录 §D。对于闭源工具，与第 2 节相同，我们测试了 OpenAI Moderation API 和 GPT-4。

## 4.2 结果：WildGuard 创下多任务性能新高

WildGuard **在提示分类方面表现最佳。** 结果见表 3 和表 4。在这两组评估集上，没有任何开放基线优于 GPT-4 。然而，在公开提示有害性基准上，WildGuard 的平均 F1 比 GPT-4 高出 1.8%，在 WGTest 上高出 1.1%。尤其在*对抗性*提示子集上，WildGuard 比最佳开放基线大幅提升 11.0%，

[8]我们将 XSTest-Resp 计入公开基准，因为其提示来自 XSTest [30]。

**表 5:** WGTrain 的消融实验，展示数据集各组成部分的贡献。各单任务模型的结果合并列于一行。

| 模型 | 提示有害性 | | | 回答有害性 | | | 拒绝检测 | | |
|---|---|---|---|---|---|---|---|---|---|
| | 公开集 | WGTest | | 公开集 | WGTest | | XSTest | WGTest | |
| | 平均 F1 | 对抗 F1 | 总体 F1 | 平均 F1 | 对抗 F1 | 总体 F1 | F1 | 对抗 F1 | 总体 F1 |
| WildGuardTrain | **86.1** | 85.5 | 88.9 | **82.4** | 68.4 | 75.4 | 92.8 | **88.5** | **88.6** |
| – 合成对抗性 | 84.6 | 77.1 | 84.4 | 78.6 | 67.8 | 73.9 | 94.1 | 88.3 | 87.6 |
| – 合成常规 | 83.6 | **85.7** | **89.8** | 81.3 | 66.9 | 75.5 | 90.2 | 85.7 | 84.9 |
| – In-the-Wild | 83.9 | 84.6 | 88.7 | 81.9 | **69.5** | **76.5** | 93.0 | 88.0 | **88.6** |
| – 标注员撰写 | 84.8 | 84.5 | 86.8 | 76.4 | 66.4 | 74.7 | **94.9** | 87.8 | 88.4 |
| 仅单任务 | 86.0 | 84.2 | 89.2 | 76.4 | 67.2 | 74.8 | 93.3 | 87.0 | 87.3 |

并超越 GPT-4 3.9%。

WildGuard **在回答有害性方面与基线相当。** 结果同样见表 3 和表 4。在回答有害性的公开基准上，我们发现 WildGuard 比所有开放基线至少高出 1.8%，并且仍是唯一超越 GPT-4 的开放模型（在四项评估中的两项上）。在 WGTest 上，WildGuard 与最佳开放基线 MD-Judge 的性能相差不超过 3%，且 WildGuard 在对抗性提示回答上的表现高出 1%。

WildGuard **显著提升了拒绝检测性能。** 在完整的拒绝评估中，表 4 显示，WildGuard 比唯一明确对拒绝行为进行分类的现有开放模型 LibrAI-LongFormer-ref 高出 26.4%，比最强开放基线高出 21.2%。WildGuard 还缩小了开放模型与 GPT-4 之间的差距，其分数与 GPT-4 相差不超过 4.1%。

与 §2 相同，考虑到基线模型接受的是回答有害性检测训练，而不是拒绝检测训练，我们还加入了仅包含有害提示（*Harm.*）这一设置下的拒绝评估。在该设置下，我们发现 WildGuard 优于所有开放基线：比最佳开放基线高出近 5%，并比回答有害性任务上最强的模型 MD-Judge 高出 9.7%。此外，在该设置下，WildGuard 还超越了 GPT-4 评判器。

**总结。** 在既有基准和 WGTest 的全部三项任务上，WildGuard 的表现达到或超过 GPT-4，并显著优于现有开放模型。唯一的例外是 WGTest 回答有害性任务上的 MD-Judge，在这项任务上，WildGuard 与其处于同一水平。这突显了 WildGuard 的灵活性和实用性：它可以同时应用于提示有害性、回答有害性和回答拒绝分类三项任务，并取得更高的准确率。值得注意的是，WildGuard 擅长对无害提示下的拒绝行为进行分类，此前没有任何开放模型能以足够好的性能支持这一能力。

### 4.3 WildGuard 消融实验结果

表 5 展示了针对 WGTrain 的一系列消融实验，以及多任务设置的消融实验：将多任务模型与使用相同训练数据、针对各项任务训练的单任务模型进行比较（格式见表 12 和表 13）。我们比较了所有任务在 WGTest 上的分数、提示和回答有害性在公开评估中的平均 F1（见 表 3），以及回答拒绝在 XSTest-Resp 上的表现。

WGTrain **的每个主要组成部分都有助于提升内容审核性能。** WGTrain 由来自四类来源的有害和无害提示组成（见 §3）；表 5 显示，每一类来源对于在各项任务上取得高性能都不可或缺。例

如，移除对抗性数据后，几乎所有测试评估的分数都会下降，其中 WGTest 对抗性提示上的 F1 下降超过 8.4 分。另一方面，如果排除合成常规数据，公开提示危害评估和 WGTest 拒绝检测的 F1 均下降 2.5–3.7 分。没有 In-the-Wild 数据时，各项任务的公开评估性能都会下降，尤其是在 ToxicChat 上，F1 下降了 10.3 分；该数据集由真实场景中人类与 LLM 交互的提示组成。 最后，排除现有标注员编写数据会使公开提示和回答有害性任务的表现显著变差（F1 损失 1.3–6 分），并使 WGTest 上全部任务的表现下降。

**多任务训练提升了模型性能。** 我们还将多任务设置下训练的 WildGuard 与针对各单项任务训练的模型进行比较。 除 XSTest-Resp 上的拒绝检测外，多任务模型在所有任务上均优于单任务模型，表明多任务训练使 WildGuard 成为一种高效的统一工具，而无需单项任务性能。 *［译注：原文此处语句不完整。］*

### 4.4 展示 WildGuard 作为人类与 LLM 交互中的内容审核器

**表 6:** 在 WildJailbreak 评估集上使用分类模型过滤有害提示与回答时的 ASR 和 RTA。

| 过滤器 \ 模型 | Tulu2+WJ (ASR (%, ↓) / RTA (%, ↓)) | Tulu2-dpo (ASR (%, ↓) / RTA (%, ↓)) |
|---|---|---|
| × | 2.3/**1.2** | 79.8/**0.0** |
| WildGuard | **0.7**/1.7 | **2.4**/0.4 |
| Llama-Guard2 | 1.9/1.6 | 53.1/0.8 |
| Aegis-Guard-D | 0.9/16.8 | 12.4/16.0 |
| Aegis-Guard-P | 1.7/4.0 | 32.7/3.6 |
| MD-Judge | 1.9/10.1 | 25.7/4.4 |

作为实际应用展示，我们在模拟聊天内容审核场景中测试 WildGuard 及其他工具，将其与生成模型配合使用，检测有害提示和回答，并在检测到危害时，以无害的拒绝回答替代模型的原始回答。测试提示采用完整的 WildJailbreak （WJ ）验证集 [20]，其中包含 2000 条有害对抗性提示和 250 条无害对抗性提示。我们将内容审核过滤器应用于 Tulu-2-dpo-7B [17]，并与在 WJ 训练集上进行安全微调的 Tulu-2 基线（Tulu-2 + WJ）进行比较。 我们衡量有害提示的攻击成功率（ASR）和无害提示的拒绝回答率（RTA），两项任务均使用 GPT-4 将回答标注为遵从或拒绝。当使用 WildGuard 、Llama-Guard 和 Aegis-Guard 作为内容审核器时，我们分别以提示有害性和回答有害性输出作为提示端和回答端的判断依据；对于 MD-Judge ，我们则将提示和回答合并输入，并使用其回答有害性输出。

表 6 显示，WildGuard 在拒绝有害越狱提示和避免过度拒绝两方面都表现最强：对于每个模型，它都能实现最低的 ASR，同时将对无害提示拒绝率的增加降至最低。 具体而言，我们发现，Tulu-2 结合 WildGuard 过滤器后，ASR 显著改善（从 79.8% 降至 2.4%），而 RTA 方面仅付出极小代价（从 0.0% 升至 0.4%）。我们还发现，将 WildGuard 用作过滤器，与直接进行安全微调的 Tulu-2 + WJ 表现相近。这表明，对于无法开展训练的应用场景，WildGuard 可以作为高效的安全过滤器，在推理时嵌入 LLM 界面。 此外，即使使用 Tulu-2 + WJ 这样的安全微调模型，仍可通过加入 WildGuard 作为额外过滤器，以相对较小的 RTA 增幅进一步降低 ASR。

## 5 相关工作

**LLM 安全内容审核工具。** 大量既有研究关注在 Twitter [40] 和 Reddit [14] 等在线社交网站上检测仇恨、毒性、冒犯性和辱骂性内容 [12, 21, 29]。 随着近期最先进的 LM（例如 GPT-4、Gemini、Claude [1, 3, 33]）及其能力的发展，研究人员开始将这些模型用作评判器 [43]，辅助开展内容审核。 除了依赖前沿 LM 之外，近期研究还使用合成收集的内容审核数据来训练公开可用的开源模型，例如 Llama2-7b [35]，以覆盖广泛的风险范围。 一些突出的例子包括 Llama-Guard [16]、其后续版本 Llama-Guard2 [26]（基于 Llama3 [2] 模型的版本）、Aegis [13]、MD-Judge [22]、HarmBench 分类器 [25] 和 BeaverDam [18]。 然而，我们的工作在几个关键方面有所不同：与许多既有研究不同，WildGuard 经过训练，能够稳健地处理对抗性输入；它还支持涵盖提示危害、回答危害和拒绝检测的多任务处理，此前没有任何模型能令人满意地同时支持这些任务。

**模型安全分类体系。** 多项既有研究制定了分类体系，用于识别潜在的模型安全风险，并将其细分为不同类别。我们为 WildGuardMix 采用的分类体系受到 Weidinger et al. [39] 的启发；该研究定义了若干广泛的风险领域及其详细子类别。 其他定义模型安全分类体系的研究包括 Tedeschi et al. [34] 和 Vidgen et al. [37]。这些分类体系有大量重叠，但在显式或隐式覆盖的内容类型，以及各大风险领域内的分类细致程度方面存在差异。

**安全训练与评估数据集。** 关键的一点是，许多既有工作（例如 Llama-Guard ）并未发布训练数据。发布了安全数据的工作包括 Anthropic 的红队测试和 RLHF 研究 [5, 11]、Aegis [13]、BeaverTails [18]（仅包含回答危害）和 SALAD-Bench [22]（仅包含提示）；但与 WGTrain 相比，这些数据对对抗性模型交互的覆盖有限，也不包含来自真实用户的 In-the-Wild 提示。 此外，现有内容审核评估集 ToxicChat、OpenAI Moderation、AegisSafetyTest、SimpleSafetyTests、Harmbench、SafeRLHF 和 BeaverTails [9, 13, 18, 23, 25, 28, 30, 36] 对对抗性提示（尤其是无害对抗性类别）的覆盖有限，覆盖的潜在危害范围狭窄，或者不测试拒绝检测和过度安全行为。WGTest 填补了这一空白，提供高质量的人工标注评估数据，涵盖广泛的危害类别、越狱，以及安全分类的全部三项重要任务。

## 6 局限性

我们的数据很大一部分是合成的，因此在某些方面可能无法完美近似真实场景中自然的人类输入。为覆盖真实世界中的用户请求分布，我们在数据集中纳入了来自 In-the-Wild 的提示，但其规模有限，因此无法涵盖真实世界中所有可能的情境。此外，我们使用了数量较多但仍然有限的一组模型来生成回答，因此可能无法覆盖所有模型回答模式。

按照安全研究中的通常做法，也往往出于不可避免的需要，我们对哪些具体内容类别属于有害类别作出了明确选择。这些类别可能不同于他人偏好的类别。由于其他模型可能基于不同的底层危害分类体系开发，因此在 WildGuardTest 上评估时，我们对危害的定义与模型开发者目标之间的差异可能会使它们表现较差。我们关注的风险类别列于附录的表 10。我们也承认，我们的风险分类体系可能无法覆盖所有潜在危害；不过，我们在附录 C 中列出了现有数据集／基准所覆盖的风险类别，而我们的风险分类体系及 WildGuardMix 所针对的具体细分主题同样覆盖这些类别，因此能够在这些现有基准上取得强劲表现。

类似地，我们也必须对拒绝的定义作出明确选择，而这可能无法完全符合他人的偏好。拒绝的定

义见图 4，该图展示了向标注员说明何种模型回答构成拒绝的指导。我们的拒绝定义包含多种情形，例如 和 ；同时还给出了可能与拒绝混淆的遵从回答示例，例如 和 。处理这些复杂行为仍然是一项挑战，我们期待在未来工作中继续完善方法。

最后，WildGuard 尚未涵盖的一个方向是更细粒度的危害类别分类。尽管 WildGuard 的三任务设置已具有广泛的覆盖范围，但这一额外能力仍是未来工作中值得探索的有趣方向。

## 7 伦理考量

尽管 WildGuard 的准确率达到了最先进水平，它仍然有时会作出错误判断；当它用于自动内容审核系统时，这可能会让不安全的模型内容或用户的有害请求通过审核。WildGuard 的使用者应当意识到这种出现不准确判断的可能性。我们也认识到，发布 WildGuardMix 可能会无意中帮助生成有害内容。这并非 WildGuardMix 的预期用途；为缓解这一风险，我们计划限制资源的使用方式，例如要求接受使用协议后才能访问数据集。

## 8 结论

在本研究中，我们提出了 WildGuard，一个统一的多任务开放 LLM 安全内容审核模型，能够检测多种常规和对抗性有害用户提示、有害模型回答，以及模型拒绝行为。为支持 WildGuard 的开发，我们创建了 WGMix，其中包含用于安全内容审核工具的全面且多样的训练数据（WGTrain）和评估数据（WGTest）。通过 10 个公开基准以及新提出的 WGTest（专门关注更具挑战性的对抗性提示及拒绝行为），我们展示了 WildGuard 相较于 10 个现有开放安全内容审核工具集的显著优势。 值得注意的是，WildGuard 在全部三项分类任务上均达到了与闭源替代方案相当、甚至更好的性能，从而弥合了开源与闭源安全内容审核工具（例如 GPT-4）之间的差距。通过公开发布 WildGuard 模型和 WildGuardMix 数据集，我们的研究推动了 LLM 安全内容审核工具集未来的开放与可靠发展，为更安全的 LLM 应用铺平了道路。

## 致谢

本研究获得了 NSF DMS-2134012、ONR N00014-24-1-2207、DARPA MCS 和 SemaFor 项目，以及 Allen Institute for AI 的支持。感谢 Ai2 研究人员在整个项目过程中提供的有益反馈。

# 参考文献


[1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. GPT-4 技术报告（Gpt-4 technical report）. *arXiv preprint arXiv:2303.08774*, 2023.

[2] AI@Meta. Llama 3 模型卡（Llama 3 model card）. 2024. URL https://github.com/meta-llama/llama3/blob/main/MODEL_CARD.md.

[3] Anthropic. Claude 3 模型家族：Opus、Sonnet、Haiku（The claude 3 model family: Opus, sonnet, haiku）. URL https://api.semanticscholar.org/CorpusID:268232499.

[4] Usman Anwar, Abulhair Saparov, Javier Rando, Daniel Paleka, Miles Turpin, Peter Hase, Ekdeep Singh Lubana, Erik Jenner, Stephen Casper, Oliver Sourbut, et al. 保障大语言模型对齐与安全的基础性挑战（Foundational challenges in assuring alignment and safety of large language models）. *arXiv preprint arXiv:2404.09932*, 2024.

[5] Yuntao Bai, Andy Jones, Kamal Ndousse, Amanda Askell, Anna Chen, Nova DasSarma, Dawn Drain, Stanislav Fort, Deep Ganguli, Tom Henighan, Nicholas Joseph, Saurav Kadavath, Jackson Kernion, Tom Conerly, Sheer El-Showk, Nelson Elhage, Zac Hatfield-Dodds, Danny Hernandez, Tristan Hume, Scott Johnston, Shauna Kravec, Liane Lovitt, Neel Nanda, Catherine Olsson, Dario Amodei, Tom Brown, Jack Clark, Sam McCandlish, Chris Olah, Ben Mann, and Jared Kaplan. 利用人类反馈强化学习训练有帮助且无害的助手（Training a helpful and harmless assistant with reinforcement learning from human feedback）, 2022.

[6] Iz Beltagy, Matthew E. Peters, and Arman Cohan. Longformer：面向长文档的 Transformer（Longformer: The long-document transformer）. *arXiv:2004.05150*, 2020.

[7] Federico Bianchi, Mirac Suzgun, Giuseppe Attanasio, Paul Röttger, Dan Jurafsky, Tatsunori Hashimoto, and James Zou. 经安全调优的 Llama：提升指令遵循大语言模型安全性的经验（Safety-tuned llamas: Lessons from improving the safety of large language models that follow instructions）. *arXiv preprint arXiv:2309.07875*, 2023.

[8] Nicholas Carlini, Milad Nasr, Christopher A. Choquette-Choo, Matthew Jagielski, Irena Gao, Anas Awadalla, Pang Wei Koh, Daphne Ippolito, Katherine Lee, Florian Tramer, and Ludwig Schmidt. 已对齐的神经网络在对抗条件下也保持对齐吗？（Are aligned neural networks adversarially aligned?）, 2023.

[9] Josef Dai, Xuehai Pan, Ruiyang Sun, Jiaming Ji, Xinbo Xu, Mickel Liu, Yizhou Wang, and Yaodong Yang. Safe RLHF：基于人类反馈的安全强化学习（Safe rlhf: Safe reinforcement learning from human feedback）. *arXiv preprint arXiv:2310.12773*, 2023.

[10] Joseph L Fleiss, Bruce Levin, Myunghee Cho Paik, et al. 评定者间一致性的测量（The measurement of interrater agreement）. *Statistical methods for rates and proportions*, 2(212-236):22–23, 1981.

[11] Deep Ganguli, Liane Lovitt, Jackson Kernion, Amanda Askell, Yuntao Bai, Saurav Kadavath, Ben Mann, Ethan Perez, Nicholas Schiefer, Kamal Ndousse, et al. 通过语言模型红队测试减少危害：方法、规模扩展行为与经验教训（Red teaming language models to reduce harms: Methods, scaling behaviors, and lessons learned）. *arXiv preprint arXiv:2209.07858*, 2022.

[12] Samuel Gehman, Suchin Gururangan, Maarten Sap, Yejin Choi, and Noah A Smith. RealToxicityPrompts：评估语言模型生成文本的毒性退化（Realtoxicityprompts: Evaluating neural toxic degeneration in language models）. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pp. 3356–3369, 2020.

[13] Shaona Ghosh, Prasoon Varshney, Erick Galinkin, and Christopher Parisien. Aegis：利用大语言模型专家集成进行在线自适应人工智能内容安全审核（Aegis: Online adaptive ai content safety moderation with ensemble of llm experts）. *arXiv preprint arXiv:2404.05993*, 2024.

[14] Rishav Hada, Sohi Sudhir, Pushkar Mishra, Helen Yannakoudakis, Saif Mohammad, and Ekaterina Shutova. Ruddit：英语 Reddit 评论的冒犯性评分规范（Ruddit: Norms of offensiveness for english reddit comments）. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pp. 2700–2717, 2021.

[15] Dan Hendrycks, Mantas Mazeika, and Thomas Woodside. 灾难性人工智能风险概述（An overview of catastrophic ai risks）. *arXiv preprint arXiv:2306.12001*, 2023.

[16] Hakan Inan, Kartikeya Upasani, Jianfeng Chi, Rashi Rungta, Krithika Iyer, Yuning Mao, Michael Tontchev, Qing Hu, Brian Fuller, Davide Testuggine, et al. Llama Guard：基于大语言模型的人机对话输入输出安全防护（Llama guard: Llm-based input-output safeguard for human-ai conversations）. *arXiv preprint arXiv:2312.06674*, 2023.

[17] Hamish Ivison, Yizhong Wang, Valentina Pyatkin, Nathan Lambert, Matthew Peters, Pradeep Dasigi, Joel Jang, David Wadden, Noah A. Smith, Iz Beltagy, and Hannaneh Hajishirzi. 气候变化中的骆驼：利用 Tulu 2 增强语言模型适配（Camels in a changing climate: Enhancing lm adaptation with tulu 2）, 2023.

[18] Jiaming Ji, Mickel Liu, Josef Dai, Xuehai Pan, Chi Zhang, Ce Bian, Boyuan Chen, Ruiyang Sun, Yizhou Wang, and Yaodong Yang. BeaverTails：通过人类偏好数据集改进大语言模型的安全对齐（Beavertails: Towards improved safety alignment of llm via a human-preference dataset）. *Advances in Neural Information Processing Systems*, 36, 2024.

[19] Albert Q. Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier, Lélio Renard Lavaud, Marie-Anne Lachaux, Pierre Stock, Teven Le

Scao, Thibaut Lavril, Thomas Wang, Timothée Lacroix, and William El Sayed. Mistral 7B（Mistral 7b）, 2023.

[20] Liwei Jiang, Kavel Rao, Seungju Han, Allyson Ettinger, Faeze Brahman, Sachin Kumar, Niloofar Mireshghallah, Ximing Lu, Maarten Sap, Yejin Choi, and Nouha Dziri. 大规模 WildTeaming：从真实场景中的越狱到在对抗条件下更安全的语言模型（Wildteaming at scale: From in-the-wild jailbreaks to (adversarially) safer language models）. *arXiv preprint arXiv:2406.18510*, 2024.

[21] Alyssa Lees, Vinh Q Tran, Yi Tay, Jeffrey Sorensen, Jai Gupta, Donald Metzler, and Lucy Vasserman. 新一代 Perspective API：高效的多语言字符级 Transformer（A new generation of perspective api: Efficient multilingual character-level transformers）. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 3197–3207, 2022.

[22] Lijun Li, Bowen Dong, Ruohui Wang, Xuhao Hu, Wangmeng Zuo, Dahua Lin, Yu Qiao, and Jing Shao. SALAD-Bench：面向大语言模型的分层综合安全基准（Salad-bench: A hierarchical and comprehensive safety benchmark for large language models）. *arXiv preprint arXiv:2402.05044*, 2024.

[23] Zi Lin, Zihan Wang, Yongqi Tong, Yangkun Wang, Yuxin Guo, Yujia Wang, and Jingbo Shang. ToxicChat：揭示真实用户与人工智能对话中毒性检测的隐性挑战（Toxicchat: Unveiling hidden challenges of toxicity detection in real-world user-ai conversation）. *arXiv preprint arXiv:2310.17389*, 2023.

[24] Todor Markov, Chong Zhang, Sandhini Agarwal, Florentine Eloundou Nekoul, Theodore Lee, Steven Adler, Angela Jiang, and Lilian Weng. 真实场景中不良内容检测的综合方法（A holistic approach to undesired content detection in the real world）. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pp. 15009–15018, 2023.

[25] Mantas Mazeika, Long Phan, Xuwang Yin, Andy Zou, Zifan Wang, Norman Mu, Elham Sakhaee, Nathaniel Li, Steven Basart, Bo Li, et al. HarmBench：用于自动化红队测试与鲁棒拒答的标准化评估框架（Harmbench: A standardized evaluation framework for automated red teaming and robust refusal）. *arXiv preprint arXiv:2402.04249*, 2024.

[26] Meta. Meta Llama Guard 2：模型卡与提示格式（Meta llama guard 2: Model cards and prompt formats）. https://llama.meta.com/docs/model-cards-and-prompt-formats/meta-llama-guard-2/, 2024.

[27] Chenghao Mou, Chris Ha, Kenneth Enevoldsen, and Peiyuan Liu. Chenghaomou/text-dedup：参考快照（Chenghaomou/text-dedup: Reference snapshot）, September 2023. URL https://doi.org/10.5281/zenodo.8364980.

[28] OpenAI. OpenAI 内容审核 API（Openai moderation api）.

[29] Sara Rosenthal, Pepa Atanasova, Georgi Karadzhov, Marcos Zampieri, and Preslav Nakov. 用于冒犯性语言识别的大规模半监督数据集（A large-scale semi-supervised dataset for offensive language identification）. *arXiv preprint arXiv:2004.14454*, 2020.

[30] Paul Röttger, Hannah Rose Kirk, Bertie Vidgen, Giuseppe Attanasio, Federico Bianchi, and Dirk Hovy. XSTest：用于识别大语言模型过度安全行为的测试套件（Xstest: A test suite for identifying exaggerated safety behaviours in large language models）. *arXiv preprint arXiv:2308.01263*, 2023.

[31] Hao Sun, Zhexin Zhang, Jiawen Deng, Jiale Cheng, and Minlie Huang. 中文大语言模型的安全性评估（Safety assessment of chinese large language models）. *arXiv preprint arXiv:2304.10436*, 2023.

[32] Lichao Sun, Yue Huang, Haoran Wang, Siyuan Wu, Qihui Zhang, Yuan Li, Chujie Gao, Yixin Huang, Wenhan Lyu, Yixuan Zhang, Xiner Li, Zhengliang Liu, Yixin Liu, Yijue Wang, Zhikun Zhang, Bertie Vidgen, Bhavya Kailkhura, Caiming Xiong, Chaowei Xiao, Chunyuan Li, Eric Xing, Furong Huang, Hao Liu, Heng Ji, Hongyi Wang, Huan Zhang, Huaxiu Yao, Manolis Kellis, Marinka Zitnik, Meng Jiang, Mohit Bansal, James Zou, Jian Pei, Jian Liu, Jianfeng Gao, Jiawei Han, Jieyu Zhao, Jiliang Tang, Jindong Wang, Joaquin Vanschoren, John Mitchell, Kai Shu, Kaidi Xu, Kai-Wei Chang, Lifang He, Lifu Huang, Michael Backes, Neil Zhenqiang Gong, Philip S. Yu, Pin-Yu Chen, Quanquan Gu, Ran Xu, Rex Ying, Shuiwang Ji, Suman Jana, Tianlong Chen, Tianming Liu, Tianyi Zhou, William Wang, Xiang Li, Xiangliang Zhang, Xiao Wang, Xing Xie, Xun Chen, Xuyu Wang, Yan Liu, Yanfang Ye, Yinzhi Cao, Yong Chen, and Yue Zhao. TrustLLM：大语言模型的可信性（Trustllm: Trustworthiness in large language models）, 2024.

[33] Gemini Team. Gemini 1.5：释放百万词元上下文中的多模态理解能力（Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context）, 2024.

[34] Simone Tedeschi, Felix Friedrich, Patrick Schramowski, Kristian Kersting, Roberto Navigli, Huu Nguyen, and Bo Li. ALERT：通过红队测试评估大语言模型安全性的综合基准（Alert: A comprehensive benchmark for assessing large language models' safety through red teaming）, 2024. URL https://arxiv.org/abs/2404.08676.

[35] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, Dan Bikel, Lukas Blecher, Cristian Canton Ferrer, Moya Chen, Guillem Cucurull, David Esiobu, Jude Fernandes, Jeremy Fu, Wenyin Fu, Brian Fuller, Cynthia Gao, Vedanuj Goswami, Naman Goyal, Anthony Hartshorn, Saghar Hosseini, Rui Hou, Hakan Inan, Marcin Kardas, Viktor Kerkez, Madian Khabsa, Isabel Kloumann, Artem Korenev, Punit Singh Koura, Marie-Anne Lachaux, Thibaut Lavril, Jenya Lee, Diana Liskovich, Yinghai Lu, Yuning Mao, Xavier Martinet, Todor Mihaylov, Pushkar Mishra, Igor Molybog, Yixin Nie, Andrew Poulton, Jeremy Reizenstein, Rashi Rungta, Kalyan Saladi, Alan Schelten, Ruan Silva, Eric Michael Smith, Ranjan Subramanian, Xiaoqing Ellen Tan, Binh Tang, Ross Taylor, Adina Williams, Jian Xiang Kuan, Puxin Xu, Zheng Yan, Iliyan

Zarov, Yuchen Zhang, Angela Fan, Melanie Kambadur, Sharan Narang, Aurelien Rodriguez, Robert Stojnic, Sergey Edunov, and Thomas Scialom. Llama 2：开放基础模型与经微调的对话模型（Llama 2: Open foundation and fine-tuned chat models）, 2023.

[36] Bertie Vidgen, Hannah Rose Kirk, Rebecca Qian, Nino Scherrer, Anand Kannappan, Scott A Hale, and Paul Röttger. SimpleSafetyTests：用于识别大语言模型重大安全风险的测试套件（Simplesafetytests: a test suite for identifying critical safety risks in large language models）. *arXiv preprint arXiv:2311.08370*, 2023.

[37] Bertie Vidgen, Adarsh Agrawal, Ahmed M. Ahmed, Victor Akinwande, Namir Al-Nuaimi, Najla Alfaraj, Elie Alhajjar, Lora Aroyo, Trupti Bavalatti, Max Bartolo, Borhane Blili-Hamelin, Kurt Bollacker, Rishi Bomassani, Marisa Ferrara Boston, Siméon Campos, Kal Chakra, Canyu Chen, Cody Coleman, Zacharie Delpierre Coudert, Leon Derczynski, Debojyoti Dutta, Ian Eisenberg, James Ezick, Heather Frase, Brian Fuller, Ram Gandikota, Agasthya Gangavarapu, Ananya Gangavarapu, James Gealy, Rajat Ghosh, James Goel, Usman Gohar, Sujata Goswami, Scott A. Hale, Wiebke Hutiri, Joseph Marvin Imperial, Surgan Jandial, Nick Judd, Felix Juefei-Xu, Foutse Khomh, Bhavya Kailkhura, Hannah Rose Kirk, Kevin Klyman, Chris Knotz, Michael Kuchnik, Shachi H. Kumar, Srijan Kumar, Chris Lengerich, Bo Li, Zeyi Liao, Eileen Peters Long, Victor Lu, Sarah Luger, Yifan Mai, Priyanka Mary Mammen, Kelvin Manyeki, Sean McGregor, Virendra Mehta, Shafee Mohammed, Emanuel Moss, Lama Nachman, Dinesh Jinenhally Naganna, Amin Nikanjam, Besmira Nushi, Luis Oala, Iftach Orr, Alicia Parrish, Cigdem Patlak, William Pietri, Forough Poursabzi-Sangdeh, Eleonora Presani, Fabrizio Puletti, Paul Röttger, Saurav Sahay, Tim Santos, Nino Scherrer, Alice Schoenauer Sebag, Patrick Schramowski, Abolfazl Shahbazi, Vin Sharma, Xudong Shen, Vamsi Sistla, Leonard Tang, Davide Testuggine, Vithursan Thangarasa, Elizabeth Anne Watkins, Rebecca Weiss, Chris Welty, Tyler Wilbers, Adina Williams, Carole-Jean Wu, Poonam Yadav, Xianjun Yang, Yi Zeng, Wenhui Zhang, Fedor Zhdanov, Jiacheng Zhu, Percy Liang, Peter Mattson, and Joaquin Vanschoren. MLCommons 人工智能安全基准 v0.5 介绍（Introducing v0.5 of the ai safety benchmark from mlcommons）, 2024. URL https://arxiv.org/abs/2404.12241.

[38] Yuxia Wang, Haonan Li, Xudong Han, Preslav Nakov, and Timothy Baldwin. Do-Not-Answer：用于评估大语言模型安全防护的数据集（Do-not-answer: A dataset for evaluating safeguards in llms）, 2023.

[39] Laura Weidinger, John Mellor, Maribeth Rauh, Conor Griffin, Jonathan Uesato, Po-Sen Huang, Myra Cheng, Mia Glaese, Borja Balle, Atoosa Kasirzadeh, et al. 语言模型造成危害的伦理与社会风险（Ethical and social risks of harm from language models）. *arXiv preprint arXiv:2112.04359*, 2021.

[40] Marcos Zampieri, Shervin Malmasi, Preslav Nakov, Sara Rosenthal, Noura Farra, and Ritesh Kumar. SemEval-2019 任务 6：识别与分类社交媒体中的冒犯性语言（OffensEval）（Semeval-2019 task 6: Identifying and categorizing offensive language in social media

(offenseval)). In *Proceedings of the 13th International Workshop on Semantic Evaluation*, pp. 75–86, 2019.

[41] Wenting Zhao, Xiang Ren, Jack Hessel, Claire Cardie, Yejin Choi, and Yuntian Deng. WildChat：真实场景中的一百万条 ChatGPT 交互日志（Wildchat: 1m chatgpt interaction logs in the wild）, 2024.

[42] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Tianle Li, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zhuohan Li, Zi Lin, Eric. P Xing, Joseph E. Gonzalez, Ion Stoica, and Hao Zhang. LMSYS-Chat-1M：大规模真实场景大语言模型对话数据集（Lmsys-chat-1m: A large-scale real-world llm conversation dataset）, 2023.

[43] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, et al. 利用 MT-Bench 与 Chatbot Arena 评估充当裁判的大语言模型（Judging llm-as-a-judge with mt-bench and chatbot arena）. *Advances in Neural Information Processing Systems*, 36, 2024.

[44] Andy Zou, Zifan Wang, J Zico Kolter, and Matt Fredrikson. 针对已对齐语言模型的通用且可迁移的对抗攻击（Universal and transferable adversarial attacks on aligned language models）. *arXiv preprint arXiv:2307.15043*, 2023.

**表 10:** WildGuardMix 中合成提示所覆盖的细粒度风险分类体系。

| 大类 | 子类 | 对抗训练数 | 常规训练数 | 对抗测试数 | 常规测试数 |
|---|---|---|---|---|---|
| 隐私 | 敏感信息（组织） | 1,264 | 1,801 | 26 | 24 |
| | 私人信息（个人） | 1,527 | 1,008 | 24 | 57 |
| | 侵犯版权 | 264 | 1,507 | 22 | 9 |
| 错误信息 | 虚假或误导性信息 | 1,437 | 2,647 | 22 | 22 |
| | 错误信息造成的实质性伤害 | 600 | 882 | 24 | 21 |
| 有害语言 | 社会刻板印象与歧视 | 3,165 | 3,178 | 23 | 53 |
| | 暴力与人身伤害 | 780 | 2,121 | 22 | 18 |
| | 有毒语言／仇恨言论 | 1,056 | 1,964 | 22 | 19 |
| | 性内容 | 444 | 1,712 | 27 | 20 |
| 恶意用途 | 网络攻击 | 450 | 1,149 | 31 | 17 |
| | 欺诈与协助违法活动 | 1,116 | 1,164 | 31 | 29 |
| | 鼓励不道德／不安全行为 | 762 | 1,658 | 24 | 22 |
| | 心理健康与过度依赖危机 | 582 | 1,231 | 26 | 21 |
| 其他危害 | | 7,100 | 553 | 17 | 81 |
| 无害 | | 20,389 | 11,849 | 455 | 490 |

## A.7 公开的标注者编写数据

我们通过不同渠道从 HH-RLHF [5] 和 Anthropic Red-Teaming 数据集 [11] 中共获取 9,491 个提示：从 HH-RLHF 的有帮助性划分中抽取的 6,000 个无害提示；从 HH-RLHF 的无害性提示中抽取的 149 个提示；构成 AegisSafetyTrain 数据集 [13] 的 3,099 个 HH-RLHF 提示（1,102 个无害提示，1,997 个有害提示）；以及构成 Safety-Tuned Llamas [7] 的 243 个 Anthropic Red Teaming Dataset 提示。我们使用 GPT-4 赋予有害性标签。 这一全面且多样化的提示集合增强了我们的数据集，使其更能体现真实世界场景中人类交互的复杂性。

**表 14:** 第4节用于全面评估内容审核工具的基准列表。Resp. 表示模型回答；* 表示为降低评估成本而对测试集进行了子采样。

| 名称 | 对抗性提示数 | 提示有害性样本数 无害／有害 | 回答有害性样本数 无害／有害 | 回答拒绝样本数 拒绝／遵从 |
|---|---|---|---|---|
| ToxicChat [23] | 91 | 2,491/362 | × | × |
| OpenAI Mod [24] | × | 1,158/522 | × | × |
| AegisSafetyTest [13] | × | 126/233 | × | × |
| SimpleSafetyTests [36] | × | 0/100 | × | × |
| Harmbench 提示 [25] | × | 0/239 | × | × |
| Harmbench 回答 [25] | 569 | × | 329/273 | × |
| BeaverTails [18] | × | × | 1,288/1,733* | × |
| SafeRLHF [9] | × | × | 1,000/1,000* | × |
| XSTest-Resp [30] | × | × | 368/78 | 178/271 |
| WildGuardTest | 796 | 946/810 | 1,467/299 | 597/1,180 |

**ToxicChat Test Set（测试集）** [23] 是一个数据集的测试划分；该数据集包含从 LMSYS 托管的 Vicuna 在线演示[10]收集的真实用户请求及其有害性标签。人工标注了 2,853 个提示，标签包括提示有害性，以及提示是否具有对抗性。

**OpenAI Moderation Dataset** [28] 是一个评估数据集，包含 1,680 个带有提示有害性标签的提示，覆盖八个风险类别。风险类别包括性内容、仇恨、暴力、骚扰、自我伤害、性内容/未成年人、仇恨/威胁以及暴力/血腥内容。

**Aegis Safety Test** [13] 是一个安全数据集的测试划分，其构建方式为使用 HH-RLHF 无害性提示中的提示，由 Mistral-7B-v0.1 生成续写，随后进行人工标注。我们使用仅含提示的数据（359 个条目），因为其数据集的最新发布版本不包含对话中各轮的发言，因此无法将其用作回答有害性分类数据。该数据集覆盖 13 个风险类别：仇恨/身份仇恨、性内容、暴力、自杀与自我伤害、威胁、涉及未成年人的性内容、枪支/非法武器、受管制/监管物质、犯罪策划/供述、个人身份信息（PII）、骚扰、粗俗用语以及其他。它还包含 （ ）类别，用于处理模糊情况。

**SimpleSafetyTests** [36] 是一个评估集，包含与高度敏感和有害主题有关的提示，例如虐待儿童、自杀与自我伤害、进食障碍、骗局与欺诈、非法物品以及身体伤害。该数据集包含作者手动编写的 100 个有害提示。

**Harmbench Prompt** [25] 是一个评估数据集，包含 239 个可能诱导 LLM 产生有害行为的有害提示。该数据集最初用于评估 LLM 对越狱攻击的稳健性，但我们将其用于提示有害性任务。该数据集提供了功能类别，我们仅选取 和 类别，因为多模态和上下文类别不适合我们的使用场景。

[10] https://chat.lmsys.org/

**Harmbench Response** [25] 是一个评估数据集，包含 602 个带有回答有害性标签的提示与回答对。该数据集同时包含常规提示和对抗性提示，其中对抗性提示是由多种自动越狱方法创建的有害提示。

**BeaverTails Test Set（测试集）** [18] 是一个人工标注数据集的测试划分，包含 33.4K 个带有有害性标签的提示与回答条目，用于回答有害性任务。提示来自 HH-RLHF 的红队测试划分和 Sun et al. [31]，回答由 Alpaca-7B 模型生成，随后进行人工标注。该数据集覆盖 14 个有害内容类别：虐待动物、虐待儿童、争议性话题/政治、歧视/刻板印象/不公正、药物滥用/武器/违禁物质、金融犯罪/财产犯罪/盗窃、仇恨言论/冒犯性语言、有关伦理/法律/安全的错误信息、非暴力的不道德行为、侵犯隐私、自我伤害、露骨性内容/成人内容、恐怖主义/有组织犯罪以及暴力/协助/教唆/煽动。我们抽取 3,021 个条目的子样本，以降低评估成本。

**SafeRLHF Test Set（测试集）** [9] 是一个偏好数据集的测试划分，每个条目包含一个提示、其后的两个回答，以及对这两个回答的比较。它与 BeaverTails 数据集使用相同的提示，但更侧重比较数据，且比较结果（人类偏好）由人工标注。我们仅选取同一提示同时具有安全回答和不安全回答的条目，并抽取 1K 个带有回答对的提示，以降低评估成本。

# D 现有内容审核工具的更多细节

## D.1 基于开源语言模型的工具

**LibrAI-LongFormer-ref** [11] 是一个拒绝分类器，其输入为模型回答（不含用户提示），输出为六个类别之一的标签，用来描述模型回答，从 （0）到 （5）。为了将这些标签映射到我们的遵从/拒绝二分类方案中，我们将输出 5 解释为遵从，将其余所有类别解释为拒绝。

**LibrAI-LongFormer-harm** [12] 是 LongFormer [6] 的另一个版本，经过训练以对回答中的有害内容进行分类。该模型作为 Do-Not-Answer 基准 [38] 的一部分进行了微调，用于检测模型对有害提示所作回答中的有害内容。它仅接收模型回答作为输入，并输出一个二元标签，表示该回答是否有害。

**MD-Judge** [13] 是作为 SALAD-Bench [22] 一部分、基于 Mistral-7B 训练的分类器。其训练数据集并未公开，但据报告，其中包含公开及自行生成的问答（提示与回答）对，同时涵盖常规提示和对抗性提示。该模型接收提示和回答作为输入，对回答的有害性进行分类。

[11] https://huggingface.co/LibrAI/longformer-action-ro
[12] https://huggingface.co/LibrAI/longformer-harmful-ro
[13] https://huggingface.co/OpenSafetyLab/MD-Judge-v0.1

**Llama-Guard** [14] 是一个基于 Llama-2 7B 的指令微调模型，能够对输入提示和模型回答中的有害内容进行分类 [16]。该模型的训练使用从 Anthropic Red Teaming 数据集 [11] 中抽样的提示，配以其专有的回答及提示有害性、回答有害性标签，并加入其内部的红队测试提示进行扩充。该模型共使用 13K 个条目训练，但其训练数据无法公开获取。

**Llama-Guard2** [15] 是 Llama-Guard 的下一代改进版本，是一个基于 Llama-3 8B 的指令微调模型 [26]。其训练集以 Llama-Guard 训练集为起点，通过扩充现有提示、使其标签发生翻转，从而重点关注困难样例。

**Aegis-Guard** [13] 是一个基于 Llama-Guard 、使用低秩适配（LoRA）的参数高效指令微调模型。其训练集由来自 HH-RLHF 的 10,798 个提示、`Mistral-7B-v0.1` 生成的对应回答，以及人工标注的有害性标签组成。其风险分类体系包含 `Needs Caution` 类别，以考虑模糊情况。Aegis-Guard 有两个变体：Aegis-Guard-Defensive[16] 将 `Needs Caution` 情况分类为有害，而 Aegis-Guard-Permissive[17] 将其分类为无害。

**Harmbench 分类器** 是在 Harmbench [25] 中为评估越狱攻击成功率而训练的模型。这些分类器有两个变体，一个基于 Llama-2-13b[18]，另一个基于 Mistral-7b[19]。这些模型通过蒸馏 GPT-4 进行训练，直到在验证集上与 GPT-4 呈现较高一致性；不过，其分类器的训练数据并未披露。

**BeaverDam-7B** [18] 是一个基于 Llama-7B 的分类器，在仅包含回答有害性数据的 BeaverTails 训练数据集上进行微调。

### D.2 GPT-4 分类

表 15 展示了我们用于 GPT-4 分类的提示。我们搜索并比较了多种提示变体，包括提供额外指导以及提示进行思维链推理，发现该提示在各项评估中的总体表现最佳。我们在所有 GPT-4 分类中均使用 `gpt-4-0125-preview`。

### D.3 基于关键词的拒绝检测

为了开发基于关键词的拒绝检测器，我们人工检查了拒绝回答的实例，以识别常见模式。完整关键词列表见表 16。

[14] https://huggingface.co/meta-llama/LlamaGuard-7b
[15] https://huggingface.co/meta-llama/Meta-Llama-Guard-2-8B
[16] https://huggingface.co/nvidia/Aegis-AI-Content-Safety-LlamaGuard-Defensive-1.0
[17] https://huggingface.co/nvidia/Aegis-AI-Content-Safety-LlamaGuard-Permissive-1.0
[18] https://huggingface.co/cais/HarmBench-Llama-2-13b-cls
[19] https://huggingface.co/cais/HarmBench-Mistral-7b-val-cls

# F 扩展结果

## F.1 WildGuard 的基座模型比较

**表 17:** 使用不同基座模型在 WildGuardTrain 上训练所得模型的表现。分数为 F1（%）。本文使用 `Mistral-7B-v0.3` 作为训练 WildGuard 的基座模型，但结果表明，选择 `Mistral-7B-v0.3` 并未带来显著提升，这凸显了 WildGuardTrain 的重要性与有效性。

| 基座模型 | 提示有害性 | | | 回答有害性 | | | 拒绝检测 | | |
|---|---|---|---|---|---|---|---|---|---|
| | 公开集 | WGTest | | 公开集 | WGTest | | XSTest | WGTest | |
| | 平均 F1 | 对抗 F1 | 总体 F1 | 平均 F1 | 对抗 F1 | 总体 F1 | F1 | 对抗 F1 | 总体 F1 |
| **`Mistral-7B-v0.3`** | 86.1 | 85.5 | 88.9 | 82.4 | 68.4 | 75.4 | 92.8 | 88.5 | 88.6 |
| `Gemma-7B` | 86.0 | 84.2 | 88.2 | 78.8 | 64.9 | 75.0 | 93.7 | 90.8 | 90.1 |
| `Llama2-7B` | 86.0 | 85.5 | 89.5 | 79.1 | 65.3 | 75.1 | 92.0 | 87.8 | 87.5 |
| `Tulu2-SFT-7B` | 87.0 | 84.9 | 89.1 | 81.0 | 72.6 | 78.7 | 93.0 | 87.9 | 88.7 |
| `Llama3-8B` | 86.0 | 84.2 | 88.6 | 81.8 | 69.8 | 77.3 | 93.8 | 88.5 | 88.4 |
| `OLMo-1.7-7B` | 85.9 | 84.8 | 88.4 | 79.7 | 67.5 | 76.2 | 94.1 | 88.6 | 86.6 |

表 17 展示了使用不同基座模型在 WildGuardTrain 上训练时的评估结果。结果显示，不同基座模型之间的差异很小，说明 WildGuard 的成功依赖于 WildGuardTrain 。值得注意的是，当我们使用 Llama2-7B 和 Llama3-8B 时，模型显著超越 Llama-Guard 和 Llama-Guard2 ，突出了 WildGuardTrain 的有效性。

## F.2 完整评估结果

表 18、19 和 20 报告了在所有公开基准及 WildGuardTest 上的完整评估结果。

## F.3 WildGuard 作为人类与 LLM 交互内容审核器的更多演示结果

表 21 进一步以 Llama3-8B-Instruct 为基座模型进行测试，并测试了在交互中将 WildGuard 及其他基线作为内容审核器的表现。结果同样表明，相较于各个基线，WildGuard 的 ASR 最低，而 RTA 仅略有上升，体现了 WildGuard 的有效性。

**表 18:** 提示有害性分类任务的完整评估结果，包括全部基线、消融实验，以及使用不同基座模型训练 WildGuard 的结果。所有结果均为 F1（%）。

| 模型 | 公开基准 | | | | | | WildGuardTest | | |
|---|---|---|---|---|---|---|---|---|---|
| | ToxiC | OAI | Aegis | SimpST | HarmB | **平均 F1** | 对抗 | 常规 | **总体 F1** |
| **与基线的比较** | | | | | | | | | |
| Llama-Guard | 61.6 | 75.8 | 74.1 | 93.0 | 67.2 | 74.4 | 32.6 | 70.5 | 56.0 |
| Llama-Guard2 | 47.1 | 76.1 | 71.8 | 95.8 | 94.0 | 77.0 | 46.1 | 85.6 | 70.9 |
| Aegis-Guard-D | 70.0 | 67.5 | 84.8 | 100.0 | 77.7 | 80.0 | 74.5 | 82.0 | 78.5 |
| Aegis-Guard-P | 73.0 | 74.7 | 82.9 | 99.0 | 70.5 | 80.0 | 62.9 | 77.9 | 71.5 |
| OpenAI Moderation API | 25.4 | 79.0 | 31.9 | 63.0 | 9.6 | 41.8 | 6.8 | 16.3 | 12.1 |
| GPT-4 | 68.3 | 70.5 | 84.4 | 100.0 | 100.0 | 84.6 | 81.6 | 93.4 | 87.9 |
| WildGuard | 70.8 | 72.1 | 89.4 | 99.5 | 98.9 | 86.1 | 85.5 | 91.7 | 88.9 |
| **消融实验** | | | | | | | | | |
| WildGuardTrain | 70.8 | 72.1 | 89.4 | 99.5 | 98.9 | 86.1 | 85.5 | 91.7 | 88.9 |
| – 合成对抗性 | 71.1 | 75.3 | 90.9 | 99.0 | 86.7 | 84.6 | 77.1 | 90.7 | 84.4 |
| – 合成常规 | 75.3 | 73.5 | 90.6 | 99.5 | 79.3 | 83.6 | 85.7 | 93.4 | 89.8 |
| – In-the-Wild | 60.5 | 69.8 | 90.2 | 99.0 | 100.0 | 83.9 | 84.6 | 92.2 | 88.7 |
| – 标注员撰写 | 71.5 | 71.1 | 79.4 | 96.4 | 99.4 | 83.6 | 84.8 | 88.5 | 86.8 |
| 仅单任务 | 73.0 | 71.9 | 90.8 | 99.5 | 100.0 | 87.0 | 84.2 | 91.6 | 88.2 |
| **基座模型变体** | | | | | | | | | |
| **`Mistral-7B-v0.3`** | 70.8 | 72.1 | 89.4 | 99.5 | 98.9 | 86.1 | 85.5 | 91.7 | 88.9 |
| `Gemma-7B` | 72.8 | 73.8 | 87.2 | 99.5 | 96.5 | 86.0 | 84.2 | 91.3 | 88.2 |
| `Llama2-7B` | 73.8 | 72.8 | 89.1 | 99.5 | 94.7 | 86.0 | 85.5 | 92.9 | 89.5 |
| `Tulu2-SFT-7B` | 73.4 | 71.9 | 90.3 | 99.5 | 99.8 | 87.0 | 84.9 | 92.6 | 89.1 |
| `Llama3-8B` | 71.1 | 71.7 | 89.6 | 99.5 | 98.1 | 86.0 | 84.2 | 92.2 | 88.6 |
| `OLMo-1.7-7B` | 72.6 | 71.5 | 90.0 | 99.5 | 96.1 | 85.9 | 84.8 | 91.4 | 88.4 |

**表 19:** 回答有害性分类任务的完整评估结果，包括全部基线、消融实验，以及使用不同基座模型训练 WildGuard 的结果。所有结果均为 F1（%）。

| 模型 | 公开基准 | | | | | WildGuardTest | | |
|---|---|---|---|---|---|---|---|---|
| | HarmB | S-RLHF | BeaverT | XST | **平均 F1** | 对抗 | 常规 | **总体 F1** |
| **与基线的比较** | | | | | | | | |
| Llama-Guard | 52.0 | 48.4 | 67.1 | 82.0 | 62.4 | 25.8 | 66.7 | 50.5 |
| Llama-Guard2 | 77.8 | 51.6 | 71.8 | 90.8 | 73.0 | 47.9 | 78.2 | 66.5 |
| Aegis-Guard-D | 62.2 | 59.3 | 74.7 | 52.8 | 62.3 | 40.4 | 57.6 | 49.1 |
| Aegis-Guard-P | 60.8 | 55.9 | 73.8 | 60.4 | 62.7 | 49.0 | 62.4 | 56.4 |
| HarmB-Llama | 84.3 | 60.0 | 77.1 | 64.5 | 71.5 | 41.9 | 50.2 | 45.7 |
| HarmB-Mistral | 87.0 | 52.4 | 75.2 | 72.0 | 71.7 | 51.8 | 70.3 | 60.1 |
| MD-Judge | 81.6 | 64.7 | 86.7 | 90.4 | 80.9 | 67.7 | 85.0 | 76.8 |
| BeaverDam | 58.4 | 72.1 | 89.9 | 83.6 | 76.0 | 51.2 | 74.3 | 63.4 |
| LibriAI-LongFormer-Harm | 62.1 | 50.6 | 67.1 | 70.9 | 62.7 | 61.7 | 64.2 | 63.2 |
| LibriAI-LongFormer-Refu | 67.6 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 |
| 关键词检测器 | 72.7 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 |
| OpenAI Moderation API | 20.6 | 10.1 | 15.7 | 46.6 | 23.2 | 14.7 | 18.8 | 16.9 |
| GPT-4 | 86.1 | 67.9 | 83.0 | 91.3 | 82.0 | 73.6 | 81.3 | 77.3 |
| WildGuard | 86.3 | 64.2 | 84.4 | 94.7 | 82.4 | 68.4 | 81.5 | 75.4 |
| **消融实验** | | | | | | | | |
| WildGuardTrain | 86.3 | 64.2 | 84.4 | 94.7 | 82.4 | 68.4 | 81.5 | 75.4 |
| – 合成对抗性 | 85.8 | 60.0 | 82.5 | 86.3 | 78.6 | 67.8 | 79.7 | 73.9 |
| – 合成常规 | 85.6 | 61.3 | 82.8 | 95.5 | 81.3 | 66.9 | 82.5 | 75.5 |
| – In-the-Wild | 87.4 | 62.7 | 83.7 | 94.0 | 81.9 | 69.5 | 82.7 | 76.5 |
| – 标注员撰写 | 87.6 | 56.8 | 79.6 | 81.8 | 76.4 | 66.4 | 81.9 | 74.7 |
| 仅单任务 | 87.2 | 57.5 | 78.5 | 82.6 | 76.4 | 67.2 | 81.8 | 74.8 |
| **基座模型变体** | | | | | | | | |
| `Mistral-7B-v0.3` | 86.3 | 64.2 | 84.4 | 94.7 | 82.4 | 68.4 | 81.5 | 75.4 |
| `Gemma-7B` | 86.3 | 57.6 | 81.5 | 89.9 | 78.8 | 64.9 | 83.3 | 75.0 |
| `Llama2-7B` | 84.7 | 59.7 | 81.8 | 90.4 | 79.1 | 65.3 | 83.6 | 75.1 |
| `Tulu2-SFT-7B` | 86.1 | 63.8 | 82.9 | 91.4 | 81.0 | 72.6 | 84.2 | 78.7 |
| `Llama3-8B` | 86.9 | 62.5 | 83.8 | 94.0 | 81.8 | 69.8 | 83.6 | 77.3 |
| `OLMo-1.7-7B` | 83.5 | 61.7 | 82.9 | 90.5 | 79.7 | 67.5 | 83.5 | 76.2 |

**表 20:** 拒绝检测任务的完整评估结果，包括全部基线、消融实验，以及使用不同基座模型训练 WildGuard 的结果。所有结果均为 F1（%）。

| 模型 | XSTest-Resp | WildGuardTest | | |
|---|---|---|---|---|
| | F1 | 对抗 | 常规 | **总体 F1** |
| **与基线的比较** | | | | |
| Llama-Guard | 62.9 | 45.1 | 56.9 | 51.4 |
| Llama-Guard2 | 64.1 | 47.9 | 58.8 | 53.8 |
| Aegis-Guard-D | 44.2 | 38.9 | 44.0 | 41.8 |
| Aegis-Guard-P | 48.5 | 45.4 | 48.2 | 46.9 |
| HarmB-Llama | 72.5 | 74.0 | 72.5 | 73.1 |
| HarmB-Mistral | 68.6 | 56.1 | 60.5 | 58.6 |
| MD-Judge | 65.2 | 50.6 | 59.4 | 55.5 |
| BeaverDam | 65.1 | 48.4 | 58.8 | 54.1 |
| LibriAI-LongFormer-Harm | 70.9 | 61.7 | 62.7 | 62.3 |
| OpenAI Moderation API | 58.6 | 44.5 | 54.3 | 49.8 |
| GPT-4 | 98.1 | 91.4 | 93.5 | 92.4 |
| WildGuard | 92.8 | 88.5 | 88.6 | 88.6 |
| **消融实验** | | | | |
| WildGuardTrain | 92.8 | 88.5 | 88.6 | 88.6 |
| – 合成对抗性 | 94.1 | 88.3 | 87.2 | 87.6 |
| – 合成常规 | 90.2 | 85.7 | 84.4 | 84.9 |
| – In-the-Wild | 93.0 | 88.0 | 88.9 | 88.6 |
| – 标注员撰写 | 94.9 | 87.8 | 88.7 | 88.4 |
| 仅单任务 | 93.3 | 87.0 | 87.3 | 87.1 |
| **基座模型变体** | | | | |
| `Mistral-7B-v0.3` | 92.8 | 88.5 | 88.6 | 88.6 |
| `Gemma-7B` | 93.7 | 90.8 | 89.5 | 90.1 |
| `Llama2-7B` | 92.0 | 87.8 | 87.4 | 87.5 |
| `Tulu2-SFT-7B` | 93.0 | 87.9 | 89.3 | 88.7 |
| `Llama3-8B` | 93.8 | 88.5 | 88.6 | 88.4 |
| `OLMo-1.7-7B` | 94.1 | 86.6 | 86.7 | 86.6 |

**表 21:** 在人类与大语言模型交互中使用 WildGuard 进行内容审核的补充结果。在 WildJailbreak 验证集上，利用分类模型过滤有害提示和回答时，有害提示的 ASR 与无害提示的 RTA 指标。

| 过滤器 \ 模型 | Llama3-8B-Inst (ASR (%, ↓) / RTA (%, ↓)) |
|---|---|
| × | 17.4/**7.6** |
| WildGuard | **1.1**/8.0 |
| Llama-Guard2 | 14.2/8.4 |
| Aegis-Guard-D | 6.0/20.8 |
| Aegis-Guard-P | 12.2/10.0 |
| MD-Judge | 10.1/10.8 |